

CHAPITRE

II

ÉTAT DE L'ART DU DOWNSCALING PAR APPRENTISSAGE PROFOND

II.1 Introduction	29
II.2 Approches déterministes	30
II.3 Approches probabilistes adversariales	32
II.4 Approches à vraisemblance explicite	33
II.5 Modèles de diffusion	34
II.6 Le paradigme à deux étages : CorrDiff	35
II.7 Fonctions de perte et contraintes physiques	37
II.8 Cadres d'évaluation et foundation models	39
II.9 Synthèse, tableau comparatif et gap scientifique	40

II.1. Introduction

Le chapitre précédent a identifié un trilemme pour le downscaling climatique génératif (section I.7) : stabilité d'entraînement, réalisme des extrêmes et robustesse sous changement de distribution apparaissent inconciliables dans les approches existantes. Le présent chapitre confronte cette analyse au paysage effectif de la littérature, des CNN déterministes

aux modèles de diffusion à deux étages. Nous abordons successivement les approches déterministes (section II.2), adversariales (section II.3), à vraisemblance explicite (section II.4) et de diffusion (section II.5), avant de détailler le paradigme CORRDIFF (section II.6) dont notre proposition est la causalisation. Pertes (section II.7) et cadres d'évaluation (section II.8) complètent la revue ; la synthèse (section II.9) identifie le gap qui motive notre contribution.

Figure F1 (Chap II) à produire — frise chronologique du downscaling profond 2017-2026 : SRCNN (2014), DeepSD (2017), U-Net climat, Rampal cGAN (2024), Ho DDPM (2020), Karras EDM (2022), Saharia SR3 (2022), Mardani CorrDiff (2023), foundation models ClimaX (2023) / GraphCast (2023) / GenCast (2024).

Figure 1 — *Frise chronologique des principales contributions du downscaling climatique profond. Le glissement progressif du paradigme déterministe vers le paradigme génératif à deux étages est visible à partir de 2020.*

La figure 1 situe chronologiquement les contributions examinées : glissement déterministe → génératif à partir de 2020, accélération après 2022 sous l'effet conjoint des modèles de diffusion et de la maturation des GCM haute résolution.

II.2. Approches déterministes

II.2.1. Régression statistique classique

Les approches statistiques de première génération — régression linéaire, *Bias Correction* (BC), *Quantile Mapping* (QM), perfect prog — ont été présentées au chapitre précédent (section ??). Elles partagent trois limites structurelles : stationnarité de la relation prédicteurs-prédictands, absence de cohérence spatiale (traitement pixel par pixel), et absence de calibration probabiliste. D'où l'introduction de méthodes

d'apprentissage non-linéaires structurées spatialement.

II.2.2. Réseaux convolutifs et super-résolution

L'application des CNN au downscaling s'est inspirée des architectures de super-résolution d'image, d'abord SRCNN [1] puis EDSR [2]. **DeepSD** [3] fut l'une des premières architectures CNN dédiées au downscaling de la précipitation, par empilement de convolutions à champ réceptif croissant. Le **U-Net** [4] a connu une adoption massive, particulièrement sous sa forme conditionnée par des champs de surface (élévation). D'autres variantes (**PAN** [5], modules d'attention spatiale, pyramides de caractéristiques) ont été explorées.

Ces approches partagent une limite décisive : produisant une unique sortie HR par entrée, elles approximent la moyenne conditionnelle de la distribution cible. Pour la précipitation à queue lourde, cette moyenne est biaisée à la baisse aux valeurs élevées, d'où le lissage des extrêmes documenté dans la littérature.

II.2.3. Architectures déterministes avancées

La période 2021-2023 a vu émerger des architectures plus sophistiquées, regroupées ici car elles partagent la même limite probabiliste que les CNN. Les **opérateurs neuronaux de Fourier** (FNO) [6] et leur variante sphérique **SFNO** [7] apprennent des opérateurs entre fonctions par représentation spectrale, prometteurs en prévision globale mais expérimentaux en downscaling régional. Les **Transformers de vision** appliqués à la super-résolution, notamment **SwinIR** [8] et son adaptation climat **PrecipFormer** [9], exploitent l'attention pour capter des dépendances longues. Toutes conservent la limite fondamentale du déterminisme : pas de distribution conditionnelle calibrée, donc le verrou « réalisme des extrêmes » reste non adressé.

II.3. Approches probabilistes adversariales

II.3.1. Réseaux antagonistes génératifs conditionnels

Le glissement vers le probabiliste a d'abord été opéré par les **réseaux antagonistes génératifs** (GAN) [10] et leur variante conditionnelle (cGAN) [11]. Un générateur G transforme un bruit $z \sim \mathcal{N}(0, I)$ et un conditionnement y_{LR} en échantillon plausible $\hat{x}_{HR} = G(y_{LR}, z)$; un discriminateur D apprend à distinguer vrais et faux. L'entraînement min-max alterne ces objectifs opposés. Appliqué au downscaling, le cGAN promet un ensemble d'échantillons HR plausibles permettant en principe d'estimer la variabilité prédictive et la distribution des extrêmes.

II.3.2. cGAN résiduel pour le downscaling climatique

Une architecture représentative est le **Residual cGAN** de Rampal et al. [12], qui combine un U-Net déterministe pré-entraîné et un cGAN sur le résidu : le générateur reçoit la prédiction U-Net, l'élévation HR, le champ GCM et un bruit, et produit une carte résiduelle additionnée à la prédiction déterministe. L'application à la Nouvelle-Zélande (CMIP6 ACCESS-CM2) combine trois termes de coût : MSE, perte adversariale pondérée par λ_{adv} , et contrainte d'intensité pénalisant la surestimation des extrêmes.

D'autres travaux apparentés incluent Harris et al. [13] (désagrégation de précipitations sur domaine européen) et Price et Rasp [14] (prévision d'extrêmes à court terme via GAN).

II.3.3. Limites empiriques des cGAN appliqués au downscaling

Quatre limites empiriques caractérisent la famille adversariale. (i) **Forte sensibilité à λ_{adv}** : la performance sur les extrêmes suit une

courbe en cloche (trop faible $\Rightarrow$ lissage par la MSE ; trop élevé $\Rightarrow$ surestimation), avec un optimum étroit et peu transférable. (ii) **Subdispersion** : les analyses de Rampal et al. [12] et Mardani et al. [25] rapportent $\sigma_{\text{pred}}/\text{RMSE} < 0,5$, ensembles systématiquement trop confiants. (iii) **Risque de *mode collapse***, intrinsèque au cadre adversarial, latent même s'il n'est pas systématiquement observé en pratique. (iv) **Validité restreinte du cadre d'évaluation** : tests menés majoritairement sur couples synthétiques RCM-LR/RCM-HR (cadre « parfait »), la transférabilité aux conditions opérationnelles GCM brut restant incertaine.

II.4. Approches à vraisemblance explicite

Les **auto-encodeurs variationnels** (VAE) [15] apprennent une représentation latente probabiliste en maximisant la borne inférieure de la log-vraisemblance (ELBO). Appliqués au downscaling [16], ils produisent des sorties probabilistes mais souffrent d'un excès de lissage lié à l'ELBO et à la dimension réduite de l'espace latent. Les **flots de normalisation** appliquent une séquence de transformations inversibles différentiables à un bruit gaussien et autorisent l'évaluation exacte de la vraisemblance via le déterminant jacobien. Leur application au downscaling [17] a fourni des résultats compétitifs, mais l'expressivité reste bornée par la contrainte d'inversibilité.

Ces deux familles n'atteignent pas le niveau des GAN ou de la diffusion en downscaling climatique. Leur intérêt méthodologique — évaluation exacte de la vraisemblance — ne compense pas une expressivité insuffisante face aux extrêmes à queue lourde et à l'hétérogénéité spatiale de la précipitation fine. Elles restent à ce jour davantage des objets d'étude méthodologique que des candidats sérieux au downscaling opérationnel.

II.5. Modèles de diffusion

II.5.1. Denoising Diffusion Probabilistic Models

Les **Denoising Diffusion Probabilistic Models** (DDPM) [18] définissent un processus direct qui bruite progressivement le signal et apprennent à inverser ce processus pour reconstruire des échantillons. Le processus direct est une chaîne de Markov gaussienne :

$$q(x_t | x_{t-1}) = \mathcal{N}(x_t; \sqrt{1 - \beta_t} x_{t-1}, \beta_t I), \quad (\text{II.1})$$

avec un calendrier de variance $(\beta_t)_{t=1}^T$. L'objectif simplifié réduit l'apprentissage à la prédiction du bruit :

$$\mathcal{L}_{\text{simple}}(\theta) = \mathbb{E}_{t, x_0, \epsilon} [\|\epsilon - \epsilon_\theta(x_t, t)\|^2], \quad (\text{II.2})$$

où ϵ_θ est typiquement un U-Net. L'échantillonnage inverse part d'un bruit pur. Face aux GAN, DDPM offre trois avantages pour le downscaling : entraînement stable sans déséquilibre adversarial, expressivité multimodale sans collapse, et calibration probabiliste intrinsèque liée à la vraisemblance variationnelle.

II.5.2. Formalisme EDM de Karras et al.

Le formalisme EDM [19] reformule la diffusion dans un cadre théorique général. Sa contribution principale est un **préconditionnement systématique** de l'entrée et de la sortie via quatre fonctions $c_{\text{in}}, c_{\text{out}}, c_{\text{noise}}, c_{\text{skip}}$ dépendant de σ , qui unifie DDPM/score matching/VP/VE et stabilise l'entraînement. Le sampler de Heun à pas variable atteint une qualité comparable à DDPM avec moitié moins d'étapes. La calibration de σ_{data} (écart-type des données normalisées) est cruciale.

II.5.3. Premières applications au climat : SR3, ResShift, ResDiff

SR3 [20] (*Super-Resolution via Repeated Refinement*) fut la première application notable de la diffusion conditionnelle à la super-résolution d'image, essaimant ensuite vers le climat. **ResShift** [21] accélère la diffusion par déplacement résiduel (diffusion partant de l'image LR sur-échantillonnée, corrigeant un résidu en peu d'étapes), avec une proximité manifeste vers le paradigme à deux étages de la section II.6. Pour mémoire, la version preprint de Mardani et al. [25] fut initialement nommée *Residual Corrective Diffusion* (ResDiff) avant d'être renommée CorrDiff. Plusieurs évolutions récentes (depuis 2023), non encore appliquées au downscaling, pourraient à terme remplacer l'étage de diffusion : **flow matching** [22] (champ de vecteurs de transport, échantillonnage ODE), **consistency models** [23] (échantillonnage en une étape), **diffusion latente** [24] (espace compressé). La diffusion EDM demeure notre choix de référence.

II.6. Le paradigme à deux étages : CorrDiff

II.6.1. Idée fondatrice

Le modèle CORRDIF (Corrective Diffusion) de Mardani et al. [25] (NVIDIA Research) propose un paradigme à deux étages dont la décomposition formelle est :

$$x_{\text{HR}} = \text{baseline}_{\text{LR}\uparrow} + \mu_{\text{HR}}(y_{\text{LR}}, s_{\text{HR}}) + \delta(\cdot), \quad (\text{II.3})$$

où $\text{baseline}_{\text{LR}\uparrow}$ désigne un sur-échantillonnage bilinéaire, μ_{HR} la moyenne HR apprise par régression déterministe, et δ un résidu stochastique échantillonné par diffusion conditionnée sur μ_{HR} et y_{LR} . L'application visée est le downscaling kilométrique de sorties GCM avec un facteur de

réduction de 25 à 50, le terrain initial étant Taïwan.

II.6.2. Architecture détaillée

Le premier étage est un U-Net classique entraîné par MSE entre μ_{HR} et la cible HR. Le second est un U-Net de diffusion EDM entraîné à prédire $\delta = x_{\text{HR}} - (\text{baseline}_{\text{LR}\uparrow} + \mu_{\text{HR}})$ conditionnellement à μ_{HR} et y_{LR} , avec échantillonnage de Heun à 20-50 pas.

*Figure F4 (Chap II) à produire — architecture détaillée CorrDiff :
(Étage 1) Entrée LR + élévation $\rightarrow$ U-Net régression $\rightarrow$ moyenne μ_{HR} ; (Étage 2) bruit + μ_{HR} + LR $\rightarrow$ U-Net diffusion EDM
(préconditionnement $c_{\text{in}}, c_{\text{out}}, c_{\text{noise}}, c_{\text{skip}}$) $\rightarrow$ résiduel δ via sampler de Heun.*

Figure 2 — Architecture détaillée de CORRDIFF [25]. Le premier étage régresse de manière déterministe la moyenne haute résolution μ_{HR} ; le second étage échantillonne par diffusion EDM le résiduel δ conditionnellement à l'étage 1.

II.6.3. Forces du paradigme à deux étages

Trois forces structurelles caractérisent ce paradigme. **Stabilité d'entraînement** : la régression déterministe converge facilement, et la diffusion du second étage opère sur des résidus de distribution plus proche d'une gaussienne. **Calibration probabiliste explicite** : la variance est contrôlée par le second étage, indépendamment d'un équilibre adversarial. **Efficacité computationnelle** : l'échantillonnage par diffusion est limité au seul résiduel, de plus faible amplitude.

II.6.4. Limites identifiées de CorrDiff

L'examen critique fait apparaître deux limites principales. La **persistance de la sub-dispersion** : malgré la calibration explicite du

second étage, CorrDiff reste sub-dispersif ($\sigma_{\text{pred}}/\text{RMSE}$ entre 0,3 et 0,5 selon les configurations), moins prononcée que les cGAN mais significative. **L'absence de structure causale explicite** : le premier étage est un U-Net générique apprenant $\mu_{\text{HR}}(y_{\text{LR}}, s_{\text{HR}})$ sans contrainte sur la nature des dépendances ; rien ne distingue associations causales (humidité de basse couche $\rightarrow$ précipitation convective) et corrélations contingentes au régime d'entraînement. CorrDiff est donc vulnérable au changement de distribution, sans garantie d'intervention.

II.6.5. Pourquoi CorrDiff plutôt que SR3 ?

Le baseline non-causal d'ORACLE aurait pu être choisi parmi d'autres travaux de diffusion résiduelle. ResDiff et CorrDiff désignent la même filiation chez Mardani et al. ; la question résiduelle est donc la comparaison à SR3 [20]. Trois raisons justifient CorrDiff. (i) **Décomposition formelle moyenne + résiduel** (équation II.3) cohérente avec la statistique climatique : μ_{HR} capture le forçage-réponse, δ la variabilité fine stochastique ; SR3 ne propose pas cette séparation. (ii) **Conception pour le downscaling kilométrique climatique**, prise en compte de l'intermittence, queue lourde et hétérogénéité de la précipitation ; SR3 est une méthode générique. (iii) **Cadre architectural modulaire** : l'étage 1 peut être substitué sans toucher à l'étage 2 — propriété qui permet précisément de *causaliser* l'étage 1 (U-Net $\rightarrow$ module à graphe causal) en conservant l'étage 2 EDM intact.

II.7. Fonctions de perte et contraintes physiques

II.7.1. Pertes adaptées à la précipitation

Au-delà de la MSE, la littérature a développé plusieurs pertes adaptées à la précipitation. Les **pertes spectrales** (FACL, *Fourier Amplitude Coherence Loss*) pénalisent l'écart entre spectres de Fourier pré-

dit et cible, préservant le contenu fréquentiel fin et corrigeant partiellement le lissage MSE. La **régularisation Wasserstein** (héritée des WGAN) remplace la divergence Jensen-Shannon implicite par une distance Wasserstein-1, plus stable et mieux comportée aux extrêmes. Les **pondérations spécifiques aux extrêmes** (*focal loss*, MSE pondérée par percentiles, top- k) accroissent le poids des pixels à forte intensité, concentrant l'apprentissage sur les cas extrêmes.

II.7.2. Contraintes physiques et explicabilité

Des **contraintes physiques dures** (conservation de masse, monotonie $T_{\min} \leq T \leq T_{\max}$, positivité de la précipitation) sont imposées par construction architecturale ou projection en sortie ; elles améliorent la cohérence multivariée mais ne résolvent pas les verrous probabilistes. L'**explicabilité** (XAI) appliquée au downscaling (Grad-CAM, Integrated Gradients) révèle a posteriori les zones d'entrée influentes. Notre proposition emprunte une voie complémentaire : organiser l'architecture autour d'une structure causale apprise, apportant par construction cohérence et interprétabilité.

Table 1 – *Principales fonctions de perte et contraintes utilisées en downscaling climatique profond.*

Famille	Exemples	Cas d'usage principal
Pertes spectrales	FACL	Contenu fréquentiel fin
Adversariales régularisées	Wasserstein, WGAN-GP	Stabilisation entraînement adversarial
Pondération extrêmes	Focal, top- k , MSE pondérée	Pixels à forte intensité
Contraintes dures	Conservation, monotonie, positivité	Cohérence physique multivariée
Explicabilité a posteriori	Grad-CAM, Integrated Gradients	Diagnostic des dépendances
Structure causale	DAG appris, intervention	Robustesse OOD et auditabilité (notre voie)

Le tableau 1 récapitule ces familles.

II.8. Cadres d'évaluation et foundation models

II.8.1. Benchmarks standardisés

Trois benchmarks récents tentent de remédier à la fragmentation des protocoles d'évaluation. **WeatherBench 2** [26] étend le benchmark initial à la prévision météorologique pilotée par les données (RMSE, biais, ACC sur ERA5). **ClimateBench** [27] cible la réponse à des scénarios d'émissions et l'émulation climatique. **ChaosBench** [28] se concentre sur la prévision à grande échelle et la stabilité à long horizon. Le constat principal : **aucun benchmark public ne couvre le downscaling probabiliste à haute résolution** ; sa construction reste un travail ouvert.

II.8.2. Foundation models climat

La période 2023-2024 a vu émerger des *foundation models* climat. **ClimaX** [29] (Microsoft) est un Transformer pré-entraîné sur CMIP6, capable de prévision, projection et downscaling après fine-tuning. **GraphCast** [30] et **GenCast** [31] (Google DeepMind) sont des graph neural networks entraînés sur ERA5 ayant dépassé plusieurs modèles physiques opérationnels. Le positionnement de notre travail est complémentaire : ORACLE cible le downscaling régional probabiliste, non le multi-tâche global ; la structure causale proposée pourrait à terme s'intégrer à une architecture de plus grande échelle.

II.9. Synthèse, tableau comparatif et gap scientifique

II.9.1. Tableau comparatif modèle $\times$ verrou

Le tableau 2 récapitule les approches revues selon les trois axes du tri-lemme (stabilité, extrêmes, robustesse OOD), complétés par deux axes propres à notre contribution (structure causale explicite, caractère génératif probabiliste).

Table 2 – Confrontation des principales approches du downscaling profond aux verrous du trilemme. Légende : $\checkmark$ = bien traité, $\triangle$ = partiellement traité, $\times$ = non traité. La colonne **Causal** renvoie à l'indispensabilité structurelle (propriété (O3)) qui sera formalisée au chapitre suivant.

Approche	Année	Stabilité	Extrêmes	OOD	Causal	Génératif
DeepSD / U-Net	2017	$\checkmark$	$\times$	$\times$	$\times$	$\times$
EDSR / SRCNN	2017	$\checkmark$	$\times$	$\times$	$\times$	$\times$
FNO / SFNO	2021-23	$\checkmark$	$\triangle$	$\triangle$	$\times$	$\times$
SwinIR / PrecipFormer	2021-23	$\checkmark$	$\triangle$	$\times$	$\times$	$\times$
cGAN (Harris et al.)	2022	$\triangle$	$\triangle$	$\times$	$\times$	$\checkmark$
Residual cGAN (Rampal)	2024	$\triangle$	$\triangle$	$\times$	$\times$	$\checkmark$
VAE downscaling	2022	$\checkmark$	$\times$	$\times$	$\times$	$\checkmark$
Normalizing Flow	2020	$\checkmark$	$\triangle$	$\times$	$\times$	$\checkmark$
DDPM / EDM brut	2020-22	$\checkmark$	$\checkmark$	$\triangle$	$\times$	$\checkmark$
SR3 / ResShift	2022-23	$\checkmark$	$\triangle$	$\triangle$	$\times$	$\checkmark$
CorrDiff (Mardani)	2023	$\checkmark$	$\triangle$	$\triangle$	$\times$	$\checkmark$
ClimaX (foundation)	2023	$\checkmark$	$\triangle$	$\triangle$	$\times$	$\triangle$
Oracle (proposé)	2026	$\checkmark$	$\checkmark ?$	$\checkmark ?$	$\checkmark$	$\checkmark$

II.9.2. Gap scientifique

Le tableau 2 fait apparaître un constat structurant : **aucune des approches revues ne résout simultanément les trois axes du tri-lemme**. Les plus stables (U-Net, DDPM, EDM brut) ne garantissent pas la robustesse OOD ; les plus probabilistes (CorrDiff, cGAN résiduel) restent sub-dispersives sur les extrêmes ; les plus expressives (cGAN) souffrent d'instabilité. Aucune n'incorpore par construction de struc-

ture causale explicite : c'est précisément cette absence qui motive notre contribution.

Le gap scientifique se formule comme **la non-résolution du tri-lemme par les approches existantes**. Le paradigme à deux étages de CORRDIFF couvre le mieux le triplet stabilité + extrêmes + probabiliste, mais n'adresse pas la robustesse OOD par construction. Notre proposition vise à combler ce gap en **causalisant le premier étage** : remplacer le U-Net générique estimant μ_{HR} par un module structurellement causal contraignant cette estimation à passer par un graphe de dépendances appris.

II.9.3. Positionnement d'Oracle dans le paysage

Figure F5 (Chap II) à produire — cartouche conceptuel Oracle revisité avec références numériques : $LR \rightarrow \text{Étage 1 causal (encodeur + DAG appris [Bello 2022, Pearl 2009])} \rightarrow \mu_{HR}$; $\text{bruit} + \mu_{HR} \rightarrow \text{Étage 2 diffusion EDM [Karras 2022]} \rightarrow \delta$; $\text{sortie HR} = \text{baseline} + \mu_{HR} + \delta$. Surligner « causalisation » comme contraste avec CorrDiff [Mardani 2023].

Figure 3 — Cartouche conceptuel revisité du modèle ORACLE avec ancrage bibliographique. Le premier étage causalise CORRDIFF [25] en y intégrant un graphe causal appris par contrainte DAGMA [32]; le second étage conserve la diffusion EDM [19].

La figure 3 résume la position de ORACLE. L'étage 1 est une causalisation de CORRDIFF [25], fondée sur la caractérisation différentiable de l'acyclicité de Bello et al. [32] et le formalisme SCM de Pearl [33]; l'étage 2 conserve la diffusion EDM [19]. L'architecture détaillée fait l'objet du chapitre suivant.

II.9.4. Transition vers le Chapitre III

Le chapitre suivant détaille l'architecture du module causal récurrent (*Recurrent Causal Network*, RCN) — apprentissage simultané de

la structure du graphe et de la dynamique de l'état latent, connexion au second étage de diffusion — et explicite les objectifs O1-O6, en particulier la propriété d'intervention (O3) qui garantit par construction qu'une intervention sur la matrice d'adjacence apprise affecte la sortie.

BIBLIOGRAPHIE

- [1] C. Dong, C. C. Loy, K. He, and X. Tang. Learning a deep convolutional network for image super-resolution. In *ECCV*, 2014.
- [2] B. Lim, S. Son, H. Kim, S. Nah, and K. M. Lee. Enhanced deep residual networks for single image super-resolution. In *CVPR Workshops*, 2017.
- [3] T. Vandal, E. Kodra, S. Ganguly, A. Michaelis, R. Nemani, and A. R. Ganguly. DeepSD : Generating high resolution climate change projections through single image super-resolution. In *ACM SIGKDD*, 2017.
- [4] O. Ronneberger, P. Fischer, and T. Brox. U-Net : Convolutional networks for biomedical image segmentation. In *MICCAI*, 2015.
- [5] J. Pan et al. Spatial attention pyramid network for unsupervised single image super-resolution. *arXiv preprint*, 2019.
- [6] Z. Li, N. Kovachki, K. Azizzadenesheli, B. Liu, K. Bhattacharya, A. Stuart, and A. Anandkumar. Fourier neural operator for parametric partial differential equations. In *ICLR*, 2021.
- [7] B. Bonev, T. Kurth, C. Hundt, J. Pathak, M. Baust, K. Kashinath, and A. Anandkumar. Spherical Fourier neural operators : Learning stable dynamics on the sphere. In *ICML*, 2023.
- [8] J. Liang, J. Cao, G. Sun, K. Zhang, L. Van Gool, and R. Timofte. SwinIR : Image restoration using Swin Transformer. In *ICCV Workshops*, 2021.

- [9] I. Lopez-Gomez et al. PrecipFormer : A transformer-based architecture for precipitation downscaling. *arXiv preprint*, 2023.
- [10] I. Goodfellow, J. Pouget-Abadie, M. Mirza, B. Xu, D. Warde-Farley, S. Ozair, A. Courville, and Y. Bengio. Generative adversarial nets. In *NeurIPS*, 2014.
- [11] M. Mirza and S. Osindero. Conditional generative adversarial nets. *arXiv preprint arXiv :1411.1784*, 2014.
- [12] N. Rampal, P. B. Gibson, S. Hobeichi, J. Sherwood, and S. B. Power. Reliable generative downscaling of climate data with conditional GANs. *Journal of Advances in Modeling Earth Systems*, 2024.
- [13] L. Harris, A. T. T. McRae, M. Chantry, P. D. Dueben, and T. N. Palmer. A generative deep learning approach to stochastic downscaling of precipitation forecasts. *Journal of Advances in Modeling Earth Systems*, 14(10) :e2022MS003120, 2022.
- [14] I. Price and S. Rasp. Increasing the accuracy and resolution of precipitation forecasts using deep generative models. In *AISTATS*, 2022.
- [15] D. P. Kingma and M. Welling. Auto-encoding variational Bayes. In *ICLR*, 2014.
- [16] S. Lange et al. Variational autoencoders for climate downscaling. *Environmental Data Science*, 2022.
- [17] B. Groenke, L. Madaus, and C. Monteleoni. ClimAlign : Unsupervised statistical downscaling of climate variables via normalizing flows. *arXiv preprint*, 2020.
- [18] J. Ho, A. Jain, and P. Abbeel. Denoising diffusion probabilistic models. In *NeurIPS*, 2020.
- [19] T. Karras, M. Aittala, T. Aila, and S. Laine. Elucidating the design space of diffusion-based generative models. In *NeurIPS*, 2022.

- [20] C. Saharia, J. Ho, W. Chan, T. Salimans, D. J. Fleet, and M. Norouzi. Image super-resolution via iterative refinement. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 2022.
- [21] Z. Yue, J. Wang, and C. C. Loy. ResShift : Efficient diffusion model for image super-resolution by residual shifting. In *NeurIPS*, 2023.
- [22] Y. Lipman, R. T. Q. Chen, H. Ben-Hamu, M. Nickel, and M. Le. Flow matching for generative modeling. In *ICLR*, 2023.
- [23] Y. Song, P. Dhariwal, M. Chen, and I. Sutskever. Consistency models. In *ICML*, 2023.
- [24] R. Rombach, A. Blattmann, D. Lorenz, P. Esser, and B. Ommer. High-resolution image synthesis with latent diffusion models. In *CVPR*, 2022.
- [25] M. Mardani, N. Brenowitz, Y. Cohen, J. Pathak, C.-Y. Chen, C.-C. Liu, A. Vahdat, K. Kashinath, J. Kautz, and M. Pritchard. Residual corrective diffusion modeling for km-scale atmospheric downscaling. *arXiv preprint arXiv :2309.15214*, 2023.
- [26] S. Rasp et al. WeatherBench 2 : A benchmark for the next generation of data-driven global weather models. *arXiv preprint arXiv :2308.15560*, 2023.
- [27] D. Watson-Parris et al. ClimateBench v1.0 : A benchmark for data-driven climate projections. *Journal of Advances in Modeling Earth Systems*, 2022.
- [28] J. Nathaniel et al. ChaosBench : A multi-channel, physics-based benchmark for subseasonal-to-seasonal climate prediction. *NeurIPS Datasets and Benchmarks*, 2024.
- [29] T. Nguyen, J. Brandstetter, A. Kapoor, J. K. Gupta, and A. Grover. ClimaX : A foundation model for weather and climate. In *ICML*, 2023.

-
- [30] R. Lam et al. Learning skillful medium-range global weather forecasting. *Science*, 382(6677) :1416-1421, 2023.
 - [31] I. Price et al. GenCast : Diffusion-based ensemble forecasting for medium-range weather. *arXiv preprint*, 2024.
 - [32] K. Bello, B. Aragam, and P. Ravikumar. DAGMA : Learning DAGs via M-matrices and a log-determinant acyclicity characterization. In *NeurIPS*, 2022.
 - [33] J. Pearl. *Causality : Models, Reasoning, and Inference*. Cambridge University Press, 2nd edition, 2009.