

III

PROPOSITION : ORACLE, ARCHITECTURE CAUSALE À DEUX ÉTAGES

III.1 Introduction • III.2 Vue d’ensemble et différence avec CORRDIF • III.3 Graphe atmosphérique hétérogène • III.4 Encodeur intelligible • III.5 Réseau causal récurrent (RCN) • III.6 Apprentissage du DAG par DAGMA • III.7 Décodeur graphe-à-grille • III.8 Interface inter-étages et propriété (O3) • III.9 Étage 2 : diffusion EDM résiduelle • III.10 Pertes et entraînement • III.11 Synthèse et traçabilité.

III.1. Introduction

Aucune approche existante ne résout simultanément le trilemme stabilité / extrêmes / robustesse hors-distribution ; le paradigme à deux étages de CORRDIF [1] se distingue comme l’antécédent le plus crédible mais n’adresse pas par construction la robustesse OOD. Ce chapitre formalise notre proposition, le modèle ORACLE, comme une *causalisation* de ce paradigme portant exclusivement sur le premier étage : le réseau de régression générique de CORRDIF y est remplacé par un module

structurellement causal (graphe atmosphérique hétérogène, encodeur intelligible, réseau causal récurrent gouverné par une matrice d’adjacence apprise sous contrainte d’acyclicité). Le second étage conserve la diffusion EDM [2] avec un conditionnement par concaténation de canaux qui assure le passage architectural du chemin causal vers la prédiction stochastique du résiduel.

III.1.1. Notations et objectifs

Sauf mention contraire, B désigne la taille du lot, T la longueur de séquence ($T = 8$), N le nombre de nœuds, $d = 128$ la dimension latente et $(H_{\text{HR}}, W_{\text{HR}}) = (172, 179)$ la résolution cible. Les symboles centraux sont récapitulés dans le tableau 1.

Tableau 1 – *Notations principales.*

Symbole	Description
$y_{\text{LR}}, x_{\text{HR}}$	Champs LR conditionnant (GCM) et HR cible (précipitation)
baseline, μ_{HR}, δ	Sur-échantillonnage bilinéaire, moyenne causale Stage 1, résiduel stochastique Stage 2
A_{dag}	Matrice d’adjacence $N \times N$ du DAG appris
H_t, H_T	État caché du graphe au pas t , état final consommé par le décodeur
$\sigma, \sigma_{\text{data}}$	Niveau de bruit EDM, écart-type empirique des résiduels
$\mathcal{D}_{\theta}$	Opérateur de débruitage EDM préconditionné

La conception obéit à six objectifs : **O1** stabilité d’entraînement (sans équilibre adversarial fragile); **O2** réalisme des extrêmes mesuré par CRPS et centiles élevés; **O3** causalité architecturale, c’est-à-dire dépendance non-triviale de μ_{HR} à A_{dag} (signature contrastive vis-à-vis de CORRDIFF); **O4** robustesse inter-GCM en régime historique sous changement de régime climatique; **O5** efficacité computationnelle sur budget CPU-only (48 cœurs, 128 Go); **O6** interprétabilité, le DAG appris devant être inspectable. O1 et O2 sont adressés par la décomposition à deux étages et la diffusion EDM; O3 et O6 par le RCN et la contrainte DAGMA; O4 par la structure causale; O5 par le pré-calcul et la diffusion sur résidu de faible amplitude.

III.2. Vue d’ensemble et différence avec Corr-Diff

III.2.1. Architecture en quatre blocs fonctionnels

À haut niveau, ORACLE est composé de quatre blocs (figure 1). Le *générateur de baseline* sur-échantillonne y_{LR} par interpolation bilinéaire. Le *module causal résiduel* (CRM) produit μ_{HR} via le chemin causal complet — graphe hétérogène, encodeur intelligible, RCN, décodeur graphe-à-grille. Le *décodeur de diffusion EDM* échantillonne le résiduel δ conditionné sur μ_{HR} et la baseline. La *recombinaison finale* agrège selon l’équation centrale du paradigme à deux étages :

$$x_{HR} = \text{baseline}_{LR\uparrow} + \mu_{HR}(y_{LR}; A_{\text{dag}}) + \delta(\sigma; \mu_{HR}, \text{baseline}). \quad (\text{III.1})$$

Figure (Chap III) à produire — Vue d’ensemble simplifiée d’Oracle en quatre blocs : (1) baseline bilinéaire, (2) module causal résiduel (graphe + encodeur + RCN + décodeur, $\rightarrow \mu_{HR}$), (3) diffusion EDM résiduelle (bruit + concat 3 canaux $\rightarrow \delta$), (4) recombinaison finale (x_{HR}).

Figure 1 — Vue d’ensemble simplifiée du modèle ORACLE en quatre blocs articulés autour de l’équation (III.1). La causalité architecturale est concentrée dans le CRM; la stochasticité réside dans le bloc EDM.

La décomposition sépare explicitement la composante déterministe causale (μ_{HR} , captant le forçage-réponse via le DAG appris) et la composante stochastique non-causale (δ , captant la variabilité fine résiduelle que la diffusion EDM modélise efficacement).

L’écart avec CORRDIF est entièrement localisé dans le module produisant μ_{HR} : CORRDIF y emploie un U-Net générique entraîné par MSE sur $x_{HR} - \text{baseline}$; ORACLE le remplace par un module causal en

quatre sous-blocs dont la sortie transite obligatoirement par A_{dag} . Cette substitution est volontairement *circonscrite* — le Stage 2 de diffusion, les pertes EDM, le sampler de Heun et le préconditionnement sont hérités tels quels — afin d’isoler l’apport de la causalité architecturale : toute amélioration mesurée sera attribuable au remplacement du module μ_{HR} et non à un changement collatéral.

III.3. Graphe atmosphérique hétérogène

Note préliminaire sur la cardinalité du graphe. L’architecture RCN est définie de manière générique pour un nombre arbitraire N de nœuds. La version théorique pleinement résolue compterait jusqu’à $\sim 32\,600$ nœuds. Dans toute la suite expérimentale (Chap. IV), nous travaillons avec une **configuration agrégée à $N = 6$ nœuds typés** : un nœud par variable physique, pas un nœud par pixel. Le DAG appris (A_{dag} de taille 6×6) est donc un graphe inter-variables. Cette agrégation est volontaire : elle rend la matrice causale interprétable au prix d’une perte de résolution spatiale dans le graphe (la résolution spatiale est reprise par les blocs convolutifs).

III.3.1. Types de nœuds et hiérarchie verticale

Le graphe atmosphérique G qui structure l’inférence causale d’ORACLE est *hétérogène* : il comporte quatre types de nœuds. **GP850**, **GP500**, **GP250** correspondent aux variables dynamiques (température, vent, humidité spécifique) aux trois niveaux de pression 850/500/250 hPa représentant la basse, moyenne et haute troposphère ; chaque nœud GP correspond à un point de la grille LR ($N_{\text{LR}} = 23 \times 26 = 598$). **SP_HR** regroupe les variables *statiques* à haute résolution (orographie, masque terre/mer, caractéristiques de surface), avec un nœud par point de la grille HR ($N_{\text{HR}} = 172 \times 179 = 30\,788$). Le total atteint $\approx 32\,600$ nœuds en configuration complète. La dissymétrie LR/HR reflète la nature physique : variables atmosphériques fournies grossièrement par le GCM,

caractéristiques de surface disponibles à la résolution cible.

III.3.2. Types d'arêtes et physique encodée

Le graphe comporte trois types d'arêtes, chacun encodant un mécanisme physique connu. Les **arêtes spatiales** (intra-niveau, voisins horizontaux des nœuds GP) modélisent l'*advection* et la diffusion. Les **arêtes verticales** (inter-niveaux GP) modélisent la *convection* et l'instabilité verticale, déterminantes pour la précipitation. Les **arêtes statique-vers-pression** (SP_HR $\rightarrow$ GP, du nœud HR vers la cellule LR qui le contient) modélisent l'*influence orographique* et l'effet d'occupation du sol. Cet ensemble constitue le support d'agrégation pour les couches SA-GEConv de l'encodeur et du RCN ; la matrice A_{dag} apprise par DAGMA pondère par-dessus les liens causaux entre variables.

Figure (Chap III) à produire — Vue conceptuelle du graphe hétérogène : trois plans de pression GP850 / GP500 / GP250 (nœuds dynamiques colorés par niveau) + plan SP_HR (nœuds statiques en gris). Arêtes : spatiales (intra-plan), verticales (inter-plans), static $\rightarrow$ pressure (en pointillé du plan SP_HR vers les plans GP). Pas de variables nommées : vue structurelle uniquement.

Figure 2 — Vue conceptuelle du graphe atmosphérique hétérogène d'ORACLE. Quatre types de nœuds (GP850, GP500, GP250, SP_HR) et trois types d'arêtes (spatiales intra-niveau, verticales inter-niveaux, statique-vers-pression). L'instanciation concrète avec les variables nommées et les dimensions exactes est différée au chapitre suivant.

III.3.3. Drivers statiques et acheminement causal

Un choix central concerne l'acheminement des drivers statiques (orographie, masque, sol). Plutôt que de les injecter comme canaux supplémentaires du Stage 2, comme dans les approches GAN résiduelles [8], nous les introduisons exclusivement comme nœuds SP_HR du graphe. Leur influence sur μ_{HR} est nécessairement médiée par les arêtes SP_HR

→ GP dont les poids sont gouvernés par A_{dag} . Ce choix garantit que *toute information passe par le chemin causal* ; il assure que l'intervention $A_{\text{dag}} \leftarrow \mathbf{0}$ supprime aussi l'influence des drivers statiques, ce qui contribue à la propriété (O3) formalisée en section III.8.

III.4. Encodeur intelligible des variables

III.4.1. Motivation : préserver l'identité physique des variables

L'encodeur intelligible projette chaque variable physique (température, vent, humidité, précipitation) dans un espace latent commun de dimension $d = 128$ qui alimentera le RCN. Sa spécificité tient à la *préservation de l'identité physique* : chaque dimension latente reste attachée à une variable source, plutôt que de fondre toutes les variables dans une représentation distribuée opaque. Cette préservation repose sur deux choix : (i) chaque couple variable-niveau est encodé par un MLP *dédié* $f_{v,p}$, ce qui empêche le mélange précoc ; (ii) une perte de reconstruction $\mathcal{L}_{\text{rec}}$ (section III.10) contraint le décodage de l'état latent à reproduire les variables d'entrée, forçant l'encodeur à conserver l'information variable par variable.

III.4.2. Architecture par variable et normalisation

Chaque MLP $f_{v,p}$ est de profondeur 3 (activations GELU, normalisation de couche). La normalisation des entrées suit deux conventions : standardisation par moyenne et écart-type pour les variables atmosphériques classiques, et transformation logarithmique $\log(1 + \text{pr})$ pour la précipitation, qui compresse la queue lourde et stabilise l'entraînement. L'agrégation entre nœuds voisins est effectuée par des couches *SAGE-Conv* [6] :

$$h_i^{(\ell+1)} = \sigma\left(W_{\text{self}}^{(\ell)} h_i^{(\ell)} + W_{\text{neigh}}^{(\ell)} \text{mean}_{j \in \mathcal{N}(i)} h_j^{(\ell)}\right), \quad (\text{III.2})$$

SAGEConv a été préféré aux variantes par attention (GAT) pour sa stabilité d'entraînement et son coût computationnel inférieur ; cette préférence est justifiée empiriquement au chapitre suivant.

III.5. Réseau causal récurrent (RCN)

III.5.1. Principe : SCM dynamique enchaîné à une mise à jour temporelle

Le *Recurrent Causal Network* (RCN) constitue le cœur méthodologique d'ORACLE. À chaque pas de temps il combine deux briques : un *modèle causal structurel* (SCM) qui prédit l'évolution de l'état caché en fonction du DAG appris, et une *mise à jour récurrente* (GRU) qui fusionne cette prédiction théorique avec l'observation courante pour produire l'état effectif. Le SCM joue le rôle du *plan de vol* théorique, la GRU celui de la *mise à jour aux instruments*. L'innovation conceptuelle d'ORACLE est que *le SCM est le moteur récurrent lui-même* : la transition $H_t \rightarrow H_{t+1}$ est définie comme une assignation structurelle causale, non comme un post-traitement appliqué à un état caché produit par ailleurs.

III.5.2. Équations SCM et mise à jour GRU

À chaque pas t , l'étape SCM produit une prédiction causale $\hat{H}_t$ à partir de H_{t-1} , de l'observation x_t et de A_{dag} . Pour chaque variable i , l'assignation structurelle s'écrit :

$$\hat{H}_t^{(i)} = f_i \left(A_{\text{dag}}^{(i,:)} \odot H_{t-1}, x_t, \varepsilon_t^{(i)} \right), \quad (\text{III.3})$$

où $A_{\text{dag}}^{(i,:)}$ regroupe les pondérations causales entrantes vers i , $\odot$ est le produit composante par composante avec broadcast nœud, $\varepsilon_t^{(i)}$ un bruit exogène, et f_i un MLP structurel propre à la variable. Les K f_i sont implémentés en parallèle, suivant l'usage des SCM neuronaux multivariés.

La perte $\mathcal{L}_{\text{rec}}$ contraint $\hat{H}_t$ à porter l'information nécessaire au décodage des variables d'entrée, forçant la dynamique à apprendre des liens prédictifs effectifs.

L'étape GRU fusionne $\hat{H}_t$ et l'embedding x_t^{emb} (produit par un MLP léger nommé FactorEncoder) suivant les équations standard de Cho et al. [7] :

$$z_t = \sigma(W_z x_t^{\text{emb}} + U_z \hat{H}_t), \quad (\text{III.4})$$

$$r_t = \sigma(W_r x_t^{\text{emb}} + U_r \hat{H}_t), \quad (\text{III.5})$$

$$\tilde{H}_t = \tanh(W_h x_t^{\text{emb}} + U_h (r_t \odot \hat{H}_t)), \quad (\text{III.6})$$

$$H_t = (1 - z_t) \odot \hat{H}_t + z_t \odot \tilde{H}_t. \quad (\text{III.7})$$

H_t est réinjecté au pas suivant comme entrée du SCM, fermant la boucle. Après $T = 8$ pas, $H_T = H_T$ est consommé par le décodeur (section III.7).

III.5.3. Passe avant

L'état H_0 est initialisé par un paramètre apprenable indépendant du lot. À chaque pas $t = 1, \dots, T$, on calcule successivement la prédiction causale $\hat{H}_t = \text{SCM}(H_{t-1}, A_{\text{dag}}, x_t)$ par l'équation (III.3), puis l'embedding $x_t^{\text{emb}} = \text{FactorEncoder}(x_t)$, puis les portes GRU $(z_t, r_t, \tilde{H}_t)$ par les équations (III.4)–(III.6), et enfin $H_t = (1 - z_t) \odot \hat{H}_t + z_t \odot \tilde{H}_t$. L'état $H_T = H_T$ est retourné après T itérations.

III.6. Apprentissage du DAG par contrainte DAGMA

III.6.1. Caractérisation différentiable et formulation DAGMA

Apprendre conjointement la structure d'un DAG et les fonctions structurelles est combinatoire dans sa formulation discrète (le nombre

de DAG à N nœuds croît super-exponentiellement). Zheng et al. [4] ont reformulé l'acyclicité comme contrainte différentiable $h_{\text{NOTEARS}}(A) = \text{tr}(e^{A \odot A}) - N$, qui s'annule ssi A est acyclique mais souffre du coût et de l'instabilité numérique de l'exponentielle de matrice. Bello, Aragam et Ravikumar [3] ont proposé une caractérisation alternative par *log-déterminant* d'une matrice M-positive :

$$h_{\text{DAGMA}}(A; s) = -\log \det(sI - A \odot A) + N \log s, \quad (\text{III.8})$$

où $s > N \cdot \max_{i,j} |A_{i,j}|$ garantit la M-positivité. La quantité h_{DAGMA} s'annule ssi A représente un DAG, ne requiert qu'une décomposition LU, et son gradient se déduit de l'inverse de $sI - A \odot A$. Dans ORACLE, cette pénalité est combinée à une sparsité L_1 encourageant une matrice creuse et auditable :

$$\mathcal{L}_{\text{dag}} = \lambda_{\text{DAGMA}} \cdot h_{\text{DAGMA}}(A_{\text{dag}}) + \lambda_{L_1} \cdot \|A_{\text{dag}}\|_1. \quad (\text{III.9})$$

Les valeurs effectives des coefficients sont détaillées au chapitre suivant.

III.6.2. Portée et limites de la causalité apprise

Portée et limites

ORACLE est **structurellement causal** : son architecture respecte par construction l'acyclicité et la propriété d'intervention, le passage par A_{dag} étant nécessaire à la production de μ_{HR} (propriété O3, section III.8). Le DAG appris **ne prétend pas refléter la causalité physique réelle** : il s'agit d'une représentation *stylisée* optimisée pour la prédiction sous contrainte d'acyclicité, dont la fidélité aux mécanismes physiques est une propriété empirique à vérifier. Cette posture demeure défendable car le DAG est **auditable** — visualisable, comparable à une connaissance a priori, corrigible manuellement par un expert — propriété indépendante de la fidélité physique stricte et apport opérationnel concret face aux approches purement corrélatives.

III.7. Décodeur graphe-à-grille et moyenne haute résolution

III.7.1. Cross-attention à résolution intermédiaire et raffinement

Le décodeur transforme l'état caché final $H_T \in \mathbb{R}^{B \times N \times d}$ en une carte $\mu_{\text{HR}} \in \mathbb{R}^{B \times 1 \times H_{\text{HR}} \times W_{\text{HR}}}$ en deux étapes : (i) attention croisée entre des requêtes définies sur une grille intermédiaire $H_{\text{int}} \times W_{\text{int}} = 43 \times 45$ (double de la résolution LR) et l'ensemble des nœuds du graphe (clés/valeurs) ; (ii) sur-échantillonnage bilinéaire et raffinement convolutif vers la résolution HR. L'attention croisée multi-têtes calcule

$$\tilde{\mu}_p = \sum_{n=1}^N \alpha_{p,n} \cdot V_n, \quad \alpha_{p,n} = \frac{\exp(\langle Q_p, K_n \rangle / \sqrt{d})}{\sum_{n'} \exp(\langle Q_p, K_{n'} \rangle / \sqrt{d})}. \quad (\text{III.10})$$

La résolution intermédiaire est dictée par la mémoire : une attention directe à 172×179 produirait une matrice $30\,788 \times N$ prohibitive ; la résolution 43×45 réduit le coût d'un facteur 16 tout en gardant assez de granularité. La carte $\tilde{\mu}$ subit ensuite un sur-échantillonnage bilinéaire vers la résolution HR, un raffinement convolutif léger (deux blocs Conv + GELU + norm) et une projection 1×1 qui produit la carte scalaire μ_{HR} .

III.8. Interface inter-étages et propriété (O3)

III.8.1. Pré-calcul, cache et recalibration de σ_{data}

Une fois le Stage 1 convergé, sa sortie est figée : on pré-calcule et sauvegarde $\mu_{\text{HR}}^{(i)}$ et $\text{baseline}^{(i)}$ pour chaque échantillon. Cette mise en cache (quelques heures) évite de ré-évaluer le CRM à chaque pas du Stage 2, réduisant son coût marginal à celui d'une simple passe de diffusion — optimisation cruciale sur budget CPU-only. À partir des couples pré-calculés, on évalue empiriquement la distribution des résiduels

$$\delta^{(i)} = \log(1 + x_{\text{HR}}^{(i)}) - \log(1 + \text{baseline}^{(i)}) - \mu_{\text{HR}}^{(i)}, \quad (\text{III.11})$$

dont l'écart-type fournit σ_{data} pour le préconditionnement EDM (section III.9). Une calibration incorrecte conduit soit à une sous-utilisation du modèle, soit à une instabilité numérique des coefficients de préconditionnement.

III.8.2. Définition formelle de la propriété (O3)

La propriété (O3) opérationnalise l'idée que le chemin causal d'ORACLE est *structurellement load-bearing*, c'est-à-dire que son retrait dégrade significativement la prédiction. Formellement :

Définition III.1 (Indispensabilité causale, O3). Soit $\text{MSE}(\mu_{\text{HR}}(A_{\text{dag}}); x_{\text{HR}})$ l'erreur quadratique moyenne du Stage 1 lorsque l'inférence utilise la ma-

trice d'adjacence apprise A_{dag} , et $\text{MSE}(\mu_{\text{HR}}(\mathbf{0}); x_{\text{HR}})$ la même quantité lorsque cette matrice est forcée à zéro. La quantité contrastive

$$\Delta_{O3} = \text{MSE}(\mu_{\text{HR}}(\mathbf{0}); x_{\text{HR}}) - \text{MSE}(\mu_{\text{HR}}(A_{\text{dag}}); x_{\text{HR}}) \quad (\text{III.12})$$

mesure l'apport du chemin causal à la qualité de la prédiction. ORACLE satisfait la propriété (O3) à un seuil τ si :

$$\frac{\Delta_{O3}}{\text{MSE}(\mu_{\text{HR}}(A_{\text{dag}}); x_{\text{HR}})} \geq \tau, \quad (\text{III.13})$$

avec typiquement $\tau \in [0,05, 0,10]$ dans nos protocoles.

III.8.3. Variante d'ablation noncausal

L'opérationnalisation de (O3) repose sur la variante **noncausal** qui force $A_{\text{dag}} = \mathbf{0}$ à l'inférence (pas à l'entraînement). Exposée par le paramètre `run_variant`, elle constitue l'instrument principal de validation expérimentale ; la mesure de Δ_{O3} est reportée au chapitre suivant.

III.9. Étage 2 : diffusion EDM résiduelle

III.9.1. Paradigme EDM et conditionnement par concaténation

Le second étage échantillonne le résiduel δ conditionnellement à μ_{HR} et à la baseline. Nous reprenons sans modification le formalisme EDM de Karras et al. [2], dont le préconditionnement s'écrit, pour $x_\sigma = x + \sigma\epsilon$:

$$\mathcal{D}_\theta(x_\sigma, \sigma) = c_{\text{skip}}(\sigma) \cdot x_\sigma + c_{\text{out}}(\sigma) \cdot \epsilon_\theta(c_{\text{in}}(\sigma) \cdot x_\sigma, c_{\text{noise}}(\sigma)), \quad (\text{III.14})$$

avec $c_{\text{skip}}, c_{\text{out}}, c_{\text{in}}, c_{\text{noise}}$ fonctions de σ et σ_{data} . Le préconditionnement EDM consiste à **normaliser adaptativement** les entrées et sorties du réseau de diffusion en fonction du niveau de bruit. Cela évite d'avoir à

ajuster manuellement des hyperparamètres : le réseau reçoit un signal d'apprentissage stable sur toute la plage de bruit. La perte pondérée s'écrit alors

$$\mathcal{L}_{\text{EDM}}(\theta) = \mathbb{E}_{x,\sigma,\epsilon} [\lambda(\sigma) \cdot \|\mathcal{D}_\theta(x + \sigma\epsilon, \sigma) - x\|^2]. \quad (\text{III.15})$$

L'échantillonnage utilise un solveur de Heun à pas variable selon le calendrier de Karras. Un examen détaillé du formalisme est donné au chapitre précédent (sous-section ??).

ORACLE conditionne exclusivement par *concaténation de canaux* (et non par cross-attention), c'est-à-dire :

$$\text{input}_{\text{UNet}} = \text{concat}(\delta_{\text{noisy}}, \mu_{\text{HR}}, \log(1 + \text{baseline})) \in \mathbb{R}^{B \times 3 \times H_{\text{HR}} \times W_{\text{HR}}}, \quad (\text{III.16})$$

avec $\delta_{\text{noisy}} = \delta + \sigma\epsilon$. Deux raisons motivent ce choix : la cross-attention introduit une voie d'information parallèle qui dilue la traçabilité causale, tandis que la concaténation force le U-Net à *voir* μ_{HR} comme un canal d'image traité localement par les couches initiales ; et la concaténation est computationnellement moins coûteuse, ce qui importe en CPU-only.

III.9.2. Pourquoi le résidu plutôt que le champ complet

Modéliser δ plutôt que x_{HR} réduit l'amplitude de la variable cible : x_{HR} couvre plusieurs ordres de grandeur (zones sèches aux extrêmes orangeux), δ est centré autour de zéro avec un écart-type de l'ordre de σ_{data} après log-transformation. Deux conséquences : la calibration de σ_{data} devient sensée (la diffusion opère sur la variabilité fine non capturée par le Stage 1) ; et la variance prédite est mieux calibrée sur la variance observée des résiduels, ce qui réduit la sub-dispersion typique des modèles génératifs sur champ complet (objectif O2).

III.10. Pertes composites et entraînement

III.10.1. Pertes des deux étages

L'entraînement du Stage 1 minimise une combinaison de quatre termes. La perte principale est l'erreur quadratique sur μ_{HR} :

$$\mathcal{L}_{\text{mse}} = \mathbb{E}[\|\mu_{\text{HR}} - (\log(1 + x_{\text{HR}}) - \log(1 + \text{baseline}))\|^2]. \quad (\text{III.17})$$

La perte de reconstruction $\mathcal{L}_{\text{rec}} = \sum_{v,p} \mathbb{E}[\|\text{decode}_{v,p}(\hat{H}_t) - x_{v,p,t}\|^2]$ contraint le décodage de l'état latent à reproduire les variables d'entrée, ce qui préserve l'identité physique. Les deux derniers termes, h_{DAGMA} et $\|A_{\text{dag}}\|_1$, sont regroupés dans $\mathcal{L}_{\text{dag}}$ (équation III.9). La perte composite du Stage 1 est :

$$\mathcal{L}_{\text{total}}^{(1)} = \mathcal{L}_{\text{mse}} + \alpha \mathcal{L}_{\text{rec}} + \mathcal{L}_{\text{dag}}. \quad (\text{III.18})$$

Le Stage 2 minimise exclusivement $\mathcal{L}_{\text{EDM}}$ (équation III.15) sur les résiduels pré-calculés, sans perte auxiliaire dans la configuration finale. Des pertes spectrales (FACL) et Wasserstein sliced ont été explorées en préparation puis abandonnées (gain marginal, instabilités) ; les détails empiriques figurent au chapitre suivant.

III.10.2. Procédure d'entraînement et optimisation

L'entraînement procède en deux phases successives. Le Stage 1 est entraîné par AdamW sur E_1 époques jusqu'à convergence sur $\mathcal{L}_{\text{total}}^{(1)}$; ses paramètres sont alors gelés et l'on pré-calcule $\mu_{\text{HR}}^{(i)}$ et $\text{baseline}^{(i)}$ pour tout le jeu d'entraînement, puis σ_{data} empirique. Le critère (O3) (équation III.13) joue le rôle de *gate* : si $\Delta_{O3}/\text{MSE} < \tau$, le Stage 1 est ré-entraîné. Le Stage 2 (U-Net de diffusion) est ensuite entraîné par Adam sur les résiduels pré-calculés : à chaque pas on tire σ selon le calendrier EDM et $\epsilon \sim \mathcal{N}(0, I)$, on forme $\text{input}_{\text{UNet}} = \text{concat}(\delta + \sigma\epsilon, \mu_{\text{HR}}, \log(1 + \text{baseline}))$, on évalue $\mathcal{D}_{\theta}$ (équation III.14) et $\mathcal{L}_{\text{EDM}} = \lambda(\sigma)\|\hat{\delta} - \delta\|^2$, puis on met à jour les paramètres et leurs poids EMA. Trois éléments

du protocole méritent mention : l'*EMA* (décroissance 0,9999) stabilise l'échantillonnage en lissant les fluctuations des paramètres ; le *conditioning dropout* (taux $p \approx 0,13$) remplace aléatoirement μ_{HR} par zéro pendant l'entraînement, préparant l'usage en classifieur-free guidance ; la valeur effective de `cfg_scale` est discutée au chapitre suivant.

III.11. Synthèse, traçabilité et choix non retenus

III.11.1. Traçabilité des composants

Le tableau 2 retrace l'inspiration et le verrou adressé par chaque composant, conformément au principe que tout choix architectural doit être justifié par référence à la littérature et contribution à au moins un axe du trilemme.

Tableau 2 – *Traçabilité des composants d'ORACLE : inspiration et verrou adressé.*

Composant	Inspiration	Verrou
Décomposition à deux étages	CORRDIFF [1]	Stabilité
Graphe hétérogène SP/GP	Contribution propre	O3 / OOD
Encodeur intelligible par MLP dédiés	Contribution propre	O6
Agrégation SAGEConv	Hamilton et al. [6]	Efficacité
RCN (SCM + GRU)	Pearl [5] + Cho [7]	O3
DAG par DAGMA	Bello et al. [3]	O6
Décodeur graphe-à-grille (cross-attn)	Contribution propre	Efficacité
Diffusion EDM (Stage 2)	Karras et al. [2]	Stabilité, extrêmes
Conditionnement causal_concat	Contribution propre	O3 architectural
Pré-calcul Stage 1	Contribution propre	Efficacité (O5)

Plusieurs alternatives ont été envisagées puis écartées : les *Diffusion Transformers* (coût supérieur au U-Net à la résolution 172×179 , apport empirique non démontré pour le downscaling à cette échelle) ; le *flow matching* et les *consistency models* (maturité limitée sur cette application, perspective de continuation signalée en conclusion) ; l'injection des drivers statiques comme canaux supplémentaires du U-Net Stage 2 (écartée pour préserver le passage architectural par le DAG, condition

de la validité de O3) ; la cross-attention pour le conditionnement Stage 2 (écartée au profit de la concaténation, cf. section III.9.1).

III.11.2. Transition vers le Chapitre IV

Le présent chapitre a présenté ORACLE dans sa forme architecturale finale. La validation empirique — satisfaction effective de la propriété (O3), mesure de la sub-dispersion résiduelle, robustesse hors-distribution — constitue l’objet du chapitre suivant, qui documente également l’environnement logiciel, les jeux de données, la trajectoire de développement et la discussion des résultats.

BIBLIOGRAPHIE

- [1] M. Mardani, N. Brenowitz, Y. Cohen, J. Pathak, C.-Y. Chen, C.-C. Liu, A. Vahdat, K. Kashinath, J. Kautz, and M. Pritchard. Residual corrective diffusion modeling for km-scale atmospheric downscaling. *arXiv preprint arXiv :2309.15214*, 2023.
- [2] T. Karras, M. Aittala, T. Aila, and S. Laine. Elucidating the design space of diffusion-based generative models. In *Advances in Neural Information Processing Systems*, 2022.
- [3] K. Bello, B. Aragam, and P. Ravikumar. DAGMA : Learning DAGs via M-matrices and a log-determinant acyclicity characterization. In *Advances in Neural Information Processing Systems*, 2022.
- [4] X. Zheng, B. Aragam, P. Ravikumar, and E. P. Xing. DAGs with NO TEARS : Continuous optimization for structure learning. In *NeurIPS*, 2018.
- [5] J. Pearl. *Causality : Models, Reasoning, and Inference*. Cambridge University Press, 2nd edition, 2009.
- [6] W. L. Hamilton, R. Ying, and J. Leskovec. Inductive representation learning on large graphs. In *NeurIPS*, 2017.
- [7] K. Cho, B. van Merriënboer, C. Gulcehre, D. Bahdanau, F. Bougares, H. Schwenk, and Y. Bengio. Learning phrase representations using RNN encoder-decoder for statistical machine translation. In *EMNLP*, 2014.
- [8] N. Rampal, P. B. Gibson, S. Hobeichi, J. Sherwood, and S. B. Po-

wer. Reliable generative downscaling of climate data with conditional GANs. *Journal of Advances in Modeling Earth Systems*, 2024.