

CHAPITRE

III

PROPOSITION : ORACLE, ARCHITECTURE CAUSALE À DEUX ÉTAGES

III.1	Introduction	45
III.2	Vue d'ensemble et différence avec CorrDiff	49
III.3	Graphe atmosphérique hétérogène	51
III.4	Encodeur intelligible des variables	53
III.5	Réseau causal récurrent (RCN)	55
III.6	Apprentissage du DAG par contrainte DAGMA	58
III.7	Décodeur graphe-à-grille et moyenne μ_{HR}	60
III.8	Interface inter-étages et propriété (O3)	62
III.9	Étage 2 : diffusion EDM résiduelle	64
III.10	Pertes composites et entraînement	67
III.11	Synthèse, traçabilité et choix non retenus	70

III.1. Introduction

Les deux chapitres précédents ont successivement posé les fondements conceptuels du downscaling climatique profond (chapitre ??) et confronté ces fondements aux principales contributions de la littérature

récente (chapitre ??). De cette confrontation a émergé un constat clair : aucune approche existante ne résout simultanément le trilemme stabilité d’entraînement / réalisme des extrêmes / robustesse hors-distribution, et le paradigme à deux étages incarné par CORRDIFF [1] se distingue comme l’antécédent le plus crédible, sans toutefois adresser par construction la robustesse OOD.

Le présent chapitre présente formellement notre proposition, le modèle ORACLE, qui constitue une *causalisation* du paradigme à deux étages. La causalisation porte exclusivement sur le premier étage, dont le rôle est d’estimer la moyenne haute résolution μ_{HR} : nous y remplaçons le réseau de régression générique de CORRDIFF par un module structurellement causal, composé d’un graphe atmosphérique hétérogène, d’un encodeur intelligible des variables, et d’un réseau causal récurrent (RCN) dont la dynamique est gouvernée par une matrice d’adjacence apprise sous contrainte d’acyclicité. Le second étage, en revanche, conserve la diffusion EDM [2] avec un conditionnement par concaténation de canaux qui assure le passage architectural du chemin causal vers la prédiction stochastique du résiduel.

Nous présentons d’abord les notations utilisées dans le reste du chapitre (sous-section III.1.1) et nous formalisons les objectifs O1-O6 qui guident la conception (sous-section III.1.2). Nous donnons ensuite une vue d’ensemble de l’architecture et de son écart à CORRDIFF (section III.2), avant de décrire en détail chacun de ses composants : le graphe hétérogène (section III.3), l’encodeur intelligible (section III.4), le réseau causal récurrent (section III.5), l’apprentissage du DAG par contrainte DAGMA (section III.6), le décodeur graphe-à-grille produisant μ_{HR} (section III.7), l’interface inter-étages et la propriété (O3) (section III.8), et enfin l’étage 2 de diffusion résiduelle (section III.9). Les pertes composites et la procédure d’entraînement font l’objet de la section III.10. Une synthèse de traçabilité (section III.11) clôt le chapitre.

III.1.1. Notations

Nous fixons dans cette sous-section les notations utilisées dans le reste du chapitre. Le tableau 1 les récapitule sous forme synthétique. Sauf mention contraire, B désigne la taille du lot, T la longueur de la séquence temporelle, N le nombre total de nœuds du graphe, d la dimension de l'espace latent, et $(H_{\text{HR}}, W_{\text{HR}})$ la résolution de la grille cible (172 et 179 respectivement pour le domaine néo-zélandais).

Tableau 1 – Notations utilisées dans le présent chapitre.

Symbole	Type	Description
y_{LR}	$\mathbb{R}^{B \times C_{\text{LR}} \times H_{\text{LR}} \times W_{\text{LR}}}$	Champ basse résolution conditionnant (sortie GCM)
x_{HR}	$\mathbb{R}^{B \times 1 \times H_{\text{HR}} \times W_{\text{HR}}}$	Champ haute résolution cible (précipitation)
baseline	$\mathbb{R}^{B \times 1 \times H_{\text{HR}} \times W_{\text{HR}}}$	Sur-échantillonnage bilinéaire de y_{LR}
μ_{HR}	$\mathbb{R}^{B \times 1 \times H_{\text{HR}} \times W_{\text{HR}}}$	Moyenne haute résolution causale (sortie <i>Stage 1</i> , désignation usuelle de l'étage 1)
δ	$\mathbb{R}^{B \times 1 \times H_{\text{HR}} \times W_{\text{HR}}}$	Résiduel stochastique (sortie <i>Stage 2</i> , désignation usuelle de l'étage 2)
A_{dag}	$\mathbb{R}^{N \times N}$	Matrice d'adjacence du DAG appris
H_t	$\mathbb{R}^{B \times N \times d}$	État caché du graphe au pas t
H_T	$\mathbb{R}^{B \times N \times d}$	État caché final, consommé par le décodeur
G	graphe hétérogène	Graphe atmosphérique (4 types de nœuds, 3 types d'arêtes)
σ	$\mathbb{R}^+$	Niveau de bruit dans la diffusion EDM
σ_{data}	$\mathbb{R}^+$	Écart-type des résiduels après normalisation
ϵ_{θ}	réseau	U-Net de diffusion (Stage 2)
$\mathcal{D}_{\theta}$	opérateur	Débruitage EDM préconditionné

III.1.2. Objectifs O1-O6

La conception d'ORACLE obéit à six objectifs, introduits dans l'introduction générale et déployés ici dans leur forme opérationnelle. Chaque objectif est associé à au moins une composante architecturale dont la justification sera explicitée dans la section correspondante.

O1 — Stabilité d'entraînement. L'entraînement doit converger sans recours à un équilibre dynamique fragile (générateur/discriminateur),

et doit être reproductible sur plusieurs initialisations indépendantes. Adressé par la décomposition à deux étages et par la diffusion EDM.

O2 — Réalisme des extrêmes. La distribution des extrêmes prédits (queue haute de la précipitation) doit être statistiquement proche de la distribution observée, mesurée notamment par le score CRPS et par les centiles élevés (p95, p99). Adressé par la diffusion résiduelle Stage 2.

O3 — Causalité architecturale. La sortie μ_{HR} doit dépendre de la matrice d'adjacence apprise A_{dag} de manière non-triviale : l'intervention $A_{\text{dag}} \leftarrow \mathbf{0}$ doit dégrader significativement la prédiction. C'est la *signature contrastive* d'ORACLE par rapport à CORR-DIFF. Adressé par le RCN et la propriété formelle (O3) explicitée en section III.8.

O4 — Robustesse hors-distribution. Le modèle doit conserver une qualité prédictive raisonnable sous changement de régime climatique. La structure causale est ici notre voie de principe ; sa validation empirique est différée au chapitre suivant.

O5 — Efficacité computationnelle. L'entraînement doit pouvoir être conduit sur un budget matériel CPU-only de l'ordre de 48 cœurs et 128 Go de mémoire, avec un temps d'exécution raisonnable (de l'ordre de la dizaine d'heures par cycle de 20 époques). Adressé par la diffusion sur résidu de faible amplitude et par la mise en cache des sorties de Stage 1.

O6 — Interprétabilité. Le DAG appris doit être inspectable et auditable par un expert métier. Adressé par construction par le module DAGMA, qui produit une matrice d'adjacence creuse et visualisable.

III.2. Vue d'ensemble et différence avec Corr-Diff

III.2.1. Architecture en quatre blocs fonctionnels

À haut niveau, ORACLE est composé de quatre blocs fonctionnels, illustrés dans la figure 1. Le premier bloc, le *générateur de baseline*, applique un sur-échantillonnage bilinéaire au champ basse résolution y_{LR} pour fournir une carte HR grossière. Le deuxième bloc, le *module causal résiduel* (Causal Residual Module, CRM), produit la moyenne haute résolution μ_{HR} via le chemin causal complet : graphe hétérogène, encodeur intelligible, RCN, et décodeur graphe-à-grille. Le troisième bloc, le *décodeur de diffusion EDM*, échantillonne le résiduel δ par diffusion conditionnée sur μ_{HR} et la baseline. Le quatrième bloc, la *recombinaison finale*, agrège les trois contributions selon l'équation centrale du paradigme à deux étages :

$$x_{\text{HR}} = \text{baseline}_{\text{LR}\uparrow} + \mu_{\text{HR}}(y_{\text{LR}}; A_{\text{dag}}) + \delta(\sigma; \mu_{\text{HR}}, \text{baseline}). \quad (\text{III.1})$$

Figure (Chap III) à produire — Vue d'ensemble simplifiée d'Oracle en quatre blocs : (1) baseline bilinéaire, (2) module causal résiduel (graphe + encodeur + RCN + décodeur, $\rightarrow \mu_{\text{HR}}$), (3) diffusion EDM résiduelle (bruit + concat 3 canaux $\rightarrow \delta$), (4) recombinaison finale (x_{HR}).

Figure 1 — Vue d'ensemble simplifiée du modèle ORACLE : quatre blocs fonctionnels articulés autour de l'équation centrale (III.1). La causalité est concentrée dans le bloc CRM; la stochasticité réside dans le bloc EDM.

L'observation centrale qui motive cette décomposition est la séparation explicite entre le composant déterministe causal (μ_{HR}) et le composant stochastique non-causal (δ). Le premier capte la composante

forçage-réponse, fondée sur des relations physiques identifiées à travers le DAG appris. Le second capte la variabilité fine résiduelle, traitée comme un bruit structuré que la diffusion EDM est particulièrement adaptée à modéliser.

III.2.2. Écart avec CorrDiff : la causalisation du premier étage

L'écart entre ORACLE et CORRDIFF se situe entièrement dans le module qui produit μ_{HR} . CORRDIFF y utilise un U-Net générique entraîné par minimisation de l'erreur quadratique moyenne entre la sortie et la cible x_{HR} — baseline. ORACLE substitue à ce U-Net un module causal en quatre sous-blocs (graphe hétérogène, encodeur intelligible, RCN, décodeur graphe-à-grille), dont la sortie est contrainte de transiter par la matrice d'adjacence apprise A_{dag} . Cette substitution est volontairement *circonscrite* : le second étage de diffusion, les pertes EDM, le sampler de Heun, le préconditionnement, sont autant d'éléments hérités tels quels de la littérature. La figure 2 matérialise cette différence.

Figure (Chap III) à produire — Comparaison côte à côte CorrDiff (gauche) vs Oracle (droite). Stage 1 surligné en couleur : CorrDiff a un U-Net générique ; Oracle a un module causal (graphe + encodeur + RCN + décodeur). Stage 2 (diffusion EDM) identique.

Figure 2 — Comparaison côte à côte des pipelines CORRDIFF [1] et ORACLE. Le seul écart se situe au niveau du premier étage : le réseau de régression générique de CORRDIFF est remplacé par un module structurellement causal dans ORACLE. Le second étage de diffusion EDM est conservé tel quel.

Cette circonscription est cohérente avec l'objectif méthodologique : isoler l'apport de la causalité, en gardant constant tout le reste. À performance terminale égale, toute amélioration mesurée d'ORACLE sur

CORRDIFF sera attribuable au remplacement du module μ_{HR} , et non à un changement collatéral du sampler ou de l'architecture de diffusion.

III.3. Graphe atmosphérique hétérogène

III.3.1. Types de nœuds et hiérarchie verticale

Le graphe atmosphérique G qui structure l'inférence causale d'ORACLE est un graphe *hétérogène*, au sens où il comporte plusieurs types de nœuds distincts, chacun associé à un niveau de l'atmosphère ou à un type de variable. Quatre types sont distingués :

- **GP850** — variables atmosphériques au niveau de pression 850 hPa (basse troposphère). Chaque nœud correspond à un point de la grille basse résolution y_{LR} ; les variables associées sont la température, les composantes du vent, et l'humidité spécifique. La taille typique pour le domaine néo-zélandais est $N_{850} = 23 \times 26 = 598$ nœuds.
- **GP500** — variables au niveau 500 hPa (moyenne troposphère), mêmes variables, même grille. Présent si le paramètre `include_mid_layer` est activé.
- **GP250** — variables au niveau 250 hPa (haute troposphère, près de la tropopause).
- **SP_HR** — variables *statiques* à haute résolution. Cette catégorie regroupe l'orographie, le masque terre/mer, et les caractéristiques de surface. Chaque nœud correspond à un point de la grille haute résolution, soit $N_{\text{HR}} = 172 \times 179 = 30\,788$ nœuds.

Le nombre total de nœuds est donc, dans la configuration complète, de l'ordre de $3 \cdot N_{\text{LR}} + N_{\text{HR}} \approx 32\,600$. Cette dissymétrie entre les nœuds dynamiques (basse résolution) et les nœuds statiques (haute résolution) reflète la nature physique du problème : les variables atmosphériques sont fournies à une résolution grossière par le GCM, tandis que les caractéristiques de surface sont disponibles à la résolution cible.

III.3.2. Types d'arêtes et physique encodée

Le graphe comporte trois types d'arêtes, chacun encodant un mécanisme physique connu :

- **Arêtes spatiales** (intra-niveau) — chaque nœud GP est connecté à ses voisins immédiats sur la grille horizontale. Ces arêtes représentent les phénomènes d'*advection* (transport horizontal des variables par le vent) et de diffusion spatiale.
- **Arêtes verticales** (inter-niveaux) — les nœuds GP850, GP500 et GP250 sont reliés verticalement aux points correspondants des autres niveaux. Ces arêtes représentent les phénomènes de *convection* et d'instabilité verticale, qui sont déterminants pour la précipitation tropicale et de mousson.
- **Arêtes statique-vers-pression** (SP_HR $\rightarrow$ GP) — chaque nœud statique HR est connecté au nœud LR dont il dépend hiérarchiquement, c'est-à-dire au nœud dont la cellule LR contient le point HR. Ces arêtes représentent l'*influence orographique* et l'effet d'occupation du sol sur la dynamique atmosphérique.

L'ensemble des arêtes constitue le support d'agrégation pour les couches de convolution sur graphe (SAGEConv) utilisées par l'encodeur intelligible et le RCN. La matrice d'adjacence dynamique A_{dag} apprise par le module DAGMA opère sur cet ensemble en pondérant les liens causaux entre variables.

III.3.3. Drivers statiques et acheminement causal

Un choix de conception central de notre proposition concerne l'acheminement des drivers statiques (orographie, masque, sol). Plutôt que de les injecter comme canaux supplémentaires du second étage de diffusion, comme cela est typiquement fait dans les approches GAN résiduelles [8], nous les introduisons exclusivement comme nœuds du graphe hétérogène, de type SP_HR. Leur influence sur la prédiction est donc nécessairement médiée par le DAG appris : un driver statique influence μ_{HR}

Figure (Chap III) à produire — Vue conceptuelle du graphe hétérogène : trois plans de pression GP850 / GP500 / GP250 (nœuds dynamiques colorés par niveau) + plan SP_HR (nœuds statiques en gris). Arêtes : spatiales (intra-plan), verticales (inter-plans), static $\rightarrow$ pressure (en pointillé du plan SP_HR vers les plans GP). Pas de variables nommées : vue structurelle uniquement.

Figure 3 — Vue conceptuelle du graphe atmosphérique hétérogène d’ORACLE. Quatre types de nœuds (GP850, GP500, GP250, SP_HR) et trois types d’arêtes (spatiales intra-niveau, verticales inter-niveaux, statique-vers-pression). L’instanciation concrète avec les variables nommées et les dimensions exactes est différée au chapitre suivant.

seulement à travers des arêtes orientées $SP_HR \rightarrow GP$, dont les poids sont gouvernés par A_{dag} .

Ce choix garantit que *toute information passe par le chemin causal*, et qu’aucun raccourci ne court-circuite la structure du DAG. Une conséquence directe est que l’intervention $A_{dag} \leftarrow \mathbf{0}$ supprime l’influence des drivers statiques sur la prédiction, ce qui contribue à la propriété (O3) formalisée en section III.8.

III.4. Encodeur intelligible des variables

III.4.1. Motivation : préserver l’identité physique des variables

Le rôle de l’encodeur intelligible est de projeter chaque variable physique observée (température, vent, humidité, etc.) dans un espace latent commun de dimension d (typiquement $d = 128$), de manière à pouvoir alimenter de façon homogène le réseau causal récurrent qui opère sur ces représentations. Une telle projection peut être réalisée par n’importe quel réseau profond ; ce qui distingue notre approche est la *préservation de l’identité physique* des variables à travers la projection : chaque dimension de l’espace latent reste attachée à une variable physique source,

et non à une combinaison opaque de toutes les variables.

Cette préservation est obtenue par deux choix architecturaux. Premièrement, chaque variable d'entrée est encodée par un MLP *dédié* (un MLP par couple variable-niveau), ce qui empêche le mélange précoce des informations. Deuxièmement, une perte de reconstruction $\mathcal{L}_{\text{rec}}$, détaillée en section III.10, contraint le décodage de l'état latent à reproduire les variables d'entrée, ce qui force l'encodeur à conserver l'information variable par variable plutôt qu'à la fondre dans une représentation distribuée.

III.4.2. Architecture par variable et normalisation

Pour chaque type de variable v et chaque niveau de pression p , un MLP $f_{v,p}$ de profondeur 3 (avec activations GELU et normalisation de couche) projette le scalaire observé en un vecteur latent de dimension d . La normalisation des entrées suit deux conventions : standardisation par moyenne et écart-type pour les variables atmosphériques classiques (température, vent), et transformation logarithmique $\log(1 + \text{pr})$ pour la précipitation, qui compresse la queue lourde et tire vers le haut les valeurs faibles. Cette dernière transformation, calibrée sur les statistiques empiriques de la zone d'étude, joue un rôle important dans la stabilité de l'entraînement.

L'agrégation des représentations vectorielles entre nœuds voisins du graphe est effectuée par des couches *SAGEConv* [6], dont l'opération de base s'écrit, pour un nœud i et ses voisins $\mathcal{N}(i)$:

$$h_i^{(\ell+1)} = \sigma\left(W_{\text{self}}^{(\ell)} h_i^{(\ell)} + W_{\text{neigh}}^{(\ell)} \text{mean}_{j \in \mathcal{N}(i)} h_j^{(\ell)}\right), \quad (\text{III.2})$$

où $W_{\text{self}}^{(\ell)}$ et $W_{\text{neigh}}^{(\ell)}$ sont les matrices apprenables de la ℓ -ième couche et σ une activation non-linéaire. L'opérateur SAGEConv a été préféré aux variantes par attention (GAT) pour sa stabilité d'entraînement et son coût computationnel inférieur ; cette préférence est rappelée et justifiée empiriquement au chapitre suivant.

III.5. Réseau causal récurrent (RCN)

III.5.1. Principe : SCM dynamique enchaîné à une mise à jour temporelle

Le *Recurrent Causal Network* (RCN) constitue le cœur méthodologique d'ORACLE. Il combine, en chaque pas de temps, deux briques fonctionnellement distinctes : un *modèle causal structurel* (SCM) qui prédit l'évolution de l'état caché en fonction du DAG appris, et une *mise à jour récurrente* (GRU) qui fusionne cette prédiction théorique avec les observations courantes pour produire l'état effectif. La métaphore employée dans nos travaux préparatoires est celle du pilote : le SCM joue le rôle du *plan de vol* théorique, tandis que la GRU joue le rôle de la *mise à jour aux instruments* qui corrige le plan en fonction des mesures réelles.

L'innovation conceptuelle d'ORACLE par rapport aux propositions antérieures (incluant nos propres tentatives initiales, documentées au chapitre suivant) est que *le SCM est le moteur récurrent lui-même*. La transition dynamique $H_t \rightarrow H_{t+1}$ est définie comme une assignation structurelle causale, et non comme un post-traitement appliqué à un état caché produit par ailleurs.

III.5.2. Équations du SCM dynamique

Formellement, à chaque pas de temps t , l'étape SCM produit une prédiction causale intermédiaire $\hat{H}_t$ à partir de l'état précédent H_{t-1} , de l'observation extérieure x_t , et de la matrice d'adjacence A_{dag} . Pour chaque variable $i \in \{1, \dots, N\}$ et chaque nœud, l'assignation structurelle s'écrit :

$$\hat{H}_t^{(i)} = f_i \left(A_{\text{dag}}^{(i,:)} \odot H_{t-1}, x_t, \varepsilon_t^{(i)} \right), \quad (\text{III.3})$$

où $A_{\text{dag}}^{(i,:)}$ désigne la i -ième ligne de la matrice d'adjacence (les pondérations causales des autres variables vers i), $\odot$ le produit composante

par composante avec broadcast sur la dimension nœud, $\varepsilon_t^{(i)}$ un terme de bruit exogène, et f_i un MLP structurel propre à la variable i . L'ensemble des f_i est implémenté en parallèle pour les K variables actives, en suivant ce qui est usuel pour les SCM neuronaux multivariés.

Une perte de reconstruction $\mathcal{L}_{\text{rec}}$ contraint $\hat{H}_t$ à porter l'information nécessaire au décodage des variables d'entrée à t , ce qui force la dynamique SCM à apprendre des liens prédictifs effectifs plutôt qu'à dégrader vers une représentation triviale.

III.5.3. Mise à jour temporelle GRU

L'étape GRU prend en entrée la prédiction causale intermédiaire $\hat{H}_t$ et l'observation x_t , qu'elle passe d'abord à travers un encodeur de facteurs (un MLP léger), pour produire le nouvel état caché H_t . Les équations de la GRU sont les équations standard de Cho et al. [7] :

$$z_t = \sigma(W_z x_t^{\text{emb}} + U_z \hat{H}_t), \quad (\text{III.4})$$

$$r_t = \sigma(W_r x_t^{\text{emb}} + U_r \hat{H}_t), \quad (\text{III.5})$$

$$\tilde{H}_t = \tanh(W_h x_t^{\text{emb}} + U_h (r_t \odot \hat{H}_t)), \quad (\text{III.6})$$

$$H_t = (1 - z_t) \odot \hat{H}_t + z_t \odot \tilde{H}_t, \quad (\text{III.7})$$

où x_t^{emb} désigne l'embedding de x_t produit par l'encodeur de facteurs, et σ la fonction sigmoïde. Les portes z_t et r_t contrôlent respectivement la mise à jour de l'état et la prise en compte du contexte; le candidat $\tilde{H}_t$ est mélangé linéairement à $\hat{H}_t$ selon le poids z_t .

L'état final H_t est alors réinjecté au pas suivant comme entrée du SCM, ce qui ferme la boucle de la dynamique RCN. Après T pas (typiquement $T = 8$ dans notre configuration), l'état $H_T = H_T$ est consommé par le décodeur graphe-à-grille décrit en section III.7.

Figure (Chap III) à produire — Cellule RCN : à gauche, bloc SCM (entrées H_{t-1} et A_{dag} , MLPs structurels en parallèle, sortie $\hat{H}_t$). Au centre, encodeur de facteurs pour x_t (Embedding). À droite, bloc GRU avec portes z_t, r_t , candidat $\tilde{H}_t$, état H_t en sortie. Flèche de bouclage $H_t \rightarrow H_{t-1}$ pour le pas suivant.

Figure 4 — Architecture de la cellule Recurrent Causal Network (RCN). Le bloc SCM (à gauche) produit une prédiction causale $\hat{H}_t$ à partir de l'état précédent et du DAG. Le bloc GRU (à droite) fusionne cette prédiction avec l'observation courante x_t pour produire le nouvel état H_t , qui est réinjecté au pas suivant.

III.5.4. Pseudo-code de la passe avant

L'algorithme 1 décrit la passe avant complète du RCN, depuis l'initialisation de l'état caché jusqu'à la production de H_T .

Algorithm 1 Passe avant du RCN

Require: Séquence $\{x_t\}_{t=1}^T$, matrice d'adjacence A_{dag}

- 1: Initialiser H_0 par `init_state` (apprenable, indépendant du lot)
 - 2: **for** $t = 1, \dots, T$ **do**
 - 3: $\hat{H}_t \leftarrow \text{SCM}(H_{t-1}, A_{\text{dag}}, x_t)$ ▷ Étape causale, équation (III.3)
 - 4: $x_t^{\text{emb}} \leftarrow \text{FactorEncoder}(x_t)$
 - 5: $z_t, r_t, \tilde{H}_t \leftarrow \text{GRU_gates}(\hat{H}_t, x_t^{\text{emb}})$ ▷ Équations (III.4)–(III.6)
 - 6: $H_t \leftarrow (1 - z_t) \odot \hat{H}_t + z_t \odot \tilde{H}_t$
 - 7: **end for**
 - 8: **return** $H_T \leftarrow H_T$
-

III.6. Apprentissage du DAG par contrainte DAGMA

III.6.1. Problème de l'apprentissage de graphes acycliques

Apprendre conjointement la structure d'un DAG et les paramètres des fonctions structurelles à partir des données est un problème combinatoire dans sa formulation discrète : le nombre de DAG à N nœuds croît plus rapidement que $N^{N(N-1)/2}$, ce qui rend impraticable toute énumération exhaustive dès que N dépasse quelques dizaines. La contribution de Zheng et al. [4] a été de reformuler la contrainte d'acyclicité comme une contrainte différentiable :

$$h_{\text{NOTEARS}}(A) = \text{tr}(e^{A \odot A}) - N, \quad (\text{III.8})$$

qui s'annule si et seulement si le graphe représenté par A est acyclique. Bien que théoriquement correcte, cette caractérisation présente des inconvénients numériques : le calcul de l'exponentielle de matrice est coûteux et numériquement instable pour des graphes de grande taille, et les gradients ont une portée limitée.

III.6.2. Caractérisation DAGMA

Bello, Aragam et Ravikumar [3] ont proposé une caractérisation alternative, plus efficace et numériquement plus stable, fondée sur le *log-déterminant* d'une matrice M-positivement diagonale. La caractérisation DAGMA s'écrit :

$$h_{\text{DAGMA}}(A; s) = -\log \det(sI - A \odot A) + N \log s, \quad (\text{III.9})$$

où s est un scalaire positif (typiquement $s > N \cdot \max_{i,j} |A_{i,j}|$) garantissant que la matrice $sI - A \odot A$ reste M-positive. La quantité h_{DAGMA}

s'annule si et seulement si A représente un DAG, comme dans le cas NOTEARS, mais son calcul ne nécessite qu'une décomposition LU et son gradient se déduit immédiatement de l'inverse de $sI - A \odot A$.

Dans ORACLE, la pénalité d'acyclicité est combinée à une pénalité de sparsité L_1 qui encourage une matrice d'adjacence creuse, condition souhaitable pour l'auditabilité du DAG appris :

$$\mathcal{L}_{\text{dag}} = \lambda_{\text{DAGMA}} \cdot h_{\text{DAGMA}}(A_{\text{dag}}) + \lambda_{L_1} \cdot \|A_{\text{dag}}\|_1. \quad (\text{III.10})$$

Les coefficients λ_{DAGMA} et λ_{L_1} sont des hyperparamètres dont les valeurs effectives sont détaillées au chapitre suivant.

Figure (Chap III) à produire — Deux panneaux : à gauche, graphe initial avec quelques cycles visibles (matrice A dense, flèches dans les deux sens entre certains nœuds). À droite, graphe après projection DAGMA (acyclique, sparsifié, valeurs faibles supprimées). Annoter $h_{\text{DAGMA}}(A) > 0$ à gauche, $h_{\text{DAGMA}}(A) = 0$ à droite.

Figure 5 — *Intuition de la contrainte DAGMA.* À gauche, un graphe initial dense et cyclique pour lequel $h_{\text{DAGMA}}(A) > 0$. À droite, le graphe obtenu après convergence de l'optimisation sous contrainte d'acyclicité différentiable et de sparsité L_1 : la matrice d'adjacence est creuse, acyclique, et auditable.

III.6.3. Portée et limites de la causalité apprise

Le caractère causal d'ORACLE mérite une clarification épistémologique précise, car la confusion entre *causalité structurelle* et *causalité physique* est fréquente dans la littérature et constitue un terrain d'observation critique pour le jury.

Portée et limites

ORACLE est **structurellement causal** au sens où son architecture respecte par construction la propriété d'acyclicité et la propriété d'intervention : la matrice d'adjacence apprise A_{dag} définit un DAG, et le passage architectural par ce DAG est nécessaire à la production de μ_{HR} (cf. propriété (O3) en section III.8).

Cependant, le DAG appris **ne prétend pas refléter la causalité physique réelle** de l'atmosphère. Il s'agit d'une représentation *stylisée*, optimisée pour la prédiction de la précipitation haute résolution sous la contrainte d'acyclicité. Sa fidélité aux mécanismes physiques sous-jacents est une propriété empirique à vérifier au cas par cas, par confrontation avec la connaissance physique disponible et avec d'autres méthodes de découverte causale.

Cette posture est néanmoins défendable et constitue, à notre sens, un atout : le DAG appris est **auditable**. Il peut être visualisé, comparé à une connaissance physique a priori, et le cas échéant corrigé manuellement par un expert métier. Cette propriété d'auditabilité, indépendante de la fidélité physique stricte, est un apport opérationnel concret par rapport aux approches purement corrélatives.

III.7. Décodeur graphe-à-grille et moyenne haute résolution

III.7.1. Du tenseur de graphe à la grille de pixels

Le décodeur graphe-à-grille a pour fonction de transformer l'état caché final $H_T \in \mathbb{R}^{B \times N \times d}$, produit par le RCN, en une carte $\mu_{\text{HR}} \in \mathbb{R}^{B \times 1 \times H_{\text{HR}} \times W_{\text{HR}}}$. Cette transformation est non triviale car les nœuds du graphe et les pixels de la grille HR ne sont pas en correspondance bijective : les nœuds dynamiques sont à basse résolution, les nœuds statiques à haute résolution, et la cible est à haute résolution.

L'approche que nous adoptons procède en deux étapes. La première étape réalise une *attention croisée* entre une requête définie sur une grille intermédiaire (de résolution intermédiaire entre LR et HR) et l'ensemble des nœuds du graphe (clés et valeurs). Cette attention croisée distribue l'information du graphe sur une grille spatiale dense. La seconde étape applique un sur-échantillonnage bilinéaire suivi d'un raffinement convolutif pour atteindre la résolution HR cible.

III.7.2. Cross-attention à résolution intermédiaire

La grille intermédiaire est de dimension $H_{\text{int}} \times W_{\text{int}}$ avec typiquement $H_{\text{int}} = 43$ et $W_{\text{int}} = 45$, soit approximativement le double de la résolution basse. Chacun de ses pixels est associé à un vecteur de requête appris $q \in \mathbb{R}^d$. L'attention croisée multi-têtes calcule, pour chaque pixel p de la grille intermédiaire :

$$\tilde{\mu}_p = \sum_{n=1}^N \alpha_{p,n} \cdot V_n, \quad \text{avec} \quad \alpha_{p,n} = \frac{\exp(\langle Q_p, K_n \rangle / \sqrt{d})}{\sum_{n'} \exp(\langle Q_p, K_{n'} \rangle / \sqrt{d})}, \quad (\text{III.11})$$

où Q_p , K_n et V_n sont les projections respectives de la requête, de la clé et de la valeur. Le choix d'une résolution intermédiaire est dicté par des contraintes de mémoire : une attention croisée directe à la résolution HR cible 172×179 produirait une matrice d'attention de taille $30\,788 \times N$, prohibitive en mémoire pour un lot de taille raisonnable. La résolution intermédiaire 43×45 réduit le coût d'un facteur 16 tout en conservant suffisamment de granularité pour un raffinement convolutif efficace.

III.7.3. Raffinement convolutif et projection finale

Après l'attention croisée, la carte intermédiaire $\tilde{\mu} \in \mathbb{R}^{B \times d \times H_{\text{int}} \times W_{\text{int}}}$ subit deux opérations successives : un sur-échantillonnage bilinéaire vers la résolution HR cible, et un raffinement convolutif léger (deux blocs de convolution avec normalisation et activation GELU) qui ajuste les détails locaux. La projection finale est une convolution 1×1 qui réduit

la dimension du canal de d à 1, produisant la carte μ_{HR} à valeurs scalaires interprétables comme la moyenne haute résolution attendue de la précipitation.

III.8. Interface inter-étages et propriété (O3)

III.8.1. Pré-calcul et mise en cache des sorties de Stage 1

Une fois l'entraînement du premier étage convergé, sa sortie μ_{HR} est figée pour la phase d'entraînement du second étage. Plus précisément, on calcule, pour chaque échantillon i du jeu d'entraînement, la moyenne haute résolution $\mu_{\text{HR}}^{(i)}$ et la baseline sur-échantillonnée $\text{baseline}^{(i)}$, et on les sauvegarde sur disque. Cette mise en cache, qui demande typiquement quelques heures de prétraitement, est un point d'optimisation important sur un budget matériel CPU-only : elle évite de ré-évaluer le module CRM à chaque pas d'entraînement du Stage 2, ce qui réduit le coût marginal d'une époque Stage 2 à celui d'une simple passe de diffusion.

III.8.2. Recalibration de l'écart-type des résiduels

À partir des couples $(\mu_{\text{HR}}^{(i)}, \text{baseline}^{(i)}, x_{\text{HR}}^{(i)})$ pré-calculés, on évalue empiriquement la distribution des résiduels :

$$\delta^{(i)} = \log(1 + x_{\text{HR}}^{(i)}) - \log(1 + \text{baseline}^{(i)}) - \mu_{\text{HR}}^{(i)}. \quad (\text{III.12})$$

L'écart-type empirique des $\delta^{(i)}$ sur l'ensemble du jeu d'entraînement fournit la valeur de l'hyperparamètre σ_{data} utilisé par le préconditionnement EDM (cf. section III.9). Cette recalibration est essentielle pour la stabilité du second étage : un σ_{data} mal calibré conduit soit à une sous-utilisation de la capacité expressive du modèle, soit à une instabilité numérique des coefficients de préconditionnement.

III.8.3. Définition formelle de la propriété (O3)

La propriété (O3) opérationnalise l'idée que le chemin causal d'ORACLE est *structurellement load-bearing*, c'est-à-dire que son retrait dégrade significativement la prédiction. Formellement :

Définition III.1 (Indispensabilité causale, O3). Soit $\text{MSE}(\mu_{\text{HR}}(A_{\text{dag}}); x_{\text{HR}})$ l'erreur quadratique moyenne du Stage 1 lorsque l'inférence utilise la matrice d'adjacence apprise A_{dag} , et $\text{MSE}(\mu_{\text{HR}}(\mathbf{0}); x_{\text{HR}})$ la même quantité lorsque cette matrice est forcée à zéro. La quantité contrastive

$$\Delta_{O3} = \text{MSE}(\mu_{\text{HR}}(\mathbf{0}); x_{\text{HR}}) - \text{MSE}(\mu_{\text{HR}}(A_{\text{dag}}); x_{\text{HR}}) \quad (\text{III.13})$$

mesure l'apport du chemin causal à la qualité de la prédiction. ORACLE satisfait la propriété (O3) à un seuil τ si :

$$\frac{\Delta_{O3}}{\text{MSE}(\mu_{\text{HR}}(A_{\text{dag}}); x_{\text{HR}})} \geq \tau, \quad (\text{III.14})$$

avec typiquement $\tau \in [0,05, 0,10]$ dans nos protocoles.

Figure (Chap III) à produire — Schéma de l'ablation (O3) : deux passes du module Stage 1 sur un même échantillon. Passe normale : $\mu_{\text{HR}}(A_{\text{dag}})$; passe ablatée : $\mu_{\text{HR}}(\mathbf{0})$. Mesure de la différence MSE et seuil τ . Annoter « gate (O3) » sur la comparaison.

Figure 6 – Schéma de la procédure d'ablation pour la propriété (O3). Deux évaluations du Stage 1 sur les mêmes données : l'une avec la matrice A_{dag} apprise, l'autre avec $A_{\text{dag}} = \mathbf{0}$. L'écart d'erreur quadratique entre les deux mesure l'indispensabilité du chemin causal.

III.8.4. Variante d’ablation **noncausal**

L’opérationnalisation de la propriété (O3) repose sur l’existence d’une variante d’ablation que nous nommons **noncausal**, qui force $A_{\text{dag}} = \mathbf{0}$ pendant l’inférence (mais pas pendant l’entraînement). Cette variante est exposée dans le code via un paramètre de configuration `run_variant` et constitue l’instrument expérimental principal de validation du caractère causal du modèle. Les résultats de l’application de cette variante au modèle entraîné, ainsi que la mesure effective de Δ_{O3} sur les jeux de test, sont reportés au chapitre suivant.

III.9. Étage 2 : diffusion EDM résiduelle

III.9.1. Choix du paradigme : EDM Karras 2022

Le second étage d’ORACLE a pour fonction d’échantillonner le résiduel stochastique δ conditionnellement à la moyenne causale μ_{HR} et à la baseline. Nous reprenons sans modification le formalisme EDM proposé par Karras et al. [2], dont les contributions principales pertinentes pour notre travail sont rappelées brièvement ici (un examen détaillé du formalisme est donné au chapitre précédent, sous-section ??).

Le préconditionnement systématique d’EDM s’écrit, pour un niveau de bruit σ et une donnée bruitée $x_\sigma = x + \sigma\epsilon$:

$$\mathcal{D}_\theta(x_\sigma, \sigma) = c_{\text{skip}}(\sigma) \cdot x_\sigma + c_{\text{out}}(\sigma) \cdot \epsilon_\theta(c_{\text{in}}(\sigma) \cdot x_\sigma, c_{\text{noise}}(\sigma)), \quad (\text{III.15})$$

où les coefficients $c_{\text{skip}}, c_{\text{out}}, c_{\text{in}}, c_{\text{noise}}$ sont définis en fonction de σ et σ_{data} selon les formules de Karras et al. L’objectif d’apprentissage est la perte EDM pondérée :

$$\mathcal{L}_{\text{EDM}}(\theta) = \mathbb{E}_{x, \sigma, \epsilon} \left[\lambda(\sigma) \cdot \|\mathcal{D}_\theta(x + \sigma\epsilon, \sigma) - x\|^2 \right], \quad (\text{III.16})$$

où $\lambda(\sigma)$ est une fonction de pondération qui équilibre la contribution des différents niveaux de bruit. L’échantillonnage utilise un solveur de

Heun à pas variable, dont la trajectoire est définie par le calendrier de Karras.

III.9.2. Spécificité Oracle : conditionnement par concaténation de canaux

Le conditionnement du U-Net de diffusion sur les sorties du Stage 1 est un point qui requiert une justification spécifique. La littérature de la diffusion conditionnelle utilise typiquement deux modes : la *cross-attention*, où le conditionnement est injecté via un mécanisme d'attention sur les couches du U-Net, et la *concaténation de canaux*, où le conditionnement est simplement concaténé aux canaux d'entrée du U-Net. ORACLE adopte exclusivement le mode par concaténation, qui s'écrit :

$$\text{input}_{\text{UNet}} = \text{concat}(\delta_{\text{noisy}}, \mu_{\text{HR}}, \log(1 + \text{baseline})) \in \mathbb{R}^{B \times 3 \times H_{\text{HR}} \times W_{\text{HR}}}, \quad (\text{III.17})$$

où $\delta_{\text{noisy}} = \delta + \sigma\epsilon$ est le résiduel bruité au niveau σ . Le U-Net reçoit donc trois canaux d'entrée et produit un canal de sortie (le résiduel débruité).

Le choix de la concaténation contre la cross-attention est motivé par deux raisons. **Premièrement**, la cross-attention introduit une voie d'information parallèle entre μ_{HR} et la sortie du UNet qui contourne en partie le chemin causal architectural ; la concaténation, en revanche, force le U-Net à *voir* μ_{HR} comme un canal d'image qu'il combine localement avec le bruit. **Deuxièmement**, la concaténation est computationnellement moins coûteuse que la cross-attention à résolution complète, ce qui est important sur notre budget CPU-only.

III.9.3. Pourquoi le résidu plutôt que le champ complet

La motivation principale du choix de modéliser le résiduel δ plutôt que le champ complet x_{HR} est la *réduction de l'amplitude* de la variable

Figure (Chap III) à produire — Schéma du conditionnement par concaténation : trois canaux d'entrée empilés (δ_{noisy} , μ_{HR} , $\log(1 + \text{baseline})$) $\rightarrow$ UNet EDM $\rightarrow$ canal de sortie ($\hat{\delta}$). Annoter la flèche « `causal_concat=True` » sur le code de configuration.

Figure 7 — Conditionnement par concaténation de canaux dans le second étage d'ORACLE. Le U-Net reçoit trois canaux d'entrée empilés : le résiduel bruité, la moyenne causale et la baseline log-transformée. Cette concaténation force le passage architectural de l'information causale par les couches initiales du U-Net.

cible. Le champ x_{HR} présente une dynamique de plusieurs ordres de grandeur, depuis les zones sèches (précipitation nulle ou très faible) jusqu'aux extrêmes de précipitation orageuse (plusieurs centaines de millimètres par jour dans certains contextes). À l'inverse, le résiduel δ , obtenu par soustraction de la baseline et de la moyenne causale, a une amplitude réduite, centrée autour de zéro et avec un écart-type typique de l'ordre de σ_{data} après log-transformation.

Cette réduction d'amplitude a deux conséquences directement pertinentes pour notre objectif. **Premièrement**, la calibration de σ_{data} devient sensée : la diffusion EDM opère sur des écarts de l'ordre de σ_{data} , ce qui correspond physiquement à la variabilité fine non capturée par le Stage 1. **Deuxièmement**, et plus important pour l'objectif O2, la variance prédite par le modèle est mieux calibrée sur la variance observée des résiduels, ce qui contribue à réduire la sub-dispersion structurellement constatée chez les modèles génératifs sur le champ complet. La vérification empirique de cette amélioration est différée au chapitre suivant.

III.10. Pertes composites et entraînement

III.10.1. Pertes du premier étage

L'entraînement du premier étage minimise une combinaison de quatre termes de perte. Le terme principal est la perte de prédiction $\mathcal{L}_{\text{mse}}$ entre la moyenne causale prédite μ_{HR} et la cible empirique $\log(1 + x_{\text{HR}}) - \log(1 + \text{baseline})$:

$$\mathcal{L}_{\text{mse}} = \mathbb{E}[\|\mu_{\text{HR}} - (\log(1 + x_{\text{HR}}) - \log(1 + \text{baseline}))\|^2]. \quad (\text{III.18})$$

Le terme $\mathcal{L}_{\text{rec}}$ contraint le décodage des variables d'entrée à partir de l'état latent $\hat{H}_t$ produit par le SCM, ce qui force l'encodeur et le SCM à conserver l'information variable par variable :

$$\mathcal{L}_{\text{rec}} = \sum_{v,p} \mathbb{E}[\|\text{decode}_{v,p}(\hat{H}_t) - x_{v,p,t}\|^2]. \quad (\text{III.19})$$

Les deux derniers termes, regroupés dans $\mathcal{L}_{\text{dag}}$, sont la pénalité DAGMA et la sparsité L_1 sur A_{dag} (équation III.10). La perte totale du premier étage est :

$$\mathcal{L}_{\text{total}}^{(1)} = \mathcal{L}_{\text{mse}} + \alpha \mathcal{L}_{\text{rec}} + \mathcal{L}_{\text{dag}}, \quad (\text{III.20})$$

où α est un coefficient de pondération entre la prédiction terminale et la reconstruction interne.

III.10.2. Perte du second étage

L'entraînement du second étage est plus simple : il consiste exclusivement en la minimisation de la perte EDM (équation III.16), évaluée sur les résiduels pré-calculés à l'issue du Stage 1. Aucune perte auxiliaire n'est ajoutée dans la configuration finale d'ORACLE :

$$\mathcal{L}_{\text{total}}^{(2)} = \mathcal{L}_{\text{EDM}}. \quad (\text{III.21})$$

Nous mentionnons toutefois que nos travaux préparatoires ont ex-

ploré l'ajout de pertes auxiliaires au second étage, en particulier une perte spectrale FACL inspirée de l'esprit des pertes spectrales (chapitre précédent, sous-section ??) et une perte de Wasserstein sliced. Ces ajouts n'ont pas conduit à une amélioration significative des métriques cibles, et ont parfois introduit des instabilités d'entraînement. Ils ont donc été abandonnés dans la version finale d'ORACLE. Les détails empiriques de cet abandon sont reportés au chapitre suivant.

III.10.3. Procédure d'entraînement en deux étages

La procédure d'entraînement d'ORACLE se compose de cinq phases enchaînées, décrites par les algorithmes 2 et 3. La séparation explicite des deux étages et l'usage du pré-calcul sont des choix qui répondent à l'objectif O5 (efficacité computationnelle).

Algorithm 2 Entraînement du premier étage (CRM)

Require: Jeu d'entraînement $\mathcal{D}_{\text{train}}$, hyperparamètres $\alpha, \lambda_{\text{DAGMA}}, \lambda_{L_1}$

- 1: Initialiser les paramètres de l'encodeur, du RCN, du décodeur et de A_{dag}
- 2: **for** chaque époque $e = 1, \dots, E_1$ **do**
- 3: **for** chaque lot $(y_{\text{LR}}, x_{\text{HR}}) \in \mathcal{D}_{\text{train}}$ **do**
- 4: Calculer $\text{baseline} = \text{upsample}(y_{\text{LR}})$
- 5: Encoder les variables d'entrée par l'encodeur intelligible
- 6: Construire le graphe hétérogène G
- 7: Calculer H_T via le RCN (algorithme 1)
- 8: Calculer μ_{HR} via le décodeur graphe-à-grille
- 9: Évaluer $\mathcal{L}_{\text{total}}^{(1)}$ (équation III.20)
- 10: Mettre à jour les paramètres par AdamW
- 11: **end for**
- 12: **end for**
- 13: Geler les paramètres du premier étage
- 14: Pour chaque échantillon $(y_{\text{LR}}, x_{\text{HR}}) \in \mathcal{D}_{\text{train}}$, pré-calculer μ_{HR} et baseline , et sauvegarder sur disque
- 15: Calculer σ_{data} empirique sur les résiduels pré-calculés
- 16: **Gate (O3)** : vérifier $\Delta_{O3}/\text{MSE} \geq \tau$ (équation III.14). Si non, ré-entraîner.

Algorithm 3 Entraînement du second étage (diffusion EDM)

Require: Résiduels pré-calculés $\{\delta^{(i)}, \mu_{\text{HR}}^{(i)}, \text{baseline}^{(i)}\}, \sigma_{\text{data}}$

- 1: Initialiser les paramètres du U-Net de diffusion
- 2: **for** chaque époque $e = 1, \dots, E_2$ **do**
- 3: **for** chaque lot $(\delta, \mu_{\text{HR}}, \text{baseline})$ tiré des pré-calculs **do**
- 4: Tirer σ selon le calendrier EDM
- 5: Tirer $\epsilon \sim \mathcal{N}(0, I)$
- 6: $\delta_{\text{noisy}} \leftarrow \delta + \sigma \epsilon$
- 7: $\text{input}_{\text{UNet}} \leftarrow \text{concat}(\delta_{\text{noisy}}, \mu_{\text{HR}}, \log(1 + \text{baseline}))$
- 8: $\hat{\delta} \leftarrow \mathcal{D}_{\theta}(\text{input}_{\text{UNet}}, \sigma)$ ▷ Équation III.15
- 9: Évaluer $\mathcal{L}_{\text{EDM}} = \lambda(\sigma) \cdot \|\hat{\delta} - \delta\|^2$
- 10: Mettre à jour les paramètres par Adam
- 11: Mettre à jour les poids EMA
- 12: **end for**
- 13: **end for**

III.10.4. Tableau récapitulatif des pertes

Le tableau 2 récapitule les pertes utilisées dans l’entraînement d’ORACLE, en distinguant les pertes effectivement actives dans la configuration finale et celles qui ont été explorées sans être retenues.

III.10.5. Optimisation, EMA et conditioning dropout

Trois éléments du protocole d’optimisation méritent une mention dans ce chapitre, leur justification quantitative étant différée au chapitre suivant. L’*Exponential Moving Average* (EMA) sur les poids du U-Net de diffusion (décroissance 0,9999) stabilise la qualité d’échantillonnage en lissant les fluctuations des paramètres autour de leur trajectoire moyenne. Le *conditioning dropout* (taux $p \approx 0,13$) consiste à remplacer aléatoirement le conditionnement μ_{HR} par un conditionnement nul pendant l’entraînement, ce qui prépare le modèle à une éventuelle utilisation en *classifier-free guidance* à l’inférence. La valeur exacte du facteur `cfg_scale` est elle aussi un paramètre d’optimisation et est discutée au

Tableau 2 – *Pertes utilisées dans l’entraînement d’ORACLE. Les pertes auxiliaires explorées et abandonnées sont reportées en partie basse pour transparence méthodologique.*

Nom	Symbole	Étage	Rôle
Erreur quadratique sur μ_{HR}	$\mathcal{L}_{\text{mse}}$	1	Régression principale, équation III.18
Reconstruction des drivers	$\mathcal{L}_{\text{rec}}$	1	Préserver l’information variable par variable
Pénalité DAGMA	h_{DAGMA}	1	Acyclicité différentiable, équation III.9
Sparsité L_1 sur A_{dag}	$\mathcal{L}_{L_1}$	1	Encourager DAG creux et auditable
Perte EDM pondérée	$\mathcal{L}_{\text{EDM}}$	2	Diffusion sur résidu, équation III.16
<i>Pertes auxiliaires explorées et abandonnées dans la version finale :</i>			
Perte spectrale FACL	$\mathcal{L}_{\text{FACL}}$	2	Préserver le spectre fréquentiel (instable)
Wasserstein sliced	$\mathcal{L}_{\text{SW}}$	2	Distance de Wasserstein 1D (gain marginal)

chapitre suivant.

III.11. Synthèse, traçabilité et choix non retenus

III.11.1. Tableau composant $\times$ inspiration $\times$ verrou adressé

Le tableau 3 retrace, composant par composant, l’inspiration bibliographique principale et le verrou du trilemme adressé. Ce tableau opérationnalise le principe énoncé dans l’introduction du chapitre, selon lequel chaque choix architectural d’ORACLE doit être justifié par référence à la littérature et par contribution à au moins l’un des trois axes du trilemme.

Tableau 3 – *Traçabilité des composants d’ORACLE : inspiration bibliographique et verrou adressé.*

Composant d’Oracle	Inspiration	Verrou
Décomposition à deux étages	CORRDIEST [1]	Stabilité
Graphe hétérogène SP/GP	Contribution propre	O3 / Robustesse OOD
Encodeur intelligible par MLP dédiés	Contribution propre	O6 Interprétabilité
Agrégation SAGEConv	Hamilton	Efficacité
RCN (SCM + GRU)	et al. [6] Pearl [5] SCM [5] + Cho GRU [7]	O3
Apprentissage du DAG par DAGMA	Bello et al. [3]	O6
Décodeur graphe-à-grille par cross-attention	Contribution propre	Efficacité
Diffusion EDM (Stage 2)	Karras et al. [2]	Stabilité, extrêmes
Conditionnement par causal_concat	Contribution propre	O3 architectural
Pré-calcul et mise en cache Stage 1	Contribution propre	Efficacité (O5)
Disclaimer causalité apprise vs physique	Contribution propre	Honnêteté épistémologique

III.11.2. Cartouche conceptuel final d’Oracle

La figure 8 fournit la vue complète de l’architecture ORACLE, en y indiquant les équations clés et les références bibliographiques. Elle constitue la version exhaustive de la vue simplifiée présentée en figure 1 ; ensemble, ces deux figures encadrent le chapitre comme une exposition graphique progressive du modèle.

III.11.3. Choix architecturaux non retenus

Au cours du développement d’ORACLE, plusieurs voies architecturales alternatives ont été envisagées et écartées. Nous les exposons briè-

Figure (Chap III) à produire — Cartouche conceptuel final d’Oracle : reprise de F1 (Chap III) enrichie. Annotations des équations clés (eq. III.1, III.3, III.9, III.15, III.17). Numéros de référence [1], [2], [3], [5] positionnés sur les blocs correspondants.

Figure 8 — Vue complète et finale du modèle ORACLE avec annotations des équations clés et des références bibliographiques sur chaque composant. Le premier étage causalise CORRDIFF [1] par insertion d’un module structurellement causal (graphe + RCN + DAGMA [3], SCM Pearl [5]) ; le second conserve la diffusion EDM [2].

vement ici, à des fins de transparence méthodologique et pour aider à situer le périmètre exact de notre proposition.

La première alternative considérée est l’usage de *Diffusion Transformers* (DiT) comme backbone du second étage, en remplacement du U-Net classique. Cette option, qui a fait ses preuves sur la génération d’image grand public, n’a pas été retenue pour deux raisons : son coût computationnel est sensiblement plus élevé que celui du U-Net pour des résolutions de l’ordre de 172×179 , et l’apport empirique pour le downscaling à cette échelle reste à démontrer.

La deuxième alternative considérée est l’usage de *flow matching* ou de *consistency models* en lieu et place de la diffusion EDM. Ces approches plus récentes promettent un coût d’inférence inférieur, mais leur maturité sur les applications downscaling reste limitée à la date de rédaction de ce mémoire. Elles constituent une perspective naturelle de continuation et sont signalées comme telles dans la conclusion générale.

La troisième alternative considérée est l’injection des drivers statiques comme canaux supplémentaires du U-Net Stage 2, en plus de leur présence dans le graphe. Cette voie hybride aurait permis au Stage 2 d’accéder directement à l’orographie sans passer par le chemin causal. Elle a été écartée précisément pour préserver la propriété architecturale selon laquelle toute information transite par le DAG appris ; cette préservation est essentielle à la validité de la propriété (O3) et à l’auditabilité

du modèle.

La quatrième alternative considérée est l’usage d’une cross-attention entre μ_{HR} et les couches intermédiaires du U-Net pour le conditionnement du second étage. Comme expliqué en section III.9.2, ce mode introduit une voie d’information parallèle qui dilue la traçabilité causale ; nous lui avons préféré la concaténation de canaux.

Enfin, plusieurs variantes méthodologiques ont été explorées pendant la trajectoire de développement du projet avant d’être écartées au profit de l’architecture intégrée présentée dans ce chapitre. Le détail de ces explorations et de leur abandon est documenté au chapitre suivant, dans le cadre de la méthodologie expérimentale.

III.11.4. Transition vers le Chapitre IV

Le présent chapitre a présenté ORACLE dans sa forme architecturale finale, telle qu’elle est implémentée dans la version actuelle du projet. La validation empirique de ses choix — en particulier la satisfaction effective de la propriété (O3), la mesure de la sub-dispersion résiduelle, et la robustesse hors-distribution — constitue l’objet du chapitre suivant. Y sont également documentés l’environnement logiciel, les jeux de données, la trajectoire de développement qui a conduit à la forme finale, et la discussion des résultats expérimentaux.

BIBLIOGRAPHIE

- [1] M. Mardani, N. Brenowitz, Y. Cohen, J. Pathak, C.-Y. Chen, C.-C. Liu, A. Vahdat, K. Kashinath, J. Kautz, and M. Pritchard. Residual corrective diffusion modeling for km-scale atmospheric downscaling. *arXiv preprint arXiv :2309.15214*, 2023.
- [2] T. Karras, M. Aittala, T. Aila, and S. Laine. Elucidating the design space of diffusion-based generative models. In *Advances in Neural Information Processing Systems*, 2022.
- [3] K. Bello, B. Aragam, and P. Ravikumar. DAGMA : Learning DAGs via M-matrices and a log-determinant acyclicity characterization. In *Advances in Neural Information Processing Systems*, 2022.
- [4] X. Zheng, B. Aragam, P. Ravikumar, and E. P. Xing. DAGs with NO TEARS : Continuous optimization for structure learning. In *NeurIPS*, 2018.
- [5] J. Pearl. *Causality : Models, Reasoning, and Inference*. Cambridge University Press, 2nd edition, 2009.
- [6] W. L. Hamilton, R. Ying, and J. Leskovec. Inductive representation learning on large graphs. In *NeurIPS*, 2017.
- [7] K. Cho, B. van Merriënboer, C. Gulcehre, D. Bahdanau, F. Bougares, H. Schwenk, and Y. Bengio. Learning phrase representations using RNN encoder-decoder for statistical machine translation. In *EMNLP*, 2014.
- [8] N. Rampal, P. B. Gibson, S. Hobeichi, J. Sherwood, and S. B. Po-

wer. Reliable generative downscaling of climate data with conditional GANs. *Journal of Advances in Modeling Earth Systems*, 2024.