

CHAPITRE

IV

MATÉRIELS, MÉTHODES, EXPÉRIMENTATIONS ET DISCUSSION

IV.1	Introduction	70
IV.2	Environnement et données	71
IV.3	Topologie effective d'ORACLE	72
IV.4	Trajectoire et procédure d'entraînement	75
IV.5	Protocole d'évaluation	77
IV.6	Résultats observés	79
IV.7	Discussion critique	87
IV.8	Synthèse	90

IV.1. Introduction

Le chapitre précédent a présenté ORACLE dans sa forme architecturale finale. Ce chapitre confronte la proposition à l'expérimentation et discute honnêtement gains et limites. Nous décrivons d'abord l'environnement et les données (section IV.2), la topologie effectivement entraînée (section IV.3), la trajectoire de développement et la procédure d'optimi-

sation (section IV.4), puis le protocole d'évaluation (section IV.5). Les résultats sont exposés en section IV.6 et discutés en section IV.7. Une synthèse (section IV.8) clôt le chapitre. Notre démarche assume deux principes de transparence : nous documentons les variantes écartées en cours de route, et nous présentons les métriques sur lesquelles ORACLE progresse comme celles sur lesquelles il sous-performe.

IV.2. Environnement et données

IV.2.1. Pile logicielle et matériel

L'implémentation repose sur Python 3.11 et PyTorch 2.3, étendu par PyTorch Geometric [?] pour les opérateurs sur graphe hétérogène, xarray [?] pour l'ingestion des sorties GCM, et Hydra [?] pour la configuration en YAML hiérarchiques. La précision mixte automatique (`bfloat16` sur GPU, `float32` sur CPU) et la compilation `torch.compile` du UNet du second étage réduisent l'empreinte mémoire et accélèrent l'exécution d'environ 30 %.

Le développement local s'appuie sur une machine CPU-only à environ 500 Go de mémoire, sans GPU. Les phases d'entraînement intensif utilisent Google Colab avec un GPU NVIDIA A100 (40 Go) ou un T4 (16 Go) en parallélisme multi-GPU. Un cycle complet d'entraînement d'ORACLE demande environ 45 heures sur A100 : 10 à 15 époques de Stage 1, suivies de 200 époques de Stage 2 sur résiduels mis en cache. Chaque exécution fixe une graine aléatoire et sérialise l'historique complet de l'entraînement dans le point de contrôle, ce qui garantit la reproductibilité.

IV.2.2. Données et prétraitements

Le domaine d'étude est la Nouvelle-Zélande, choisie pour la disponibilité d'un jeu de données aligné sur la référence CORRDIFF [?]. La grille HR couvre 172×179 pixels (résolution effective de 5 à 10 km). Les

prédicteurs LR sont issus du modèle ACCESS-CM2 (CMIP6 historique), interpolés sur une grille 23×26 que nous sur-échantillonons par interpolation bilinéaire vers la résolution cible (*baseline*). Quinze variables atmosphériques sont conservées : vent u, v, w , humidité spécifique q et température t , chacune à trois niveaux 850, 500 et 250 hPa.

La cible HR est la précipitation journalière, traitée en espace $\log(1 + \text{precip})$ pour stabiliser l'entraînement face à la queue lourde. La sortie finale du modèle est reconstruite par

$$\hat{x}_{\text{HR}} = \text{baseline} + \mu_{\text{HR}} + \hat{\delta}, \quad (\text{IV.1})$$

où μ_{HR} est la moyenne haute résolution causale et $\hat{\delta}$ le résiduel échantillonné par la diffusion. Les données sont partitionnées en entraînement (1980–2009), validation (2010–2012) et test ID (ACCESS-CM2, 2013–2014). Les jeux inter-GCM historiques sont EC-Earth3 et NorESM2-MM sur la même période d'évaluation. Chaque échantillon est une séquence de $T = 8$ pas temporels avec fenêtre glissante de pas 4. Les variables LR sont normalisées canal par canal sur l'ensemble d'entraînement ; un masque binaire exclut les pixels océaniques des pertes et des métriques (domaine continental utile $\approx 60\%$).

IV.3. Topologie effective d'Oracle

La Figure IV.1 synthétise l'architecture globale d'ORACLE comme un pipeline en deux étages : un premier étage causal qui produit la moyenne déterministe μ_{HR} à partir d'un graphe hétérogène intelligible, et un second étage de diffusion résiduelle qui ajoute la composante stochastique $\hat{\delta}$ pour reconstruire la sortie $\hat{x}_{\text{HR}}$. La Figure IV.2 détaille la topologie du graphe à $N = 6$ nœuds typés exploité par le RCN du Stage 1.




Figure IV.1 – Pipeline architectural d'ORACLE : Stage 1 (causal, déterministe) produit la moyenne μ_{HR} par chemin obligatoire à travers le DAG appris ; Stage 2 (diffusion EDM) échantillonne le résiduel $\hat{\delta}$ conditionné par concaténation de canaux.




Figure IV.2 – Graphe atmosphérique hétérogène à $N = 6$ nœuds typés. La hiérarchie verticale $GP_{250} \rightarrow GP_{500} \rightarrow GP_{850}$ reflète le couplage quasi-géostrophique descendant attendu ; SP_{HR} est la sortie haute résolution.

IV.3.1. Premier étage : encodeur, RCN, décodeur

L'encodeur intelligible comporte un perceptron multicouche dédié par couple variable-niveau (15 sous-réseaux), chacun produisant une représentation latente de dimension $d = 128$. L'absence de paramètres partagés empêche le mélange précoce des informations et préserve la lisibilité de la matrice A_{dag} apprise par DAGMA [?]. Le graphe hétérogène

comporte $N = 6$ nœuds : trois nœuds spatiaux par niveau de géopotential (GP850, GP500, GP250), deux nœuds de couplage inter-niveaux (GP850→GP500, GP500→GP250) et un nœud de sortie SP_HR. La matrice $A_{\text{dag}} \in \mathbb{R}^{6 \times 6}$ est initialisée selon un *prior* tridiagonal physique (couplage quasi-géostrophique descendant) mais reste librement apprenable.

La cellule du RCN combine une propagation par A_{dag} et une mise à jour GRU [?] sur huit pas temporels. Une perte de reconstruction $\mathcal{L}_{\text{rec}}$ pèse sur chaque pas, ce qui empêche le RCN d'apprendre une représentation déconnectée de l'identité physique des variables. Le décodeur **GraphToGridDecoder** transforme l'état final H_T en moyenne μ_{HR} par cross-attention vers une grille intermédiaire 43×45 , sur-échantillonnage bilinéaire et raffinement convolutif léger (deux couches Conv 3×3 , 32 canaux, GELU), pour environ 407 000 paramètres.

ORACLE ajoute une *skip-connection conditionnelle* **ConditionalSkipBlock** qui combine deux voies :

$$\mu_{\text{HR}} = \alpha(y_{\text{LR}}) \cdot \mu_{\text{causal}} + (1 - \alpha(y_{\text{LR}})) \cdot \mu_{\text{direct}}, \quad (\text{IV.2})$$

avec $\alpha(y_{\text{LR}}) \in [0, 1]$ une porte apprise, initialisée biaisée vers la voie causale ($\alpha_0 \approx 0,88$) et contrainte par une régularisation $\mathcal{L}_{\text{O3-preserve}}$ qui pénalise toute dérive sous $\alpha_{\text{floor}} = 0,6$. Cette régularisation empêche le modèle de devenir non-causal déguisé tout en libérant une capacité résiduelle pour les cas où le LR brut contient un signal directement exploitable.

IV.3.2. Second étage : UNet EDM

Le second étage est un UNet résiduel EDM [?] en configuration *Normal* de l'implémentation CORRDIF de NVIDIA PhysicsNeMo : quatre niveaux de profondeur, `block_out_channels` = (128, 256, 256, 256), environ 42,8 millions de paramètres. Le conditionnement se fait par concaténation de canaux à l'entrée du UNet, qui reçoit le tenseur à trois

canaux $[\delta_{\text{bruité}}, \mu_{\text{HR}}, \log(1 + \text{baseline})]$. Cette interface garantit la propriété (O3) : remplacer μ_{HR} par zéro modifie nécessairement la sortie.

L'écart-type des données σ_{data} est recalibré à la fin du Stage 1 par l'algorithme de Welford sur les résiduels réels (typiquement $\sigma_{\text{data}} \approx 0,19$). Cette recalibration empêche le UNet d'apprendre l'identité par défaut — pathologie observée dans nos versions antérieures.

IV.4. Trajectoire et procédure d'entraînement

IV.4.1. Trajectoire P0→P4

La trajectoire de développement éclaire les choix architecturaux retenus. Elle a démarré (P0) avec l'antécédent HG-SCM [?], abandonné après confirmation que son périmètre relève de la classification de nœuds et non du downscaling génératif probabiliste — les deux problèmes diffèrent par nature, et aucune transposition directe ne conservait l'esprit du modèle source.

La phase P1 (mars 2026) a implémenté une première version utilisant un schedule DDPM standard [?] et un UNet à deux niveaux, avec conditionnement par cross-attention. Une ablation a révélé une pathologie de fond : le UNet apprenait à *contourner* le conditionnement causal. Remplacer A_{dag} par zéro ne dégradait pas la prédiction — la propriété (O3) échouait.

La phase P2 (mai 2026) a diagnostiqué trois pathologies simultanées : σ_{data} mal calibré, DAG décoratif, et sur-lissage des extrêmes. Le pivot a remplacé DDPM par EDM [?], ce qui a réglé la calibration via le préconditionnement explicite de σ_{data} . Mais le DAG décoratif persistait : tant qu'un chemin de bypass existait entre l'état latent et la sortie, le réseau l'empruntait.

Les phases P0 à P2 reposaient sur un schéma *single-stage*. L'innovation introduite en P3 est précisément le passage au paradigme *two-*

stage : moyenne déterministe causale (RCN sur A_{dag}) suivie d'un résidu stochastique par diffusion EDM. P4 conserve ce paradigme et le finalise. La séquence LR $\rightarrow$ encoder $\rightarrow$ RCN $\rightarrow H_T \rightarrow \mu_{\text{HR}}$ devient un chemin de calcul sans bypass possible : μ_{HR} est mathématiquement $f(H_T(A_{\text{dag}}))$ et rien d'autre. La causalité architecturale passe de *prior* à dépendance fonctionnelle garantie par la topologie. Une pathologie secondaire est apparue — le *residual collapse* d'un UNet sous-dimensionné apprenant à prédire un résiduel quasi-nul.

La phase P4 (mai–juin 2026) a remonté le UNet à sa taille cano-nique (42,8 M paramètres), recalibré σ_{data} systématiquement, et migré le sampler vers DPM-Solver++ [?] avec *churn*. Cinq leviers complémentaires composent la variante finale : pondération tail-weighted de la perte Stage 1, supervision séquence-à-séquence stochastique, prior physique tridiagonal sur A_{dag} , skip-connection conditionnelle, et pondération tail-weighted EDM Stage 2.

Variante alternative écartée. Une version plus capacitaire (encodeur 192-dim, pertes spectrales FACL, régularisation Wasserstein, EMA) a été testée puis abandonnée : après correction de plusieurs bugs d'implémentation, elle ne battait pas la baseline V4. Cet épisode justifie le principe de parcimonie de la version finale retenue.

IV.4.2. Procédure two-stage et sampler à l'inférence

Le premier étage entraîne conjointement encodeur, RCN, décodeur et skip-block via AdamW [?] (taux 5×10^{-4} , décroissance cosinus, 10 à 15 époques). La perte composite combine MSE pixel sur μ_{HR} , reconstruction $\mathcal{L}_{\text{rec}}$, pénalité d'acyclicité $\mathcal{L}_{\text{DAGMA}}$ (warmup linéaire sur 5 époques), pénalité L_1 sur A_{dag} , régularisation $\mathcal{L}_{\text{O3-preserve}}$, pondération tail-weighted ($\tau = \log(1 + 10)$ mm/j, $\alpha = 0,5$), supervision séquence-à-séquence stochastique sur $k = 5$ pas, et prior physique tridiagonal.

Le second étage entraîne le UNet diffusif sur les résiduels Stage 1 gelés, mis en cache pour éviter le re-décodage à chaque batch. La perte

EDM est

$$\mathcal{L}_{\text{EDM}} = \mathbb{E}_{\sigma, \delta, n} [\lambda(\sigma) \cdot \|\mathcal{D}_\theta(\delta + \sigma n, \sigma) - \delta\|_2^2], \quad (\text{IV.3})$$

avec $n \sim \mathcal{N}(0, I)$ et $\lambda(\sigma) = (\sigma^2 + \sigma_{\text{data}}^2)/(\sigma \cdot \sigma_{\text{data}})^2$, multipliée par un facteur 2,0 au-delà du quantile p99 de la précipitation reconstruite. À l'inférence, le sampler DPM-Solver++ utilise 32 pas, $S_{\text{churn}} = 40$ pour la diversité, et $\text{cfg} = 1,5$ pour accentuer le conditionnement. La taille d'ensemble est $K = 12$ membres pour les évaluations inter-GCM historiques coûteuses, $K = 64$ pour les évaluations ID.

Entre les deux étages, σ_{data} est recalibré et la porte O3 est vérifiée par mesure du ratio

$$\text{ratio}_{\text{O3}} = \mathbb{E} [|\mu_{\text{HR}}(A_{\text{dag}}) - \mu_{\text{HR}}(\mathbf{0})|] / \mathbb{E} [|\mu_{\text{HR}}(A_{\text{dag}})|]. \quad (\text{IV.4})$$

Un ratio inférieur à 0,05 signalerait que A_{dag} ne porte pas assez de signal et l'entraînement serait interrompu. La valeur mesurée pour ORACLE est 0,87, ce qui valide le passage à Stage 2.

Portée et limites

Ce que mesure (et ne mesure pas) le ratio O3. L'ablation $A_{\text{dag}} = 0$ mesure la sensibilité fonctionnelle du modèle à la matrice apprise. Un ratio de 0,87 indique que la matrice contribue à la qualité de sortie, mais ne prouve pas qu'elle capture une relation causale au sens de Pearl. Un contrôle plus exigeant — couper une arête tirée au hasard et observer une dégradation comparable — n'a pas été conduit ici et constitue une limite explicite. Le ratio O3 doit donc être lu comme un indicateur d'importance fonctionnelle, non comme une preuve de causalité.

IV.5. Protocole d'évaluation

Convention d'unités. Sauf mention contraire, les métriques d'erreur (RMSE, MAE, CRPS) du Tableau IV.1 sont reportées dans l'espace $\log(1 + \text{precip})$ (espace d'entraînement, sans unité). Les métriques cli-

matologiques du Tableau IV.3 (RX1day, R10mm, CDD) sont reportées en mm/jour (espace physique).

Aide-mémoire. RMSE/MAE : erreurs quadratique/absolue (proche de 0 = mieux). CRPS : version probabiliste du MAE. Spread/RMSE : 1 = bien calibré, < 1 = trop confiant. RAPSD/FSS : structure spatiale (RAPSD proche de 0, FSS proche de 1). RX1day/R10mm/CDD : indices ETCCDI sur la précipitation. Δ_{signal} : sensibilité au DAG (proche de 1 = plus utilisé). Q_{int} : signes corrects sur 2 perturbations. Q_{phys} : orientation du DAG (0,5 = aléatoire, 1 = parfait).

L'évaluation mobilise quatre familles de métriques croisées. L'*erreur ponctuelle* (RMSE, MAE, Pearson, global et par échantillon); la *calibration probabiliste* (CRPS, CRPS-SS relatif à une climatologie, ratio *spread-skill*, histogramme de rang); la *structure spatiale* (distance RAPSD, FSS à plusieurs échelles); les *extrêmes* (F1 aux quantiles p95 et p99, indices ETCCDI [?] : RX1day, R10mm, CDD). Le CRPS-SS utilise comme référence la climatologie empirique pixel par pixel calculée sur le jeu de test (365 jours); une référence calendrier 1991-2020 reste en perspective.

Deux diagnostics spécifiques à l'architecture causale sont conduits. Le *ratio O3* mesure l'indispensabilité architecturale du DAG (équation IV.4). Le *test de perturbation contrôlée* mesure la réponse du modèle à des perturbations $\Delta(\cdot)$ atomiques sur les variables atmosphériques — $\Delta(q_{850} + 20\%)$ et $\Delta(t_{850} + 3 \text{ K})$ —, comparée au signe physiquement attendu (Clausius-Clapeyron). Nous quantifions le résultat par Q_{int} , la fraction des perturbations cohérentes en signe, avec intervalle de confiance bootstrap 95 % sur $n = 30$ jours.

Le test inter-GCM en régime historique utilise deux GCM extérieurs (EC-Earth3, NorESM2-MM) sur la même période et les mêmes hyperparamètres que le test ID. Chaque résultat est comparé à une baseline *Noncausal* qui remplace encodeur intelligible et RCN par un régresseur convolutif générique (**RegressionMeanPredictor**), tout en conservant à l'identique le UNet EDM et les hyperparamètres. Cette comparaison isole strictement l'effet de la causalisation du Stage 1.

Portée et limites

Portée du test inter-GCM historique. EC-Earth3 et NorESM2-MM restent en régime historique. Un test plus exigeant utiliserait un scénario SSP futur. Le test de perturbation contrôlée Q_{int} constitue un argument indirect en faveur d’une telle robustesse ; la validation directe en projection future fait partie des perspectives.

IV.6. Résultats observés

IV.6.1. Performance en distribution

Tableau IV.1 – *Métriques en distribution sur ACCESS-CM2 (2013–2014), espace $\log(1 + \text{precip})$, ensemble $K = 64$. Les intervalles entre crochets sont des IC 95% bootstrap (10 000 rééchantillonnages, $n = 16$ valeurs per-sample).*

Métrique	ORACLE	Noncausal	Δ_{rel}
RMSE	0,124	0,130	−4,1%
MAE	0,060	0,064	−5,7%
Pearson global	0,825	0,819	+0,7%
Pearson per-sample	0,834 [0,802, 0,865]	0,829 [0,795, 0,860]	$\Delta = +0,005 [-0,042]$
F1@p95	0,650	0,656	−0,8%
F1@p99	0,512	0,550	−6,9%
RAPSD distance	241,8	270,1	−10,5%
Δ_{signal} (sensibilité L^1 , $\mu_{\text{HR}} \rightarrow 0$)	0,872	0,839	+4,0%

Note de notation. Δ_{signal} mesure la chute relative de la norme L^1 du signal prédit lorsque A_{dag} est mis à zéro. Distinct du ratio O3 strict (ΔMSE relatif, valeur $\approx 0,107$ rapportée plus loin), qui mesure l’effet sur l’erreur quadratique. Les deux quantités ne sont pas numériquement comparables.

Note IC. Les intervalles entre crochets sont des IC 95% obtenus par bootstrap (10 000 rééchantillonnages avec remise) sur les $n = 16$ valeurs per-sample.

ORACLE améliore l’erreur ponctuelle de quatre à six pourcent et réduit la distance spectrale RAPSD de plus de dix pourcent ; la corrélation

Pearson reste statistiquement comparable. La structure de l'amélioration suggère que le premier étage causal ne change pas l'ordre de grandeur de la prédiction moyenne mais la place mieux dans l'espace des fréquences spatiales. La métrique F1@p99 régresse, ce qui est discuté en annexe.




Figure IV.3 — Spectres radiaux moyens. La distance PSD ORACLE-ERA5 est réduite d'un facteur ~ 450 vs CORRDIFF.

Le *Fractions Skill Score* confirme par ailleurs cette amélioration de la structure spatiale : ORACLE devient *skillful* dès l'échelle ~ 30 km, contre ~ 80 km pour CORRDIFF. Le détail du FSS en fonction de l'échelle spatiale est reporté en annexe IV.E (Fig. IV.12).


IV.6.2. Calibration probabiliste

Le CRPS chute de 40% par rapport à la baseline non-causale — gain statistiquement significatif au sens des tests de Diebold-Mariano et Wilcoxon sur $n = 365$ jours $\times \approx 18\,000$ pixels continentaux. Le ratio *spread-skill* passe de 0,20 à 0,69, soit un facteur 3,5 d'amélioration de la calibration d'ensemble. Le modèle reste sous-dispersif au sens strict de Fortin et al. [?] (cible 1,0) mais sort largement du régime « ensemble inutilisable » ($< 0,5$) pour entrer dans une zone où la quantification d'in-

Tableau IV.2 – Métriques probabilistes en distribution sur ACCESS-CM2, ensemble $K = 12$.

Métrique	ORACLE	Noncausal	Lecture
CRPS (mm/j)	0,249	0,415	gain -40%
CRPS-SS (vs climatologie)	+0,895	+0,826	+6,9 pts
Spread/RMSE	0,686	0,197	$\times 3,5$
RMSE global (mm/j)	1,118	1,537	-27%
χ^2 histogramme de rang	$5,4 \times 10^6$	$3,25 \times 10^7$	-83%

certitude commence à être informative. L’histogramme de rang réduit son écart au profil uniforme d’un facteur six.

**Figure IV.4** – Diagramme de fiabilité. ORACLE proche de la diagonale ; CORRDIFF sur-confiant. Sous-dispersion résiduelle.

IV.6.3. Indices climatiques et extrêmes

Tableau IV.3 – Biais sur les indices ETCCDI en distribution. Plus c’est proche de zéro, mieux c’est.

Index	ORACLE	Noncausal	Lecture
RX1day (mm)	-2,73	-4,09	ORACLE sous-prédit moins (-33%)
R10mm (jours)	+0,88	+2,65	gain net (-67%)
CDD (jours)	+17,95	+21,51	gain (-17% , cf. annexe)
DJF moyen (mm/j)	-0,25	-0,09	comparable
PSD distance	0,001	0,447	gain massif ($\times 450$)

ORACLE sous-prédit moins les extrêmes journaliers que la baseline (RX1day $-2,73$ vs $-4,09$ mm) et place mieux le nombre de jours de pluie modérée (R10mm $+0,88$ vs $+2,65$). Le nombre de jours secs consécutifs reste sur-estimé d’environ dix-huit jours, biais résiduel hérité de la fonction de perte CRPS/MSE attirant les prédictions vers la médiane

conditionnelle (cf. annexe). La distance spectrale de puissance tombe à un niveau quasi-négligeable.

L’histogramme des intensités de pluie en échelle log-log confirme qu’ORACLE reproduit la queue droite jusqu’aux valeurs extrêmes alors que CORRDIFF la tronque au-delà de ~ 30 mm/j ; le détail est reporté en annexe IV.E (Fig. IV.11).




Figure IV.5 — *Biais sur RX1day. Le déficit se concentre sur le versant occidental — révèle l’absence de DEM.*

Portée et limites

Limite assumée — Indice CDD. Le biais résiduel sur CDD (+18 j) dépasse l’amplitude climatologique typique de la Nouvelle-Zélande (12 à 17 j). Deux causes structurelles : (i) le seuil de jour sec à 1 mm est très sensible à la queue basse que la perte CRPS lisse vers la médiane ; (ii) le modèle est entraîné en sortie continue sans tête Bernoulli explicite. **Nous ne revendiquons donc aucune valeur opérationnelle de l’Oracle actuel pour le diagnostic de sécheresse.** Une tête Bernoulli-gamma est portée en perspective.

IV.6.4. Robustesse inter-GCM en régime historique

Tableau IV.4 – Métriques inter-GCM historiques sur deux GCM extérieurs ($ID = ACCESS-CM2$ rappelé pour référence).

GCM	ORACLE		Noncausal		Δ CRPS	Lecture
	CRPS	spr/RMSE	CRPS	spr/RMSE		
ACCESS-CM2 (ID)	0,249	0,686	0,415	0,197	−40%	gain net
EC-Earth3 (inter-GCM)	0,319	0,575	0,457	0,183	−30%	gain net
NorESM2-MM (inter-GCM)	0,342	0,593	0,478	0,196	−28%	gain net

Sur le split ID, ORACLE atteint un CRPS de 0,249 contre 0,415 pour CORRDIFF (gain absolu de 40%). Sur les splits inter-GCM, ORACLE monte à 0,319 (EC-Earth3) et 0,342 (NorESM2-MM) contre 0,457 et 0,478 respectivement. ORACLE part d'un meilleur point ID ; sa dégradation relative inter-GCM est légèrement plus marquée que celle de CORRDIFF, mais il reste $1,4\times$ meilleur en valeur absolue. Le gain causal porte donc sur le *niveau* d'erreur, pas sur la *pente* de dégradation. Le ratio *spread-skill* reste largement au-dessus de la baseline sur les deux jeux inter-GCM (0,58 à 0,59 vs 0,18 à 0,20).

IV.6.5. Diagnostics causaux

Tableau IV.5 – Réponse aux perturbations contrôlées $\Delta(q + 20\%)$ et $\Delta(t + 3 \text{ K})$; IC bootstrap 95 % sur $n = 30$.

Modèle	Perturbation	δ_{moy}	IC 95 %	Signe	Lecture
ORACLE	$\Delta(q_{850})$	$+1,24 \times 10^{-3}$	exclut 0	oui	cohérent CC
ORACLE	$\Delta(t_{850})$	$+0,84 \times 10^{-3}$	exclut 0	oui	cohérent CC
Noncausal	$\Delta(q_{850})$	$+0,55 \times 10^{-3}$	exclut 0	oui	cohérent
Noncausal	$\Delta(t_{850})$	$-0,84 \times 10^{-3}$	exclut 0	non	contraire CC

ORACLE répond avec un signe physiquement correct aux deux perturbations contrôlées (2 interventions testées, 2 cohérentes). La baseline non-causale répond correctement à la perturbation d'humidité mais avec

un signe inversé à la perturbation thermique (1 sur 2 cohérente). Cette inversion s'explique par le fait que la baseline apprend une corrélation observationnelle entre température élevée et régimes anticycloniques secs de Nouvelle-Zélande, sans capter la relation Clausius-Clapeyron qui agirait toutes choses égales par ailleurs.

Portée et limites

Précautions sur Q_{int} . La taille d'échantillon $n = 30$ par perturbation est modeste, les magnitudes mesurées sont petites (de l'ordre de 10^{-3} en unités relatives), et la matrice A_{dag} apprise reste à magnitudes globalement uniformes. Il est plus prudent de parler de *réponse interventionnelle cohérente* dans le sens physique attendu que d'*identification causale complète*.

Structure de A_{dag} . La matrice apprise comporte sept arêtes de magnitude $\geq 0,05$ sur les vingt-cinq entrées hors-diagonale, toutes comprises entre 0,178 et 0,189 — distribution remarquablement plate. Sur cinq arêtes physiquement attendues, deux sont correctement orientées ($Q_{\text{phys}} = 0,40$). Cette observation est cohérente avec la limite théorique d'identifiabilité de l'apprentissage de structure sur données observationnelles [?] : DAGMA pénalise non-acyclicité et non-parcimonie, mais ne possède pas les contraintes nécessaires pour hiérarchiser les magnitudes survivantes. Le DAG appris est donc à interpréter comme une régularisation structurelle inductive, nuance reprise en discussion.




Figure IV.6 – DAG appris A_{dag} (lignes = enfants, colonnes = parents). La structure est plate ($Q_{\text{phys}} = 0,40$, deux arêtes physiquement attendues sur cinq correctement orientées). La comparaison avec le DAG physique attendu et les cartes de réponse aux perturbations contrôlées sont reportées en annexe IV.D (Fig. IV.9 et Fig. IV.10).

Portée et limites

Limites de l'apprentissage de A_{dag} . (a) Les magnitudes des arêtes sont quasi-uniformes ($\sim 0,18$), suggérant l'absence de hiérarchie causale marquée. (b) L'ablation contrôlée donne $\Delta\text{MSE} = 0,107$ quand on remplace A_{dag} par une matrice aléatoire : la contribution à la performance est modeste. (c) Les gains principaux d'ORACLE proviennent vraisemblablement de l'architecture two-stage avec concat-conditioning et de la recalibration σ_{data} , plutôt que de la structure causale hiérarchisée elle-même. L'apport scientifique du DAG est donc à comprendre comme une régularisation structurelle qui force le passage par des embeddings physiquement interprétables, plus que comme une découverte causale forte.

Simplification revendiquée du DAG à 6 nœuds. Le graphe causal appris ne comporte que six nœuds, un par variable d'entrée agrégée. Cette granularité est une simplification revendiquée : elle rend le DAG lisible et apprenable, mais ne représente pas explicitement les opérateurs dynamiques (vorticité, divergence, advection d'humidité) qui

structurent la circulation atmosphérique. Un graphe à 12-20 nœuds enrichi par des diagnostics dynamiques est une perspective immédiate.

Effet de proxy : t comme substitut de q . Les sensibilités intégrées (cf. annexe IV.C) rapportent t_{850} (0,118) au-dessus de q_{850} (0,046). Ce classement est l'inverse de la hiérarchie causale attendue : c'est l'humidité qui détermine directement le contenu précipitable. Nous l'interprétons comme un **effet de proxy** : à l'échelle synoptique néo-zélandaise, t_{850} et q_{850} sont corrélées via la relation Clausius-Clapeyron observationnelle. Le modèle exploite cette corrélation statistique mais ne distingue pas causalement les deux variables. Pathologie qu'un graphe causal devrait révéler — motive l'enrichissement du DAG (perspective).

Arête physiquement incorrecte $SP_HR \rightarrow GP850$. Une arête du DAG appris pointe de la précipitation haute résolution SP_HR vers le géopotentiel à 850 hPa. **Cette arête est physiquement incorrecte** : la pluie locale est une conséquence de la dynamique grande échelle, pas une cause. Plutôt que de masquer cette arête, nous la rapportons explicitement : c'est précisément le type de défaut qu'un DAG ouvert au jury doit exposer. Une version améliorée injectera des contraintes d'orientation par tiers temporel (large échelle $\Rightarrow$ locale).

Quantification Clausius-Clapeyron. Sous $\Delta t + 3$ K, ORACLE prédit Δ pluie moyenne $\approx +0,84 \cdot 10^{-3}$ mm/j. Rapporté à une climatologie moyenne ≈ 3 mm/j et à un forçage de 3 K, la sensibilité simulée vaut :

$$0,84 \cdot 10^{-3} / (3 \times 3) \approx 0,01\%/K.$$

La relation de Clausius-Clapeyron prédit $\sim 7\%/K$. Notre modèle est donc à environ **trois ordres de grandeur en dessous**. Le signe est correct, la magnitude ne l'est pas. Le test d'intervention vaut comme contrôle de cohérence directionnelle, **pas comme outil de projection climatique**.

IV.7. Discussion critique

IV.7.1. Contributions empiriques défendables

Trois résultats se défendent solidement. D’abord, la réduction de 40% du CRPS en distribution et de 28 à 30 % en inter-GCM historique est statistiquement significative et ne dépend pas du choix d’hyperparamètres d’évaluation. Ensuite, l’amélioration du ratio *spread-skill* d’un facteur 3,5 fait sortir le modèle du régime « ensemble inutilisable ». Enfin, la quasi-disparition de la distance spectrale de puissance (de 0,45 à 0,001) signifie que la distribution des intensités à toutes les échelles spatiales coïncide avec la cible — marqueur difficile à reproduire par des modèles non-structurés.

IV.7.2. Causalité architecturale et limite d’identification

La propriété (O3) est satisfaite par construction (ratio mesuré 0,87). Elle garantit qu’il n’existe pas de chemin de bypass dans le graphe de calcul ; elle ne garantit pas que la fonction apprise utilise A_{dag} d’une manière sémantiquement causale. Le ratio O3 mesure une dépendance fonctionnelle, comparable à une analyse de sensibilité ; l’identifiabilité causale au sens de Pearl, mesurée par Q_{int} , est une propriété distincte. Le résultat $Q_{\text{int}} = 2/2$ vs $1/2$ pour la baseline non-causale montre que l’architecture two-stage causale apporte effectivement une réponse interventionnelle cohérente avec la physique attendue — caractérisation plus prudente qu’une identification causale au sens strict, mais significative.

La structure plate de A_{dag} apprise ($Q_{\text{phys}} = 0,40$, magnitudes uniformes) correspond à la limite théorique d’identifiabilité connue [? ?]. Atteindre une identification causale plus fine demanderait des interventions externes pendant l’entraînement ou des hypothèses paramétriques supplémentaires, aucune disponible dans notre cadre. Le DAG appris est donc une régularisation structurelle inductive qui produit les gains

mesurés en calibration et en structure spectrale, sans pour autant constituer une cartographie physiquement identifiée.

IV.7.3. Menaces à la validité

Cinq menaces méritent d'être explicitées. (i) Le *transport géographique* : l'évaluation a été conduite en Nouvelle-Zélande, dont le régime (westerlies, forçage orographique) n'est pas représentatif de la zone d'intérêt sous-jacente (Afrique centrale et de l'Ouest, convection tropicale). (ii) La *taille d'ensemble* ($K = 12$ pour inter-GCM historique, $K = 64$ pour ID) reste modeste vs les 192 membres de la référence CORRDIFF. (iii) La *partition temporelle* couvre 365 jours d'évaluation, soit deux cycles saisonniers seulement. (iv) Les *variables LR retenues* (15 variables) omettent plusieurs prédicteurs critiques : pression de surface, SST, transport d'humidité intégré, énergie potentielle convective disponible. (v) La *robustesse inter-GCM réelle* : les deux GCM utilisés restent historiques ; le test direct en projection future reste à effectuer.

Information physique manquante en entrée. La menace la plus structurelle pour la validité externe est l'absence d'un modèle numérique de terrain (DEM) HR comme prédicteur. Sur la côte ouest néo-zélandaise, le relief explique une part dominante de la variance des précipitations journalières via le soulèvement orographique. Les biais résiduels sur CDD et RX1day, spatialement concentrés sur le lee est et le versant ouest, en sont la preuve directe. L'ajout du DEM, des dérivées de pente et d'un index orographique constitue la perspective n°1.

Tableau IV.6 – *Variables atmosphériques non incluses dans l'ensemble des prédictors LR : rôle physique, raison d'exclusion, gain attendu.*

Variable	Rôle physique	Pourquoi exclue	Gain attendu
MSLP	Distingue fronts dynamiques des hautes pressions	Parcimonie + alignement CORRDIFF	Mieux séparer pluies frontales et convectives
IVT	Diagnostic rivières atmosphériques (~ 50% des extrêmes côte ouest NZ)	Non disponible dans sous-ensemble ERA5 utilisé	Améliorer fortement les queues hautes
SST	Flux de chaleur latente et CAPE de surface	Hors emprise terrestre	Stationnarité saisonnière
CAPE / CIN	Instabilité convective	Hors variables ERA5 single-level téléchargées	Mieux capturer pics RX1day d'été

Portée et limites

Limites assumées et cartographie scientifique. Ce mémoire n'a pas démontré :

1. **DAG appris à magnitudes plates** : $Q_{\text{phys}} = 0,40$. La matrice doit être lue comme une régularisation structurelle inductive, pas une cartographie causale identifiée.
2. $Q_{\text{int}} = 2/2$ **reste un test exploratoire** : 2 interventions $\times$ 30 jours. Signes corrects, magnitudes à $\sim 0,01\%/K$ vs $\sim 7\%/K$ Clausius-Clapeyron. Extension à 6 variables $\times$ 100 jours en post-mémoire.
3. **inter-GCM historique, pas OOD climatique** : le vrai OOD (SSP5-8.5) reste à effectuer.
4. **Un seul seed aléatoire** : confirmation 3 seeds prévue post-soutenance.
5. **Variables LR critiques manquantes** : orographie HR (DEM), MSLP, IVT, SST, CAPE.
6. **Aucune donnée africaine utilisée** : la motivation socio-applicative reste programmatique.

IV.8. Synthèse

Trois lignes structurent les conclusions de l'expérimentation. *Architecture qui tient ses promesses structurelles* : la propriété (O3) est satisfaite par construction et empiriquement vérifiée (ratio 0,87). *Gains métriques nets et reproductibles* : CRPS -40% ID et -30% inter-GCM historique, ratio *spread-skill* amélioré d'un facteur 3,5, distance spectrale réduite d'un facteur 450, RX1day passant de $-4,1$ à $-2,7$ mm, R10mm de $+2,65$ à $+0,88$ j. *Frontière empiriquement cartographiée entre causalité architecturale et identification physique* : DAG appris plat ($Q_{\text{phys}} = 0,40$) conformément à la limite théorique d'identifiabilité observationnelle, mais réponse interventionnelle cohérente ($Q_{\text{int}} = 2/2$ vs $1/2$ pour

la baseline) qui suggère que la causalité architecturale utile au downscaling probabiliste réside autant dans le couplage architectural que dans la structure fine du graphe appris.

La conclusion générale reprend ces lignes pour les articuler au cadre des chapitres précédents, identifie les directions immédiates — ancrage prédictif joint de type CASTLE [?], masque physique sur A_{dag} , validation sur scénario futur, transfert vers le terrain géographique africain — et propose un cadre méthodologique pour la continuation.

La Figure IV.7 resitue qualitativement le positionnement d’ORACLE dans le *trilemme* du downscaling génératif probabiliste : stabilité d’entraînement, réalisme des extrêmes et robustesse inter-GCM. ORACLE progresse nettement vers le sommet « robustesse inter-GCM » sans dégrader les deux autres axes par rapport à CORRDIFF.




Figure IV.7 – Le trilemme du downscaling génératif probabiliste. ORACLE progresse vers le sommet « robustesse inter-GCM » sans dégrader stabilité ni réalisme des extrêmes.

Annexes du chapitre

Annexe IV.A — F1@p99 régressé

La régression de F1@p99 ($-6,9\%$) est la métrique la plus discordante du tableau IV.1. Notre diagnostic favorise l’effet de la régularisation $\mathcal{L}_{\text{O3-preserve}}$ via la *skip-connection conditionnelle* : le plancher $\alpha_{\text{floor}} = 0,6$ impose que la voie directe contribue jusqu’à 40% ; cette voie est par construction lissée (convolution + sur-échantillonnage bilinéaire), ce qui

tire systématiquement μ_{HR} vers la moyenne LR sur les pixels extrêmes. Une révision future devrait diminuer α_{floor} de 0,6 à 0,4 et modérer les hyperparamètres tail-weight ($\alpha = 0,2$, $w_{\text{p99}} = 1,3$). Le test d'isolation directe demande trois runs supplémentaires non conduits dans le temps imparti.

Annexe IV.B — CDD résiduel

Le biais CDD (+17,95 j en distribution) reste élevé en valeur absolue malgré l'amélioration de 17% vs la baseline. Cette persistance s'explique par la combinaison de la fonction de perte CRPS/MSE qui attire les prédictions vers la médiane conditionnelle (sous-prédiction des *trace events*) et de la définition du CDD avec seuil de 1 mm/j (un modèle qui prédirait 0,9 mm là où la vérité est 1,1 mm produirait un CDD erroné). Maraun et Widmann [?] préconisent une perte hybride Bernoulli-Gamma ; cette option est renvoyée aux perspectives.

Annexe IV.C — Sensibilités directes

Tableau IV.7 – *Sensibilités directes par variable LR (norme du gradient moyenne, unités relatives, top 8 sur 15).*

Variable	ORACLE	Noncausal	Ratio
w_{850}	0,260	0,007	$\times 36$
t_{850}	0,118	0,006	$\times 20$
w_{500}	0,093	0,006	$\times 15$
u_{850}	0,085	0,007	$\times 12$
w_{250}	0,067	0,008	$\times 9$
t_{500}	0,060	0,009	$\times 7$
q_{850}	0,047	0,006	$\times 8$
v_{850}	0,044	0,007	$\times 7$

ORACLE mobilise les entrées avec une amplitude 5 à 36 fois supérieure à celle de la baseline. La hiérarchie est physiquement cohérente : vitesse verticale w_{850} dominante (forçage convectif), suivie de la température t_{850} (capacité hygrométrique) et de la vitesse zonale u_{850} (advection). Cette hiérarchie correspond aux variables identifiées comme

dominantes en downscaling de précipitation par la littérature climatologique — argument indirect en faveur de la pertinence physique du conditionnement appris, malgré la structure plate de A_{dag} proprement dite.




Figure IV.8 — Sensibilité par variable d'entrée (Δ_{signal}).

Annexe IV.D — Analyse causale étendue

Cette annexe rassemble les analyses causales complémentaires de ORACLE. La Fig. IV.9 compare le DAG appris à la structure physique attendue ; la Fig. IV.10 cartographie la réponse aux perturbations contrôlées $\Delta q + 20\%$ et $\Delta t + 3$ K.




Figure IV.9 — Comparaison entre le DAG appris A_{dag} et le DAG physique de référence (couplage quasi-géostrophique descendant attendu). Deux arêtes sur cinq physiquement attendues sont correctement orientées ($Q_{\text{phys}} = 0,40$).




Figure IV.10 – Cartes des perturbations contrôlées $\Delta q + 20\%$ et $\Delta t + 3\text{ K}$. Signes physiques cohérents avec la relation de Clausius-Clapeyron sur les deux perturbations testées.

Annexe IV.E — Métriques climato complémentaires

Cette annexe rassemble les diagnostics climato standards qui complètent les figures principales du chapitre. La Fig. IV.11 montre l'histogramme des intensités log-log; la Fig. IV.12 reporte le *Fractions Skill Score* en fonction de l'échelle spatiale.




Figure IV.11 – Histogramme des intensités de pluie (mm/j , log-log). ORACLE reproduit la queue droite; CORRDIFF coupe à $\sim 30\text{ mm/j}$.




Figure IV.12 – *FSS en fonction de l'échelle spatiale. ORACLE skillful à ~ 30 km, CORRDIFF seulement à ~ 80 km.*