

Désagrégation climatique

Verrous techniques de la descente d'échelle climatique et apport d'une approche causale

1 Présentation du downscaling

Les modèles climatiques globaux (GCM, *General Circulation Models*) utilisés par le GIEC simulent l'atmosphère à une résolution typique de 100 à 250 km par maille. À cette échelle, la dynamique régionale (relief, contrastes côte/intérieur, microclimats) est invisible : Douala et Yaoundé occupent la même cellule, le mont Cameroun n'a aucun effet, la transition savane-forêt disparaît. Pour utiliser ces simulations dans des décisions d'aménagement, d'agriculture ou d'énergie, il faut produire une représentation à plus fine échelle (typiquement 1 à 12 km) : c'est la **descente d'échelle climatique** (*downscaling*).

Deux grandes familles de méthodes coexistent. La **descente d'échelle dynamique** (*dynamical downscaling*) emboîte un modèle régional (RCM) dans le GCM et résout les équations de l'atmosphère à plus fine maille : c'est physiquement rigoureux mais très coûteux. La **descente d'échelle statistique** (*statistical / ML-based downscaling*) apprend, à partir d'archives historiques, une fonction qui relie les champs à grande échelle aux champs locaux : c'est moins coûteux mais a ses propres limites (interprétabilité, généralisation hors-distribution, cohérence physique).

2 Enjeux pour le Cameroun et l'Afrique

Au Cameroun, **l'agriculture représente environ 22 % du PIB et fait vivre près de 44 % de la population active**, et plus de 70 % de la population en dépend pour ses moyens de subsistance — secteur très majoritairement pluvial [1, 2]. La qualité des projections climatiques locales est donc un déterminant direct de la sécurité alimentaire, énergétique et sanitaire.

- **Agriculture pluviale** : le calendrier traditionnel des saisons est déjà déphasé ; sans projections locales fiables, l'adaptation des dates de semis et le choix variétal restent empiriques.
- **Hydroélectricité** : la centrale de Lagdo contribue à environ 74 % de la production électrique du Nord-Cameroun ; sa planification opérationnelle (règles de lâcher, débits transfrontaliers) dépend de projections de précipitations sur le bassin de la Bénoué [3].
- **Risques climatiques aigus** : les inondations de l'Extrême-Nord en octobre 2024 ont affecté environ 356 000 personnes, détruit 56 000 maisons et noyé 82 500 hectares de cultures [4] ; ces événements ne sont actuellement pas anticipés à l'échelle communale.

— **Santé publique** : l’extension de la saison humide vers le Sahel modifie la distribution spatiale du paludisme et lui ouvre de nouvelles zones [5].

À l’échelle continentale, **la productivité agricole africaine a diminué d’environ 34 % depuis 1961** sous l’effet du changement climatique — la régression la plus forte observée toutes régions confondues [6]. La Banque Mondiale estime qu’**en l’absence d’adaptation, le Cameroun pourrait perdre entre 4 et 10 % de son PIB d’ici 2050** [2]. Le Plan National d’Adaptation aux Changements Climatiques (PNACC) exige des projections différenciées par zone agro-écologique (cinq zones), exigence techniquement inaccessible sans descente d’échelle locale.

3 Limitations identifiées dans la littérature

Trois familles méthodologiques dominent l’état de l’art, et chacune présente un verrou bloquant dans un contexte africain.

(a) La descente d’échelle dynamique : un coût computationnel rédhibitoire

Les modèles régionaux (RCM) reposent sur la résolution numérique des équations primitives de l’atmosphère sur des grilles fines. La configuration CWA-WRF utilisée à Taïwan tourne par exemple sur **928 cœurs SPARC64 en parallèle** [8]. À budget fixe, on ne peut donc descendre qu’*un seul scénario* d’un GCM à la fois, ce qui maintient les résolutions opérationnelles à **12–50 km** dans les exercices CORDEX. Or les applications de risque (assurance paramétrique, planification d’urgence) nécessitent **plusieurs milliers de membres d’ensemble**, ordre de grandeur incompatible avec un coût RCM [9].

Pour un continent qui héberge **moins de 1 % des capacités HPC mondiales** [7], ce paradigme exclut de facto la production locale de projections fines. C’est ce qui motive la recherche d’alternatives par apprentissage profond [10, 11].

(b) Les modèles d’apprentissage profond : opacité et violations physiques

Les architectures par U-Net, GAN conditionnels ou modèles de diffusion apprennent une correspondance statistique entre champs à grande échelle et champs locaux. Trois faiblesses sont aujourd’hui documentées.

Violations de contraintes physiques. González-Abad et al. [12] montrent que des architectures CNN univariées appliquées aux variables de température produisent des sorties *physiquement impossibles* (par exemple $T_{\min} > T_{\max}$). Le taux de violation passe d’environ **4 % à l’entraînement à 15–17 % en projection 2100 sous le scénario RCP8.5**, à mesure que les conditions s’éloignent de la distribution d’apprentissage. Les auteurs citent

également des modèles publiés (Wang & Tian 2022) ayant produit des valeurs minimales supérieures aux maximales sur des cas réels.

Opacité et non-reproductibilité. Doury et al. [13] qualifient explicitement leur émulateur d’« *neural network model as a black-box regression model* » et montrent que **31 réentraînements identiques d’un même U-Net (25 M de paramètres)** produisent des erreurs sur la climatologie future variant de **0,003 à 0,139 °C**, soit un facteur 46, dû exclusivement à la stochasticité interne (initialisation, ordre des batches). Les approches d’explicabilité *post-hoc* de type cartes de saillance ou Integrated Gradients [14] permettent de diagnostiquer des pathologies (attribution erronée des prédicteurs en climat futur) mais ne contraignent pas l’apprentissage : le modèle a déjà appris ses corrélations fallacieuses.

Échec hors-distribution. La généralisation à un climat futur non-stationnaire reste une limite structurelle. Doury et al. [13] montrent qu’un émulateur entraîné uniquement sur la période historique (1951–2005) **ne reproduit que 30 %** du signal de changement climatique simulé par le RCM en RCP8.5, contre environ 80 % lorsque l’entraînement couvre déjà des états futurs.

(c) Les modèles génératifs résiduels : performance acquise au prix d’une hypothèse de stationnarité

La référence actuelle, CorrDiff/ResDiff (NVIDIA [8]), décompose la tâche en deux étapes : (i) une régression déterministe pour la moyenne conditionnelle μ_{HR} , (ii) un modèle de diffusion EDM pour le résidu. L’approche est **environ 60× plus rapide** que la simulation WRF de référence à inference et apprend efficacement à partir de 4 années de données. Toutefois, les auteurs identifient eux-mêmes la difficulté centrale : un « *significant distribution shift between the input and target data* ». L’efficacité-échantillon de la méthode repose sur la faible variance du résidu, propriété qui n’est garantie que sous l’hypothèse de stationnarité de la distribution-cible. Combinée au résultat de Doury et al. [13], cette limite implique qu’une utilisation rigoureuse en projection nécessiterait des données d’entraînement issues du climat futur — données elles-mêmes produites par un modèle dynamique, ce qui ramène au verrou (a).

4 Apport de notre approche : une descente d’échelle structurée par la causalité

Notre proposition (modèle ORACLE, branche causal-spatio-temporal) intègre explicitement un **graphe causal orienté acyclique (DAG)** appris conjointement à la prédiction, sous contrainte d’un prior physique encodant les relations attendues de la dynamique quasi-géostrophique (couplage descendant pression haute altitude → pression moyenne troposphère → pression basse couche → précipitation au sol [15]). La contrainte d’acyclicité s’appuie sur l’opérateur différentiable DAGMA, complétée d’une régularisation L1 décroissante et d’une pénalité quadratique vers la matrice de référence G_{phys} .

Quatre propriétés en découlent.

- **Interprétabilité intrinsèque, pas post-hoc.** La structure causale est apprise dans l’architecture elle-même : la matrice A_{DAG} est lisible, vérifiable, et peut être confrontée à la physique connue. Réponse directe au problème de la boîte noire identifié par [13, 14].
- **Cohérence physique encodée *a priori*.** Le prior G_{phys} contraint l’optimisation à une variété de solutions où les arêtes causales fortes correspondent aux relations physiquement attendues, réduisant le risque de violations du type $T_{min} > T_{max}$ documenté par [12].
- **Robustesse à la non-stationnarité.** Les relations causales encodées (couplage QG vertical) sont des invariants physiques qui restent valides sous changement climatique. Cela atténue la dégradation hors-distribution constatée par [13] pour les modèles purement statistiques.
- **Coût computationnel accessible.** L’apprentissage complet (Stage 1 causal + Stage 2 diffusion) se déroule sur **un GPU L4 en 48 heures**, accessible via une session Google Colab pour quelques euros — une infrastructure soutenable pour une université africaine, sans recours à un cluster HPC dédié.

Pour le Cameroun, cela ouvre la voie à des projections **locales, interprétables, robustes au changement climatique et accessibles financièrement** : pour la sécurité alimentaire (PNACC), la gestion de Lagdo, l’anticipation des inondations de l’Extrême-Nord et la cartographie sanitaire face à l’expansion du paludisme.

Sources

- [1] IMF (2024). *Climate Change in Cameroon : Key Challenges and Reform Priorities*. IMF Country Report 24/052.
- [2] World Bank (2022). *Cameroon Country Climate and Development Report (CCDR)*.
- [3] Nonki R. M., Lenouo A., et al. (2021). Impact of climate change on hydropower potential of the Lagdo dam, Benue River Basin, Northern Cameroon. *Proc. IAHS* 384, 337–342.
- [4] OCHA / WFP (2024). *Cameroon Far-North Floods Situation Reports*. ReliefWeb, octobre 2024.
- [5] Sokhna C. et al. (2022). Malaria transmission in Sahelian African regions : a witness of climate changes. *Trop. Med. Infect. Dis.*
- [6] Trisos C. H. et al. (2022). *IPCC AR6 WGII, Chapter 9 : Africa*.
- [7] Bachmann et al. (2025). Discovering HPC Resources in Africa. *PEARC '25*, ACM.
- [8] Mardani M. et al. (2024). Generative residual diffusion modeling for km-scale atmospheric downscaling. arXiv :2309.15214 (NVIDIA).
- [9] Hobeichi S. et al. (2023). Using machine learning to cut the cost of dynamical downscaling. *Earth’s Future* 11, e2022EF003291.
- [10] Rampal N. et al. (2024). A reliable GAN approach for climate downscaling and weather generation. *J. Adv. Modeling Earth Systems* (JAMES).

- [11] Doury A. et al. (2024). Enhancing regional climate downscaling through advances in machine learning. *AI for the Earth Systems* 3(2).
- [12] González-Abad J. et al. (2023). Multi-variable hard physical constraints for climate model downscaling. AAAI Fall Symposium FSS-23.
- [13] Doury A., Somot S., et al. (2023). Regional climate model emulator based on deep learning : concept and first evaluation. *Climate Dynamics* 60, 1751–1779.
- [14] González-Abad J. et al. (2023). Using explainability to inform statistical downscaling. *JAMES* (arXiv :2302.01771).
- [15] Holton J. R., Hakim G. J. (2013). *An Introduction to Dynamic Meteorology*, 5^e éd., Academic Press.