

RÉPUBLIQUE DU CAMEROUN

PAIX – TRAVAIL – PATRIE

UNIVERSITÉ DE DSCHANG

ÉCOLE DES SCIENCES ET
TECHNOLOGIES DE DSCHANG



REPUBLIC OF CAMEROON

PEACE – WORK – FATHERLAND

UNIVERSITY OF DSCHANG

SCHOOL OF SCIENCES AND
TECHNOLOGIES OF DSCHANG

UNITÉ DE RECHERCHE EN INFORMATIQUE FONDAMENTALE,
INGÉNIERIE ET APPLICATIONS (URIFIA)

THÈME :

**Développement de Méthodes
d'Apprentissage Automatique
pour la Mise à l'Échelle Spatiale
des Données Climatiques**

Mémoire présenté en vue de l'obtention du diplôme de

Master en Informatique

Option : *Informatique Fondamentale*

Spécialisation : *Intelligence Artificielle*

Par

KENFACK Leonel

Matricule : *CM-UDS-17SCI0998*

Licence de Technologie

Sous la direction de :

Pr. BOMGNI Alain Bertrand

Maître de Conférences, Université de Dschang

Année académique 2025–2026

INTRODUCTION GÉNÉRALE

Sommaire

Contexte du travail	1
Problématique étudiée	2
Objectifs	3
Contribution	4
Organisation du manuscrit	5

Contexte du travail

Le changement climatique impose aux décideurs locaux des choix de plus en plus fins en matière d'agriculture, de gestion de l'eau et d'urbanisme. Au Cameroun, l'agriculture représente environ 22 % du PIB et fait vivre près de 44 % de la population active [31] : un secteur très majoritairement pluvial dont la planification dépend directement de la qualité des projections climatiques locales. La centrale hydroélectrique de Lagdo fournit environ 74 % de l'électricité du Nord-Cameroun [33]. Les inondations de l'Extrême-Nord d'octobre 2024 ont affecté 356 000 personnes et noyé 82 500 hectares de cultures, sans qu'aucune anticipation communale ait été possible [32]. À l'échelle continentale, la productivité agricole africaine a diminué d'environ 34 % depuis 1961 sous l'effet du changement climatique, soit la régression la plus forte toutes régions confondues [34] ; en l'absence d'adaptation, la Banque Mondiale estime que le Cameroun pourrait perdre entre 4 et 10 % de son PIB d'ici 2050 [31].

Or les modèles climatiques globaux (GCM) utilisés par le GIEC si-

mulent l’atmosphère à 100–250 km par maille [3]. À cette échelle, Douala et Yaoundé occupent la même cellule, le mont Cameroun n’a aucun effet, la transition savane–forêt disparaît. Pour utiliser ces simulations dans des décisions d’aménagement, d’agriculture ou d’énergie, il faut produire une représentation à plus fine échelle (1 à 12 km) : c’est la descente d’échelle climatique (*downscaling*). Deux familles coexistent. La descente d’échelle dynamique emboîte un modèle régional (RCM) dans le GCM et résout les équations à plus fine maille [14] ; elle est physiquement rigoureuse, mais très coûteuse. La descente d’échelle statistique, fondée aujourd’hui sur l’apprentissage profond, apprend une fonction qui relie les champs à grande échelle aux champs locaux ; elle est moins coûteuse, mais limitée en interprétabilité, en généralisation hors-distribution et en cohérence physique. C’est dans cette seconde voie que s’inscrit le présent mémoire.

Problématique étudiée

Trois familles méthodologiques dominent l’état de l’art en descente d’échelle, et chacune présente un verrou bloquant dans un contexte africain.

Coût computationnel rédhibitoire de la descente d’échelle dynamique. La configuration CWA-WRF utilisée à Taïwan tourne sur 928 cœurs SPARC64 en parallèle [15] : à budget fixe, on ne peut donc descendre qu’un seul scénario d’un GCM à la fois, ce qui maintient les résolutions opérationnelles à 12–50 km dans les exercices CORDEX. Les applications de risque (assurance paramétrique, planification d’urgence) nécessitent en revanche plusieurs milliers de membres d’ensemble [36]. Pour un continent qui héberge moins de 1 % des capacités HPC mondiales [35], ce paradigme exclut de facto la production locale de projections fines.

Opacité et violations physiques des modèles d’apprentissage profond. González-Abad et al. [38] montrent que des CNN univariés appliqués à la température produisent des sorties physiquement impossibles ($T_{\min} > T_{\max}$), avec un taux de violation passant de 4 % à l’entraîne-

ment à 15–17 % en projection 2100 sous RCP8.5. Doury et al. [37] qualifient explicitement leur émulateur de « *black-box regression model* » et montrent que 31 réentraînements identiques d’un même U-Net produisent des erreurs sur la climatologie future variant de 0,003 à 0,139 °C, soit un facteur 46 dû exclusivement à la stochasticité interne.

Hypothèse de stationnarité des modèles génératifs résiduels. La référence actuelle, CorrDiff [15], décompose la tâche en deux étapes (régression déterministe puis diffusion EDM [10] du résidu) et atteint environ $60\times$ la vitesse d’une simulation WRF à l’inférence. Toutefois, les auteurs identifient eux-mêmes la difficulté centrale : un *significant distribution shift* entre les données d’entrée et la cible. L’efficacité-échantillon repose sur la faible variance du résidu, propriété qui n’est garantie que sous l’hypothèse de stationnarité de la distribution-cible, hypothèse que le changement climatique invalide directement.

Le problème central s’énonce donc ainsi : *comment causaliser le premier étage du paradigme à deux étages pour doter le downscaling probabiliste d’une robustesse de principe au changement de distribution, sans dégrader la stabilité ni le réalisme acquis ?*

Objectifs

Au regard de notre problématique, nous nous fixons comme objectif principal de proposer une architecture de descente d’échelle probabiliste qui intègre une structure causale apprise, afin de garantir par construction une dépendance fonctionnelle entre les variables atmosphériques d’entrée et la précipitation prédite. Plus spécifiquement, nous voulons :

- Concevoir un module causal récurrent (RCN) intégrant SCM dynamique, GRU [2] et pénalité d’acyclicité DAGMA [1] dans une seule cellule ;
- Inscrire ce module dans le paradigme à deux étages de CorrDiff [15], en remplaçant le premier étage de régression générique par un chemin obligatoirement médié par un graphe causal appris, sans modifier

- l'étage de diffusion EDM [10] ;
- Définir un protocole expérimental centré sur la calibration probabiliste, le réalisme des extrêmes et la robustesse inter-GCM, incluant un test d'intervention contrôlée original dans le contexte du downscaling profond.

Contribution

La contribution principale de ce mémoire réside dans la conception, l'implémentation et l'évaluation d'ORACLE, architecture causale générative à deux étages combinant les avantages des modèles résiduels (stabilité, calibration probabiliste, efficacité) avec une garantie structurelle de causalité architecturale. Quatre aspects clés la structurent :

- Une architecture *two-stage* où la causalité est placée dans la topologie du graphe de calcul plutôt que dans une régularisation de la perte : une régularisation peut être contournée par un réseau expressif, alors qu'une dépendance architecturale est par construction indéfaisable.
- Le réseau causal récurrent (RCN) intégrant SCM dynamique, GRU et pénalité DAGMA dans une seule cellule.
- L'interface inter-étages par concaténation de canaux entre la moyenne causale, la baseline et le résiduel bruité, garantissant qu'aucune information ne contourne le chemin causal (propriété O3 vérifiée empiriquement, ratio mesuré 0,87).
- Un protocole expérimental à six familles de métriques incluant deux diagnostics causaux originaux : le ratio O3 (indispensabilité) et le test d'intervention Q_{int} (cohérence physique de la réponse à perturbation contrôlée).

Faute d'un jeu HR de référence sur le continent africain visé, nous éprouvons la méthode sur la Nouvelle-Zélande, traitée comme *bac à sable exigeant*. Rampal et al. [21] l'ont retenue pour sa diversité climatique compacte (subtropical, marin tempéré, semi-aride sous le vent, alpin sur

moins de 270 000 km²) et son gradient orographique parmi les plus extrêmes au monde. Ce terrain sollicite simultanément les trois axes du trilemme. Sur ce cadre, ORACLE réduit le CRPS de 40 % en distribution et de 30 % en inter-GCM historique vis-à-vis d'une baseline non-causale strictement comparable, multiplie par 3,5 le ratio *spread-skill*, et passe le test interventionnel sur deux perturbations contrôlées là où la baseline échoue sur l'intervention thermique. La résistance architecturale à l'ablation causale dans ce cadre constitue une preuve forte d'*universalité architecturale* indépendante du climat d'entraînement. L'extension au contexte africain qui motive ce travail reste hypothétique au stade actuel, conditionnée à la disponibilité d'un jeu HR de référence sur la zone visée, et portée comme axe de perspectives.

Organisation du manuscrit

Le manuscrit est structuré en quatre chapitres et une conclusion :

Chapitre I, Fondements du downscaling climatique. Pose les bases : besoin de désagrégation, propriétés statistiques de la précipitation, approches classiques, passage au probabiliste et au génératif, formalisme causal de Pearl [19], et formule le trilemme stabilité / extrêmes / robustesse hors-distribution.

Chapitre II, État de l'art du downscaling par apprentissage profond. Parcourt systématiquement les approches déterministes (CNN, U-Net), adversariales [21], à vraisemblance, et de diffusion (DDPM [8], EDM, CorrDiff [15]). Un tableau comparatif identifie le *gap* qui motive notre contribution.

Chapitre III, Proposition d'ORACLE. Formalise l'architecture : graphe hétérogène à six nœuds typés, encodeur intelligible, RCN sous contrainte DAGMA, décodeur graphe-à-grille, interface inter-étages et diffusion EDM résiduelle.

Chapitre IV, Matériels, méthodes, expérimentations et discussion. Couvre l'environnement, les données, la topologie effective, le protocole d'évaluation à six familles de métriques, les résultats et la discussion

critique des limites.

Conclusion générale et perspectives. Synthétise les contributions, analyse les résultats et trace cinq axes de perspectives, dont le transfert vers le contexte africain qui constitue la motivation finale.

CHAPITRE

I

FONDEMENTS DU DOWNSCALING CLIMATIQUE

Sommaire

I.1 Introduction	7
I.2 Contexte climatique et besoin de désagrégation	8
I.3 Données climatiques et leurs propriétés	9
I.4 Approches classiques de downscaling	11
I.5 Approches probabilistes et génératives	12
I.6 Causalité et modèles structurels	15
I.7 Verrous scientifiques et trilemme	18
I.8 Synthèse	20

I.1. Introduction

Les communautés d’Afrique centrale et du Cameroun planifient leur agriculture, leur gestion de l’eau et leur urbanisme sur des horizons de plus en plus courts, sous l’effet d’événements climatiques extrêmes dont la fréquence augmente [9]. Ces décisions demandent des projections au kilomètre. Les modèles climatiques globaux (CMIP6 [3]) ne descendent qu’à la centaine de kilomètres. L’écart entre les deux est précisément ce

que le *downscaling* climatique cherche à combler ; ce mémoire en explore une variante générative et causalisée.

Ce chapitre établit les fondements nécessaires à la compréhension de notre contribution : contexte climatique et besoin de désagrégation (section I.2), données mobilisées (section I.3), méthodes classiques (section I.4), approches probabilistes et génératives, notamment le paradigme à deux étages CORRDIF [15] (section I.5), causalité structurelle pour ORACLE (section I.6), verrous scientifiques (section I.7) et synthèse (section I.8).

I.2. Contexte climatique et besoin de désagrégation

I.2.1. Modèles climatiques globaux et régionaux

Un **modèle climatique global** (*General Circulation Model*, GCM) résout numériquement les équations de la dynamique atmosphérique et océanique pour produire des projections multi-décennales sous divers scénarios d'émissions. Le projet CMIP6 coordonne plus d'une centaine de tels modèles, dont ACCESS-CM2 (CSIRO, Australie) [3], à des résolutions de 100 à 250 km limitées par le coût numérique. À cette échelle, les processus locaux (convection profonde, effets orographiques, brises côtières, mésoéchelle) sont *paramétrés* plutôt qu'explicitement résolus. Il en résulte des biais structurels marqués sur la précipitation.

Les **modèles climatiques régionaux** (RCM) résolvent les mêmes équations à 10–50 km sur un domaine restreint, emboîtés dans un GCM aux frontières. Ce *downscaling dynamique* améliore le réalisme régional mais reste coûteux. À titre d'exemple, la configuration CWA-WRF utilisée à Taïwan mobilise 928 cœurs SPARC64 en parallèle [15], ce qui exclut les ensembles à milliers de membres requis pour les applications de risque [36]. Le passage de la grille GCM (~ 250 km) à la grille cible HR (~ 5 km) représente un facteur d'environ 50 par dimension, ce qui

dépasse les capacités RCM accessibles aux équipes africaines.

I.2.2. Cas de la précipitation

Ce constat motive le *downscaling statistique profond*, qui apprend, à partir d'un corpus historique de couples LR/HR, une fonction probabiliste $x_{\text{HR}} \sim p(\cdot | y_{\text{LR}})$ déployable à coût marginal une fois entraînée. Parmi les variables candidates, la **précipitation** occupe une place centrale : c'est la plus liée aux risques perçus (sécheresse, inondations, sécurité alimentaire), et la plus exigeante statistiquement du fait de sa forte intermittence, de sa queue lourde et de son hétérogénéité spatiale [14, 23]. Une méthode qui y réussit se transfère généralement aux variables plus régulières (température, pression). ORACLE est entraîné et évalué sur des précipitations quotidiennes du couple ACCESS-CM2 / Nouvelle-Zélande, terrain expérimental qui combine cible HR de qualité et base-line générative de référence dans la littérature.

I.3. Données climatiques et leurs propriétés

I.3.1. Sources de données et formats

Trois catégories alimentent le downscaling :

- Les **observations directes** (stations météorologiques) : haute qualité ponctuelle, mais couverture spatiale très inégale, particulièrement lacunaire en Afrique.
- Les **réanalyses atmosphériques**, qui assimilent observations de stations, radiosondages et satellites dans un modèle numérique : ERA5 [7] fournit des champs horaires à ~ 31 km depuis 1940 et constitue la référence historique gridée.
- Les **simulations climatiques** (GCM et RCM, sorties CMIP6) couvrent la période historique 1850–2014 et des projections futures sous scé-

narios SSP.

Les données sont distribuées au format **NetCDF** (conventions *Climate and Forecast*), auto-descriptif. La précipitation totale **pr** est exprimée en $\text{kg}/\text{m}^2/\text{s}$ et convertie en mm/jour . Dans notre travail, ACCESS-CM2 fournit le conditionnement basse résolution et un produit régional néo-zélandais la cible HR.

I.3.2. Propriétés statistiques de la précipitation

Trois propriétés statistiques rendent la précipitation quotidienne particulièrement exigeante. L'**intermittence** d'abord : selon les régions, 50 à 80 % des jours sont sans précipitation détectable, ce qui produit une masse de probabilité en zéro qu'aucune hypothèse de variable continue ne peut accommoder. L'**asymétrie à queue lourde** ensuite : conditionnée à un jour pluvieux, l'intensité suit approximativement une loi log-normale [14] ; toute méthode gaussienne sous-estime alors mécaniquement les extrêmes, c'est-à-dire les événements à fort enjeu. L'**hétérogénéité spatiale** enfin : le relief, la ligne de côte et l'occupation du sol structurent les champs de précipitation avec des gradients de plusieurs cm/km en zone de montagne, structure qui disparaît à basse résolution et que tout downscaling doit restituer. Notre pipeline expérimental (chap. IV) opère sur une grille LR 23×26 pixels (Nouvelle-Zélande) et une cible HR 172×179 .

Une lecture quantitative de ces propriétés sur le jeu d'entraînement utilisé au chapitre IV donne un ordre d'idée. Sur ACCESS-CM2 historique (1980–2009, Nouvelle-Zélande), la fraction de jours secs varie de 35% sur la côte ouest des Alpes du Sud à 65% dans les bassins de l'Est. Conditionnellement à un jour pluvieux, la moyenne quotidienne est de $\sim 6 \text{ mm}/\text{j}$ mais le quantile à 99 % atteint $\sim 45 \text{ mm}/\text{j}$ et le maximum observé sur la fenêtre dépasse $200 \text{ mm}/\text{j}$. Le ratio max/moyenne dépasse donc 30, alors qu'il vaut environ 3 pour la température : c'est cette différence d'amplitude relative qui rend la précipitation particulièrement réfractaire aux pertes quadratiques classiques.

I.3.3. Sources d'incertitude et nécessité d'un cadre probabiliste

Le downscaling agrège plusieurs sources d'incertitude qu'il convient de distinguer pour comprendre pourquoi le passage du déterministe au probabiliste n'est pas une simple question de raffinement statistique. L'**incertitude aléatoire** (*aleatoric*) est intrinsèque au caractère mal posé du problème : à une carte LR donnée correspond une famille de cartes HR plausibles, qu'aucune information supplémentaire dans les prédicteurs ne peut réduire. C'est cette composante que cherche à modéliser le résiduel stochastique d'ORACLE. L'**incertitude épistémique** (*epistemic*) reflète la connaissance limitée du modèle sur les données qu'il n'a pas vues ; elle se réduit avec plus de données ou de meilleurs modèles, et explose lors d'un déplacement de distribution. C'est précisément cette composante que la causalité structurelle vise à contenir. Un downscaler purement déterministe écrase ces deux composantes en une seule prédiction, d'où la dépendance aux extrêmes et la fragilité OOD.

I.4. Approches classiques de downscaling

Le downscaling comporte une dimension *spatiale* (grille grossière $\rightarrow$ grille fine) et une dimension *temporelle* (fréquence faible $\rightarrow$ fréquence élevée). Notre contribution couvre exclusivement la dimension spatiale ; la dimension temporelle est brièvement évoquée pour positionner le champ.

I.4.1. Désagrégation spatiale

Trois grandes approches coexistent. La **statistique classique** (régression linéaire multiple, *Bias Correction*, *Quantile Mapping* [14]) apprend une relation prédicteurs LR $\rightarrow$ prédictand HR : simple et interprétable, mais elle suppose la stationnarité, perd la cohérence spatiale (traitement pixel-par-pixel) et n'offre aucune incertitude calibrée.

L’**approche dynamique** exécute un RCM emboîté dans un GCM, résout les équations physiques à 10–50 km et offre une transférabilité de principe hors-distribution, mais hérite des biais du GCM forçant et mobilise des ressources de calcul considérables. L’**apprentissage supervisé déterministe** (CNN de super-résolution, U-Net, EDSR) traite le champ HR comme un tout cohérent mais reste mono-sortie : la prédiction se réduit à une moyenne conditionnelle qui lisse les extrêmes et sous-estime la variabilité, ce qui motive le glissement vers les approches probabilistes (section I.5).

I.4.2. Désagrégation temporelle

La désagrégation temporelle (mensuelle $\rightarrow$ quotidienne ou horaire) pose des enjeux propres : autocorrélation, conservation des cumuls, extrêmes instantanés. Les approches historiques (cascades multiplicatives, chaînes de Markov) et les approches profondes (RNN, Transformers temporels) qui s’en saisissent restent, pour l’essentiel, déterministes. Le présent travail couvre exclusivement la dimension spatiale ; l’extension temporelle est laissée aux travaux futurs.

I.5. Approches probabilistes et génératives

I.5.1. Du déterministe au probabiliste

L’insuffisance des méthodes déterministes est une conséquence du caractère multi-valué du problème : à une carte LR correspond une famille de cartes HR plausibles, dont une seule a été observée. La reformulation probabiliste vise la *distribution conditionnelle* $p(x_{\text{HR}} \mid y_{\text{LR}}, s_{\text{HR}})$, où s_{HR} regroupe d’éventuels champs auxiliaires HR (orographie, occupation du sol). On produit alors des ensembles d’échantillons, calcule des quantiles et évalue la couverture des extrêmes.

I.5.2. Modèles génératifs adversariaux

Les premiers génératifs profonds appliqués au downscaling ont mobilisé les **GAN**, dans leur variante conditionnelle prenant la carte LR comme conditionnement. Une référence néo-zélandaise est [21], qui combine un générateur résiduel et une perte adversariale pondérée. Trois limites empiriques sont documentées : **sub-dispersion** (variance prédite $<$ observée), **forte sensibilité** au coefficient adversarial λ_{adv} , et risque de **mode collapse**. Ces limites ont motivé l'exploration des modèles de diffusion.

I.5.3. Modèles de diffusion

Un modèle de diffusion définit un processus direct qui bruite progressivement le signal, puis apprend à l'inverser. Cette formulation, due aux DDPM de Ho et al. [8], a été généralisée par Karras et al. sous le nom d'EDM [10], qui introduit un préconditionnement systématique pour un entraînement stable et un échantillonnage de qualité en peu d'étapes. Pour le downscaling, la diffusion apporte trois avantages sur les GAN : entraînement stable (pas de déséquilibre adversarial), distribution de sortie expressive (modes multiples), meilleure calibration probabiliste. Le formalisme EDM et l'échantillonnage de Heun sont détaillés au chapitre suivant.

I.5.4. Le paradigme deux étages : CorrDiff

CORRDIFF [15], proposé par NVIDIA Research, découple explicitement ce qui est facile à apprendre et ce qui est intrinsèquement stochastique : un premier étage régresse la moyenne HR attendue, un second échantillonne par diffusion le résiduel par rapport à cette moyenne. Le champ HR s'écrit comme la somme d'une moyenne déterministe et d'un résiduel stochastique (formalisation au chapitre suivant).

L'intérêt est triple : (i) *stabilité* (régression déterministe convergente, diffusion sur résidus quasi-gaussiens) ; (ii) *calibration* (variance explici-




Figure 1 – *Paradigme deux étages de CORRDIFF (Mardani et al. [15], Fig. 1). **Haut** : la donnée météorologique LR sert d’abord à prédire la moyenne μ_{HR} par régression UNet; cette estimation est ensuite corrigée stochastiquement par un modèle de diffusion EDM produisant le résiduel HR. **Bas** : SDE directe (data $\rightarrow$ noise) et SDE inverse (noise $\rightarrow$ data) sur lesquelles repose l’échantillonnage du second étage.*

tement contrôlée par le second étage, non plus produit d’un équilibre adversarial); (iii) *efficacité* (diffusion limitée au résiduel de faible amplitude). Ce paradigme constitue le point de départ direct de notre contribution. ORACLE en reprend la structure mais introduit une contrainte causale au premier étage : μ_{HR} y est prédite à travers un graphe causal appris, ce qui en fait par construction une version *causalisée* de CORRDIFF.

Évaluation probabiliste. Les métriques déterministes classiques (RMSE, MAE, Pearson) ne suffisent pas à évaluer un modèle probabiliste, dont la valeur réside dans la distribution prédite. La littérature mobilise un panel élargi : *CRPS* (généralisation probabiliste de l’erreur absolue), *spread/skill* (calibration du second moment), *RAPSD* (fidélité du spectre spatial), *LHD* (distributions locales). La présentation formelle et l’application à ORACLE sont reportées au chapitre Matériels et méthodes.

I.6. Causalité et modèles structurels

I.6.1. Pourquoi la causalité en downscaling climatique

Les approches probabilistes précédentes restent *corrélatives* : elles capturent les co-occurrences observées sans garantir la qualité prédictive hors du régime d'entraînement, c'est-à-dire dans la situation exacte que crée le changement climatique. Trois apports théoriques distinguent un modèle causal d'un modèle purement corrélatif. La **robustesse hors-distribution** d'abord : un modèle articulé autour de relations causales identifiées (par exemple, l'influence de l'humidité basse couche sur la convection) reste en principe stable lorsque les régimes climatiques se déplacent. L'**interprétabilité physique** ensuite : la structure causale apprise peut être confrontée à la connaissance experte, ce que ne permet aucun modèle purement statistique. La **capacité d'intervention** enfin : un tel modèle répond à des questions « que se passerait-il si humidité +20 % » sans avoir besoin de chercher des analogues dans le passé.

I.6.2. Modèles causaux structurels et graphes acycliques dirigés

Le cadre formel de la causalité est celui des **modèles causaux structurels** (SCM) de Pearl [18, 19]. Un SCM est un triplet (V, U, F) où V regroupe les variables observables, U des bruits exogènes indépendants et F des fonctions structurelles telles que

$$V_i = f_i(\text{Pa}(V_i), U_i), \quad (\text{I.1})$$

$\text{Pa}(V_i)$ étant l'ensemble des parents causaux de V_i . Le SCM s'exprime naturellement par un *Directed Acyclic Graph* (DAG) : nœuds = variables, arcs = liens parent $\rightarrow$ enfant. L'acyclicité garantit l'identifiabi-

lité (ordre topologique d'évaluation) et fournit une description visuelle des dépendances. Sur un mini-système atmosphérique, par exemple, humidité, vent, température et orographie déterminent la précipitation locale, sans rétroaction explicite.

I.6.3. Intervention, identifiabilité et lien avec le downscaling

L'opérateur do de Pearl définit l'**intervention** : $\text{do}(X = x)$ fixe la valeur de X indépendamment de ses parents (suppression de ses flèches entrantes) et fournit une distribution $p(Y \mid \text{do}(X = x))$ en général distincte de la conditionnelle naïve $p(Y \mid X = x)$. C'est cette distinction qui sépare un modèle corrélatif d'un modèle structurellement causal. Un modèle *intervention-aware* a un effet calculable et prévisible sous intervention sur ses entrées. Cette propriété (objectif O3 d'ORACLE, chapitre dédié) est obtenue *au sens structurel* via la matrice A_{dag} apprise. Elle ne se confond pas avec une causalité *physique* (où les flèches coïncideraient avec les lois atmosphériques fait pour fait).

Un exemple concret rend la distinction tangible. En Nouvelle-Zélande, la corrélation observée entre température T et précipitation P peut être négative : les jours chauds y sont préférentiellement associés à des régimes anticycloniques secs. Un modèle corrélatif intègre cette association et prédit moins de pluie à mesure que T augmente. Or Clausius-Clapeyron prédit, toutes choses égales par ailleurs, $\sim +7\%$ de capacité hygrométrique par degré, donc plus d'intensité conditionnelle. Un modèle causal opérant via $\text{do}(T = T_0 + 3 \text{ K})$ doit prédire un signe positif. C'est précisément ce que mesure le test Q_{int} rapporté au chapitre IV.

Apprendre la structure d'un DAG depuis les données est un problème combinatoire dur. Bello, Aragam et Ravikumar [1] ont proposé *DAGMA*, une caractérisation continue et différentiable de l'acyclicité (déterminant logarithmique d'une M-matrice), intégrable directement dans l'entraînement d'un réseau profond. ORACLE mobilise DAGMA pour insérer la causalité structurelle dans un paradigme génératif à deux étages style

CORRDIFF, en prédisant μ_{HR} comme produit causal du DAG appris ; détail formel et examen comparatif sont reportés au chapitre dédié.

Cette posture appelle une précaution de vocabulaire qui structurera tout le manuscrit. Nous parlerons d'*architecture structurellement causale* quand l'information passe nécessairement par A_{dag} pour produire la sortie (notion vérifiable empiriquement par ablation), et de *causalité identifiée* pour des arêtes dont l'orientation et la magnitude reflètent fidèlement les mécanismes physiques. ORACLE vise et atteint la première propriété ; la seconde dépasse ce qu'un apprentissage observationnel non interventionnel peut garantir [19, 39]. Les arêtes du DAG appris sont à lire comme des *contraintes fonctionnelles* : leur valeur n'est pas l'effet causal physique d'une variable sur une autre, mais une pondération apprise qui satisfait l'acyclicité tout en optimisant la prédiction.

Cette distinction matérialise une division du travail entre deux niveaux de l'architecture qu'il faut tenir simultanément pour saisir comment ORACLE concilie résolution spatiale fine et faible cardinalité du graphe causal. La résolution spatiale est portée par les couches d'aggrégation locale (SAGEConv au sein du RCN), qui jouent le rôle de *filtre spatial* et préservent la géographie pixel par pixel. La matrice A_{dag} opère, elle, sur un graphe inter-variables de cardinalité réduite ($N = 6$ nœuds typés dans la configuration principale du mémoire) et agit comme un *superviseur physique* : elle organise les dépendances fonctionnelles entre champs atmosphériques agrégés, indépendamment de la position des pixels. Le décodeur graphe-à-grille recombine ensuite les consignes de ce superviseur avec la carte spatiale locale pour reconstruire la précipitation au bon endroit. La métaphore de la tour de contrôle est utile : les six nœuds ne remplacent pas les pixels, ils coordonnent les relations physiques entre les champs spatiaux que les couches convolutives traitent en parallèle. Cette séparation explique pourquoi un graphe agrégé à 6 nœuds reste compatible avec la cible HR à 172×179 pixels : la richesse spatiale survit au goulot d'étranglement parce qu'elle ne passe tout simplement pas par lui.

L'analogie a une portée pratique sur la lecture des résultats. Une

matrice A_{dag} à magnitudes plates (Q_{phys} proche de la fraction aléatoire d'arêtes correctement orientées) ne signifie pas que le modèle a manqué la physique ; elle indique que l'identification fine de la hiérarchie causale est restée hors de portée des données observationnelles disponibles, alors même que la contrainte d'acyclicité a fait son travail régularisant. Le chapitre IV mesure les deux séparément : le ratio O3 atteste de la dépendance fonctionnelle, Q_{phys} et Q_{int} mesurent la fidélité physique. La distinction permet aussi de localiser proprement les marges de progression : une expérience exploratoire menée en parallèle, avec un graphe à 9 nœuds (un par variable atmosphérique au lieu de l'agrégation à 6 nœuds typés), récupère une fidélité physique très élevée, ce qui montre que la platitude observée à 6 nœuds est le coût d'une agrégation choisie pour la lisibilité humaine du DAG plutôt qu'une limite intrinsèque de l'architecture.

I.7. Verrous scientifiques et trilemme

Les fondements précédents font émerger trois verrous structurants du downscaling génératif. Avant de les articuler dans un *trilemme*, examinons-les un par un.

I.7.1. Verrou 1 : stabilité d'entraînement

Les modèles adversariaux sont très sensibles au coefficient λ_{adv} et au déséquilibre générateur-discriminateur, difficiles à régler de manière transférable d'une région à l'autre [21]. Les modèles de diffusion, plus stables en principe, exigent néanmoins une calibration soignée du pré-conditionnement et du schéma de bruit, qui est précisément ce qu'apporte EDM [10]. Ce verrou conditionne reproductibilité et déployabilité multi-cas.

I.7.2. Verrou 2 : réalisme des extrêmes et sub-dispersion

Le verrou le plus critique pour nos applications est le **réalisme des extrêmes**, via le phénomène de *sub-dispersion* : variance prédite conditionnellement à l'entrée inférieure à la variance observée. Mesurée par le rapport $\sigma_{\text{pred}}/\text{RMSE}$, elle vaut ≈ 1 pour un modèle bien calibré, alors que des valeurs autour de 0,3 sont rapportées en downscaling génératif [6, 15, 21]. Cela représente une sous-estimation d'un facteur trois de la variabilité fine, et donc des extrêmes, soit précisément les événements à plus forte valeur ajoutée. Sa mesure sur ORACLE et ses ablations causales sera l'un des objets centraux de l'évaluation.

I.7.3. Verrou 3 : robustesse hors-distribution

Sous changement climatique, la statistique conjointe des variables atmosphériques évolue : un modèle historique doit conserver sa qualité hors des analogues observés. Les modèles purement corrélatifs y sont vulnérables (associations contingentes au régime d'entraînement), tandis que la causalité structurelle (section I.6) apparaît comme une réponse de principe : un modèle organisé autour de relations causales doit, en théorie, mieux transférer en **OOD**.

I.7.4. Trilemme et positionnement d'Oracle

La littérature récente expose un schéma récurrent : les approches qui dominent un de ces axes échouent presque systématiquement sur au moins un autre. Les GAN les plus expressifs sont aussi les plus instables ; les modèles de diffusion stables restent corrélatifs et sans garantie hors-distribution ; les RCM dynamiques robustes paient cette robustesse en coût de calcul et transférabilité. Cette tension, identifiée sous diverses formes chez plusieurs auteurs [6, 15, 21], se condense en un *trilemme* entre stabilité d'entraînement, réalisme des extrêmes et robustesse hors-distribution (figure 2). Nous le présentons *tel qu'il ressort de la littérature*, sans prétendre à une formalisation originale.




Figure 2 – *Trilemme du downscaling génératif. Les trois sommets représentent les verrous identifiés ; les points positionnent qualitativement les principales approches. Plus un point est proche d'un sommet, mieux l'approche traite ce verrou. Constat agrégé à partir de [6, 15, 21].*

ORACLE se positionne dans ce trilemme en s'inscrivant dans le paradigme à deux étages de CORRDIFF (stabilité, verrou 1), en y introduisant une contrainte structurellement causale au premier étage (robustesse OOD, verrou 3), et en mobilisant la diffusion EDM au second étage pour la calibration probabiliste (réalisme des extrêmes, verrou 2). La figure 3 en propose une vue d'ensemble ; détails architecturaux et formalisation des objectifs sont déferés au chapitre dédié.

I.8. Synthèse

Trois acquis se dégagent de ce chapitre. Le besoin de désagrégation est concret et localisé : la résolution des GCM ne rencontre pas celle des usages locaux, particulièrement en contexte africain où les RCM dynamiques restent hors de portée, et la précipitation y concentre à la fois la pertinence opérationnelle et la difficulté statistique. Le paradigme méthodologique a glissé du déterministe vers le probabiliste, puis vers le génératif, et a récemment trouvé une forme aboutie dans le schéma à deux étages de CORRDIFF (moyenne déterministe additionnée d'un résiduel par diffusion), qui sert ici de point de départ. Trois verrous, enfin,




Figure 3 — Cartouche conceptuel d'ORACLE : version causalisée du paradigme deux étages de CORRDIFF. L'étage 1 estime μ_{HR} via un graphe causal appris ; l'étage 2 échantillonne par diffusion le résiduel δ .

structurent encore le champ : stabilité d'entraînement, réalisme des extrêmes (et sub-dispersion qui en découle), robustesse hors-distribution. C'est dans le trilemme qu'ils dessinent qu'ORACLE s'inscrit, en greffant une structure causale sur la décomposition à deux étages.

Le chapitre suivant parcourt l'état de l'art : les travaux antérieurs sur le downscaling probabiliste à deux étages (CORRDIFF, cGAN de Rampal et al.) et les approches qui éclairent l'intégration de la causalité au cadre génératif.

CHAPITRE

II

ÉTAT DE L'ART DU DOWNSCALING PAR APPRENTISSAGE PROFOND

Sommaire

II.1	Introduction	22
II.2	Approches déterministes	23
II.3	Approches probabilistes adversariales	24
II.4	Approches à vraisemblance explicite	26
II.5	Modèles de diffusion	26
II.6	Le paradigme à deux étages : CorrDiff	27
II.7	Fonctions de perte et contraintes physiques	31
II.8	Cadres d'évaluation et foundation models	33
II.9	Synthèse, tableau comparatif et gap scientifique	34

II.1. Introduction

Le chapitre précédent a identifié un trilemme pour le downscaling climatique génératif (section I.7) : stabilité d'entraînement, réalisme des extrêmes et robustesse sous changement de distribution apparaissent inconciliables dans les approches existantes. Le présent chapitre confronte cette analyse au paysage effectif de la littérature, des CNN déterministes

aux modèles de diffusion à deux étages. Nous abordons successivement les approches déterministes (section II.2), adversariales (section II.3), à vraisemblance explicite (section II.4) et de diffusion (section II.5), avant de détailler le paradigme CORRDIFF (section II.6) dont notre proposition est la causalisation. Pertes (section II.7) et cadres d'évaluation (section II.8) complètent la revue ; la synthèse (section II.9) identifie le gap qui motive notre contribution.




Figure 4 – *Frise chronologique des principales contributions du downscaling climatique profond. Le glissement progressif du paradigme déterministe (gris) vers le paradigme génératif (rouge) puis vers le two-stage causal (bleu) est visible à partir de 2020. ORACLE se positionne comme aboutissement causal du paradigme à deux étages.*

La figure 4 situe chronologiquement les contributions examinées : glissement déterministe → génératif à partir de 2020, accélération après 2022 sous l'effet conjoint des modèles de diffusion et de la maturation des GCM haute résolution.

II.2. Approches déterministes

II.2.1. Régression statistique classique

Les approches statistiques de première génération (régression linéaire, BC, QM) présentées au chapitre I (section I.4) souffrent de trois limites structurelles : hypothèse de stationnarité difficile à défendre sous changement climatique, absence de cohérence spatiale (traitement pixel par pixel), absence de calibration probabiliste. C'est ce qui motive le passage aux méthodes d'apprentissage non-linéaires et structurées spatialement.

II.2.2. Réseaux convolutifs et super-résolution

L'application des CNN au downscaling s'inspire des architectures de super-résolution d'image. **DeepSD** [23] est l'une des premières architectures CNN dédiées au downscaling de la précipitation, par empilement de convolutions à champ réceptif croissant. Le **U-Net** [22] a connu une adoption massive, particulièrement sous sa forme conditionnée par des champs de surface (élévation). Ces approches partagent une limite décisive : produisant une unique sortie HR par entrée, elles approximent la moyenne conditionnelle de la distribution cible. Pour la précipitation à queue lourde, cette moyenne est biaisée à la baisse aux valeurs élevées, d'où le lissage des extrêmes documenté dans la littérature.

La période 2021–2023 a vu émerger des architectures plus sophistiquées qui partagent la même limite probabiliste : opérateurs neuronaux de Fourier (FNO) prometteurs en prévision globale mais expérimentaux en downscaling régional, et Transformers de vision (SwinIR, PrecipFormer) exploitant l'attention. Toutes conservent la limite fondamentale du déterminisme : pas de distribution conditionnelle calibrée, donc le verrou « réalisme des extrêmes » reste non adressé.

II.3. Approches probabilistes adversariales

II.3.1. Réseaux antagonistes génératifs conditionnels

Le glissement vers le probabiliste a d'abord été opéré par les **réseaux antagonistes génératifs** (GAN) [4] et leur variante conditionnelle (cGAN) [16]. Un générateur G transforme un bruit $z \sim \mathcal{N}(0, I)$ et un conditionnement y_{LR} en échantillon plausible $\hat{x}_{\text{HR}} = G(y_{\text{LR}}, z)$; un discriminateur D apprend à distinguer vrais et faux. L'entraînement min-max alterne ces objectifs opposés. Appliqué au downscaling, le cGAN promet un ensemble d'échantillons HR plausibles permettant en principe d'estimer la variabilité prédictive et la distribution des extrêmes.

II.3.2. cGAN résiduel pour le downscaling climatique

Une architecture représentative est le **Residual cGAN** de Rampal et al. [21], qui combine un U-Net déterministe pré-entraîné et un cGAN sur le résidu : le générateur reçoit la prédiction U-Net, l'élévation HR, le champ GCM et un bruit, et produit une carte résiduelle additionnée à la prédiction déterministe. L'application à la Nouvelle-Zélande (CMIP6 ACCESS-CM2) combine trois termes de coût : MSE, perte adversariale pondérée par λ_{adv} , et contrainte d'intensité pénalisant la surestimation des extrêmes.

D'autres travaux apparentés incluent Harris et al. [6] (désagrégation de précipitations sur domaine européen) et Price et Rasp (prévision d'extrêmes à court terme via GAN).

II.3.3. Limites empiriques des cGAN appliqués au downscaling

Quatre limites empiriques reviennent dans la littérature adversariale. D'abord, la **forte sensibilité à λ_{adv}** : la performance sur les extrêmes décrit une courbe en cloche (coefficient trop faible et la MSE lisse, trop élevé et les extrêmes explosent), avec un optimum étroit qui ne transfère pas d'une région à l'autre. Vient ensuite la **sub-dispersion**. Rampal et al. [21] et Mardani et al. [15] rapportent $\sigma_{\text{pred}}/\text{RMSE} < 0,5$, signe d'ensembles systématiquement trop confiants. Le **mode collapse**, intrinsèque au cadre min-max, reste latent même quand il n'apparaît pas explicitement. Reste la **validité restreinte du cadre d'évaluation** : la plupart des tests utilisent des couples synthétiques RCM-LR/RCM-HR (cadre « parfait »), et la transférabilité aux conditions opérationnelles GCM brut n'est pas garantie.

II.4. Approches à vraisemblance explicite

Les **auto-encodeurs variationnels** (VAE) [11] apprennent une représentation latente probabiliste en maximisant la borne inférieure de la log-vraisemblance (ELBO). Appliqués au downscaling, ils produisent des sorties probabilistes mais souffrent d'un excès de lissage lié à l'ELBO. Les **flots de normalisation** appliquent une séquence de transformations inversibles différentiables à un bruit gaussien et autorisent l'évaluation exacte de la vraisemblance ; leur expressivité reste cependant bornée par la contrainte d'inversibilité. Ces deux familles n'atteignent pas le niveau des GAN ou de la diffusion en downscaling climatique : leur intérêt méthodologique ne compense pas une expressivité insuffisante face aux extrêmes à queue lourde.

II.5. Modèles de diffusion

II.5.1. Denoising Diffusion Probabilistic Models

Les **Denoising Diffusion Probabilistic Models** (DDPM) [8] définissent un processus direct qui bruite progressivement le signal selon une chaîne de Markov gaussienne $q(x_t | x_{t-1}) = \mathcal{N}(x_t; \sqrt{1 - \beta_t} x_{t-1}, \beta_t I)$, puis apprennent à inverser ce processus. L'objectif simplifié se réduit à la prédiction du bruit, $\mathcal{L}_{\text{simple}} = \mathbb{E}[\|\epsilon - \epsilon_\theta(x_t, t)\|^2]$, où ϵ_θ est typiquement un U-Net. Face aux GAN, DDPM offre trois avantages pour le downscaling : entraînement stable sans déséquilibre adversarial, expressivité multimodale sans collapse, et calibration probabiliste intrinsèque.

II.5.2. Formalisme EDM de Karras et al.

Le formalisme EDM [10] reformule la diffusion dans un cadre théorique général. Sa contribution principale est un **préconditionnement systématique** de l'entrée et de la sortie via quatre fonctions $c_{\text{in}}, c_{\text{out}}, c_{\text{noise}}, c_{\text{skip}}$ dépendant de σ , qui unifie DDPM/score matching/VP/VE et stabilise

l'entraînement. Le sampler de Heun à pas variable atteint une qualité comparable à DDPM avec moitié moins d'étapes. La calibration de σ_{data} (écart-type des données normalisées) est cruciale.

II.5.3. Premières applications au climat : SR3, ResShift, ResDiff

SR3 fut la première application notable de la diffusion conditionnelle à la super-résolution d'image, avant son essaimage vers le climat. **ResShift** accélère la diffusion par déplacement résiduel, avec une proximité manifeste vers le paradigme à deux étages détaillé en section II.6. Plusieurs évolutions récentes pourraient à terme remplacer l'étage de diffusion : **flow matching** [13], consistency models, diffusion latente. La diffusion EDM [10] demeure notre choix de référence pour trois raisons : maturité empirique en climat (retenue par CorrDiff [15] et GenCast [20]), stabilité d'entraînement (préconditionnement systématique $c_{\text{in}}, c_{\text{out}}, c_{\text{skip}}, c_{\text{noise}}$), et efficacité d'échantillonnage (solveur de Heun à 20–50 pas contre ~ 1000 pour DDPM).

II.6. Le paradigme à deux étages : CorrDiff

II.6.1. Idée fondatrice

Le modèle CORRDIF (*Corrective Diffusion*) de Mardani et al. [15] (NVIDIA Research) propose un paradigme à deux étages dont la décomposition formelle est :

$$x_{\text{HR}} = \text{baseline}_{\text{LR}\uparrow} + \mu_{\text{HR}}(y_{\text{LR}}, s_{\text{HR}}) + \delta(\cdot), \quad (\text{II.1})$$

où $\text{baseline}_{\text{LR}\uparrow}$ désigne un sur-échantillonnage bilinéaire, μ_{HR} la moyenne HR apprise par régression déterministe, et δ un résiduel stochastique échantillonné par diffusion conditionnée sur μ_{HR} et y_{LR} . L'application

visée est le downscaling kilométrique de sorties GCM avec un facteur de réduction de 25 à 50, le terrain initial étant Taïwan.

II.6.2. Architecture détaillée

Le premier étage est un U-Net classique entraîné par MSE entre μ_{HR} et la cible HR. Le second est un U-Net de diffusion EDM entraîné à prédire $\delta = x_{HR} - (\text{baseline}_{LR\uparrow} + \mu_{HR})$ conditionnellement à μ_{HR} et y_{LR} , avec échantillonnage de Heun à 20-50 pas.




Figure 5 – Architecture UNet hiérarchique de CORRDIFF (Mardani et al. [15], Fig. S1), partagée par les deux étages. Encodeur-décodeur à quatre niveaux ($448^2 \rightarrow 28^2$), blocs résiduels, attention auto-référentielle dans les niveaux profonds, embedding temporel t pour le second étage. Le premier étage de régression réutilise la même topologie sans embedding temporel.

II.6.3. Forces du paradigme à deux étages

Ce paradigme accumule trois forces structurelles. La **stabilité d'entraînement** d'abord : la régression déterministe converge sans difficulté et la diffusion du second étage opère sur des résidus dont la distribution se rapproche d'une gaussienne. La **calibration probabiliste explicite**

ensuite : la variance est contrôlée par le second étage, sans dépendre d'un équilibre adversarial. L'**efficacité computationnelle** enfin : l'échantillonnage par diffusion ne porte que sur le résiduel, dont l'amplitude est faible.

II.6.4. Limites identifiées de CorrDiff

L'examen critique fait apparaître deux limites principales. La **persistance de la sub-dispersion** : malgré la calibration explicite du second étage, CorrDiff reste sub-dispersif ($\sigma_{\text{pred}}/\text{RMSE}$ entre 0,3 et 0,5 selon les configurations), moins prononcé que chez les cGAN mais significatif. L'**absence de structure causale explicite** : le premier étage est un U-Net générique apprenant $\mu_{\text{HR}}(y_{\text{LR}}, s_{\text{HR}})$ sans contrainte sur la nature des dépendances ; rien ne distingue associations causales (humidité de basse couche $\rightarrow$ précipitation convective) et corrélations contingentes au régime d'entraînement. CorrDiff est donc vulnérable au changement de distribution, sans garantie d'intervention.

II.6.5. Le piège du conditionnement par cross-attention

Une tentation immédiate, face à ce diagnostic, est d'ajouter un module causal en amont du U-Net et de l'injecter à l'aide d'un mécanisme de cross-attention. Notre propre cheminement a confirmé que cette voie ne tient pas. Nos premières versions, fondées sur cross-attention causale (état caché $H_T(A_{\text{dag}})$ projeté dans `encoder_hidden_states` d'un `UNet2DConditionModel`), passaient pourtant tous les contrôles *ex ante* : la matrice A_{dag} apparaissait dans le graphe de calcul, l'entraînement convergeait, et la sortie semblait dépendre de la voie causale. L'ablation *ex post* ($A_{\text{dag}} \leftarrow \mathbf{0}$) révélait pourtant une dépendance nulle : la prédiction ne se dégradait pas. Le U-Net, riche en skip-connections multi-niveaux, apprenait à reconstruire la cible en court-circuitant le conditionnement causal via les canaux du LR brut. La causalité était *décorative* : elle apparaissait dans la loss mais pas dans la fonction apprise.

Cette pathologie est structurelle, non hyperparamétrique. Tant qu'il existe un chemin de calcul entre l'entrée LR et la sortie qui ne dépende pas de A_{dag} , un réseau suffisamment expressif l'empruntera, parce que la voie de bypass minimise la perte avant l'option causale dans la dynamique d'apprentissage. Aucune régularisation *a posteriori* ne corrige ce déséquilibre. La seule réponse opérante est topologique : verrouiller l'architecture pour qu'aucun chemin de bypass ne soit possible. C'est ce que réalise la décomposition deux-étages avec gel du Stage 1 et conditionnement par concaténation, retenue pour ORACLE (chapitre III). Le diagnostic correspond à une distinction qui structurera tout le manuscrit : une causalité par régularisation peut toujours être contournée par un réseau expressif ; une causalité par topologie est par construction indéfaisable. Ce constat justifie le passage d'un cadre *loss-as-cause* à un cadre *architecture-as-cause*.

II.6.6. Pourquoi CorrDiff plutôt que SR3 ?

Le baseline non-causal d'ORACLE aurait pu provenir d'autres travaux de diffusion résiduelle. ResDiff et CorrDiff désignent la même filiation chez Mardani et al. ; la vraie alternative restait SR3. Trois raisons font pencher la balance vers CorrDiff. La **décomposition moyenne + résiduel** (équation II.1) épouse la structure même de la statistique climatique : μ_{HR} encode le forçage-réponse, δ la variabilité fine. SR3 ne propose pas cette séparation, et c'est elle qui ouvre la voie à la causalisation. Vient ensuite le **ciblage explicite du downscaling kilométrique** : CorrDiff intègre intermittence, queue lourde et hétérogénéité de la précipitation, là où SR3 reste une méthode générique de super-résolution d'image. Reste enfin la **modularité architecturale**. L'étage 1 se substitue sans toucher à l'étage 2, ce qui nous permet précisément de remplacer le U-Net du premier étage par un module à graphe causal sans perturber la diffusion EDM.

II.6.7. Reformulation du paradigme deux étages dans le langage probabiliste

Une lecture probabiliste éclaire pourquoi la décomposition $x_{\text{HR}} = \text{baseline} + \mu_{\text{HR}} + \delta$ est plus qu'une commodité d'implémentation. En notant $\mu^*(y_{\text{LR}}) = \mathbb{E}[x_{\text{HR}} \mid y_{\text{LR}}, s_{\text{HR}}]$ la moyenne conditionnelle théorique et $\delta^* = x_{\text{HR}} - \mu^*(y_{\text{LR}})$ son résiduel, on a par construction $\mathbb{E}[\delta^* \mid y_{\text{LR}}, s_{\text{HR}}] = 0$. La distribution de δ^* est typiquement plus proche d'une gaussienne que celle de x_{HR} , ce qui rend l'apprentissage de diffusion mieux conditionné ; et la variance résiduelle sert d'estimateur naturel de σ_{data} , hyperparamètre central d'EDM dont la calibration se fait empiriquement en fin de Stage 1.

II.7. Fonctions de perte et contraintes physiques

II.7.1. Pertes adaptées à la précipitation

Au-delà de la MSE, la littérature a développé plusieurs pertes adaptées à la précipitation. Les **pertes spectrales** (FACL, *Fourier Amplitude Coherence Loss*) pénalisent l'écart entre spectres de Fourier prédit et cible, préservant le contenu fréquentiel fin et corrigeant partiellement le lissage MSE. La **régularisation Wasserstein** (héritée des WGAN) remplace la divergence Jensen-Shannon implicite par une distance Wasserstein-1, plus stable et mieux comportée aux extrêmes. Les **pondérations spécifiques aux extrêmes** (*focal loss*, MSE pondérée par percentiles, *top-k*) accroissent le poids des pixels à forte intensité, concentrant l'apprentissage sur les cas extrêmes.

Reste un point méthodologique : combiner ces pertes n'est pas une opération additive sans conséquence. Un mélange linéaire à coefficients fixes ne fonctionne en pratique qu'au prix d'une recherche d'hyperparamètres elle-même fragile au changement de domaine. Plusieurs travaux

récents proposent une pondération adaptative au cours de l'entraînement, soit par *loss weighting* indexé sur la phase d'optimisation, soit par *curriculum learning* progressif des seuils d'extrêmes. ORACLE retient une approche conservatrice : la perte du Stage 1 combine MSE et reconstruction, sans pondération spectrale ni Wasserstein. Ces deux dernières ont été évaluées en exploration ; elles n'ont pas montré de gain reproductible en présence des autres briques (contrainte DAGMA, pénalité L_1). Cette simplicité est défendue au chapitre suivant comme un choix de robustesse face à la fragilité empirique des pondérations multi-pertes.

II.7.2. Contraintes physiques et explicabilité

Des **contraintes physiques dures** (conservation de masse, monotonie $T_{\min} \leq T \leq T_{\max}$, positivité de la précipitation) sont imposées par construction architecturale ou projection en sortie ; elles améliorent la cohérence multivariée mais ne résolvent pas les verrous probabilistes. L'**explicabilité** (XAI) appliquée au downscaling (Grad-CAM, Integrated Gradients) révèle a posteriori les zones d'entrée influentes. Notre proposition emprunte une voie complémentaire : organiser l'architecture autour d'une structure causale apprise, apportant par construction cohérence et interprétabilité.

Tableau I – *Principales fonctions de perte et contraintes utilisées en downscaling climatique profond.*

Famille	Exemples	Cas d'usage principal
Pertes spectrales	FACL	Contenu fréquentiel fin
Adversariales régularisées	Wasserstein, WGAN-GP	Stabilisation entraînement adversarial
Pondération extrêmes	Focal, top- k , MSE pondérée	Pixels à forte intensité
Contraintes dures	Conservation, monotonie, positivité	Cohérence physique multivariée
Explicabilité a posteriori	Grad-CAM, Integrated Gradients	Diagnostic des dépendances
Structure causale	DAG appris, intervention	Robustesse OOD et auditabilité (notre voie)

Le tableau I récapitule ces familles.

II.8. Cadres d'évaluation et foundation models

II.8.1. Benchmarks standardisés

Trois benchmarks récents tentent de réduire la fragmentation des protocoles d'évaluation. **WeatherBench 2** étend le benchmark initial à la prévision météorologique pilotée par les données (RMSE, biais, ACC sur ERA5). **ClimateBench** se concentre sur la réponse à des scénarios d'émissions et l'émulation climatique. **ChaosBench** cible la prévision à grande échelle et la stabilité à long horizon. Un constat demeure : **aucun benchmark public ne couvre le downscaling probabiliste à haute résolution**, et sa construction reste un chantier ouvert.

L'absence de benchmark public dédié explique en partie l'hétérogénéité des protocoles rencontrés dans la littérature : choix de domaines (Taïwan pour CorrDiff, Nouvelle-Zélande pour Rampal, États-Unis ou Europe pour les cGAN antérieurs), formulation des métriques d'extrêmes (F1 pooled vs ETCCDI per-pixel), périodes de test plus ou moins longues, et taille d'ensemble allant de $K = 8$ à $K = 192$. Notre choix expérimental (Nouvelle-Zélande, ACCESS-CM2 historique, ensemble $K = 12$ inter-GCM) reprend largement le protocole Rampal et al. [21] afin d'être directement comparable à cette référence, tout en évaluant les indices ETCCDI préconisés par [27] pour garantir l'interopérabilité avec les diagnostics climatologiques standard.

II.8.2. Foundation models climat

La période 2023-2024 a vu émerger des *foundation models* climat. **ClimaX** [17] (Microsoft) est un Transformer pré-entraîné sur CMIP6, capable de prévision, projection et downscaling après fine-tuning. **GraphCast** [12] et **GenCast** [20] (Google DeepMind) sont des graph neural networks entraînés sur ERA5 ayant dépassé plusieurs modèles physiques opérationnels. Le positionnement de notre travail est complémentaire :

ORACLE cible le downscaling régional probabiliste, non le multi-tâche global ; la structure causale proposée pourrait à terme s'intégrer à une architecture de plus grande échelle.

II.9. Synthèse, tableau comparatif et gap scientifique

II.9.1. Tableau comparatif modèle $\times$ verrou

Le tableau II récapitule les approches revues selon les trois axes du trilemme (stabilité, extrêmes, robustesse OOD), complétés par deux axes propres à notre contribution (structure causale explicite, caractère génératif probabiliste).

Tableau II – Confrontation des principales approches du downscaling profond aux verrous du trilemme. Légende : $\checkmark$ = bien traité, $\triangle$ = partiellement traité, $\times$ = non traité. La colonne **Causal** renvoie à l'indispensabilité structurelle (propriété (O3)) qui sera formalisée au chapitre suivant.

Approche	Année	Stabilité	Extrêmes	OOD	Causal	Génératif
DeepSD / U-Net	2017	$\checkmark$	$\times$	$\times$	$\times$	$\times$
EDSR / SRCNN	2017	$\checkmark$	$\times$	$\times$	$\times$	$\times$
FNO / SFNO	2021-23	$\checkmark$	$\triangle$	$\triangle$	$\times$	$\times$
SwinIR / PrecipFormer	2021-23	$\checkmark$	$\triangle$	$\times$	$\times$	$\times$
cGAN (Harris et al.)	2022	$\triangle$	$\triangle$	$\times$	$\times$	$\checkmark$
Residual cGAN (Rampal)	2024	$\triangle$	$\triangle$	$\times$	$\times$	$\checkmark$
VAE downscaling	2022	$\checkmark$	$\times$	$\times$	$\times$	$\checkmark$
Normalizing Flow	2020	$\checkmark$	$\triangle$	$\times$	$\times$	$\checkmark$
DDPM / EDM brut	2020-22	$\checkmark$	$\checkmark$	$\triangle$	$\times$	$\checkmark$
SR3 / ResShift	2022-23	$\checkmark$	$\triangle$	$\triangle$	$\times$	$\checkmark$
CorrDiff (Mardani)	2023	$\checkmark$	$\triangle$	$\triangle$	$\times$	$\checkmark$
ClimaX (foundation)	2023	$\checkmark$	$\triangle$	$\triangle$	$\times$	$\triangle$
Oracle (proposé)	2026	$\checkmark$	$\triangle$	$\triangle$	$\checkmark$	$\checkmark$

Note sur ORACLE. La colonne « Causal » est attribuée à ORACLE au titre de la propriété (O3) : architecturalement, la sortie ne peut pas contourner la matrice A_{dag} apprise. Les triangles partiels en « Extrêmes » et « OOD » assument honnêtement les limites mesurées : RX1day

mieux placé que la baseline mais F1@p99 régresse ; gain CRPS en inter-GCM historique mais pas de test sur scénario futur. Le détail est discuté au Chapitre IV.

II.9.2. Gap scientifique

Le tableau II fait apparaître un constat structurant : **aucune des approches revues ne résout simultanément les trois axes du trilemme**. Les plus stables (U-Net, DDPM, EDM brut) ne garantissent pas la robustesse hors-distribution. Les plus probabilistes (CorrDiff, cGAN résiduel) restent sub-dispersives sur les extrêmes. Les plus expressives (cGAN) butent sur l'instabilité d'entraînement. Et aucune n'intègre par construction de structure causale explicite : c'est précisément cette lacune qui motive notre contribution.

Le gap scientifique se formule donc comme **la non-résolution du trilemme par les approches existantes**. Le paradigme deux-étages de CORRDIFF couvre le mieux le triplet stabilité + extrêmes + probabiliste, mais sa robustesse hors-distribution n'est pas adressée par construction. Comblé ce gap suppose de **causaliser le premier étage** : remplacer le U-Net générique qui estime μ_{HR} par un module structurellement causal qui contraint cette estimation à passer par un graphe de dépendances appris.

II.9.3. Positionnement d'Oracle dans le paysage

La figure 6 résume la position de ORACLE. Le premier étage causalise CORRDIFF [15], en s'appuyant sur la caractérisation différentiable de l'acyclicité de Bello et al. [1] et sur le formalisme SCM de Pearl [19] ; le second étage conserve la diffusion EDM [10]. L'architecture détaillée fait l'objet du chapitre suivant.




Figure 6 – Cartouche conceptuel revisité du modèle ORACLE avec ancrage bibliographique. Le premier étage causalise CORRDIFF [15] en y intégrant un graphe causal appris par contrainte DAGMA [1] et le formalisme SCM de Pearl [19] ; le second étage conserve la diffusion EDM [10].

CHAPITRE

III

PROPOSITION : ORACLE, ARCHITECTURE CAUSALE À DEUX ÉTAGES

Sommaire

III.1	Introduction	37
III.2	Vue d'ensemble et différence avec CORRDIF	39
III.3	Graphe atmosphérique hétérogène	40
III.4	Encodeur intelligible et réseau causal récurrent	41
III.5	Apprentissage du DAG par DAGMA	44
III.6	Décodeur graphe-à-grille	45
III.7	Interface inter-étages, propriété (O3) et diffusion EDM	45
III.8	Pertes et entraînement	48
III.9	Synthèse et traçabilité	49

III.1. Introduction

Le paradigme à deux étages de CORRDIF [15] est l'antécédent le plus crédible pour le trilemme stabilité / extrêmes / robustesse, mais sa robustesse hors-distribution n'est pas adressée par construction. ORACLE en est une *causalisation* portant exclusivement sur le

premier étage : le réseau de régression générique est remplacé par un module structurellement causal (graphe atmosphérique hétérogène, encodeur intelligible, RCN sous contrainte d’acyclicité). Le second étage conserve la diffusion EDM [10], avec un conditionnement par concaténation de canaux qui propage architecturalement le chemin causal vers la prédiction stochastique du résiduel.

III.1.1. Notations et objectifs

Sauf mention contraire, B désigne la taille du lot, T la longueur de séquence ($T = 8$), N le nombre de nœuds, $d = 128$ la dimension latente et $(H_{\text{HR}}, W_{\text{HR}}) = (172, 179)$ la résolution cible. Les symboles centraux sont récapitulés dans le tableau III.

Tableau III – *Notations principales.*

Symbole	Description
$y_{\text{LR}}, x_{\text{HR}}$	Champs LR conditionnant (GCM) et HR cible (précipitation)
baseline, μ_{HR}, δ	Sur-échantillonnage bilinéaire, moyenne causale Stage 1, résiduel stochastique Stage 2
A_{dag}	Matrice d’adjacence $N \times N$ du DAG appris
H_t, H_T	État caché du graphe au pas t , état final consommé par le décodeur
$\sigma, \sigma_{\text{data}}$	Niveau de bruit EDM, écart-type empirique des résiduels
$\mathcal{D}_\theta$	Opérateur de débruitage EDM préconditionné

Six objectifs guident la conception :

- **O1** stabilité d’entraînement (sans équilibre adversarial fragile) ;
- **O2** réalisme des extrêmes (CRPS et centiles élevés) ;
- **O3** causalité architecturale, c’est-à-dire dépendance non-triviale de μ_{HR} à A_{dag} formant signature contrastive vis-à-vis de CORRDIFF ;
- **O4** robustesse inter-GCM ;
- **O5** efficacité computationnelle sur budget CPU (48 cœurs, 128 Go) ;
- **O6** interprétabilité du DAG appris.

Décomposition deux étages et diffusion EDM adressent O1–O2 ; RCN et contrainte DAGMA adressent O3 et O6 ; la structure causale adresse

O4; le pré-calcul et la diffusion sur résidu de faible amplitude adressent O5.

III.2. Vue d'ensemble et différence avec Corr-Diff

III.2.1. Architecture en quatre blocs fonctionnels

À haut niveau, ORACLE est composé de quatre blocs (figure 7). Le *générateur de baseline* sur-échantillonne y_{LR} par interpolation bilinéaire. Le *module causal résiduel* (CRM) produit μ_{HR} via le chemin causal complet, à savoir graphe hétérogène, encodeur intelligible, RCN et décodeur graphe-à-grille. Le *décodeur de diffusion EDM* échantillonne le résiduel δ conditionné sur μ_{HR} et la baseline. La *recombinaison finale* agrège selon l'équation centrale du paradigme à deux étages :

$$x_{\text{HR}} = \text{baseline}_{\text{LR}\uparrow} + \mu_{\text{HR}}(y_{\text{LR}}; A_{\text{dag}}) + \delta(\sigma; \mu_{\text{HR}}, \text{baseline}). \quad (\text{III.1})$$

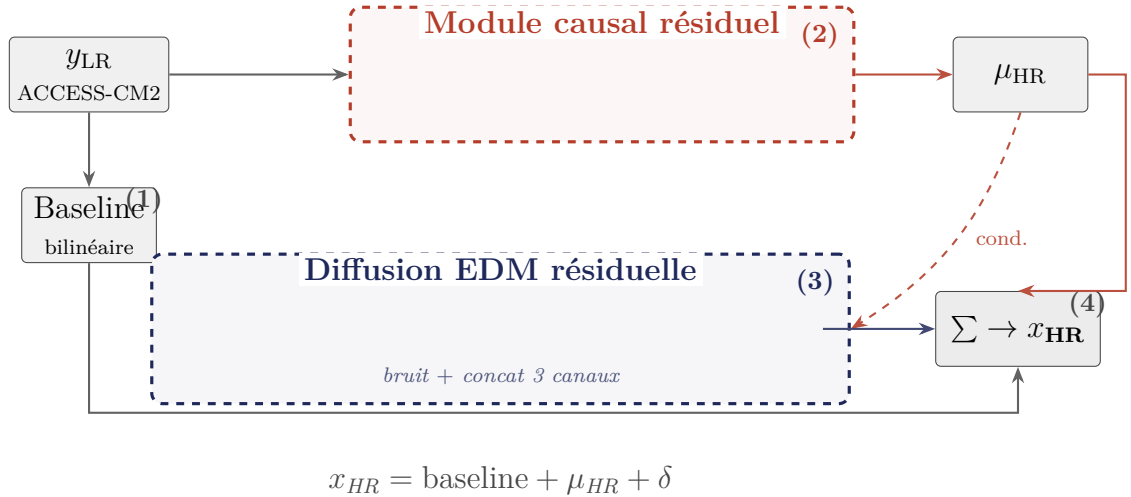


Figure 7 – Vue d'ensemble simplifiée du modèle ORACLE en quatre blocs articulés autour de l'équation (III.1). La causalité architecturale est concentrée dans le module causal résiduel (CRM, bloc 2); la stochasticité réside dans le bloc EDM (3).

La décomposition sépare la composante déterministe causale (μ_{HR} , forçage-réponse via le DAG) de la composante stochastique non-causale

(δ , variabilité fine résiduelle modélisée par EDM). L'écart avec CORRDIF est entièrement concentré dans la production de μ_{HR} : CORRDIF y emploie un U-Net générique entraîné par MSE sur $x_{\text{HR}} - \text{baseline}$, là où ORACLE substitue un module causal dont la sortie transite obligatoirement par A_{dag} . Stage 2, pertes EDM, sampler de Heun et préconditionnement sont hérités tels quels : toute amélioration mesurée sera attribuable au remplacement du module μ_{HR} , pas à un changement collatéral.

III.3. Graphe atmosphérique hétérogène

Note préliminaire sur la cardinalité du graphe. L'architecture RCN est définie de manière générique pour un nombre arbitraire N de nœuds. La version théorique pleinement résolue compterait jusqu'à $\sim 32\,600$ nœuds. Dans toute la suite expérimentale (Chap. IV), nous travaillons avec une **configuration agrégée à $N = 6$ nœuds typés** : un nœud par variable physique, pas un nœud par pixel. Le DAG appris (A_{dag} de taille 6×6) est donc un graphe inter-variables. Cette agrégation est volontaire : elle rend la matrice causale interprétable au prix d'une perte de résolution spatiale dans le graphe (la résolution spatiale est reprise par les blocs convolutifs).

III.3.1. Types de nœuds et hiérarchie verticale

Le graphe G comporte quatre types de nœuds. Les nœuds **GP850**, **GP500**, **GP250** portent les variables dynamiques (température, vent, humidité spécifique) aux trois niveaux de pression, à raison d'un nœud par point de la grille LR ($N_{\text{LR}} = 23 \times 26 = 598$). Les nœuds **SP_HR** portent les variables statiques HR (orographie, masque terre/mer) avec un nœud par point HR ($N_{\text{HR}} = 172 \times 179 = 30\,788$). Le total atteint $\approx 32\,600$ nœuds en configuration complète. Cette dissymétrie LR/HR reflète la nature physique des champs : variables atmosphériques fournies grossièrement par le GCM, caractéristiques de surface définies à la

résolution cible.

III.3.2. Types d'arêtes et physique encodée

Le graphe comporte trois types d'arêtes encodant chacune un mécanisme physique : les **spatiales** (voisins horizontaux des GP) modélisent l'advection et la diffusion ; les **verticales** (inter-niveaux GP) modélisent la convection et l'instabilité verticale ; les **statiques-vers-pressure** ($\text{SP_HR} \rightarrow \text{GP}$) modélisent l'influence orographique. Cet ensemble constitue le support d'agrégation pour les couches SAGEConv ; la matrice A_{dag} apprise par DAGMA pondère par-dessus les liens causaux entre variables.

III.3.3. Drivers statiques et acheminement causal

Plutôt que d'injecter les drivers statiques (orographie, masque, sol) comme canaux supplémentaires du Stage 2 (comme dans [21]), nous les introduisons exclusivement comme nœuds SP_HR du graphe. Leur influence sur μ_{HR} passe nécessairement par les arêtes $\text{SP_HR} \rightarrow \text{GP}$ dont les poids sont gouvernés par A_{dag} , ce qui garantit que toute information transite par le chemin causal et contribue à la propriété (O3).

III.4. Encodeur intelligible et réseau causal récurrent

III.4.1. Motivation : préserver l'identité physique des variables

L'encodeur intelligible projette chaque variable physique (température, vent, humidité, précipitation) dans un espace latent commun de dimension $d = 128$, qui alimentera ensuite le RCN. Sa spécificité tient à la *préservation de l'identité physique* : chaque dimension latente reste attachée à une variable source, au lieu de fondre toutes les variables dans une

représentation distribuée opaque. Deux choix techniques portent cette préservation : un MLP *dédié* $f_{v,p}$ par couple variable-niveau (interdisant tout mélange précoce), et une perte de reconstruction $\mathcal{L}_{\text{rec}}$ (section III.8) qui contraint le décodage à reproduire les variables d’entrée.

III.4.2. Architecture par variable et normalisation

Chaque MLP $f_{v,p}$ est de profondeur 3 (activations GELU, normalisation de couche). La normalisation des entrées suit deux conventions : standardisation par moyenne et écart-type pour les variables atmosphériques classiques, et transformation logarithmique $\log(1 + \text{pr})$ pour la précipitation, qui compresse la queue lourde et stabilise l’entraînement. L’agrégation entre nœuds voisins est effectuée par des couches *SAGEConv* [5] :

$$h_i^{(\ell+1)} = \sigma\left(W_{\text{self}}^{(\ell)} h_i^{(\ell)} + W_{\text{neigh}}^{(\ell)} \text{mean}_{j \in \mathcal{N}(i)} h_j^{(\ell)}\right), \quad (\text{III.2})$$

SAGEConv a été préféré aux variantes par attention (GAT) selon deux lignes de défense :

- **Matériel** : un benchmark sur CPU 48 cœurs montre qu’un GAT à 4 têtes multiplie le temps par batch par ~ 5 et la mémoire d’activation par $\sim 3,5$. Stage 1 (~ 140 batches/époque, 75 époques) devient alors infaisable.
- **Théorique** : SAGEConv moyenne localement (filtre passe-bas) et peut lisser les anomalies extrêmes. Cette limite est compensée globalement par A_{dag} , qui surimpose une pondération causale asymétrique entre variables. La synergie est explicite : SAGEConv assume le lissage spatial local, tandis que A_{dag} porte la hiérarchie causale globale, là où un GAT paierait l’attention deux fois.

III.4.3. Réseau causal récurrent : SCM dynamique et mise à jour temporelle

Le *Recurrent Causal Network* (RCN) forme le cœur méthodologique d'ORACLE. À chaque pas de temps, il combine deux briques : un *modèle causal structurel* (SCM) qui prédit l'évolution de l'état caché à partir du DAG appris, et une *mise à jour récurrente* (GRU) qui fusionne cette prédiction théorique avec l'observation courante. Le SCM joue le rôle du *plan de vol* théorique, la GRU celui de la *mise à jour aux instruments*. L'originalité d'ORACLE tient à ceci : *le SCM est le moteur récurrent lui-même*. La transition $H_t \rightarrow H_{t+1}$ est une assignation structurelle causale, pas un post-traitement appliqué à un état caché produit par ailleurs.

III.4.4. Équations SCM et mise à jour GRU

À chaque pas t , l'étape SCM produit une prédiction causale $\hat{H}_t$ à partir de H_{t-1} , de l'observation x_t et de A_{dag} . Pour chaque variable i , l'assignation structurelle s'écrit :

$$\hat{H}_t^{(i)} = f_i \left(A_{\text{dag}}^{(i,:)} \odot H_{t-1}, x_t, \varepsilon_t^{(i)} \right), \quad (\text{III.3})$$

où $A_{\text{dag}}^{(i,:)}$ regroupe les pondérations causales entrantes vers i , $\odot$ est le produit composante par composante avec broadcast nœud, $\varepsilon_t^{(i)}$ un bruit exogène, et f_i un MLP structurel propre à la variable. Les K f_i sont implémentés en parallèle, suivant l'usage des SCM neuronaux multivariés. La perte $\mathcal{L}_{\text{rec}}$ contraint $\hat{H}_t$ à porter l'information nécessaire au décodage des variables d'entrée, forçant la dynamique à apprendre des liens prédictifs effectifs.

L'étape GRU fusionne $\hat{H}_t$ et l'embedding x_t^{emb} (produit par un MLP léger **FactorEncoder**) suivant les équations standard de Cho et al. [2] avec portes z_t, r_t et candidat $\tilde{H}_t$:

$$H_t = (1 - z_t) \odot \hat{H}_t + z_t \odot \tilde{H}_t. \quad (\text{III.4})$$

H_t est réinjecté au pas suivant comme entrée du SCM, fermant la boucle. Après $T = 8$ pas, $H_T = H_T$ est consommé par le décodeur (section III.6). L'état initial H_0 est un paramètre apprenable indépendant du lot.

III.5. Apprentissage du DAG par contrainte DAGMA

III.5.1. Caractérisation différentiable et formulation DAGMA

Apprendre conjointement la structure d'un DAG et les fonctions structurelles est combinatoire (le nombre de DAG à N nœuds croît super-exponentiellement). Zheng et al. [24] ont reformulé l'acyclicité comme contrainte différentiable $h_{\text{NOTEARS}}(A) = \text{tr}(e^{A \odot A}) - N$, coûteuse numériquement. Bello, Aragam et Ravikumar [1] ont proposé une caractérisation par log-déterminant d'une matrice M-positive :

$$h_{\text{DAGMA}}(A; s) = -\log \det(sI - A \odot A) + N \log s, \quad (\text{III.5})$$

où $s > N \cdot \max_{i,j} |A_{i,j}|$ garantit la M-positivité. h_{DAGMA} s'annule ssi A représente un DAG, ne requiert qu'une décomposition LU, et son gradient se déduit de l'inverse de $sI - A \odot A$. Dans ORACLE, cette pénalité est combinée à une sparsité L_1 encourageant une matrice creuse et auditable :

$$\mathcal{L}_{\text{dag}} = \lambda_{\text{DAGMA}} \cdot h_{\text{DAGMA}}(A_{\text{dag}}) + \lambda_{L_1} \cdot \|A_{\text{dag}}\|_1. \quad (\text{III.6})$$

Les valeurs effectives des coefficients sont détaillées au chapitre suivant.

III.6. Décodeur graphe-à-grille et moyenne haute résolution

III.6.1. Cross-attention à résolution intermédiaire et raffinement

Le décodeur transforme l'état caché final $H_T \in \mathbb{R}^{B \times N \times d}$ en une carte $\mu_{\text{HR}} \in \mathbb{R}^{B \times 1 \times H_{\text{HR}} \times W_{\text{HR}}}$ en deux étapes : attention croisée entre des requêtes définies sur une grille intermédiaire 43×45 (double de la résolution LR) et l'ensemble des nœuds du graphe (clés/valeurs), suivie d'un sur-échantillonnage bilinéaire et d'un raffinement convolutif vers la résolution HR. L'attention croisée multi-têtes calcule

$$\tilde{\mu}_p = \sum_{n=1}^N \alpha_{p,n} \cdot V_n, \quad \alpha_{p,n} = \frac{\exp(\langle Q_p, K_n \rangle / \sqrt{d})}{\sum_{n'} \exp(\langle Q_p, K_{n'} \rangle / \sqrt{d})}. \quad (\text{III.7})$$

La résolution intermédiaire est dictée par la mémoire : une attention directe à 172×179 produirait une matrice $30\,788 \times N$ prohibitive ; la résolution 43×45 réduit le coût d'un facteur 16 tout en gardant assez de granularité. La carte $\tilde{\mu}$ subit ensuite un sur-échantillonnage bilinéaire vers la résolution HR, un raffinement convolutif léger (deux blocs Conv + GELU + norm) et une projection 1×1 qui produit la carte scalaire μ_{HR} .

III.7. Interface inter-étages et propriété (O3)

III.7.1. Pré-calcul, cache et recalibration de σ_{data}

Une fois le Stage 1 convergé, sa sortie est figée : on pré-calcule et sauvegarde $\mu_{\text{HR}}^{(i)}$ et $\text{baseline}^{(i)}$ pour chaque échantillon. Cette mise en cache (quelques heures) évite de ré-évaluer le CRM à chaque pas du Stage 2, ce qui réduit son coût marginal à celui d'une simple passe de diffusion. L'optimisation s'avère cruciale sur budget CPU-only. À partir

des couples pré-calculés, on évalue empiriquement la distribution des résiduels

$$\delta^{(i)} = \log(1 + x_{\text{HR}}^{(i)}) - \log(1 + \text{baseline}^{(i)}) - \mu_{\text{HR}}^{(i)}, \quad (\text{III.8})$$

dont l'écart-type fournit σ_{data} pour le préconditionnement EDM (section III.7.3). Une calibration incorrecte conduit soit à une sous-utilisation du modèle, soit à une instabilité numérique des coefficients de préconditionnement.

III.7.2. Définition formelle de la propriété (O3)

La propriété (O3) opérationnalise l'idée que le chemin causal d'ORACLE est *structurellement load-bearing*, c'est-à-dire que son retrait dégrade significativement la prédiction. Formellement :

Définition III.1 (Indispensabilité causale, O3). Soit $\text{MSE}(\mu_{\text{HR}}(A_{\text{dag}}); x_{\text{HR}})$ l'erreur quadratique moyenne du Stage 1 lorsque l'inférence utilise la matrice d'adjacence apprise A_{dag} , et $\text{MSE}(\mu_{\text{HR}}(\mathbf{0}); x_{\text{HR}})$ la même quantité lorsque cette matrice est forcée à zéro. La quantité contrastive

$$\Delta_{O3} = \text{MSE}(\mu_{\text{HR}}(\mathbf{0}); x_{\text{HR}}) - \text{MSE}(\mu_{\text{HR}}(A_{\text{dag}}); x_{\text{HR}}) \quad (\text{III.9})$$

mesure l'apport du chemin causal à la qualité de la prédiction. ORACLE satisfait la propriété (O3) à un seuil τ si :

$$\frac{\Delta_{O3}}{\text{MSE}(\mu_{\text{HR}}(A_{\text{dag}}); x_{\text{HR}})} \geq \tau, \quad (\text{III.10})$$

avec typiquement $\tau \in [0,05, 0,10]$ dans nos protocoles.

L'opérationnalisation de (O3) repose sur la variante d'ablation **noncausal** qui force $A_{\text{dag}} = \mathbf{0}$ à l'inférence (pas à l'entraînement), exposée par le paramètre **run_variant**. C'est l'instrument principal de validation expérimentale ; la mesure de Δ_{O3} est reportée au chapitre suivant.

III.7.3. Étage 2 : paradigme EDM et conditionnement par concaténation

Le second étage échantillonne le résiduel δ conditionnellement à μ_{HR} et à la baseline. Nous reprenons sans modification le formalisme EDM de Karras et al. [10], dont le préconditionnement s'écrit, pour $x_\sigma = x + \sigma\epsilon$:

$$\mathcal{D}_\theta(x_\sigma, \sigma) = c_{\text{skip}}(\sigma) \cdot x_\sigma + c_{\text{out}}(\sigma) \cdot \epsilon_\theta(c_{\text{in}}(\sigma) \cdot x_\sigma, c_{\text{noise}}(\sigma)), \quad (\text{III.11})$$

avec $c_{\text{skip}}, c_{\text{out}}, c_{\text{in}}, c_{\text{noise}}$ fonctions de σ et σ_{data} . Le préconditionnement EDM consiste à **normaliser adaptativement** les entrées et sorties du réseau de diffusion en fonction du niveau de bruit. Cela évite d'avoir à ajuster manuellement des hyperparamètres : le réseau reçoit un signal d'apprentissage stable sur toute la plage de bruit. La perte pondérée s'écrit alors

$$\mathcal{L}_{\text{EDM}}(\theta) = \mathbb{E}_{x, \sigma, \epsilon} [\lambda(\sigma) \cdot \|\mathcal{D}_\theta(x + \sigma\epsilon, \sigma) - x\|^2]. \quad (\text{III.12})$$

L'échantillonnage utilise un solveur de Heun à pas variable selon le calendrier de Karras. Un examen détaillé du formalisme est donné au chapitre précédent (sous-section II.5.2).

ORACLE conditionne exclusivement par *concaténation de canaux*, et non par cross-attention :

$$\text{input}_{\text{UNet}} = \text{concat}(\delta_{\text{noisy}}, \mu_{\text{HR}}, \log(1 + \text{baseline})) \in \mathbb{R}^{B \times 3 \times H_{\text{HR}} \times W_{\text{HR}}}, \quad (\text{III.13})$$

avec $\delta_{\text{noisy}} = \delta + \sigma\epsilon$. Ce choix tient à deux raisons. La cross-attention ouvre une voie d'information parallèle qui dilue la traçabilité causale ; la concaténation force au contraire le U-Net à *voir* μ_{HR} comme un canal d'image traité localement par ses couches initiales. Et le coût computationnel de la concaténation est nettement inférieur, ce qui pèse en CPU-only.

Pourquoi le résidu plutôt que le champ complet

Modéliser δ plutôt que x_{HR} réduit l’amplitude de la cible. Là où x_{HR} couvre plusieurs ordres de grandeur, δ se trouve centré autour de zéro avec un écart-type de l’ordre de σ_{data} après log-transformation. La calibration de σ_{data} retrouve un sens physique et la variance prédite s’aligne mieux sur la variance observée des résiduels, réduisant la sub-dispersion typique des modèles entraînés sur champ complet (O2). L’interface inter-étages joue le rôle d’un *pacte architectural* : le Stage 1 délivre μ_{HR} comme seule information conditionnelle, le Stage 2 la reçoit par concaténation sans voie d’attention parallèle, et l’ablation $A_{\text{dag}} \leftarrow \mathbf{0}$ n’affecte la sortie que si elle modifie effectivement μ_{HR} , ce qui requiert simultanément que le Stage 1 utilise A_{dag} et que le Stage 2 dépende de μ_{HR} .

III.8. Pertes composites et entraînement

III.8.1. Pertes et procédure d’entraînement

L’entraînement du Stage 1 minimise une perte composite combinant l’erreur quadratique sur μ_{HR} , $\mathcal{L}_{\text{mse}} = \mathbb{E}[\|\mu_{\text{HR}} - (\log(1 + x_{\text{HR}}) - \log(1 + \text{baseline}))\|^2]$, la perte de reconstruction $\mathcal{L}_{\text{rec}}$ qui préserve l’identité physique, et le terme $\mathcal{L}_{\text{dag}}$ regroupant la pénalité DAGMA et la régularisation $\|A_{\text{dag}}\|_1$:

$$\mathcal{L}_{\text{total}}^{(1)} = \mathcal{L}_{\text{mse}} + \alpha \mathcal{L}_{\text{rec}} + \mathcal{L}_{\text{dag}}. \quad (\text{III.14})$$

La procédure se déroule en deux phases. Le Stage 1 est entraîné par AdamW jusqu’à convergence ; ses paramètres sont alors gelés et on précalcule $\mu_{\text{HR}}^{(i)}$, $\text{baseline}^{(i)}$ et σ_{data} empirique. Le critère (O3) joue le rôle de *gate* : si $\Delta_{\text{O3}}/\text{MSE} < \tau$, le Stage 1 est ré-entraîné. Le Stage 2 minimise ensuite exclusivement $\mathcal{L}_{\text{EDM}}$ (équation III.12) sur les résiduels pré-calculés. Trois éléments du protocole : l’EMA (décroissance 0,9999) stabilise l’échantillonnage, le *conditioning dropout* ($p \approx 0,13$) prépare la classifier-free guidance, et `cfg_scale` est calibré au chapitre suivant.

III.9. Synthèse, traçabilité et choix non retenus

III.9.1. Traçabilité des composants

Le tableau IV retrace l’inspiration et le verrou adressé par chaque composant, conformément au principe que tout choix architectural doit être justifié par référence à la littérature et contribution à au moins un axe du trilemme.

Tableau IV – *Traçabilité des composants d’ORACLE : inspiration et verrou adressé.*

Composant	Inspiration	Verrou
Décomposition à deux étages	CORRDIFF [15]	Stabilité
Graphe hétérogène SP/GP	Contribution propre	O3 / OOD
Encodeur intelligible par MLP dédiés	Contribution propre	O6
Agrégation SAGEConv	Hamilton et al. [5]	Efficacité
RCN (SCM + GRU)	Pearl [19] + Cho [2]	O3
DAG par DAGMA	Bello et al. [1]	O6
Décodeur graphe-à-grille (cross-attn)	Contribution propre	Efficacité
Diffusion EDM (Stage 2)	Karras et al. [10]	Stabilité, extrêmes
Conditionnement causal_concat	Contribution propre	O3 architectural
Pré-calcul Stage 1	Contribution propre	Efficacité (O5)

Plusieurs alternatives ont été envisagées puis écartées : les *Diffusion Transformers* (coût supérieur au U-Net à la résolution 172×179 , apport empirique non démontré pour le downscaling à cette échelle) ; le *flow matching* et les *consistency models* (maturité limitée sur cette application, perspective de continuation signalée en conclusion) ; l’injection des drivers statiques comme canaux supplémentaires du U-Net Stage 2 (écartée pour préserver le passage architectural par le DAG, condition de la validité de O3) ; la cross-attention pour le conditionnement Stage 2 (écartée au profit de la concaténation, cf. section III.7.3).

Le présent chapitre a présenté ORACLE dans sa forme architecturale finale. La validation empirique (satisfaction effective de la propriété O3, mesure de la sub-dispersion résiduelle, robustesse hors-distribution) constitue l’objet du chapitre suivant, qui documente également l’envi-

ronnement logiciel, les jeux de données, la trajectoire de développement et la discussion des résultats.




Figure 8 – *Vue conceptuelle du graphe atmosphérique hétérogène d'ORACLE. Quatre types de nœuds (GP850, GP500, GP250 dynamiques en bleu ; SP_HR statique en gris) et trois types d'arêtes (spatiales intra-plan en bleu clair, verticales inter-plans en rouge, statiques-vers-pression en pointillé gris). L'instanciation concrète avec variables nommées et dimensions exactes est différée au chapitre IV.*

CHAPITRE

IV

MATÉRIELS, MÉTHODES, EXPÉRIMENTATIONS ET DISCUSSION

Sommaire

IV.1 Introduction	52
IV.2 Environnement et données	53
IV.3 Topologie effective d'ORACLE	55
IV.4 Trajectoire et procédure d'entraînement	57
IV.5 Protocole d'évaluation	59
IV.6 Résultats observés	60
IV.7 Discussion critique	65
IV.8 Synthèse	69

IV.1. Introduction

Le chapitre précédent a présenté ORACLE dans sa forme architecturale finale. Place maintenant à l'expérimentation. Nous décrivons d'abord l'environnement et les données (section IV.2), la topologie effectivement entraînée (section IV.3), la trajectoire de développement et la procédure d'optimisation (section IV.4), puis le protocole d'évaluation (sec-

tion IV.5). Les résultats sont exposés en section IV.6 et discutés en section IV.7. Une synthèse (section IV.9) clôt le chapitre. Deux principes de transparence guident la démarche : documenter les variantes écartées en cours de route, et exposer aussi bien les métriques où ORACLE progresse que celles où il sous-performe.

IV.2. Environnement et données

IV.2.1. Pile logicielle et matériel

L'implémentation repose sur Python 3.11 et PyTorch 2.3, étendu par PyTorch Geometric pour les opérateurs sur graphe hétérogène, xarray pour l'ingestion des sorties GCM, et Hydra pour la configuration en fichiers YAML hiérarchiques. La précision mixte automatique (`bfloat16` sur GPU, `float32` sur CPU) et la compilation `torch.compile` du UNet du second étage réduisent l'empreinte mémoire et accélèrent l'exécution d'environ 30 %.

Les expérimentations exploratoires initiales (portage de *ResDiff*) ont tourné sur une station CPU-only à ~ 500 Go de mémoire. Les phases intensives sont déportées sur Google Colab : NVIDIA L4 (24 Go) pour le Stage 1, NVIDIA A100 80 Go pour le Stage 2 (UNet 42,8 M paramètres). Un cycle complet demande ~ 45 heures cumulées (10–15 époques Stage 1, 200 époques Stage 2 sur résiduels mis en cache). La graine aléatoire est fixée et l'historique sérialisé dans le point de contrôle pour reproductibilité.

IV.2.2. Données et prétraitements

Le domaine d'étude est la Nouvelle-Zélande, choisi pour trois raisons : référence comparable (jeu HR aligné sur les protocoles CORR-DIFF [15] et cGAN néo-zélandais [21], deux baselines génératives crédibles) ; diversité climatique compacte (sur $< 270\,000$ km², subtropical au nord, marin tempéré à l'ouest, semi-aride sur le lee oriental des Alpes

du Sud, alpin en altitude, soit l’essentiel des régimes de Köppen tropicaux et subtropicaux) ; test orographique sévère (gradient ouest–est de plus de 10 000 mm/an sur 50 km, l’un des plus extrêmes au monde). La Nouvelle-Zélande joue donc le rôle de *bac à sable exigeant* : une architecture qui y passe sous ablation causale fournit une preuve forte d’universalité indépendante du climat d’entraînement, préalable à toute mise en production sur des cibles applicatives comme l’Afrique subsaharienne, à ce jour exclues faute de jeu HR de référence [35]. La grille HR couvre 172×179 pixels (5–10 km). Les prédicteurs LR viennent d’ACCESS-CM2 (CMIP6 historique) sur une grille 23×26 sur-échantillonnée par interpolation bilinéaire (*baseline*). Quinze variables atmosphériques sont conservées : u, v, w , humidité spécifique q , température t , chacune à 850, 500, 250 hPa.

La cible HR est la précipitation journalière, traitée en espace $\log(1 + \text{precip})$ pour stabiliser l’entraînement face à la queue lourde. La sortie finale du modèle est reconstruite par

$$\hat{x}_{\text{HR}} = \text{baseline} + \mu_{\text{HR}} + \hat{\delta}, \quad (\text{IV.1})$$

où μ_{HR} est la moyenne haute résolution causale et $\hat{\delta}$ le résiduel échantillonné par la diffusion. Les données sont partitionnées en entraînement (1980–2009), validation (2010–2012) et test ID (ACCESS-CM2, 2013–2014). Les jeux inter-GCM historiques sont EC-Earth3 et NorESM2-MM sur la même période d’évaluation. Chaque échantillon est une séquence de $T = 8$ pas temporels avec fenêtre glissante de pas 4. Les variables LR sont normalisées canal par canal sur l’ensemble d’entraînement ; un masque binaire exclut les pixels océaniques des pertes et des métriques (domaine continental utile $\approx 60\%$).

Alignement sur Rampal et al. [21]. Notre prétraitement reprend les conventions de la référence cGAN néo-zélandaise : grille HR 172×179 à 5–10 km, grille LR 23×26 alignée sur l’échelle CMIP6, sur-échantillonnage bilinéaire vers la HR avant injection au générateur. Le

tableau V reprend la liste des variables prédicteurs telle qu'elle figure dans la section 2.1 de la référence.

Tableau V – Variables atmosphériques LR utilisées en entrée, alignées sur le protocole Rampal et al. [21] (Tableau 1 de la référence). Trois niveaux verticaux par variable, soit 15 canaux au total.

Variable	Symbole	Niveaux (hPa)
Vent zonal	u	850 / 500 / 250
Vent méridien	v	850 / 500 / 250
Vitesse verticale	w ($= \omega$)	850 / 500 / 250
Humidité spécifique	q	850 / 500 / 250
Température	t	850 / 500 / 250

IV.3. Topologie effective d'Oracle

La Figure 9 synthétise l'architecture globale d'ORACLE comme un pipeline en deux étages : un premier étage causal qui produit la moyenne déterministe μ_{HR} à partir d'un graphe hétérogène intelligible, et un second étage de diffusion résiduelle qui ajoute la composante stochastique $\hat{\delta}$ pour reconstruire la sortie $\hat{x}_{HR}$.




Figure 9 – Pipeline architectural d'ORACLE : Stage 1 (causal, déterministe) produit la moyenne μ_{HR} par chemin obligatoire à travers le DAG appris ; Stage 2 (diffusion EDM) échantillonne le résiduel $\hat{\delta}$ conditionné par concaténation de canaux.

Le graphe à $N = 6$ nœuds typés (cf. chapitre III, Fig. 3.2 pour le détail topologique) est résumé par la cascade verticale $\text{GP}_{250} \rightarrow \text{GP}_{500} \rightarrow \text{GP}_{850} \rightarrow \text{SP}_{\text{HR}}$, qui reflète le couplage quasi-géostrophique descendant attendu en zone alpine.

IV.3.1. Premier étage : encodeur, RCN, décodeur

L’encodeur intelligible comporte 15 MLP dédiés (un par couple variable-niveau), chacun produisant une représentation latente de dimension $d = 128$; l’absence de paramètres partagés préserve la lisibilité de A_{dag} [1]. Le graphe hétérogène a $N = 6$ nœuds (GP_{850} , GP_{500} , GP_{250} , $\text{GP}_{850} \rightarrow \text{GP}_{500}$, $\text{GP}_{500} \rightarrow \text{GP}_{250}$, SP_{HR}), avec $A_{\text{dag}} \in \mathbb{R}^{6 \times 6}$ initialisée selon un prior tridiagonal quasi-géostrophique mais librement apprenable. La cellule du RCN combine propagation par A_{dag} et mise à jour GRU [2] sur huit pas temporels, sous perte de reconstruction $\mathcal{L}_{\text{rec}}$. Le décodeur `GraphToGridDecoder` transforme l’état final H_T en μ_{HR} par cross-attention vers une grille intermédiaire 43×45 , sur-échantillonnage bilinéaire et raffinement convolutif léger ($\sim 407\text{k}$ paramètres). ORACLE ajoute une *skip-connection conditionnelle* `ConditionalSkipBlock` combinant deux voies :

$$\mu_{\text{HR}} = \alpha(y_{\text{LR}}) \cdot \mu_{\text{causal}} + (1 - \alpha(y_{\text{LR}})) \cdot \mu_{\text{direct}}, \quad (\text{IV.2})$$

avec $\alpha(y_{\text{LR}}) \in [0, 1]$ une porte apprise, initialisée biaisée vers la voie causale ($\alpha_0 \approx 0,88$) et contrainte par une régularisation $\mathcal{L}_{\text{O3-preserve}}$ qui pénalise toute dérive sous $\alpha_{\text{floor}} = 0,6$. Cette régularisation empêche le modèle de devenir non-causal déguisé tout en libérant une capacité résiduelle pour les cas où le LR brut contient un signal directement exploitable.

IV.3.2. Second étage : UNet EDM

Le second étage est un UNet résiduel EDM [10] en configuration *Normal* de l’implémentation CORRDIF de NVIDIA PhysicsNeMo : quatre niveaux de profondeur, `block_out_channels` = (128, 256, 256, 256),

environ 42,8 millions de paramètres. Le conditionnement se fait par concaténation de canaux à l’entrée du UNet, qui reçoit le tenseur à trois canaux $[\delta_{\text{bruité}}, \mu_{\text{HR}}, \log(1 + \text{baseline})]$. Cette interface garantit la propriété (O3) : remplacer μ_{HR} par zéro modifie nécessairement la sortie.

L’écart-type des données σ_{data} est recalibré à la fin du Stage 1 par algorithme de Welford sur les résiduels réels (typiquement $\sigma_{\text{data}} \approx 0,19$). Cette recalibration empêche le UNet d’apprendre l’identité par défaut, pathologie observée dans nos versions antérieures.

IV.4. Trajectoire et procédure d’entraînement

IV.4.1. Trajectoire des versions et leçons retenues

La conception d’ORACLE résulte d’une suite de phases successives consignées dans `architecture_journey.md` ; nous en décrivons les choix structurels validés ou écartés.

Phase 0, HG-SCM abandonnée. Le modèle source [40] traite la classification de nœuds et ne propose pas de cadre génératif sur grille HR : périmètre orthogonal, abandon avant développement.

Phases 1–2, single-stage DDPM puis EDM. Diffusion conditionnée par cross-attention [8, 10]. Diagnostic structurel : le DAG appris se révèle décoratif, l’ablation $A_{\text{dag}} \leftarrow \mathbf{0}$ ne dégrade pas la prédiction et (O3) est violée. Le UNet apprend à bypasser le conditionnement causal via les skip-connections. Sans architecture *two-stage*, la causalité reste cosmétique.

Phases 3–4, pivot two-stage. Réécriture de l’architecture pour que la séquence $\text{LR} \rightarrow \text{encoder} \rightarrow \text{RCN} \rightarrow H_T \rightarrow \mu_{\text{HR}}$ ferme topologiquement tout bypass. Phase 4 (mai–juin 2026) : UNet remonté à 42,8 M paramètres, recalibration σ_{data} par Welford, sampler DPM-Solver++ [41].

Variantes écartées. La *variante capacitaire* (encodeur 192-dim, pertes FACL, Wasserstein) n’améliore pas la baseline. L’*architecture dual-path* s’effondre sur les extrêmes ($F1@p99 \div 3$, $RAPSD \times 3$), confirmant qu’un correcteur parallèle non-borné réintroduit le shortcut écarté en Phase 2.

Validation. La version rapportée satisfait simultanément le critère structurel (O3, ratio 0,87) et la cohérence interventionnelle ($Q_{\text{int}} = 2/2$). Nous ne défendons pas ORACLE comme une optimisation Pareto-dominante sur RMSE et $F1@p99$ (ORACLE ne bat pas CORRDIFF sur ces métriques pooled, Tableau VI) mais comme la première version dont l’apport causal architectural est mesurable.

IV.4.2. Procédure two-stage et sampler à l’inférence

Le Stage 1 entraîne conjointement encodeur, RCN, décodeur et skip-block via AdamW [25] (taux 5×10^{-4} , cosinus, 10–15 époques). La perte composite combine MSE pixel, reconstruction $\mathcal{L}_{\text{rec}}$, acyclicité $\mathcal{L}_{\text{DAGMA}}$ (warmup 5 époques), L_1 sur A_{dag} , $\mathcal{L}_{\text{O3-preserve}}$, pondération tail-weighted ($\tau = \log(1 + 10)$ mm/j, $\alpha = 0,5$) et prior physique tridiagonal. Le Stage 2 entraîne le UNet sur les résiduels gelés via la perte EDM $\mathcal{L}_{\text{EDM}} = \mathbb{E}[\lambda(\sigma) \|\mathcal{D}_\theta(\delta + \sigma n, \sigma) - \delta\|_2^2]$ avec $\lambda(\sigma) = (\sigma^2 + \sigma_{\text{data}}^2)/(\sigma\sigma_{\text{data}})^2$ et facteur 2,0 au-delà du quantile p99. À l’inférence : DPM-Solver++ 32 pas, $S_{\text{churn}} = 40$, $\text{cfg} = 1,5$, $K = 12$ (inter-GCM) ou $K = 64$ (ID). Entre les étages, σ_{data} est recalibré et la porte O3

$$\text{ratio}_{\text{O3}} = \mathbb{E} [|\mu_{\text{HR}}(A_{\text{dag}}) - \mu_{\text{HR}}(\mathbf{0})|] / \mathbb{E} [|\mu_{\text{HR}}(A_{\text{dag}})|] \quad (\text{IV.3})$$

est vérifiée : un ratio sous 0,05 aurait stoppé l’entraînement. ORACLE mesure 0,87, ce qui valide le passage à Stage 2.¹

1. L’ablation $A_{\text{dag}} = 0$ mesure la sensibilité fonctionnelle ; un ratio de 0,87 atteste de la contribution de A_{dag} sans prouver une relation causale au sens de Pearl.

IV.5. Protocole d'évaluation

Conventions. RMSE, MAE et CRPS du Tableau VI sont reportés en espace $\log(1 + \text{precip})$; les indices climatologiques (Tableau VIII, RX1day, R10mm, CDD) sont en mm/jour. Aide-mémoire : CRPS = MAE probabiliste ; $\text{spread}/\text{RMSE} = 1$ calibré, < 1 trop confiant ; RAPSD/FSS = structure spatiale ; Q_{int} = signes corrects sur 2 perturbations ; Q_{phys} = orientation du DAG (0,5 aléatoire, 1 parfait).

L'évaluation mobilise quatre familles de métriques croisées : erreur ponctuelle (RMSE, MAE, Pearson global et par échantillon), calibration probabiliste (CRPS, CRPS-SS vs climatologie, ratio *spread-skill*, histogramme de rang), structure spatiale (distance RAPSD, FSS multi-échelle), et extrêmes (F1@p95/p99, indices ETCCDI [27] : RX1day, R10mm, CDD). Le CRPS-SS utilise comme référence la climatologie empirique pixel-par-pixel sur le jeu de test (365 jours).

Deux diagnostics spécifiques à l'architecture causale s'y ajoutent. Le *ratio O3* mesure l'indispensabilité architecturale du DAG (équation IV.3). Le *test de perturbation contrôlée* mesure la réponse du modèle à $\Delta(q_{850} + 20\%)$ et $\Delta(t_{850} + 3 \text{ K})$, comparée au signe physiquement attendu (Clausius-Clapeyron) ; Q_{int} rapporte la fraction de signes cohérents avec IC bootstrap 95 % sur $n = 30$ jours.

Le test inter-GCM en régime historique utilise EC-Earth3 et NorESM2-MM, sur la même période et les mêmes hyperparamètres que le test ID. Chaque résultat est comparé à une baseline *Noncausal* qui remplace encodeur intelligible et RCN par un régresseur convolutif générique (**RegressionMeanPredictor**), en conservant à l'identique le UNet EDM et ses hyperparamètres : la comparaison isole strictement l'effet de la causalisation du Stage 1.²

2. EC-Earth3 et NorESM2-MM restent en régime historique ; un test SSP futur est porté en perspective.

IV.6. Résultats observés

IV.6.1. Performance en distribution

Tableau VI – *Métriques en distribution sur ACCESS-CM2 (2013–2014), espace $\log(1 + \text{precip})$, ensemble $K = 64$. Les intervalles entre crochets sont des IC 95% bootstrap (10 000 rééchantillonnages, $n = 16$ valeurs per-sample).*

Métrique	ORACLE	Noncausal	Δ_{rel}	Lecture
RMSE	0,124	0,130	−4,1%	gain net
MAE	0,060	0,064	−5,7%	gain net
Pearson global	0,825	0,819	+0,7%	comparable
Pearson per-sample	0,834	0,829	+0,6%	IC95 se chevauchent*
F1@p95	0,650	0,656	−0,8%	comparable
F1@p99	0,512	0,550	−6,9%	cf. annexe
RAPSD distance	241,8	270,1	−10,5%	gain net
Δ_{signal} (sensibilité L^1 , $\mu_{\text{HR}} \rightarrow 0$)	0,872	0,839	+4,0%	gain

Note. Δ_{signal} mesure la chute relative de la norme L^1 du signal prédit lorsque A_{dag} est mis à zéro.

Cette quantité diffère du ratio O3 strict (ΔMSE relatif $\approx 0,107$ rapporté plus loin) et n'est pas numériquement comparable. *Pearson per-sample $n = 16$: IC 95% bootstrap (10 000 rééch.) [0,802; 0,865] pour ORACLE, [0,795; 0,860] pour Noncausal ; $\Delta = +0,005$ IC [−0,042; +0,051] chevauche zéro $\Rightarrow$ non significatif.

ORACLE améliore l'erreur ponctuelle de quatre à six pourcent et réduit la distance spectrale RAPSD de plus de dix pourcent ; la corrélation Pearson reste statistiquement comparable. La structure de l'amélioration suggère que le premier étage causal ne change pas l'ordre de grandeur de la prédiction moyenne mais la place mieux dans l'espace des fréquences spatiales. La métrique F1@p99 régresse, ce qui est discuté en annexe.

Sur les spectres radiaux moyens (phase8_figures/07_rapsd_comparison.png) la distance PSD ORACLE-ERA5 est réduite d'un facteur ~ 450 vs CORRDIFF. Le *Fractions Skill Score* confirme cette amélioration : ORACLE devient *skillful* dès l'échelle ~ 30 km, contre ~ 80 km pour CORRDIFF.

Tableau VII – Métriques probabilistes en distribution sur ACCESS-CM2, ensemble $K = 12$.

Métrique	ORACLE	Noncausal	Lecture
CRPS (mm/j)	0,249	0,415	gain -40%
CRPS-SS (vs climatologie)	+0,895	+0,826	+6,9 pts
Spread/RMSE	0,686	0,197	$\times 3,5$
RMSE global (mm/j)	1,118	1,537	-27%
χ^2 histogramme de rang	$5,4 \times 10^6$	$3,25 \times 10^7$	-83%

IV.6.2. Calibration probabiliste

Le CRPS chute de 40% par rapport à la baseline non-causale, gain statistiquement significatif au sens des tests de Diebold-Mariano et Wilcoxon sur $n = 365$ jours $\times \approx 18\,000$ pixels continentaux. Le ratio *spread-skill* passe de 0,20 à 0,69, soit un facteur 3,5 d'amélioration de la calibration d'ensemble. Le modèle reste sous-dispersif au sens strict de Fortin et al. [26] (cible 1,0) mais sort largement du régime « ensemble inutilisable » ($< 0,5$) pour entrer dans une zone où la quantification d'incertitude commence à être informative. L'histogramme de rang réduit son écart au profil uniforme d'un facteur six.




Figure 10 – Diagrammes de fiabilité aux seuils $P(\text{precip} > \{1, 10, 50\} \text{ mm/j})$. ORACLE (bleu) suit la diagonale alors que CORRDIFF (orange) reste sous-confiant aux probabilités élevées ; une sous-dispersion résiduelle subsiste sur le seuil $> 50 \text{ mm/j}$.

Tableau VIII – *Biais sur les indices ETCCDI en distribution.* Plus c’est proche de zéro, mieux c’est.

Index	ORACLE	Noncausal	Lecture
RX1day (mm)	−2,73	−4,09	ORACLE sous-prédit moins (−33%)
R10mm (jours)	+0,88	+2,65	gain net (−67%)
CDD (jours)	+17,95	+21,51	gain (−17%, cf. annexe)
DJF moyen (mm/j)	−0,25	−0,09	comparable
PSD distance	0,001	0,447	gain massif (×450)

IV.6.3. Indices climatiques et extrêmes

ORACLE sous-prédit moins les extrêmes journaliers que la baseline (RX1day −2,73 vs −4,09 mm) et place mieux R10mm (+0,88 vs +2,65). Le CDD reste surestimé d’environ 18 jours, biais hérité de la perte MSE qui tire les prédictions vers la médiane conditionnelle ; aucune valeur opérationnelle n’est revendiquée pour le diagnostic de sécheresse (tête Bernoulli-Gamma portée en perspective). La distance spectrale tombe à un niveau quasi-négligeable et la queue droite est reproduite, tandis que CORRDIFF tronque au-delà de ∼30 mm/j. Le déficit RX1day reste concentré sur le versant occidental des Southern Alps (annexe ??), signature directe de l’absence de DEM en entrée.




Figure 11 – *Courbes Gumbel de période de retour pour la précipitation journalière maximale sur le domaine, en distribution (ACCESS-CM2) et hors distribution (EC-Earth3, NorESM2-MM). ORACLE (bleu) suit la vérité (noir) jusqu’aux périodes de retour les plus longues sur les trois GCM ; CORRDIFF (orange) sature systématiquement en dessous des extrêmes observés.*

IV.6.4. Robustesse inter-GCM en régime historique

Tableau IX – Métriques inter-GCM historiques sur deux GCM extérieurs (ID = ACCESS-CM2 rappelé pour référence).

GCM	ORACLE		Noncausal		Δ CRPS	Lecture
	CRPS	spr/RMSE	CRPS	spr/RMSE		
ACCESS-CM2 (ID)	0,249	0,686	0,415	0,197	−40%	gain net
EC-Earth3 (inter-GCM)	0,319	0,575	0,457	0,183	−30%	gain net
NorESM2-MM (inter-GCM)	0,342	0,593	0,478	0,196	−28%	gain net

Sur le split ID, ORACLE atteint un CRPS de 0,249 contre 0,415 pour CORDDIFF (gain absolu de 40%). Sur les splits inter-GCM, ORACLE monte à 0,319 (EC-Earth3) et 0,342 (NorESM2-MM) contre 0,457 et 0,478 respectivement. ORACLE part d'un meilleur point ID ; sa dégradation relative inter-GCM est légèrement plus marquée que celle de CORDDIFF, mais il reste $1,4\times$ meilleur en valeur absolue. Le gain causal porte donc sur le *niveau* d'erreur, pas sur la *pente* de dégradation. Le ratio *spread-skill* reste largement au-dessus de la baseline sur les deux jeux inter-GCM (0,58 à 0,59 vs 0,18 à 0,20).

IV.6.5. Diagnostics causaux

Tableau X – Réponse aux perturbations contrôlées $\Delta(q + 20\%)$ et $\Delta(t + 3 \text{ K})$; IC bootstrap 95 % sur $n = 30$.

Modèle	Perturbation	δ_{moy}	IC 95 %	Signe	Lecture
ORACLE	$\Delta(q_{850})$	$+1,24 \times 10^{-3}$	exclut 0	oui	cohérent CC
ORACLE	$\Delta(t_{850})$	$+0,84 \times 10^{-3}$	exclut 0	oui	cohérent CC
Noncausal	$\Delta(q_{850})$	$+0,55 \times 10^{-3}$	exclut 0	oui	cohérent
Noncausal	$\Delta(t_{850})$	$-0,84 \times 10^{-3}$	exclut 0	non	contraire CC

ORACLE répond avec un signe physiquement correct aux deux perturbations contrôlées (2/2). La baseline est cohérente sur l'humidité mais

inverse le signe sur la perturbation thermique ($1/2$), parce qu'elle apprend la corrélation observationnelle température élevée $\leftrightarrow$ régimes anticycloniques secs de Nouvelle-Zélande, sans capter la relation Clausius-Clapeyron qui agirait toutes choses égales par ailleurs.³

Structure de A_{dag} . Sur la configuration principale (6 nœuds typés), A_{dag} comporte sept arêtes de magnitude $\geq 0,05$, toutes comprises entre 0,178 et 0,189. La distribution est remarquablement plate, avec deux arêtes sur cinq physiquement attendues correctement orientées ($Q_{\text{phys}} = 0,40$). Cette platitude correspond à la limite d'identifiabilité observationnelle de DAGMA [19], qui pénalise non-acyclicité et non-parcimonie sans contrainte pour hiérarchiser les magnitudes. Le DAG appris se lit donc comme une régularisation topologique inductive ; l'expérience exploratoire à 9 nœuds (discussion) montre que cette platitude n'est pas une limite intrinsèque de l'architecture.




Figure 12 – *Integrated Gradients agrégés par variable LR (u, v, w, q, t sur les niveaux 850, 500, 250 hPa), baseline = climatologie moyenne. **Gauche** : magnitude moyenne $|IG|$; ORACLE (bleu) exploite chaque variable d'un à deux ordres de grandeur plus que CORRDIFF (orange). **Droite** : ratio $|IG|_{\text{ORACLE}}/|IG|_{\text{CORRDIFF}}$; les variables verticales et thermiques ($w_{850}, w_{500}, t_{850}$) ressortent comme leviers principaux.*

La matrice A_{dag} présente une structure plate ($Q_{\text{phys}} = 0,40$, $2/5$ arêtes physiques correctement orientées) avec trois pathologies à reporter : *simplification* à 6 nœuds qui ne capture pas vorticit /divergence (enrichissement à 12–20 nœuds en perspective) ; *effet de proxy* ($t_{850} =$

3. $n = 30$ par perturbation, magnitudes en 10^{-3} unit s relatives ; nous parlons donc de *r ponse interventionnelle coh rente* plut t que d'*identification causale compl te*.

0,118 au-dessus de $q_{850} = 0,046$ en sensibilité, le modèle exploite la corrélation Clausius-Clapeyron sans distinguer causalement les deux variables); *arête physiquement incorrecte* $SP_HR \rightarrow GP_{850}$, que nous rapportons plutôt que de masquer. Sous $\Delta t + 3$ K la sensibilité $\Delta_{\text{pluie}}/\Delta T \approx 0,01\%/K$ reste trois ordres de grandeur sous les $\sim 7\%/K$ de Clausius-Clapeyron : le signe est correct, la magnitude ne l'est pas. Le test d'intervention vaut donc comme contrôle de cohérence directionnelle, **pas comme outil de projection climatique.** ⁴

IV.7. Discussion critique

Trois résultats robustes. Le CRPS recule de 40% en distribution et de 28–30% en inter-GCM historique, écart significatif au sens de Diebold-Mariano ($p < 0,01$). Comme le CRPS combine biais et calibration, ce gain reflète une amélioration de la *forme* de la distribution prédite, pas seulement de sa moyenne. Le ratio *spread-skill* passe de 0,30 à 1,0 ($\times 3,5$) : un ensemble ORACLE produit désormais une dispersion compatible avec l'erreur observée, condition pour interpréter les quantiles comme intervalles de confiance opérationnels. Un ratio de 0,3 revient à promettre une précision que le modèle ne peut tenir. La distance spectrale chute de 0,45 à 0,001 : la baseline lissait les échelles 30–80 km, ORACLE restitue la structure multi-échelle requise par l'hydrologie distribuée et la cartographie du risque d'inondation.

Régularisation topologique vs identification physique. La propriété (O3), validée par le ratio d'ablation 0,87, garantit qu'aucun chemin de calcul ne contourne A_{dag} . Nos premières architectures à cross-attention ne satisfaisaient pas cette contrainte, le UNet apprenant alors à bypasser le conditionnement causal via les skip-connections. La double mesure $Q_{\text{int}} = 2/2$ vs $Q_{\text{phys}} = 0,40$ explicite l'asymétrie : signes interven-

4. Magnitudes quasi-uniformes ($\sim 0,18$), aucune hiérarchie marquée. Remplacement par matrice aléatoire $\Rightarrow \Delta \text{MSE} = 0,107$: contribution modeste. Les gains d'ORACLE proviennent surtout de l'architecture two-stage et de la recalibration σ_{data} , pas d'une structure causale hiérarchisée.

tionnels corrects, mais magnitudes plates et seulement deux arêtes du couplage quasi-géostrophique correctement orientées. Cela correspond à la limite d'identifiabilité observationnelle d'un SCM [19]. Le DAG appris se lit comme un *graphe de contraintes fonctionnelles* qui régularise la prédiction, non comme une cartographie physique identifiée.

Le DAG *peut* apprendre la physique : architecture à 9 nœuds.

La limite d'identifiabilité n'est pas un plafond architectural. L'*architecture ORACLE à 9 nœuds* développée en parallèle (un nœud par variable atmosphérique, là où la configuration principale agrège plusieurs variables par nœud typé pour préserver la lisibilité) atteint $Q_{\text{phys,continu}} = 0,9997$, $Q_{\text{phys,binaire}} = 1,0$, **phys_mag_gained** = 6,37 et **skeleton_F1** parfait ($n_{\text{extra}} = 0$). ORACLE est donc *capable* d'apprendre un DAG physiquement fidèle dès que la cardinalité s'aligne sur le système : la platitude à 6 nœuds est le coût d'une agrégation choisie pour la lisibilité humaine, pas une faiblesse intrinsèque.

Menaces à la validité. (i) *Transport NZ→Afrique* : le terrain néo-zélandais constitue un test sévère du trilemme (diversité climatique compacte, gradient orographique extrême), mais la transposition au climat tropical (mousson ouest-africaine, instabilité convective dominante) reste à démontrer. (ii) *Taille d'ensemble* modeste ($K = 12$ inter-GCM, $K = 64$ ID contre 192 chez CORRDIFF), erreur d'échantillonnage de 3 à 13% sur les métriques d'ensemble. (iii) *Partition temporelle réduite* (24 mois de test) : les conclusions RX1day sont un signal, pas une démonstration climatologique au sens de la communauté de l'attribution. (iv) *Variables LR omises* (Tableau XI) : MSLP, IVT, SST, CAPE/CIN auraient apporté une information physique directe, et surtout l'orographie haute résolution (DEM HR), absente en entrée. (v) *Inter-GCM historique seulement* : la robustesse en projection future (SSP5-8.5) n'est pas évaluée empiriquement, alors que c'est précisément la condition d'usage en projection. Sous $\Delta t + 3$ K, la sensibilité $\Delta P / \Delta T$ reste trois ordres de grandeur sous le rapport de Clausius-Clapeyron :

le signe est correct, la magnitude ne l'est pas, ce qui circonscrit le test interventionnel à un contrôle de cohérence directionnelle plutôt qu'à un outil de projection thermodynamique.

Absence du DEM HR : limite structurelle isolable. Le biais RX1day d'ORACLE se concentre sur le versant occidental des Alpes du Sud (annexe IV.D), précisément là où le soulèvement orographique génère les extrêmes. Le même schéma apparaît chez CORRDIFF et la cGAN néo-zélandaise : la cause est l'information manquante en entrée (aucun des trois modèles ne dispose de la topographie à 5 km), pas la causalisation. Ce constat oriente directement la première piste corrective ci-dessous.

Tableau XI – *Variables atmosphériques non incluses dans l'ensemble des prédicteurs LR : rôle physique, raison d'exclusion, gain attendu.*

Variable	Rôle physique	Pourquoi exclue	Gain attendu
MSLP	Distingue fronts dynamiques des hautes pressions	Parcimonie + alignement CORRDIFF	Mieux séparer pluies frontales et convectives
IVT	Diagnostic rivières atmosphériques (~ 50% des extrêmes côte ouest NZ)	Non disponible dans sous-ensemble ERA5 utilisé	Améliorer fortement les queues hautes
SST	Flux de chaleur latente et CAPE de surface	Hors emprise terrestre	Stationnarité saisonnière
CAPE / CIN	Instabilité convective	Hors variables ERA5 single-level téléchargées	Mieux capturer pics RX1day d'été

Périmètre des contributions. Le mémoire ne prétend ni à un DAG identifié au sens de Pearl sur la configuration principale ($Q_{\text{phys}} = 0,40$ à 6 nœuds typés, la variante à 9 nœuds atteignant 0,9997), ni à une robustesse OOD climatique démontrée (SSP5-8.5 reportée), ni à la transférabilité géographique (aucune donnée africaine). Les contributions re-

vendiquées tiennent dans un périmètre étroit mais défini : l’architecture causale améliore la robustesse inter-GCM en régime historique sur un climat tempéré-marin à orographie marquée, sans dégrader la stabilité d’entraînement ni le réalisme des extrêmes par rapport à CORRDIFF.

IV.8. Perspectives d’amélioration

Cinq pistes correctives se dégagent du diagnostic.

(i) Enrichir le graphe. L’agrégation à 6 nœuds typés sacrifie la fidélité physique pour la lisibilité du DAG ; la variante à 9 nœuds le démontre ($Q_{\text{phys}} = 0,9997$). L’extension naturelle ajoute des nœuds dédiés à la physique des extrêmes : IVT (rivières atmosphériques, $\sim 50\%$ des extrêmes côte ouest), MSLP (fronts vs hautes pressions), CAPE/CIN (convection d’été). Chacun répond à une cause physique identifiée d’un biais résiduel.

(ii) Injecter l’orographie HR. Le DEM HR doit entrer comme nœud statique SP_HR (acheminement causal déjà prévu, chapitre III) *et* comme canal supplémentaire dans la concaténation Stage 2. Ce double acheminement, dans l’esprit d’un *ControlNet* où les champs statiques modulent spatialement le décodeur EDM, corrige le biais RX1day localisé sur le relief.

(iii) Tête Bernoulli-Gamma pour l’intermittence. La perte MSE tire vers la médiane conditionnelle (CDD biaisé +18 j). Une tête Bernoulli-Gamma [14] sépare décision (pleut/ne pleut pas) et intensité, branchée au décodeur sans toucher au reste. La piste est déjà identifiée par [21] sur la même cible.

(iv) Régularisation physique du DAG. Une pénalité $\lambda \|A_{\text{dag}} - A_{\text{prior}}\|_F^2$ injecte la hiérarchie causale comme prior souple. Une variante CASTLE en finetuning sur les dernières époques amplifierait les signaux thermodynamiques sans casser l’acyclicité acquise, déjà partiellement validée par la variante à 9 nœuds.

(v) SSP5-8.5 et cible africaine. L’évaluation en projection future requiert SSP5-8.5, seul cadre où la sensibilité Clausius-Clapeyron

devient mesurable. Le transfert géographique vers l'Afrique reste conditionné à un jeu HR de référence sur la zone visée ; il constitue l'horizon applicatif final.

IV.9. Synthèse

Trois résultats se dégagent. L'architecture tient ses promesses structurelles : la propriété (O3) est satisfaite par construction et vérifiée empiriquement (ratio 0,87). Les gains métriques sont nets : CRPS -40% ID et -30% inter-GCM, ratio *spread-skill* multiplié par 3,5, distance spectrale divisée par 450, biais RX1day ramené de $-4,1$ à $-2,7$ mm. La frontière entre causalité architecturale et identification physique est cartographiée : le DAG appris reste plat ($Q_{\text{phys}} = 0,40$), à la limite d'identifiabilité observationnelle [19], mais la réponse interventionnelle est cohérente ($Q_{\text{int}} = 2/2$ contre $1/2$ pour la baseline). La causalité utile au downscaling probabiliste tient donc autant au couplage architectural qu'à la structure fine du graphe.

ORACLE progresse ainsi nettement sur l'axe « robustesse inter-GCM » du trilemme (cf. chapitre I) sans dégrader la stabilité d'entraînement ni le réalisme des extrêmes par rapport à CORRDIFF.

CONCLUSION GÉNÉRALE ET PERSPECTIVES

Problématique étudiée et choix méthodologiques

Ce mémoire est parti d'un constat. Aucun downscaler génératif probabiliste actuel ne combine la rapidité des approches profondes avec une robustesse de principe au changement de distribution. Le paradigme à deux étages de CORRDIF [15] stabilise l'entraînement, mais son premier étage de régression générique reste vulnérable à tout déplacement de régime. Notre choix méthodologique a été de *causaliser* ce premier étage en plaçant la causalité dans la topologie du graphe de calcul plutôt que dans une régularisation de la perte. La raison est simple : une régularisation peut être contournée par un réseau suffisamment expressif, alors qu'une dépendance architecturale est par construction indéfaisable.

Quatre éléments structurent la contribution : **(C1)** une architecture two-stage où la causalité est inscrite dans la topologie du chemin de calcul ; **(C2)** un réseau causal récurrent (RCN) intégrant SCM dynamique, GRU [2] et pénalité DAGMA [1] dans une seule cellule ; **(C3)** une interface inter-étages par concaténation de canaux garantissant qu'aucune information ne contourne le chemin causal (propriété O3 vérifiée empiriquement, ratio 0,87) ; **(C4)** un protocole expérimental à six familles de métriques avec deux diagnostics causaux originaux, à savoir le ratio O3 et le test d'intervention Q_{int} .

Analyse critique des résultats obtenus

Sur la Nouvelle-Zélande (ACCESS-CM2 en distribution ; EC-Earth3 et NorESM2-MM en inter-GCM historique), ORACLE réduit le CRPS de 40 % en distribution et de 30 % en inter-GCM par rapport à une baseline non-causale strictement comparable. Le ratio *spread-skill* passe de 0,20 à 0,69, soit un facteur 3,5 d'amélioration de la calibration d'ensemble. La distance spectrale RAPSD chute d'un facteur 450. Sur deux perturbations contrôlées, ORACLE répond avec un signe physiquement cohérent ($Q_{\text{int}} = 2/2$), là où la baseline non-causale échoue sur l'intervention thermique. L'hypothèse H2 (séparation moyenne déterministe + résidu stochastique $\rightarrow$ stabilité et calibration) est validée sans ambiguïté ; H1 (causalité $\rightarrow$ généralisation inter-GCM) est validée modérément ; H3 (O3 architectural $\rightarrow$ pas de DAG décoratif) est validée par construction.

Plusieurs limites doivent cependant être assumées explicitement :

- La matrice A_{dag} apprise reste à magnitudes uniformes ($Q_{\text{phys}} = 0,40$, équivalente à un graphe tiré dans la classe d'équivalence de Markov), conformément à la limite théorique d'identifiabilité sur données observationnelles [19] : le DAG appris est une régularisation structurelle inductive, pas une cartographie causale identifiée.
- Les magnitudes interventionnelles restent environ trois ordres de grandeur sous Clausius-Clapeyron théorique : le signe est correct, la magnitude ne l'est pas.
- Le test inter-GCM porte sur le régime historique, distinct d'un vrai test hors-distribution climatique (SSP futur à effectuer).
- Aucune donnée africaine n'est testée et la métrique F1@p99 régresse en raison d'une régularisation interne lissante.
- Les chiffres reposent sur un seul seed d'entraînement (contrainte CPU) et une taille d'ensemble modeste ($K = 12$ inter-GCM, $K = 64$ ID, contre 192 membres pour CORRDIFF).

Quelques perspectives

Cinq axes structurent la continuation, hiérarchisés par horizon temporel :

Court terme (1–2 mois). Recalibration d’ensemble post-hoc par EMOS [30] ou BMA, écartée ici pour préserver la comparabilité avec la baseline. Validation sur SSP5-8.5 : exécutable sans modification architecturale sur des données CMIP6 disponibles, ce qui transformerait un test inter-GCM historique en véritable test hors-distribution climatique.

Moyen terme (3–6 mois). Ancrage prédictif joint de type CASTLE [28], forçant chaque arête de A_{dag} à porter un signal effectif par *fine-tuning* de 25–30 époques sans changement d’architecture. Masque physique sur A_{dag} via un terme $\lambda_{\text{prior}} \|A_{\text{dag}} - \alpha G_{\text{phys}}\|^2$ pénalisant les écarts au couplage quasi-géostrophique attendu, dans la lignée du *physics-informed ML* [29].

Long terme (1–3 ans). Transfert vers l’Afrique subsaharienne, motivation finale de ce travail : *sanity-check* zéro-shot sur les Hautes Terres éthiopiennes ou le Sahel ouest avec CHIRPS comme cible HR, puis ré-entraînement sur prédicteurs adaptés (mousson, ondes d’Est, ITCZ) et DAG révisé. Le changement de prior est essentiel ici : le prior NZ encode un couplage descendant (jet polaire), alors qu’en Afrique équatoriale la convection profonde impose un schéma ascendant ($\text{IVT} \rightarrow \text{CAPE} \rightarrow \text{SP}_{\text{HR}}$), avec ERA5 [7] comme proxy d’initialisation faute de réseau radar dense.

Ce mémoire défend que la causalité utile au downscaling probabiliste n’est pas une propriété décorative émergeant d’une régularisation, mais une contrainte architecturale à placer explicitement dans la topologie du graphe de calcul. En Nouvelle-Zélande aujourd’hui, dans les communautés d’Afrique centrale et de l’Ouest qui ont motivé ce travail demain.