

RÉPUBLIQUE DU CAMEROUN

PAIX – TRAVAIL – PATRIE

UNIVERSITÉ DE DSCHANG

ÉCOLE DES SCIENCES ET
TECHNOLOGIES DE DSCHANG



REPUBLIC OF CAMEROON

PEACE – WORK – FATHERLAND

UNIVERSITY OF DSCHANG

SCHOOL OF SCIENCES AND
TECHNOLOGIES OF DSCHANG

UNITÉ DE RECHERCHE EN INFORMATIQUE FONDAMENTALE,
INGÉNIERIE ET APPLICATIONS (URIFIA)

THÈME :

**Développement de Méthodes
d'Apprentissage Automatique
pour la Mise à l'Échelle Spatiale
des Données Climatiques**

Mémoire présenté en vue de l'obtention du diplôme de

Master en Informatique

Option : Informatique Fondamentale

Spécialisation : Intelligence Artificielle

Par

KENFACK Leonel

Matricule : *CM-UDS-17SCI0998*

Licence en Informatique Fondamentale

Sous la direction de :

Pr. BOMGNI Alain Bertrand

Professeur Titulaire, Université de Dschang

Année académique 2025–2026

Certification

Je soussigné, **KENFACK Leonel**, étudiant en Master 2 en Informatique, option *Informatique Fondamentale*, spécialisation *Intelligence Artificielle* au Département de Mathématiques et Informatique, matricule CM-UDS-17SCI0998, Faculté des Sciences, Université de Dschang, certifie que les présents travaux de recherche intitulés « *Développement de Méthodes d'Apprentissage Automatique pour la Mise à l'Échelle Spatiale des Données Climatiques* », réalisés au sein de l'Unité de Recherche en Informatique Fondamentale, Ingénierie et Applications (URIFIA) de l'Université de Dschang sous la direction du **Pr. BOMGNI Alain Bertrand**, Professeur Titulaire à l'Université de Dschang, sont le fruit de mes propres travaux de recherche.

Cela n'a jamais été publié auparavant pour l'obtention d'un diplôme.

L'étudiant

KENFACK Leonel

Date :

Le superviseur

Pr. BOMGNI Alain Bertrand

(Professeur Titulaire)

Date :

Le chef de département

Date :

*À mes parents,
dont la patience et le soutien constant ont rendu possible
ce parcours d'études supérieures.*

REMERCIEMENTS

Je tiens à remercier **Dieu Tout-Puissant** sans qui rien n'aurait été possible.

Je remercie mon directeur de mémoire, le **Pr. BOMGNI Alain Bertrand**, pour sa disponibilité, la rigueur de ses relectures et la confiance qu'il m'a accordée. Je lui suis particulièrement reconnaissant de m'avoir mis à disposition le serveur de calcul qui a rendu possible l'ensemble des phases exploratoires de ce travail, ainsi que pour les conseils méthodologiques qui en ont structuré la forme finale.

J'adresse mes remerciements à **l'ensemble de mes enseignants** de l'Université de Dschang, dont les enseignements ont nourri la formation scientifique sur laquelle ce mémoire s'appuie. Je remercie également les membres du jury qui ont accepté d'évaluer ce travail.

Je remercie enfin **mes parents** et mes proches, dont le soutien quotidien et la patience indéfectible ont rendu ces deux années fertiles.

Table des matières

Table des figures

Liste des tableaux

LISTE DES ACRONYMES

ACCESS-CM2	GCM australien utilisé en distribution (CMIP6)
CASTLE	<i>Causal Structure Learning via Auxiliary Causal Graph Discovery</i>
CC	Clausius-Clapeyron, relation vapeur saturante / température
CDD	<i>Consecutive Dry Days</i> , jours secs consécutifs (ETCCDI)
cGAN	<i>Conditional Generative Adversarial Network</i>
CMIP6	<i>Coupled Model Intercomparison Project Phase 6</i>
CORRDIFF	Architecture two-stage de diffusion résiduelle (Mardani 2024)
CRPS	/ <i>Continuous Ranked Probability Score</i> et son skill score
CRPS-SS	
DAG	<i>Directed Acyclic Graph</i> , graphe acyclique dirigé
DAGMA	<i>DAG via M-matrices and log-determinant Acyclicity</i>
DDPM	/ <i>Denoising Diffusion Probabilistic Models</i> / EDM
EDM	(Karras 2022)
EC-Earth3, NorESM2-MM	GCM utilisés en hors-distribution
ERA5	Réanalyse atmosphérique de référence (Hersbach 2020)
ETCCDI	<i>Expert Team on Climate Change Detection and Indices</i>

F1@p95/p99	Score F1 sur les pixels excédant le quantile p95 ou p99
FSS	<i>Fractions Skill Score</i>
GAN	<i>Generative Adversarial Network</i>
GCM / RCM	Modèle de circulation générale / modèle climatique régional
GIEC / IPCC	Groupe d'experts intergouvernemental sur l'évolution du climat
GP	Géopotential, à différents niveaux de pression (GP850, GP500, GP250)
GRU	<i>Gated Recurrent Unit</i> (Cho 2014)
HR / LR	Haute / basse résolution
ID / OOD	En distribution / hors-distribution
IG	<i>Integrated Gradients</i>
MAE / MSE / RMSE	Erreurs ponctuelles standards
$Q_{\text{int}}, Q_{\text{phys}}$	Score interventionnel / orientation physique du DAG
RAPSD / PSD	<i>Power Spectral Density</i> radialement moyennée
RCN	<i>Recurrent Causal Network</i> , réseau causal récurrent
R10mm / RX1day	Indices ETCCDI sur la précipitation
SCM	<i>Structural Causal Model</i> (Pearl)
SSP	<i>Shared Socioeconomic Pathway</i> , scénario CMIP6
UNet	Architecture U pour segmentation et diffusion (Ronneberger 2015)
URIFIA	Unité de Recherche d'Informatique Fondamentale et Appliquée

RÉSUMÉ

Le *downscaling* climatique transforme des champs atmosphériques basse résolution issus de modèles globaux en champs haute résolution exploitables localement. Les architectures profondes récentes (cGAN résiduels, diffusion à deux étages) améliorent qualité prédictive et calibration mais restent fragiles sous changement de distribution. Ce mémoire propose ORACLE, une architecture à deux étages qui place la causalité dans la topologie du graphe de calcul : un encodeur intelligible par variable, un graphe hétérogène à six nœuds, un réseau causal récurrent gouverné par une matrice apprise sous contrainte DAGMA et un décodeur graphe-à-grille produisent une moyenne haute résolution ; une diffusion EDM résiduelle conditionnée par concaténation de canaux échantillonne le résidu, garantissant par construction la propriété d’indispensabilité du DAG (O3).

Sur la Nouvelle-Zélande (ACCESS-CM2 en distribution ; EC-Earth3, NorESM2-MM hors-distribution), ORACLE réduit le CRPS de 40% en ID et de 30% en inter-GCM historique. Le ratio *spread-skill* passe de 0,20 à 0,69 ($\times 3,5$) ; la distance spectrale chute d’un facteur 450. La réponse à deux perturbations contrôlées ($\Delta q + 20\%$, $\Delta t + 3$ K) coïncide avec le signe physique attendu, là où la baseline non-causale échoue sur l’intervention thermique. Le mémoire assume ses limites : le DAG appris reste à magnitudes plates ($Q_{\text{phys}} = 0,40$), à lire comme une régularisation structurelle inductive plutôt qu’une cartographie causale identifiée.

Mots-clés : downscaling climatique, modèles de diffusion, EDM, causalité architecturale, DAGMA, robustesse inter-GCM en régime historique, précipitation, CMIP6, intervention contrôlée, calibration d’ensemble.

ABSTRACT

Climate downscaling transforms low-resolution atmospheric fields from global climate models into high-resolution fields suitable for local decision-making. Recent deep architectures (residual cGANs, two-stage diffusion) improve predictive accuracy and probabilistic calibration but remain fragile under distribution shift. This thesis proposes ORACLE, a two-stage architecture that places causality in the computation graph topology : a per-variable intelligible encoder, a six-node heterogeneous graph, a recurrent causal network governed by a DAGMA-constrained learned matrix and a graph-to-grid decoder produce a high-resolution mean ; a residual EDM diffusion conditioned by channel concatenation samples the residual, guaranteeing by construction the DAG indispensability property (O3).

Over New Zealand (ACCESS-CM2 in-distribution ; EC-Earth3, NorESM2-MM out-of-distribution), ORACLE reduces the CRPS by 40% in-distribution and by 30% inter-GCM. The spread-skill ratio rises from 0.20 to 0.69 ($\times 3.5$) ; the spectral distance drops by a factor of 450. The response to two controlled perturbations ($\Delta q + 20\%$, $\Delta t + 3$ K) matches the expected physical sign, whereas the non-causal baseline fails on the thermal intervention. The thesis openly assumes its limitations : the learned DAG remains with flat magnitudes ($Q_{\text{phys}} = 0.40$), to be read as inductive structural regularisation rather than identified causal mapping.

Keywords : climate downscaling, diffusion models, EDM, architectural causality, DAGMA, inter-GCM robustness in historical regime, precipitation, CMIP6, controlled intervention, ensemble calibration.

INTRODUCTION GÉNÉRALE

Contexte du travail	??
Problématique étudiée	??
Objectifs	??
Contribution	??
Organisation du manuscrit	??

Contexte du travail

Le changement climatique impose aux décideurs locaux des choix de plus en plus fins en matière d’agriculture, de gestion de l’eau et d’urbanisme. Au Cameroun, l’agriculture représente environ 22 % du PIB et fait vivre près de 44 % de la population active [?] : secteur très majoritairement pluvial dont la planification dépend directement de la qualité des projections climatiques locales. La centrale hydroélectrique de Lagdo fournit environ 74 % de l’électricité du Nord-Cameroun [?] ; les inondations de l’Extrême-Nord d’octobre 2024 ont affecté 356 000 personnes et noyé 82 500 hectares de cultures sans qu’aucune anticipation communale ait été possible [?]. À l’échelle continentale, la productivité agricole africaine a diminué d’environ 34 % depuis 1961 sous l’effet du changement climatique — la régression la plus forte toutes régions confondues [?] — et la Banque Mondiale estime qu’en l’absence d’adaptation, le Cameroun pourrait perdre entre 4 et 10 % de son PIB d’ici 2050 [?].

Or les modèles climatiques globaux (GCM) utilisés par le GIEC simulent l’atmosphère à 100–250 km par maille [?]. À cette échelle, Douala et Yaoundé occupent la même cellule, le mont Cameroun n’a

aucun effet, la transition savane–forêt disparaît. Pour utiliser ces simulations dans des décisions d’aménagement, d’agriculture ou d’énergie, il faut produire une représentation à plus fine échelle (1 à 12 km) : c’est la **descente d’échelle climatique** (*downscaling*). Deux familles coexistent : la **descente d’échelle dynamique** emboîte un modèle régional (RCM) dans le GCM et résout les équations à plus fine maille [?] — physiquement rigoureux mais très coûteux — ; la **descente d’échelle statistique**, fondée aujourd’hui sur l’apprentissage profond, apprend une fonction qui relie les champs à grande échelle aux champs locaux — moins coûteuse mais limitée en interprétabilité, généralisation hors-distribution et cohérence physique. C’est dans cette seconde voie que s’inscrit le présent mémoire.

Problématique étudiée

Trois familles méthodologiques dominent l’état de l’art en descente d’échelle, et chacune présente un verrou bloquant dans un contexte africain.

Coût computationnel rédhibitoire de la descente d’échelle dynamique. La configuration CWA-WRF utilisée à Taïwan tourne sur 928 cœurs SPARC64 en parallèle [?] : à budget fixe, on ne peut donc descendre qu’un seul scénario d’un GCM à la fois, ce qui maintient les résolutions opérationnelles à 12–50 km dans les exercices CORDEX. Les applications de risque (assurance paramétrique, planification d’urgence) nécessitent en revanche plusieurs milliers de membres d’ensemble [?]. Pour un continent qui héberge moins de 1 % des capacités HPC mondiales [?], ce paradigme exclut de facto la production locale de projections fines.

Opacité et violations physiques des modèles d’apprentissage profond. González-Abad et al. [?] montrent que des CNN univariés appliqués à la température produisent des sorties physiquement impossibles ($T_{\min} > T_{\max}$), avec un taux de violation passant de 4 % à l’entraînement à 15–17 % en projection 2100 sous RCP8.5. Doury et al. [?]

qualifient explicitement leur émulateur de « *black-box regression model* » et montrent que 31 réentraînements identiques d'un même U-Net produisent des erreurs sur la climatologie future variant de 0,003 à 0,139 °C — facteur 46 dû exclusivement à la stochasticité interne.

Hypothèse de stationnarité des modèles génératifs résiduels.

La référence actuelle, CorrDiff [?], décompose la tâche en deux étapes (régression déterministe + diffusion EDM [?] du résidu) et atteint environ $60\times$ la vitesse d'une simulation WRF à l'inférence. Toutefois, les auteurs identifient eux-mêmes la difficulté centrale : un *significant distribution shift* entre les données d'entrée et la cible. L'efficacité-échantillon repose sur la faible variance du résidu, propriété qui n'est garantie que sous l'hypothèse de stationnarité de la distribution-cible — hypothèse que le changement climatique invalide directement.

Le problème central s'énonce donc ainsi : *comment causaliser le premier étage du paradigme à deux étages pour doter le downscaling probabiliste d'une robustesse de principe au changement de distribution, sans dégrader la stabilité ni le réalisme acquis ?*

Objectifs

Au regard de notre problématique, nous nous fixons comme objectif principal de proposer une architecture de descente d'échelle probabiliste qui intègre une structure causale apprise, afin de garantir par construction une dépendance fonctionnelle entre les variables atmosphériques d'entrée et la précipitation prédite. Plus spécifiquement, nous voulons :

- Concevoir un **module causal récurrent** (RCN) intégrant SCM dynamique, GRU [?] et pénalité d'acyclicité DAGMA [?] dans une seule cellule ;
- Inscrire ce module dans le paradigme à deux étages de CorrDiff [?], en remplaçant le premier étage de régression générique par un chemin obligatoirement médié par un graphe causal appris, sans modifier l'étage de diffusion EDM [?] ;

- Définir un **protocole expérimental** centré sur la calibration probabiliste, le réalisme des extrêmes et la robustesse inter-GCM, incluant un test d'intervention contrôlée original dans le contexte du downscaling profond.

Contribution

La contribution principale de ce mémoire réside dans la conception, l'implémentation et l'évaluation d'ORACLE, architecture causale générative à deux étages combinant les avantages des modèles résiduels (stabilité, calibration probabiliste, efficacité) avec une garantie structurelle de causalité architecturale. Quatre aspects clés la structurent :

- Une architecture *two-stage* où la causalité est placée dans la **topologie du graphe de calcul** plutôt que dans une régularisation de la perte — une régularisation peut être contournée par un réseau expressif, une dépendance architecturale est par construction indéfaisable.
- Le **réseau causal récurrent** (RCN) intégrant SCM dynamique, GRU et pénalité DAGMA dans une seule cellule.
- L'**interface inter-étages par concaténation de canaux** entre la moyenne causale, la baseline et le résiduel bruité, garantissant qu'aucune information ne contourne le chemin causal (propriété O3 vérifiée empiriquement, ratio mesuré 0,87).
- Un **protocole expérimental à six familles de métriques** incluant deux diagnostics causaux originaux : le ratio O3 (indispensabilité) et le test d'intervention Q_{int} (cohérence physique de la réponse à perturbation contrôlée).

Faute d'un jeu HR de référence sur le continent africain visé, nous éprouvons la méthode sur la Nouvelle-Zélande, traitée comme *bac à sable exigeant* : choisie par Rampal et al. [?] pour la diversité climatique compacte (subtropical, marin tempéré, semi-aride sous le vent, alpin sur moins de 270 000 km²) et un gradient orographique parmi les plus

extrêmes au monde, ce terrain sollicite simultanément les trois axes du trilemme. Sur ce cadre, ORACLE réduit le CRPS de 40 % en distribution et de 30 % en inter-GCM historique vis-à-vis d’une baseline non-causale strictement comparable, multiplie par 3,5 le ratio *spread-skill*, et passe le test interventionnel sur deux perturbations contrôlées là où la baseline échoue sur l’intervention thermique — la résistance architecturale à l’ablation causale dans ce cadre constitue une preuve forte d’*universalité architecturale* indépendante du climat d’entraînement. L’extension au contexte africain qui motive ce travail reste hypothétique au stade actuel, conditionnée à la disponibilité d’un jeu HR de référence sur la zone visée, et portée comme axe de perspectives.

Organisation du manuscrit

Le manuscrit est structuré en quatre chapitres et une conclusion :

Chapitre I — Fondements du downscaling climatique. Pose les bases : besoin de désagrégation, propriétés statistiques de la précipitation, approches classiques, passage au probabiliste et au génératif, formalisme causal de Pearl [?], et formule le trilemme stabilité / extrêmes / robustesse hors-distribution.

Chapitre II — État de l’art du downscaling par apprentissage profond. Parcourt systématiquement les approches déterministes (CNN, U-Net), adversariales [?], à vraisemblance, et de diffusion (DDPM [?], EDM, CorrDiff [?]). Un tableau comparatif identifie le *gap* qui motive notre contribution.

Chapitre III — Proposition d’Oracle. Formalise l’architecture : graphe hétérogène à six nœuds typés, encodeur intelligible, RCN sous contrainte DAGMA, décodeur graphe-à-grille, interface inter-étages et diffusion EDM résiduelle.

Chapitre IV — Matériels, méthodes, expérimentations et discussion. Couvre l’environnement, les données, la topologie effective, le protocole d’évaluation à six familles de métriques, les résultats et la discussion critique des limites.

Conclusion générale et perspectives. Synthétise les contributions, analyse les résultats et trace cinq axes de perspectives, dont le transfert vers le contexte africain qui constitue la motivation finale.

CHAPITRE

I

FONDEMENTS DU DOWNSCALING CLIMATIQUE

I.1	Introduction	??
I.2	Contexte climatique et besoin de désagrégation	??
I.3	Données climatiques et leurs propriétés	??
I.4	Approches classiques de downscaling	??
I.5	Approches probabilistes et génératives	??
I.6	Causalité et modèles structurels	??
I.7	Verrous scientifiques et trilemme	??
I.8	Synthèse	??

I.1. Introduction

Les communautés d'Afrique centrale et du Cameroun planifient leur agriculture, leur gestion de l'eau et leur urbanisme sur des horizons de plus en plus courts, sous l'effet d'événements climatiques extrêmes dont la fréquence augmente [?]. Ces décisions demandent des projections au kilomètre. Les modèles climatiques globaux (CMIP6 [?]) ne descendent qu'à la centaine de kilomètres. L'écart entre les deux est précisément ce

que le *downscaling* climatique cherche à combler ; ce mémoire en explore une variante générative et causalisée.

Ce chapitre établit les fondements nécessaires à la compréhension de notre contribution : contexte climatique et besoin de désagrégation (section ??), données mobilisées (section ??), méthodes classiques (section ??), approches probabilistes et génératives, notamment le paradigme à deux étages CORRDIF [?] (section ??), causalité structurelle pour ORACLE (section ??), verrous scientifiques (section ??) et synthèse (section ??).

I.2. Contexte climatique et besoin de désagrégation

I.2.1. Modèles climatiques globaux et régionaux

Un **modèle climatique global** (*General Circulation Model*, GCM) résout numériquement les équations de la dynamique atmosphérique et océanique pour produire des projections multi-décennales sous divers scénarios d'émissions. Le projet CMIP6 coordonne plus d'une centaine de tels modèles, dont ACCESS-CM2 (CSIRO, Australie) [?], à des résolutions de 100 à 250 km limitées par le coût numérique. À cette échelle, les processus locaux — convection profonde, effets orographiques, brises côtières, mésoéchelle — sont *paramétrés* plutôt qu'explicitement résolus, ce qui introduit des biais structurels marqués pour la précipitation.

Les **modèles climatiques régionaux** (RCM) résolvent les mêmes équations à 10–50 km sur un domaine restreint, emboîtés dans un GCM aux frontières : ce *downscaling dynamique* améliore le réalisme régional mais reste coûteux — à titre d'exemple, la configuration CWA-WRF utilisée à Taïwan mobilise 928 cœurs SPARC64 en parallèle [?], ce qui exclut les ensembles à milliers de membres requis pour les applications de risque [?]. Le passage de la grille GCM (~ 250 km) à la grille cible HR (~ 5 km) représente un facteur d'environ 50 par dimension, ce qui

dépasse les capacités RCM accessibles aux équipes africaines.

I.2.2. Cas de la précipitation

Ce constat motive le *downscaling statistique profond*, qui apprend, à partir d'un corpus historique de couples LR/HR, une fonction probabiliste $x_{\text{HR}} \sim p(\cdot | y_{\text{LR}})$ déployable à coût marginal une fois entraînée. Parmi les variables candidates, la **précipitation** occupe une place centrale : la plus liée aux risques perçus (sécheresse, inondations, sécurité alimentaire) et la plus exigeante statistiquement — forte intermittence, queue lourde, hétérogénéité spatiale [? ?]. Une méthode qui y réussit se transfère généralement aux variables plus régulières (température, pression). ORACLE est entraîné et évalué sur des précipitations quotidiennes du couple ACCESS-CM2 / Nouvelle-Zélande, terrain expérimental qui combine cible HR de qualité et baseline génératif de référence dans la littérature.

I.3. Données climatiques et leurs propriétés

I.3.1. Sources de données et formats

Trois catégories alimentent le downscaling :

- Les **observations directes** (stations météorologiques) — haute qualité ponctuelle, couverture spatiale très inégale, particulièrement lacunaire en Afrique.
- Les **réanalyses atmosphériques**, qui assimilent observations stations, radiosondages et satellites dans un modèle numérique : ERA5 [?] fournit des champs horaires à ~ 31 km depuis 1940 et constitue la référence historique gridée.
- Les **simulations climatiques** (GCM et RCM, sorties CMIP6) couvrent la période historique 1850–2014 et des projections futures sous scé-

narios SSP.

Les données sont distribuées au format **NetCDF** (conventions *Climate and Forecast*), auto-descriptif. La précipitation totale **pr** est exprimée en $\text{kg}/\text{m}^2/\text{s}$ et convertie en mm/jour . Dans notre travail, ACCESS-CM2 fournit le conditionnement basse résolution et un produit régional néo-zélandais la cible HR.

I.3.2. Propriétés statistiques de la précipitation

Trois propriétés statistiques rendent la précipitation quotidienne particulièrement exigeante. L'**intermittence** d'abord : selon les régions, 50 à 80 % des jours sont sans précipitation détectable, ce qui produit une masse de probabilité en zéro qu'aucune hypothèse de variable continue ne peut accommoder. L'**asymétrie à queue lourde** ensuite : conditionnée à un jour pluvieux, l'intensité suit approximativement une loi log-normale [?] ; toute méthode gaussienne sous-estime alors mécaniquement les extrêmes, c'est-à-dire les événements à fort enjeu. L'**hétérogénéité spatiale** enfin : le relief, la ligne de côte et l'occupation du sol structurent les champs de précipitation avec des gradients de plusieurs cm/km en zone de montagne, structure qui disparaît à basse résolution et que tout downscaling doit restituer. Notre pipeline expérimental (chap. IV) opère sur une grille LR 23×26 pixels (Nouvelle-Zélande) et une cible HR 172×179 .

Une lecture quantitative de ces propriétés sur le jeu d'entraînement utilisé au chapitre IV donne un ordre d'idée. Sur ACCESS-CM2 historique (1980–2009, Nouvelle-Zélande), la fraction de jours secs varie de 35% sur la côte ouest des Alpes du Sud à 65% dans les bassins de l'Est. Conditionnellement à un jour pluvieux, la moyenne quotidienne est de $\sim 6 \text{ mm}/\text{j}$ mais le quantile à 99 % atteint $\sim 45 \text{ mm}/\text{j}$ et le maximum observé sur la fenêtre dépasse $200 \text{ mm}/\text{j}$. Le ratio max/moyenne dépasse donc 30, alors qu'il vaut environ 3 pour la température : c'est cette différence d'amplitude relative qui rend la précipitation particulièrement réfractaire aux pertes quadratiques classiques.

I.3.3. Sources d'incertitude et nécessité d'un cadre probabiliste

Le downscaling agrège plusieurs sources d'incertitude qu'il convient de distinguer pour comprendre pourquoi le passage du déterministe au probabiliste n'est pas une simple question de raffinement statistique. L'**incertitude aléatoire** (*aleatoric*) est intrinsèque au caractère mal posé du problème : à une carte LR donnée correspond une famille de cartes HR plausibles, qu'aucune information supplémentaire dans les prédicteurs ne peut réduire. C'est cette composante que cherche à modéliser le résiduel stochastique d'ORACLE. L'**incertitude épistémique** (*epistemic*) reflète la connaissance limitée du modèle sur les données qu'il n'a pas vues ; elle se réduit avec plus de données ou de meilleurs modèles, et explose lors d'un déplacement de distribution. C'est précisément cette composante que la causalité structurelle vise à contenir. Un downscaler purement déterministe écrase ces deux composantes en une seule prédiction, d'où la dépendance aux extrêmes et la fragilité OOD.

I.4. Approches classiques de downscaling

Le downscaling comporte une dimension *spatiale* (grille grossière $\rightarrow$ grille fine) et une dimension *temporelle* (fréquence faible $\rightarrow$ fréquence élevée). Notre contribution couvre exclusivement la dimension spatiale ; la dimension temporelle est brièvement évoquée pour positionner le champ.

I.4.1. Désagrégation spatiale

Trois grandes approches coexistent. La **statistique classique** (régression linéaire multiple, *Bias Correction*, *Quantile Mapping* [?]) apprend une relation prédicteurs LR $\rightarrow$ prédictand HR : simple et interprétable, mais elle suppose la stationnarité, perd la cohérence spatiale (traitement pixel-par-pixel) et n'offre aucune incertitude calibrée.

L'**approche dynamique** exécute un RCM emboîté dans un GCM, résout les équations physiques à 10–50 km et offre une transférabilité de principe hors-distribution, mais hérite des biais du GCM forçant et mobilise des ressources de calcul considérables. L'**apprentissage supervisé déterministe** (CNN de super-résolution, U-Net, EDSR) traite le champ HR comme un tout cohérent mais reste mono-sortie : la prédiction se réduit à une moyenne conditionnelle qui lisse les extrêmes et sous-estime la variabilité, ce qui motive le glissement vers les approches probabilistes (section ??).

I.4.2. Désagrégation temporelle

La désagrégation temporelle (mensuelle $\rightarrow$ quotidienne ou horaire) pose des enjeux propres — autocorrélation, conservation des cumuls, extrêmes instantanés — traités par des approches historiques (cascades multiplicatives, chaînes de Markov) ou profondes (RNN, Transformers temporels) pour l'essentiel déterministes. Le présent travail couvre exclusivement la dimension spatiale ; l'extension temporelle est laissée aux travaux futurs.

I.5. Approches probabilistes et génératives

I.5.1. Du déterministe au probabiliste

L'insuffisance des méthodes déterministes est une conséquence du caractère multi-valué du problème : à une carte LR correspond une famille de cartes HR plausibles, dont une seule a été observée. La reformulation probabiliste vise la *distribution conditionnelle* $p(x_{\text{HR}} \mid y_{\text{LR}}, s_{\text{HR}})$, où s_{HR} regroupe d'éventuels champs auxiliaires HR (orographie, occupation du sol). On produit alors des ensembles d'échantillons, calcule des quantiles et évalue la couverture des extrêmes.

I.5.2. Modèles génératifs adversariaux

Les premiers génératifs profonds appliqués au downscaling ont mobilisé les **GAN**, dans leur variante conditionnelle prenant la carte LR comme conditionnement. Une référence néo-zélandaise est [?], qui combine un générateur résiduel et une perte adversariale pondérée. Trois limites empiriques sont documentées : **sub-dispersion** (variance prédite $<$ observée), **forte sensibilité** au coefficient adversarial λ_{adv} , et risque de **mode collapse**. Ces limites ont motivé l'exploration des modèles de diffusion.

I.5.3. Modèles de diffusion

Un modèle de diffusion définit un processus direct qui bruite progressivement le signal, puis apprend à l'inverser. Cette formulation, due aux DDPM de Ho et al. [?], a été généralisée par Karras et al. sous le nom d'EDM [?], qui introduit un préconditionnement systématique pour un entraînement stable et un échantillonnage de qualité en peu d'étapes. Pour le downscaling, la diffusion apporte trois avantages sur les GAN : entraînement stable (pas de déséquilibre adversarial), distribution de sortie expressive (modes multiples), meilleure calibration probabiliste. Le formalisme EDM et l'échantillonnage de Heun sont détaillés au chapitre suivant.

I.5.4. Le paradigme deux étages : CorrDiff

CORRDIFF [?], proposé par NVIDIA Research, découple explicitement ce qui est facile à apprendre et ce qui est intrinsèquement stochastique : un premier étage régresse la moyenne HR attendue, un second échantillonne par diffusion le résiduel par rapport à cette moyenne. Le champ HR s'écrit comme la somme d'une moyenne déterministe et d'un résiduel stochastique (formalisation au chapitre suivant).

L'intérêt est triple : (i) *stabilité* (régression déterministe convergente, diffusion sur résidus quasi-gaussiens) ; (ii) *calibration* (variance explici-




Figure 1 – *Paradigme deux étages de CORRDIFF (Mardani et al. [?], Fig. 1). **Haut** : la donnée météorologique LR sert d'abord à prédire la moyenne μ_{HR} par régression UNet; cette estimation est ensuite corrigée stochastiquement par un modèle de diffusion EDM produisant le résiduel HR. **Bas** : SDE directe (data $\rightarrow$ noise) et SDE inverse (noise $\rightarrow$ data) sur lesquelles repose l'échantillonnage du second étage.*

tement contrôlée par le second étage, non plus produit d'un équilibre adversarial); (iii) *efficacité* (diffusion limitée au résiduel de faible amplitude). Ce paradigme constitue le point de départ direct de notre contribution. ORACLE en reprend la structure mais introduit une contrainte causale au premier étage : μ_{HR} y est prédite à travers un graphe causal appris, ce qui en fait par construction une version *causalisée* de CORRDIFF.

Évaluation probabiliste. Les métriques déterministes classiques (RMSE, MAE, Pearson) ne suffisent pas à évaluer un modèle probabiliste, dont la valeur réside dans la distribution prédite. La littérature mobilise un panel élargi : *CRPS* (généralisation probabiliste de l'erreur absolue), *spread/skill* (calibration du second moment), *RAPSD* (fidélité du spectre spatial), *LHD* (distributions locales). La présentation formelle et l'application à ORACLE sont reportées au chapitre Matériels et méthodes.

I.6. Causalité et modèles structurels

I.6.1. Pourquoi la causalité en downscaling climatique

Les approches probabilistes précédentes restent *corrélatives* : elles capturent les co-occurrences observées sans garantir la qualité prédictive hors du régime d’entraînement — exactement la situation que crée le changement climatique. Trois apports théoriques distinguent un modèle causal d’un modèle purement corrélatif. La **robustesse hors-distribution** d’abord : un modèle articulé autour de relations causales identifiées (par exemple, l’influence de l’humidité basse couche sur la convection) reste en principe stable lorsque les régimes climatiques se déplacent. L’**interprétabilité physique** ensuite : la structure causale apprise peut être confrontée à la connaissance experte, ce que ne permet aucun modèle purement statistique. La **capacité d’intervention** enfin : un tel modèle répond à des questions « que se passerait-il si humidité +20 % » sans avoir besoin de chercher des analogues dans le passé.

I.6.2. Modèles causaux structurels et graphes acycliques dirigés

Le cadre formel de la causalité est celui des **modèles causaux structurels** (SCM) de Pearl [? ?]. Un SCM est un triplet (V, U, F) où V regroupe les variables observables, U des bruits exogènes indépendants et F des fonctions structurelles telles que

$$V_i = f_i(\text{Pa}(V_i), U_i), \quad (\text{I.1})$$

$\text{Pa}(V_i)$ étant l’ensemble des parents causaux de V_i . Le SCM s’exprime naturellement par un *Directed Acyclic Graph* (DAG) : nœuds = variables, arcs = liens parent $\rightarrow$ enfant. L’acyclicité garantit l’identifiabilité (ordre topologique d’évaluation) et fournit une description visuelle des dépen-

dances — par exemple, sur un mini-système atmosphérique, humidité, vent, température et orographie déterminent la précipitation locale, sans rétroaction explicite.

I.6.3. Intervention, identifiabilité et lien avec le downscaling

L'opérateur do de Pearl définit l'**intervention** : $\text{do}(X = x)$ fixe la valeur de X indépendamment de ses parents (suppression de ses flèches entrantes) et fournit une distribution $p(Y \mid \text{do}(X = x))$ en général distincte de la conditionnelle naïve $p(Y \mid X = x)$. C'est cette distinction qui sépare un modèle corrélatif d'un modèle structurellement causal. Un modèle *intervention-aware* a un effet calculable et prévisible sous intervention sur ses entrées. Cette propriété (objectif O3 d'ORACLE, chapitre dédié) est obtenue *au sens structurel* via la matrice A_{dag} apprise. Elle ne se confond pas avec une causalité *physique* (où les flèches coïncideraient avec les lois atmosphériques fait pour fait).

Un exemple concret rend la distinction tangible. En Nouvelle-Zélande, la corrélation observée entre température T et précipitation P peut être négative : les jours chauds y sont préférentiellement associés à des régimes anticycloniques secs. Un modèle corrélatif intègre cette association et prédit moins de pluie à mesure que T augmente. Or Clausius-Clapeyron prédit, toutes choses égales par ailleurs, $\sim +7\%$ de capacité hygrométrique par degré, donc plus d'intensité conditionnelle. Un modèle causal opérant via $\text{do}(T = T_0 + 3 \text{ K})$ doit prédire un signe positif — précisément ce que mesure le test Q_{int} rapporté au chapitre IV.

Apprendre la structure d'un DAG depuis les données est un problème combinatoire dur. Bello, Aragam et Ravikumar [?] ont proposé *DAGMA*, une caractérisation continue et différentiable de l'acyclicité (déterminant logarithmique d'une M-matrice), intégrable directement dans l'entraînement d'un réseau profond. ORACLE mobilise DAGMA pour insérer la causalité structurelle dans un paradigme génératif à deux étages style CORRDIFF, en prédisant μ_{HR} comme produit cau-

sal du DAG appris ; détail formel et examen comparatif sont reportés au chapitre dédié.

Cette posture appelle une précaution de vocabulaire qui structurera tout le manuscrit. Nous parlerons d'*architecture structurellement causale* quand l'information passe nécessairement par A_{dag} pour produire la sortie (notion vérifiable empiriquement par ablation), et de *causalité identifiée* pour des arêtes dont l'orientation et la magnitude reflètent fidèlement les mécanismes physiques. ORACLE vise et atteint la première propriété ; la seconde dépasse ce qu'un apprentissage observationnel non interventionnel peut garantir [? ?]. Les arêtes du DAG appris sont à lire comme des *contraintes fonctionnelles* : leur valeur n'est pas l'effet causal physique d'une variable sur une autre, mais une pondération apprise qui satisfait l'acyclicité tout en optimisant la prédiction.

I.7. Verrous scientifiques et trilemme

Les fondements précédents font émerger trois verrous structurants du downscaling génératif. Avant de les articuler dans un *trilemme*, examinons-les un par un.

I.7.1. Verrou 1 : stabilité d'entraînement

Les modèles adversariaux sont très sensibles au coefficient λ_{adv} et au déséquilibre générateur-discriminateur, difficiles à régler de manière transférable d'une région à l'autre [?]. Les modèles de diffusion, plus stables en principe, exigent néanmoins une calibration soignée du pré-conditionnement et du schéma de bruit — c'est précisément ce qu'apporte EDM [?]. Ce verrou conditionne reproductibilité et déployabilité multi-cas.

I.7.2. Verrou 2 : réalisme des extrêmes et sub-dispersion

Le verrou le plus critique pour nos applications est le **réalisme des extrêmes**, via le phénomène de *sub-dispersion* : variance prédite conditionnellement à l'entrée inférieure à la variance observée. Mesurée par le rapport $\sigma_{\text{pred}}/\text{RMSE}$, elle vaut ≈ 1 pour un modèle bien calibré, mais des valeurs autour de 0,3 sont rapportées en downscaling génératif [? ? ?], soit une sous-estimation d'un facteur trois de la variabilité fine, donc des extrêmes — précisément les événements à plus forte valeur ajoutée. Sa mesure sur ORACLE et ses ablations causales sera l'un des objets centraux de l'évaluation.

I.7.3. Verrou 3 : robustesse hors-distribution

Sous changement climatique, la statistique conjointe des variables atmosphériques évolue : un modèle historique doit conserver sa qualité hors des analogues observés. Les modèles purement corrélatifs y sont vulnérables (associations contingentes au régime d'entraînement), tandis que la causalité structurelle (section ??) apparaît comme une réponse de principe : un modèle organisé autour de relations causales doit, en théorie, mieux transférer en **OOD**.

I.7.4. Trilemme et positionnement d'Oracle

La littérature récente expose un schéma récurrent : les approches qui dominent un de ces axes échouent presque systématiquement sur au moins un autre. Les GAN les plus expressifs sont aussi les plus instables ; les modèles de diffusion stables restent corrélatifs et sans garantie hors-distribution ; les RCM dynamiques robustes paient cette robustesse en coût de calcul et transférabilité. Cette tension, identifiée sous diverses formes chez plusieurs auteurs [? ? ?], se condense en un *trilemme* entre stabilité d'entraînement, réalisme des extrêmes et robustesse hors-distribution (figure ??). Nous le présentons *tel qu'il ressort de la littérature*, sans prétendre à une formalisation originale.




Figure 2 – *Trilemme du downscaling génératif. Les trois sommets représentent les verrous identifiés ; les points positionnent qualitativement les principales approches. Plus un point est proche d'un sommet, mieux l'approche traite ce verrou. Constat agrégé à partir de [? ? ?].*

ORACLE se positionne dans ce trilemme en s'inscrivant dans le paradigme à deux étages de CORRDIFF (stabilité, verrou 1), en y introduisant une contrainte structurellement causale au premier étage (robustesse OOD, verrou 3), et en mobilisant la diffusion EDM au second étage pour la calibration probabiliste (réalisme des extrêmes, verrou 2). La figure ?? en propose une vue d'ensemble ; détails architecturaux et formalisation des objectifs sont déferés au chapitre dédié.

I.8. Synthèse

Trois acquis se dégagent de ce chapitre. Le besoin de désagrégation est concret et localisé : la résolution des GCM ne rencontre pas celle des usages locaux, particulièrement en contexte africain où les RCM dynamiques restent hors de portée, et la précipitation y concentre à la fois la pertinence opérationnelle et la difficulté statistique. Le paradigme méthodologique a glissé du déterministe vers le probabiliste, puis vers le génératif, et a récemment trouvé dans le paradigme deux-étages de CORRDIFF — moyenne déterministe plus résiduel par diffusion — une forme aboutie qui sert ici de point de départ. Trois verrous, enfin, struc-




Figure 3 — Cartouche conceptuel d'ORACLE : version causalisée du paradigme deux étages de CORRDIFF. L'étage 1 estime μ_{HR} via un graphe causal appris ; l'étage 2 échantillonne par diffusion le résiduel δ .

turent encore le champ : stabilité d'entraînement, réalisme des extrêmes (et sub-dispersion qui en découle), robustesse hors-distribution. C'est dans le trilemme qu'ils dessinent qu'ORACLE s'inscrit, en greffant une structure causale sur la décomposition à deux étages.

Le chapitre suivant parcourt l'état de l'art : les travaux antérieurs sur le downscaling probabiliste à deux étages (CORRDIFF, cGAN de Rampal et al.) et les approches qui éclairent l'intégration de la causalité au cadre génératif.

CHAPITRE

II

ÉTAT DE L'ART DU DOWNSCALING PAR APPRENTISSAGE PROFOND

II.1	Introduction	??
II.2	Approches déterministes	??
II.3	Approches probabilistes adversariales	??
II.4	Approches à vraisemblance explicite	??
II.5	Modèles de diffusion	??
II.6	Le paradigme à deux étages : CorrDiff	??
II.7	Fonctions de perte et contraintes physiques	??
II.8	Cadres d'évaluation et foundation models	??
II.9	Synthèse, tableau comparatif et gap scientifique	??

II.1. Introduction

Le chapitre précédent a identifié un trilemme pour le downscaling climatique génératif (section I.7) : stabilité d'entraînement, réalisme des extrêmes et robustesse sous changement de distribution apparaissent inconciliables dans les approches existantes. Le présent chapitre confronte cette analyse au paysage effectif de la littérature, des CNN déterministes

aux modèles de diffusion à deux étages. Nous abordons successivement les approches déterministes (section ??), adversariales (section ??), à vraisemblance explicite (section ??) et de diffusion (section ??), avant de détailler le paradigme CORRDIFF (section ??) dont notre proposition est la causalisation. Pertes (section ??) et cadres d'évaluation (section ??) complètent la revue ; la synthèse (section ??) identifie le gap qui motive notre contribution.




Figure 4 – *Frise chronologique des principales contributions du downscaling climatique profond. Le glissement progressif du paradigme déterministe (gris) vers le paradigme génératif (rouge) puis vers le two-stage causal (bleu) est visible à partir de 2020. ORACLE se positionne comme aboutissement causal du paradigme à deux étages.*

La figure ?? situe chronologiquement les contributions examinées : glissement déterministe → génératif à partir de 2020, accélération après 2022 sous l'effet conjoint des modèles de diffusion et de la maturation des GCM haute résolution.

II.2. Approches déterministes

II.2.1. Régression statistique classique

Les approches statistiques de première génération (régression linéaire, BC, QM) présentées au chapitre I (section ??) souffrent de trois limites structurelles : hypothèse de stationnarité difficile à défendre sous changement climatique, absence de cohérence spatiale (traitement pixel par pixel), absence de calibration probabiliste. C'est ce qui motive le passage aux méthodes d'apprentissage non-linéaires et structurées spatialement.

II.2.2. Réseaux convolutifs et super-résolution

L'application des CNN au downscaling s'inspire des architectures de super-résolution d'image. **DeepSD** [?] est l'une des premières architectures CNN dédiées au downscaling de la précipitation, par empilement de convolutions à champ réceptif croissant. Le **U-Net** [?] a connu une adoption massive, particulièrement sous sa forme conditionnée par des champs de surface (élévation). Ces approches partagent une limite décisive : produisant une unique sortie HR par entrée, elles approximent la moyenne conditionnelle de la distribution cible. Pour la précipitation à queue lourde, cette moyenne est biaisée à la baisse aux valeurs élevées, d'où le lissage des extrêmes documenté dans la littérature.

La période 2021–2023 a vu émerger des architectures plus sophistiquées qui partagent la même limite probabiliste : opérateurs neuronaux de Fourier (FNO) prometteurs en prévision globale mais expérimentaux en downscaling régional, et Transformers de vision (SwinIR, PrecipFormer) exploitant l'attention. Toutes conservent la limite fondamentale du déterminisme : pas de distribution conditionnelle calibrée, donc le verrou « réalisme des extrêmes » reste non adressé.

II.3. Approches probabilistes adversariales

II.3.1. Réseaux antagonistes génératifs conditionnels

Le glissement vers le probabiliste a d'abord été opéré par les **réseaux antagonistes génératifs** (GAN) [?] et leur variante conditionnelle (cGAN) [?]. Un générateur G transforme un bruit $z \sim \mathcal{N}(0, I)$ et un conditionnement y_{LR} en échantillon plausible $\hat{x}_{\text{HR}} = G(y_{\text{LR}}, z)$; un discriminateur D apprend à distinguer vrais et faux. L'entraînement min-max alterne ces objectifs opposés. Appliqué au downscaling, le cGAN promet un ensemble d'échantillons HR plausibles permettant en principe d'estimer la variabilité prédictive et la distribution des extrêmes.

II.3.2. cGAN résiduel pour le downscaling climatique

Une architecture représentative est le **Residual cGAN** de Rampal et al. [?], qui combine un U-Net déterministe pré-entraîné et un cGAN sur le résidu : le générateur reçoit la prédiction U-Net, l'élévation HR, le champ GCM et un bruit, et produit une carte résiduelle additionnée à la prédiction déterministe. L'application à la Nouvelle-Zélande (CMIP6 ACCESS-CM2) combine trois termes de coût : MSE, perte adversariale pondérée par λ_{adv} , et contrainte d'intensité pénalisant la surestimation des extrêmes.

D'autres travaux apparentés incluent Harris et al. [?] (désagrégation de précipitations sur domaine européen) et Price et Rasp (prévision d'extrêmes à court terme via GAN).

II.3.3. Limites empiriques des cGAN appliqués au downscaling

Quatre limites empiriques reviennent dans la littérature adversariale. La **forte sensibilité à λ_{adv}** d'abord : la performance sur les extrêmes décrit une courbe en cloche — coefficient trop faible et la MSE lisse, trop élevé et les extrêmes explosent —, avec un optimum étroit qui ne transfère pas d'une région à l'autre. La **sub-dispersion** ensuite : Rampal et al. [?] et Mardani et al. [?] rapportent $\sigma_{\text{pred}}/\text{RMSE} < 0,5$, signe d'ensembles systématiquement trop confiants. Le **mode collapse**, intrinsèque au cadre min-max, reste latent même quand il n'apparaît pas explicitement. Enfin, la **validité restreinte du cadre d'évaluation** : la plupart des tests utilisent des couples synthétiques RCM-LR/RCM-HR (cadre « parfait »), et la transférabilité aux conditions opérationnelles GCM brut n'est pas garantie.

II.4. Approches à vraisemblance explicite

Les **auto-encodeurs variationnels** (VAE) [?] apprennent une représentation latente probabiliste en maximisant la borne inférieure de la log-vraisemblance (ELBO). Appliqués au downscaling, ils produisent des sorties probabilistes mais souffrent d'un excès de lissage lié à l'ELBO. Les **flots de normalisation** appliquent une séquence de transformations inversibles différentiables à un bruit gaussien et autorisent l'évaluation exacte de la vraisemblance; leur expressivité reste cependant bornée par la contrainte d'inversibilité. Ces deux familles n'atteignent pas le niveau des GAN ou de la diffusion en downscaling climatique : leur intérêt méthodologique ne compense pas une expressivité insuffisante face aux extrêmes à queue lourde.

II.5. Modèles de diffusion

II.5.1. Denoising Diffusion Probabilistic Models

Les **Denoising Diffusion Probabilistic Models** (DDPM) [?] définissent un processus direct qui bruite progressivement le signal selon une chaîne de Markov gaussienne $q(x_t | x_{t-1}) = \mathcal{N}(x_t; \sqrt{1 - \beta_t} x_{t-1}, \beta_t I)$, puis apprennent à inverser ce processus. L'objectif simplifié se réduit à la prédiction du bruit, $\mathcal{L}_{\text{simple}} = \mathbb{E}[\|\epsilon - \epsilon_\theta(x_t, t)\|^2]$, où ϵ_θ est typiquement un U-Net. Face aux GAN, DDPM offre trois avantages pour le downscaling : entraînement stable sans déséquilibre adversarial, expressivité multimodale sans collapse, et calibration probabiliste intrinsèque.

II.5.2. Formalisme EDM de Karras et al.

Le formalisme EDM [?] reformule la diffusion dans un cadre théorique général. Sa contribution principale est un **préconditionnement systématique** de l'entrée et de la sortie via quatre fonctions $c_{\text{in}}, c_{\text{out}}, c_{\text{noise}}, c_{\text{skip}}$ dépendant de σ , qui unifie DDPM/score matching/VP/VE et stabilise

l'entraînement. Le sampler de Heun à pas variable atteint une qualité comparable à DDPM avec moitié moins d'étapes. La calibration de σ_{data} (écart-type des données normalisées) est cruciale.

II.5.3. Premières applications au climat : SR3, ResShift, ResDiff

SR3 fut la première application notable de la diffusion conditionnelle à la super-résolution d'image, avant son essaimage vers le climat. **ResShift** accélère la diffusion par déplacement résiduel, avec une proximité manifeste vers le paradigme à deux étages détaillé en section ???. Plusieurs évolutions récentes pourraient à terme remplacer l'étage de diffusion : **flow matching** [?], consistency models, diffusion latente. La diffusion EDM [?] demeure notre choix de référence pour trois raisons : maturité empirique en climat (retenue par CorrDiff [?] et GenCast [?]), stabilité d'entraînement (préconditionnement systématique $c_{\text{in}}, c_{\text{out}}, c_{\text{skip}}, c_{\text{noise}}$), et efficacité d'échantillonnage (solveur de Heun à 20–50 pas contre ~ 1000 pour DDPM).

II.6. Le paradigme à deux étages : CorrDiff

II.6.1. Idée fondatrice

Le modèle CORRDIF (Corrective Diffusion) de Mardani et al. [?] (NVIDIA Research) propose un paradigme à deux étages dont la décomposition formelle est :

$$x_{\text{HR}} = \text{baseline}_{\text{LR}\uparrow} + \mu_{\text{HR}}(y_{\text{LR}}, s_{\text{HR}}) + \delta(\cdot), \quad (\text{II.1})$$

où $\text{baseline}_{\text{LR}\uparrow}$ désigne un sur-échantillonnage bilinéaire, μ_{HR} la moyenne HR apprise par régression déterministe, et δ un résiduel stochastique échantillonné par diffusion conditionnée sur μ_{HR} et y_{LR} . L'application

visée est le downscaling kilométrique de sorties GCM avec un facteur de réduction de 25 à 50, le terrain initial étant Taïwan.

II.6.2. Architecture détaillée

Le premier étage est un U-Net classique entraîné par MSE entre μ_{HR} et la cible HR. Le second est un U-Net de diffusion EDM entraîné à prédire $\delta = x_{\text{HR}} - (\text{baseline}_{\text{LR}\uparrow} + \mu_{\text{HR}})$ conditionnellement à μ_{HR} et y_{LR} , avec échantillonnage de Heun à 20-50 pas.




Figure 5 – Architecture UNet hiérarchique de CORRDIFF (Mardani et al. [?], Fig. S1), partagée par les deux étages. Encodeur-décodeur à quatre niveaux ($448^2 \rightarrow 28^2$), blocs résiduels, attention auto-référentielle dans les niveaux profonds, embedding temporel t pour le second étage. Le premier étage de régression réutilise la même topologie sans embedding temporel.

II.6.3. Forces du paradigme à deux étages

Ce paradigme accumule trois forces structurelles. La **stabilité d'entraînement** d'abord : la régression déterministe converge sans difficulté et la diffusion du second étage opère sur des résidus dont la distribution se rapproche d'une gaussienne. La **calibration probabiliste explicite**

ensuite : la variance est contrôlée par le second étage, sans dépendre d'un équilibre adversarial. L'**efficacité computationnelle** enfin : l'échantillonnage par diffusion ne porte que sur le résiduel, dont l'amplitude est faible.

II.6.4. Limites identifiées de CorrDiff

L'examen critique fait apparaître deux limites principales. La **persistance de la sub-dispersion** : malgré la calibration explicite du second étage, CorrDiff reste sub-dispersif ($\sigma_{\text{pred}}/\text{RMSE}$ entre 0,3 et 0,5 selon les configurations), moins prononcée que les cGAN mais significative. L'**absence de structure causale explicite** : le premier étage est un U-Net générique apprenant $\mu_{\text{HR}}(y_{\text{LR}}, s_{\text{HR}})$ sans contrainte sur la nature des dépendances ; rien ne distingue associations causales (humidité de basse couche $\rightarrow$ précipitation convective) et corrélations contingentes au régime d'entraînement. CorrDiff est donc vulnérable au changement de distribution, sans garantie d'intervention.

II.6.5. Pourquoi CorrDiff plutôt que SR3 ?

Le baseline non-causal d'ORACLE aurait pu provenir d'autres travaux de diffusion résiduelle. ResDiff et CorrDiff désignent la même filiation chez Mardani et al. ; la vraie alternative restait SR3. Trois raisons font pencher la balance vers CorrDiff. La **décomposition moyenne + résiduel** (équation ??) épouse la structure même de la statistique climatique : μ_{HR} encode le forçage-réponse, δ la variabilité fine. SR3 ne propose pas cette séparation, et c'est elle qui ouvre la voie à la causalisation. Le **ciblage explicite du downscaling kilométrique** ensuite : CorrDiff intègre intermittence, queue lourde et hétérogénéité de la précipitation, là où SR3 reste une méthode générique de super-résolution d'image. La **modularité architecturale** enfin : l'étage 1 se substitue sans toucher à l'étage 2 — précisément ce qui nous permet de remplacer le U-Net du premier étage par un module à graphe causal sans perturber

la diffusion EDM.

II.6.6. Reformulation du paradigme deux étages dans le langage probabiliste

Une lecture probabiliste éclaire pourquoi la décomposition $x_{\text{HR}} = \text{baseline} + \mu_{\text{HR}} + \delta$ est plus qu'une commodité d'implémentation. En notant $\mu^*(y_{\text{LR}}) = \mathbb{E}[x_{\text{HR}} \mid y_{\text{LR}}, s_{\text{HR}}]$ la moyenne conditionnelle théorique et $\delta^* = x_{\text{HR}} - \mu^*(y_{\text{LR}})$ son résiduel, on a par construction $\mathbb{E}[\delta^* \mid y_{\text{LR}}, s_{\text{HR}}] = 0$. La distribution de δ^* est typiquement plus proche d'une gaussienne que celle de x_{HR} , ce qui rend l'apprentissage de diffusion mieux conditionné ; et la variance résiduelle sert d'estimateur naturel de σ_{data} , hyperparamètre central d'EDM dont la calibration se fait empiriquement en fin de Stage 1.

II.7. Fonctions de perte et contraintes physiques

II.7.1. Pertes adaptées à la précipitation

Au-delà de la MSE, la littérature a développé plusieurs pertes adaptées à la précipitation. Les **pertes spectrales** (FACL, *Fourier Amplitude Coherence Loss*) pénalisent l'écart entre spectres de Fourier prédit et cible, préservant le contenu fréquentiel fin et corrigeant partiellement le lissage MSE. La **régularisation Wasserstein** (héritée des WGAN) remplace la divergence Jensen-Shannon implicite par une distance Wasserstein-1, plus stable et mieux comportée aux extrêmes. Les **pondérations spécifiques aux extrêmes** (*focal loss*, MSE pondérée par percentiles, top- k) accroissent le poids des pixels à forte intensité, concentrant l'apprentissage sur les cas extrêmes.

Une remarque méthodologique mérite d'être soulignée : la combinaison de ces pertes n'est pas additive sans conséquence. Un mélange li-

néaire avec coefficients fixes ne fonctionne en pratique qu'au prix d'une recherche d'hyperparamètres elle-même fragile au changement de domaine. Plusieurs travaux récents proposent une pondération adaptative au cours de l'entraînement (*loss weighting* en fonction de la phase d'optimisation, ou *curriculum learning* progressif des seuils d'extrêmes). ORACLE adopte une approche conservatrice : la perte du Stage 1 combine MSE et reconstruction sans pondération spectrale ni Wasserstein, ces dernières ayant été évaluées en exploration mais n'ayant pas montré de gain reproductible en présence des autres briques (contrainte DAGMA, pénalité L_1). Cette simplicité est défendue au chapitre suivant comme un choix de robustesse face à la fragilité empirique des pondérations multi-pertes.

II.7.2. Contraintes physiques et explicabilité

Des **contraintes physiques dures** (conservation de masse, monotonie $T_{\min} \leq T \leq T_{\max}$, positivité de la précipitation) sont imposées par construction architecturale ou projection en sortie ; elles améliorent la cohérence multivariée mais ne résolvent pas les verrous probabilistes. L'**explicabilité** (XAI) appliquée au downscaling (Grad-CAM, Integrated Gradients) révèle a posteriori les zones d'entrée influentes. Notre proposition emprunte une voie complémentaire : organiser l'architecture autour d'une structure causale apprise, apportant par construction cohérence et interprétabilité.

Le tableau ?? récapitule ces familles.

II.8. Cadres d'évaluation et foundation models

II.8.1. Benchmarks standardisés

Trois benchmarks récents tentent de réduire la fragmentation des protocoles d'évaluation. **WeatherBench 2** étend le benchmark initial

Tableau II – *Principales fonctions de perte et contraintes utilisées en downscaling climatique profond.*

Famille	Exemples	Cas d'usage principal
Pertes spectrales	FACL	Contenu fréquentiel fin
Adversariales régularisées	Wasserstein, WGAN-GP	Stabilisation entraînement adversarial
Pondération extrêmes	Focal, top- k , MSE pondérée	Pixels à forte intensité
Contraintes dures	Conservation, monotonie, positivité	Cohérence physique multivariée
Explicabilité a posteriori	Grad-CAM, Integrated Gradients	Diagnostic des dépendances
Structure causale	DAG appris, intervention	Robustesse OOD et auditabilité (notre voie)

à la prévision météorologique pilotée par les données (RMSE, biais, ACC sur ERA5). **ClimateBench** se concentre sur la réponse à des scénarios d'émissions et l'émulation climatique. **ChaosBench** cible la prévision à grande échelle et la stabilité à long horizon. Un constat demeure : **aucun benchmark public ne couvre le downscaling probabiliste à haute résolution**, et sa construction reste un chantier ouvert.

L'absence de benchmark public dédié explique en partie l'hétérogénéité des protocoles rencontrés dans la littérature : choix de domaines (Taïwan pour CorrDiff, Nouvelle-Zélande pour Rampal, États-Unis ou Europe pour les cGAN antérieurs), formulation des métriques d'extrêmes (F1 pooled vs ETCCDI per-pixel), périodes de test plus ou moins longues, et taille d'ensemble allant de $K = 8$ à $K = 192$. Notre choix expérimental (Nouvelle-Zélande, ACCESS-CM2 historique, ensemble $K = 12$ inter-GCM) reprend largement le protocole Rampal et al. [?] afin d'être directement comparable à cette référence, tout en évaluant les indices ETCCDI préconisés par [?] pour garantir l'interopérabilité avec les diagnostics climatologiques standard.

II.8.2. Foundation models climat

La période 2023-2024 a vu émerger des *foundation models* climat. **ClimaX** [?] (Microsoft) est un Transformer pré-entraîné sur CMIP6, capable de prévision, projection et downscaling après fine-tuning. **Gra-**

phCast [?] et **GenCast** [?] (Google DeepMind) sont des graph neural networks entraînés sur ERA5 ayant dépassé plusieurs modèles physiques opérationnels. Le positionnement de notre travail est complémentaire : ORACLE cible le downscaling régional probabiliste, non le multi-tâche global ; la structure causale proposée pourrait à terme s'intégrer à une architecture de plus grande échelle.

II.9. Synthèse, tableau comparatif et gap scientifique

II.9.1. Tableau comparatif modèle × verrou

Le tableau ?? récapitule les approches revues selon les trois axes du trilemme (stabilité, extrêmes, robustesse OOD), complétés par deux axes propres à notre contribution (structure causale explicite, caractère génératif probabiliste).

Tableau III – *Confrontation des principales approches du downscaling profond aux verrous du trilemme. Légende : ✓ = bien traité, △ = partiellement traité, × = non traité. La colonne **Causal** renvoie à l'indispensabilité structurelle (propriété (O3)) qui sera formalisée au chapitre suivant.*

Approche	Année	Stabilité	Extrêmes	OOD	Causal	Génératif
DeepSD / U-Net	2017	✓	×	×	×	×
EDSR / SRCNN	2017	✓	×	×	×	×
FNO / SFNO	2021-23	✓	△	△	×	×
SwinIR / PrecipFormer	2021-23	✓	△	×	×	×
cGAN (Harris et al.)	2022	△	△	×	×	✓
Residual cGAN (Rampal)	2024	△	△	×	×	✓
VAE downscaling	2022	✓	×	×	×	✓
Normalizing Flow	2020	✓	△	×	×	✓
DDPM / EDM brut	2020-22	✓	✓	△	×	✓
SR3 / ResShift	2022-23	✓	△	△	×	✓
CorrDiff (Mardani)	2023	✓	△	△	×	✓
ClimaX (foundation)	2023	✓	△	△	×	△
Oracle (proposé)	2026	✓	△	△	✓	✓

Note sur ORACLE. La colonne « Causal » est attribuée à ORACLE au titre de la propriété (O3) — architecturalement, la sortie ne peut pas

contourner la matrice A_{dag} apprise. Les triangles partiels en « Extrêmes » et « OOD » assument honnêtement les limites mesurées : RX1day mieux placé que la baseline mais F1@p99 régresse ; gain CRPS en inter-GCM historique mais pas de test sur scénario futur. Le détail est discuté au Chapitre IV.

II.9.2. Gap scientifique

Le tableau ?? fait apparaître un constat structurant : **aucune des approches revues ne résout simultanément les trois axes du trilemme**. Les plus stables (U-Net, DDPM, EDM brut) ne garantissent pas la robustesse hors-distribution. Les plus probabilistes (CorrDiff, cGAN résiduel) restent sub-dispersives sur les extrêmes. Les plus expressives (cGAN) butent sur l'instabilité d'entraînement. Et aucune n'intègre par construction de structure causale explicite : c'est précisément cette lacune qui motive notre contribution.

Le gap scientifique se formule donc comme **la non-résolution du trilemme par les approches existantes**. Le paradigme deux-étages de CORRDIFF couvre le mieux le triplet stabilité + extrêmes + probabiliste, mais sa robustesse hors-distribution n'est pas adressée par construction. Comblé ce gap suppose de **causaliser le premier étage** : remplacer le U-Net générique qui estime μ_{HR} par un module structurellement causal qui contraint cette estimation à passer par un graphe de dépendances appris.

II.9.3. Positionnement d'Oracle dans le paysage

La figure ?? résume la position de ORACLE. Le premier étage causalise CORRDIFF [?], en s'appuyant sur la caractérisation différentiable de l'acyclicité de Bello et al. [?] et sur le formalisme SCM de Pearl [?] ; le second étage conserve la diffusion EDM [?]. L'architecture détaillée fait l'objet du chapitre suivant.




Figure 6 – Cartouche conceptuel revisité du modèle ORACLE avec ancrage bibliographique. Le premier étage causalise CORRDIFF [?] en y intégrant un graphe causal appris par contrainte DAGMA [?] et le formalisme SCM de Pearl [?]; le second étage conserve la diffusion EDM [?].

CHAPITRE

III

PROPOSITION : ORACLE, ARCHITECTURE CAUSALE À DEUX ÉTAGES

III.1	Introduction	??
III.2	Vue d'ensemble et différence avec CORRDIFF	??
III.3	Graphe atmosphérique hétérogène	??
III.4	Encodeur intelligible et réseau causal récurrent	??
III.5	Apprentissage du DAG par DAGMA	??
III.6	Décodeur graphe-à-grille	??
III.7	Interface inter-étages, propriété (O3) et diffusion EDM	??
III.8	Pertes et entraînement	??
III.9	Synthèse et traçabilité	??

III.1. Introduction

Le paradigme à deux étages de CORRDIFF [?] est l'antécédent le plus crédible pour le trilemme stabilité / extrêmes / robustesse, mais sa robustesse hors-distribution n'est pas adressée par construction. ORACLE en est une *causalisation* portant exclusivement sur le premier étage : le réseau de régression générique est remplacé par un module structurel-

lement causal (graphe atmosphérique hétérogène, encodeur intelligible, RCN sous contrainte d’acyclicité). Le second étage conserve la diffusion EDM [?], avec un conditionnement par concaténation de canaux qui propage architecturalement le chemin causal vers la prédiction stochastique du résiduel.

III.1.1. Notations et objectifs

Sauf mention contraire, B désigne la taille du lot, T la longueur de séquence ($T = 8$), N le nombre de nœuds, $d = 128$ la dimension latente et $(H_{\text{HR}}, W_{\text{HR}}) = (172, 179)$ la résolution cible. Les symboles centraux sont récapitulés dans le tableau ??.

Tableau IV – Notations principales.

Symbole	Description
$y_{\text{LR}}, x_{\text{HR}}$	Champs LR conditionnant (GCM) et HR cible (précipitation)
baseline, μ_{HR}, δ	Sur-échantillonnage bilinéaire, moyenne causale Stage 1, résiduel stochastique Stage 2
A_{dag}	Matrice d’adjacence $N \times N$ du DAG appris
H_t, H_T	État caché du graphe au pas t , état final consommé par le décodeur
$\sigma, \sigma_{\text{data}}$	Niveau de bruit EDM, écart-type empirique des résiduels
$\mathcal{D}_{\theta}$	Opérateur de débruitage EDM préconditionné

Six objectifs guident la conception :

- **O1** stabilité d’entraînement (sans équilibre adversarial fragile) ;
- **O2** réalisme des extrêmes (CRPS et centiles élevés) ;
- **O3** causalité architecturale — dépendance non-triviale de μ_{HR} à A_{dag} , signature contrastive vis-à-vis de CORRDIFF ;
- **O4** robustesse inter-GCM ;
- **O5** efficacité computationnelle sur budget CPU (48 cœurs, 128 Go) ;
- **O6** interprétabilité du DAG appris.

Décomposition deux étages et diffusion EDM adressent O1–O2 ; RCN et contrainte DAGMA adressent O3 et O6 ; la structure causale adresse

O4; le pré-calcul et la diffusion sur résidu de faible amplitude adressent O5.

III.2. Vue d'ensemble et différence avec Corr-Diff

III.2.1. Architecture en quatre blocs fonctionnels

À haut niveau, ORACLE est composé de quatre blocs (figure ??). Le *générateur de baseline* sur-échantillonne y_{LR} par interpolation bilinéaire. Le *module causal résiduel* (CRM) produit μ_{HR} via le chemin causal complet — graphe hétérogène, encodeur intelligible, RCN, décodeur graphe-à-grille. Le *décodeur de diffusion EDM* échantillonne le résiduel δ conditionné sur μ_{HR} et la baseline. La *recombinaison finale* agrège selon l'équation centrale du paradigme à deux étages :

$$x_{\text{HR}} = \text{baseline}_{\text{LR}\uparrow} + \mu_{\text{HR}}(y_{\text{LR}}; A_{\text{dag}}) + \delta(\sigma; \mu_{\text{HR}}, \text{baseline}). \quad (\text{III.1})$$




Figure 7 – Vue d'ensemble simplifiée du modèle ORACLE en quatre blocs articulés autour de l'équation (??). La causalité architecturale est concentrée dans le module causal résiduel (CRM, bloc 2); la stochasticité réside dans le bloc EDM (3).

La décomposition sépare la composante déterministe causale (μ_{HR} , forçage-réponse via le DAG) de la composante stochastique non-causale

(δ , variabilité fine résiduelle modélisée par EDM). L'écart avec CORRDIF est entièrement concentré dans la production de μ_{HR} : CORRDIF y emploie un U-Net générique entraîné par MSE sur $x_{\text{HR}} - \text{baseline}$, là où ORACLE substitue un module causal dont la sortie transite obligatoirement par A_{dag} . Stage 2, pertes EDM, sampler de Heun et préconditionnement sont hérités tels quels : toute amélioration mesurée sera attribuable au remplacement du module μ_{HR} , pas à un changement collatéral.

III.3. Graphe atmosphérique hétérogène

Note préliminaire sur la cardinalité du graphe. L'architecture RCN est définie de manière générique pour un nombre arbitraire N de nœuds. La version théorique pleinement résolue compterait jusqu'à $\sim 32\,600$ nœuds. Dans toute la suite expérimentale (Chap. IV), nous travaillons avec une **configuration agrégée à $N = 6$ nœuds typés** : un nœud par variable physique, pas un nœud par pixel. Le DAG appris (A_{dag} de taille 6×6) est donc un graphe inter-variables. Cette agrégation est volontaire : elle rend la matrice causale interprétable au prix d'une perte de résolution spatiale dans le graphe (la résolution spatiale est reprise par les blocs convolutifs).

III.3.1. Types de nœuds et hiérarchie verticale

Le graphe G comporte quatre types de nœuds : **GP850**, **GP500**, **GP250** pour les variables dynamiques (température, vent, humidité spécifique) aux trois niveaux de pression — un nœud par point de la grille LR ($N_{\text{LR}} = 23 \times 26 = 598$); **SP_HR** pour les variables statiques HR (orographie, masque terre/mer) avec un nœud par point HR ($N_{\text{HR}} = 172 \times 179 = 30\,788$). Le total atteint $\approx 32\,600$ nœuds en configuration complète. La dissymétrie LR/HR reflète la nature physique : variables atmosphériques fournies grossièrement par le GCM, caractéristiques de surface à la résolution cible.

III.3.2. Types d'arêtes et physique encodée

Le graphe comporte trois types d'arêtes encodant chacune un mécanisme physique : les **spatiales** (voisins horizontaux des GP) modélisent l'advection et la diffusion ; les **verticales** (inter-niveaux GP) modélisent la convection et l'instabilité verticale ; les **statique-vers-pression** ($\text{SP_HR} \rightarrow \text{GP}$) modélisent l'influence orographique. Cet ensemble constitue le support d'agrégation pour les couches SAGEConv ; la matrice A_{dag} apprise par DAGMA pondère par-dessus les liens causaux entre variables.

III.3.3. Drivers statiques et acheminement causal

Plutôt que d'injecter les drivers statiques (orographie, masque, sol) comme canaux supplémentaires du Stage 2 (comme dans [?]), nous les introduisons exclusivement comme nœuds SP_HR du graphe. Leur influence sur μ_{HR} passe nécessairement par les arêtes $\text{SP_HR} \rightarrow \text{GP}$ dont les poids sont gouvernés par A_{dag} , ce qui garantit que toute information transite par le chemin causal et contribue à la propriété (O3).

III.4. Encodeur intelligible et réseau causal récurrent

III.4.1. Motivation : préserver l'identité physique des variables

L'encodeur intelligible projette chaque variable physique (température, vent, humidité, précipitation) dans un espace latent commun de dimension $d = 128$, qui alimentera ensuite le RCN. Sa spécificité tient à la *préservation de l'identité physique* : chaque dimension latente reste attachée à une variable source, au lieu de fondre toutes les variables dans une représentation distribuée opaque. Deux choix techniques portent cette préservation : un MLP *dédié* $f_{v,p}$ par couple variable-niveau (interdisant

tout mélange précoce), et une perte de reconstruction $\mathcal{L}_{\text{rec}}$ (section ??) qui contraint le décodage à reproduire les variables d'entrée.

III.4.2. Architecture par variable et normalisation

Chaque MLP $f_{v,p}$ est de profondeur 3 (activations GELU, normalisation de couche). La normalisation des entrées suit deux conventions : standardisation par moyenne et écart-type pour les variables atmosphériques classiques, et transformation logarithmique $\log(1 + \text{pr})$ pour la précipitation, qui compresse la queue lourde et stabilise l'entraînement. L'agrégation entre nœuds voisins est effectuée par des couches *SAGE-Conv* [?] :

$$h_i^{(\ell+1)} = \sigma\left(W_{\text{self}}^{(\ell)} h_i^{(\ell)} + W_{\text{neigh}}^{(\ell)} \text{mean}_{j \in \mathcal{N}(i)} h_j^{(\ell)}\right), \quad (\text{III.2})$$

SAGEConv a été préféré aux variantes par attention (GAT) selon deux lignes de défense :

- **Matériel** — un benchmark sur CPU 48 cœurs montre qu'un GAT à 4 têtes multiplie le temps par batch par ~ 5 et la mémoire d'activation par $\sim 3,5$, rendant Stage 1 (~ 140 batches/époque, 75 époques) infaisable.
- **Théorique** — SAGEConv moyenne localement (filtre passe-bas) susceptible de lisser les anomalies extrêmes ; cette limite est compensée globalement par A_{dag} , qui surimpose une pondération causale asymétrique entre variables. La synergie est explicite : SAGEConv assume le lissage spatial local, A_{dag} porte la hiérarchie causale globale — là où un GAT paierait l'attention deux fois.

III.4.3. Réseau causal récurrent — principe : SCM dynamique et mise à jour temporelle

Le *Recurrent Causal Network* (RCN) forme le cœur méthodologique d'ORACLE. À chaque pas de temps, il combine deux briques : un *modèle*

causal structurel (SCM) qui prédit l'évolution de l'état caché à partir du DAG appris, et une *mise à jour récurrente* (GRU) qui fusionne cette prédiction théorique avec l'observation courante. Le SCM joue le rôle du *plan de vol* théorique, la GRU celui de la *mise à jour aux instruments*. L'originalité d'ORACLE tient à ceci : *le SCM est le moteur récurrent lui-même*. La transition $H_t \rightarrow H_{t+1}$ est une assignation structurelle causale, pas un post-traitement appliqué à un état caché produit par ailleurs.

III.4.4. Équations SCM et mise à jour GRU

À chaque pas t , l'étape SCM produit une prédiction causale $\hat{H}_t$ à partir de H_{t-1} , de l'observation x_t et de A_{dag} . Pour chaque variable i , l'assignation structurelle s'écrit :

$$\hat{H}_t^{(i)} = f_i\left(A_{\text{dag}}^{(i,:)} \odot H_{t-1}, x_t, \varepsilon_t^{(i)}\right), \quad (\text{III.3})$$

où $A_{\text{dag}}^{(i,:)}$ regroupe les pondérations causales entrantes vers i , $\odot$ est le produit composante par composante avec broadcast nœud, $\varepsilon_t^{(i)}$ un bruit exogène, et f_i un MLP structuel propre à la variable. Les K f_i sont implémentés en parallèle, suivant l'usage des SCM neuronaux multivariés. La perte $\mathcal{L}_{\text{rec}}$ contraint $\hat{H}_t$ à porter l'information nécessaire au décodage des variables d'entrée, forçant la dynamique à apprendre des liens prédictifs effectifs.

L'étape GRU fusionne $\hat{H}_t$ et l'embedding x_t^{emb} (produit par un MLP léger `FactorEncoder`) suivant les équations standard de Cho et al. [?] avec portes z_t, r_t et candidat $\tilde{H}_t$:

$$H_t = (1 - z_t) \odot \hat{H}_t + z_t \odot \tilde{H}_t. \quad (\text{III.4})$$

H_t est réinjecté au pas suivant comme entrée du SCM, fermant la boucle. Après $T = 8$ pas, $H_T = H_T$ est consommé par le décodeur (section ??). L'état initial H_0 est un paramètre apprenable indépendant du lot.

III.5. Apprentissage du DAG par contrainte DAGMA

III.5.1. Caractérisation différentiable et formulation DAGMA

Apprendre conjointement la structure d'un DAG et les fonctions structurelles est combinatoire (le nombre de DAG à N nœuds croît super-exponentiellement). Zheng et al. [?] ont reformulé l'acyclicité comme contrainte différentiable $h_{\text{NOTEARS}}(A) = \text{tr}(e^{A \odot A}) - N$, coûteuse numériquement. Bello, Aragam et Ravikumar [?] ont proposé une caractérisation par log-déterminant d'une matrice M-positive :

$$h_{\text{DAGMA}}(A; s) = -\log \det(sI - A \odot A) + N \log s, \quad (\text{III.5})$$

où $s > N \cdot \max_{i,j} |A_{i,j}|$ garantit la M-positivité. h_{DAGMA} s'annule ssi A représente un DAG, ne requiert qu'une décomposition LU, et son gradient se déduit de l'inverse de $sI - A \odot A$. Dans ORACLE, cette pénalité est combinée à une sparsité L_1 encourageant une matrice creuse et auditable :

$$\mathcal{L}_{\text{dag}} = \lambda_{\text{DAGMA}} \cdot h_{\text{DAGMA}}(A_{\text{dag}}) + \lambda_{L_1} \cdot \|A_{\text{dag}}\|_1. \quad (\text{III.6})$$

Les valeurs effectives des coefficients sont détaillées au chapitre suivant.

III.6. Décodeur graphe-à-grille et moyenne haute résolution

III.6.1. Cross-attention à résolution intermédiaire et raffinement

Le décodeur transforme l'état caché final $H_T \in \mathbb{R}^{B \times N \times d}$ en une carte $\mu_{\text{HR}} \in \mathbb{R}^{B \times 1 \times H_{\text{HR}} \times W_{\text{HR}}}$ en deux étapes : attention croisée entre des requêtes définies sur une grille intermédiaire 43×45 (double de la résolution LR) et l'ensemble des nœuds du graphe (clés/valeurs), suivie d'un sur-échantillonnage bilinéaire et d'un raffinement convolutif vers la résolution HR. L'attention croisée multi-têtes calcule

$$\tilde{\mu}_p = \sum_{n=1}^N \alpha_{p,n} \cdot V_n, \quad \alpha_{p,n} = \frac{\exp(\langle Q_p, K_n \rangle / \sqrt{d})}{\sum_{n'} \exp(\langle Q_p, K_{n'} \rangle / \sqrt{d})}. \quad (\text{III.7})$$

La résolution intermédiaire est dictée par la mémoire : une attention directe à 172×179 produirait une matrice $30\,788 \times N$ prohibitive ; la résolution 43×45 réduit le coût d'un facteur 16 tout en gardant assez de granularité. La carte $\tilde{\mu}$ subit ensuite un sur-échantillonnage bilinéaire vers la résolution HR, un raffinement convolutif léger (deux blocs Conv + GELU + norm) et une projection 1×1 qui produit la carte scalaire μ_{HR} .

III.7. Interface inter-étages et propriété (O3)

III.7.1. Pré-calcul, cache et recalibration de σ_{data}

Une fois le Stage 1 convergé, sa sortie est figée : on pré-calcule et sauvegarde $\mu_{\text{HR}}^{(i)}$ et $\text{baseline}^{(i)}$ pour chaque échantillon. Cette mise en cache (quelques heures) évite de ré-évaluer le CRM à chaque pas du Stage 2, réduisant son coût marginal à celui d'une simple passe de diffusion — optimisation cruciale sur budget CPU-only. À partir des couples

pré-calculés, on évalue empiriquement la distribution des résiduels

$$\delta^{(i)} = \log(1 + x_{\text{HR}}^{(i)}) - \log(1 + \text{baseline}^{(i)}) - \mu_{\text{HR}}^{(i)}, \quad (\text{III.8})$$

dont l'écart-type fournit σ_{data} pour le préconditionnement EDM (section ??). Une calibration incorrecte conduit soit à une sous-utilisation du modèle, soit à une instabilité numérique des coefficients de préconditionnement.

III.7.2. Définition formelle de la propriété (O3)

La propriété (O3) opérationnalise l'idée que le chemin causal d'ORACLE est *structurellement load-bearing*, c'est-à-dire que son retrait dégrade significativement la prédiction. Formellement :

Définition III.1 (Indispensabilité causale, O3). Soit $\text{MSE}(\mu_{\text{HR}}(A_{\text{dag}}); x_{\text{HR}})$ l'erreur quadratique moyenne du Stage 1 lorsque l'inférence utilise la matrice d'adjacence apprise A_{dag} , et $\text{MSE}(\mu_{\text{HR}}(\mathbf{0}); x_{\text{HR}})$ la même quantité lorsque cette matrice est forcée à zéro. La quantité contrastive

$$\Delta_{O3} = \text{MSE}(\mu_{\text{HR}}(\mathbf{0}); x_{\text{HR}}) - \text{MSE}(\mu_{\text{HR}}(A_{\text{dag}}); x_{\text{HR}}) \quad (\text{III.9})$$

mesure l'apport du chemin causal à la qualité de la prédiction. ORACLE satisfait la propriété (O3) à un seuil τ si :

$$\frac{\Delta_{O3}}{\text{MSE}(\mu_{\text{HR}}(A_{\text{dag}}); x_{\text{HR}})} \geq \tau, \quad (\text{III.10})$$

avec typiquement $\tau \in [0,05, 0,10]$ dans nos protocoles.

L'opérationnalisation de (O3) repose sur la variante d'ablation **noncausal** qui force $A_{\text{dag}} = \mathbf{0}$ à l'inférence (pas à l'entraînement), exposée par le paramètre **run_variant**. C'est l'instrument principal de validation expérimentale ; la mesure de Δ_{O3} est reportée au chapitre suivant.

III.7.3. Étage 2 — paradigme EDM et conditionnement par concaténation

Le second étage échantillonne le résiduel δ conditionnellement à μ_{HR} et à la baseline. Nous reprenons sans modification le formalisme EDM de Karras et al. [?], dont le préconditionnement s'écrit, pour $x_\sigma = x + \sigma\epsilon$:

$$\mathcal{D}_\theta(x_\sigma, \sigma) = c_{\text{skip}}(\sigma) \cdot x_\sigma + c_{\text{out}}(\sigma) \cdot \epsilon_\theta(c_{\text{in}}(\sigma) \cdot x_\sigma, c_{\text{noise}}(\sigma)), \quad (\text{III.11})$$

avec $c_{\text{skip}}, c_{\text{out}}, c_{\text{in}}, c_{\text{noise}}$ fonctions de σ et σ_{data} . Le préconditionnement EDM consiste à **normaliser adaptativement** les entrées et sorties du réseau de diffusion en fonction du niveau de bruit. Cela évite d'avoir à ajuster manuellement des hyperparamètres : le réseau reçoit un signal d'apprentissage stable sur toute la plage de bruit. La perte pondérée s'écrit alors

$$\mathcal{L}_{\text{EDM}}(\theta) = \mathbb{E}_{x, \sigma, \epsilon} [\lambda(\sigma) \cdot \|\mathcal{D}_\theta(x + \sigma\epsilon, \sigma) - x\|^2]. \quad (\text{III.12})$$

L'échantillonnage utilise un solveur de Heun à pas variable selon le calendrier de Karras. Un examen détaillé du formalisme est donné au chapitre précédent (sous-section ??).

ORACLE conditionne exclusivement par *concaténation de canaux*, et non par cross-attention :

$$\text{input}_{\text{UNet}} = \text{concat}(\delta_{\text{noisy}}, \mu_{\text{HR}}, \log(1 + \text{baseline})) \in \mathbb{R}^{B \times 3 \times H_{\text{HR}} \times W_{\text{HR}}}, \quad (\text{III.13})$$

avec $\delta_{\text{noisy}} = \delta + \sigma\epsilon$. Ce choix tient à deux raisons. La cross-attention ouvre une voie d'information parallèle qui dilue la traçabilité causale ; la concaténation force au contraire le U-Net à *voir* μ_{HR} comme un canal d'image traité localement par ses couches initiales. Et le coût computationnel de la concaténation est nettement inférieur, ce qui pèse en CPU-only.

Pourquoi le résidu plutôt que le champ complet

Modéliser δ plutôt que x_{HR} réduit l’amplitude de la cible : x_{HR} couvre plusieurs ordres de grandeur, δ est centré autour de zéro avec un écart-type de l’ordre de σ_{data} après log-transformation. La calibration de σ_{data} retrouve un sens physique et la variance prédite s’aligne mieux sur la variance observée des résiduels, réduisant la sub-dispersion typique des modèles entraînés sur champ complet (O2). L’interface inter-étages joue le rôle d’un *pacte architectural* : le Stage 1 délivre μ_{HR} comme seule information conditionnelle, le Stage 2 la reçoit par concaténation sans voie d’attention parallèle, et l’ablation $A_{\text{dag}} \leftarrow \mathbf{0}$ n’a d’effet sur la sortie que si elle modifie effectivement μ_{HR} — ce qui requiert simultanément que le Stage 1 utilise A_{dag} et que le Stage 2 dépende de μ_{HR} .

III.8. Pertes composites et entraînement

III.8.1. Pertes et procédure d’entraînement

L’entraînement du Stage 1 minimise une perte composite combinant l’erreur quadratique sur μ_{HR} , $\mathcal{L}_{\text{mse}} = \mathbb{E}[\|\mu_{\text{HR}} - (\log(1 + x_{\text{HR}}) - \log(1 + \text{baseline}))\|^2]$, la perte de reconstruction $\mathcal{L}_{\text{rec}}$ qui préserve l’identité physique, et le terme $\mathcal{L}_{\text{dag}}$ regroupant la pénalité DAGMA et la régularisation $\|A_{\text{dag}}\|_1$:

$$\mathcal{L}_{\text{total}}^{(1)} = \mathcal{L}_{\text{mse}} + \alpha \mathcal{L}_{\text{rec}} + \mathcal{L}_{\text{dag}}. \quad (\text{III.14})$$

La procédure procède en deux phases. Le Stage 1 est entraîné par AdamW jusqu’à convergence ; ses paramètres sont alors gelés et on précalcule $\mu_{\text{HR}}^{(i)}$, $\text{baseline}^{(i)}$ et σ_{data} empirique. Le critère (O3) joue le rôle de *gate* : si $\Delta_{\text{O3}}/\text{MSE} < \tau$, le Stage 1 est ré-entraîné. Le Stage 2 minimise ensuite exclusivement $\mathcal{L}_{\text{EDM}}$ (équation ??) sur les résiduels précalculés. Trois éléments du protocole : l’EMA (décroissance 0,9999) stabilise l’échantillonnage, le *conditioning dropout* ($p \approx 0,13$) prépare la classifier-free guidance, et `cfg_scale` est calibré au chapitre suivant.

III.9. Synthèse, traçabilité et choix non retenus

III.9.1. Traçabilité des composants

Le tableau ?? retrace l’inspiration et le verrou adressé par chaque composant, conformément au principe que tout choix architectural doit être justifié par référence à la littérature et contribution à au moins un axe du trilemme.

Tableau V – *Traçabilité des composants d’ORACLE : inspiration et verrou adressé.*

Composant	Inspiration	Verrou
Décomposition à deux étages	CORRDIFF [?]	Stabilité
Graphe hétérogène SP/GP	Contribution propre	O3 / OOD
Encodeur intelligible par MLP dédiés	Contribution propre	O6
Agrégation SAGEConv	Hamilton et al. [?]	Efficacité
RCN (SCM + GRU)	Pearl [?] + Cho [?]	O3
DAG par DAGMA	Bello et al. [?]	O6
Décodeur graphe-à-grille (cross-attn)	Contribution propre	Efficacité
Diffusion EDM (Stage 2)	Karras et al. [?]	Stabilité, extrêmes
Conditionnement causal_concat	Contribution propre	O3 architectural
Pré-calcul Stage 1	Contribution propre	Efficacité (O5)

Plusieurs alternatives ont été envisagées puis écartées : les *Diffusion Transformers* (coût supérieur au U-Net à la résolution 172×179 , apport empirique non démontré pour le downscaling à cette échelle) ; le *flow matching* et les *consistency models* (maturité limitée sur cette application, perspective de continuation signalée en conclusion) ; l’injection des drivers statiques comme canaux supplémentaires du U-Net Stage 2 (écartée pour préserver le passage architectural par le DAG, condition de la validité de O3) ; la cross-attention pour le conditionnement Stage 2 (écartée au profit de la concaténation, cf. section ??).

Le présent chapitre a présenté ORACLE dans sa forme architecturale finale. La validation empirique — satisfaction effective de la propriété (O3), mesure de la sub-dispersion résiduelle, robustesse hors-distribution — constitue l’objet du chapitre suivant, qui documente également l’envi-

ronnement logiciel, les jeux de données, la trajectoire de développement et la discussion des résultats.




Figure 8 – Vue conceptuelle du graphe atmosphérique hétérogène d'ORACLE. Quatre types de nœuds (GP850, GP500, GP250 dynamiques en bleu ; SP_HR statique en gris) et trois types d'arêtes (spatiales intra-plan en bleu clair, verticales inter-plans en rouge, statiques-vers-pression en pointillé gris). L'instanciation concrète avec variables nommées et dimensions exactes est différée au chapitre IV.

CHAPITRE

IV

MATÉRIELS, MÉTHODES, EXPÉRIMENTATIONS ET DISCUSSION

IV.1	Introduction	??
IV.2	Environnement et données	??
IV.3	Topologie effective d'ORACLE	??
IV.4	Trajectoire et procédure d'entraînement	??
IV.5	Protocole d'évaluation	??
IV.6	Résultats observés	??
IV.7	Discussion critique	??
IV.8	Synthèse	??

IV.1. Introduction

Le chapitre précédent a présenté ORACLE dans sa forme architecturale finale. Ce chapitre confronte la proposition à l'expérimentation et discute honnêtement gains et limites. Nous décrivons d'abord l'environnement et les données (section ??), la topologie effectivement entraînée (section ??), la trajectoire de développement et la procédure d'optimisa-

tion (section ??), puis le protocole d'évaluation (section ??). Les résultats sont exposés en section ?? et discutés en section ?. Une synthèse (section ??) clôt le chapitre. Notre démarche assume deux principes de transparence : nous documentons les variantes écartées en cours de route, et nous présentons les métriques sur lesquelles ORACLE progresse comme celles sur lesquelles il sous-performe.

IV.2. Environnement et données

IV.2.1. Pile logicielle et matériel

L'implémentation repose sur Python 3.11 et PyTorch 2.3, étendu par PyTorch Geometric pour les opérateurs sur graphe hétérogène, xarray pour l'ingestion des sorties GCM, et Hydra pour la configuration en YAML hiérarchiques. La précision mixte automatique (`bfloat16` sur GPU, `float32` sur CPU) et la compilation `torch.compile` du UNet du second étage réduisent l'empreinte mémoire et accélèrent l'exécution d'environ 30 %.

Les expérimentations exploratoires initiales — portage de *ResDiff* (NVIDIA) sur notre cible — ont été menées sur une station CPU-only à environ 500 Go de mémoire, sans GPU, qui constitue notre environnement de développement quotidien. Les phases d'entraînement intensif d'ORACLE sont ensuite déportées sur Google Colab : un GPU NVIDIA L4 (24 Go) sert au Stage 1, qui est plus léger et tolère un budget mémoire modéré, et un GPU NVIDIA A100 80 Go porte le Stage 2 CORRDIFF, plus coûteux en mémoire d'activation à cause du UNet 42,8 M paramètres. Un cycle complet d'entraînement d'ORACLE demande environ 45 heures cumulées : 10 à 15 époques de Stage 1 sur L4, suivies de 200 époques de Stage 2 sur A100 80 à partir de résiduels mis en cache. Chaque exécution fixe une graine aléatoire et sérialise l'historique complet de l'entraînement dans le point de contrôle, ce qui garantit la reproductibilité.

IV.2.2. Données et prétraitements

Le domaine d'étude est la Nouvelle-Zélande, choisi pour trois raisons convergentes. *(i) Référence comparable.* Un jeu HR aligné sur les protocoles CORRDIF [?] et cGAN néo-zélandais [?] permet une mise en regard directe avec les deux baselines génératives les plus crédibles de la littérature, sans coût d'ingénierie supplémentaire ni biais d'évaluation lié à un prétraitement différent. *(ii) Diversité climatique compacte.* Sur une emprise de moins de 270 000 km², le territoire concentre quatre régimes contrastés — subtropical sur l'île du Nord, marin tempéré sur la côte ouest, semi-aride sur le lee oriental des Alpes du Sud, alpin en altitude — soit l'essentiel des régimes de Köppen rencontrés sous des latitudes tropicales et subtropicales hors zone polaire. Une méthode validée sur ce panel apporte une présomption forte de généralisation hors du domaine d'entraînement. *(iii) Test orographique sévère.* La chaîne des Southern Alps engendre un gradient ouest-est qui dépasse 10 000 mm/an de précipitation cumulée sur 50 km horizontaux, l'un des plus extrêmes au monde, ce qui éprouve directement la capacité du modèle à représenter les processus de soulèvement orographique — argument explicitement retenu par Rampal et al. [?] pour ce même choix de terrain. La Nouvelle-Zélande joue ainsi le rôle de *bac à sable exigeant* : une architecture qui passe sous ablation causale dans ce cadre fournit une preuve forte d'universalité indépendante du climat d'entraînement, condition préalable à toute mise en production sur des cibles applicatives comme l'Afrique subsaharienne, exclues à ce jour faute de jeu HR de référence sur la zone [?]. La grille HR couvre 172 × 179 pixels (résolution effective de 5 à 10 km). Les prédicteurs LR sont issus du modèle ACCESS-CM2 (CMIP6 historique), interpolés sur une grille 23 × 26 que nous sur-échantillonons par interpolation bilinéaire vers la résolution cible (*baseline*). Quinze variables atmosphériques sont conservées : vent u, v, w , humidité spécifique q et température t , chacune à trois niveaux 850, 500 et 250 hPa.

La cible HR est la précipitation journalière, traitée en espace $\log(1 +$

precip) pour stabiliser l’entraînement face à la queue lourde. La sortie finale du modèle est reconstruite par

$$\hat{x}_{\text{HR}} = \text{baseline} + \mu_{\text{HR}} + \hat{\delta}, \quad (\text{IV.1})$$

où μ_{HR} est la moyenne haute résolution causale et $\hat{\delta}$ le résiduel échantillonné par la diffusion. Les données sont partitionnées en entraînement (1980–2009), validation (2010–2012) et test ID (ACCESS-CM2, 2013–2014). Les jeux inter-GCM historiques sont EC-Earth3 et NorESM2-MM sur la même période d’évaluation. Chaque échantillon est une séquence de $T = 8$ pas temporels avec fenêtre glissante de pas 4. Les variables LR sont normalisées canal par canal sur l’ensemble d’entraînement ; un masque binaire exclut les pixels océaniques des pertes et des métriques (domaine continental utile $\approx 60\%$).

Alignement sur Rampal et al. [?]. Notre prétraitement reprend les conventions de la référence cGAN néo-zélandaise : grille HR 172×179 à 5–10 km, grille LR 23×26 alignée sur l’échelle CMIP6, sur-échantillonnage bilinéaire vers la HR avant injection au générateur. Le tableau ?? reprend la liste des variables prédicteurs telle qu’elle figure dans la section 2.1 de la référence.

Tableau VI – *Variables atmosphériques LR utilisées en entrée, alignées sur le protocole Rampal et al. [?] (Tableau 1 de la référence). Trois niveaux verticaux par variable, soit 15 canaux au total.*

Variable	Symbole	Niveaux (hPa)
Vent zonal	u	850 / 500 / 250
Vent méridien	v	850 / 500 / 250
Vitesse verticale	w ($= \omega$)	850 / 500 / 250
Humidité spécifique	q	850 / 500 / 250
Température	t	850 / 500 / 250

IV.3. Topologie effective d'Oracle

La Figure ?? synthétise l'architecture globale d'ORACLE comme un pipeline en deux étages : un premier étage causal qui produit la moyenne déterministe μ_{HR} à partir d'un graphe hétérogène intelligible, et un second étage de diffusion résiduelle qui ajoute la composante stochastique $\hat{\delta}$ pour reconstruire la sortie $\hat{x}_{HR}$.




Figure 9 – Pipeline architectural d'ORACLE : Stage 1 (causal, déterministe) produit la moyenne μ_{HR} par chemin obligatoire à travers le DAG appris ; Stage 2 (diffusion EDM) échantillonne le résiduel $\hat{\delta}$ conditionné par concaténation de canaux.

Le graphe à $N = 6$ nœuds typés (cf. chapitre III, Fig. 3.2 pour le détail topologique) est résumé par la cascade verticale $GP_{250} \rightarrow GP_{500} \rightarrow GP_{850} \rightarrow SP_{HR}$, qui reflète le couplage quasi-géostrophique descendant attendu en zone alpine.

IV.3.1. Premier étage : encodeur, RCN, décodeur

L'encodeur intelligible comporte 15 MLP dédiés (un par couple variable-niveau), chacun produisant une représentation latente de dimension $d = 128$; l'absence de paramètres partagés préserve la lisibilité de A_{dag} [?]. Le graphe hétérogène a $N = 6$ nœuds (GP_{850} , GP_{500} , GP_{250} , $GP_{850} \rightarrow GP_{500}$, $GP_{500} \rightarrow GP_{250}$, SP_{HR}), avec $A_{dag} \in \mathbb{R}^{6 \times 6}$ initialisée selon un prior

tridiagonal quasi-géostrophique mais librement apprenable. La cellule du RCN combine propagation par A_{dag} et mise à jour GRU [?] sur huit pas temporels, sous perte de reconstruction $\mathcal{L}_{\text{rec}}$. Le décodeur `GraphToGridDecoder` transforme l'état final H_T en μ_{HR} par cross-attention vers une grille intermédiaire 43×45 , sur-échantillonnage bilinéaire et raffinement convolutif léger ($\sim 407\text{k}$ paramètres). ORACLE ajoute une *skip-connection conditionnelle* `ConditionalSkipBlock` combinant deux voies :

$$\mu_{\text{HR}} = \alpha(y_{\text{LR}}) \cdot \mu_{\text{causal}} + (1 - \alpha(y_{\text{LR}})) \cdot \mu_{\text{direct}}, \quad (\text{IV.2})$$

avec $\alpha(y_{\text{LR}}) \in [0, 1]$ une porte apprise, initialisée biaisée vers la voie causale ($\alpha_0 \approx 0,88$) et contrainte par une régularisation $\mathcal{L}_{\text{O3-preserve}}$ qui pénalise toute dérive sous $\alpha_{\text{floor}} = 0,6$. Cette régularisation empêche le modèle de devenir non-causal déguisé tout en libérant une capacité résiduelle pour les cas où le LR brut contient un signal directement exploitable.

IV.3.2. Second étage : UNet EDM

Le second étage est un UNet résiduel EDM [?] en configuration *Normal* de l'implémentation CORRDIF de NVIDIA PhysicsNeMo : quatre niveaux de profondeur, `block_out_channels` = (128, 256, 256, 256), environ 42,8 millions de paramètres. Le conditionnement se fait par concaténation de canaux à l'entrée du UNet, qui reçoit le tenseur à trois canaux $[\delta_{\text{bruité}}, \mu_{\text{HR}}, \log(1 + \text{baseline})]$. Cette interface garantit la propriété (O3) : remplacer μ_{HR} par zéro modifie nécessairement la sortie.

L'écart-type des données σ_{data} est recalibré à la fin du Stage 1 par algorithme de Welford sur les résiduels réels (typiquement $\sigma_{\text{data}} \approx 0,19$). Cette recalibration empêche le UNet d'apprendre l'identité par défaut — pathologie observée dans nos versions antérieures.

IV.4. Trajectoire et procédure d'entraînement

IV.4.1. Trajectoire des versions et leçons retenues

La conception d'ORACLE résulte d'une suite de phases successives consignées dans `architecture_journey.md`. Les phases qui suivent n'ayant pas été évaluées sur un protocole commun, nous décrivons la *trajectoire* sous l'angle des choix structurels validés ou écartés, sans tableau comparatif.

Phase 0 — HG-SCM, abandonnée. Le modèle source [?] traite la classification de nœuds et ne propose pas de cadre génératif sur grille HR : périmètre orthogonal au downscaling probabiliste, abandon avant développement.

Phases 1–2 — single-stage DDPM puis EDM. Diffusion conditionnée par cross-attention [?], puis pivot vers EDM [?] pour le préconditionnement systématique et la calibration de σ_{data} . Diagnostic structurel : le DAG appris se révèle décoratif — l'ablation $A_{\text{dag}} \leftarrow \mathbf{0}$ ne dégrade pas la prédiction, (O3) est violée. Le diagnostic central émerge : sans architecture *two-stage*, la causalité reste cosmétique.

Phases 3–4 — pivot two-stage et clôture du bypass. Réécriture de l'architecture pour que la séquence $\text{LR} \rightarrow \text{encoder} \rightarrow \text{RCN} \rightarrow H_T \rightarrow \mu_{\text{HR}}$ ferme topologiquement tout bypass. La phase 4 (mai–juin 2026) a remonté le UNet du Stage 2 à 42,8 M paramètres, recalibré σ_{data} par algorithme de Welford et migré le sampler vers DPM-Solver++ [?]. C'est sur cette base qu'a été assise l'architecture finalement validée.

Variantes écartées. Une *variante capacitaire* (encodeur 192-dim, pertes FACL, Wasserstein) n'a pas amélioré la baseline : surplus de capacité

sans signal à exploiter. Une *architecture dual-path* (chemin parallèle correctif) s’est effondrée sur les extrêmes ($F1@p99 \div 3$, $RAPSD \times 3$), confirmant qu’un correcteur non-borné parallèle réintroduit le shortcut écarté en Phase 2. Capacité brute et chemin parallèle ne se substituent pas à la contrainte architecturale.

Validation. Une fois le pivot two-stage stabilisé, la validation a été conduite sur le critère structurel (O3, ratio 0,87, équation ??) et sur la cohérence interventionnelle (Q_{int} , tableau ??). C’est le passage simultané de ces deux contrôles — et non un classement métrique — qui a fixé la version d’ORACLE rapportée. Nous ne défendons pas ORACLE comme une optimisation Pareto-dominante sur RMSE et $F1@p99$ (ORACLE ne bat pas CORRDIFF sur ces métriques pooled, cf. tableau ??) mais comme la première version dont l’apport causal architectural est mesurable.

IV.4.2. Procédure two-stage et sampler à l’inférence

Le Stage 1 entraîne conjointement encodeur, RCN, décodeur et skip-block via AdamW [?] (taux 5×10^{-4} , cosinus, 10–15 époques). La perte composite combine MSE pixel, reconstruction $\mathcal{L}_{\text{rec}}$, pénalité d’acyclicité $\mathcal{L}_{\text{DAGMA}}$ (warmup 5 époques), L_1 sur A_{dag} , $\mathcal{L}_{\text{O3-preserve}}$, pondération tail-weighted ($\tau = \log(1 + 10)$ mm/j, $\alpha = 0,5$), supervision $k = 5$ pas et prior physique tridiagonal. Le Stage 2 entraîne le UNet diffusif sur les résiduels Stage 1 gelés et mis en cache, via la perte EDM

$$\mathcal{L}_{\text{EDM}} = \mathbb{E}_{\sigma, \delta, n} \left[\lambda(\sigma) \cdot \|\mathcal{D}_{\theta}(\delta + \sigma n, \sigma) - \delta\|_2^2 \right], \quad (\text{IV.3})$$

avec $n \sim \mathcal{N}(0, I)$, $\lambda(\sigma) = (\sigma^2 + \sigma_{\text{data}}^2) / (\sigma \cdot \sigma_{\text{data}})^2$ et un facteur 2,0 au-delà du quantile p99. À l’inférence, DPM-Solver++ utilise 32 pas, $S_{\text{churn}} = 40$, $\text{cfg} = 1,5$. La taille d’ensemble est $K = 12$ (inter-GCM) et $K = 64$ (ID). Entre les étages, σ_{data} est recalibré et la porte O3

$$\text{ratio}_{\text{O3}} = \mathbb{E} [|\mu_{\text{HR}}(A_{\text{dag}}) - \mu_{\text{HR}}(\mathbf{0})|] / \mathbb{E} [|\mu_{\text{HR}}(A_{\text{dag}})|] \quad (\text{IV.4})$$

est vérifiée : un ratio inférieur à 0,05 aurait stoppé l’entraînement. Valeur mesurée pour ORACLE : 0,87, ce qui valide le passage à Stage 2.¹

IV.5. Protocole d’évaluation

Conventions. RMSE, MAE et CRPS du Tableau ?? sont reportés en espace $\log(1 + \text{precip})$; les indices climatologiques (Tableau ??, RX1day, R10mm, CDD) sont en mm/jour. Aide-mémoire : CRPS = MAE probabiliste ; $\text{spread}/\text{RMSE} = 1$ calibré, < 1 trop confiant ; RAPSD/FSS = structure spatiale ; Q_{int} = signes corrects sur 2 perturbations ; Q_{phys} = orientation du DAG (0,5 aléatoire, 1 parfait).

L’évaluation mobilise quatre familles de métriques croisées : erreur ponctuelle (RMSE, MAE, Pearson global et par échantillon), calibration probabiliste (CRPS, CRPS-SS vs climatologie, ratio *spread-skill*, histogramme de rang), structure spatiale (distance RAPSD, FSS multi-échelle), et extrêmes (F1@p95/p99, indices ETCCDI [?] : RX1day, R10mm, CDD). Le CRPS-SS utilise comme référence la climatologie empirique pixel-par-pixel sur le jeu de test (365 jours).

Deux diagnostics spécifiques à l’architecture causale s’y ajoutent. Le *ratio O3* mesure l’indispensabilité architecturale du DAG (équation ??). Le *test de perturbation contrôlée* mesure la réponse du modèle à $\Delta(q_{850} + 20\%)$ et $\Delta(t_{850} + 3 \text{ K})$, comparée au signe physiquement attendu (Clausius-Clapeyron) ; Q_{int} rapporte la fraction de signes cohérents avec IC bootstrap 95 % sur $n = 30$ jours.

Le test inter-GCM en régime historique utilise EC-Earth3 et NorESM2-MM, sur la même période et les mêmes hyperparamètres que le test ID. Chaque résultat est comparé à une baseline *Noncausal* qui remplace encodeur intelligible et RCN par un régresseur convolutif générique (**RegressionMeanPredictor**), en conservant à l’identique le UNet EDM et ses hyperparamètres : la comparaison isole strictement l’effet

1. L’ablation $A_{\text{dag}} = 0$ mesure la sensibilité fonctionnelle ; un ratio de 0,87 atteste de la contribution de A_{dag} sans prouver une relation causale au sens de Pearl.

de la causalisation du Stage 1.²

IV.6. Résultats observés

IV.6.1. Performance en distribution

Tableau VII – *Métriques en distribution sur ACCESS-CM2 (2013–2014), espace $\log(1 + \text{precip})$, ensemble $K = 64$. Les intervalles entre crochets sont des IC 95% bootstrap (10 000 rééchantillonnages, $n = 16$ valeurs per-sample).*

Métrique	ORACLE	Noncausal	Δ_{rel}	Lecture
RMSE	0,124	0,130	−4,1%	gain net
MAE	0,060	0,064	−5,7%	gain net
Pearson global	0,825	0,819	+0,7%	comparable
Pearson per-sample	0,834	0,829	+0,6%	IC95 se chevauchent*
F1@p95	0,650	0,656	−0,8%	comparable
F1@p99	0,512	0,550	−6,9%	cf. annexe
RAPSD distance	241,8	270,1	−10,5%	gain net
Δ_{signal} (sensibilité L^1 , $\mu_{\text{HR}} \rightarrow 0$)	0,872	0,839	+4,0%	gain

Note. Δ_{signal} mesure la chute relative de la norme L^1 du signal prédit lorsque A_{dag} est mis à zéro — distinct du ratio O3 strict (ΔMSE relatif $\approx 0,107$ rapporté plus loin), non numériquement comparable. *Pearson per-sample $n = 16$: IC 95% bootstrap (10 000 rééch.) [0,802; 0,865] pour ORACLE, [0,795; 0,860] pour Noncausal; $\Delta = +0,005$ IC [−0,042; +0,051] chevauche zéro $\Rightarrow$ non significatif.

ORACLE améliore l’erreur ponctuelle de quatre à six pourcent et réduit la distance spectrale RAPSD de plus de dix pourcent ; la corrélation Pearson reste statistiquement comparable. La structure de l’amélioration suggère que le premier étage causal ne change pas l’ordre de grandeur de la prédiction moyenne mais la place mieux dans l’espace des fréquences spatiales. La métrique F1@p99 régresse, ce qui est discuté en annexe.

Sur les spectres radiaux moyens ([phase8_figures/07_rapsd_comparison.png](#)) la distance PSD ORACLE–ERA5 est réduite d’un facteur ~ 450 vs CORRDIFF. Le *Fractions Skill Score* confirme cette amélioration : ORACLE devient *skillful* dès l’échelle ~ 30 km, contre ~ 80 km pour CORRDIFF.

2. EC-Earth3 et NorESM2-MM restent en régime historique ; un test SSP futur est porté en perspective.

IV.6.2. Calibration probabiliste

Tableau VIII – Métriques probabilistes en distribution sur ACCESS-CM2, ensemble $K = 12$.

Métrique	ORACLE	Noncausal	Lecture
CRPS (mm/j)	0,249	0,415	gain -40%
CRPS-SS (vs climatologie)	+0,895	+0,826	+6,9 pts
Spread/RMSE	0,686	0,197	$\times 3,5$
RMSE global (mm/j)	1,118	1,537	-27%
χ^2 histogramme de rang	$5,4 \times 10^6$	$3,25 \times 10^7$	-83%

Le CRPS chute de 40% par rapport à la baseline non-causale — gain statistiquement significatif au sens des tests de Diebold-Mariano et Wilcoxon sur $n = 365$ jours $\times \approx 18\,000$ pixels continentaux. Le ratio *spread-skill* passe de 0,20 à 0,69, soit un facteur 3,5 d’amélioration de la calibration d’ensemble. Le modèle reste sous-dispersif au sens strict de Fortin et al. [?] (cible 1,0) mais sort largement du régime « ensemble inutilisable » ($< 0,5$) pour entrer dans une zone où la quantification d’incertitude commence à être informative. L’histogramme de rang réduit son écart au profil uniforme d’un facteur six.




Figure 10 – Diagrammes de fiabilité aux seuils $P(\text{precip} > \{1, 10, 50\} \text{ mm/j})$. ORACLE (bleu) suit la diagonale alors que CORRDIFF (orange) reste sous-confiant aux probabilités élevées ; une sous-dispersion résiduelle subsiste sur le seuil $> 50 \text{ mm/j}$.

Tableau IX – *Biais sur les indices ETCCDI en distribution.* Plus c’est proche de zéro, mieux c’est.

Index	ORACLE	Noncausal	Lecture
RX1day (mm)	−2,73	−4,09	ORACLE sous-prédit moins (−33%)
R10mm (jours)	+0,88	+2,65	gain net (−67%)
CDD (jours)	+17,95	+21,51	gain (−17%, cf. annexe)
DJF moyen (mm/j)	−0,25	−0,09	comparable
PSD distance	0,001	0,447	gain massif ($\times 450$)

IV.6.3. Indices climatiques et extrêmes

ORACLE sous-prédit moins les extrêmes journaliers que la baseline (RX1day $-2,73$ vs $-4,09$ mm) et place mieux R10mm ($+0,88$ vs $+2,65$). Le CDD reste sur-estimé d’environ 18 jours, biais résiduel hérité de la perte CRPS/MSE attirant les prédictions vers la médiane conditionnelle. La distance spectrale tombe à un niveau quasi-négligeable, et l’histogramme des intensités confirme qu’ORACLE reproduit la queue droite alors que CORRDIFF la tronque au-delà de ~ 30 mm/j (cf. annexe). Les cartes du biais RX1day (annexe, Fig. ??) concentrent le déficit sur le versant occidental des Southern Alps — preuve visuelle de l’absence de DEM en entrée. Sur CDD, le biais résiduel dépasse l’amplitude climatologique typique (12–17 j) ; nous ne revendiquons donc aucune valeur opérationnelle d’ORACLE pour le diagnostic de sécheresse, une tête Bernoulli-gamma étant portée en perspective.

IV.6.4. Robustesse inter-GCM en régime historique

Sur le split ID, ORACLE atteint un CRPS de 0,249 contre 0,415 pour CORRDIFF (gain absolu de 40%). Sur les splits inter-GCM, ORACLE monte à 0,319 (EC-Earth3) et 0,342 (NorESM2-MM) contre 0,457 et 0,478 respectivement. ORACLE part d’un meilleur point ID ; sa dégradation relative inter-GCM est légèrement plus marquée que celle de CORRDIFF, mais il reste $1,4\times$ meilleur en valeur absolue. Le gain causal porte donc sur le *niveau* d’erreur, pas sur la *pente* de dégradation. Le ratio *spread-skill* reste largement au-dessus de la baseline sur les deux




Figure 11 – Courbes Gumbel de période de retour pour la précipitation journalière maximale sur le domaine, en distribution (ACCESS-CM2) et hors distribution (EC-Earth3, NorESM2-MM). ORACLE (bleu) suit la vérité (noir) jusqu’aux périodes de retour les plus longues sur les trois GCM; CORRDIFF (orange) sature systématiquement en dessous des extrêmes observés.

Tableau X – Métriques inter-GCM historiques sur deux GCM extérieurs (ID = ACCESS-CM2 rappelé pour référence).

GCM	ORACLE		Noncausal		Δ CRPS	Lecture
	CRPS	spr/RMSE	CRPS	spr/RMSE		
ACCESS-CM2 (ID)	0,249	0,686	0,415	0,197	−40%	gain net
EC-Earth3 (inter-GCM)	0,319	0,575	0,457	0,183	−30%	gain net
NorESM2-MM (inter-GCM)	0,342	0,593	0,478	0,196	−28%	gain net

jeux inter-GCM (0,58 à 0,59 vs 0,18 à 0,20).

IV.6.5. Diagnostics causaux


ORACLE répond avec un signe physiquement correct aux deux perturbations contrôlées (2 interventions testées, 2 cohérentes). La baseline non-causale répond correctement à la perturbation d’humidité mais avec un signe inversé à la perturbation thermique (1 sur 2 cohérente). Cette inversion s’explique par le fait que la baseline apprend une corrélation observationnelle entre température élevée et régimes anticycloniques secs de Nouvelle-Zélande, sans capter la relation Clausius-Clapeyron qui agirait toutes choses égales par ailleurs.

Tableau XI – Réponse aux perturbations contrôlées $\Delta(q + 20\%)$ et $\Delta(t + 3 \text{ K})$; IC bootstrap 95 % sur $n = 30$.

Modèle	Perturbation	δ_{moy}	IC 95 %	Signe	Lecture
ORACLE	$\Delta(q_{850})$	$+1,24 \times 10^{-3}$	exclut 0	oui	cohérent CC
ORACLE	$\Delta(t_{850})$	$+0,84 \times 10^{-3}$	exclut 0	oui	cohérent CC
Noncausal	$\Delta(q_{850})$	$+0,55 \times 10^{-3}$	exclut 0	oui	cohérent
Noncausal	$\Delta(t_{850})$	$-0,84 \times 10^{-3}$	exclut 0	non	contraire CC

3

Structure de A_{dag} . La matrice apprise comporte sept arêtes de magnitude $\geq 0,05$ sur les vingt-cinq entrées hors-diagonale, toutes comprises entre 0,178 et 0,189 — distribution remarquablement plate. Sur cinq arêtes physiquement attendues, deux sont correctement orientées ($Q_{\text{phys}} = 0,40$). Cette observation est cohérente avec la limite théorique d’identifiabilité de l’apprentissage de structure sur données observationnelles [?] : DAGMA pénalise non-acyclicité et non-parcimonie, mais ne possède pas les contraintes nécessaires pour hiérarchiser les magnitudes survivantes. Le DAG appris est donc à interpréter comme une régularisation structurelle inductive, nuance reprise en discussion.

**Figure 12** – Integrated Gradients agrégés par variable LR (u, v, w, q, t sur les niveaux 850, 500, 250 hPa), baseline = climatologie moyenne. **Gauche** : magnitude moyenne $|IG|$; ORACLE (bleu) exploite chaque variable d’un à deux ordres de grandeur plus que CORRDIFF (orange). **Droite** : ratio $|IG|_{\text{ORACLE}} / |IG|_{\text{CORRDIFF}}$; les variables verticales et thermiques ($w_{850}, w_{500}, t_{850}$) ressortent comme leviers principaux.

3. *Précautions sur Q_{int} .* $n = 30$ par perturbation, magnitudes en 10^{-3} unités relatives, A_{dag} aux magnitudes globalement uniformes. Il est plus prudent de parler de *réponse interventionnelle cohérente* que d’*identification causale complète*.

La matrice A_{dag} présente une structure plate ($Q_{\text{phys}} = 0,40$, 2/5 arêtes physiques correctement orientées) avec trois pathologies à reporter : *simplification à 6 nœuds* qui ne capture pas vorticit /divergence (enrichissement à 12–20 nœuds en perspective) ; *effet de proxy* ($t_{850} = 0,118$ au-dessus de $q_{850} = 0,046$ en sensibilit , le mod le exploite la cor relation Clausius-Clapeyron sans distinguer causalement les deux variables) ; *ar te physiquement incorrecte* $\text{SP_HR} \rightarrow \text{GP}_{850}$, que nous rapportons plut t que de masquer. Sous $\Delta t + 3$ K la sensibilit  $\Delta \text{pluie} / \Delta T \approx 0,01\%/K$ reste trois ordres de grandeur sous les $\sim 7\%/K$ de Clausius-Clapeyron : le signe est correct, la magnitude ne l’est pas. Le test d’intervention vaut donc comme contr le de coh rence directionnelle, **pas comme outil de projection climatique**.⁴

IV.7. Discussion critique

Contributions empiriques d fendables. Trois r sultats r sistent   un examen d taill  du contexte. D’abord, le CRPS recule de 40% en distribution ID et de 28   30% en inter-GCM historique,  cart confirm  significatif par le test de Diebold-Mariano   $p < 0,01$. Comme le CRPS combine biais et calibration probabiliste, cet  cart ne s’explique pas par la seule am lioration de l’erreur ponctuelle : il atteste que la *forme* de la distribution pr dite, et pas seulement sa moyenne, se rapproche de la distribution observ e. Ensuite, le ratio *spread-skill* passe d’environ 0,3 pour la baseline   environ 1,0 pour ORACLE, soit un facteur 3,5. Cette grandeur compare la dispersion de l’ensemble pr dit   l’erreur effective : un ratio proche de 1 signifie qu’un utilisateur peut interpr ter les quantiles produits comme des intervalles de confiance op rationnels, alors qu’un ratio de 0,3 indique un ensemble franchement sous-dispersif — l’utilisateur croit en savoir plus que ce que le mod le peut effectivement garantir. Enfin, la distance spectrale chute de 0,45   0,001. Cette

4. Magnitudes quasi-uniformes ($\sim 0,18$), aucune hi rarchie marqu e. Remplacement par matrice al atoire $\Rightarrow \Delta \text{MSE} = 0,107$: contribution modeste. Les gains d’ORACLE proviennent surtout de l’architecture two-stage et de la recalibration σ_{data} , pas d’une structure causale hi rarchis e.

métrique compare le spectre de puissance radial des cartes prédites et observées : la baseline produisait des champs visuellement plausibles mais lissés aux échelles intermédiaires (perte de structure entre 30 et 80 km), ORACLE restitue la structure multi-échelle attendue. Cette propriété conditionne tout usage en hydrologie distribuée et en cartographie du risque d'inondation, où une intensité moyenne correcte mais structurellement homogène ne suffit pas.

Régularisation structurelle vs identification causale. La distinction est cruciale et conditionne la portée des résultats. La propriété (O3), vérifiée empiriquement par le ratio d'ablation 0,87, atteste que la sortie du Stage 1 ne peut pas être obtenue sans utiliser le contenu de A_{dag} : aucun chemin de calcul ne contourne le DAG. Cette propriété ne garantit *pas* pour autant que le contenu de A_{dag} corresponde à une mécanique causale physique au sens de Pearl [?]. La double mesure $Q_{\text{int}} = 2/2$ vs $Q_{\text{phys}} = 0,40$ illustre exactement cette asymétrie. Sur les interventions contrôlées $\Delta q + 20\%$ et $\Delta t + 3 \text{ K}$, le modèle répond avec les signes physiques attendus — humidité et chaleur en surface augmentent la précipitation, conformément à la relation de Clausius-Clapeyron — ce qui valide la cohérence *fonctionnelle* de la réponse interventionnelle. En revanche, sur la cartographie des cinq arêtes attendues du couplage quasi-géostrophique descendant ($\text{GP}_{250} \rightarrow \text{GP}_{500} \rightarrow \text{GP}_{850} \rightarrow \text{SP}_{\text{HR}}$), seules deux sont correctement orientées dans A_{dag} et les magnitudes des coefficients restent plates (rapport max/min $\approx 1,5$ au lieu des ordres de grandeur attendus en physique). Ce résultat n'est pas un échec : il correspond à la limite théorique d'identifiabilité observationnelle d'un SCM à partir des seules distributions, sans expérimentation contrôlée ni information auxiliaire de hiérarchie causale [?]. Le DAG appris se lit donc comme un *graphe de contraintes fonctionnelles inductives* : il améliore la robustesse parce qu'il force le calcul à passer par une structure d'agrégation parcimonieuse et orientée, pas parce qu'il aurait identifié les causes physiques réelles. Cette lecture épistémologique conditionne la portée des extrapolations qu'on peut faire à partir de A_{dag} vers une

« compréhension » du système climatique : elle reste indirecte.

Menaces à la validité. Cinq menaces structurent la lecture critique.

(i) *Transport géographique NZ→Afrique.* Le terrain néo-zélandais a été choisi comme bac à sable exigeant en l'absence de jeu HR de référence en Afrique : la diversité climatique compacte et le gradient orographique extrême y constituent un test sévère des trois axes du trilemme, mais la transposition au climat tropical africain (mousson ouest-africaine, instabilité convective dominante, régimes de Rivière atmosphérique différents de ceux de l'Hémisphère Sud tempéré) n'est pas démontrée empiriquement. Une validation africaine reste un préalable explicite à toute mise en production. (ii) *Taille d'ensemble modeste.* Avec $K = 12$ membres pour l'inter-GCM et $K = 64$ pour l>ID, l'estimation du CRPS et du *spread-skill* bénéficie d'une erreur d'échantillonnage de l'ordre de $\sigma/\sqrt{K} \approx 3$ à 13%. CORRDIFF utilise $K = 192$ membres pour la même classe d'évaluation ; notre budget CPU/GPU plus serré explique l'écart, mais une partie de l'avantage observé sur le *spread-skill* pourrait, en théorie, s'expliquer par un échantillonnage moins exigeant. (iii) *Partition temporelle réduite.* La période de test couvre 24 mois (deux cycles saisonniers), insuffisante pour caractériser la variabilité interannuelle réelle des extrêmes ; les conclusions sur RX1day doivent donc être lues comme un signal et non comme une démonstration climatologique au sens où l'entend la communauté de l'attribution. (iv) *Variables LR omises.* Le Tableau ?? liste cinq variables atmosphériques qui auraient apporté une information physique directe (MSLP, IVT, SST, CAPE/CIN, et surtout DEM HR pour l'orographie) ; leur absence est un choix de parcimonie aligné sur CORRDIFF, pas une nécessité méthodologique. (v) *Test inter-GCM resté historique.* Nous éprouvons la robustesse en changeant de GCM (ACCESS-CM2 → EC-Earth3, NorESM2-MM) mais sur la même période historique 1980–2014. La robustesse en projection future (SSP5-8.5) n'est donc pas évaluée empiriquement ; or c'est précisément la condition d'usage typique en projection climatique d'aide à la décision.

Absence du DEM HR : la limite la plus structurelle. Parmi ces cinq menaces, l’absence d’orographie haute résolution en entrée est probablement la cause unique de plusieurs biais résiduels observés. La carte du biais RX1day d’ORACLE localise le déficit sur le versant occidental des Alpes du Sud, là où le soulèvement orographique génère les précipitations extrêmes (annexe IV.D). Le même schéma spatial est observé chez CORRDIFF et la cGAN néo-zélandaise, ce qui confirme que la cause est l’*information manquante* en entrée et non un défaut de la causalisation : aucun des trois modèles ne dispose de la topographie à 5 km. Une révision à venir doit donc inclure le DEM HR comme nœud SP_HR statique du graphe ; le mécanisme d’acheminement causal est déjà en place pour cela (cf. chapitre III).

Tableau XII – *Variables atmosphériques non incluses dans l’ensemble des prédicteurs LR : rôle physique, raison d’exclusion, gain attendu.*

Variable	Rôle physique	Pourquoi exclue	Gain attendu
MSLP	Distingue fronts dynamiques des hautes pressions	Parcimonie + alignement CORRDIFF	Mieux séparer pluies frontales et convectives
IVT	Diagnostic rivières atmosphériques (~ 50% des extrêmes côte ouest NZ)	Non disponible dans sous-ensemble ERA5 utilisé	Améliorer fortement les queues hautes
SST	Flux de chaleur latente et CAPE de surface	Hors emprise terrestre	Stationnarité saisonnière
CAPE / CIN	Instabilité convective	Hors variables ERA5 single-level téléchargées	Mieux capturer pics RX1day d’été

Limites assumées et périmètre de validité. Le mémoire ne démontre ni un DAG identifié au sens de Pearl ($Q_{\text{phys}} = 0,40$, magnitudes plates), ni une robustesse OOD climatique réelle (test SSP5-8.5 à effectuer), ni la transférabilité géographique (aucune donnée africaine, donc aucun test direct sur le climat tropical visé comme cible appli-

cative finale). S’y ajoutent un seul seed d’entraînement — la variance d’estimation par initialisation reste à mesurer —, des magnitudes interventionnelles trois ordres de grandeur sous le rapport de Clausius-Clapeyron, et l’absence en entrée de variables physiquement pertinentes (DEM, MSLP, IVT, SST, CAPE). La fenêtre des contributions revendiquées tient ainsi dans un périmètre étroit mais bien défini : l’architecture causale améliore la robustesse inter-GCM en régime historique sur un climat tempéré-marin à orographie marquée (la Nouvelle-Zélande comme bac à sable exigeant), sans dégrader la stabilité d’entraînement ni le réalisme des extrêmes par rapport à CORRDIFF, et sans prétendre à une identification physique du graphe appris. L’extension à des cibles tropicales et à l’évaluation en projection future constitue la suite directe du travail.

IV.8. Synthèse

Trois résultats se dégagent. L’architecture tient ses promesses structurelles : la propriété (O3) est satisfaite par construction et vérifiée empiriquement (ratio 0,87). Les gains métriques sont nets : CRPS -40% ID et -30% inter-GCM, ratio *spread-skill* multiplié par 3,5, distance spectrale divisée par 450, biais RX1day ramené de $-4,1$ à $-2,7$ mm. La frontière entre causalité architecturale et identification physique est cartographiée : le DAG appris reste plat ($Q_{\text{phys}} = 0,40$), à la limite d’identifiabilité observationnelle [?], mais la réponse interventionnelle est cohérente ($Q_{\text{int}} = 2/2$ contre $1/2$ pour la baseline). La causalité utile au downscaling probabiliste tient donc autant au couplage architectural qu’à la structure fine du graphe.

ORACLE progresse ainsi nettement sur l’axe « robustesse inter-GCM » du trilemme (cf. chapitre I) sans dégrader la stabilité d’entraînement ni le réalisme des extrêmes par rapport à CORRDIFF.

CONCLUSION GÉNÉRALE ET PERSPECTIVES

Problématique étudiée et choix méthodologiques

Ce mémoire est parti d'un constat : aucun downscaler génératif probabiliste actuel ne combine la rapidité des approches profondes avec une robustesse de principe au changement de distribution. Le paradigme à deux étages de CORRDIFF [?] stabilise l'entraînement mais son premier étage de régression générique reste vulnérable à tout déplacement de régime. Notre choix méthodologique a été de *causaliser* ce premier étage en plaçant la causalité dans la topologie du graphe de calcul plutôt que dans une régularisation de la perte — une régularisation peut être contournée par un réseau expressif, une dépendance architecturale est par construction indéfaisable.

Quatre éléments structurent la contribution : **(C1)** une architecture two-stage où la causalité est inscrite dans la topologie du chemin de calcul ; **(C2)** un réseau causal récurrent (RCN) intégrant SCM dynamique, GRU [?] et pénalité DAGMA [?] dans une seule cellule ; **(C3)** une interface inter-étages par concaténation de canaux garantissant qu'aucune information ne contourne le chemin causal (propriété O3 vérifiée empiriquement, ratio 0,87) ; **(C4)** un protocole expérimental à six familles de métriques avec deux diagnostics causaux originaux — ratio O3 et test d'intervention Q_{int} .

Analyse critique des résultats obtenus

Sur la Nouvelle-Zélande (ACCESS-CM2 en distribution ; EC-Earth3 et NorESM2-MM en inter-GCM historique), ORACLE réduit le CRPS de 40 % en distribution et de 30 % en inter-GCM par rapport à une baseline non-causale strictement comparable. Le ratio *spread-skill* passe de 0,20 à 0,69, soit un facteur 3,5 d'amélioration de la calibration d'ensemble. La distance spectrale RAPSD chute d'un facteur 450. Sur deux perturbations contrôlées, ORACLE répond avec un signe physiquement cohérent ($Q_{\text{int}} = 2/2$), là où la baseline non-causale échoue sur l'intervention thermique. L'hypothèse H2 (séparation moyenne déterministe + résidu stochastique $\rightarrow$ stabilité et calibration) est validée sans ambiguïté ; H1 (causalité $\rightarrow$ généralisation inter-GCM) est validée modérément ; H3 (O3 architectural $\rightarrow$ pas de DAG décoratif) est validée par construction.

Plusieurs limites doivent cependant être assumées explicitement :

- La matrice A_{dag} apprise reste à magnitudes uniformes ($Q_{\text{phys}} = 0,40$, équivalente à un graphe tiré dans la classe d'équivalence de Markov), conformément à la limite théorique d'identifiabilité sur données observationnelles [?] : le DAG appris est une régularisation structurelle inductive, pas une cartographie causale identifiée.
- Les magnitudes interventionnelles restent environ trois ordres de grandeur sous Clausius-Clapeyron théorique — le signe est correct, la magnitude ne l'est pas.
- Le test inter-GCM porte sur le régime historique, distinct d'un vrai test hors-distribution climatique (SSP futur à effectuer).
- Aucune donnée africaine n'est testée et la métrique F1@p99 régresse en raison d'une régularisation interne lissante.
- Les chiffres reposent sur un seul seed d'entraînement (contrainte CPU) et une taille d'ensemble modeste ($K = 12$ inter-GCM, $K = 64$ ID, contre 192 membres pour CORRDIFF).

Quelques perspectives

Cinq axes structurent la continuation, hiérarchisés par horizon temporel :

Court terme (1–2 mois). Recalibration d’ensemble post-hoc par EMOS [?] ou BMA, écartée ici pour préserver la comparabilité avec la baseline. Validation sur SSP5-8.5 : exécutable sans modification architecturale sur des données CMIP6 disponibles, ce qui transformerait un test inter-GCM historique en véritable test hors-distribution climatique.

Moyen terme (3–6 mois). Ancrage prédictif joint de type CASTLE [?], forçant chaque arête de A_{dag} à porter un signal effectif par *fine-tuning* de 25–30 époques sans changement d’architecture. Masque physique sur A_{dag} via un terme $\lambda_{\text{prior}} \|A_{\text{dag}} - \alpha G_{\text{phys}}\|^2$ pénalisant les écarts au couplage quasi-géostrophique attendu, dans la lignée du *physics-informed ML* [?].

Long terme (1–3 ans). Transfert vers l’Afrique subsaharienne, motivation finale de ce travail : *sanity-check* zéro-shot sur les Hautes Terres éthiopiennes ou le Sahel ouest avec CHIRPS comme cible HR, puis ré-entraînement sur prédicteurs adaptés (mousson, ondes d’Est, ITCZ) et DAG révisé — le prior NZ encode un couplage descendant (jet polaire), alors qu’en Afrique équatoriale la convection profonde impose un schéma ascendant (IVT $\rightarrow$ CAPE $\rightarrow$ SP_{HR}), avec ERA5 [?] comme proxy d’initialisation faute de réseau radar dense.

Ce mémoire défend que la causalité utile au downscaling probabiliste n’est pas une propriété décorative émergeant d’une régularisation, mais une contrainte architecturale à placer explicitement dans la topologie du graphe de calcul — en Nouvelle-Zélande aujourd’hui, dans les communautés d’Afrique centrale et de l’Ouest qui ont motivé ce travail demain.

ANNEXES — CHAPITRE IV

Annexe IV.A — Diagnostics ciblés (F1@p99, CDD)

Régression F1@p99 (−6,9%). La skip-connection conditionnelle avec plancher $\alpha_{\text{floor}} = 0,6$ force la voie directe (convolution + upsampling bilinéaire, lissée par construction) à contribuer jusqu’à 40%, tirant μ_{HR} vers la moyenne LR sur les pixels extrêmes. Révision future : $\alpha_{\text{floor}} \rightarrow 0,4$, hyperparamètres tail-weight modérés. *Biais CDD* (+17,95 *j*). La perte CRPS/MSE attire vers la médiane conditionnelle (sous-prédiction des *trace events*), et le seuil 1 mm/*j* est très sensible à la queue basse. Perte hybride Bernoulli-Gamma [?] renvoyée aux perspectives.

Annexe IV.B — Sensibilités directes

Tableau XIII — *Sensibilités directes par variable LR (norme du gradient moyenne, unités relatives, top 8 sur 15).*

Variable	ORACLE	Noncausal	Ratio
w_{850}	0,260	0,007	×36
t_{850}	0,118	0,006	×20
w_{500}	0,093	0,006	×15
u_{850}	0,085	0,007	×12
w_{250}	0,067	0,008	×9
t_{500}	0,060	0,009	×7
q_{850}	0,047	0,006	×8
v_{850}	0,044	0,007	×7

ORACLE mobilise les entrées avec une amplitude 5 à 36 fois supérieure à la baseline. La hiérarchie est physiquement cohérente : w_{850}

(forçage convectif) dominante, puis t_{850} (capacité hygrométrique), u_{850} (advection) — les variables identifiées comme dominantes en downscaling de précipitation par la littérature climatologique. Argument indirect de pertinence physique du conditionnement appris, malgré la structure plate de A_{dag} .

Annexe IV.D — Analyse causale étendue

La Fig. ?? cartographie la réponse aux perturbations contrôlées $\Delta q + 20\%$ et $\Delta t + 3$ K. La comparaison entre le DAG appris A_{dag} et le DAG physique de référence (couplage quasi-géostrophique descendant) est disponible dans `results/v5_evaluation/phase11_causal_advanced/` : deux arêtes sur cinq physiquement attendues sont correctement orientées ($Q_{\text{phys}} = 0,40$).




Figure 13 — Cartes des perturbations contrôlées $\Delta q + 20\%$ et $\Delta t + 3$ K. Signes physiques cohérents avec la relation de Clausius-Clapeyron sur les deux perturbations testées.




Figure 14 — Biais sur l'indice *RX1day* pour ORACLE. Le déficit, concentré sur le versant occidental des Southern Alps, révèle l'absence d'orographie HR (DEM) en entrée — même schéma spatial sur CORDDIFF, donc la cause est l'information manquante, pas la causalisation.

Annexe IV.E — Métriques climato complémentaires

Diagnostics climato standards : la distribution log-log des intensités confirme que ORACLE reproduit la queue droite tandis que CORDDIFF coupe à ~ 30 mm/j ; le *Fractions Skill Score* indique que ORACLE est *skillful* à l'échelle ~ 30 km, contre ~ 80 km pour CORDDIFF. Figures correspondantes disponibles dans `results/v5_evaluation/phase9_climate_star`

BIBLIOGRAPHIE

- [1] K. Bello, B. Aragam, and P. Ravikumar. DAGMA : Learning DAGs via M-matrices and a log-determinant acyclicity characterization. In *Advances in Neural Information Processing Systems*, 2022.
- [2] K. Cho, B. van Merriënboer, C. Gulcehre, D. Bahdanau, F. Bougares, H. Schwenk, and Y. Bengio. Learning phrase representations using RNN encoder-decoder for statistical machine translation. In *EMNLP*, 2014.
- [3] V. Eyring, S. Bony, G. A. Meehl, C. A. Senior, B. Stevens, R. J. Stouffer, and K. E. Taylor. Overview of the Coupled Model Intercomparison Project Phase 6 (CMIP6) experimental design and organization. *Geoscientific Model Development*, 9 :1937–1958, 2016.
- [4] I. Goodfellow, J. Pouget-Abadie, M. Mirza, B. Xu, D. Warde-Farley, S. Ozair, A. Courville, and Y. Bengio. Generative adversarial nets. In *NeurIPS*, 2014.
- [5] W. L. Hamilton, R. Ying, and J. Leskovec. Inductive representation learning on large graphs. In *NeurIPS*, 2017.
- [6] L. Harris, A. T. T. McRae, M. Chantry, P. D. Dueben, and T. N. Palmer. A generative deep learning approach to stochastic downscaling of precipitation forecasts. *Journal of Advances in Modeling Earth Systems*, 14(10) :e2022MS003120, 2022.
- [7] H. Hersbach et al. The ERA5 global reanalysis. *Quarterly Journal of the Royal Meteorological Society*, 146 :1999–2049, 2020.

- [8] J. Ho, A. Jain, and P. Abbeel. Denoising diffusion probabilistic models. In *Advances in Neural Information Processing Systems*, 2020.
- [9] IPCC. *Climate Change 2021 : The Physical Science Basis. Contribution of Working Group I to the Sixth Assessment Report of the Intergovernmental Panel on Climate Change*. Cambridge University Press, 2021.
- [10] T. Karras, M. Aittala, T. Aila, and S. Laine. Elucidating the design space of diffusion-based generative models. In *Advances in Neural Information Processing Systems*, 2022.
- [11] D. P. Kingma and M. Welling. Auto-encoding variational Bayes. In *ICLR*, 2014.
- [12] R. Lam et al. Learning skillful medium-range global weather forecasting. *Science*, 382(6677) :1416-1421, 2023.
- [13] Y. Lipman, R. T. Q. Chen, H. Ben-Hamu, M. Nickel, and M. Le. Flow matching for generative modeling. In *ICLR*, 2023.
- [14] D. Maraun and M. Widmann. *Statistical Downscaling and Bias Correction for Climate Research*. Cambridge University Press, 2018.
- [15] M. Mardani, N. Brenowitz, Y. Cohen, J. Pathak, C.-Y. Chen, C.-C. Liu, A. Vahdat, K. Kashinath, J. Kautz, and M. Pritchard. Residual corrective diffusion modeling for km-scale atmospheric downscaling. *arXiv preprint arXiv :2309.15214*, 2023.
- [16] M. Mirza and S. Osindero. Conditional generative adversarial nets. *arXiv preprint arXiv :1411.1784*, 2014.
- [17] T. Nguyen, J. Brandstetter, A. Kapoor, J. K. Gupta, and A. Grover. ClimaX : A foundation model for weather and climate. In *ICML*, 2023.

- [18] J. Pearl and D. Mackenzie. *The Book of Why : The New Science of Cause and Effect*. Basic Books, 2018.
- [19] J. Pearl. *Causality : Models, Reasoning, and Inference*. Cambridge University Press, 2nd edition, 2009.
- [20] I. Price et al. GenCast : Diffusion-based ensemble forecasting for medium-range weather. *arXiv preprint*, 2024.
- [21] N. Rampal, P. B. Gibson, S. Hobeichi, J. Sherwood, and S. B. Power. Reliable generative downscaling of climate data with conditional GANs. *Journal of Advances in Modeling Earth Systems*, 2024.
- [22] O. Ronneberger, P. Fischer, and T. Brox. U-Net : Convolutional networks for biomedical image segmentation. In *MICCAI*, 2015.
- [23] T. Vandal, E. Kodra, S. Ganguly, A. Michaelis, R. Nemani, and A. R. Ganguly. DeepSD : Generating high resolution climate change projections through single image super-resolution. In *Proceedings of the 23rd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, 2017.
- [24] X. Zheng, B. Aragam, P. Ravikumar, and E. P. Xing. DAGs with NO TEARS : Continuous optimization for structure learning. In *NeurIPS*, 2018.
- [25] I. Loshchilov and F. Hutter. Decoupled weight decay regularization. In *ICLR*, 2019.
- [26] V. Fortin, M. Abaza, F. Anctil, and R. Turcotte. Why should ensemble spread match the RMSE of the ensemble mean ? *Journal of Hydrometeorology*, 15(4) :1708–1713, 2014.
- [27] X. Zhang, L. Alexander, G. C. Hegerl, et al. Indices for monitoring changes in extremes based on daily temperature and precipitation data. *WIREs Climate Change*, 2(6) :851–870, 2011.

- [28] T. Kyono, Y. Zhang, and M. van der Schaar. CASTLE : Regularization via auxiliary causal graph discovery. In *Advances in Neural Information Processing Systems*, 2020.
- [29] G. E. Karniadakis, I. G. Kevrekidis, L. Lu, P. Perdikaris, S. Wang, and L. Yang. Physics-informed machine learning. *Nature Reviews Physics*, 3 :422–440, 2021.
- [30] T. Gneiting, A. E. Raftery, A. H. Westveld, and T. Goldman. Calibrated probabilistic forecasting using ensemble model output statistics and minimum CRPS estimation. *Monthly Weather Review*, 133(5) :1098–1118, 2005.
- [31] World Bank. *Cameroon Country Climate and Development Report (CCDR)*. World Bank Group, 2022.
- [32] OCHA / WFP. *Cameroon Far-North Floods Situation Reports*. ReliefWeb, octobre 2024.
- [33] R. M. Nonki, A. Lenouo, et al. Impact of climate change on hydropower potential of the Lagdo dam, Benue River Basin, Northern Cameroon. *Proceedings of IAHS*, 384 :337–342, 2021.
- [34] C. H. Trisos, I. O. Adelekan, E. Totin, et al. Africa. In *IPCC AR6 Working Group II Report*, Cambridge University Press, 2022.
- [35] K. Bachmann et al. Discovering HPC resources in Africa. In *PEARC’25*, ACM, 2025.
- [36] S. Hobeichi et al. Using machine learning to cut the cost of dynamical downscaling. *Earth’s Future*, 11 :e2022EF003291, 2023.
- [37] A. Doury, S. Somot, et al. Regional climate model emulator based on deep learning : concept and first evaluation. *Climate Dynamics*, 60 :1751–1779, 2023.

- [38] J. González-Abad et al. Multi-variable hard physical constraints for climate model downscaling. In *AAAI Fall Symposium FSS-23*, 2023.