

RÉPUBLIQUE DU CAMEROUN

PAIX – TRAVAIL – PATRIE

UNIVERSITÉ DE DSCHANG

ÉCOLE DES SCIENCES ET
TECHNOLOGIES DE DSCHANG



REPUBLIC OF CAMEROON

PEACE – WORK – FATHERLAND

UNIVERSITY OF DSCHANG

SCHOOL OF SCIENCES AND
TECHNOLOGIES OF DSCHANG

UNITÉ DE RECHERCHE EN INFORMATIQUE FONDAMENTALE,
INGÉNIERIE ET APPLICATIONS (URIFIA)

THÈME :

**Développement d'une méthode
d'apprentissage automatique
pour la mise à l'échelle spatiale
des données climatiques**

Mémoire présenté en vue de l'obtention du diplôme de

Master en Informatique

Option : *Informatique Fondamentale*

Spécialisation : *Intelligence Artificielle*

Par

KENFACK Leonel

Matricule : *CM-UDS-17SCI0998*

Licence de Technologie

Sous la direction de :

Pr BOMGNI Alain Bertrand

Maître de Conférences, Université de Dschang

Année académique 2025–2026

DÉDICACE

*À mes parents,
dont la patience et le soutien constant ont rendu possible
ce parcours d'études supérieures.*

REMERCIEMENTS

Je tiens à remercier **Dieu Tout-Puissant**, sans qui rien n'aurait été possible. J'adresse toute ma gratitude à mon encadreur, **Pr BOMGNI Alain Bertrand**, pour sa patience, sa disponibilité et surtout ses judicieux conseils, qui ont contribué à alimenter ma réflexion. Je lui suis particulièrement reconnaissant de m'avoir mis à disposition le serveur de calcul qui a rendu possible l'ensemble des phases exploratoires de ce travail.

En témoignage de ma gratitude et de mon profond respect, j'adresse mes vifs et sincères remerciements :

- À tous les **membres du jury**, pour l'honneur qu'ils m'accordent en appréciant ce travail ;
- À tous les **enseignants du département de Mathématiques-Informatique** de l'Université de Dschang, qui m'ont fourni les outils nécessaires à la réussite de mes études universitaires ;
- À mes **frères et sœurs** pour l'attention permanente, le soutien multiforme et les encouragements ;
- À tous les **membres de ma famille** qui ont cru en moi et m'ont soutenu tant moralement que physiquement pour l'atteinte de cet objectif ;
- À tous mes **camarades de promotion de Master 2 Recherche** pour les discussions que nous avons partagées ;
- À tous mes **aînés académiques** qui m'ont toujours soutenu, conseillé et qui m'ont donné le courage d'avancer dans les recherches ;
- À toutes les **personnes** qui ont participé, de près ou de loin, à l'élaboration de ce mémoire. Je vous serai éternellement reconnaissant.

TABLE DES MATIÈRES

Dédicace	ii
Remerciements	iii
Liste des Acronymes	ix
Liste des Tableaux	xi
Liste des Figures	xii
Résumé	xiii
Abstract	xv
Introduction générale	1
Contexte du travail	1
Problématique étudiée	2
Objectifs	4
Contribution	5
Organisation du manuscrit	7
Chapitre I ► Fondements du downscaling climatique	8
I.1 - Introduction	8
I.2 - Contexte climatique et besoin de désagrégation	9
I.2.1 - Modèles climatiques globaux et régionaux	9
I.2.2 - Cas de la précipitation	10
I.3 - Données climatiques et leurs propriétés	10

I.3.1 - Sources de données et formats	10
I.3.2 - Propriétés statistiques de la précipitation	11
I.3.3 - Sources d'incertitude et nécessité d'un cadre probabiliste	12
I.4 - Approches classiques de downscaling	12
I.4.1 - Désagrégation spatiale	13
I.4.2 - Désagrégation temporelle	13
I.5 - Approches probabilistes et génératives	14
I.5.1 - Du déterministe au probabiliste	14
I.5.2 - Modèles génératifs adversariaux	14
I.5.3 - Modèles de diffusion	14
I.5.4 - Le paradigme deux étages : CorrDiff	15
I.6 - Causalité et modèles structurels	16
I.6.1 - Pourquoi la causalité en downscaling climatique . . .	16
I.6.2 - Modèles causaux structurels et graphes acycliques dirigés	17
I.6.3 - Intervention, identifiabilité et lien avec le downscaling	17
I.7 - Verrous scientifiques et trilemme	20
I.7.1 - Verrou 1 : stabilité d'entraînement	20
I.7.2 - Verrou 2 : réalisme des extrêmes et sub-dispersion .	20
I.7.3 - Verrou 3 : robustesse hors-distribution	20
I.7.4 - Trilemme et positionnement d'ORACLE	21
I.8 - Synthèse	22
 <i>Chapitre II ► État de l'art du downscaling par apprentissage profond</i>	 24
II.1 - Introduction	24
II.2 - Approches déterministes	25
II.2.1 - Régression statistique classique	25
II.2.2 - Réseaux convolutifs et super-résolution	26
II.3 - Approches probabilistes adversariales	26
II.3.1 - Réseaux antagonistes génératifs conditionnels . . .	26
II.3.2 - cGAN résiduel pour le downscaling climatique . . .	27

II.3.3 - Limites empiriques des cGAN appliqués au down- casing	27
II.4 - Approches à vraisemblance explicite	27
II.5 - Modèles de diffusion	28
II.5.1 - Denoising Diffusion Probabilistic Models	28
II.5.2 - Formalisme EDM de Karras et al.	28
II.5.3 - Premières applications au climat : SR3, ResShift, ResDiff	29
II.6 - Le paradigme à deux étages : CorrDiff	29
II.6.1 - Idée fondatrice	29
II.6.2 - Architecture détaillée	30
II.6.3 - Forces du paradigme à deux étages	30
II.6.4 - Limites identifiées de CorrDiff	31
II.6.5 - Le piège du conditionnement par cross-attention . .	31
II.6.6 - Pourquoi CorrDiff plutôt que SR3 ?	32
II.6.7 - Reformulation du paradigme deux étages dans le lan- gage probabiliste	33
II.7 - Fonctions de perte et contraintes physiques	33
II.7.1 - Pertes adaptées à la précipitation	33
II.7.2 - Contraintes physiques et explicabilité	34
II.8 - Cadres d'évaluation et foundation models	35
II.8.1 - Benchmarks standardisés	35
II.8.2 - Foundation models climat	35
II.9 - Synthèse, tableau comparatif et gap scientifique	36
II.9.1 - Tableau comparatif modèle × verrou	36
II.9.2 - Gap scientifique	37
II.9.3 - Positionnement d'Oracle dans le paysage	37
Chapitre III ► Proposition : Oracle, architecture causale à deux étages	39
III.1 - Introduction	39
III.2 - Vue d'ensemble et différence avec CorrDiff	41

III.3 - Graphe atmosphérique hétérogène	42
III.3.1 - Types de nœuds et hiérarchie verticale	42
III.3.2 - Types d'arêtes et physique encodée	42
III.3.3 - Drivers statiques et acheminement causal	44
III.4 - Encodeur intelligible et réseau causal récurrent	44
III.4.1 - Motivation : préserver l'identité physique des variables	44
III.4.2 - Architecture par variable et normalisation	44
III.4.3 - Réseau causal récurrent : SCM dynamique et mise à jour temporelle	45
III.4.4 - Équations SCM et mise à jour GRU	46
III.5 - Apprentissage du DAG par contrainte DAGMA	46
III.6 - Décodeur graphe-à-grille et moyenne haute résolution . .	47
III.7 - Interface inter-étages et propriété (O3)	48
III.7.1 - Pré-calcul, cache et recalibration de σ_{data}	48
III.7.2 - Définition formelle de la propriété (O3)	48
III.7.3 - Étage 2 : paradigme EDM et conditionnement par concaténation	49
III.8 - Pertes composites et entraînement	50
III.9 - Synthèse, traçabilité et choix non retenus	51
Chapitre IV ► Matériels, méthodes, expérimentations et discussion	52
IV.1 - Introduction	52
IV.2 - Environnement et données	53
IV.2.1 - Pile logicielle et matériel	53
IV.2.2 - Données et prétraitements	53
IV.3 - Topologie effective d'ORACLE	55
IV.3.1 - Premier étage : encodeur, RCN, décodeur	56
IV.3.2 - Second étage : UNet EDM	56
IV.4 - Trajectoire et procédure d'entraînement	57
IV.4.1 - Trajectoire des versions et leçons retenues	57
IV.4.2 - Procédure two-stage et sampler à l'inférence	58
IV.5 - Protocole d'évaluation	59

IV.6 - Résultats observés	60
IV.6.1 - Performance en distribution	60
IV.6.2 - Calibration probabiliste	61
IV.6.3 - Indices climatiques et extrêmes	62
IV.6.4 - Robustesse inter-GCM en régime historique	63
IV.6.5 - Diagnostics causaux	65
IV.7 - Discussion critique	67
IV.8 - Perspectives d'amélioration	72
IV.9 - Synthèse	73
Conclusion générale et perspectives	75
Problématique étudiée et choix méthodologiques	75
Analyse critique des résultats obtenus	76
Quelques perspectives	77
Bibliographie	79
<i>Annexe A</i> ► Diagnostics et métriques complémentaires	84
<i>Annexe B</i> ► Analyses causales complémentaires	86

LISTE DES ACRONYMES

ACCESS-CM2	GCM australien utilisé en distribution (CMIP6)
BMA	<i>Bayesian Model Averaging</i> , recalibration d'ensemble
CASTLE	<i>Causal Structure Learning via Auxiliary Causal Graph Discovery</i>
CC	Clausius-Clapeyron, relation vapeur saturante / température
CDD	<i>Consecutive Dry Days</i> , jours secs consécutifs (ETCCDI)
cGAN	<i>Conditional Generative Adversarial Network</i>
CHIRPS	<i>Climate Hazards group InfraRed Precipitation with Station data</i>
CMIP6	<i>Coupled Model Intercomparison Project Phase 6</i>
CORRDIFF	Architecture two-stage de diffusion résiduelle (Mardani 2024)
CRPS / CRPS-SS	<i>Continuous Ranked Probability Score</i> et son skill score
DAG	<i>Directed Acyclic Graph</i> , graphe acyclique dirigé
DAGMA	<i>DAG via M-matrices and log-determinant Acyclicity</i>
DDPM / EDM	<i>Denoising Diffusion Probabilistic Models / EDM</i> (Karras 2022)
EC-Earth3, NorESM2-MM	GCM extérieurs du test inter-GCM (régime historique)
EMOS	<i>Ensemble Model Output Statistics</i> , recalibration post-hoc (Gneiting 2005)
ERA5	Réanalyse atmosphérique de référence (Hersbach 2020)
ETCCDI	<i>Expert Team on Climate Change Detection and Indices</i>
F1@p95/p99	Score F1 sur les pixels excédant le quantile p95 ou p99
FSS	<i>Fractions Skill Score</i>
GAN	<i>Generative Adversarial Network</i>
GCM / RCM	Modèle de circulation générale / modèle climatique régional
GIEC / IPCC	Groupe d'experts intergouvernemental sur l'évolution du climat

GP	Géopotentiel, à différents niveaux de pression (GP850, GP500, GP250)
GRU	<i>Gated Recurrent Unit</i> (Cho 2014)
HG-SCM	<i>Heterogeneous Graph Structural Causal Model</i> (Lin et al. 2023)
HR / LR	Haute / basse résolution
ID / OOD	En distribution / hors-distribution
IG	<i>Integrated Gradients</i>
ITCZ	Zone de convergence intertropicale (<i>InterTropical Convergence Zone</i>)
IVT	<i>Integrated Vapour Transport</i> , transport intégré de vapeur d'eau
MAE / MSE / RMSE	Erreurs ponctuelles standards
ORACLE	<i>Out-of-distribution Robust Atmospheric Causal Learning Engine for Climate Downscaling</i> (modèle proposé dans ce mémoire)
$Q_{\text{int}}, Q_{\text{phys}}$	Score interventionnel / orientation physique du DAG
RAPSD / PSD	<i>Power Spectral Density</i> radialement moyennée
RCN	<i>Recurrent Causal Network</i> , réseau causal récurrent
R10mm / RX1day	Indices ETCCDI sur la précipitation
SCM	<i>Structural Causal Model</i> (Pearl)
SSP	<i>Shared Socioeconomic Pathway</i> , scénario CMIP6
UNet	Architecture U pour segmentation et diffusion (Ronneberger 2015)
URIFIA	Unité de Recherche d'Informatique Fondamentale et Appliquée

LISTE DES TABLEAUX

I - Fonctions de perte	34
II - Approches du downscaling vs verrous	36
III - Notations principales.	40
IV - Traçabilité des composants	51
V - Variables LR utilisées	55
VI - Métriques en distribution	61
VII - Métriques probabilistes	61
VIII - Biais sur indices ETCCDI	62
IX - Métriques inter-GCM	63
X - Réponse aux perturbations contrôlées	65
XI - Ablation du DAG à protocole fixé	68
XII - Compromis skill vs fidélité causale : 6 vs 9 nœuds	69
XIII - Variables atmosphériques omises	71
XIV - Sensibilités directes par variable	85
XV - Arêtes du DAG à 9 nœuds	89

LISTE DES FIGURES

1 - Paradigme deux étages CorrDiff	15
2 - Trilemme du downscaling génératif	21
3 - Cartouche conceptuel d'Oracle	22
4 - Frise chronologique du downscaling	25
5 - Architecture UNet hiérarchique de CorrDiff	30
6 - Cartouche revisité d'Oracle	38
7 - Vue d'ensemble d'Oracle	41
8 - Graphe atmosphérique hétérogène	43
9 - Pipeline architectural d'Oracle	55
10 - Diagrammes de fiabilité	62
11 - Courbes Gumbel période de retour	63
12 - Integrated Gradients par variable	66
13 - Cartes des perturbations contrôlées	86
14 - Biais RX1day d'Oracle	87
15 - DAG appris à 9 nœuds	88

RÉSUMÉ

Les modèles climatiques mondiaux projettent le climat sur plusieurs décennies, mais leurs cartes sont très grossières : chaque point y résume une zone d'environ deux cents kilomètres de côté, où une ville et une montagne reçoivent la même valeur. Or les décisions concrètes (se protéger des inondations, gérer l'eau, planifier les cultures) exigent le détail local. Reconstruire la carte fine à partir de la carte grossière, c'est la mise à l'échelle spatiale, ou *downscaling*.

Deux familles de solutions existent. La première rejoue la physique sur une région réduite : fidèle, mais d'un coût de calcul hors de portée de nombreux pays. La seconde confie la tâche à l'apprentissage automatique, qui apprend sur des archives la correspondance entre cartes grossières et fines. Rapide et précise, cette voie retient toutefois des coïncidences plutôt que des causes : quand le climat change, elles se brisent et le modèle échoue là où l'on en a le plus besoin.

Ce mémoire propose ORACLE, un modèle construit pour raisonner en causes et effets plutôt qu'en ressemblances : l'information doit traverser un schéma explicite de relations physiques (l'humidité et les vents qui produisent la pluie, le relief qui la renforce), avant qu'un second module n'ajoute les détails fins et une marge d'incertitude honnête.

Testé en Nouvelle-Zélande, ORACLE réduit d'environ 40 % l'erreur de reconstruction de la référence, le meilleur modèle comparable, et de près de 30 % sur des modèles climatiques jamais vus à l'apprentissage. Sa marge d'incertitude devient 3,5 fois plus fiable et le détail de ses cartes rejoint celui des observations. Quand on augmente artificiellement la température ou l'humidité, il réagit dans le sens prévu par la physique, là où la référence se trompe. Ces résultats valent pour le climat des dernières décennies ; la robustesse à un climat plus chaud reste à démontrer.

Mots-clés : mise à l'échelle spatiale (*downscaling*), apprentissage automatique, causalité, précipitations, incertitude, changement climatique.

DEVELOPMENT OF A MACHINE LEARNING METHOD FOR SPATIAL DOWNSCALING OF CLIMATE DATA

ABSTRACT

Global climate models project the climate several decades ahead, but their maps are very coarse : each point summarises an area roughly two hundred kilometres across, in which a city and a mountain receive the same value. Yet practical decisions (protecting against floods, managing water, planning crops) require local detail. Rebuilding the fine map from the coarse one is called spatial downscaling.

Two families of solutions exist. The first replays physics over a smaller region : faithful, but at a computational cost out of reach for many countries. The second relies on machine learning, which learns from archives the correspondence between coarse and fine maps. Fast and accurate, this route nevertheless memorises coincidences rather than causes : when the climate changes, they break down and the model fails where it is needed most.

This thesis proposes ORACLE, a model built to reason in causes and effects rather than resemblances : the information must flow through an explicit diagram of physical relations (the moisture and winds that produce rain, the terrain that strengthens it), before a second module adds the fine details and an honest uncertainty margin.

Tested over New Zealand, ORACLE reduces the reconstruction error of the reference, the best comparable model, by about 40%, and by nearly 30% on climate models never seen during training. Its uncertainty margin becomes 3.5 times more reliable, and the detail of its maps matches that of observations. When temperature or moisture is artificially increased, it responds in the direction predicted by physics, where the reference gets it wrong. These results hold for the climate of recent decades ; robustness to a warmer climate is still to be demonstrated.

Keywords : spatial downscaling, machine learning, causality, precipitation, uncertainty, climate change.

INTRODUCTION GÉNÉRALE

SOMMAIRE

Contexte du travail	1
Problématique étudiée	2
Objectifs	4
Contribution	5
Organisation du manuscrit	7

Contexte du travail

Le changement climatique impose aux décideurs locaux des choix de plus en plus fins en matière d'agriculture, de gestion de l'eau et d'urbanisme. Au Cameroun, l'agriculture représente environ 22 % du PIB et fait vivre près de 44 % de la population active [31] : un secteur très majoritairement pluvial dont la planification dépend directement de la qualité des projections climatiques locales. La centrale hydroélectrique de Lagdo fournit environ 74 % de l'électricité du Nord-Cameroun [33]. Les inondations de l'Extrême-Nord d'octobre 2024 ont affecté 356 000 personnes et noyé 82 500 hectares de cultures, sans qu'aucune anticipation communale n'ait été possible [32]. À l'échelle continentale, le changement climatique a réduit d'environ 34 % la croissance de la productivité agricole africaine depuis 1961, soit le frein le plus fort toutes régions confon-

dues [34]; en l'absence d'adaptation, la Banque mondiale estime que le Cameroun pourrait perdre entre 4 et 10 % de son PIB d'ici 2050 [31].

Pour anticiper ces risques, la communauté scientifique s'appuie sur des modèles climatiques globaux (GCM) : des programmes qui simulent l'atmosphère de la planète entière sur plusieurs décennies. Leur limite est le manque de finesse : chaque point de leur grille résume une zone de 100 à 250 km de côté [3]. À cette échelle, Douala et Yaoundé occupent la même cellule, le mont Cameroun n'a aucun effet, la transition savane-forêt disparaît. Pour utiliser ces simulations dans des décisions d'aménagement, d'agriculture ou d'énergie, il faut donc reconstruire l'information à une échelle plus fine (1 à 12 km) : c'est la descente d'échelle climatique (*downscaling*). Deux familles coexistent. La descente d'échelle *dynamique* emboîte dans le GCM un modèle régional (RCM) qui rejoue les équations de la physique, sur la seule région d'intérêt, à une maille plus fine [14] : rigoureuse, mais très coûteuse en calcul. La descente d'échelle *statistique* apprend, à partir d'archives, la correspondance entre cartes grossières et cartes fines ; elle repose aujourd'hui sur l'apprentissage profond, cette branche de l'intelligence artificielle qui empile de nombreuses couches de calcul pour capturer des relations complexes. Moins coûteuse, elle se heurte en revanche à trois limites : on comprend mal ce qu'elle a appris (interprétabilité), elle se dégrade sur des conditions éloignées de celles de l'apprentissage (généralisation dite hors-distribution) et rien ne l'empêche de violer la physique. C'est dans cette seconde voie que s'inscrit le présent mémoire.

Problématique étudiée

Trois verrous rendent aujourd'hui ces deux familles inadaptées à un déploiement africain : un verrou de coût pour la voie dynamique, et pour la voie statistique, deux verrous correspondant à ses deux générations de méthodes, les émulateurs déterministes de première génération puis les modèles génératifs à deux étages qui leur ont succédé.

Premier verrou, le coût de calcul de la voie dynamique est hors de portée pour la plupart des pays africains. Un exemple fixe l'ordre de grandeur : la configuration régionale utilisée à Taïwan (CWA-WRF) mobilise 928 cœurs de calcul en parallèle [15]. À budget fixe, on ne descend donc qu'un seul scénario à la fois, et les grands exercices internationaux de régionalisation (CORDEX) restent à des mailles de 12–50 km. Or les applications de risque (assurance paramétrique, où l'indemnisation se déclenche automatiquement dès qu'un seuil météorologique mesuré est franchi ; planification d'urgence) demandent des milliers de simulations parallèles pour couvrir l'éventail des futurs possibles, ce que l'on appelle des membres d'ensemble [36]. Pour un continent qui héberge moins de 1 % des capacités mondiales de calcul haute performance [35], ce paradigme exclut de facto la production locale de projections fines.

Deuxième verrou, du côté statistique : les émulateurs déterministes de première génération, des réseaux de neurones entraînés à reproduire une simulation physique, restent opaques (on comprend mal ce qu'ils ont appris) et rien ne les empêche de violer les lois physiques qu'ils imitent, puisqu'ils optimisent un score plutôt qu'une contrainte physique. González-Abad et al. [38] montrent ainsi que des réseaux convolutifs (CNN) entraînés séparément sur la température minimale et la température maximale produisent des sorties physiquement impossibles ($T_{\min} > T_{\max}$), à un taux qui passe de 4 % sur les données d'apprentissage à 15–17 % en projection 2100 sous un scénario de fort réchauffement (RCP8.5). Doury et al. [37] qualifient leur propre émulateur de « *black-box regression model* » (modèle de régression boîte noire) et montrent que 31 ré-entraînements identiques du même réseau produisent des erreurs sur la climatologie future variant d'un facteur 46 sous l'effet du seul hasard de l'initialisation.

Troisième verrou, plus récent : les modèles génératifs (qui produisent des réalisations plausibles plutôt qu'une valeur unique) à deux étages ont résolu l'opacité de la génération précédente, mais reposent sur une hypothèse tout aussi fragile. La référence actuelle, CorrDiff [15], découpe

la tâche en deux temps : une première étape prédit la partie prévisible du champ fin (sa moyenne), puis une seconde étape génère les détails restants, appelés le résidu, par un procédé stochastique (c'est-à-dire aléatoire) nommé diffusion [10] que le chapitre II détaillera. Le tout est environ 60 fois plus rapide qu'une simulation physique. Toutefois, les auteurs identifient eux-mêmes la difficulté centrale : un *significant distribution shift* (décalage substantiel de distribution) entre les données d'entraînement et les conditions d'usage. Toute la construction suppose en effet que la relation entre cartes grossières et cartes fines reste stable dans le temps (hypothèse de stationnarité) : c'est précisément la généralisation hors-distribution déjà signalée plus haut, et c'est ce que le changement climatique invalide par construction.

Le problème central s'énonce donc ainsi : *comment causaliser le premier étage du paradigme à deux étages pour doter le downscaling probabiliste d'une robustesse de principe au changement de distribution, sans dégrader la stabilité ni le réalisme acquis ?* Par « causaliser », nous entendons remplacer l'estimateur générique de ce premier étage par un module dont la sortie transite obligatoirement par un graphe de relations de cause à effet appris ; le terme est repris dans ce sens tout au long du mémoire.

Objectifs

Au regard de cette problématique, notre objectif principal est de proposer une architecture de descente d'échelle probabiliste dont les prédictions passent obligatoirement par des relations de cause à effet apprises, plutôt que par de simples associations statistiques. Plus spécifiquement, nous voulons :

- Concevoir le module qui porte cette causalité : un réseau récurrent (appliqué pas de temps par pas de temps) où chaque variable atmosphérique n'est influencée que par ses causes, identifiées dans un graphe appris sous contrainte d'absence de boucle (les outils correspondants, le modèle causal structurel SCM [19], la cellule récurrente GRU [2] et

la contrainte d’acyclicité DAGMA [1], sont introduits progressivement aux chapitres I et III) ;

- Inscrire ce module dans le paradigme à deux étages de CorrDiff [15], en remplaçant uniquement la première étape (la régression générique) par ce chemin causal, sans modifier l’étape de diffusion [10] : toute différence mesurée sera ainsi attribuable à la causalité et à elle seule ;
- Définir un protocole expérimental qui juge à la fois la justesse des prévisions, la fiabilité de leur incertitude, le réalisme des extrêmes et la robustesse face à des modèles climatiques jamais vus, complété par un test original dans le contexte du downscaling par apprentissage profond : perturber volontairement une entrée et vérifier que la réponse du modèle suit le sens prévu par la physique.

Contribution

La contribution principale de ce mémoire réside dans la conception, l’implémentation et l’évaluation d’ORACLE, une architecture générative à deux étages qui conserve les avantages des modèles résiduels (stabilité, calibration probabiliste au sens de la fiabilité des incertitudes annoncées, efficacité) et y ajoute une garantie structurelle de causalité. Quatre choix la structurent, auxquels nous nous référerons par les étiquettes (C1) à (C4) dans la suite du manuscrit :

- (C1) Le placement de la causalité dans l’architecture elle-même plutôt que dans une pénalité d’entraînement : une pénalité peut être contournée par un réseau suffisamment expressif, alors qu’un chemin câblé dans la structure du calcul est, par construction, incontournable.
- (C2) Le réseau causal récurrent (RCN), qui réunit dans une même cellule la prédiction de chaque variable par ses causes et sa mise à jour au fil du temps (chapitre III).
- (C3) Une interface entre les deux étages conçue pour qu’aucune information ne contourne le chemin causal. Cette indispensabilité du

graphe, que nous nommons propriété O3 (le troisième des six objectifs de conception d'ORACLE, la causalité architecturale, énoncés au chapitre III), est vérifiée empiriquement : couper le graphe modifie la sortie de 87 % de son amplitude.

- (C4) Un protocole expérimental à six familles de métriques, dont deux diagnostics causaux originaux : le ratio O3 (le graphe sert-il réellement au calcul ?) et le test d'intervention Q_{int} (le modèle répond-il dans le sens de la physique quand on force une de ses entrées ?).

Faute d'un jeu de données de référence à haute résolution sur le continent africain visé, nous éprouvons la méthode sur la Nouvelle-Zélande, un *bac à sable* exigeant : un terrain de test qui n'est pas la cible finale, mais qui la remplace avantageusement pour valider la méthode, car il concentre volontairement des conditions extrêmes. Rampal et al. [21] l'ont retenue pour sa diversité climatique compacte (subtropical, marin tempéré, semi-aride sous le vent, alpin sur moins de 270 000 km²) et l'un des gradients de relief les plus extrêmes au monde : des conditions qui mettent la méthode à l'épreuve plus durement qu'un terrain climatiquement plus uniforme. Ce terrain sollicite simultanément trois exigences difficiles à concilier, que ce mémoire désignera comme le trilemme : un entraînement stable, des extrêmes réalistes et une robustesse au changement de distribution. Sur ce cadre, ORACLE réduit de 40 % l'erreur de prévision probabiliste par rapport à une *baseline* (modèle de référence) non causale strictement comparable, et de 30 % face à des modèles climatiques jamais vus à l'apprentissage ; il améliore d'un facteur 3,5 la fiabilité de son estimation d'incertitude (au sens du rapport entre dispersion prédite et erreur, défini au chapitre IV) et conserve le signe physiquement correct sous deux perturbations contrôlées (il s'agit d'une cohérence de direction, non d'une identification causale complète), là où la baseline échoue sur la perturbation thermique. La dépendance de l'architecture à son graphe causal, vérifiée sur ce terrain, est une propriété structurelle : elle plaide pour une validité indépendante du climat d'entraînement. L'extension au contexte africain qui motive ce travail reste hypothétique au stade actuel,

conditionnée à la disponibilité d'un jeu de référence sur la zone visée, et portée comme axe de perspectives.

Organisation du manuscrit

Le manuscrit est structuré en quatre chapitres et une conclusion, ordonnés pour qu'aucune notion ne soit utilisée avant d'avoir été introduite :

Chapitre I, Fondements du downscaling climatique. Pose les bases accessibles à un lecteur non spécialiste : besoin de désagrégation, propriétés statistiques de la précipitation, approches classiques, passage au probabiliste et au génératif, langage mathématique de la causalité proposé par Pearl [19], et formulation du trilemme stabilité / extrêmes / robustesse hors-distribution.

Chapitre II, État de l'art du downscaling par apprentissage profond. Parcourt systématiquement les familles de modèles, chacune étant présentée avant d'être comparée : approches déterministes (CNN, U-Net), adversariales [21], à vraisemblance explicite, et de diffusion (dont les formulations DDPM [8] et EDM, précisées sur place, et CorrDiff [15]). Un tableau comparatif identifie le *gap* qui motive notre contribution.

Chapitre III, Proposition d'ORACLE. Formalise l'architecture : graphe atmosphérique à six nœuds typés, encodeur préservant l'identité de chaque variable, réseau causal récurrent sous contrainte d'acyclicité, décodeur du graphe vers la grille, interface inter-étages et diffusion résiduelle.

Chapitre IV, Matériels, méthodes, expérimentations et discussion. Couvre l'environnement, les données, la topologie effectivement entraînée, le protocole d'évaluation à six familles de métriques, les résultats et la discussion critique des limites.

Conclusion générale et perspectives. Synthétise les contributions, analyse les résultats et trace cinq axes de perspectives, dont le transfert vers le contexte africain qui constitue la motivation finale.

I

CHAPITRE

FONDEMENTS DU DOWNSCALING CLIMATIQUE

SOMMAIRE

I.1 - Introduction	8
I.2 - Contexte climatique et besoin de désagrégation	9
I.3 - Données climatiques et leurs propriétés	10
I.4 - Approches classiques de downscaling	12
I.5 - Approches probabilistes et génératives	14
I.6 - Causalité et modèles structurels	16
I.7 - Verrous scientifiques et trilemme	20
I.8 - Synthèse	22

I.1. Introduction

Les communautés d’Afrique centrale et du Cameroun planifient leur agriculture, leur gestion de l’eau et leur urbanisme sur des horizons de plus en plus courts, sous l’effet d’événements climatiques extrêmes dont la fréquence augmente [9]. Ces décisions demandent des projections au kilomètre. Les modèles climatiques globaux, coordonnés au sein du projet d’intercomparaison CMIP6 [3], ne descendent qu’à la centaine de kilomètres. L’écart entre les deux est précisément ce que le *downscaling*

climatique cherche à combler ; ce mémoire en explore une variante générative et causalisée.

Ce chapitre établit les fondements nécessaires à la compréhension de notre contribution : contexte climatique et besoin de désagrégation (section I.2), données mobilisées (section I.3), méthodes classiques (section I.4), approches probabilistes et génératives, notamment le paradigme à deux étages CORRDIFF [15] (section I.5), causalité structurelle pour ORACLE (section I.6), verrous scientifiques (section I.7) et synthèse (section I.8).

I.2. Contexte climatique et besoin de désagrégation

I.2.1. Modèles climatiques globaux et régionaux

Un **modèle climatique global** (*General Circulation Model*, GCM) est un programme qui reproduit, heure par heure, le comportement de l'atmosphère et de l'océan à l'échelle de la planète entière, en résolvant numériquement les équations physiques qui gouvernent leur mouvement. Le projet CMIP6 coordonne plus d'une centaine de ces modèles, dont ACCESS-CM2 (CSIRO, Australie) [3], pour produire des projections sur plusieurs décennies sous divers scénarios d'émissions. Leur grille de calcul reste néanmoins grossière (100 à 250 km de côté) : le coût numérique interdit de la resserrer davantage. Sous cette taille de maille, certains phénomènes (un nuage convectif, une brise côtière, le relief d'une vallée) sont plus petits que la grille elle-même et ne peuvent donc pas y être calculés directement ; le modèle les remplace alors par une formule statistique simplifiée, dite *paramétrisation*, calibrée pour reproduire leur effet moyen sans en simuler le détail. Cette approximation, nécessaire, est aussi la source des biais structurels que les GCM présentent sur la précipitation.

Un **modèle climatique régional** (RCM) applique la même démarche, mais sur un territoire restreint et à une maille plus fine (10 à 50 km), en utilisant les sorties du GCM comme conditions aux limites : le GCM fournit

l'état de l'atmosphère aux frontières de la petite région étudiée, et le RCM y résout la physique en détail à l'intérieur. Cet *emboîtement* constitue le *downscaling dynamique* et améliore le réalisme régional, mais à un coût de calcul élevé : la configuration CWA-WRF utilisée à Taïwan mobilise par exemple 928 cœurs de calcul en parallèle (processeurs SPARC64) [15], ce qui exclut les ensembles à milliers de membres requis pour les applications de risque [36]. Le passage de la grille GCM (environ 250 km) à la grille cible haute résolution (HR, environ 5 km) représente un facteur d'environ 50 par dimension, ce qui dépasse les capacités RCM accessibles aux équipes africaines.

1.2.2. Cas de la précipitation

Ce constat motive le *downscaling statistique profond*, qui apprend à partir d'un corpus historique de couples de cartes basse résolution (LR, pour *low resolution*) et haute résolution (HR) une fonction probabiliste $x_{HR} \sim p(\cdot | y_{LR})$: à une carte grossière y_{LR} donnée, le modèle associe une distribution de cartes fines x_{HR} plausibles, déployable à coût marginal une fois entraîné. Parmi les variables candidates, la **précipitation** occupe une place centrale : c'est la plus liée aux risques perçus (sécheresse, inondations, sécurité alimentaire), et la plus exigeante statistiquement du fait de sa forte intermittence, de sa queue lourde et de son hétérogénéité spatiale [14, 23]. Une méthode qui y réussit se transfère généralement aux variables plus régulières (température, pression). ORACLE est entraîné et évalué sur des précipitations quotidiennes du couple ACCESS-CM2 / Nouvelle-Zélande, terrain expérimental qui combine cible HR de qualité et baseline générative de référence dans la littérature.

1.3. Données climatiques et leurs propriétés

1.3.1. Sources de données et formats

Trois catégories alimentent le downscaling :

- Les **observations directes** (stations météorologiques) : haute qualité ponctuelle, mais couverture spatiale très inégale, particulièrement lacunaire en Afrique.
- Les **réanalyses atmosphériques**, qui assimilent observations de stations, radiosondages et satellites dans un modèle numérique : ERA5 [7] fournit des champs horaires à environ 31 km depuis 1940 et constitue la référence historique maillée.
- Les **simulations climatiques** (GCM et RCM, sorties CMIP6) couvrent la période historique 1850–2014 et des projections futures sous scénarios socio-économiques SSP (*Shared Socioeconomic Pathways*).

Les données sont distribuées au format NetCDF (conventions *Climate and Forecast*), auto-descriptif. La précipitation totale p_r est exprimée en $\text{kg/m}^2/\text{s}$ et convertie en mm/jour . Dans notre travail, ACCESS-CM2 fournit le conditionnement basse résolution et un produit régional néo-zélandais la cible HR.

1.3.2. Propriétés statistiques de la précipitation

Trois propriétés statistiques rendent la précipitation quotidienne particulièrement exigeante. L'**intermittence** d'abord : selon les régions, 50 à 80 % des jours sont sans précipitation détectable, ce qui produit une masse de probabilité en zéro qu'aucune hypothèse de variable continue ne peut accommoder. L'**asymétrie à queue lourde** ensuite : conditionnée à un jour pluvieux, l'intensité suit approximativement une loi log-normale [14]; toute méthode gaussienne sous-estime alors mécaniquement les extrêmes, c'est-à-dire les événements à fort enjeu. L'**hétérogénéité spatiale** enfin : le relief, la ligne de côte et l'occupation du sol structurent les champs de précipitation avec des gradients de plusieurs cm/km en zone de montagne, structure qui disparaît à basse résolution et que tout downscaling doit restituer. Notre pipeline expérimental (chap. IV) opère sur une grille LR 23×26 pixels (Nouvelle-Zélande) et une cible HR 172×179 .

Une lecture quantitative de ces propriétés sur le jeu d'entraînement utilisé au chapitre IV donne un ordre d'idée. Sur ACCESS-CM2 historique (1980–2009, Nouvelle-Zélande), la fraction de jours secs sur la cible haute résolution de précipitation (seuil de 1 mm/j) varie de 35 % sur la côte ouest des Alpes du Sud à 65 % dans les bassins de l'Est. Conditionnellement à un jour pluvieux, la moyenne quotidienne est d'environ 6 mm/j, mais le quantile à 99 % atteint environ 45 mm/j et le maximum observé sur la fenêtre dépasse 200 mm/j. Le ratio max/moyenne dépasse donc 30, alors qu'il vaut environ 3 pour la température : c'est cette différence d'amplitude relative qui rend la précipitation particulièrement réfractaire aux pertes quadratiques classiques.

1.3.3. Sources d'incertitude et nécessité d'un cadre probabiliste

Le downscaling agrège plusieurs sources d'incertitude qu'il convient de distinguer pour comprendre pourquoi le passage du déterministe au probabiliste n'est pas une simple question de raffinement statistique. L'**incertitude aléatoire** (*aleatoric*) est intrinsèque au caractère mal posé du problème : à une carte LR donnée correspond une famille de cartes HR plausibles, qu'aucune information supplémentaire dans les prédicteurs ne peut réduire. C'est cette composante que cherche à modéliser le résiduel stochastique d'ORACLE. L'**incertitude épistémique** (*epistemic*) reflète la connaissance limitée du modèle sur les données qu'il n'a pas vues ; elle se réduit avec plus de données ou de meilleurs modèles, et explose lors d'un déplacement de distribution. C'est précisément cette composante que la causalité structurelle vise à contenir. Un downscaler purement déterministe écrase ces deux composantes en une seule prédiction, d'où le lissage des extrêmes et la fragilité hors-distribution (OOD, pour *out-of-distribution* ; nous utiliserons cet acronyme dans la suite).

1.4. Approches classiques de downscaling

Le downscaling comporte une dimension *spatiale* (grille grossière → grille fine) et une dimension *temporelle* (fréquence faible → fréquence élevée). Notre contribution couvre exclusivement la dimension spatiale ; la dimension temporelle est brièvement évoquée pour positionner le champ.

I.4.1. Désagrégation spatiale

Trois grandes approches coexistent. La **statistique classique** (régression linéaire multiple, correction de biais, *Quantile Mapping*, qui ajuste quantile par quantile la distribution simulée sur la distribution observée [14]) apprend une relation prédicteurs LR → prédicande HR : simple et interprétable, mais elle suppose la stationnarité, perd la cohérence spatiale (traitement pixel par pixel) et n’offre aucune incertitude calibrée. L’**approche dynamique** (le RCM emboîté dans un GCM, présenté en section I.2.1) offre une transférabilité de principe hors-distribution, mais hérite des biais du GCM forçant et mobilise des ressources de calcul considérables. L’**apprentissage supervisé déterministe** (réseaux convolutifs de super-résolution tels que U-Net ou EDSR, qui produisent une seule carte en sortie) traite le champ HR comme un tout cohérent mais reste mono-sortie : la prédiction se réduit à une moyenne conditionnelle qui lisse les extrêmes et sous-estime la variabilité, ce qui motive le glissement vers les approches probabilistes (section I.5).

I.4.2. Désagrégation temporelle

La désagrégation temporelle (mensuelle → quotidienne ou horaire) pose des enjeux propres : autocorrélation, conservation des cumuls, extrêmes instantanés. Les approches historiques (cascades multiplicatives, chaînes de Markov) et les approches profondes (RNN et Transformers, deux familles de réseaux conçues pour les séquences) qui s’en saisissent restent, pour l’essentiel, déterministes. Le présent travail couvre exclusivement la dimension spatiale ; l’extension temporelle est laissée aux travaux futurs.

I.5. Approches probabilistes et génératives

I.5.1. Du déterministe au probabiliste

L'insuffisance des méthodes déterministes est une conséquence du caractère multi-valué du problème, déjà noté en section I.3.3 : à une carte LR correspond une famille de cartes HR plausibles, dont une seule a été observée. La reformulation probabiliste vise la *distribution conditionnelle* $p(x_{\text{HR}} \mid y_{\text{LR}}, s_{\text{HR}})$, où s_{HR} regroupe d'éventuels champs auxiliaires HR (orographie, occupation du sol). On produit alors des ensembles d'échantillons, calcule des quantiles et évalue la couverture des extrêmes.

I.5.2. Modèles génératifs adversariaux

Les premiers génératifs profonds appliqués au downscaling ont mobilisé les réseaux antagonistes génératifs (**GAN**) : deux réseaux s'y affrontent, un générateur qui produit des cartes fines et un discriminateur qui apprend à les distinguer des vraies, jusqu'à ce que les cartes générées deviennent indiscernables. Leur variante conditionnelle prend la carte LR comme point de départ. Une référence néo-zélandaise est [21], qui combine un générateur résiduel et une perte adversariale pondérée. Trois limites empiriques sont documentées : la **sub-dispersion** (variance prédite $<$ observée), une **forte sensibilité** au coefficient adversarial λ_{adv} , et un risque de **mode collapse** (le générateur se replie sur quelques sorties types et perd la diversité). Ces limites ont motivé l'exploration des modèles de diffusion.

I.5.3. Modèles de diffusion

Un modèle de diffusion définit un processus direct qui bruite progressivement le signal, puis apprend à l'inverser. Cette formulation, due aux DDPM (*Denoising Diffusion Probabilistic Models*) de Ho et al. [8], a été généralisée par Karras et al. sous le nom d'EDM [10], qui introduit un préconditionnement systématique pour un entraînement stable et un échantillonnage de qualité en peu d'étapes. Pour le downscaling, la dif-

fusion apporte trois avantages sur les GAN : un entraînement stable (pas de déséquilibre adversarial), une distribution de sortie expressive (modes multiples), une meilleure calibration probabiliste. Le formalisme EDM et l'échantillonnage de Heun sont détaillés au chapitre suivant.

1.5.4. Le paradigme deux étages : CorrDiff

CORRDIFF [15], proposé par NVIDIA Research, découple explicitement ce qui est facile à apprendre et ce qui est intrinsèquement stochastique : un premier étage régresse la moyenne HR attendue, un second échantillonne par diffusion le résiduel par rapport à cette moyenne. Le champ HR s'écrit comme la somme d'une moyenne déterministe et d'un résiduel stochastique (formalisation au chapitre suivant).




FIGURE 1 – Paradigme deux étages de CORRDIFF (Mardani et al. [15], Fig. 1). **Haut** : la donnée météorologique LR sert d'abord à prédire la moyenne μ_{HR} par régression UNet; cette estimation est ensuite corrigée stochastiquement par un modèle de diffusion EDM produisant le résiduel HR. **Bas** : SDE (équation différentielle stochastique) directe (données $\rightarrow$ bruit) et SDE inverse (bruit $\rightarrow$ données) sur lesquelles repose l'échantillonnage du second étage.

L'intérêt est triple : (i) la *stabilité* (régression déterministe convergente, diffusion sur résidus quasi-gaussiens) ; (ii) la *calibration* (variance explicitement contrôlée par le second étage, non plus produit d'un équi-

libre adversarial); (iii) l'*efficacité* (diffusion limitée au résiduel de faible amplitude). Ce paradigme constitue le point de départ direct de notre contribution. ORACLE en reprend la structure mais introduit une contrainte causale au premier étage : μ_{HR} y est prédite à travers un graphe causal appris, ce qui en fait par construction une version *causalisée* de CORRDIFF.

Évaluation probabiliste. Les métriques déterministes classiques (RMSE, l'erreur quadratique moyenne; MAE, l'erreur absolue moyenne; corrélation de Pearson) ne suffisent pas à évaluer un modèle probabiliste, dont la valeur réside dans la distribution prédite. La littérature mobilise un panel élargi : *CRPS* (généralisation probabiliste de l'erreur absolue), *spread/skill* (calibration du second moment), *RAPSD* (fidélité du spectre spatial), *LHD* (distributions locales). La présentation formelle et l'application à ORACLE sont reportées au chapitre Matériels et méthodes.

1.6. Causalité et modèles structurels

1.6.1. Pourquoi la causalité en downscaling climatique

Les approches probabilistes précédentes restent *corrélatives* : elles capturent les co-occurrences observées sans garantir la qualité prédictive hors du régime d'entraînement, c'est-à-dire dans la situation exacte que crée le changement climatique. Trois apports théoriques distinguent un modèle causal d'un modèle purement corrélatif. La **robustesse hors-distribution** d'abord : un modèle articulé autour de relations causales identifiées (par exemple, l'influence de l'humidité basse couche sur la convection) reste en principe stable lorsque les régimes climatiques se déplacent. L'**interprétabilité physique** ensuite : la structure causale apprise peut être confrontée à la connaissance experte, ce que ne permet aucun modèle purement statistique. La **capacité d'intervention** enfin : un tel modèle répond à des questions « que se passerait-il si humidité +20 % » sans avoir besoin de chercher des analogues dans le passé.

I.6.2. Modèles causaux structurels et graphes acycliques dirigés

Le cadre formel de la causalité est celui des **modèles causaux structurels** (SCM) de Pearl [18, 19]. Un SCM est un triplet (V, U, F) où V regroupe les variables observables, U des bruits exogènes indépendants et F des fonctions structurelles telles que

$$V_i = f_i(\text{Pa}(V_i), U_i), \quad (\text{I.1})$$

$\text{Pa}(V_i)$ étant l'ensemble des parents causaux de V_i . L'équation se lit simplement : chaque variable est entièrement déterminée par ses causes directes et par un bruit qui lui est propre. Le SCM s'exprime naturellement par un *Directed Acyclic Graph* (DAG) : nœuds = variables, arcs = liens parent $\rightarrow$ enfant. L'acyclicité garantit un ordre topologique d'évaluation (le système se résout de proche en proche, sans circularité) et fournit une description visuelle des dépendances. Sur un mini-système atmosphérique, par exemple, humidité, vent, température et orographie déterminent la précipitation locale, sans rétroaction explicite.

I.6.3. Intervention, identifiabilité et lien avec le downscaling

L'opérateur do de Pearl définit l'**intervention** : $\text{do}(X = x)$ fixe la valeur de X indépendamment de ses parents (suppression de ses flèches entrantes) et fournit une distribution $p(Y | \text{do}(X = x))$ en général distincte de la conditionnelle naïve $p(Y | X = x)$. C'est cette distinction qui sépare un modèle corrélatif d'un modèle structurellement causal. Un modèle *intervention-aware* a un effet calculable et prévisible sous intervention sur ses entrées. Cette propriété (objectif O3 d'ORACLE, chapitre dédié) est obtenue *au sens structurel* via la matrice A_{dag} apprise (la matrice d'adjacence pondérée du graphe causal). Elle ne se confond pas avec une causalité *physique* (où les flèches coïncideraient avec les lois atmosphériques point par point).

Un exemple concret rend la distinction tangible. En Nouvelle-Zélande, la corrélation observée entre température T et précipitation P peut être négative : les jours chauds y sont préférentiellement associés à des régimes

anticycloniques secs. Un modèle corrélatif intègre cette association et prédit moins de pluie à mesure que T augmente. Or la relation thermodynamique de Clausius-Clapeyron prédit, toutes choses égales par ailleurs, environ $+7\%$ de capacité hygrométrique par degré, donc plus d'intensité conditionnelle. Un modèle causal opérant via $\text{do}(T = T_0 + 3\text{ K})$ doit prédire un signe positif. C'est précisément ce que mesure le test Q_{int} rapporté au chapitre IV.

Apprendre la structure d'un DAG depuis les données est un problème combinatoire dur. Bello, Aragam et Ravikumar [1] ont proposé *DAGMA*, une caractérisation continue et différentiable de l'acyclicité (déterminant logarithmique d'une M-matrice), intégrable directement dans l'entraînement d'un réseau profond. ORACLE mobilise DAGMA pour insérer la causalité structurelle dans un paradigme génératif à deux étages style CORRDIFF, en prédisant μ_{HR} comme produit causal du DAG appris ; détail formel et examen comparatif sont reportés au chapitre dédié.

Cette posture appelle une précaution de vocabulaire qui structurera tout le manuscrit. Nous parlerons d'*architecture structurellement causale* quand l'information passe nécessairement par A_{dag} pour produire la sortie (notion vérifiable empiriquement par ablation : la suppression contrôlée d'un composant pour en mesurer l'effet), et de *causalité identifiée* pour des arêtes dont l'orientation et la magnitude reflètent fidèlement les mécanismes physiques. ORACLE vise et atteint la première propriété ; la seconde dépasse ce qu'un apprentissage purement observationnel peut garantir [19, 39]. Les arêtes du DAG appris sont à lire comme des *contraintes fonctionnelles* : leurs valeurs ne sont pas l'effet causal physique d'une variable sur une autre, mais des pondérations apprises qui satisfont l'acyclicité tout en optimisant la prédiction.

Cette distinction matérialise une division du travail entre deux niveaux de l'architecture qu'il faut tenir simultanément pour saisir comment ORACLE concilie résolution spatiale fine et faible cardinalité du graphe causal. La résolution spatiale est portée par les couches d'agrégation locale (dites SAGEConv, au sein du RCN, le réseau causal récurrent

présenté au chapitre III : chaque point de grille y combine sa propre information avec la moyenne de celle de ses voisins), qui jouent le rôle de *filtre spatial* et préservent la géographie pixel par pixel. La matrice A_{dag} opère, elle, sur un graphe inter-variables de cardinalité réduite ($N = 6$ nœuds typés dans la configuration principale du mémoire) et agit comme un *superviseur physique* : elle organise les dépendances fonctionnelles entre champs atmosphériques agrégés, indépendamment de la position des pixels. Le décodeur graphe-à-grille recombine ensuite les consignes de ce superviseur avec la carte spatiale locale pour reconstruire la précipitation au bon endroit. La métaphore de la tour de contrôle est utile : les six nœuds ne remplacent pas les pixels, ils coordonnent les relations physiques entre les champs spatiaux que les couches convolutives traitent en parallèle. Cette séparation explique pourquoi un graphe agrégé à 6 nœuds reste compatible avec la cible HR à 172×179 pixels : la richesse spatiale survit au goulot d'étranglement parce qu'elle ne passe tout simplement pas par lui.

L'analogie a une portée pratique sur la lecture des résultats. Le fait que la matrice A_{dag} soit à magnitudes plates (Q_{phys} proche de la fraction aléatoire d'arêtes correctement orientées) ne signifie pas que le modèle ait manqué la physique ; ce fait indique que l'identification fine de la hiérarchie causale est restée hors de portée des données observationnelles disponibles, alors même que la contrainte d'acyclicité a fait son travail régularisant. Le chapitre IV mesure les deux séparément : le ratio d'ablation O3 (défini au chapitre IV) atteste de la dépendance fonctionnelle, Q_{phys} et Q_{int} mesurent la fidélité physique. La distinction permet aussi de localiser proprement les marges de progression : une expérience exploratoire menée en parallèle, avec un graphe à 9 nœuds (un par variable atmosphérique au lieu de l'agrégation à 6 nœuds typés), récupère une fidélité physique très élevée, ce qui montre que la platitude observée à 6 nœuds est le coût d'une agrégation choisie pour la lisibilité humaine du DAG plutôt qu'une limite intrinsèque de l'architecture.

I.7. Verrous scientifiques et trilemme

Les fondements précédents font émerger trois verrous structurants du downscaling génératif. Avant de les articuler dans un *trilemme*, examinons-les un par un.

I.7.1. Verrou 1 : stabilité d'entraînement

Les modèles adversariaux sont très sensibles au coefficient λ_{adv} et au déséquilibre générateur-discriminateur, difficiles à régler de manière transférable d'une région à l'autre [21]. Les modèles de diffusion, plus stables en principe, exigent néanmoins une calibration soignée du pré-conditionnement et du schéma de bruit. C'est précisément ce qu'apporte EDM [10]. Ce verrou conditionne reproductibilité et déployabilité multi-cas.

I.7.2. Verrou 2 : réalisme des extrêmes et sub-dispersion

Le verrou le plus critique pour nos applications est le **réalisme des extrêmes**, via le phénomène de *sub-dispersion* introduit en section I.5.2 : variance prédite conditionnellement à l'entrée inférieure à la variance observée. Mesurée par le rapport $\sigma_{pred}/RMSE$ (dispersion prédite rapportée à l'erreur RMSE), elle vaut ≈ 1 pour un modèle bien calibré, alors que des valeurs autour de 0,3 sont rapportées en downscaling génératif [6, 15, 21]. Cela représente une sous-estimation d'un facteur trois de la variabilité fine, et donc des extrêmes, soit précisément les événements à plus forte valeur ajoutée. Sa mesure sur ORACLE et ses ablations causales sera l'un des objets centraux de l'évaluation.

I.7.3. Verrou 3 : robustesse hors-distribution

Sous changement climatique, la statistique conjointe des variables atmosphériques évolue : un modèle historique doit conserver sa qualité hors des analogues observés. Les modèles purement corrélatifs y sont vulnérables (associations contingentes au régime d'entraînement), tandis que la causalité structurelle (section I.6) apparaît comme une réponse de prin-

cipe : un modèle organisé autour de relations causales doit, en théorie, mieux transférer en **OOD**.

I.7.4. Trilemme et positionnement d'ORACLE

La littérature récente expose un schéma récurrent : les approches qui dominent un de ces axes échouent presque systématiquement sur au moins un autre. Les GAN les plus expressifs sont aussi les plus instables ; les modèles de diffusion stables restent corrélatifs et sans garantie hors-distribution ; les RCM dynamiques robustes paient cette robustesse en coût de calcul et transférabilité. Cette tension, identifiée sous diverses formes chez plusieurs auteurs [6, 15, 21], se condense en un *trilemme* entre la stabilité d'entraînement, le réalisme des extrêmes et la robustesse hors-distribution (figure 2). Nous le présentons *tel qu'il ressort de la littérature*, sans prétendre à une formalisation originale.




FIGURE 2 – *Trilemme du downscaling génératif. Les trois sommets représentent les verrous identifiés ; les points positionnent qualitativement les principales approches. Plus un point est proche d'un sommet, mieux l'approche traite ce verrou. Constat agrégé à partir de [6, 15, 21] ; le positionnement des points est qualitatif, à visée illustrative, et non le résultat d'une mesure.*

ORACLE se positionne dans ce trilemme en s'inscrivant dans le paradigme à deux étages de CORRDIFF (stabilité, verrou 1), en y introduisant une contrainte structurellement causale au premier étage (robustesse OOD, verrou 3), et en mobilisant la diffusion EDM au second étage pour

la calibration probabiliste (réalisme des extrêmes, verrou 2). La figure 3 en propose une vue d'ensemble ; détails architecturaux et formalisation des objectifs sont déferés au chapitre dédié.




FIGURE 3 – Cartouche conceptuel d'ORACLE : version causalisée du paradigme deux étages de CORRDIFF. L'étage 1 estime μ_{HR} via un graphe causal appris ; l'étage 2 échantillonne par diffusion le résiduel δ .

I.8. Synthèse

Trois acquis se dégagent de ce chapitre. Le besoin de désagrégation est concret et localisé : la résolution des GCM ne rencontre pas celle des usages locaux, particulièrement en contexte africain où les RCM dynamiques restent hors de portée, et la précipitation y concentre à la fois la pertinence opérationnelle et la difficulté statistique. Le paradigme méthodologique a glissé du déterministe vers le probabiliste, puis vers le génératif, et a récemment trouvé une forme aboutie dans le schéma à deux étages de CORRDIFF (moyenne déterministe additionnée d'un résiduel par diffusion), qui sert ici de point de départ. Trois verrous, enfin, structurent encore le champ : stabilité d'entraînement, réalisme des extrêmes (et la sub-dispersion qui en découle), robustesse hors-distribution. C'est

dans le trilemme qu'ils dessinent qu'ORACLE s'inscrit, en greffant une structure causale sur la décomposition à deux étages.

Le chapitre suivant parcourt l'état de l'art : les travaux antérieurs sur le downscaling probabiliste à deux étages (CORRDIFF, cGAN de Rampal et al.) et les approches qui éclairent l'intégration de la causalité au cadre génératif.

II

CHAPITRE

ÉTAT DE L'ART DU DOWNSCALING PAR APPRENTISSAGE PROFOND

SOMMAIRE

II.1 - Introduction	24
II.2 - Approches déterministes	25
II.3 - Approches probabilistes adversariales	26
II.4 - Approches à vraisemblance explicite	27
II.5 - Modèles de diffusion	28
II.6 - Le paradigme à deux étages : CorrDiff	29
II.7 - Fonctions de perte et contraintes physiques	33
II.8 - Cadres d'évaluation et foundation models	35
II.9 - Synthèse, tableau comparatif et gap scientifique	36

II.1. Introduction

Le chapitre précédent a identifié un trilemme pour le downscaling climatique génératif (section I.7) : stabilité d'entraînement, réalisme des extrêmes et robustesse sous changement de distribution apparaissent inconciliables dans les approches existantes. Le présent chapitre confronte cette analyse au paysage effectif de la littérature, des CNN déterministes aux

modèles de diffusion à deux étages. Nous abordons successivement les approches déterministes (section II.2), adversariales (section II.3), à vraisemblance explicite (section II.4) et de diffusion (section II.5), avant de détailler le paradigme CORRDIFF (section II.6) dont notre proposition est la causalisation. Pertes (section II.7) et cadres d'évaluation (section II.8) complètent la revue ; la synthèse (section II.9) identifie le gap qui motive notre contribution.




FIGURE 4 – *Frise chronologique des principales contributions du downscaling climatique profond. Le glissement progressif du paradigme déterministe (gris) vers le paradigme génératif (rouge) puis vers le two-stage causal (bleu) est visible à partir de 2020. ORACLE se positionne comme aboutissement causal du paradigme à deux étages.*

La figure 4 situe chronologiquement les contributions examinées : glissement déterministe → génératif à partir de 2020, accélération après 2022 sous l'effet conjoint des modèles de diffusion et de la maturation des GCM haute résolution.

II.2. Approches déterministes

II.2.1. Régression statistique classique

Les approches statistiques de première génération (régression linéaire, BC, QM) présentées au chapitre I (section I.4) souffrent de trois limites structurelles : hypothèse de stationnarité difficile à défendre sous changement climatique, absence de cohérence spatiale (traitement pixel par

pixel), absence de calibration probabiliste. C'est ce qui motive le passage aux méthodes d'apprentissage non linéaires et structurées spatialement.

II.2.2. Réseaux convolutifs et super-résolution

L'application des CNN au downscaling s'inspire des architectures de super-résolution d'image. **DeepSD** [23] est l'une des premières architectures CNN dédiées au downscaling de la précipitation, par empilement de convolutions à champ réceptif croissant (chaque couche successive « voit » une portion de plus en plus large de la carte d'entrée). Le **U-Net** [22] a connu une adoption massive, particulièrement sous sa forme conditionnée par des champs de surface (élévation). Ces approches partagent une limite décisive : produisant une unique sortie HR par entrée, elles approximent la moyenne conditionnelle de la distribution cible. Pour la précipitation à queue lourde, cette moyenne est biaisée à la baisse aux valeurs élevées, d'où le lissage des extrêmes documenté dans la littérature.

La période 2021–2023 a vu émerger des architectures plus sophistiquées qui partagent la même limite probabiliste : opérateurs neuronaux de Fourier (FNO) prometteurs en prévision globale mais expérimentaux en downscaling régional, et Transformers de vision (SwinIR, PrecipFormer) exploitant l'attention, ce mécanisme qui pondère dynamiquement les zones de l'entrée les plus pertinentes pour chaque sortie. Toutes conservent la limite fondamentale du déterminisme : pas de distribution conditionnelle calibrée, donc le verrou « réalisme des extrêmes » reste non adressé.

II.3. Approches probabilistes adversariales

II.3.1. Réseaux antagonistes génératifs conditionnels

Le glissement vers le probabiliste a d'abord été opéré par les **réseaux antagonistes génératifs** (GAN) [4] et leur variante conditionnelle (cGAN) [16]. Un générateur G transforme un bruit $z \sim \mathcal{N}(0, I)$ et un conditionnement y_{LR} en échantillon plausible $\hat{x}_{HR} = G(y_{LR}, z)$; un discriminateur D apprend à distinguer vrais et faux. L'entraînement min-max

alterne ces objectifs opposés. Appliqué au downscaling, le cGAN promet un ensemble d'échantillons HR plausibles permettant en principe d'estimer la variabilité prédictive et la distribution des extrêmes.

II.3.2. cGAN résiduel pour le downscaling climatique

Une architecture représentative est le **Residual cGAN** de Rampal et al. [21], qui combine un U-Net déterministe pré-entraîné et un cGAN sur le résidu : le générateur reçoit la prédiction U-Net, l'élévation HR, le champ GCM et un bruit, et produit une carte résiduelle additionnée à la prédiction déterministe. L'application à la Nouvelle-Zélande (CMIP6 ACCESS-CM2) combine trois termes de coût : MSE, perte adversariale pondérée par λ_{adv} , et contrainte d'intensité pénalisant la surestimation des extrêmes.

D'autres travaux apparentés incluent Harris et al. [6] (désagrégation de précipitations sur domaine européen) et Price et Rasp (prévision d'extrêmes à court terme via GAN).

II.3.3. Limites empiriques des cGAN appliqués au downscaling

Quatre limites empiriques reviennent dans la littérature adversariale. D'abord, la **forte sensibilité à λ_{adv}** : la performance sur les extrêmes décrit une courbe en cloche (un coefficient trop faible et la MSE lisse, un coefficient trop élevé et les extrêmes explosent), avec un optimum étroit qui ne transfère pas d'une région à l'autre. Vient ensuite la **sub-dispersion**. Rampal et al. [21] et Mardani et al. [15] rapportent $\sigma_{pred}/RMSE < 0,5$, signe d'ensembles systématiquement trop confiants. Le **mode collapse**, intrinsèque au cadre min-max, reste latent même quand il n'apparaît pas explicitement. Reste la **validité restreinte du cadre d'évaluation** : la plupart des tests utilisent des couples synthétiques RCM-LR/RCM-HR (cadre « parfait »), et la transférabilité aux conditions opérationnelles GCM brut n'est pas garantie.

II.4. Approches à vraisemblance explicite

Les **auto-encodeurs variationnels** (VAE) [11] apprennent une représentation interne compacte et probabiliste des données, en maximisant un objectif qui approche la vraisemblance par en dessous (la borne ELBO). Appliqués au downscaling, ils produisent des sorties probabilistes mais souffrent d'un excès de lissage lié à l'ELBO. Les **flots de normalisation** appliquent une séquence de transformations inversibles différentiables à un bruit gaussien et autorisent l'évaluation exacte de la vraisemblance ; leur expressivité reste cependant bornée par la contrainte d'inversibilité. Ces deux familles n'atteignent pas le niveau des GAN ou de la diffusion en downscaling climatique : leur intérêt méthodologique ne compense pas une expressivité insuffisante face aux extrêmes à queue lourde.

II.5. Modèles de diffusion

II.5.1. Denoising Diffusion Probabilistic Models

L'idée des modèles de diffusion se résume simplement : détruire progressivement une image en y ajoutant du bruit, entraîner un réseau à refaire le chemin inverse, puis générer en partant d'un bruit pur que l'on débruite pas à pas. Formellement, les **Denoising Diffusion Probabilistic Models** (DDPM) [8] définissent un processus direct qui bruite le signal selon une chaîne de Markov gaussienne $q(x_t | x_{t-1}) = \mathcal{N}(x_t; \sqrt{1 - \beta_t} x_{t-1}, \beta_t I)$, puis apprennent à inverser ce processus. L'objectif simplifié se réduit à la prédiction du bruit, $\mathcal{L}_{\text{simple}} = \mathbb{E}[\|\varepsilon - \varepsilon_\theta(x_t, t)\|^2]$, où ε_θ est typiquement un U-Net. Face aux GAN, DDPM offre trois avantages pour le downscaling : entraînement stable sans déséquilibre adversarial, expressivité multimodale sans collapse, et calibration probabiliste intrinsèque.

II.5.2. Formalisme EDM de Karras et al.

Le formalisme EDM [10] reformule la diffusion dans un cadre théorique général. Sa contribution principale est un **préconditionnement systématique** : une mise à l'échelle automatique des entrées et sorties du réseau selon le niveau de bruit, portée par quatre fonctions $c_{\text{in}}, c_{\text{out}}, c_{\text{noise}}, c_{\text{skip}}$

dépendant de σ , qui unifie les variantes antérieures (DDPM, *score matching* : une formulation où le réseau apprend le gradient de la densité des données bruitées) et stabilise l’entraînement. Le sampler de Heun (la méthode numérique qui parcourt les étapes de débruitage) atteint à pas variable une qualité comparable à DDPM avec un ordre de grandeur d’étapes en moins (quelques dizaines contre environ un millier). La calibration de σ_{data} (écart-type des données normalisées) est cruciale.

II.5.3. Premières applications au climat : SR3, ResShift, ResDiff

SR3 fut la première application notable de la diffusion conditionnelle à la super-résolution d’image, avant son essaimage vers le climat. **ResShift** accélère la diffusion par déplacement résiduel, avec une proximité manifeste vers le paradigme à deux étages détaillé en section II.6. Plusieurs évolutions récentes pourraient à terme remplacer l’étage de diffusion : **flow matching** [13] (transport direct du bruit vers les données par un champ de vitesses appris), consistency models (génération en une ou deux étapes par distillation), diffusion latente (diffusion opérée dans un espace compressé). La diffusion EDM [10] demeure notre choix de référence pour trois raisons : maturité empirique en climat (retenue par CorrDiff [15] et GenCast [20]), stabilité d’entraînement (le préconditionnement systématique de la section II.5.2), et efficacité d’échantillonnage (solveur de Heun à 20–50 pas contre environ 1000 pour DDPM).

II.6. Le paradigme à deux étages : CorrDiff

II.6.1. Idée fondatrice

Le modèle CORRDIFF (*Corrective Diffusion*) de Mardani et al. [15] (NVIDIA Research) propose un paradigme à deux étages dont la décomposition formelle est :

$$x_{\text{HR}} = \text{baseline}_{\text{LR}\uparrow} + \mu_{\text{HR}}(y_{\text{LR}}, s_{\text{HR}}) + \delta(\cdot), \quad (\text{II.1})$$

où $\text{baseline}_{\text{LR}\uparrow}$ désigne un sur-échantillonnage bilinéaire, μ_{HR} la moyenne HR apprise par régression déterministe, et δ un résiduel stochastique échantillonné par diffusion conditionnée sur μ_{HR} et y_{LR} . L'application visée est le downscaling kilométrique de sorties GCM avec un facteur de réduction de 25 à 50, le terrain initial étant Taïwan.

II.6.2. Architecture détaillée

Le premier étage est un U-Net classique entraîné par MSE entre μ_{HR} et la cible HR. Le second est un U-Net de diffusion EDM entraîné à prédire $\delta = x_{\text{HR}} - (\text{baseline}_{\text{LR}\uparrow} + \mu_{\text{HR}})$ conditionnellement à μ_{HR} et y_{LR} , avec échantillonnage de Heun à 20–50 pas.




FIGURE 5 – Architecture UNet hiérarchique de CORRDIFF (Mardani et al. [15], Fig. S1), partagée par les deux étages. Encodeur–décodeur à quatre niveaux ($448^2 \rightarrow 28^2$), blocs résiduels, attention auto-référentielle dans les niveaux profonds, embedding temporel t pour le second étage. Le premier étage de régression réutilise la même topologie sans embedding temporel.

II.6.3. Forces du paradigme à deux étages

Ce paradigme accumule trois forces structurelles. La **stabilité d'entraînement** d'abord : la régression déterministe converge sans difficulté et la diffusion du second étage opère sur des résidus dont la distribution

se rapproche d'une gaussienne. La **calibration probabiliste explicite** ensuite : la variance est contrôlée par le second étage, sans dépendre d'un équilibre adversarial. L'**efficacité computationnelle** enfin : l'échantillonnage par diffusion ne porte que sur le résiduel, dont l'amplitude est faible.

II.6.4. Limites identifiées de CorrDiff

L'examen critique fait apparaître deux limites principales. La **persistance de la sub-dispersion** : malgré la calibration explicite du second étage, CorrDiff reste sub-dispersif ($\sigma_{\text{pred}}/\text{RMSE}$ entre 0,3 et 0,5 selon les configurations); la persistance est moins prononcée que chez les cGAN mais reste significative. L'**absence de structure causale explicite** : le premier étage est un U-Net générique apprenant $\mu_{\text{HR}}(y_{\text{LR}}, s_{\text{HR}})$ sans contrainte sur la nature des dépendances; rien ne distingue les associations causales (humidité de basse couche $\rightarrow$ précipitation convective) des corrélations contingentes au régime d'entraînement. CorrDiff est donc vulnérable au changement de distribution, sans garantie d'intervention.

II.6.5. Le piège du conditionnement par cross-attention

Une tentation immédiate, face à ce diagnostic, est d'ajouter un module causal en amont du U-Net et de l'injecter à l'aide d'un mécanisme de cross-attention (une forme d'attention par laquelle le réseau consulte une source d'information extérieure à son entrée principale). Notre propre cheminement a confirmé que cette voie ne tient pas. Nos premières versions, fondées sur cross-attention causale (état caché $H_T(A_{\text{dag}})$ projeté dans `encoder_hidden_states` d'un `UNet2DConditionModel`), passaient pourtant tous les contrôles *ex ante* : la matrice A_{dag} apparaissait dans le graphe de calcul, l'entraînement convergeait, et la sortie semblait dépendre de la voie causale. L'ablation *ex post* ($A_{\text{dag}} \leftarrow \mathbf{0}$) révélait pourtant une dépendance nulle : la prédiction ne se dégradait pas. Le U-Net, riche en skip-connections multi-niveaux (des raccourcis internes qui relient chaque niveau de l'encodeur au niveau de même résolution du décodeur), apprenait à reconstruire la cible en court-circuitant le conditionne-

ment causal via les canaux du LR brut. La causalité était *décorative* : elle apparaissait dans la loss mais pas dans la fonction apprise.

Cette pathologie est structurelle, non hyperparamétrique. Tant qu’il existe un chemin de calcul entre l’entrée LR et la sortie qui ne dépende pas de A_{dag} , un réseau suffisamment expressif l’empruntera, parce que la voie de bypass minimise la perte plus rapidement que la voie causale en cours d’apprentissage. Aucune régularisation *a posteriori* ne corrige ce déséquilibre. La seule réponse opérante est topologique : verrouiller l’architecture pour qu’aucun chemin de bypass ne soit possible. C’est ce que réalise la décomposition deux-étages avec gel du Stage 1 et conditionnement par concaténation, retenue pour ORACLE (chapitre III). Le diagnostic correspond à une distinction qui structurera tout le manuscrit : une causalité par régularisation peut toujours être contournée par un réseau expressif ; une causalité par topologie est par construction indéfaisable. Ce constat justifie le passage d’un cadre *loss-as-cause* à un cadre *architecture-as-cause*.

II.6.6. Pourquoi CorrDiff plutôt que SR3 ?

La baseline non causale d’ORACLE aurait pu provenir d’autres travaux de diffusion résiduelle. ResDiff et CorrDiff désignent la même filiation chez Mardani et al. ; la vraie alternative restait SR3. Trois raisons font pencher la balance vers CorrDiff. La **décomposition moyenne + résiduel** (équation II.1) épouse la structure même de la statistique climatique : μ_{HR} encode le forçage-réponse, δ la variabilité fine. SR3 ne propose pas cette séparation, et c’est elle qui ouvre la voie à la causalisation. Vient ensuite le **ciblage explicite du downscaling kilométrique** : CorrDiff intègre intermittence, queue lourde et hétérogénéité de la précipitation, là où SR3 reste une méthode générique de super-résolution d’image. Reste enfin la **modularité architecturale**. L’étage 1 se substitue sans toucher à l’étage 2, ce qui nous permet précisément de remplacer le U-Net du premier étage par un module à graphe causal sans perturber la diffusion EDM.

II.6.7. Reformulation du paradigme deux étages dans le langage probabiliste

Une lecture probabiliste éclaire pourquoi la décomposition $x_{\text{HR}} = \text{baseline} + \mu_{\text{HR}} + \delta$ est plus qu'une commodité d'implémentation. En notant $\mu^*(y_{\text{LR}}) = \mathbb{E}[x_{\text{HR}} \mid y_{\text{LR}}, s_{\text{HR}}]$ la moyenne conditionnelle théorique et $\delta^* = x_{\text{HR}} - \mu^*(y_{\text{LR}})$ son résiduel, on a par construction $\mathbb{E}[\delta^* \mid y_{\text{LR}}, s_{\text{HR}}] = 0$. La distribution de δ^* est typiquement plus proche d'une gaussienne que celle de x_{HR} , ce qui rend l'apprentissage de diffusion mieux conditionné ; et la variance résiduelle sert d'estimateur naturel de σ_{data} , hyperparamètre central d'EDM dont la calibration se fait empiriquement en fin de Stage 1.

II.7. Fonctions de perte et contraintes physiques

II.7.1. Pertes adaptées à la précipitation

Au-delà de la MSE, la littérature a développé plusieurs pertes adaptées à la précipitation. Les **pertes spectrales** (FACL, *Fourier Amplitude Coherence Loss*) pénalisent l'écart entre spectres de Fourier prédit et cible, préservant le contenu fréquentiel fin et corrigeant partiellement le lissage MSE. La **régularisation Wasserstein** (héritée des WGAN) remplace la divergence Jensen-Shannon implicite (la mesure d'écart entre distributions que minimise le GAN original) par une distance Wasserstein-1, plus stable et mieux comportée aux extrêmes. Les **pondérations spécifiques aux extrêmes** (*focal loss*, MSE pondérée par percentiles, top- k) accroissent le poids des pixels à forte intensité, concentrant l'apprentissage sur les cas extrêmes.

Reste un point méthodologique : combiner ces pertes n'est pas une opération additive sans conséquence. Un mélange linéaire à coefficients fixes ne fonctionne en pratique qu'au prix d'une recherche d'hyperparamètres elle-même fragile au changement de domaine. Plusieurs travaux récents proposent une pondération adaptative au cours de l'entraînement, soit par *loss weighting* indexé sur la phase d'optimisation, soit par *cur-*

riculum learning progressif des seuils d'extrêmes. ORACLE retient une approche conservatrice : la perte du Stage 1 combine MSE et reconstruction, sans pondération spectrale ni Wasserstein. Ces deux dernières ont été évaluées en exploration ; elles n'ont pas montré de gain reproductible en présence des autres briques (contrainte DAGMA d'acyclicité du graphe, détaillée au chapitre III, et pénalité L_1). Cette simplicité est défendue au chapitre suivant comme un choix de robustesse face à la fragilité empirique des pondérations multi-pertes.

II.7.2. Contraintes physiques et explicabilité

Des **contraintes physiques dures** (conservation de masse, monotonie $T_{\min} \leq T \leq T_{\max}$, positivité de la précipitation) sont imposées par construction architecturale ou projection en sortie ; elles améliorent la cohérence multivariée mais ne résolvent pas les verrous probabilistes. L'**explicabilité** (XAI) appliquée au downscaling (Grad-CAM, Integrated Gradients) révèle a posteriori les zones d'entrée influentes. Notre proposition emprunte une voie complémentaire : organiser l'architecture autour d'une structure causale apprise, apportant par construction cohérence et interprétabilité.

TABLEAU I – Principales fonctions de perte et contraintes utilisées en downscaling climatique profond.

Famille	Exemples	Cas d'usage principal
Pertes spectrales	FACL	Contenu fréquentiel fin
Adversariales régularisées	Wasserstein, WGAN-GP	Stabilisation entraînement adversarial
Pondération extrêmes	Focal, top- k , MSE pondérée	Pixels à forte intensité
Contraintes dures	Conservation, monotonie, positivité	Cohérence physique multivariée
Explicabilité a posteriori	Grad-CAM, Integrated Gradients	Diagnostic des dépendances
Structure causale	DAG appris, intervention	Robustesse OOD et auditabilité (notre voie)

Le tableau I récapitule ces familles.

II.8. Cadres d'évaluation et foundation models

II.8.1. Benchmarks standardisés

Trois benchmarks récents tentent de réduire la fragmentation des protocoles d'évaluation. **WeatherBench 2** étend le benchmark initial à la prévision météorologique pilotée par les données (RMSE, biais, corrélation d'anomalie ACC sur ERA5). **ClimateBench** se concentre sur la réponse à des scénarios d'émissions et l'émulation climatique. **ChaosBench** cible la prévision à grande échelle et la stabilité à long horizon. Un constat demeure : **aucun benchmark public ne couvre le downscaling probabiliste à haute résolution**, et sa construction reste un chantier ouvert.

L'absence de benchmark public dédié explique en partie l'hétérogénéité des protocoles rencontrés dans la littérature : choix de domaines (Taïwan pour CorrDiff, Nouvelle-Zélande pour Rampal, États-Unis ou Europe pour les cGAN antérieurs), formulation des métriques d'extrêmes (score F1 de détection des dépassements de seuil calculé sur tous les pixels agrégés, ou indices climatiques standardisés ETCCDI calculés pixel par pixel), périodes de test plus ou moins longues, et taille d'ensemble allant de $K = 8$ à $K = 192$. Notre choix expérimental (Nouvelle-Zélande, ACCESS-CM2 historique, ensemble $K = 12$ inter-GCM) reprend largement le protocole Rampal et al. [21] afin d'être directement comparable à cette référence, tout en évaluant les indices ETCCDI préconisés par [27] pour garantir l'interopérabilité avec les diagnostics climatologiques standard.

II.8.2. Foundation models climat

La période 2023-2024 a vu émerger des *foundation models* climat (grands modèles généralistes pré-entraînés, réutilisables sur plusieurs tâches). **ClimaX** [17] (Microsoft) est un Transformer pré-entraîné sur CMIP6, capable de prévision, projection et downscaling après *fine-tuning* (ré-entraînement léger sur la tâche cible). **GraphCast** [12] et **GenCast** [20] (Google Deep-

Mind) sont des réseaux de neurones opérant sur des graphes (*graph neural networks*) entraînés sur ERA5 qui ont dépassé plusieurs modèles physiques opérationnels. Le positionnement de notre travail est complémentaire : ORACLE cible le downscaling régional probabiliste, non le multi-tâche global ; la structure causale proposée pourrait à terme s'intégrer à une architecture de plus grande échelle.

II.9. Synthèse, tableau comparatif et gap scientifique

II.9.1. Tableau comparatif modèle × verrou

Le tableau II récapitule les approches revues selon les trois axes du trilemme (stabilité, extrêmes, robustesse OOD), complétés par deux axes propres à notre contribution (structure causale explicite, caractère génératif probabiliste).

TABLEAU II – *Confrontation des principales approches du downscaling profond aux verrous du trilemme. Légende : ✓ = bien traité, △ = partiellement traité, × = non traité. La colonne **Causal** renvoie à l'indispensabilité structurelle (propriété (O3)) qui sera formalisée au chapitre suivant.*

Approche	Année	Stabilité	Extrêmes	OOD	Causal	Génératif
DeepSD / U-Net	2017	✓	×	×	×	×
EDSR / SRCNN	2017	✓	×	×	×	×
FNO / SFNO	2021-23	✓	△	△	×	×
SwinIR / PrecipFormer	2021-23	✓	△	×	×	×
cGAN (Harris et al.)	2022	△	△	×	×	✓
Residual cGAN (Rampal)	2024	△	△	×	×	✓
VAE downscaling	2022	✓	×	×	×	✓
Normalizing Flow	2020	✓	△	×	×	✓
DDPM / EDM brut	2020-22	✓	✓	△	×	✓
SR3 / ResShift	2022-23	✓	△	△	×	✓
CorrDiff (Mardani)	2023	✓	△	△	×	✓
ClimaX (foundation)	2023	✓	△	△	×	△
ORACLE (proposé)	2026	✓	△	△	✓	✓

Note sur ORACLE. La colonne « Causal » est attribuée à ORACLE au titre de la propriété (O3) : architecturalement, la sortie ne peut pas contourner la matrice A_{dag} apprise. Les triangles partiels en « Extrêmes » et « OOD »

reflètent honnêtement les limites mesurées : RX1day (le cumul journalier maximal de précipitation) mieux placé que la baseline mais F1@p99 régresse ; gain CRPS en inter-GCM historique mais pas de test sur scénario futur. Le détail est discuté au chapitre IV.

II.9.2. Gap scientifique

Le tableau II fait apparaître un constat structurant : **aucune des approches revues ne résout simultanément les trois axes du trilemme**. Les plus stables (U-Net, DDPM, EDM brut) ne garantissent pas la robustesse hors-distribution. Les plus probabilistes (CorrDiff, cGAN résiduel) restent sub-dispersives sur les extrêmes. Les plus expressives (cGAN) butent sur l’instabilité d’entraînement. Et aucune n’intègre par construction de structure causale explicite : c’est précisément cette lacune qui motive notre contribution.

Le gap scientifique se formule donc comme **la non-résolution du trilemme par les approches existantes**. Le paradigme deux-étages de CORRDIFF couvre le mieux le triplet stabilité + extrêmes + probabiliste, mais sa robustesse hors-distribution n’est pas adressée par construction. Comblé ce gap suppose de **causaliser le premier étage** : remplacer le U-Net générique qui estime μ_{HR} par un module structurellement causal qui contraint cette estimation à passer par un graphe de dépendances appris.

II.9.3. Positionnement d’Oracle dans le paysage

La figure 6 résume la position de ORACLE. Le premier étage causalise CORRDIFF [15], en s’appuyant sur la caractérisation différentiable de l’acyclicité de Bello et al. [1] et sur le formalisme SCM de Pearl [19] ; le second étage conserve la diffusion EDM [10]. L’architecture détaillée fait l’objet du chapitre suivant.

Contraste avec CORRDIFF [Mardani 2023] :

Stage 1 générique → Stage 1 causal

causalisation via DAGMA [Bello 2022], formalisme SCM [Pearl 2009]




FIGURE 6 – Cartouche conceptuel revisité du modèle ORACLE avec ancrage bibliographique. Le premier étage causalise CORRDIFF [15] en y intégrant un graphe causal appris par contrainte DAGMA [1] et le formalisme SCM de Pearl [19]; le second étage conserve la diffusion EDM [10].

III

CHAPITRE

PROPOSITION : ORACLE, ARCHITECTURE CAUSALE À DEUX ÉTAGES

SOMMAIRE

III.1 - Introduction	39
III.2 - Vue d'ensemble et différence avec CorrDiff	41
III.3 - Graphe atmosphérique hétérogène	42
III.4 - Encodeur intelligible et réseau causal récurrent	44
III.5 - Apprentissage du DAG par contrainte DAGMA	46
III.6 - Décodeur graphe-à-grille et moyenne haute résolution	47
III.7 - Interface inter-étages et propriété (O3)	48
III.8 - Pertes composites et entraînement	50
III.9 - Synthèse, traçabilité et choix non retenus	51

III.1. Introduction

Le paradigme à deux étages de CORRDIFF [15] est l'antécédent le plus crédible pour le trilemme stabilité / extrêmes / robustesse, mais sa robustesse hors-distribution n'est pas adressée par construction. ORACLE en est une *causalisation* portant exclusivement sur le premier étage : le

réseau de régression générique est remplacé par un module structurellement causal (graphe atmosphérique hétérogène, encodeur intelligible, RCN sous contrainte d'acyclicité). Le second étage conserve la diffusion EDM [10], avec un conditionnement par concaténation de canaux : les cartes produites par le premier étage sont empilées à l'entrée du réseau de diffusion comme les canaux d'une image couleur, ce qui propage architecturalement le chemin causal vers la prédiction stochastique du résiduel.

Sauf mention contraire, B désigne la taille du lot, T la longueur de séquence ($T = 8$), N le nombre de nœuds, $d = 128$ la dimension latente et $(H_{\text{HR}}, W_{\text{HR}}) = (172, 179)$ la résolution cible. Les symboles centraux sont récapitulés dans le tableau III.

TABLEAU III – Notations principales.

Symbole	Description
$y_{\text{LR}}, x_{\text{HR}}$	Champs LR conditionnants (GCM) et HR cible (précipitation)
baseline, μ_{HR}, δ	Sur-échantillonnage bilinéaire, moyenne causale Stage 1, résiduel stochastique Stage 2
A_{dag}	Matrice d'adjacence $N \times N$ du DAG appris
H_t, H_T	État caché du graphe au pas t , état final consommé par le décodeur
$\sigma, \sigma_{\text{data}}$	Niveau de bruit EDM, écart-type empirique des résiduels
$\mathcal{D}_{\theta}$	Opérateur de débruitage EDM préconditionné

Six objectifs guident la conception :

- **O1** stabilité d'entraînement (sans équilibre adversarial fragile);
- **O2** réalisme des extrêmes (CRPS et centiles élevés);
- **O3** causalité architecturale, c'est-à-dire dépendance non triviale de μ_{HR} à A_{dag} formant signature contrastive vis-à-vis de CORRDIFF;
- **O4** robustesse inter-GCM;
- **O5** efficacité computationnelle sur budget CPU (48 cœurs, 128 Go);
- **O6** interprétabilité du DAG appris.

La décomposition à deux étages et la diffusion EDM adressent O1–O2; le RCN et la contrainte d'acyclicité DAGMA (section III.5) adressent O3 et O6; la structure causale adresse O4; le pré-calcul et la diffusion sur le résidu de faible amplitude adressent O5.

III.2. Vue d'ensemble et différence avec CorrDiff

À haut niveau, ORACLE est composé de quatre blocs (figure 7). Le *générateur de baseline* sur-échantillonne y_{LR} par interpolation bilinéaire : un simple agrandissement de la carte grossière, qui fournit un point de départ sans ajouter d'information. Le *module causal résiduel* (CRM) produit μ_{HR} via le chemin causal complet, à savoir graphe hétérogène, encodeur intelligible, RCN et décodeur graphe-à-grille. Le *décodeur de diffusion EDM* échantillonne le résiduel δ conditionné sur μ_{HR} et la baseline. La *recombinaison finale* agrège selon l'équation centrale du paradigme à deux étages :

$$x_{HR} = \text{baseline}_{LR\uparrow} + \mu_{HR}(y_{LR}; A_{\text{dag}}) + \delta(\sigma; \mu_{HR}, \text{baseline}). \quad (\text{III.1})$$




FIGURE 7 – Vue d'ensemble simplifiée du modèle ORACLE en quatre blocs articulés autour de l'équation (III.1). La causalité architecturale est concentrée dans le module causal résiduel (CRM, bloc 2); la stochasticité réside dans le bloc EDM (3).

La décomposition sépare la composante déterministe causale (μ_{HR} , forçage-réponse via le DAG) de la composante stochastique non causale (δ , variabilité fine résiduelle modélisée par EDM). L'écart avec CORRDIFF est entièrement concentré dans la production de μ_{HR} : CORRDIFF y emploie un U-Net générique entraîné par MSE sur $x_{HR} - \text{baseline}$, là où ORACLE substitue un module causal dont la sortie transite obligatoirement par A_{dag} . Le Stage 2, les pertes EDM, le sampler de Heun et le préconditionnement sont hérités tels quels : toute amélioration mesurée

sera attribuable au remplacement du module μ_{HR} , pas à un changement collatéral.

III.3. Graphe atmosphérique hétérogène

Note préliminaire sur la cardinalité du graphe. L'architecture RCN est définie de manière générique pour un nombre arbitraire N de nœuds. La version théorique pleinement résolue compterait jusqu'à environ 32 600 nœuds. Dans toute la suite expérimentale (Chap. IV), nous travaillons avec une **configuration agrégée à $N = 6$ nœuds typés** : un nœud par variable physique, pas un nœud par pixel. Le DAG appris (A_{dag} de taille 6×6) est donc un graphe inter-variables. Cette agrégation est volontaire : elle rend la matrice causale interprétable au prix d'une perte de résolution spatiale dans le graphe (la résolution spatiale est reprise par les blocs convolutifs).

III.3.1. Types de nœuds et hiérarchie verticale

Le graphe G comporte quatre types de nœuds. Les nœuds **GP850**, **GP500**, **GP250**, un par niveau de pression (850, 500 et 250 hPa), portent les variables dynamiques (température, vent, humidité spécifique), à raison d'un nœud par point de la grille LR ($N_{LR} = 23 \times 26 = 598$). Les nœuds **SP_HR** (paramètres statiques de surface à haute résolution) portent les variables statiques HR (orographie, masque terre/mer) avec un nœud par point HR ($N_{HR} = 172 \times 179 = 30\,788$). Le total atteint $\approx 32\,600$ nœuds en configuration complète. Cette dissymétrie LR/HR reflète la nature physique des champs : variables atmosphériques fournies grossièrement par le GCM, caractéristiques de surface définies à la résolution cible.

III.3.2. Types d'arêtes et physique encodée

Le graphe comporte trois types d'arêtes encodant chacune un mécanisme physique : les **spatiales** (voisins horizontaux des GP) modélisent l'advection et la diffusion ; les **verticales** (inter-niveaux GP) modé-

lisent la convection et l'instabilité verticale ; les **statiques-vers-pression** ($SP_{HR} \rightarrow GP$) modélisent l'influence orographique. Cet ensemble constitue le support d'agrégation pour les couches SAGEConv (section III.4.2) ; la matrice A_{dag} apprise par DAGMA pondère par-dessus les liens causaux entre variables.




FIGURE 8 – Vue conceptuelle du graphe atmosphérique hétérogène d'ORACLE. Quatre types de nœuds (GP_{850} , GP_{500} , GP_{250} dynamiques en bleu ; SP_{HR} statique en gris) et trois types d'arêtes (spatiales intra-plan en bleu clair, verticales inter-plans en rouge, statiques-vers-pression en pointillé gris). L'instanciation concrète avec variables nommées et dimensions exactes est différée au chapitre IV.

III.3.3. Drivers statiques et acheminement causal

Plutôt que d'injecter les drivers statiques (orographie, masque, sol) sous forme de canaux supplémentaires du Stage 2 (pratique adoptée par [21]), nous les introduisons exclusivement comme nœuds SP_{HR} du graphe. Leur influence sur μ_{HR} passe nécessairement par les arêtes $SP_{HR} \rightarrow GP$ dont les poids sont gouvernés par A_{dag} , ce qui garantit que toute information transite par le chemin causal et contribue à la propriété (O3).

III.4. Encodeur intelligible et réseau causal récurrent

III.4.1. Motivation : préserver l'identité physique des variables

L'encodeur intelligible projette chaque variable physique (température, vent, humidité, précipitation) dans un espace latent commun de dimension $d = 128$, qui alimentera ensuite le RCN. Sa spécificité tient à la *préservation de l'identité physique* : chaque dimension latente reste attachée à une variable source, au lieu de fondre toutes les variables dans une représentation distribuée opaque. Deux choix techniques portent cette préservation : un perceptron multicouche (MLP, un petit réseau de neurones entièrement connecté) *dédié* $f_{v,p}$ par couple variable-niveau (interdisant tout mélange précoce), et une perte de reconstruction $\mathcal{L}_{rec}$ (section III.8) qui contraint le décodage à reproduire les variables d'entrée.

III.4.2. Architecture par variable et normalisation

Chaque MLP $f_{v,p}$ est de profondeur 3 (activations GELU, une non-linéarité lisse ; normalisation de couche). La normalisation des entrées suit deux conventions : standardisation par moyenne et écart-type pour les variables atmosphériques classiques, et transformation logarithmique $\log(1 + pr)$ pour la précipitation, qui compresse la queue lourde et stabilise l'entraînement. L'agrégation entre nœuds voisins est effectuée par des couches *SAGEConv* [5] :

$$h_i^{(\ell+1)} = \phi \left(W_{\text{self}}^{(\ell)} h_i^{(\ell)} + W_{\text{neigh}}^{(\ell)} \text{mean}_{j \in \mathcal{N}(i)} h_j^{(\ell)} \right), \quad (\text{III.2})$$

où ϕ est une non-linéarité, $W_{\text{self}}^{(\ell)}$ et $W_{\text{neigh}}^{(\ell)}$ des matrices de poids apprises et $\mathcal{N}(i)$ l'ensemble des voisins du nœud i . SAGEConv a été préféré aux variantes par attention (GAT) selon deux lignes de défense :

- **Matériel** : un benchmark sur CPU 48 cœurs montre qu'un GAT à 4 têtes multiplie le temps par batch par environ 5 et la mémoire d'activation par environ 3,5. Stage 1 (environ 140 batches/époque, 75 époques) devient alors infaisable.
- **Théorique** : SAGEConv moyenne localement (filtre passe-bas) et peut lisser les anomalies extrêmes. Cette limite est compensée globalement par A_{dag} , qui surimpose une pondération causale asymétrique entre variables. La synergie est explicite : SAGEConv assume le lissage spatial local, tandis que A_{dag} porte la hiérarchie causale globale. Un GAT, lui, paierait l'attention deux fois.

III.4.3. Réseau causal récurrent : SCM dynamique et mise à jour temporelle

Le *Recurrent Causal Network* (RCN) forme le cœur méthodologique d'ORACLE. À chaque pas de temps, il combine deux briques : un *modèle causal structurel* (SCM) qui prédit l'évolution de l'état caché à partir du DAG appris, et une *mise à jour récurrente* (GRU, une cellule standard des réseaux récurrents qui dose ce qu'elle conserve de l'état précédent et ce qu'elle intègre du nouveau) qui fusionne cette prédiction théorique avec l'observation courante. Le SCM joue le rôle du *plan de vol* théorique, la GRU celui de la *mise à jour aux instruments*. L'originalité d'ORACLE tient à ceci : *le SCM est le moteur récurrent lui-même*. La transition $H_t \rightarrow H_{t+1}$ est une assignation structurelle causale, pas un post-traitement appliqué à un état caché produit par ailleurs.

III.4.4. Équations SCM et mise à jour GRU

À chaque pas t , l'étape SCM produit une prédiction causale $\hat{H}_t$ à partir de H_{t-1} , de l'observation x_t et de A_{dag} . Pour chaque variable i , l'assignation structurelle s'écrit :

$$\hat{H}_t^{(i)} = f_i \left(A_{\text{dag}}^{(i,:)} \odot H_{t-1}, x_t, \epsilon_t^{(i)} \right), \quad (\text{III.3})$$

où $A_{\text{dag}}^{(i,:)}$ regroupe les pondérations causales entrantes vers i , $\odot$ est le produit composante par composante, répliqué sur la dimension des nœuds, $\epsilon_t^{(i)}$ un bruit exogène, et f_i un MLP structurel propre à la variable. Les N fonctions f_i sont implémentées en parallèle, suivant l'usage des SCM neuronaux multivariés. La perte $\mathcal{L}_{\text{rec}}$ contraint $\hat{H}_t$ à porter l'information nécessaire au décodage des variables d'entrée, forçant la dynamique à apprendre des liens prédictifs effectifs.

L'étape GRU fusionne $\hat{H}_t$ et l'embedding x_t^{emb} (produit par un MLP léger FactorEncoder) suivant les équations standard de Cho et al. [2] avec portes z_t, r_t et candidat $\tilde{H}_t$:

$$H_t = (1 - z_t) \odot \hat{H}_t + z_t \odot \tilde{H}_t. \quad (\text{III.4})$$

H_t est réinjecté au pas suivant comme entrée du SCM, fermant la boucle. Après $T = 8$ pas, $H_T = H_T$ est consommé par le décodeur (section III.6). L'état initial H_0 est un paramètre apprenable indépendant du lot.

III.5. Apprentissage du DAG par contrainte DAGMA

Apprendre conjointement la structure d'un DAG et les fonctions structurelles est combinatoire (le nombre de DAG à N nœuds croît super-exponentiellement). Zheng et al. [24] ont reformulé l'acyclicité comme contrainte différentiable $h_{\text{NOTEARS}}(A) = \text{tr}(e^{A \odot A}) - N$, dont l'évaluation reste numériquement coûteuse. Bello, Aragam et Ravikumar [1] ont proposé une caractérisation par log-déterminant d'une M-matrice (matrice inversible à inverse positive) :

$$h_{\text{DAGMA}}(A; s) = -\log \det(sI - A \odot A) + N \log s, \quad (\text{III.5})$$

où $s > \rho(A \odot A)$, le rayon spectral de $A \odot A$, garantit que $sI - A \odot A$ est une M-matrice. h_{DAGMA} s'annule ssi A représente un DAG, ne requiert qu'une décomposition LU, et son gradient se déduit de l'inverse de $sI - A \odot A$. Dans ORACLE, cette pénalité est combinée à une sparsité L_1 encourageant une matrice creuse et auditable :

$$\mathcal{L}_{\text{dag}} = \lambda_{\text{DAGMA}} \cdot h_{\text{DAGMA}}(A_{\text{dag}}) + \lambda_{L_1} \cdot \|A_{\text{dag}}\|_1. \quad (\text{III.6})$$

Les valeurs effectives des coefficients sont détaillées au chapitre suivant.

III.6. Décodeur graphe-à-grille et moyenne haute résolution

Le décodeur transforme l'état caché final $H_T \in \mathbb{R}^{B \times N \times d}$ en une carte $\mu_{\text{HR}} \in \mathbb{R}^{B \times 1 \times H_{\text{HR}} \times W_{\text{HR}}}$. L'intuition d'abord : chaque position d'une grille intermédiaire interroge tous les nœuds du graphe et retient une moyenne pondérée de leurs informations, les poids étant calculés à partir de projections apprises. Formellement, deux étapes : attention croisée entre des requêtes définies sur une grille intermédiaire 43×45 (un quart de la résolution HR dans chaque direction) et l'ensemble des nœuds du graphe (clés/valeurs), suivie d'un sur-échantillonnage bilinéaire et d'un raffinement convolutif vers la résolution HR. L'attention croisée multi-têtes calcule

$$\tilde{\mu}_p = \sum_{n=1}^N \alpha_{p,n} \cdot V_n, \quad \alpha_{p,n} = \frac{\exp(\langle Q_p, K_n \rangle / \sqrt{d})}{\sum_{n'} \exp(\langle Q_p, K_{n'} \rangle / \sqrt{d})}. \quad (\text{III.7})$$

La résolution intermédiaire est dictée par la mémoire : une attention directe à 172×179 produirait une matrice $30788 \times N$ prohibitive dans la configuration pleinement résolue du graphe ; la résolution 43×45 réduit le coût d'un facteur 16 tout en gardant assez de granularité. La carte $\tilde{\mu}$ subit ensuite un sur-échantillonnage bilinéaire vers la résolution HR, un raffinement convolutif léger (deux blocs Conv + GELU + norm) et une projection 1×1 qui produit la carte scalaire μ_{HR} .

III.7. Interface inter-étages et propriété (O3)

III.7.1. Pré-calcul, cache et recalibration de σ_{data}

Une fois le Stage 1 convergé, sa sortie est figée : on pré-calcule et sauvegarde $\mu_{\text{HR}}^{(i)}$ et $\text{baseline}^{(i)}$ pour chaque échantillon. Cette mise en cache (quelques heures) évite de ré-évaluer le CRM à chaque pas du Stage 2, ce qui réduit son coût marginal à celui d'une simple passe de diffusion. L'optimisation s'avère cruciale sur budget CPU-only. À partir des couples pré-calculés, on évalue empiriquement la distribution des résiduels

$$\delta^{(i)} = \log(1 + x_{\text{HR}}^{(i)}) - \log(1 + \text{baseline}^{(i)}) - \mu_{\text{HR}}^{(i)}, \quad (\text{III.8})$$

dont l'écart-type fournit σ_{data} pour le préconditionnement EDM (section III.7.3). Une calibration incorrecte conduit soit à une sous-utilisation du modèle, soit à une instabilité numérique des coefficients de préconditionnement.

III.7.2. Définition formelle de la propriété (O3)

La propriété (O3) opérationnalise l'idée que le chemin causal d'ORACLE est structurellement porteur (*load-bearing*), c'est-à-dire que son retrait dégrade significativement la prédiction. Formellement :

Définition 1 (Indispensabilité causale, O3) Soit $\text{MSE}(\mu_{\text{HR}}(A_{\text{dag}}); x_{\text{HR}})$ l'erreur quadratique moyenne du Stage 1 lorsque l'inférence utilise la matrice d'adjacence apprise A_{dag} , et $\text{MSE}(\mu_{\text{HR}}(\mathbf{0}); x_{\text{HR}})$ la même quantité lorsque cette matrice est forcée à zéro. La quantité contrastive

$$\Delta_{\text{O3}} = \text{MSE}(\mu_{\text{HR}}(\mathbf{0}); x_{\text{HR}}) - \text{MSE}(\mu_{\text{HR}}(A_{\text{dag}}); x_{\text{HR}}) \quad (\text{III.9})$$

mesure l'apport du chemin causal à la qualité de la prédiction. ORACLE satisfait la propriété (O3) à un seuil τ si :

$$\frac{\Delta_{\text{O3}}}{\text{MSE}(\mu_{\text{HR}}(A_{\text{dag}}); x_{\text{HR}})} \geq \tau, \quad (\text{III.10})$$

avec typiquement $\tau \in [0,05, 0,10]$ dans nos protocoles.

L'opérationnalisation de (O3) repose sur la variante d'ablation `noncausal` qui force $A_{\text{dag}} = \mathbf{0}$ à l'inférence (pas à l'entraînement), exposée par le paramètre `run_variant`. C'est l'instrument principal de validation expérimentale ; la mesure de Δ_{O3} est reportée au chapitre suivant.

III.7.3. Étage 2 : paradigme EDM et conditionnement par concaténation

Le second étage échantillonne le résiduel δ conditionnellement à μ_{HR} et à la baseline. Nous reprenons sans modification le formalisme EDM de Karras et al. [10], dont le préconditionnement s'écrit, pour $x_{\sigma} = x + \sigma\epsilon$:

$$\mathcal{D}_{\theta}(x_{\sigma}, \sigma) = c_{\text{skip}}(\sigma) \cdot x_{\sigma} + c_{\text{out}}(\sigma) \cdot \epsilon_{\theta}(c_{\text{in}}(\sigma) \cdot x_{\sigma}, c_{\text{noise}}(\sigma)), \quad (\text{III.11})$$

avec $c_{\text{skip}}, c_{\text{out}}, c_{\text{in}}, c_{\text{noise}}$ fonctions de σ et σ_{data} . Le préconditionnement EDM consiste à **normaliser adaptativement** les entrées et sorties du réseau de diffusion en fonction du niveau de bruit. Cela évite d'avoir à ajuster manuellement des hyperparamètres : le réseau reçoit un signal d'apprentissage stable sur toute la plage de bruit. La perte pondérée s'écrit alors

$$\mathcal{L}_{\text{EDM}}(\theta) = \mathbb{E}_{x, \sigma, \epsilon} \left[\lambda(\sigma) \cdot \|\mathcal{D}_{\theta}(x + \sigma\epsilon, \sigma) - x\|^2 \right]. \quad (\text{III.12})$$

L'échantillonnage utilise un solveur de Heun à pas variable selon le calendrier de Karras. Un examen détaillé du formalisme est donné au chapitre précédent (sous-section II.5.2).

ORACLE conditionne exclusivement par *concaténation de canaux*, et non par cross-attention :

$$\text{input}_{\text{UNet}} = \text{concat}(\delta_{\text{noisy}}, \mu_{\text{HR}}, \log(1 + \text{baseline})) \in \mathbb{R}^{B \times 3 \times H_{\text{HR}} \times W_{\text{HR}}}, \quad (\text{III.13})$$

avec $\delta_{\text{noisy}} = \delta + \sigma\epsilon$. Ce choix tient à deux raisons. La cross-attention ouvre une voie d'information parallèle qui dilue la traçabilité causale ; la concaténation force au contraire le U-Net à *voir* μ_{HR} comme un canal d'image traité localement par ses couches initiales. Et le coût computationnel de la concaténation est nettement inférieur, ce qui pèse en CPU-only.

Modéliser δ plutôt que x_{HR} réduit l'amplitude de la cible. Là où x_{HR} couvre plusieurs ordres de grandeur, δ se trouve centré autour de zéro avec un écart-type de l'ordre de σ_{data} après log-transformation. La calibration de σ_{data} retrouve un sens physique et la variance prédite s'aligne mieux sur la variance observée des résiduels, réduisant la sub-dispersion typique des modèles entraînés sur champ complet (O2). L'interface inter-étages joue le rôle d'un *pacte architectural* : le Stage 1 délivre μ_{HR} comme seule information conditionnelle, le Stage 2 la reçoit par concaténation sans voie d'attention parallèle, et l'ablation $A_{\text{dag}} \leftarrow \mathbf{0}$ n'affecte la sortie que si elle modifie effectivement μ_{HR} , ce qui requiert simultanément que le Stage 1 utilise A_{dag} et que le Stage 2 dépende de μ_{HR} .

III.8. Pertes composites et entraînement

L'entraînement du Stage 1 minimise une perte composite combinant l'erreur quadratique sur μ_{HR} , $\mathcal{L}_{\text{mse}} = \mathbb{E}[\|\mu_{\text{HR}} - (\log(1 + x_{\text{HR}}) - \log(1 + \text{baseline}))\|^2]$, la perte de reconstruction $\mathcal{L}_{\text{rec}}$ qui préserve l'identité physique, et le terme $\mathcal{L}_{\text{dag}}$ regroupant la pénalité DAGMA et la régularisation $\|A_{\text{dag}}\|_1$:

$$\mathcal{L}_{\text{total}}^{(1)} = \mathcal{L}_{\text{mse}} + \alpha \mathcal{L}_{\text{rec}} + \mathcal{L}_{\text{dag}}. \quad (\text{III.14})$$

La procédure se déroule en deux phases. Le Stage 1 est entraîné par l'optimiseur AdamW jusqu'à convergence ; on évalue alors le critère (O3) qui joue le rôle de porte de validation (*gate*) : si $\Delta_{O3}/\text{MSE} < \tau$, le Stage 1 est ré-entraîné ; sinon, ses paramètres sont gelés et on pré-calcule $\mu_{\text{HR}}^{(i)}$, $\text{baseline}^{(i)}$ et σ_{data} empirique. Le Stage 2 minimise ensuite exclusivement $\mathcal{L}_{\text{EDM}}$ (équation III.12) sur les résiduels pré-calculés. Trois éléments du protocole : l'EMA (moyenne mobile exponentielle des poids, décroissance 0,9999) stabilise l'échantillonnage, le *conditioning dropout* (masquage aléatoire du conditionnement pendant l'entraînement, $p \approx 0,13$) prépare la *classifier-free guidance* (amplification, à l'échantillonnage, de l'effet du conditionnement), dont l'intensité `cfg_scale` est calibrée au chapitre suivant.

III.9. Synthèse, traçabilité et choix non retenus

Le tableau IV retrace l’inspiration et le verrou adressé par chaque composant, conformément au principe que tout choix architectural doit être justifié par référence à la littérature et contribution à au moins un axe du trilemme.

TABLEAU IV – *Traçabilité des composants d’ORACLE : inspiration et verrou adressé.*

Composant	Inspiration	Verrou
Décomposition à deux étages	CORRDIFF [15]	Stabilité
Graphe hétérogène SP/GP	Contribution propre	O3 / OOD
Encodeur intelligible par MLP dédiés	Contribution propre	O6
Agrégation SAGEConv	Hamilton et al. [5]	Efficacité
RCN (SCM + GRU)	Pearl [19] + Cho [2]	O3
DAG par DAGMA	Bello et al. [1]	O6
Décodeur graphe-à-grille (cross-attn)	Contribution propre	Efficacité
Diffusion EDM (Stage 2)	Karras et al. [10]	Stabilité, extrêmes
Conditionnement causal_concat	Contribution propre	O3 architectural
Pré-calcul Stage 1	Contribution propre	Efficacité (O5)

Plusieurs alternatives ont été envisagées puis écartées : les *Diffusion Transformers* (coût supérieur à celui du U-Net à la résolution 172×179 , apport empirique non démontré pour le downscaling à cette échelle); le *flow matching* et les *consistency models* (maturité limitée sur cette application, perspective de continuation signalée en conclusion); l’injection des drivers statiques comme canaux supplémentaires du U-Net Stage 2 (écartée pour préserver le passage architectural par le DAG, condition de la validité de O3); la cross-attention pour le conditionnement Stage 2 (écartée au profit de la concaténation, cf. section III.7.3).

Le présent chapitre a présenté ORACLE dans sa forme architecturale finale. La validation empirique (satisfaction effective de la propriété O3, mesure de la sub-dispersion résiduelle, robustesse hors-distribution) constitue l’objet du chapitre suivant, qui documente également l’environnement logiciel, les jeux de données, la trajectoire de développement et la discussion des résultats.

IV

CHAPITRE

MATÉRIELS, MÉTHODES, EXPÉRIMENTATIONS ET DISCUSSION

SOMMAIRE

IV.1 - Introduction	52
IV.2 - Environnement et données	53
IV.3 - Topologie effective d'ORACLE	55
IV.4 - Trajectoire et procédure d'entraînement	57
IV.5 - Protocole d'évaluation	59
IV.6 - Résultats observés	60
IV.7 - Discussion critique	67
IV.8 - Perspectives d'amélioration	72
IV.9 - Synthèse	73

IV.1. Introduction

Le chapitre précédent a présenté ORACLE dans sa forme architecturale finale. Place maintenant à l'expérimentation. Nous décrivons d'abord l'environnement et les données (section IV.2), la topologie effectivement entraînée (section IV.3), la trajectoire de développement et la procédure d'optimisation (section IV.4), puis le protocole d'évaluation (section IV.5).

Les résultats sont exposés en section IV.6 et discutés en section IV.7. Une synthèse (section IV.9) clôt le chapitre. Deux principes de transparence guident la démarche : documenter les variantes écartées en cours de route, et exposer aussi bien les métriques où ORACLE progresse que celles où il sous-performe.

IV.2. Environnement et données

IV.2.1. Pile logicielle et matériel

L'implémentation repose sur Python 3.11 et PyTorch 2.3, étendus par PyTorch Geometric pour les opérateurs sur graphe hétérogène, xarray pour l'ingestion des sorties GCM, et Hydra pour la configuration en fichiers YAML hiérarchiques. La précision mixte automatique (calculs en format flottant réduit `bfloat16` sur GPU, `float32` sur CPU) et la compilation `torch.compile` du UNet du second étage réduisent l'empreinte mémoire et accélèrent l'exécution d'environ 30 %.

Les expérimentations exploratoires initiales (adaptation du code *ResDiff* de NVIDIA à notre environnement Colab) ont tourné sur une station CPU-only à environ 500 Go de mémoire. Les phases intensives sont déportées sur Google Colab : NVIDIA L4 (24 Go) pour le Stage 1, NVIDIA A100 80 Go pour le Stage 2 (UNet 42,8 M paramètres). Un cycle complet demande environ 45 heures cumulées (10–15 époques Stage 1, 200 époques Stage 2 sur résiduels mis en cache). La graine aléatoire est fixée et l'historique sérialisé dans le point de contrôle pour la reproductibilité.

IV.2.2. Données et prétraitements

Le domaine d'étude est la Nouvelle-Zélande, choisi pour trois raisons : référence comparable (jeu HR aligné sur les protocoles CORRDIF [15] et cGAN néo-zélandais [21], deux baselines génératives crédibles) ; diversité climatique compacte (sur $< 270\,000\text{ km}^2$, subtropical au nord, marin tempéré à l'ouest, semi-aride sur le versant oriental sous le vent (*lee*) des

Alpes du Sud, alpin en altitude, soit une large gamme de climats de la classification de Köppen, du subtropical humide à l'alpin); test orographique sévère (gradient ouest–est de plus de 10 000 mm/an sur 50 km, l'un des plus extrêmes au monde). La Nouvelle-Zélande joue donc le rôle de *bac à sable exigeant* : une architecture qui y passe sous ablation causale fournit une preuve forte d'universalité indépendante du climat d'entraînement, préalable à toute mise en production sur des cibles applicatives comme l'Afrique subsaharienne, à ce jour exclues faute de jeu HR de référence [35]. La grille HR couvre 172×179 pixels (5–10 km). Les prédictors LR viennent d'ACCESS-CM2 (CMIP6 historique) sur une grille 23×26 sur-échantillonnée par interpolation bilinéaire (*baseline*). Quinze variables atmosphériques sont conservées : u, v, w , humidité spécifique q , température t , chacune à 850, 500, 250 hPa.

La cible HR est la précipitation journalière, traitée en espace $\log(1 + \text{precip})$ pour stabiliser l'entraînement face à la queue lourde. La sortie finale du modèle est reconstruite par

$$\hat{x}_{\text{HR}} = \text{baseline} + \mu_{\text{HR}} + \hat{\delta}, \quad (\text{IV.1})$$

où μ_{HR} est la moyenne haute résolution causale et $\hat{\delta}$ le résiduel échantillonné par la diffusion. Les données sont partitionnées en entraînement (1980–2009), validation (2010–2012) et test ID (*in-distribution* : même GCM qu'à l'entraînement ; ACCESS-CM2, 2013–2014). Les jeux inter-GCM historiques sont EC-Earth3 et NorESM2-MM sur la même période d'évaluation. Chaque échantillon est une séquence de $T = 8$ pas temporels avec fenêtre glissante de pas 4. Les variables LR sont normalisées canal par canal sur l'ensemble d'entraînement ; un masque binaire exclut les pixels océaniques des pertes et des métriques (domaine continental utile $\approx 60\%$).

Alignement sur Rampal et al. [21]. Notre prétraitement reprend les conventions de la référence cGAN néo-zélandaise : grille HR 172×179 à 5–10 km, grille LR 23×26 alignée sur l'échelle CMIP6, sur-échantillonnage

bilinéaire vers la HR avant injection au générateur. Le tableau V reprend la liste des variables prédicteurs telle qu'elle figure dans la section 2.1 de la référence.

TABLEAU V – Variables atmosphériques LR utilisées en entrée, alignées sur le protocole Rampal et al. [21] (Tableau 1 de la référence). Trois niveaux verticaux par variable, soit 15 canaux au total.

Variable	Symbole	Niveaux (hPa)
Vent zonal	u	850 / 500 / 250
Vent méridien	v	850 / 500 / 250
Vitesse verticale	w ($= \omega$)	850 / 500 / 250
Humidité spécifique	q	850 / 500 / 250
Température	t	850 / 500 / 250

IV.3. Topologie effective d'ORACLE

La Figure 9 synthétise l'architecture globale d'ORACLE comme un pipeline en deux étages : un premier étage causal qui produit la moyenne déterministe μ_{HR} à partir d'un graphe hétérogène intelligible, et un second étage de diffusion résiduelle qui ajoute la composante stochastique $\hat{\delta}$ pour reconstruire la sortie $\hat{x}_{HR}$.




FIGURE 9 – Pipeline architectural d'ORACLE : Stage 1 (causal, déterministe) produit la moyenne μ_{HR} par chemin obligatoire à travers le DAG appris ; Stage 2 (diffusion EDM) échantillonne le résiduel $\hat{\delta}$ conditionné par concaténation de canaux.

Le graphe à $N = 6$ nœuds typés (cf. chapitre III, figure 8 pour le détail topologique) est résumé par la cascade verticale $GP_{250} \rightarrow GP_{500} \rightarrow GP_{850} \rightarrow SP_{HR}$, qui reflète le couplage quasi-géostrophique (l'équilibre de grande échelle entre vent et pression, dominé par la rotation terrestre) descendant attendu en zone alpine.

IV.3.1. Premier étage : encodeur, RCN, décodeur

L'encodeur intelligible comporte 15 MLP dédiés (un par couple variable-niveau), chacun produisant une représentation latente de dimension $d = 128$; l'absence de paramètres partagés préserve la lisibilité de A_{dag} [1]. Le graphe hétérogène a $N = 6$ nœuds ($GP_{850}, GP_{500}, GP_{250}, GP_{850} \rightarrow GP_{500}, GP_{500} \rightarrow GP_{250}, SP_{HR}$), avec $A_{dag} \in \mathbb{R}^{6 \times 6}$ initialisée selon un prior tri-diagonal quasi-géostrophique mais librement apprenable. La cellule du RCN combine propagation par A_{dag} et mise à jour GRU [2] sur huit pas temporels, sous perte de reconstruction $\mathcal{L}_{rec}$. Le décodeur `GraphToGridDecoder` transforme l'état final H_T en μ_{HR} par cross-attention vers une grille intermédiaire 43×45 , sur-échantillonnage bilinéaire et raffinement convolutif léger (environ 407k paramètres). ORACLE ajoute une *skip-connection conditionnelle* `ConditionalSkipBlock`, un raccourci dont la contribution est dosée par une porte apprise, combinant deux voies :

$$\mu_{HR} = \alpha(y_{LR}) \cdot \mu_{causal} + (1 - \alpha(y_{LR})) \cdot \mu_{direct}, \quad (IV.2)$$

avec $\alpha(y_{LR}) \in [0, 1]$ cette porte, initialisée biaisée vers la voie causale ($\alpha_0 \approx 0,88$) et contrainte par une régularisation $\mathcal{L}_{O3-preserve}$ qui pénalise toute dérive sous $\alpha_{floor} = 0,6$. Cette régularisation empêche le modèle de devenir non causal déguisé tout en libérant une capacité résiduelle pour les cas où le LR brut contient un signal directement exploitable.

IV.3.2. Second étage : UNet EDM

Le second étage est un UNet résiduel EDM [10] en configuration *Normal* de l'implémentation CORRDIF de NVIDIA PhysicsNeMo : quatre niveaux de profondeur, `block_out_channels = (128, 256, 256, 256)`, environ 42,8 millions de paramètres. Le conditionnement se fait par conca-

ténation de canaux à l'entrée du UNet, qui reçoit le tenseur à trois canaux $[\delta_{\text{bruit}}, \mu_{\text{HR}}, \log(1 + \text{baseline})]$. Cette interface garantit la propriété (O3) : remplacer μ_{HR} par zéro modifie nécessairement la sortie.

L'écart-type des données σ_{data} est recalibré à la fin du Stage 1 par algorithme de Welford (un calcul incrémental de moyenne et de variance) sur les résiduels réels (typiquement $\sigma_{\text{data}} \approx 0,19$). Cette recalibration empêche le UNet d'apprendre l'identité par défaut, pathologie observée dans nos versions antérieures.

IV.4. Trajectoire et procédure d'entraînement

IV.4.1. Trajectoire des versions et leçons retenues

La conception d'ORACLE résulte d'une suite de phases successives consignées dans `architecture_journey.md`; nous en décrivons les choix structurels validés ou écartés.

Phase 0, HG-SCM abandonné. Le modèle source [40] traite la classification de nœuds et ne propose pas de cadre génératif sur grille HR : périmètre orthogonal, abandon avant développement.

Phases 1–2, single-stage DDPM puis EDM. Diffusion conditionnée par cross-attention [8, 10]. Diagnostic structurel : le DAG appris se révèle décoratif, l'ablation $A_{\text{dag}} \leftarrow \mathbf{0}$ ne dégrade pas la prédiction et (O3) est violée (piège du contournement décrit au chapitre II). Sans architecture *two-stage*, la causalité reste cosmétique.

Phases 3–4, pivot two-stage. Réécriture de l'architecture pour que la séquence $\text{LR} \rightarrow \text{encoder} \rightarrow \text{RCN} \rightarrow H_T \rightarrow \mu_{\text{HR}}$ ferme topologiquement tout bypass. Phase 4 (mai–juin 2026) : UNet remonté à 42,8 M paramètres, recalibration σ_{data} par Welford, sampler (échantillonneur numérique de la diffusion) DPM-Solver++ [41].

Variantes écartées. La *variante capacitaire* (encodeur 192-dim, pertes spectrales FACL et de type Wasserstein) n'améliore pas la baseline. L'*architecture dual-path* s'effondre sur les extrêmes (F1@p99, le score de détection des dépassements du 99^e centile, divisé par 3 ; RAPSD multiplié par 3), ce qui confirme qu'un correcteur parallèle non borné réintroduit le shortcut écarté en Phase 2.

Validation. La version rapportée satisfait simultanément le critère structurel (O3, ratio 0,87) et la cohérence interventionnelle ($Q_{\text{int}} = 2/2$). Nous ne défendons pas ORACLE comme une optimisation Pareto-dominante sur RMSE et F1@p99 (ORACLE ne bat pas CORRDIFF sur ces métriques agrégées tous jours et pixels confondus, dites *pooled*, Tableau VI) mais comme la première version dont l'apport causal architectural est mesurable.

IV.4.2. Procédure two-stage et sampler à l'inférence

Le Stage 1 entraîne conjointement l'encodeur, le RCN, le décodeur et le skip-block via l'optimiseur AdamW [25] (taux 5×10^{-4} , décroissance en cosinus, 10–15 époques). La perte composite combine MSE pixel, reconstruction $\mathcal{L}_{\text{rec}}$, acyclicité $\mathcal{L}_{\text{DAGMA}}$ (activée progressivement sur 5 époques, *warmup*), L_1 sur A_{dag} , $\mathcal{L}_{\text{O3-preserve}}$, pondération renforcée de la queue de distribution (*tail-weighted*, $\tau = \log(1 + 10)$ mm/j, $\alpha = 0,5$) et prior physique tridiagonal. Le Stage 2 entraîne le UNet sur les résiduels gelés via la perte EDM $\mathcal{L}_{\text{EDM}} = \mathbb{E}[\lambda(\sigma) \|\mathcal{D}_\theta(\delta + \sigma n, \sigma) - \delta\|_2^2]$ avec $\lambda(\sigma) = (\sigma^2 + \sigma_{\text{data}}^2) / (\sigma \sigma_{\text{data}})^2$ et facteur 2,0 au-delà du quantile p99. À l'inférence : DPM-Solver++ 32 pas, $S_{\text{churn}} = 40$ (bruit réinjecté pendant l'échantillonnage), $\text{cfg} = 1,5$ (intensité du guidage défini au chapitre III), et des ensembles de $K = 12$ membres (inter-GCM) ou $K = 64$ (ID). Entre les étages, σ_{data} est recalibré et la porte O3

$$\text{ratio}_{\text{O3}} = \mathbb{E}[\|\mu_{\text{HR}}(A_{\text{dag}}) - \mu_{\text{HR}}(\mathbf{0})\|] / \mathbb{E}[\|\mu_{\text{HR}}(A_{\text{dag}})\|] \quad (\text{IV.3})$$

est vérifiée : un ratio sous 0,05 aurait stoppé l'entraînement. ORACLE mesure 0,87, ce qui valide le passage à Stage 2.¹

IV.5. Protocole d'évaluation

Conventions d'unités. Dans le Tableau VI, RMSE et MAE sont en espace $\log(1 + \text{precip})$. Le CRPS et le RMSE global (Tableaux VII et IX) sont en mm/jour ; les indices climatologiques (Tableau VIII) sont en unités propres (RX1day en mm, R10mm et CDD en jours). Nous rappelons l'espace à chaque tableau pour lever toute ambiguïté. Aide-mémoire : CRPS = MAE probabiliste ; spread/RMSE = 1 calibré, < 1 trop confiant ; RAPSD/FSS = structure spatiale ; Q_{int} = signes corrects sur 2 perturbations ; Q_{phys} = orientation du DAG (0,5 aléatoire, 1 parfait).

L'évaluation mobilise quatre familles de métriques croisées : erreur ponctuelle (RMSE, MAE, Pearson global et par échantillon), calibration probabiliste (CRPS, CRPS-SS vs climatologie, ratio *spread-skill*, histogramme de rang : le rang de l'observation parmi les K membres de l'ensemble, plat si l'ensemble est calibré), structure spatiale (distance RAPSD, FSS multi-échelle, pour *Fractions Skill Score*), et extrêmes (F1 @ p95/p99, indices ETCCDI [27] : RX1day, le cumul journalier maximal ; R10mm, le nombre de jours à plus de 10 mm ; CDD, la plus longue série de jours secs consécutifs). Le CRPS-SS utilise comme référence la climatologie empirique pixel par pixel sur le jeu de test (365 jours).

Deux diagnostics spécifiques à l'architecture causale s'y ajoutent. Le *ratio O3* mesure l'indispensabilité architecturale du DAG (équation IV.3). Le *test de perturbation contrôlée* mesure la réponse du modèle à $\Delta(q_{850} + 20\%)$ et $\Delta(t_{850} + 3\text{ K})$, comparée au signe physiquement attendu (Clausius-Clapeyron) ; Q_{int} rapporte la fraction de signes cohérents, avec un intervalle de confiance à 95 % estimé par bootstrap (rééchantillonnage aléatoire des jours) sur $n = 30$ jours.

1. L'ablation $A_{\text{dag}} = 0$ mesure la sensibilité fonctionnelle ; un ratio de 0,87 atteste de la contribution de A_{dag} sans prouver une relation causale au sens de Pearl.

Le test inter-GCM en régime historique utilise EC-Earth3 et NorESM2-MM, sur la même période et les mêmes hyperparamètres que le test ID. Chaque résultat est comparé à une baseline *Noncausal* qui remplace l’encodeur intelligible et le RCN par un régresseur convolutif générique, en conservant à l’identique le UNet EDM et ses hyperparamètres : la comparaison isole strictement l’effet de la causalisation du Stage 1. Cette baseline n’est rien d’autre que CORRDIFF réentraîné dans les mêmes conditions. Nous l’appelons « Noncausal » partout, dans les tableaux comme sur les figures.²

Taille d’ensemble et graine. Les métriques déterministes (Tableau VI) reposent sur un ensemble de $K = 64$ membres, les métriques probabilistes (Tableaux VII et IX) sur un ensemble plus modeste de $K = 12$, contre 192 chez CORRDIFF. Le CRPS et le ratio *spread-skill* étant sensibles à K , cette différence induit une erreur d’échantillonnage de 3 à 13 % sur les métriques d’ensemble, à garder à l’esprit en lisant les valeurs absolues. Par ailleurs, tous les chiffres proviennent d’un unique entraînement (graine fixée, contrainte de calcul) : la variabilité d’initialisation n’est pas quantifiée. Les écarts de quelques pour cent entre modèles sont donc à interpréter avec prudence ; seuls les écarts massifs (CRPS -40% , *spread-skill* $\times 3,5$, distance spectrale $\div 450$) sont robustes à cette incertitude.

IV.6. Résultats observés

IV.6.1. Performance en distribution

ORACLE améliore l’erreur ponctuelle de quatre à six pour cent et réduit la distance spectrale RAPSD de plus de dix pour cent ; la corrélation Pearson reste statistiquement comparable. La structure de l’amélioration suggère que le premier étage causal ne change pas l’ordre de grandeur de la prédiction moyenne mais la place mieux dans l’espace des fréquences spatiales. La métrique F1@p99 régresse, ce qui est discuté en annexe.

2. EC-Earth3 et NorESM2-MM restent en régime historique ; un test SSP futur est porté en perspective.

TABLEAU VI – Métriques en distribution sur ACCESS-CM2 (2013–2014), espace $\log(1 + \text{precip})$, ensemble $K = 64$. Les intervalles entre crochets sont des IC 95 % bootstrap (10 000 rééchantillonnages, $n = 16$ valeurs per-sample).

Métrique	ORACLE	Noncausal	Δ_{rel}	Lecture
RMSE	0,124	0,130	−4,1 %	gain net
MAE	0,060	0,064	−5,7 %	gain net
Pearson global	0,825	0,819	+0,7 %	comparable
Pearson per-sample	0,834	0,829	+0,6 %	IC95 se chevauchent*
F1@p95	0,650	0,656	−0,8 %	comparable
F1@p99	0,512	0,550	−6,9 %	cf. annexe
RAPSD distance	241,8	270,1	−10,5 %	gain net
Δ_{signal} (sensibilité L^1 , $\mu_{\text{HR}} \rightarrow 0$)	0,872	0,839	+4,0 %	gain

Note. Δ_{signal} mesure la chute relative de la norme L^1 du signal prédit lorsque A_{dag} est mis à zéro.

Cette quantité diffère du ratio O3 strict (ΔMSE relatif $\approx 0,107$ rapporté plus loin) et n'est pas numériquement comparable. *Pearson per-sample $n = 16$: IC 95 % bootstrap (10 000 rééch.) [0,802;0,865] pour ORACLE, [0,795;0,860] pour Noncausal; $\Delta = +0,005$ IC [−0,042; +0,051] chevauche zéro $\Rightarrow$ non significatif.

Sur les spectres radiaux moyens, la distance spectrale PSD (calculée sur les spectres moyens, distincte de la distance RAPSD par échantillon du Tableau VI) entre ORACLE et ERA5 est réduite d'un facteur environ 450 par rapport à CORRDIFF. Le *Fractions Skill Score*, qui mesure à partir de quelle échelle spatiale une prédiction devient fiable, confirme cette amélioration : ORACLE est fiable dès l'échelle environ 30 km, contre environ 80 km pour CORRDIFF.

IV.6.2. Calibration probabiliste

TABLEAU VII – Métriques probabilistes en distribution sur ACCESS-CM2, ensemble $K = 12$.

Métrique	ORACLE	Noncausal	Lecture
CRPS (mm/j)	0,249	0,415	gain −40 %
CRPS-SS (vs climatologie)	+0,895	+0,826	+6,9 pts
Spread/RMSE	0,686	0,197	$\times 3,5$
RMSE global (mm/j)	1,118	1,537	−27 %
χ^2 histogramme de rang	$5,4 \times 10^6$	$3,25 \times 10^7$	−83 %

Le CRPS chute de 40 % par rapport à la baseline non causale, gain statistiquement significatif au sens des tests de Diebold-Mariano et de

Wilcoxon (deux tests statistiques appariés de comparaison de prévisions) sur $n = 365 \text{ jours} \times \approx 18000 \text{ pixels continentaux}$. Le ratio *spread-skill* passe de 0,20 à 0,69, soit un facteur 3,5 d'amélioration de la calibration d'ensemble. Le modèle reste sous-dispersif au sens strict de Fortin et al. [26] (cible 1,0) mais sort largement du régime « ensemble inutilisable » ($< 0,5$) pour entrer dans une zone où la quantification d'incertitude commence à être informative. L'histogramme de rang réduit son écart au profil uniforme d'un facteur six.




FIGURE 10 – Diagrammes de fiabilité aux seuils $P(\text{precip} > \{1, 10, 50\} \text{ mm/j})$. ORACLE (bleu) suit la diagonale alors que la baseline Noncausal (orange) reste sous-confiante aux probabilités élevées; une sous-dispersion résiduelle subsiste sur le seuil $> 50 \text{ mm/j}$.

IV.6.3. Indices climatiques et extrêmes

TABLEAU VIII – Biais sur les indices ETCCDI en distribution. Plus c'est proche de zéro, mieux c'est.

Indice	ORACLE	Noncausal	Lecture
RX1day (mm)	−2,73	−4,09	ORACLE sous-prédit moins (−33 %)
R10mm (jours)	+0,88	+2,65	gain net (−67 %)
CDD (jours)	+17,95	+21,51	gain (−17 %, cf. annexe)
DJF (déc.–févr.) moyen (mm/j)	−0,25	−0,09	comparable
PSD distance	0,001	0,447	gain massif ($\times 450$)

ORACLE sous-prédit moins les extrêmes journaliers que la baseline (RX1day −2,73 vs −4,09 mm) et place mieux R10mm (+0,88 vs +2,65). Le CDD reste surestimé d'environ 18 jours, biais hérité de la perte MSE

qui tire les prédictions vers la médiane conditionnelle; aucune valeur opérationnelle n'est revendiquée pour le diagnostic de sécheresse (tête Bernoulli-Gamma, qui sépare l'occurrence et l'intensité de la pluie, portée en perspective, section IV.8). La distance spectrale tombe à un niveau quasi négligeable et la queue droite est reproduite, tandis que CORRDIFF tronque au-delà d'environ 30 mm/j. Le déficit RX1day reste concentré sur le versant occidental des Southern Alps (annexe 14), signature directe de l'absence de DEM (modèle numérique de terrain) en entrée.




FIGURE 11 – Courbes de période de retour ajustées par la loi de Gumbel, la loi statistique des maxima (la période de retour mesure la rareté d'un événement : un événement « centennal » ne survient en moyenne qu'une fois par siècle) pour la précipitation journalière maximale sur le domaine, en distribution (ACCESS-CM2) et hors distribution (EC-Earth3, NorESM2-MM). ORACLE (bleu) suit la vérité (noir) jusqu'aux périodes de retour les plus longues sur les trois GCM; la baseline Noncausal (orange) sature systématiquement en dessous des extrêmes observés.

IV.6.4. Robustesse inter-GCM en régime historique

TABEAU IX – Métriques inter-GCM historiques sur deux GCM extérieurs (ID = ACCESS-CM2 rappelé pour référence).

GCM	ORACLE		Noncausal		Δ CRPS	Lecture
	CRPS	spr/RMSE	CRPS	spr/RMSE		
ACCESS-CM2 (ID)	0,249	0,686	0,415	0,197	−40 %	gain net
EC-Earth3 (inter-GCM)	0,319	0,575	0,457	0,183	−30 %	gain net
NorESM2-MM (inter-GCM)	0,342	0,593	0,478	0,196	−28 %	gain net

Sur le split ID, ORACLE atteint un CRPS de 0,249 contre 0,415 pour CORRDIFF (gain absolu de 40%). Sur les splits inter-GCM, ORACLE monte à 0,319 (EC-Earth3) et 0,342 (NorESM2-MM) contre 0,457 et 0,478 respectivement. ORACLE part d'un meilleur point ID; sa dégradation relative inter-GCM est légèrement plus marquée que celle de CORRDIFF, mais il reste $1,4\times$ meilleur en valeur absolue. Le gain causal porte donc sur le *niveau* d'erreur, pas sur la *pente* de dégradation. Le ratio *spread-skill* reste largement au-dessus de la baseline sur les deux jeux inter-GCM (0,58 à 0,59 vs 0,18 à 0,20).

Stabilité temporelle du gain. Un test directionnel complémentaire évalue les deux modèles sur trois tranches intra-historiques de la même chaîne ACCESS-CM2 : la référence en distribution (2012–2013), une tranche antérieure jamais vue (1960–1965, soit quatorze ans avant le début de la période d'entraînement) et la queue chaude de la période de test (les 7 % de jours les plus chauds en t_{850} du pool 2012–2014, hors entraînement et validation). Le protocole est allégé (120 jours par tranche, 75 pour la queue chaude, ensembles à $K = 8$ membres), la normalisation restant figée sur les statistiques d'entraînement. Le gain relatif de CRPS d'ORACLE reste stable : 33,0 % en distribution (0,302 contre 0,451), 30,6 % sur la tranche antérieure (0,389 contre 0,561) et 35,2 % sur la queue chaude (0,288 contre 0,444), avec un ratio spread-skill supérieur sur les trois tranches ($\approx 0,26$ contre $\approx 0,20$). Trois précautions bornent cette lecture. Les décalages testés restent faibles (au plus $0,34\sigma$ en t_{850} moyen sur le domaine) : la tranche 1960–1965 mesure une extrapolation temporelle, pas un climat notablement plus froid. La queue chaude recoupe les années de la référence : c'est un sous-échantillonnage conditionnel du jeu de test, pas une sortie de distribution. Enfin, comme en inter-GCM, la pente de dégradation n'avantage pas ORACLE (sur la tranche antérieure, +28,8 % contre +24,4 % pour CORRDIFF, écart indiscernable du bruit d'échantillonnage à cet effectif). Ce test établit donc la persistance de l'avantage hors de la

fenêtre temporelle d'entraînement ; il ne démontre pas une robustesse au décalage climatique de type scénario.

IV.6.5. Diagnostics causaux

TABLEAU X – Réponse aux perturbations contrôlées $\Delta(q + 20\%)$ et $\Delta(t + 3\text{ K})$; IC bootstrap 95 % sur $n = 30$. CC = relation de Clausius-Clapeyron.

Modèle	Perturbation	δ_{moy}	IC 95 %	Signe	Lecture
ORACLE	$\Delta(q_{850})$	$+1,24 \times 10^{-3}$	exclut 0	oui	cohérent CC
ORACLE	$\Delta(t_{850})$	$+0,84 \times 10^{-3}$	exclut 0	oui	cohérent CC
Noncausal	$\Delta(q_{850})$	$+0,55 \times 10^{-3}$	exclut 0	oui	cohérent
Noncausal	$\Delta(t_{850})$	$-0,84 \times 10^{-3}$	exclut 0	non	contraire CC

ORACLE répond avec un signe physiquement correct aux deux perturbations contrôlées (2/2). La baseline est cohérente sur l'humidité mais inverse le signe sur la perturbation thermique (1/2), parce qu'elle apprend la corrélation observationnelle température élevée $\leftrightarrow$ régimes anticycloniques secs de la Nouvelle-Zélande, sans capter la relation Clausius-Clapeyron qui agirait toutes choses égales par ailleurs.³

Structure de A_{dag} . Sur la configuration principale (6 nœuds typés), A_{dag} comporte sept arêtes de magnitude $\geq 0,05$, toutes comprises entre 0,178 et 0,189. La distribution est remarquablement plate, avec deux arêtes correctement orientées sur les cinq physiquement attendues ($Q_{\text{phys}} = 0,40$). Cette platitude tient à la limite d'identifiabilité observationnelle d'un modèle structurel appris sur données non expérimentales [19] : la contrainte DAGMA [1] pénalise la non-acyclicité et la non-parcimonie, mais rien n'y hiérarchise les magnitudes. Le DAG appris se lit donc comme une régularisation topologique inductive ; l'expérience exploratoire à 9 nœuds (discussion) montre que cette platitude n'est pas une limite intrinsèque de l'architecture.

La matrice A_{dag} présente une structure plate ($Q_{\text{phys}} = 0,40$, 2/5 arêtes physiques correctement orientées) avec trois pathologies à signaler : *sim-*

3. $n = 30$ par perturbation, magnitudes en 10^{-3} unités relatives ; nous parlons donc de *réponse interventionnelle cohérente* plutôt que d'*identification causale complète*.




FIGURE 12 – *Integrated Gradients (méthode d’attribution mesurant la contribution de chaque variable d’entrée à la prédiction) agrégés par variable LR (u, v, w, q, t sur les niveaux 850, 500, 250 hPa), baseline = climatologie moyenne. Gauche : magnitude moyenne $|IG|$; ORACLE (bleu) exploite chaque variable d’un à deux ordres de grandeur plus que la baseline Noncausal (orange). Droite : ratio $|IG|_{\text{ORACLE}}/|IG|_{\text{Noncausal}}$; les variables verticales et thermiques ($w_{850}, w_{500}, t_{850}$) ressortent comme leviers principaux.*

plification à 6 nœuds qui ne capture pas vorticité/divergence (enrichissement à 12–20 nœuds en perspective) ; effet de proxy ($t_{850} = 0,118$ au-dessus de $q_{850} = 0,046$ en sensibilité, le modèle exploite la corrélation Clausius-Clapeyron sans distinguer causalement les deux variables) ; *arête physiquement incorrecte* $SP_HR \rightarrow GP_{850}$, que nous mentionnons plutôt que de la masquer. Sous $\Delta t + 3$ K la sensibilité $\Delta \text{pluie}/\Delta T \approx 0,01 \text{ \%}/\text{K}$ reste trois ordres de grandeur sous les environ $7 \text{ \%}/\text{K}$ de Clausius-Clapeyron : le signe est correct, la magnitude ne l’est pas. Le test d’intervention vaut donc comme contrôle de cohérence directionnelle, **pas comme outil de projection climatique.**⁴

4. Les magnitudes sont presque toutes égales (environ 0,18), sans hiérarchie nette. Remplacer A_{dag} par une matrice aléatoire ne bouge la MSE que de 0,107 : à six nœuds, le DAG ne porte pas l’essentiel de l’erreur brute, et c’est le comportement attendu ; l’ablation complète sur la chaîne two-stage entière (Tableau XI) quantifie cette décomposition. Le gain de *skill* vient de l’architecture causale à deux étages et de la recalibration σ_{data} . Le DAG, lui, joue un autre rôle : il permet l’intervention

IV.7. Discussion critique

Trois résultats robustes. Le CRPS recule de 40 % en distribution et de 28–30 % en inter-GCM historique, écart significatif au sens de Diebold-Mariano ($p < 0,01$). Comme le CRPS combine biais et calibration, ce gain reflète une amélioration de la *forme* de la distribution prédite, pas seulement de sa moyenne. Le ratio *spread-skill* passe de 0,20 à 0,69 ($\times 3,5$). La dispersion de l'ensemble ORACLE se rapproche nettement de l'erreur observée, sans l'atteindre tout à fait ; on peut commencer à lire les quantiles comme des intervalles de confiance, ce qu'un ratio de 0,2 interdisait : un tel ratio promet une précision que le modèle ne tient pas. La distance spectrale chute de 0,45 à 0,001 : la baseline lissait les échelles 30–80 km, ORACLE restitue la structure multi-échelle requise par l'hydrologie distribuée et la cartographie du risque d'inondation.

Régularisation topologique vs identification physique. La propriété (O3), validée par le ratio d'ablation 0,87, garantit qu'aucun chemin de calcul ne contourne A_{dag} . Nos premières architectures à cross-attention ne satisfaisaient pas cette contrainte (chapitre II et Phases 1–2 ci-dessus). La double mesure $Q_{\text{int}} = 2/2$ vs $Q_{\text{phys}} = 0,40$ explicite l'asymétrie : signes interventionnels corrects, mais magnitudes plates et seulement deux arêtes du couplage quasi-géostrophique correctement orientées. Cela correspond à la limite d'identifiabilité observationnelle d'un SCM [19]. Le DAG appris se lit comme un *graphe de contraintes fonctionnelles* qui régularise la prédiction, non comme une cartographie physique identifiée.

Ablation : que porte le two-stage, que porte le DAG ? Pour séparer la contribution du paradigme two-stage causal de celle de la structure fine du DAG, nous évaluons quatre variantes à protocole strictement identique, en ne touchant que A_{dag} à l'inférence (Tableau XI). Sur l'écart total de CRPS entre la baseline et ORACLE complet (0,084 mm/j à ce protocole),

contrôlée (Q_{int}) et la vérification structurelle (O3), et il retrouve la vraie structure physique dès qu'on lui donne assez de nœuds (§IV.7).

l'architecture two-stage causale en apporte l'essentiel (0,071 mm/j, soit 84 %) : même privé de son DAG ($A_{\text{dag}} = \mathbf{0}$), le chemin causal entraîné reste 13,5 % meilleur que la baseline. La structure fine du DAG ajoute le complément (0,014 mm/j, 16 %), petit mais du bon côté sur toutes les métriques (CRPS, dispersion, RMSE). Une observation renforce la lecture : remplacer A_{dag} par une matrice acyclique aléatoire de même norme de Frobenius fait *pire* que la mettre à zéro (0,529 contre 0,522 mm/j) ; une topologie fausse nuit là où la topologie apprise aide, ce qui montre que la structure n'est pas interchangeable. La revendication causale du mémoire, les contributions (C1) et (C2) annoncées en introduction, se calibre donc ainsi : le couplage architectural (encodeur intelligible, RCN, interface O3) porte le gain de skill, le DAG appris y ajoute un complément mesurable, et c'est lui qui permet l'intervention contrôlée (Q_{int}) et la vérification structurelle (O3) qui font l'objet des diagnostics causaux.

TABLEAU XI – Ablation du DAG à protocole fixé : quatre variantes évaluées à l'identique sur ACCESS-CM2 en distribution (sous-ensemble de 40 jours, $K = 8, 14$ pas de diffusion, espace mm/j). Seul A_{dag} change à l'inférence ; la variante « aléatoire » utilise une matrice acyclique de même norme de Frobenius. Les valeurs absolues ne sont pas comparables au Tableau VII (protocole réduit) ; seules les différences entre variantes s'interprètent.

Variante	CRPS	Spread/RMSE	RMSE	Lecture
ORACLE complet (A_{dag} appris)	0,508	0,255	1,821	référence
$A_{\text{dag}} = \mathbf{0}$	0,522	0,250	1,860	+2,7 % CRPS
A_{dag} aléatoire (même norme)	0,529	0,250	1,867	+4,2 % CRPS
Noncausal (baseline)	0,592	0,232	2,109	+16,6 % CRPS

Le DAG peut apprendre la physique : architecture à 9 nœuds. La limite d'identifiabilité n'est pas un plafond architectural. L'architecture ORACLE à 9 nœuds développée en parallèle (un nœud par variable atmosphérique, là où la configuration principale agrège plusieurs variables par nœud typé pour préserver la lisibilité) atteint $Q_{\text{phys,continu}} = 0,9997$, $Q_{\text{phys,binaire}} = 1,0$, un gain de magnitude des arêtes physiques $\text{phys_mag_gained} = 6,37$ et un squelette de graphe exactement retrouvé (skeleton_F1 parfait, aucune arête surnuméraire : $n_{\text{extra}} = 0$). ORACLE est donc *capable* d'ap-

prendre un DAG physiquement fidèle dès que la cardinalité s’aligne sur le système : la platitude à 6 nœuds est le coût d’une agrégation choisie pour la lisibilité humaine, pas une faiblesse intrinsèque. Ce choix ne coûte rien sur la tâche, au contraire : à protocole d’évaluation identique ($K = 64$, 16 batches de test), la configuration à 6 nœuds *domine* la variante à 9 nœuds sur *toutes* les métriques de *skill* (RMSE, F1@p99, corrélation, fidélité spectrale, calibration ; Tableau XII), la variante à 9 nœuds n’échangeant ce skill que contre la fidélité du DAG (Q_{phys}). C’est pourquoi nous retenons le 6 nœuds comme **modèle principal** : la tâche est le downscaling de la précipitation, pas la découverte causale, et l’on choisit la configuration qui downscale le mieux tout en conservant un squelette causal lisible ; la variante à 9 nœuds vaut comme *preuve* que la machinerie causale est réelle et non décorative (documentée en annexe B).

TABLEAU XII – *Compromis lisibilité/skill contre fidélité causale du DAG : configuration principale à 6 nœuds contre variante à 9 nœuds, même protocole d’évaluation ($K = 64$, 16 batches de test, espace $\log(1 + \text{precip})$ sauf Q_{phys}). Le 6 nœuds l’emporte sur tout le skill ; le 9 nœuds seulement sur la fidélité du DAG.*

Métrique	6 nœuds	9 nœuds	Meilleur
RMSE	0,124	0,141	6 nœuds
MAE	0,060	0,069	6 nœuds
F1@p99	0,512	0,453	6 nœuds
Pearson global	0,825	0,767	6 nœuds
Distance RAPSD	241,8	319,4	6 nœuds
Ratio <i>spread-skill</i>	0,412	0,360	6 nœuds
Q_{phys} (fidélité DAG)	0,40	0,9997	9 nœuds

Menaces à la validité. (i) *Transport NZ→Afrique* : le terrain néo-zélandais constitue un test sévère du trilemme (diversité climatique compacte, gradient orographique extrême), mais la transposition au climat tropical (mousson ouest-africaine, instabilité convective dominante) reste à démontrer. (ii) *Taille d’ensemble* modeste ($K = 12$ inter-GCM, $K = 64$ ID contre 192 chez CORRDIFF), erreur d’échantillonnage de 3 à 13 % sur les métriques d’ensemble. (iii) *Partition temporelle réduite* (24 mois de test) : les conclusions RX1day sont un signal, pas une démonstration clima-

tologique au sens de la communauté de l'attribution. (iv) *Variables LR omises* (Tableau XIII) : MSLP, IVT, SST, CAPE/CIN auraient apporté une information physique directe ; surtout, l'orographie haute résolution (DEM HR) reste absente en entrée. (v) *Inter-GCM historique seulement* : la robustesse en projection future (SSP5-8.5) n'est pas évaluée empiriquement, alors que c'est précisément la condition d'usage en projection. Sous $\Delta t + 3 \text{ K}$, la sensibilité $\Delta P / \Delta T$ reste trois ordres de grandeur sous le rapport de Clausius-Clapeyron : le signe est correct, la magnitude ne l'est pas, ce qui circonscrit le test interventionnel à un contrôle de cohérence directionnelle plutôt qu'à un outil de projection thermodynamique.

Absence du DEM HR : limite structurelle isolable. Le biais RX1day d'ORACLE se concentre sur le versant occidental des Alpes du Sud (annexe B), précisément là où le soulèvement orographique génère les extrêmes. Le même schéma apparaît chez CORRDIFF et le cGAN néo-zélandais : la cause est l'information manquante en entrée (aucun des trois modèles ne dispose de la topographie à 5 km), pas la causalisation. Sur ces extrêmes orographiques précis, la comparaison à CORRDIFF se fait donc à information d'entrée égale et également déficitaire : le meilleur RX1day d'ORACLE n'est pas à porter au crédit de la causalisation, il reflète surtout un lissage différent. L'apport causal se mesure ailleurs (calibration, structure spectrale, robustesse inter-GCM), pas sur ce biais de relief. Ce constat oriente directement la première piste corrective ci-dessous.

TABLEAU XIII – Variables atmosphériques non incluses dans l'ensemble des prédicteurs
 LR : rôle physique, raison d'exclusion, gain attendu.

Variable	Rôle physique	Pourquoi exclure	Gain attendu
MSLP (pression au niveau de la mer)	Distinguer les fronts + cycloniques des hautes pressions	Baroclinicité	Mieux séparer les pluies frontales et convectives
IVT (transport intégré de vapeur d'eau)	Diagnostic des modes sphériques (en-vision 50 % des extrêmes côte ouest NZ)	Non	Améliorer la prévision des queues hautes
SST (température de surface de la mer)	Flux de chaleur latente et CAPE de surface	Hors prise en compte	Stationnarité saisonnière
CAPE / CIN (énergie convective disponible / inhibition convective)	Instabilité convective	Hors variables ERA5	Mieux capturer les single-pics
MÉMOIRE DE MASTER EN INFORMATIQUE, UNIVERSITÉ DE DSCHANG		level-1 télé-chargées	RX1day d'été

Périmètre des contributions. Ce que ce chapitre démontre : un gain de CRPS de 40 % en distribution et de 28–30 % en inter-GCM historique face à une baseline strictement appariée ; la persistance de ce gain (30 à 35 %) sur des tranches temporelles hors de la fenêtre d'entraînement (période 1960–1965 jamais vue, queue chaude 2012–2014) ; une calibration d'ensemble multipliée par 3,5 ; une distance spectrale divisée par 450 ; l'indispensabilité architecturale du chemin causal (ratio $O3 = 0,87$) ; une réponse de signe correct aux deux perturbations contrôlées. En regard, le mémoire ne prétend ni à un DAG identifié au sens de Pearl sur la configuration principale ($Q_{\text{phys}} = 0,40$ à 6 nœuds typés, la variante à 9 nœuds atteignant 0,9997 ; Tableau XII et annexe B), ni à une robustesse hors-distribution climatique de type scénario (les tests inter-GCM et temporels restent en régime historique, avec des décalages $\leq 0,34\sigma$; SSP5-8.5 reportée), ni à la transférabilité géographique (aucune donnée africaine), ni à la variabilité inter-graine (un seul entraînement). Les contributions revendiquées tiennent dans un périmètre étroit mais défini : l'architecture causale améliore la robustesse inter-GCM en régime historique sur un climat tempéré-marin à orographie marquée, sans dégrader la stabilité d'entraînement ni le réalisme des extrêmes par rapport à CORRDIFF.

IV.8. Perspectives d'amélioration

Cinq pistes correctives se dégagent du diagnostic.

(i) **Enrichir le graphe.** L'agrégation à 6 nœuds typés sacrifie la fidélité physique pour la lisibilité du DAG ; la variante à 9 nœuds le démontre ($Q_{\text{phys}} = 0,9997$; annexe B), au prix d'un skill de downscaling moindre (Tableau XII). L'extension naturelle ajoute des nœuds dédiés à la physique des extrêmes : IVT (rivières atmosphériques, environ 50 % des extrêmes côte ouest), MSLP (fronts vs hautes pressions), CAPE/CIN (convection d'été). Chacun répond à une cause physique identifiée d'un biais résiduel.

(ii) Injecter l’orographie HR. Le DEM HR doit entrer comme nœud statique SP_HR (acheminement causal déjà prévu, chapitre III) *et* comme canal supplémentaire dans la concaténation Stage 2. Ce double acheminement, dans l’esprit d’un *ControlNet* où les champs statiques modulent spatialement le décodeur EDM, corrige le biais RX1day localisé sur le relief.

(iii) Tête Bernoulli-Gamma pour l’intermittence. La perte MSE tire vers la médiane conditionnelle (CDD biaisé +18 j). Une tête Bernoulli-Gamma [14] sépare décision (pleut/ne pleut pas) et intensité, branchée au décodeur sans toucher au reste. La piste est déjà identifiée par [21] sur la même cible.

(iv) Régularisation physique du DAG. Une pénalité $\lambda \|A_{\text{dag}} - A_{\text{prior}}\|_F^2$ injecte la hiérarchie causale comme prior souple. Une régularisation de type CASTLE (reconstruction causale auxiliaire) [28] en *fine-tuning* sur les dernières époques amplifierait les signaux thermodynamiques sans casser l’acyclicité acquise, déjà partiellement validée par la variante à 9 nœuds.

(v) SSP5-8.5 et cible africaine. L’évaluation en projection future requiert SSP5-8.5, seul cadre où la sensibilité Clausius-Clapeyron devient mesurable. Le transfert géographique vers l’Afrique reste conditionné à un jeu HR de référence sur la zone visée ; il constitue l’horizon applicatif final.

IV.9. Synthèse

Trois résultats se dégagent. L’architecture tient ses promesses structurales : la propriété (O3) est satisfaite par construction et vérifiée empiriquement (ratio 0,87). Les gains métriques sont nets : CRPS -40% ID et -30% inter-GCM, ratio *spread-skill* multiplié par 3,5, distance spectrale divisée par 450, biais RX1day ramené de $-4,1$ à $-2,7$ mm. La frontière entre causalité architecturale et identification physique est cartographiée : le DAG appris reste plat ($Q_{\text{phys}} = 0,40$), à la limite d’identifiabi-

lité observationnelle [19], mais la réponse interventionnelle est cohérente ($Q_{\text{int}} = 2/2$ contre $1/2$ pour la baseline). La causalité utile au downscaling probabiliste tient donc autant au couplage architectural qu'à la structure fine du graphe.

ORACLE progresse ainsi nettement sur l'axe « robustesse inter-GCM » du trilemme (cf. chapitre I) sans dégrader la stabilité d'entraînement ni le réalisme des extrêmes par rapport à CORRDIFF.

CONCLUSION GÉNÉRALE ET PERSPECTIVES

SOMMAIRE

Problématique étudiée et choix méthodologiques	75
Analyse critique des résultats obtenus	76
Quelques perspectives	77

Problématique étudiée et choix méthodologiques

Ce mémoire est parti d'un constat. Aucun modèle actuel de descente d'échelle par apprentissage ne combine la rapidité des réseaux profonds avec une robustesse de principe au changement de distribution, c'est-à-dire au cas où les données rencontrées à l'usage ne ressemblent plus à celles de l'entraînement. Le paradigme à deux étages de CORRDIFF [15] stabilise l'entraînement, mais son premier étage de régression générique reste vulnérable à tout déplacement de régime. Notre choix méthodologique a été de *causaliser* ce premier étage en plaçant la causalité dans la topologie du graphe de calcul plutôt que dans une régularisation de la perte. La raison est simple : une régularisation peut être contournée par un réseau suffisamment expressif, alors qu'une dépendance architecturale ne peut, par construction, pas être contournée.

Quatre éléments structurent la contribution, selon les étiquettes annoncées en introduction : (C1) une architecture à deux étages (*two-stage*)

où la causalité est inscrite dans la topologie du chemin de calcul; (C2) un réseau causal récurrent (RCN) intégrant dans une seule cellule le modèle d'équations causales (SCM), la mémoire récurrente (GRU [2]) et la contrainte d'acyclicité (DAGMA [1]) présentés aux chapitres I et III; (C3) une interface inter-étages par concaténation de canaux garantissant qu'aucune information ne contourne le chemin causal (propriété O3 vérifiée empiriquement, ratio 0,87); (C4) un protocole expérimental à six familles de métriques avec deux diagnostics causaux originaux, à savoir le ratio O3 et le test d'intervention Q_{int} .

Analyse critique des résultats obtenus

Sur la Nouvelle-Zélande (ACCESS-CM2 en distribution; EC-Earth3 et NorESM2-MM, deux autres modèles climatiques globaux ou GCM, en inter-GCM historique), ORACLE réduit le CRPS, l'erreur de prévision probabiliste, de 40 % en distribution et de 30 % en inter-GCM par rapport à une *baseline* (modèle de référence) non causale strictement comparable. Le ratio *spread-skill*, qui compare l'incertitude annoncée à l'erreur réellement commise (idéalement 1), passe de 0,20 à 0,69, soit un facteur 3,5 de réduction de la sous-dispersion de l'ensemble, sans atteindre encore la calibration idéale. La distance spectrale RAPSD, qui mesure l'écart de finesse des textures entre cartes produites et cartes observées, chute d'un facteur 450. Sur deux perturbations contrôlées, ORACLE répond avec un signe physiquement cohérent ($Q_{\text{int}} = 2/2$), là où la baseline non causale échoue sur l'intervention thermique. Les trois hypothèses de départ reçoivent des verdicts contrastés. Séparer une moyenne déterministe d'un résidu stochastique améliore la stabilité et la calibration : validé sans ambiguïté. La causalité améliore la généralisation d'un modèle climatique à l'autre : validé, mais modérément. Enfin, l'indispensabilité architecturale du graphe (O3) écarte le risque d'un graphe causal purement décoratif : validé par construction.

Plusieurs limites doivent cependant être assumées explicitement :

- La matrice A_{dag} apprise reste à magnitudes uniformes ($Q_{\text{phys}} = 0,40$, le score d'accord entre les arêtes apprises et la physique attendue, sur une échelle de 0 à 1) : au vu des données seules, le graphe appris est indiscernable des autres membres de sa classe d'équivalence de Markov (l'ensemble des graphes que des données observationnelles ne permettent pas de départager), conformément à la limite théorique d'identifiabilité [19]. Le DAG appris est une régularisation structurelle inductive, pas une cartographie causale identifiée.
- Les magnitudes interventionnelles restent environ trois ordres de grandeur sous la valeur théorique de Clausius-Clapeyron (la loi qui relie réchauffement et humidité disponible) : le signe est correct, la magnitude ne l'est pas.
- Le test inter-GCM porte sur le régime historique, distinct d'un vrai test hors-distribution climatique (test sur un scénario d'émissions futur, dit SSP, encore à effectuer).
- Aucune donnée africaine n'est testée et la métrique F1 @p99 (détection des dépassements du 99^e centile) régresse en raison d'une régularisation interne lissante.
- Les chiffres reposent sur un seul *seed* (graine aléatoire) d'entraînement (contrainte CPU) et une taille d'ensemble modeste ($K = 12$ membres en inter-GCM, $K = 64$ en distribution, contre 192 membres pour CORRDIFF).

Quelques perspectives

Cinq axes structurent la suite des travaux, hiérarchisés par horizon temporel :

Court terme (1–2 mois). Une recalibration d'ensemble post-hoc par EMOS [30] ou BMA (deux méthodes statistiques classiques de correction des ensembles) améliorerait la calibration sans toucher à l'architecture. Nous l'avons écartée ici pour préserver la comparabilité avec la baseline. La validation sur le scénario SSP5-8.5 (le scénario d'émissions le plus in-

tense considéré par le GIEC), exécutable sans modification architecturale sur les données CMIP6 disponibles, transformerait notre test inter-GCM historique en véritable test hors-distribution climatique.

Moyen terme (3–6 mois). Un ancrage prédictif joint de type CASTLE [28] forcerait chaque arête de A_{dag} à porter un signal effectif, par *fine-tuning* de 25 à 30 époques sans changement d’architecture. En complément, un masque physique sur A_{dag} , via un terme $\lambda_{\text{prior}} \|A_{\text{dag}} - \alpha G_{\text{phys}}\|^2$, pénaliserait les écarts au couplage quasi-géostrophique attendu (l’équilibre de grande échelle entre vent et pression). Cette piste s’inscrit dans la lignée du *physics-informed ML* [29].

Long terme (1–3 ans). Le transfert vers l’Afrique subsaharienne reste la motivation finale du travail. Une première étape est une vérification de cohérence par transfert direct, sans ré-entraînement (*zero-shot*), sur les Hautes Terres éthiopiennes ou le Sahel occidental, avec CHIRPS (un produit d’estimation des précipitations combinant satellite et stations au sol, couvrant l’Afrique) comme cible haute résolution. Vient ensuite un ré-entraînement sur des prédicteurs adaptés (mousson, ondes d’Est, zone de convergence intertropicale) et un DAG révisé. Le changement de prior (le graphe causal supposé a priori) est essentiel : le prior néo-zélandais encode un couplage descendant (jet polaire), alors qu’en Afrique équatoriale la convection profonde impose un schéma ascendant (transport intégré d’humidité IVT $\rightarrow$ énergie convective disponible CAPE $\rightarrow$ précipitation de surface SP_{HR}). La réanalyse atmosphérique ERA5 [7] sert de substitut d’initialisation faute de réseau radar dense.

Ce mémoire défend que la causalité utile au downscaling probabiliste n’est pas une propriété décorative émergeant d’une régularisation, mais une contrainte architecturale à placer explicitement dans la topologie du graphe de calcul. Cette approche fait ses preuves en Nouvelle-Zélande aujourd’hui ; elle devra les refaire demain dans les communautés d’Afrique centrale qui ont motivé ce travail.

BIBLIOGRAPHIE

- [1] K. Bello, B. Aragam, and P. Ravikumar. DAGMA : Learning DAGs via M-matrices and a log-determinant acyclicity characterization. In *Advances in Neural Information Processing Systems*, 2022.
- [2] K. Cho, B. van Merriënboer, C. Gulcehre, D. Bahdanau, F. Bougares, H. Schwenk, and Y. Bengio. Learning phrase representations using RNN encoder-decoder for statistical machine translation. In *EMNLP*, 2014.
- [3] V. Eyring, S. Bony, G. A. Meehl, C. A. Senior, B. Stevens, R. J. Stouffer, and K. E. Taylor. Overview of the Coupled Model Intercomparison Project Phase 6 (CMIP6) experimental design and organization. *Geoscientific Model Development*, 9 :1937–1958, 2016.
- [4] I. Goodfellow, J. Pouget-Abadie, M. Mirza, B. Xu, D. Warde-Farley, S. Ozair, A. Courville, and Y. Bengio. Generative adversarial nets. In *NeurIPS*, 2014.
- [5] W. L. Hamilton, R. Ying, and J. Leskovec. Inductive representation learning on large graphs. In *NeurIPS*, 2017.
- [6] L. Harris, A. T. T. McRae, M. Chantry, P. D. Dueben, and T. N. Palmer. A generative deep learning approach to stochastic downscaling of precipitation forecasts. *Journal of Advances in Modeling Earth Systems*, 14(10) :e2022MS003120, 2022.
- [7] H. Hersbach et al. The ERA5 global reanalysis. *Quarterly Journal of the Royal Meteorological Society*, 146 :1999–2049, 2020.

- [8] J. Ho, A. Jain, and P. Abbeel. Denoising diffusion probabilistic models. In *Advances in Neural Information Processing Systems*, 2020.
- [9] IPCC. *Climate Change 2021 : The Physical Science Basis. Contribution of Working Group I to the Sixth Assessment Report of the Intergovernmental Panel on Climate Change*. Cambridge University Press, 2021.
- [10] T. Karras, M. Aittala, T. Aila, and S. Laine. Elucidating the design space of diffusion-based generative models. In *Advances in Neural Information Processing Systems*, 2022.
- [11] D. P. Kingma and M. Welling. Auto-encoding variational Bayes. In *ICLR*, 2014.
- [12] R. Lam et al. Learning skillful medium-range global weather forecasting. *Science*, 382(6677) :1416-1421, 2023.
- [13] Y. Lipman, R. T. Q. Chen, H. Ben-Hamu, M. Nickel, and M. Le. Flow matching for generative modeling. In *ICLR*, 2023.
- [14] D. Maraun and M. Widmann. *Statistical Downscaling and Bias Correction for Climate Research*. Cambridge University Press, 2018.
- [15] M. Mardani, N. Brenowitz, Y. Cohen, J. Pathak, C.-Y. Chen, C.-C. Liu, A. Vahdat, K. Kashinath, J. Kautz, and M. Pritchard. Residual corrective diffusion modeling for km-scale atmospheric downscaling. *arXiv preprint arXiv :2309.15214*, 2023.
- [16] M. Mirza and S. Osindero. Conditional generative adversarial nets. *arXiv preprint arXiv :1411.1784*, 2014.
- [17] T. Nguyen, J. Brandstetter, A. Kapoor, J. K. Gupta, and A. Grover. ClimaX : A foundation model for weather and climate. In *ICML*, 2023.

- [18] J. Pearl and D. Mackenzie. *The Book of Why : The New Science of Cause and Effect*. Basic Books, 2018.
- [19] J. Pearl. *Causality : Models, Reasoning, and Inference*. Cambridge University Press, 2nd edition, 2009.
- [20] I. Price et al. GenCast : Diffusion-based ensemble forecasting for medium-range weather. *arXiv preprint*, 2024.
- [21] N. Rampal, P. B. Gibson, S. Hobeichi, J. Sherwood, and S. B. Power. Reliable generative downscaling of climate data with conditional GANs. *Journal of Advances in Modeling Earth Systems*, 2024.
- [22] O. Ronneberger, P. Fischer, and T. Brox. U-Net : Convolutional networks for biomedical image segmentation. In *MICCAI*, 2015.
- [23] T. Vandal, E. Kodra, S. Ganguly, A. Michaelis, R. Nemani, and A. R. Ganguly. DeepSD : Generating high resolution climate change projections through single image super-resolution. In *Proceedings of the 23rd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, 2017.
- [24] X. Zheng, B. Aragam, P. Ravikumar, and E. P. Xing. DAGs with NO TEARS : Continuous optimization for structure learning. In *NeurIPS*, 2018.
- [25] I. Loshchilov and F. Hutter. Decoupled weight decay regularization. In *ICLR*, 2019.
- [26] V. Fortin, M. Abaza, F. Anctil, and R. Turcotte. Why should ensemble spread match the RMSE of the ensemble mean? *Journal of Hydrometeorology*, 15(4) :1708–1713, 2014.
- [27] X. Zhang, L. Alexander, G. C. Hegerl, et al. Indices for monitoring changes in extremes based on daily temperature and precipitation data. *WIREs Climate Change*, 2(6) :851–870, 2011.

- [28] T. Kyono, Y. Zhang, and M. van der Schaar. CASTLE : Regularization via auxiliary causal graph discovery. In *Advances in Neural Information Processing Systems*, 2020.
- [29] G. E. Karniadakis, I. G. Kevrekidis, L. Lu, P. Perdikaris, S. Wang, and L. Yang. Physics-informed machine learning. *Nature Reviews Physics*, 3 :422–440, 2021.
- [30] T. Gneiting, A. E. Raftery, A. H. Westveld, and T. Goldman. Calibrated probabilistic forecasting using ensemble model output statistics and minimum CRPS estimation. *Monthly Weather Review*, 133(5) :1098–1118, 2005.
- [31] World Bank. *Cameroon Country Climate and Development Report (CCDR)*. World Bank Group, 2022.
- [32] OCHA / WFP. *Cameroon Far-North Floods Situation Reports*. ReliefWeb, octobre 2024.
- [33] R. M. Nonki, A. Lenouo, et al. Impact of climate change on hydropower potential of the Lagdo dam, Benue River Basin, Northern Cameroon. *Proceedings of IAHS*, 384 :337–342, 2021.
- [34] C. H. Trisos, I. O. Adelekan, E. Totin, et al. Africa. In *IPCC AR6 Working Group II Report*, Cambridge University Press, 2022.
- [35] K. Bachmann et al. Discovering HPC resources in Africa. In *PEARC’25*, ACM, 2025.
- [36] S. Hobeichi et al. Using machine learning to cut the cost of dynamical downscaling. *Earth’s Future*, 11 :e2022EF003291, 2023.
- [37] A. Doury, S. Somot, et al. Regional climate model emulator based on deep learning : concept and first evaluation. *Climate Dynamics*, 60 :1751–1779, 2023.

- [38] J. González-Abad et al. Multi-variable hard physical constraints for climate model downscaling. In *AAAI Fall Symposium FSS-23*, 2023.
- [39] P. Spirtes, C. Glymour, and R. Scheines. *Causation, Prediction, and Search*. MIT Press, 2nd edition, 2000.
- [40] Y. Lin et al. HG-SCM : Heterogeneous graph structural causal model for node classification. *arXiv preprint*, 2023.
- [41] C. Lu, Y. Zhou, F. Bao, J. Chen, C. Li, and J. Zhu. DPM-Solver++ : Fast solver for guided sampling of diffusion probabilistic models. *arXiv preprint arXiv :2211.01095*, 2022.

DIAGNOSTICS ET MÉTRIQUES COMPLÉMENTAIRES

Diagnostics ciblés (F1@p99, CDD)

Régression F1@p99 (−6,9 %). La skip-connection conditionnelle avec plancher $\alpha_{\text{floor}} = 0,6$ force la voie directe (convolution + upsampling bilinéaire, lissée par construction) à contribuer jusqu’à 40 %, tirant μ_{HR} vers la moyenne LR sur les pixels extrêmes. Révision future : $\alpha_{\text{floor}} \rightarrow 0,4$, hyperparamètres tail-weight modérés. *Biais CDD* (+17,95 j). La perte CRPS/MSE attire vers la médiane conditionnelle (sous-prédiction des *trace events*), et le seuil de 1 mm/j est très sensible à la queue basse. La perte hybride Bernoulli-Gamma [14] est renvoyée aux perspectives.

Sensibilités directes

ORACLE mobilise les entrées avec une amplitude 5 à 36 fois supérieure à la baseline. La hiérarchie est physiquement cohérente : w_{850} (forçage convectif) dominante, puis t_{850} (capacité hygrométrique), u_{850} (advection). Ces variables sont précisément celles identifiées comme dominantes en downscaling de précipitation par la littérature climatologique. C’est un argument indirect de pertinence physique du conditionnement appris, malgré la structure plate de A_{dag} .

TABLEAU XIV – *Sensibilités directes par variable LR (norme moyenne du gradient, unités relatives, top 8 sur 15).*

Variable	ORACLE	Noncausal	Ratio
w_{850}	0,260	0,007	$\times 36$
t_{850}	0,118	0,006	$\times 20$
w_{500}	0,093	0,006	$\times 15$
u_{850}	0,085	0,007	$\times 12$
w_{250}	0,067	0,008	$\times 9$
t_{500}	0,060	0,009	$\times 7$
q_{850}	0,047	0,006	$\times 8$
v_{850}	0,044	0,007	$\times 7$

Métriques climato complémentaires

Diagnostics climato standards : la distribution log-log des intensités confirme que ORACLE reproduit la queue droite tandis que CORRDIFF tronque la distribution à environ 30 mm/j ; le *Fractions Skill Score* indique que ORACLE est *skillful* à l'échelle environ 30 km, contre environ 80 km pour CORRDIFF.

ANALYSES CAUSALES COMPLÉMENTAIRES

Analyse causale étendue

La Fig. 13 cartographie la réponse aux perturbations contrôlées $\Delta q + 20\%$ et $\Delta t + 3\text{ K}$. La comparaison entre le DAG appris A_{dag} et le DAG physique de référence (couplage quasi-géostrophique descendant) donne deux arêtes sur cinq physiquement attendues correctement orientées ($Q_{\text{phys}} = 0,40$).




FIGURE 13 – Cartes des perturbations contrôlées $\Delta q + 20\%$ et $\Delta t + 3\text{ K}$. Signes physiques cohérents avec la relation de Clausius-Clapeyron sur les deux perturbations testées. Les amplitudes, de l'ordre de 10^{-3} en unités relatives, rendent les cartes visuellement peu contrastées : les statistiques quantitatives (moyennes et IC bootstrap) figurent au Tableau X.




FIGURE 14 – *Biais sur l'indice RX1day pour ORACLE. Le déficit, concentré sur le versant occidental des Southern Alps, révèle l'absence d'orographie HR (DEM) en entrée. Le même schéma spatial s'observe sur CORRDIFF, ce qui montre que la cause est l'information manquante, pas la causalisation. La rangée RX1day porte l'essentiel du message; les autres indices sont donnés pour complétude, chaque carte ayant sa propre échelle de couleur.*

Variante à 9 nœuds (récupération structurelle)

La variante à 9 nœuds attribue un nœud à chaque variable atmosphérique : la chaîne sèche quasi-géostrophique (GP850, GP500, GP250, plus les méta-paths GP850→GP500 et GP500→GP250) est complétée par la chaîne humide de Held-Soden (Q850, W500, IVT), puis fermée sur la précipitation de surface SP_HR. Elle est entraînée sous le *même* proto-

cole two-stage que la configuration principale (split temporel 1980–2009 / 2010–2011 / 2012–2013, 215 époques, seed 42).

La matrice A_{dag} apprise (Fig. 15) récupère les **dix** arêtes physiquement attendues avec le signe correct et sans arête parasite ($n_{\text{extra}} = 0$), pour un score de fidélité continu $Q_{\text{phys}} = 0,9997$ (binaire 1,0) et un squelette parfait ($\text{skeleton_F1} = 1,0$); le détail arête par arête figure au Tableau XV. Les magnitudes restent quasi uniformes (environ 0,69) : la structure est *fidèlement orientée* sans être hiérarchisée en amplitude, ce qui reste cohérent avec la limite d'identifiabilité observationnelle d'un SCM.




FIGURE 15 – Matrice d’adjacence causale A_{dag} apprise (variante 9 nœuds, seed 42; ligne = cause, colonne = effet). Les dix arêtes physiquement attendues (encadrées) sont toutes récupérées avec le signe correct, sans arête parasite.

TABLEAU XV – *Arêtes physiquement attendues et poids appris de A_{dag} (variante 9 nœuds, seed 42). Les dix arêtes sont récupérées avec le signe correct.*

Arête (cause → effet)	Signe attendu	Poids appris
GP250 → GP500	+	+0,685
GP500 → GP850	+	+0,688
GP850 → SP_HR	+	+0,686
GP850 → GP500 → GP500	+	+0,690
GP500 → GP250 → GP250	+	+0,694
GP850 → Q850	+	+0,685
GP500 → W500	+	+0,691
Q850 → IVT	+	+0,693
W500 → SP_HR	+	+0,692
IVT → SP_HR	+	+0,692

Cette récupération parfaite de la topologie confirme que la platitude à 6 nœuds n'est pas un plafond de l'architecture, mais le coût d'une agrégation choisie pour la lisibilité ; ce gain de fidélité se paie néanmoins en *skill* de downscaling (Tableau XII), ce qui justifie de conserver la configuration à 6 nœuds comme modèle principal.