

Plan Général Détaillé du Mémoire

21 mai 2026

1 Contexte et positionnement du manuscrit

Le présent plan définit l'orientation générale d'un mémoire consacré au développement de méthodes d'apprentissage automatique pour la désagrégation temporelle et la mise à l'échelle spatiale des données climatiques destinées aux communautés locales.

Le projet porte sur **Oracle**, une architecture causale et générative à deux étages pour le downscaling climatique probabiliste. Les axes structurants du manuscrit sont les suivants :

- produire des champs climatiques haute résolution à partir de prédicteurs basse résolution ;
- améliorer la robustesse hors distribution dans un contexte de changement climatique ;
- limiter les hallucinations statistiques des modèles purement corrélatifs par une structure causale explicite ;
- combiner un prédicteur causal de moyenne haute résolution avec un décodeur de diffusion résiduelle.

2 Plan global proposé du mémoire

Pages préliminaire

- Page de garde
- Dédicace
- Remerciements
- Résumé (français) + mots-clés
- Abstract (anglais) + keywords
- Liste des abréviations/sigles
- Table des matières
- Liste des figures et des tableaux

Corps du mémoire

1. Introduction générale

- Contexte climatique, besoins locaux et limites des résolutions disponibles
- Problématique de généralisation hors distribution

- Questions de recherche
 - Objectifs scientifiques et techniques
 - Hypothèses de travail
 - Méthodologie globale
 - Contributions attendues
 - Organisation du document
- 2. Chapitre 1 – Fondements du downscaling climatique**
- Données climatiques basse et haute résolution
 - Désagrégation temporelle et mise à l'échelle spatiale
 - Modélisation probabiliste des champs climatiques
 - Métriques d'évaluation climatiques et probabilistes
 - Trilemme : stabilité, réalisme des extrêmes, robustesse OOD
 - Synthèse de positionnement pour la suite
- 3. Chapitre 2 – État de l'art du downscaling par apprentissage profond**
- Approches déterministes : régression, U-Net, super-résolution, opérateurs neuronaux de Fourier (FNO/SFNO) et Transformers de vision (SwinIR, PrecipFormer)
 - Modèles génératifs adversariaux et Residual cGAN
 - Modèles à vraisemblance : flots de normalisation et auto-encodeurs variationnels
 - Diffusion et modèles score-based : ResDiff, EDM/EDM2, CorrDiff, diffusion latente, Diffusion Transformers et diffusion spatio-temporelle
 - Flow matching, interpolants stochastiques et échantillonnage accéléré (consistency models)
 - Fonctions de perte avancées : pertes spectrales (FACL), régularisation Wasserstein, pondération des extrêmes
 - Contraintes physiques, explicabilité (XAI), causalité et robustesse hors distribution
 - Évaluation probabiliste et cadres de benchmark standardisés
 - Limites des approches existantes et gap scientifique
- 4. Chapitre 3 – Proposition Oracle : architecture two-stage causale**
- Graphe atmosphérique hétérogène
 - Encodeur intelligible de variables
 - RCN : SCM, GRU et DAGMA
 - Stage 1 : prédiction de la moyenne causale
 - Stage 2 : diffusion résiduelle EDM
 - Dynamique d'entraînement et propriété (O3)
- 5. Chapitre 4 – Matériels, méthodes, expérimentations et discussion**
- Environnement logiciel et matériel (Python, PyTorch, Hydra, AMP, `torch.compile`)
 - Données ACCESS-CM2 historique, prétraitements et séquences temporelles (`seq_len = 16`, `stride = 4`)

- Topologie Oracle : graphe hétérogène, encodeur intelligible, RCN, Stage 1 (**GraphToGridDecoder**), Stage 2 (UNet EDM)
- Optimisation two-stage : AdamW + cosine pour Stage 1, Adam + groupes séparés pour Stage 2, pertes **huber+cosine** et focal
- Diffusion EDM (Karras) : sampler de Heun, sigma calibré
- Protocole d'évaluation : MAE, MSE, corrélation, CRPS, FSS, RAPSD, F1@p95/p99
- Diagnostic causal et vérification de la propriété (O3) (ablation A_{dag} vs **0**)
- Résultats observés, discussion critique et menaces à la validité

6. Conclusion générale et perspectives

- Récapitulatif des contributions
- Réponse à la problématique
- Limites du travail
- Perspectives de recherche et d'application

Fin du document

- Bibliographie
- Annexes (questionnaires, détails techniques, résultats complémentaires)

3 Plan détaillé de l'Introduction générale

Titre recommandé : *Introduction générale.*

Objectif de l'introduction

Poser le problème de recherche : comment produire des simulations climatiques locales haute résolution qui soient à la fois réalistes, probabilistes, physiquement cohérentes et robustes face aux climats futurs hors distribution.

Structure détaillée proposée

I.1 Contexte général

- Importance des données climatiques locales pour l'agriculture, la gestion des risques, les infrastructures et l'adaptation communautaire.
- Limitation pratique des modèles globaux et régionaux : résolution souvent insuffisante pour les décisions locales.
- Rôle du downscaling : transformer des champs atmosphériques grossiers en cartes plus fines et exploitables.

I.2 Motivation

- Les modèles déterministes produisent souvent des champs trop lissés et sous-estiment les extrêmes.

- Les modèles génératifs améliorent le réalisme, mais peuvent rester instables, sous-dispersifs ou non interprétables.
- Le changement climatique rend fragile l’hypothèse de stationnarité : les corrélations du passé ne suffisent plus.

I.3 Problématique

- Les approches profondes apprennent parfois des raccourcis statistiques qui fonctionnent sur les données historiques mais se dégradent en climat futur.
- La diffusion résiduelle stabilise la génération, mais n’impose pas nativement de raisonnement causal ou physique.
- La question centrale est de concevoir une architecture où la causalité n’est pas un simple diagnostic ajouté après coup, mais un chemin de calcul nécessaire à la prédiction.

I.4 Questions de recherche

- Q1 : Les architectures génératives existantes, notamment Residual cGAN et ResDiff, suffisent-elles à garantir une robustesse hors distribution ?
- Q2 : Un modèle causal structurel intégré dans une dynamique récurrente permet-il de mieux guider le downscaling climatique ?
- Q3 : Une architecture two-stage, combinant moyenne causale et diffusion résiduelle, permet-elle de préserver les extrêmes et la calibration probabiliste ?

I.5 Objectifs

- **Objectif général** : concevoir et évaluer une architecture d’apprentissage profond causale et générative pour le downscaling climatique local.
- **Objectifs spécifiques** :
 1. analyser les limites des approches déterministes, adversariales et diffusives ;
 2. formaliser le problème de downscaling probabiliste sous contrainte causale ;
 3. proposer une architecture Oracle à deux étages ;
 4. évaluer la qualité spatiale, probabiliste et extrême des sorties produites.

I.6 Hypothèses de travail

- H1 : un modèle qui apprend des relations causales invariantes généralise mieux qu’un modèle purement corrélatif en contexte OOD.
- H2 : la séparation moyenne causale / résidu stochastique stabilise l’apprentissage et améliore la représentation des extrêmes.
- H3 : la propriété d’indispensabilité causale architecturale (O3) limite le risque de graphe causal simplement décoratif.

I.7 Méthodologie générale

- Revue critique des méthodes de downscaling par apprentissage profond.
- Formalisation du problème comme estimation d’une distribution conditionnelle haute résolution.
- Conception d’un graphe atmosphérique hétérogène, d’un RCN et d’un décodeur de diffusion résiduelle.
- Évaluation sur données ERA5 avec métriques d’erreur, de calibration et d’événements extrêmes.

I.8 Contributions attendues

- Une architecture causale two-stage pour le downscaling climatique probabiliste.
- Un RCN associant SCM, GRU et contrainte d’acyclicité DAGMA.
- Une interface causale entre le prédicteur de moyenne et le décodeur de diffusion résiduelle.
- Un protocole expérimental centré sur la calibration, les extrêmes et les ablations causales.

I.9 Organisation du manuscrit

- Résumer en un paragraphe la fonction de chaque chapitre.
- Assurer une transition naturelle vers le chapitre 1.

Livrables attendus pour l’introduction

- Une formulation claire du problème de downscaling OOD.
- Trois questions de recherche directement reliées à l’architecture proposée.
- Une liste courte de contributions scientifiques et techniques.
- Un plan du manuscrit qui relie les fondements, l’état de l’art, Oracle et l’évaluation.

4 Plan détaillé du Chapitre 1

Titre recommandé : *Fondements du downscaling climatique et concepts cibles.*

Objectif du chapitre

Installer les bases climatiques, statistiques et méthodologiques nécessaires à la compréhension du downscaling probabiliste et du besoin de causalité dans les modèles profonds.

Structure détaillée proposée

1.1 Introduction du chapitre

- Situer le chapitre comme socle conceptuel du mémoire.
- Annoncer les notions : données climatiques, résolution, downscaling, incertitude et OOD.
- Préciser que la revue des architectures avancées est traitée au chapitre 2.

1.2 Données climatiques et niveaux de résolution

- Présenter les modèles globaux, les modèles régionaux, les réanalyses et les observations.
- Expliquer la différence entre basse résolution et haute résolution spatiale.
- Introduire les champs atmosphériques utiles : vent, humidité, température, pression, précipitations.
- Montrer l'intérêt d'une représentation 3D de l'atmosphère par niveaux de pression.

1.3 Désagrégation temporelle et mise à l'échelle spatiale

- Définir la désagrégation temporelle et la mise à l'échelle spatiale.
- Distinguer downscaling statistique, dynamique et hybride.
- Expliquer le passage typique d'une grille basse résolution à une carte locale haute résolution.
- Préciser le cas d'étude : entrées LR, cible HR et séquences temporelles.

1.4 Downscaling probabiliste

- Formaliser l'objectif : estimer $p(x_{\text{HR}} \mid y_{\text{LR}}, s_{\text{HR}}, \mathcal{G})$.
- Expliquer pourquoi une seule prédiction moyenne est insuffisante pour les précipitations et les extrêmes.
- Introduire les notions de résidu, incertitude, ensemble et calibration probabiliste.

1.5 Changement climatique et robustesse hors distribution

- Définir la notion de distribution d'entraînement et de décalage hors distribution.
- Expliquer la fragilité des corrélations apprises à partir du passé.
- Motiver la recherche de mécanismes invariants, liés à la physique et à la causalité.

1.6 Métriques d'évaluation

- Métriques ponctuelles : MAE, MSE, corrélation spatiale.
- Métriques probabilistes : CRPS, spread-skill, calibration.
- Métriques spatiales et spectrales : FSS, RAPSD.
- Métriques d'extrêmes : seuils p95/p99, précision, rappel, F1-score.

1.7 Le trilemme du downscaling profond

- Stabilité d'entraînement : éviter les échecs numériques et les comportements adversariaux instables.
- Réalisme : reproduire les structures fines, la variance et les événements extrêmes.
- Robustesse OOD : rester fiable lorsque les conditions climatiques futures diffèrent de l'historique.

1.8 Synthèse et transition

- Résumer les concepts nécessaires à la lecture de l'état de l'art.
- Montrer que le problème exige plus qu'une simple super-résolution d'image.
- Introduire les familles de modèles profonds discutées au chapitre 2.

Livrables attendus pour un Chapitre 1 solide

- Un schéma basse résolution vers haute résolution.
- Un glossaire des variables climatiques et des métriques.
- Un encadré sur le problème OOD en climat.
- Une synthèse du trilemme stabilité–réalisme–robustesse.

Orientation rédactionnelle

Le chapitre 1 doit rester **pédagogique et sélectif** : il ne couvre pas toute la climatologie, mais fournit les bases nécessaires à la compréhension du problème et des choix méthodologiques.

5 Plan détaillé du Chapitre 2

Titre recommandé : *État de l'art : approches déterministes, génératives et causales pour le downscaling.*

Objectif du chapitre

Réaliser une revue critique des approches de downscaling par apprentissage profond afin de faire apparaître le besoin d'une architecture causale, probabiliste et robuste hors distribution.

Structure détaillée proposée

2.1 Introduction du chapitre

- Rappeler le trilemme identifié au chapitre 1.
- Présenter les axes de comparaison : stabilité, extrêmes, incertitude, physique, explicabilité et OOD.

2.2 Approches déterministes de downscaling

- Régressions statistiques classiques (BCSD, BCCA, analogues) et limites de la stationnarité.
- Réseaux convolutifs et super-résolution : SRCNN, EDSR, ESRCGAN adaptés aux champs climatiques.
- Architectures U-Net et encodeur-décodeur à sauts de connexion.

- Opérateurs neuronaux de Fourier (FNO) : downscaling à résolution arbitraire et adaptation *zero-shot* à des facteurs de montée en résolution non vus (Yang et al., 2024, JMLR).
- Opérateurs de Fourier sphériques (SFNO) pour émulateurs climatiques globaux (légers, type LUCIE).
- Variantes contraintes par la physique : perte de Clausius–Clapeyron pour les variables thermiques (Jiang et al., 2023, JAMES).
- Transformers de vision pour la super-résolution : SwinIR, Swin v2, PrecipFormer ; comparaison *full-domain* vs approches par tuiles (*tiling*).
- Limite transverse : lissage spatial, perte des hautes fréquences (RAPSD dégradée) et sous-estimation systématique des extrêmes.

2.3 Modèles génératifs adversariaux

- Introduire le cGAN et le Residual cGAN appliqués au downscaling.
- GAN fiables et extrapolation climatique : architectures CNN déterministe + GAN sur le résidu pour mieux extrapoler vers des climats plus chauds (Rampal et al., 2025, JAMES).
- Discuter les forces : textures plus fines, restitution des hautes fréquences, meilleure reproduction visuelle.
- Discuter les limites : sensibilité à λ_{adv} , sous-dispersion, *mode collapse*, instabilité d’entraînement et hallucinations.

2.4 Modèles à vraisemblance : flots de normalisation et VAE

- Flots de normalisation pour le downscaling : ClimAlign (downscaling statistique non supervisé) et flots de normalisation conditionnels (Groenke et al., 2020 ; Winkler et al., 2024).
- Intérêt : vraisemblance exacte, échantillonnage probabiliste et lien avec le transport optimal.
- Auto-encodeurs variationnels (VAE) et régularisation de l’espace latent (divergence de Kullback–Leibler).
- Limites : qualité d’échantillon souvent inférieure à la diffusion, contraintes architecturales d’inversibilité des flots.

2.5 Diffusion et modèles score-based

- Cadres fondateurs : DDPM, modèles score-based / SDE et échantillonnage Predictor–Corrector.
- ResDiff : moyenne déterministe puis diffusion sur le résidu de plus faible variance.
- EDM (Karras et al., 2022) : préconditionnement, échantillonnage de Heun, calibration de σ_{data} ; EDM2 (Karras et al., 2024) pour la dynamique d’entraînement et l’EMA.
- CorrDiff (Mardani et al., 2024) : downscaling km-échelle régression + correcteur diffusif, référence NVIDIA.

- Diffusion latente : mimer des simulations km-échelle (COSMO5.0_CLM9) à coût réduit (Tomasi et al., 2025, GMD).
- Diffusion Transformers (DiT) et génération d'ensembles probabilistes (GenCast, DeepMind, 2024).
- Diffusion spatio-temporelle et vidéo : guidage par flot optique (OF-Diff), émulation 3D température/précipitations (DiffESM).
- Correction de biais et downscaling conjoints par espace d'embedding partagé (Aich et al., 2025).
- Limites : coût d'échantillonnage élevé, absence native de contrainte causale et risque de raccourcis statistiques.

2.6 Flow matching, interpolants stochastiques et échantillonnage accéléré

- Flow matching et *rectified flow* : Physics-Constrained Adaptive Flow Matching (PC-AFM) avec contraintes de conservation douces.
- Interpolants stochastiques (CDSI) : trajectoires évoluant directement de la basse résolution vers la cible, sans partir d'un bruit pur.
- Accélération de l'échantillonnage : *consistency models*, flow map matching, distillation de score, Restart sampling (Xu et al., 2023).
- Intérêt : réduction drastique du nombre d'étapes d'inférence tout en conservant le réalisme.

2.7 Fonctions de perte avancées et transport optimal

- Pertes spectrales et de Fourier : FACL (amplitude + corrélation) pour restaurer les hautes fréquences (Yang et al., 2024).
- Régularisation par distance de Wasserstein : WassDiff pour la fidélité des extrêmes de précipitations (Liu et al., 2024).
- Pertes pondérées sur les extrêmes (*tail-weighted* / *intensity-weighted*, Ravuri et al., 2021).
- Lien avec le transport optimal et la calibration distributionnelle.

2.8 Contraintes physiques et cohérence inter-variables

- Exemples de violations : $T_{\min} > T_{\max}$, incohérences entre humidité, pression et précipitations.
- Approches par pénalités physiques, conservation de masse/énergie et paramétrisation contrainte.
- Réseaux informés par la physique (PINN) et relations thermodynamiques (Clausius-Clapeyron).
- Limites des contraintes ajoutées sans structure causale interne.

2.9 Explicabilité, causalité et robustesse OOD

- Cartes de saillance et diagnostics post-hoc (XAI).
- Causalité structurelle : SCM, DAG, DAGMA, invariance causale.

- Rôle de la variabilité interne dans les projections fines des extrêmes (Hess et al., 2025).
- Limite du graphe décoratif : un graphe peut exister sans devenir nécessaire à la prédiction.

2.10 Évaluation probabiliste et cadres de benchmark

- Métriques déterministes et de structure : MAE, RMSE, corrélation de Pearson, RAPSD.
- Métriques probabilistes : CRPS (par pixel et *max-pooled*), diagramme *spread-skill*, FSS.
- Métriques d'extrêmes : F1@p95/p99, indices de précipitations intenses.
- Cadres de benchmark standardisés émergents pour comparer équitablement les méthodes.

2.11 Synthèse des limites P1–P5

- P1 : instabilité ou sensibilité d'entraînement.
- P2 : mauvaise quantification de l'incertitude et sous-dispersion.
- P3 : incohérences physiques ou inter-variables.
- P4 : hypothèse de stationnarité fragile.
- P5 : causalité non indispensable, ou graphe décoratif.

2.12 Gap de recherche et transition

- Formuler le besoin : une architecture où le chemin causal gouverne la moyenne haute résolution.
- Justifier la combinaison d'un RCN causal et d'une diffusion résiduelle.
- Introduire Oracle comme réponse architecturale au gap.

Livrables attendus pour le chapitre 2

- Un tableau comparatif étendu des familles de modèles : régression/U-Net, FNO/SFNO, Transformers, cGAN, flots de normalisation/VAE, ResDiff, EDM/EDM2, CorrDiff, diffusion latente, DiT, flow matching/interpolants stochastiques, modèles causaux.
- Une grille d'analyse selon les axes : stabilité, extrêmes, incertitude, physique, explicabilité, OOD et coût d'inférence.
- Une synthèse P1–P5 des limites de la littérature.
- Une justification claire de l'architecture Oracle.

6 Plan détaillé du Chapitre 3

Titre recommandé : *Proposition Oracle : architecture two-stage causale pour le downscaling.*

Objectif du chapitre

Présenter la contribution centrale du mémoire : une architecture où un chemin causal construit une moyenne haute résolution indispensable, puis une diffusion EDM modélise uniquement le résidu stochastique.

Structure détaillée proposée

3.1 Introduction du chapitre

- Rappeler les limites identifiées dans l'état de l'art.
- Introduire le principe two-stage : moyenne causale puis résidu diffusif.
- Présenter la propriété (O3) d'indispensabilité causale architecturale.

3.2 Vue d'ensemble de l'architecture

- Pipeline global : graphe hétérogène, encodeur intelligible, RCN, prédicteur de moyenne, décodeur EDM.
- Entrées basse résolution, variables statiques haute résolution et cible précipitation.
- Sortie finale : $x_{\text{HR}} = \mu_{\text{HR}} + \delta$.

3.3 Graphe atmosphérique hétérogène

- Nœuds associés aux niveaux de pression 850, 500 et 250 hPa.
- Nœuds de surface et variables statiques haute résolution.
- Arêtes spatiales, verticales, temporelles et statiques.
- Utilisation d'une structure compatible avec des données climatiques multi-échelles.

3.4 Encodeur intelligible de variables

- Objectif : produire des représentations sémantiques lisibles par type de variable.
- Méta-chemins et agrégation de type SAGEConv.
- Réduction vers un ensemble restreint de variables causales interprétables.

3.5 Recurrent Causal Network

- SCM : transition causale guidée par une matrice d'adjacence acyclique.
- GRU : fusion entre plan causal et observation à l'instant courant.
- Perte de reconstruction et stabilisation temporelle de l'état caché.
- Rôle du RCN : devenir le moteur logique de la simulation, et non un module d'explication externe.

3.6 DAGMA et projection spectrale

- Contrainte d'acyclicité pour apprendre un DAG valide.
- Pénalité douce pendant l'entraînement.
- Projection dure pour rendre la structure causale certifiable.

3.7 Stage 1 : prédiction de la moyenne causale

- Construction de μ_{HR} à partir des états causaux.
- Cross-attention vers une grille haute résolution apprise.
- Décodeur CNN Graph-to-Grid.
- Fonction de perte du stage 1 : erreur de moyenne, éventuelles contraintes physiques, régularisation causale.

3.8 Interface inter-étages

- Calcul du résidu initial $\delta_0 = x_{\text{HR}} - \mu_{\text{HR}}$.
- Recalibration de σ_{data} par estimation de type Welford.
- Gel du stage 1 pour empêcher la diffusion de court-circuiter le chemin causal.
- Gate d'ablation (O3) pour tester l'indispensabilité de la causalité.

3.9 Stage 2 : diffusion résiduelle EDM

- Apprentissage du résidu plutôt que du champ complet.
- Conditionnement par concaténation de canaux : résidu bruité, moyenne causale et baseline transformée.
- Absence d'accès direct à l'état caché causal dans le décodeur diffusif.
- Sampling EDM avec solveur de type Heun.

3.10 Pertes composites et dynamique d'entraînement

- Pertes causales, récurrentes, déterministes, diffusives, physiques et de parcimonie.
- Entraînement séquentiel du stage 1 puis du stage 2.
- Gestion des gradients, clipping, précision mixte et stabilité numérique.

3.11 Synthèse et transition

- Récapituler l'architecture Oracle.
- Relier chaque composant à une limite de la littérature.
- Introduire le protocole expérimental du chapitre 4.

Livrables attendus pour le chapitre 3

- Un schéma global de l'architecture Oracle.
- Un algorithme d'entraînement en deux étages.
- Une description mathématique de μ_{HR} , δ_0 et du conditionnement EDM.
- Une explication claire de la propriété (O3).

7 Plan détaillé du Chapitre 4

Titre recommandé : *Matériels, méthodes, expérimentations et discussion.*

Objectif du chapitre

Documenter les données, l’environnement expérimental, les hyperparamètres et les résultats utilisés pour évaluer Oracle.

Structure détaillée proposée

4.1 Introduction du chapitre

- Rappeler les hypothèses testées (downscaling probabiliste, robustesse OOD, indispensabilité causale (O3)).
- Annoncer les dimensions d’évaluation : erreur ponctuelle, calibration probabiliste, structure spectrale, extrêmes (p95/p99) et ablations causales.
- Préciser que les choix expérimentaux reflètent la configuration réelle du dépôt, pilotée par Hydra (`config/training_config.yaml`) et le point d’entrée `ops/train_st_cdgm.py`.

4.2 Environnement logiciel et matériel

- Plateforme cible de référence : Colab Pro avec GPU T4 (16 Go VRAM, 4–8 vCPU, 15–50 Go RAM) ; profil A100 80 Go supporté via surcharge Hydra.
- Repli CPU : option dédiée (`training.device=cpu`, `training.use_amp=false`, `training.compile.enabled=false`).
- Précision : entraînement en *fp16* via AMP (`autocast` + `GradScaler`) sur GPU.
- Optimisation runtime : `torch.compile` activé en mode *default* pour encodeur, RCN et UNet ; `cudnn.benchmark=True` ; TF32 lorsque supporté.
- Pile logicielle : Python 3.10, PyTorch ≥ 2.0 , PyTorch Geometric ≥ 2.3 , `diffusers` ≥ 0.21 , `accelerate`, `transformers`.
- Données et calcul : NetCDF (`xarray`, `netCDF4`, `h5netcdf`), `dask` pour le chargement paresseux et `xbatcher` pour les batches spatiaux ; orchestration via `hydra-core` et `omegaconf`.
- Reproductibilité : configuration sérialisée par Hydra et persistance des checkpoints (`epoch_last.pth`, `epoch_best.pth`) avec `persist_every=1`.

4.3 Jeux de données et préparation

- Source : champs climatiques au format NetCDF, partition train avec `predictor_ACCESS-CM2_hist.nc` (LR) et `pr_ACCESS-CM2_hist.nc` (HR), prédicteurs statiques ERA5 `ERA5_eval_ccam_12km`.
- Entrées LR : 15 champs dynamiques sur grille 23×26 : composantes u , v , w du vent, humidité spécifique q et température t aux niveaux pression 850, 500 et 250 hPa.
- Champs statiques : orographie (`orog`), élévation effective (`he`) et indice de végétation (`vegt`), injectés dans le nœud SP_HR du graphe hétérogène.
- Cible HR : précipitations `pr` sur grille 172×179 .
- Prétraitements : standardisation moyenne/écart-type des prédicteurs, transformation $\log(1 + p)$ des précipitations (avec $\delta = 0,01$ mm), stratégie de remplissage des NaN `mean`.

- Baseline intermédiaire : stratégie `hr_smoothing` avec facteur 4, fournissant un champ de référence dont le résidu HR est ensuite modélisé.
- Séquences temporelles : `seq_len=16` et `stride=4`, chargées *lazy* (`eager_load_datasets=false`) pour limiter la pression mémoire NetCDF.
- Pipeline orienté graphe : conversion grille LR vers nœuds via `HeteroGraphBuilder` avec couches GP850/GP500/GP250 (`include_mid_layer=true`).

4.4 Topologie du modèle

- Méta-chemins de l’encodeur intelligible : 5 chemins dynamiques (`GP850_spat_adj`, `GP850_to_GP500`, `GP500_spat_adj`, `GP500_to_GP250`, `GP250_spat_adj`) plus, lorsque les statiques sont disponibles, le chemin causal `SP_HR → GP850` (forçage orographique).
- Encodeur : `hidden_dim=128`, `conditioning_dim=128`, mécanisme `causal_conditioning` actif avec `num_dag_tokens=2` injectés dans la cross-attention.
- RCN : `hidden_dim=128`, `driver_dim=15` (aligné sur les variables LR), `dropout=0,1`, BPTT avec `detach_interval=8`.
- Initialisation de A_{dag} : amorçage depuis le prior physique 6×6 (couplage tridiagonal vertical + forçage orographique), avec un bruit gaussien $\sigma = 0,02$.
- Stage 1 (`GraphToGridDecoder`) : architecture `graph_to_grid_xattn` avec $d_{\text{model}} = 128$, 4 têtes d’attention, grille intermédiaire 43×45 et raffinement CNN $128 \rightarrow 64 \rightarrow 32 \rightarrow 1$.
- Stage 2 (décodeur de diffusion, configuration V4 *CorrDiff Large*) : UNet `diffusers UNet2DConditionModel` à 5 niveaux $172 \times 179 \rightarrow 86 \times 90 \rightarrow 43 \times 45 \rightarrow 21 \times 22 \rightarrow 10 \times 11$, `block_out_channels=[128, 256, 256, 256, 256]` (~ 53 millions de paramètres), `layers_per_block=2`, blocs `DownBlock2D` aux 4 premiers niveaux puis `CrossAttnDownBlock2D` au niveau le plus petit (symétrie miroir en remontée), `attention_head_dim=8`, `norm_num_groups=32`, `use_gradient_checkpointing=true` pour rester sous 80 Go VRAM A100.
- Conditionnement : `causal_concat_mode=true` ; l’entrée UNet est la concaténation par canal ($\delta_\sigma, \mu_{\text{HR}}, \log(1+b)$), garantissant que le seul chemin par lequel A_{dag} atteint le décodeur est le canal μ_{HR} (propriété (O3) architecturale).
- Trajectoire architecturale V1 $\rightarrow$ V4 : V1 *CorrDiff Mini* ($[64, 128, 128]$, ~ 12 M params, Heun, `stride=2`), V2 *CorrDiff Normal* 4 niveaux ($[128, 256, 256, 256]$, ~ 50 M params, `tail-loss` $w_{p95}, w_{p99} = 8, 25$), V3 ajout EMA + `stride=1` + horizon 100 époques, V4 montée à 5 niveaux et `tail-loss` bumpée $w_{p95}, w_{p99} = 12, 40$ (cf. section 4.8).

4.5 Protocole d’optimisation et hyperparamètres

- Architecture two-stage activée (`two_stage.enabled=true`).
- **Stage 1 – prédicteur causal de moyenne :**
 - Optimiseur AdamW, `weight_decay=10-4`, planificateur cosine avec 1 époque de warmup.
 - Taux d’apprentissage initial : 3×10^{-4} .
 - Pertes pondérées : $\lambda_{\text{reg}} = 1,0$ (MSE sur μ_{HR}), $\beta_{\text{rec}} = 0,05$ (reconstruction RCN), $\gamma_{\text{dag}}^{\text{max}} = 0,10$ avec rampe sur 2 époques (DAGMA), $\lambda_{\text{L1}} = 10^{-3}$, $\lambda_{\text{prior}} = 0,05$ (ancrage sur le prior physique en `sum`).

- Plafond `epochs_max=7`, early stopping plateau MSE (`patience=3`).
- Garde-fous anti-collapse : grad-gate $A_{\text{dag}} = 1,0$, projection plancher $\|A\|_F \geq 0,10$, abort si $\|A\|_F < 0,05$.
- Diagnostic RAPSD logé à chaque époque pour détecter le sur-lissage.
- **Stage 2 – décodeur de diffusion résiduelle (configuration V4) :**
 - Optimiseur AdamW, taux d'apprentissage 2×10^{-4} , gradient clipping à 1,0, AMP *bf16* (CUDA).
 - Stage 1 gelé (`freeze_stage1=true`) : encodeur, RCN, DAGMA et Graph-ToGridDecoder sans gradient.
 - Plafond `epochs_max=100` (V3/V4) sur `stride=1` ($\sim 1,4 \times 10^4$ échantillons par époque), soit 110 époques au total avec Stage 1 (10 + 100).
 - Mode `causal_concat_mode=true` : entrée UNet = concaténation $(\delta_\sigma, \mu_{\text{HR}}, \log(1+b))$.
 - Recalibration de σ_{data} post-Stage 1 (`sigma_data_recalibrate=true`, `sigma_min_scale_factor=0,02`), suivie d'une recalibration *post-Stage 2* (`sigma_data_recalibrate_post=true`) qui sert de filet de sécurité : si une dérive supérieure à 10 % est détectée, le sampler d'inférence est réaligné.
 - **Exponential Moving Average (BS37)** : moyenne exponentielle des poids du décodeur diffusif avec décalage $\beta_{\text{EMA}} = 0,9999$, persistée dans chaque checkpoint (clé `diffusion_ema_state_dict`). Le phénomène de moyenne EMA, proposé par ? et reformulé par ?, est l'unique changement le plus impactant entre V2 et V3 : l'inférence finale utilise les poids EMA, pas les poids *live*.
 - **Perte contrastive DAG (BS35)** : à chaque $N_c = 4$ batchs, la perte EDM est évaluée deux fois, sur $\mu_{\text{HR}}(A_{\text{dag}})$ et sur $\mu_{\text{HR}}(\mathbf{0})$, et un terme de marge $\lambda_c \max(0, m_c - (\mathcal{L}_{\text{stage2}}^{(0)} - \mathcal{L}_{\text{stage2}}))$ avec $\lambda_c = 0,5$ et $m_c = 0,02$ force le décodeur à effectivement exploiter le chemin causal. Un garde-fou dynamique décroît λ_c si la sensibilité DAG reste négative deux époques consécutives, et un mécanisme *auto-tune* substitue l'ablation `zero` par `permute` puis `random` si le signal contrastif s'évanouit après 15 époques.
- **Paramètres de la diffusion EDM (Karras 2022)** : formulation EDM, σ_{data} recalibré dynamiquement, $\sigma_{\text{min}} = 0,002$, $\sigma_{\text{max}} = 80$, $\rho = 7$, $P_{\text{mean}} = -1,2$, $P_{\text{std}} = 1,2$. Sampler d'inférence : DPM-Solver++ multi-step (?) avec churn stochastique $S_{\text{churn}} = 40$, 32 pas de débruitage, classifier-free guidance `cfg_scale=1,5` (avec `conditioning_dropout_prob=0,1` à l'entraînement). La combinaison *DPM-Solver++ + $S_{\text{churn}}=40 + \text{CFG}=1,5$* constitue le *Tier 0* V2-eval+ et apporte un gain net en RAPSD et Spread/RMSE sans aucun re-entraînement.
- **Pertes communes** : reconstruction EDM L2 à perte pondérée tail-weighted (multipliateurs $w_{p95} = 12$, $w_{p99} = 40$ aux seuils $\tau_{95} = 15$ et $\tau_{99} = 30$ mm/jour) pour forcer l'apprentissage des extrêmes ; le terme contrastif DAG ci-dessus est ajouté pour les batchs qualifiés.
- **Réglages d'entraînement** : `batch_size=64` effectif, `num_workers=8`, `pin_memory=true`, `prefetch_factor=2`, planificateur cosinus, persistance du checkpoint (`epoch_last.pth`, `epoch_best.pth`, plus `diffusion_ema_state_dict`) à chaque époque pour sécuriser une éventuelle déconnexion Colab.

4.6 Protocole d'évaluation

- Erreurs ponctuelles : MAE, MSE, corrélation spatiale.
- Calibration probabiliste : CRPS estimé par échantillonnage Monte-Carlo (`num_samples=8` par défaut, jusqu'à 32 membres pour CRPS exact) et diagnostic *spread-skill*.
- Structure spatiale et spectrale : FSS multi-seuils, RAPSD logé à chaque époque.
- Événements extrêmes : F1-score aux percentiles p_{95} et p_{99} (`compute_f1_extremes=true`).
- Sampler d'évaluation : `dpm_solver++` avec `eval_num_steps=32` et $S_{\text{churn}} = 40$; les poids du décodeur utilisés à l'inférence sont la copie EMA ($\beta = 0,9999$), pas les poids *live*.
- Seuils opérationnels déclarés dans la configuration : `MSE_MAX=0,15`, `MAE_MAX=0,20`, `CORR_MIN=0,91`.
- Sorties : visualisations sauvegardées (`save_visualizations=true`) dans `results/`.

4.7 Diagnostic causal et vérification de la propriété (O3)

- **Diagnostic amont post-Stage 1.** Ablation causale automatisée (`causal_ablation.enabled=true`, `n_samples=100`) sur le *champ moyen* produit par Stage 1, avec calcul de la sensibilité relative $\delta\mu = \|\mu_{\text{HR}}(A_{\text{dag}}) - \mu_{\text{HR}}(\mathbf{0})\|_2 / \|\mu_{\text{HR}}(A_{\text{dag}})\|_2$.
- Trois régimes reportés par le diagnostic : $\delta\mu < 0,01$ (DAG DÉCORATIF – abort de la *run*), $0,01 \leq \delta\mu < 0,10$ (SIGNAL CAUSAL MODESTE), $\delta\mu \geq 0,10$ (SIGNAL CAUSAL FORT). Le modèle V2 mesure $\delta\mu \approx 0,18$, placé fermement dans le régime FORT.
- **Signal contrastif pendant l'entraînement (BS35-CONTRASTIVE).** Sensibilité DAG $\Delta\mathcal{L}_{\text{stage2}} = \mathcal{L}_{\text{stage2}}^{(0)} - \mathcal{L}_{\text{stage2}}$ logée à chaque pas du Stage 2. Une valeur positive certifie que le décodeur diffusif exploite activement μ_{HR} ; le garde-fou progressif décrit en 4.5 atténue la perte contrastive si $\Delta\mathcal{L} < 0$ pour prévenir la déstabilisation.
- **Suite d'interventions à l'inférence (BS35).** Quatre modes évalués sur le *même* fold de validation, $K = 16$ membres d'ensemble par échantillon :
 - CAUSAL : pipeline standard (DAG appris).
 - ZERO-DAG : substitution $A_{\text{dag}} \leftarrow \mathbf{0}$ à l'inférence uniquement.
 - RANDOM-DAG : substitution par une matrice triangulaire supérieure aléatoire à sparsité identique.
 - PERMUTE-DAG : permutation aléatoire des lignes de A_{dag} .
- **Contrefactuel architectural (REG. BASELINE).** Substitution de tout le pipeline causal (encodeur + RCN + DAGMA + `GraphToGridDecoder`) par un prédicteur de moyenne iso-capacité `RegressionMeanPredictor` (UNet *CorrDiff-style* à budget paramétrique apparié), entraîné pour le même nombre d'époques. Si REG. BASELINE sous-performe CAUSAL à budget identique, l'architecture causale est empiriquement nécessaire ; sinon le DAG est réduit au statut d'auxiliaire interprétatif.

- Critère de la propriété (O3) : $r_{O3} = F1@p99^{(CAUSAL)} - F1@p99^{(ZERO-DAG)} \geq 0,05$;
abort de la *run* si l'épreuve amont échoue (`abort_if_fail=true`). La V2 mesure $r_{O3} \approx 0,13$.
- Suivi continu de $\|A_{dag}\|_F$ et de la sparsité induite par DAGMA + L1 + projection spectrale.

4.8 Résultats expérimentaux : trajectoire V1→V4

- **Cibles Oracle (???)** : Pearson 0,896, F1@p95 0,837, F1@p99 0,754. Ces valeurs sont *l'objectif dépasser*, pas un résultat de la présente étude ; elles sont dérivées de la littérature existante (cGAN résiduel et ResDiff) et fixent la barre que la trajectoire V1→V4 cherche à franchir.
- **Stratégie de *full retrain isolé*** : chaque variante V1, V2, V3, V4 dispose de son propre répertoire de `checkpoint` (`ckpt/`, `ckpt_v2_corrdiff_normal/`, `ckpt_v3_ema_long/`, `ckpt_v4_corrdiff_large/`) afin d'éviter tout *state_dict mismatch* entre architectures et de préserver chaque baseline pour la comparaison mémoire.
- Tableau de synthèse (valeurs en *(en cours)* à renseigner depuis les fichiers `v2_eval_plus_metrics.json`, `v3_metrics.json` et `v4_metrics.json` produits par la cellule `FINAL_VALIDATION` du notebook) :

Variante	Pearson ↑	F1@p95 ↑	F1@p99 ↑	RAPSD d
V1 (CorrDiff Mini)	0,36	0,42	0,0037	812
V2 (CorrDiff Normal, 50 ep)	0,71	0,42	0,29	364
V2 étendu (200 ep, stride=2)	0,82	0,65	0,53	258
V2-eval+ (Tier 0, inf.)	(post-run)	(post-run)	(post-run)	(post-run)
V3 (Tier 0+1, EMA + 100 ep)	(post-run Colab)	(post-run Colab)	(post-run Colab)	(post-run C)
V4 (Tier 0+1+2, CorrDiff L)	(post-run Colab)	(post-run Colab)	(post-run Colab)	(post-run C)
Cible Oracle	0,896	0,837	0,754	→ 0

- **Lecture de la trajectoire V1→V2 (mesurée)**. Le passage de *CorrDiff Mini* à *CorrDiff Normal* avec ajout de la *tail-loss* pondérée multiplie la corrélation par ~ 2 et le F1@p99 par ~ 78 , ce qui confirme que la sous-performance de V1 était dictée par la *capacité* de Stage 2 et non par le prédicteur causal Stage 1.
- **Apport attendu de chaque tiers (V2→V4)**. Tier 0 (V2-eval+, gain *gratuit* : DPM-Solver++ + S_{churn} + CFG + EMA à l'inférence) : +0,07 à +0,11 Pearson, +0,10 à +0,20 F1@p99. Tier 1 (V3, EMA pendant l'entraînement + stride=1 + horizon 100 époques + recalibration post-S2) : +0,06 à +0,08 Pearson, +0,15 à +0,25 F1@p99. Tier 2 (V4, montée à 5 niveaux + *tail-loss* bumpée) : +0,04 à +0,06 Pearson, +0,10 à +0,15 F1@p99, gain principal sur RAPSD via la profondeur du *champ réceptif*.
- Les valeurs ci-dessus sont issues du notebook `st_cdgm_training_evaluation.ipynb` et persistées à chaque époque ; les exécutions futures seront réestimées avec intervalles de confiance et répétitions `seed` multiples.

4.8b Validation causale (apport mesurable du DAG)

- **Apport scientifique central** : l'objectif n'est pas seulement de dépasser les métriques Oracle, mais de *quantifier l'apport du DAG* dans cette dépassement. L'argument repose sur quatre indicateurs cumulatifs :

1. Diagnostic amont $\delta\mu$ (cf. 4.7) – mesure *intrinsèque* à Stage 1.
 2. Sensibilité contrastive $\Delta\mathcal{L}_{\text{stage2}}$ (cf. 4.5/4.7) – mesure *dynamique* à l’entraînement de Stage 2.
 3. Suite BS35 d’interventions à l’inférence (cf. 4.7) – mesure *descendante* sur la qualité finale.
 4. Contrefactuel architectural REG. BASELINE – mesure *contrefactuelle* à iso-capacité.
- Tableau BS35 attendu (à renseigner depuis `v4_bs35_ablation.json`) :

Mode	Pearson $\uparrow$	F1@p99 $\uparrow$	r_{O3}
CAUSAL (V4)	(en cours)	(en cours)	—
ZERO-DAG (V4)	(en cours)	(en cours)	(en cours)
RANDOM-DAG (V4)	(en cours)	(en cours)	(en cours)
PERMUTE-DAG (V4)	(en cours)	(en cours)	(en cours)
REG. BASELINE	(en cours)	(en cours)	—

- Une défaillance de REG. BASELINE à égaler CAUSAL à budget apparié constituerait la *plus forte* preuve empirique disponible que la causalité est *nécessaire*, par opposition à un graphe décoratif. Cette ligne joue un rôle analogue au bras de contrôle d’une expérience randomisée.

4.9 Analyse des résultats

- Lire la corrélation spatiale comme un indicateur de localisation des structures pluvieuses produites.
- Discuter le CRPS comme mesure conjointe de calibration et de finesse de l’ensemble (avec écart *spread-skill*).
- Justifier l’apport du focal loss et de la pondération des extrêmes pour les scores $F1@p95$ et $F1@p99$.
- Relier les résultats au rôle du RCN (mémoire causale), du Stage 1 (champ moyen explicite) et du décodeur EDM (variabilité fine).
- Discuter le compromis temps d’inférence vs nombre de pas (`eval_num_steps`) et nombre de membres CRPS.

4.10 Discussion critique

- Risque de *collapse* du résidu si μ_{HR} absorbe une fraction trop importante du signal HR ; le déclenchement du garde-fou `abort_on_collapse` et de `dag_floor_projection` doit être reporté.
- Limite d’une baseline lissage HR pour certains régimes convectifs ; évolution potentielle vers des baselines bicubiques calibrées ou apprises.
- Difficulté des queues lourdes de précipitations et intérêt de variantes *t*-EDM ou WassDiff comme perspectives.
- Coût d’inférence dominant : compromis vitesse/précision à régler via `eval_num_steps`, `num_samples` et `eval_scheduler`.
- Sensibilité des métriques au choix du seuil de précipitations et à la transformation $\log(1 + p)$.

4.11 Menaces à la validité

- Validité interne : qualité des splits temporels, choix de normalisation, traitement des NaN (stratégie `mean`), reproductibilité des graines.
- Validité externe : couverture limitée aux données ACCESS-CM2 historique, nécessité d'évaluations sur d'autres réanalyses (ERA5) et sur les scénarios CMIP6/CORDEX.
- Validité statistique : incertitude des métriques mono-run, nécessité de répétitions et d'intervalles bootstrap.
- Validité opérationnelle : passage de l'apprentissage en climat historique au déploiement sur scénarios futurs (OOD), avec recalibration potentielle de σ_{data} et vérification de stabilité du DAG.

4.12 Synthèse du chapitre

- Résumer ce que les résultats confirment vis-à-vis des hypothèses Q1–Q3.
- Identifier les points encore à consolider (répétitions, OOD, baselines supplémentaires).
- Préparer la transition vers la conclusion générale.

Livrables attendus pour le chapitre 4

- Tableau exhaustif des données, des variables et des hyperparamètres effectivement utilisés (issu de `config/training_config.yaml`).
- Tableau de résultats principaux (point estimate + répétitions à venir).
- Figures comparatives : champs HR prédits, observations, baseline, résidu et μ_{HR} .
- Tableau d'ablations causales : DAG appris, DAG nul, DAG aléatoire, prior physique seul.
- Section de discussion critique, limites et menaces à la validité.

8 Plan détaillé de la Conclusion générale

Titre recommandé : *Conclusion générale et perspectives.*

Objectif de la conclusion

Fermer l'argument scientifique : revenir sur la problématique, synthétiser les apports validés, expliciter les limites et ouvrir des perspectives réalistes.

Structure détaillée proposée

C.1 Récapitulatif de la problématique

- Reprendre le problème : produire un downscaling local probabiliste fiable en climat futur.
- Rappeler le fil directeur : du trilemme OOD à l'architecture Oracle.

C.2 Synthèse des contributions

- Contribution conceptuelle : formulation du besoin de causalité indispensable, au-delà de l’explicabilité post-hoc.
- Contribution architecturale : graphe hétérogène, encodeur intelligible, RCN, DAGMA et projection spectrale.
- Contribution générative : décomposition moyenne causale / résidu EDM.
- Contribution expérimentale : protocole centré sur calibration, extrêmes et ablations causales.

C.3 Réponses aux questions de recherche

- Réponse à Q1 : positionner les limites des modèles adversariaux et diffusifs non causaux.
- Réponse à Q2 : expliquer le rôle du RCN comme moteur causal récurrent.
- Réponse à Q3 : relier les résultats aux métriques de calibration et d’extrêmes.

C.4 Limites du travail

- Domaine climatique et volume de données encore limités.
- Validation OOD à consolider avec des scénarios climatiques futurs.
- Baseline non causale à améliorer pour certains usages opérationnels.
- Coût d’inférence de la diffusion à optimiser.

C.5 Perspectives

- Extension multivariable avec pertes physiques inter-variables.
- Évaluation sur plusieurs domaines climatiques et jeux CORDEX/CMIP6 (généralisation OOD réelle au sens de la section 1.5).
- **Tier 3 architectural** : entraînement *joint* de Stage 1 et Stage 2 (sans gel après Stage 1) sous contrainte explicite de la propriété (O3) ; ajout d’une perte *spectrale* sur le RAPSD pour pousser au plus près la cible Oracle ; passage à t -EDM (?) pour les queues lourdes Student- t , ou à WassDiff (?) pour la calibration multivariée.
- Couplage avec correction de biais et chaînes d’impact pour les communautés locales.
- Outils de visualisation XAI pour auditer les chemins causaux appris (carte de chaleur de la sensibilité à chaque arête de A_{dag} , projection saillance-DAG sur la moyenne μ_{HR}).

C.6 Mot de clôture

- Rappeler la valeur scientifique : passer d’un modèle qui reproduit des motifs climatiques à un modèle qui exploite des mécanismes causaux invariants.
- Rappeler la valeur pratique : produire des cartes locales plus fiables pour l’adaptation climatique.

Livrables attendus pour la conclusion

- Un tableau “Questions de recherche vs réponses apportées”.
- Une section limites courte, explicite et honnête.
- Une liste de perspectives priorisées pour poursuite en article ou thèse.