

Prédire le potentiel de fixation de l'azote chez les bactéries par intelligence artificielle

MOSAIC : un outil computationnel pour accélérer la sélection des biofertilisants

Thématique : Agriculture durable · Sécurité alimentaire · Intelligence artificielle · Bioinformatique

Résumé exécutif. L'azote est indispensable à la croissance des plantes, mais sa production industrielle consomme 1 à 2 % de l'énergie mondiale et génère des gaz à effet de serre. Des bactéries naturellement présentes dans les sols fixent l'azote atmosphérique sans engrais chimiques. Les identifier rapidement parmi des milliers de souches candidates est un défi coûteux.

MOSAIC, développé à l'Université de Dschang, prédit si une bactérie fixe l'azote et estime son niveau d'activité à partir de données génomiques : précision de **91,4 %**, AUC de **0,9646**, +2,8 points sur l'outil de référence international Carmna. MOSAIC peut réduire de 40 à 60 % le nombre de souches à tester en laboratoire, au bénéfice direct du développement des biofertilisants.

Problématique

L'agriculture camerounaise et africaine dépend fortement des engrais azotés importés, dont le coût pèse sur les exploitations familiales. Leur usage excessif dégrade les sols et contribue aux émissions de gaz à effet de serre.

Les biofertilisants bactériens représentent une alternative, mais leur développement bute sur un goulet d'étranglement : parmi des centaines de souches isolées sur le terrain, identifier celles qui fixent vraiment l'azote. Le test de référence (test ARA) est lent, coûteux et exige des équipements spécialisés.

Les outils computationnels existants traitent les données génomiques comme une liste plate de chiffres et séparent la classification du statut de fixation et l'estimation de l'activité en deux modèles indépendants laissant inexploitées les relations entre familles de descripteurs.

Résultats scientifiques

MOSAIC a été évalué sur le benchmark ARA : 402 souches (193 fixatrices, 209 non fixatrices).

Classification du statut de fixation (n = 81)

Méthode	AUC	F1
MOSAIC	0,9646	0,9136
Carmna	0,9365	0,85
NFEmbed-C	0,922	0,892

Rappel : **0,9487** (9 fixatrices sur 10 détectées). Précision globale : **91,4 %**.

Estimation de l'activité nitrogénase

Méthode	R ²	RMSE
MOSAIC	0,6217	0,5256
Carmna	0,5572	0,5687
Bomgni et al.	0,622	–

L'analyse d'interprétabilité (SHAP, attention, t-SNE) révèle que les descripteurs de composition et d'usage des codons sont les plus déterminants et oriente des hypothèses biologiques sur les signatures génomiques des souches fixatrices.

Analyse et implications

MOSAIC organise les 35 341 descripteurs d'une souche en 59 groupes interconnectés par un graphe. Un réseau de neurones (GAT) propage l'information entre ces groupes avant de prédire simultanément le statut et l'activité. Ce cadre relationnel capture des interactions entre familles de descripteurs que les méthodes précédentes ignoraient.

Un pipeline hybride raffine la prédiction en espace latent : SMOTE équilibre les classes avant le classifieur XGBoost tandis que le régresseur SVR-RBF est entraîné indépendamment, les deux optimisés par Optuna. Ce pipeline apporte +0,92 point d'AUC par rapport aux têtes directes du réseau.

Limite : MOSAIC est un outil de priorisation. Ses prédictions hiérarchisent les souches candidates pour des

tests ciblés ; elles ne remplacent pas la validation expérimentale. Un jeu de données camerounais élargirait la représentativité du modèle.

Options de politique

Option A – Filtre computationnel. Utiliser MOSAIC avant tout test ARA : réduction estimée de 40 à 60 % du nombre de souches à tester.

Option B – Base de données nationale. Séquencer et intégrer les souches isolées au Cameroun pour ré-entraîner MOSAIC sur des données locales en partenariat avec l'IRAD et les universités.

Option C – Service web académique. Déployer MOSAIC comme outil en ligne en libre accès pour les unités de recherche agronomiques.

Recommandations politiques

- **MINRESI** : financer une extension du benchmark ARA avec des souches camerounaises et d'Afrique centrale.
- **MINADER** : intégrer les outils de prédiction computationnelle dans la chaîne de développement des

biofertilisants.

- **UDs/URIFIA** : déployer MOSAIC comme service académique mutualisé sous licence ouverte en partenariat avec l'IRAD.
- **Bailleurs** : considérer l'IA appliquée à l'agronomie durable comme un axe de financement à fort levier et faible coût de développement.

Acteurs cibles

MINRESI, MINADER, IRAD, universités camerounaises, FAO, CGIAR, Banque africaine de développement, industries de biofertilisants.

Méthodologie (résumé)

Benchmark ARA (402 souches, données publiques). Descripteurs : 35 341 dimensions en 59 blocs. Graphe inter-blocs par corrélations de Pearson. Architecture : GAT auto-encodeur, vecteur latent $\mathbf{z} \in \mathbb{R}^{128}$, têtes de classification et de régression. Pipeline hybride : SMOTE pour équilibrer les classes avant XGBoost ; SVR-RBF entraîné indépendamment ; Optuna (150 essais) pour les deux. Protocole : partition stratifiée 321/81, transformation $\log_{10}(x+2)$ de la cible.



Auteur : Dilane SAGUEU WAKAM, Université de Dschang, URIFIA **Encadrant** : Pr Alain Bertrand BOMGNI, Maître de Conférences, UDS/FS

Contact : sagueuwakam@gmail.com

Travaux associés : DIGNIF (*Diazotroph Identification via Graph Neural Networks*), soumis à *Computational Biology and Chemistry*, 2026 ; Dual-Level Bayesian Predictive Modeling of Biological Nitrogen Fixation, 2026.