

RÉPUBLIQUE DU CAMEROUN

Paix – Travail – Patrie

UNIVERSITÉ DE DSCHANG

École des Sciences et
Technologies de Dschang



REPUBLIC OF CAMEROON

Peace – Work – Fatherland

UNIVERSITY OF DSCHANG

School of Sciences and
Technologies of Dschang

Unité de Recherche en Informatique Fondamentale, Ingénierie et Applications (URIFIA)

Développement de Méthodes d'Apprentissage Automatique pour la Mise à l'Échelle Spatiale des Données Climatiques

Mémoire de Master en Informatique — option Informatique Fondamentale, spécialisation Intelligence Artificielle

Présenté par **KENFACK Leonel**

Sous la direction du **Pr. BOMGNI Alain Bertrand**, Maître de Conférences

Année académique 2025–2026

Plan de l'exposé

Contexte et problématique

État de l'art

Proposition : ORACLE

Matériels et méthodes

Résultats


Discussion et conclusion

Le fil de l'exposé

Un besoin local vital → un verrou scientifique précis → une réponse architecturale, ORACLE → des résultats mesurés contre une baseline stricte → des limites assumées.

Les modèles climatiques globaux voient le monde à 100–250 km

- ▶ Les GCM du GIEC (CMIP6) simulent l'atmosphère avec des mailles de 100 à 250 km de côté.
- ▶ À cette échelle : Douala et Yaoundé occupent la même cellule, le mont Cameroun n'a aucun effet, la transition savane–forêt disparaît.
- ▶ **Downscaling** (descente d'échelle) : produire, à partir de ces sorties grossières, une représentation fine (1 à 12 km) utilisable pour la décision.



Même territoire, deux lectures :
l'une invisible aux décideurs, l'autre
exploitable.

Pourquoi ? Les décisions d'adaptation se prennent à l'échelle locale

- ▶ **Agriculture** : semer quoi, où, quand — la planification d'un bassin agricole pluvial dépend de la pluie *locale*, pas de la moyenne régionale.
- ▶ **Eau et énergie** : dimensionner un barrage ou un réseau de drainage exige la distribution fine des précipitations, extrêmes compris.
- ▶ **Urbanisme et risque** : les inondations de l'Extrême-Nord du Cameroun (octobre 2024) ont affecté 356 000 personnes et noyé 82 500 hectares de cultures — *sans qu'aucune anticipation communale n'ait été possible.*

Le message

Sans downscaling, les projections climatiques existent mais restent *inutilisables* là où elles seraient le plus nécessaires.

En Afrique, le besoin est vital et les moyens de calcul manquent

Le besoin

- ▶ Cameroun : l'agriculture pèse **22 % du PIB** et fait vivre **44 %** de la population active (Banque Mondiale).
- ▶ La centrale de Lagdo fournit **74 %** de l'électricité du Nord-Cameroun.
- ▶ Productivité agricole africaine : **-34 % depuis 1961** sous l'effet du changement climatique (GIEC AR6), pire régression mondiale.
- ▶ Sans adaptation : **4 à 10 % du PIB** camerounais menacé d'ici 2050.

Les moyens

- ▶ Le continent héberge **moins de 1 %** des capacités mondiales de calcul haute performance.
- ▶ Le downscaling dynamique classique y est donc *de facto* hors de portée en production locale.

Conséquence

Il faut des méthodes de downscaling *peu coûteuses à l'inférence* et *fiables hors de leur régime d'entraînement*.

Deux familles de downscaling, deux impasses différentes

Dynamique (RCM emboîté)

- ▶ Résout les équations physiques à maille fine : **rigoureux**.
- ▶ Mais la configuration CWA-WRF de référence tourne sur **928 cœurs en parallèle** : un seul scénario à la fois, résolutions CORDEX bloquées à 12–50 km.

Statistique (apprentissage profond)


- ▶ Apprend $y_{LR} \mapsto x_{HR}$: **rapide**, milliers de membres possibles.
- ▶ Mais *boîte noire* : sorties impossibles ($T_{\min} > T_{\max}$, 4 % $\rightarrow$ 15–17 % en projection 2100), 31 réentraînements identiques $\Rightarrow$ erreurs variant d'un **facteur 46**.

Ce mémoire s'inscrit dans la seconde voie — en s'attaquant à ses défauts d'interprétabilité et de généralisation.

La littérature fait ressortir trois verrous structurants

1. **Stabilité d'entraînement.** Les GAN sont très sensibles au poids adversarial λ_{adv} et au déséquilibre générateur–discriminateur ; réglages peu transférables d'une région à l'autre.
2. **Réalisme des extrêmes (sub-dispersion).** Variance prédite trop faible : $\sigma_{\text{pred}}/\text{RMSE} \approx 0,3$ rapporté dans le domaine (cible : 1), soit un facteur 3 de sous-estimation de la variabilité — donc des extrêmes, précisément les événements à plus forte valeur.
3. **Robustesse hors-distribution.** Sous changement climatique, la statistique jointe des variables évolue ; un modèle purement corrélatif apprend des associations contingentes au régime d'entraînement.

Aucune approche ne tient les trois sommets à la fois : un trilemme



- ▶ Les cGAN les plus **expressifs** sont les plus **instables**.
- ▶ Les diffusions **stables** restent **corrélatives**, sans garantie OOD.
- ▶ Les RCM **robustes** paient en **coût de calcul**.

Constat agrégé de la littérature (Rampal 2024, Mardani 2023, Harris 2022) — pas une formalisation originale.

La question centrale du mémoire

*Comment **causaliser le premier étage** du paradigme à deux étages pour doter le downscaling probabiliste d'une **robustesse de principe** au changement de distribution, **sans dégrader** la stabilité ni le réalisme acquis ?*

Trois termes à défendre aujourd'hui :

- ▶ **causaliser** : quelle forme de causalité, placée où ? (Proposition)
- ▶ **robustesse de principe** : comment la mesurer honnêtement ? (Protocole)
- ▶ **sans dégrader** : contre quelle référence ? (Baseline stricte)

Les cGAN résiduels : nets sur les extrêmes, fragiles à l'entraînement

- ▶ Référence du domaine néo-zélandais : le cGAN résiduel de Rampal et al. (2024) — un CNN prédit la moyenne, un générateur adversarial ajoute les détails.
- ▶ **Forces** : champs nets, bonne texture des fortes pluies, inférence rapide.
- ▶ **Limites empiriques** : instabilité générateur–discriminateur, *mode collapse*, pas de vraisemblance explicite — et sub-dispersion persistante.

Ce qu'on en retient pour ORACLE

L'idée *résiduelle* (prédire l'écart à une moyenne) est précieuse ; le cadre adversarial, lui, compromet le verrou n°1 (stabilité).

Les modèles de diffusion : le cadre stable, formalisé par EDM

- ▶ Principe : apprendre à débruiter progressivement un champ, puis échantillonner en partant du bruit — entraînement par simple régression, **stable**.
- ▶ Le formalisme EDM (Karras et al., 2022) **normalise adaptativement** entrées et sorties selon le niveau de bruit σ :

$$\mathcal{D}_\theta(x_\sigma, \sigma) = c_{\text{skip}}(\sigma) x_\sigma + c_{\text{out}}(\sigma) \epsilon_\theta(c_{\text{in}}(\sigma) x_\sigma, c_{\text{noise}}(\sigma))$$

- ▶ Le réseau reçoit un signal d'apprentissage stable sur toute la plage de bruit : plus d'hyperparamètres de schéma à régler à la main.
- ▶ **Mais** : un modèle de diffusion reste *corrélatif* — rien ne contraint ce qu'il apprend à survivre à un changement de régime.

CorrDiff : régression déterministe puis diffusion du résidu




Figure : Mardani et al. (2023), reproduite au chapitre I du mémoire.

- **Étage 1** : un U-Net entraîné par MSE prédit la moyenne conditionnelle.
- **Étage 2** : une diffusion EDM échantillonne le *résidu* — cible centrée, de faible amplitude.
- **Résultat** : $\sim 60\times$ la vitesse d'un RCM WRF à l'inférence, calibration correcte.

C'est le paradigme que nous adoptons — et que nous allons modifier en un point précis.

Deux failles de CorrDiff : stationnarité supposée, conditionnement contournable

1. **Hypothèse de stationnarité.** L'efficacité du schéma résiduel repose sur la *faible variance du résidu*, garantie seulement si la distribution cible est stationnaire — hypothèse que le changement climatique invalide directement. Les auteurs signalent eux-mêmes un *significant distribution shift*.
2. **Le piège du conditionnement par cross-attention.** Une voie d'attention parallèle permet au réseau de puiser l'information *en contournant* le module que l'on croit conditionnant.

Constat vécu (phases exploratoires 1–2 du projet)

Avec un conditionnement par cross-attention, notre DAG appris était *décoratif* : forcer $A_{\text{dag}} \leftarrow \mathbf{0}$ ne dégradait pas la prédiction. Le U-Net bypassait le chemin causal via ses skip-connections.

Le gap : aucune approche n'intègre de structure causale par construction

Approche	Stabilité	Extrêmes	OOD	Causal	Génératif
U-Net / CNN (2017)	✓	×	×	×	×
cGAN résiduel (2024)	△	△	×	×	✓
DDPM / EDM brut (2020-22)	✓	✓	△	×	✓
CORRDIFF (2023)	✓	△	△	×	✓
Oracle (proposé)	✓	△	△	✓	✓

✓ = bien traité △ = partiel × = non traité. Extrait du tableau modèle×verrou du chapitre II ; les △ d'ORACLE reflètent honnêtement les limites mesurées.

Formulation du gap

Le paradigme deux-étages couvre le mieux stabilité + extrêmes + probabiliste, mais sa robustesse OOD n'est pas adressée *par construction* : il faut **causaliser son premier étage**.

Ce que nous proposons

Objectif principal. Une architecture de downscaling probabiliste intégrant une structure causale *apprise*, qui garantit *par construction* la dépendance entre variables atmosphériques d'entrée et précipitation prédite.

1. Concevoir un **réseau causal récurrent** (RCN) : SCM dynamique + GRU + pénalité d'acyclicité DAGMA, dans une seule cellule ;
2. L'inscrire dans le paradigme deux-étages de CORRDIFF en remplaçant *uniquement* le premier étage — l'étage de diffusion EDM reste **inchangé** ;
3. Définir un **protocole** centré sur la calibration probabiliste, le réalisme des extrêmes et la robustesse inter-GCM, incluant un test d'intervention contrôlée original dans ce contexte.

L'idée clé : placer la causalité dans la topologie, pas dans la perte

Causalité par régularisation

Un terme de perte « causal » peut être **contourné** par un réseau suffisamment expressif : il minimise la pénalité sans changer son mécanisme.


Causalité par architecture

Une dépendance inscrite dans le *graphe de calcul* est **indéfaisable par construction** : aucune information conditionnelle ne peut transiter ailleurs que par A_{dag} .

C'est un déplacement du *lieu* de la contrainte : de la fonction objectif vers la topologie du réseau. Toute la conception d'ORACLE découle de ce choix — et il se **teste** (propriété O3, plus loin).

Oracle en quatre blocs, autour d'une décomposition additive

$$x_{\text{HR}} = \underbrace{\text{baseline}_{\text{LR}\uparrow}}_{\text{interpolation}} + \underbrace{\mu_{\text{HR}}(y_{\text{LR}}; A_{\text{dag}})}_{\text{moyenne causale (Étage 1)}} + \underbrace{\delta(\sigma; \mu_{\text{HR}}, \text{baseline})}_{\text{résidu stochastique (Étage 2)}}$$




Attribution propre

L'écart avec CORRDIF est **entièrement concentré dans le bloc (2)** : Étage 2, pertes EDM, sampler et préconditionnement sont hérités tels quels. Toute amélioration mesurée est attribuable à la causalisation.

Un graphe atmosphérique hétérogène, agrégé à 6 nœuds pour rester lisible

- ▶ Nœuds **GP850**, **GP500**, **GP250** : variables dynamiques aux trois niveaux de pression ; nœud **SP_HR** : statiques haute résolution (orographie, masque terre/mer).
- ▶ Trois types d'arêtes = trois mécanismes physiques : **spatiales** (advection), **verticales** (convection), **statiques** → **pression** (influence orographique).
- ▶ Version résolue : $\sim 32\,600$ nœuds. Version expérimentale : **6 nœuds typés** $\Rightarrow A_{\text{dag}} \in \mathbb{R}^{6 \times 6}$ inter-variables, *interprétable par un humain*.



Un encodeur intelligible : quinze MLP dédiés, zéro paramètre partagé

- ▶ Un MLP *par couple* (variable, niveau de pression) : $u, v, w, q, t \times \{850, 500, 250\} \text{ hPa} \rightarrow$ latent de dimension $d = 128$ chacun.
- ▶ Aucun poids partagé entre variables : chaque ligne et colonne de A_{dag} conserve une **identité physique** lisible.

Pourquoi c'est important

Avec un encodeur mélangeant les canaux (convolution standard), l'arête « $q_{850} \rightarrow$ précipitation » ne voudrait plus rien dire : l'interprétabilité du DAG se joue *avant* le DAG, dans l'encodeur.

Le RCN : le modèle causal structurel est le moteur récurrent

À chaque pas t , deux briques en boucle fermée ($T = 8$ pas) :

1. Assignment SCM (*plan de vol*)

$$\hat{H}_t^{(i)} = f_i(A_{\text{dag}}^{(i,\cdot)} \odot H_{t-1}, x_t, \varepsilon_t^{(i)})$$

chaque variable i est prédite *uniquement* depuis ses parents dans A_{dag} — un MLP structurel f_i par variable.

2. Mise à jour GRU (*instruments*)

$$H_t = (1 - z_t) \odot \hat{H}_t + z_t \odot \tilde{H}_t$$

fusion de la prédiction théorique et de l'observation courante (portes z_t, r_t standard).

L'originalité

La transition d'état $H_t \rightarrow H_{t+1}$ **est** l'assignation causale — le SCM n'est pas un post-traitement appliqué à un état caché produit par ailleurs.

Apprendre un graphe acyclique par descente de gradient : DAGMA

Chercher un DAG est combinatoire (croissance super-exponentielle en N). DAGMA (Bello et al., 2022) rend l'acyclicité *différentiable* :

$$h_{\text{DAGMA}}(A; s) = -\log \det(s I - A \odot A) + N \log s, \quad s > N \max_{i,j} |A_{i,j}|$$

- ▶ $h_{\text{DAGMA}}(A) = 0 \iff A$ représente un DAG ; gradient via l'inverse de $sI - A \odot A$, coût d'une décomposition LU.
- ▶ Dans ORACLE, combinée à une sparsité L_1 pour une matrice **creuse et auditable** :
 $\mathcal{L}_{\text{dag}} = \lambda_{\text{DAGMA}} h_{\text{DAGMA}}(A_{\text{dag}}) + \lambda_{L_1} \|A_{\text{dag}}\|_1.$
- ▶ Warmup de 5 époques : la contrainte monte en puissance une fois les représentations stabilisées.

Du graphe à la grille : cross-attention intermédiaire puis raffinement

L'état final $H_T \in \mathbb{R}^{B \times N \times d}$ devient une carte $\mu_{HR} \in \mathbb{R}^{B \times 1 \times 172 \times 179}$:

$$\tilde{\mu}_p = \sum_{n=1}^N \alpha_{p,n} V_n, \quad \alpha_{p,n} = \text{softmax}_n \left(\langle Q_p, K_n \rangle / \sqrt{d} \right)$$

- Requêtes sur une grille intermédiaire 43×45 (attention directe à 172×179 : matrice $30\,788 \times N$ prohibitive ; coût réduit d'un facteur 16), puis sur-échantillonnage bilinéaire + raffinement convolutif léger.
- **Garde-fou** : skip conditionnel $\mu_{HR} = \alpha(y_{LR}) \mu_{\text{causal}} + (1 - \alpha(y_{LR})) \mu_{\text{direct}}$, avec porte apprise contrainte $\alpha \geq 0,6$ — le modèle ne peut pas devenir un « non-causal déguisé ».

La propriété (O3) : l'indispensabilité du chemin causal est *testable*

Définition (indispensabilité causale, O3)

Soit $\Delta_{O3} = \text{MSE}(\mu_{\text{HR}}(\mathbf{0})) - \text{MSE}(\mu_{\text{HR}}(A_{\text{dag}}))$ le surcoût d'erreur quand A_{dag} est forcée à zéro à l'inférence. ORACLE satisfait (O3) au seuil τ si

$$\frac{\Delta_{O3}}{\text{MSE}(\mu_{\text{HR}}(A_{\text{dag}}))} \geq \tau, \quad \tau \in [0,05, 0,10].$$

- ▶ Opérationnalisée par une variante d'ablation qui force $A_{\text{dag}} = \mathbf{0}$ à *l'inférence seulement* : si le DAG était décoratif, rien ne bougerait.
- ▶ C'est le critère qui a **disqualifié** nos architectures à cross-attention (phases 1–2) — et qui sert de **porte d'entrée** au second étage.

Étage 2 : diffusion du résidu, conditionnée par concaténation — jamais par attention

$$\text{input}_{\text{UNet}} = \text{concat}(\delta_{\text{bruite}}, \mu_{\text{HR}}, \log(1 + \text{baseline})) \in \mathbb{R}^{B \times 3 \times H \times W}$$

- ▶ La concaténation force le U-Net à *voir* μ_{HR} comme un canal d'image traité localement — **aucune voie d'information parallèle** (leçon des phases 1–2) ; et elle coûte moins cher que l'attention.
- ▶ Le résidu est une cible *facile* : centré autour de zéro, écart-type σ_{data} après log-transformation — la calibration retrouve un sens physique et la sub-dispersion recule (verrou n°2).
- ▶ Formalisme EDM repris **sans modification** : préconditionnement $(c_{\text{skip}}, c_{\text{out}}, c_{\text{in}}, c_{\text{noise}})$, perte pondérée $\lambda(\sigma)$, solveur de Heun / DPM-Solver++.

Terrain d'essai : la Nouvelle-Zélande, un bac à sable exigeant

Faute de jeu haute résolution de référence sur la zone africaine visée, trois raisons dictent ce choix :

1. **Référence comparable** : jeu HR aligné sur les protocoles CORRDIFF et cGAN néo-zélandais — deux baselines génératives crédibles.
2. **Diversité climatique compacte** : subtropical, marin tempéré, semi-aride sous le vent, alpin — sur moins de 270 000 km².
3. **Test orographique sévère** : gradient ouest–est de plus de 10 000 mm/an sur 50 km, parmi les plus extrêmes au monde.

Statut épistémique

Une architecture qui tient ici sous ablation causale fournit une preuve d'*universalité architecturale* indépendante du climat d'entraînement — préalable au transfert africain, qui reste l'horizon du travail.

Données : quinze prédicteurs ACCESS-CM2 vers la pluie journalière à 5–10 km

- ▶ **Entrée LR** : grille 23×26 ; u, v, w, q, t à 850/500/250 hPa (15 canaux), protocole aligné sur Rampal et al.
- ▶ **Cible HR** : précipitation journalière, grille 172×179 , traitée en $\log(1 + \text{precip})$ (queue lourde).
- ▶ Séquences de $T = 8$ pas, masque océanique exclu des pertes ($\approx 60\%$ de pixels continentaux utiles).

Partitions

- ▶ Entraînement : 1980–2009
- ▶ Validation : 2010–2012
- ▶ Test en distribution : ACCESS-CM2, 2013–2014
- ▶ **Test inter-GCM** : EC-Earth3 et NorESM2-MM, jamais vus, même période d'évaluation

Un entraînement en deux temps, avec cache des résiduels

1. **Étage 1** (GPU L4) : encodeur + RCN + décodeur, AdamW, 10–15 époques ; perte composite (MSE, reconstruction, DAGMA, L_1 , préservation O3, pondération des queues).
2. **Gel et cache** : μ_{HR} et baseline pré-calculées pour chaque échantillon ; recalibration de σ_{data} par algorithme de Welford sur les résiduels réels ($\approx 0,19$) — sans elle, le U-Net apprend l'identité.
3. **Étage 2** (GPU A100) : U-Net EDM de 42,8 M de paramètres, 200 époques sur les résiduels gelés.

Cycle complet ≈ 45 h cumulées. Inférence : DPM-Solver++, 32 pas, ensembles $K = 64$ (en distribution) et $K = 12$ (inter-GCM).

Protocole : quatre familles de métriques, deux diagnostics causaux, une baseline stricte

Quatre familles

- ▶ Erreur ponctuelle : RMSE, MAE, Pearson
- ▶ Calibration : CRPS, *spread-skill*, histogramme de rang
- ▶ Structure spatiale : RAPSD, FSS multi-échelle
- ▶ Extrêmes : F1@p95/p99, indices ETCCDI (RX1day, R10mm, CDD)

Deux diagnostics causaux

- ▶ Ratio O3 (indispensabilité)
- ▶ Perturbations contrôlées $\Delta(q_{850} + 20\%)$, $\Delta(t_{850} + 3\text{ K}) \rightarrow Q_{\text{int}}$

La baseline « Noncausal »

CORRDIFF réentraîné dans les mêmes conditions : mêmes données, même U-Net EDM, mêmes hyperparamètres — seul l'étage 1 causal est remplacé par un régresseur convolutif générique.

La comparaison isole strictement l'effet de la causalisation ; significativité par tests de Diebold–Mariano et Wilcoxon.

Avant tout résultat : O3 mesurée à 0,87 — le chemin causal est porteur

$$\text{ratio}_{O3} = \frac{\mathbb{E}[|\mu_{\text{HR}}(A_{\text{dag}}) - \mu_{\text{HR}}(\mathbf{0})|]}{\mathbb{E}[|\mu_{\text{HR}}(A_{\text{dag}})|]} = \mathbf{0,87} \quad (\text{seuil d'arrêt : } 0,05)$$


- ▶ 87 % de l'amplitude du signal prédit dépend fonctionnellement de A_{dag} : le DAG n'est **pas décoratif** ; l'entraînement du second étage est validé.
- ▶ Honnêteté de lecture : ce ratio atteste une *sensibilité fonctionnelle*, pas une relation causale au sens de Pearl — la distinction structurera la discussion des résultats.

Calibration : le CRPS recule de 40 %, le *spread-skill* triple

Métrique (en distribution)	ORACLE	Noncausal	Lecture
CRPS (mm/j)	0,249	0,415	gain −40 %
CRPS-SS (vs climatologie)	+0,895	+0,826	+6,9 pts
Spread/RMSE (cible 1)	0,686	0,197	×3,5
RMSE global (mm/j)	1,118	1,537	−27 %
χ^2 histogramme de rang	$5,4 \times 10^6$	$3,25 \times 10^7$	−83 %

- ▶ Gain significatif (Diebold–Mariano et Wilcoxon, $p < 0,01$, $n = 365 \text{ jours} \times \approx 18\,000 \text{ pixels}$).
- ▶ Spread-skill $0,20 \rightarrow 0,69$: l'ensemble sort du régime « inutilisable » ($< 0,5$) — on peut commencer à lire les quantiles comme des intervalles de confiance. Cible 1,0 non atteinte : sous-dispersion résiduelle assumée.

Les probabilités prédites deviennent fiables — sauf au seuil le plus extrême




Diagrammes de fiabilité, $P(\text{precip} > \{1, 10, 50\} \text{ mm/j})$. ORACLE (bleu) suit la diagonale ; la baseline Noncausal (orange) reste sous-confiante aux probabilités élevées. Sous-dispersion résiduelle à $> 50 \text{ mm/j}$.

Extrêmes : biais réduits sur RX1day et R10mm, distance spectrale divisée par 450

Biais (proche de 0 = mieux)	ORACLE	Noncausal	Lecture
RX1day (mm)	−2,73	−4,09	sous-prédiction réduite de 33 %
R10mm (jours)	+0,88	+2,65	gain −67 %
CDD (jours)	+17,95	+21,51	surestimé des deux côtés
Distance PSD	0,001	0,447	÷450

- ▶ La baseline lissait les échelles 30–80 km ; ORACLE devient *skillful* (FSS) dès ~30 km contre ~80 km, et restitue la queue droite là où CORRDIFF tronque au-delà de ~30 mm/j.
- ▶ CDD : biais hérité de la perte MSE — aucune valeur opérationnelle revendiquée pour la sécheresse.

Périodes de retour : Oracle suit la vérité là où la baseline sature



Courbes de Gumbel, précipitation journalière maximale — en distribution (ACCESS-CM2) et sur les deux GCM jamais vus. ORACLE (bleu) suit la vérité (noir) jusqu'aux périodes les plus longues ; la baseline Noncausal (orange) sature systématiquement sous les extrêmes observés.

Robustesse inter-GCM : le gain persiste sur deux modèles jamais vus

GCM	ORACLE		Noncausal		Δ CRPS
	CRPS	spr/RMSE	CRPS	spr/RMSE	
ACCESS-CM2 (réf. ID)	0,249	0,686	0,415	0,197	−40 %
EC-Earth3 (inter-GCM)	0,319	0,575	0,457	0,183	−30 %
NorESM2-MM (inter-GCM)	0,342	0,593	0,478	0,196	−28 %

- ▶ ORACLE reste $1,4\times$ meilleur en valeur absolue sur des GCM *jamais vus* à l'entraînement, avec un spread-skill $3\times$ supérieur.
- ▶ Lecture honnête : le gain causal porte sur le *niveau* d'erreur, pas sur la *pente* de dégradation — et le régime reste historique (le test SSP futur est en perspective).

Perturbations contrôlées : Oracle répond avec le bon signe, deux fois sur deux


Modèle	Perturbation	$\delta_{\text{moy}} (\times 10^{-3})$	Signe attendu ?
ORACLE	$q_{850} + 20 \%$	+1,24	oui (cohérent Clausius–Clapeyron)
ORACLE	$t_{850} + 3 \text{ K}$	+0,84	oui (cohérent Clausius–Clapeyron)
Noncausal	$q_{850} + 20 \%$	+0,55	oui
Noncausal	$t_{850} + 3 \text{ K}$	−0,84	non (signe inversé)

IC bootstrap 95 % excluant 0 dans les quatre cas ; $n = 30$ jours par perturbation.

Pourquoi la baseline échoue sur la température

Elle a appris la corrélation observationnelle « température élevée $\leftrightarrow$ régimes anticycloniques secs » de la Nouvelle-Zélande, au lieu de la relation thermodynamique qui agirait *toutes choses égales par ailleurs*.

Le modèle causal exploite réellement ses variables d'entrée



Integrated Gradients agrégés par variable LR. **Gauche** : ORACLE (bleu) exploite chaque variable un à deux ordres de grandeur de plus que la baseline Noncausal (orange). **Droite** : les leviers dominants sont physiquement sensés — vitesse verticale (w_{850} , w_{500}) et température (t_{850}).

Ce que le DAG apprend — et ce qu'il n'apprend pas

À 6 nœuds (configuration principale)

- ▶ Magnitudes **plates** ($\approx 0,18$ partout), $Q_{\text{phys}} = 0,40$.
- ▶ Limite d'identifiabilité *observationnelle* d'un SCM (Pearl) : le DAG appris est une *régularisation topologique*, pas une cartographie causale identifiée.

À 9 nœuds (un nœud par variable)

- ▶ $Q_{\text{phys}}^{\text{continu}} = \mathbf{0,9997}$, squelette $F1 = \mathbf{1,0}$, zéro arête parasite.
- ▶ La platitude n'est **pas un plafond architectural** : c'est le prix de l'agrégation choisie pour la lisibilité humaine.

L'asymétrie à retenir ($Q_{\text{int}} = 2/2$ vs $Q_{\text{phys}} = 0,40$)

Signes interventionnels corrects *sans* magnitudes identifiées : le DAG rend le modèle **intervenable** et **vérifiable** (O3) — c'est son rôle, distinct de celui du gain de skill.

Cinq limites assumées

1. **Magnitudes interventionnelles** $\approx$ trois ordres de grandeur sous Clausius–Clapeyron (0,01 %/K vs ~ 7 %/K) : le signe est correct, la magnitude non — contrôle de cohérence, pas outil de projection.
2. **Inter-GCM historique** $\neq$ vrai test hors-distribution climatique (validation SSP5-8.5 en perspective immédiate).
3. **Aucune donnée africaine testée** ; la métrique F1@p99 régresse ($-6,9$ %, régularisation lissante interne).
4. **Un seul seed** d'entraînement (contrainte de calcul) ; ensembles modestes ($K = 12/64$ contre 192 chez CORRDIFF).
5. **Orographie HR absente en entrée** : le déficit RX1day se concentre sur le versant ouest des Alpes du Sud — limite *isolable*, partagée par toutes les baselines du domaine.

Perspectives : trois horizons, cap sur l'Afrique

- Court terme (1–2 mois) Recalibration d'ensemble post-hoc (EMOS/BMA); validation sur **SSP5-8.5** — transforme le test inter-GCM historique en véritable test hors-distribution, sans modification architecturale.
- Moyen terme (3–6 mois) Ancrage prédictif joint type CASTLE (chaque arête de A_{dag} forcée à porter un signal); masque physique $\lambda_{\text{prior}} \|A_{\text{dag}} - \alpha G_{\text{phys}}\|^2$.
- Long terme (1–3 ans) **Transfert africain** : sanity-check zéro-shot (Hautes Terres éthiopiennes, Sahel ouest, cible CHIRPS), puis ré-entraînement sur prédicteurs adaptés (mousson, ondes d'Est, ITCZ) et **prior causal révisé** — convection profonde ascendante, là où le prior néo-zélandais encode un couplage descendant.

Conclusion : la causalité utile est une contrainte architecturale

- C1** Une architecture two-stage où la causalité est inscrite dans la **topologie du chemin de calcul** — indéfaisable par construction.
- C2** Le **réseau causal récurrent** : SCM dynamique + GRU + DAGMA dans une seule cellule.
- C3** Une **interface inter-étages** par concaténation garantissant qu'aucune information ne contourne le chemin causal ($O3 = 0,87$).
- C4** Un **protocole** à six familles de métriques avec deux diagnostics causaux originaux (ratio $O3$, Q_{int}).

CRPS **−40 %** ID CRPS **−30 %** inter-GCM spread-skill **×3,5** Q_{int} **2/2** vs 1/2

La causalité utile au downscaling n'est pas une propriété décorative émergeant d'une régularisation, mais une contrainte à placer explicitement dans le graphe de calcul. Elle fait ses preuves en Nouvelle-Zélande aujourd'hui ; elle devra les refaire demain dans les communautés d'Afrique centrale qui ont motivé ce travail.

Merci de votre attention

Questions ?


KENFACK Leonel — Université de Dschang, URIFIA
Sous la direction du Pr. BOMGNI Alain Bertrand

Backup A — Métriques ponctuelles en distribution (espace $\log(1 + p)$)

Métrique	ORACLE	Noncausal	Δ_{rel}
RMSE	0,124	0,130	−4,1 %
MAE	0,060	0,064	−5,7 %
Pearson global	0,825	0,819	+0,7 % (n.s.)
F1@p95	0,650	0,656	−0,8 %
F1@p99	0,512	0,550	−6,9 %
RAPSD distance	241,8	270,1	−10,5 %


Ensemble $K = 64$, IC bootstrap 95 %. Nous ne défendons pas ORACLE comme Pareto-dominant sur RMSE/F1@p99 pooled, mais comme la première version dont l'apport causal architectural est *mesurable*. La régression F1@p99 est analysée en annexe du mémoire (régularisation lissante).

Backup B — Cartes de réponse aux interventions



Réponse spatiale aux perturbations contrôlées (annexe IV du mémoire) : la réponse d'ORACLE est distribuée et du bon signe ; magnitudes en 10^{-3} unités relatives.

Backup C — Où se concentre le biais d'extrêmes ?



Biais RX1day d'ORACLE concentré sur le versant occidental des Alpes du Sud (annexe IV du mémoire) :
signature de l'absence de DEM haute résolution en entrée, partagée par CORRDIFF et le cGAN
néo-zélandais — limite isolable, première piste corrective.