

**RÉPUBLIQUE DU CAMEROUN
PAIX-TRAVAIL-PATRIE**

UNIVERSITÉ DE DSCHANG

ÉCOLE DOCTORALE



**REPUBLIC OF CAMEROON
PEACE-WORK-FATHERLAND**

UNIVERSITY OF DSCHANG

POST GRADUATE SCHOOL

ÉCOLE DES SCIENCES ET TECHNOLOGIES DE DSCHANG

**UNITÉ DE RECHERCHE EN INFORMATIQUE FONDAMENTALE,
INGÉNIERIE ET APPLICATION (URIFIA)**

THÈME :

**UNE APPROCHE BASÉE SUR LES TRANSFORMERS ET BILSTM-CRF
POUR LA RECONNAISSANCE D'ENTITÉS NOMMÉES
DE GÈNES ET DE PROTÉINES**

Mémoire soutenu publiquement en vue de l'obtention du diplôme de

Master en Informatique

Option : Informatique Fondamentale

Spécialité : Intelligence Artificielle

Présente Par :

FEUZING NTEMMA Donald

Matricule : CM-UDS-19SCI0454

Licence en informatique fondamentale

Sous la direction de :

Pr BOMGNI Alain Bertrand

Professeur Titulaire, Université de Dschang.

année 2024

DÉDICACE

*À mon père NTEMMA TCHENDJI GAETAN et à ma mère KENDJEU
SILVIE SIDONIE.*

REMERCIEMENTS

Je tiens à remercier **Dieu Tout-Puissant** sans qui rien n'aurait été possible.

J'adresse toute ma gratitude à mon encadreur, **Pr BOMGNI ALAIN BER-TRAND**, pour sa patience, sa disponibilité et surtout ses judicieux conseils, qui ont contribué à alimenter ma réflexion.

En témoignage de ma gratitude et de mon profond respect, j'adresse mes vifs et sincères remerciements :

- À tous les membres du jury, pour l'honneur qu'ils m'accordent en appréciant ce travail ;
- Au Pr TCHOUBE T. Maurice, pour ses critiques éclairées, ses remarques judicieuses, ses nombreux conseils et ses encouragements bienveillants ;
- Au Pr KENGNE T. Vianney, pour ses observations perspicaces, ses remarques pertinentes, ses précieux conseils et ses encouragements motivants ;
- Au Dr NYABEYE P. Doris-Khöler, pour ses analyses approfondies, ses remarques détaillées, ses suggestions utiles et ses encouragements soutenus ;
- À SIKOUNMO FOGUE Francois Xavier et YAWENI Tangui pour la solide formation, le partage d'expériences, et les remarques constructives ;
- À mes parents NTEMMA TCHENDJI GAËTAN et KENDJEU SYLVIE SIDONIE pour leurs conseils ainsi que leur soutien inconditionnel, à la fois moral et financier, qui m'ont permis de réaliser les études de choix et par conséquent ce mémoire ;
- À mon grand frère DETCHOM Jean Noël pour ses nombreux conseils et ses encouragements ;
- À mes petites sœurs et petits frères Diane, Daniella, Ange, Junior et Mariella pour l'attention permanente, le soutien multiforme et les encouragements ;
- À tous les membres de ma famille qui ont cru en moi et m'ont soutenu tant moralement que physiquement pour l'atteinte de cet objectif ;
- À tous mes camarades de promotion de Master 2 Recherche pour les discussions que nous avons partagées ;

TABLE DES MATIÈRES

Dédicace	i
Remerciements	ii
Table des matières	iii
Liste des Acronymes	vii
Liste des tableaux	viii
Table des figures	ix
Résumé	x
Abstract	xii
Introduction générale	1
Contexte du travail	1
Problématique étudiée	2
Objectifs	3
Contribution	3
Organisation du manuscrit	5
Chapitre 1 ► Généralités sur l'apprentissage automatique, le traitement du langage naturel et la reconnaissance d'entités nommées	6
I.1 - Introduction	6
I.2 - Généralités sur l'apprentissage automatique	7
I.2.1 - Les méthodes d'analyse de l'apprentissage automatique	8
I.2.1.1 - Apprentissage supervisé	8
I.2.1.2 - Apprentissage non supervisé	11
I.2.1.3 - Apprentissage semi-supervisé	12
I.2.1.4 - Apprentissage par renforcement	12
I.2.2 - Domaine d'application : Apprentissage profond	13
I.2.2.1 - Neurones artificiels	14
I.2.2.2 - Réseaux de neurones artificiels	15
I.2.2.3 - Réseaux de neurones récurrents	16
I.2.2.4 - Les réseaux LSTM et BiLSTM	17

I.2.2.5 - Réseaux de neurones convolutifs	20
I.2.2.6 - Les transformers	21
I.3 - Traitement automatique du langage naturel	25
I.3.1 - Définition du TALN	25
I.3.2 - Composent clés du TALN	25
I.3.3 - Outils et technologies du TALN.	26
I.3.4 - Applications du TALN	27
I.4 - Reconnaissance d'entités nommées	27
I.4.1 - Définition et objectifs	27
I.4.2 - Méthodologie de la REN	28
I.4.3 - Défis spécifiques de la REN	29
I.5 - Synthèse	30
 Chapitre II ► État de l'art sur la reconnaissance d'entités nommées :	
Cadre biomédical	31
II.1 - Introduction	31
II.2 - Généralité sur la reconnaissance d'entités nommées biomédicale	32
II.2.1 - Définition et spécificités de la REN biomédicale	32
II.2.1.1 - Définition de la REN biomédicale	32
II.2.1.2 - Spécificités du domaine biomédical	32
II.2.2 - Types d'entités nommées biomédicale	32
II.2.2.1 - Catégories principales d'entités	32
II.2.2.2 - Exemples et annotations	33
II.2.3 - Défis de la REN biomédicale	33
II.2.3.1 - Ambiguïté et synonymie	33
II.2.3.2 - Néologismes et termes rares	33
II.2.3.3 - Longueur et complexité des termes	34
II.2.4 - Ressources et outils pour la REN biomédicale	34
II.2.4.1 - Corpus et bases de données annotées	34
II.2.4.2 - Outils et bibliothèques	34
II.3 - Approches de reconnaissance d'entités nommées biomédicale	35
II.3.1 - Approches basées sur l'apprentissage automatique : Les champs aléatoires conditionnels	35
II.3.1.1 - Généralité sur les champs aléatoires conditionnels	35
II.3.1.2 - Reconnaissance d'entités nommées biomédicales uti- lisant des champs aléatoires conditionnels et des ensembles de caractéristiques riches[52]	37

II.3.2 - Approches basées sur l'apprentissage profond : Les transformers	38
II.3.2.1 - BERT : Pré-entraînement de transformeurs bidirectionnels profonds pour la compréhension du langage [13]	38
II.3.2.2 - BioBERT : Un modèle de représentation linguistique biomédicale pré-entraîné pour l'exploration de textes biomédicaux[34]	40
II.3.2.3 - BioByGANS : Reconnaissance d'entités nommées biomédicales par fusion des caractéristiques contextuelles et syntaxiques à travers un réseau d'attention graphique dans un cadre de classification de nœuds[76]	41
II.3.3 - Approches basées sur l'apprentissage profond : Le BiLSTM+CRF	42
II.3.3.1 - HunFlair : Un outil facile à utiliser pour la reconnaissance d'entités nommées biomédicales à la pointe de la technologie[71]	42
II.4 - Analyse des résultats obtenus par les approches de REN biomédicale : Gènes et protéines	44
II.4.1 - Cas des approches basées sur les CRF	44
II.4.2 - Cas des approches basées sur les transformers	45
II.4.3 - Cas des approches basées sur les BiLSTM-CRF	46
II.5 - Synthèse	46
Chapitre III ► Contribution à la reconnaissance d'entités nommées biomédicales : Gènes et protéines	48
III.1 - Introduction	48
III.2 - Description de l'approche proposée	49
III.3 - Workflow de la méthode proposée	50
III.3.1 - Architecture du modèle proposé	50
III.3.1.1 - Collecte de données d'entraînement	51
III.3.1.2 - Couche de prétraitement des données	51
III.3.1.3 - Couche d'extraction des embeddings	51
III.3.1.4 - Couche de reprojektion	52
III.3.1.5 - Couche de traitement séquentiel	52
III.3.1.6 - Couche de segmentation et d'étiquetage	52
III.3.2 - Evaluation du modèle	53

III.4 - Environnement de travail, résultats de simulation et discussions . .	55
III.4.1 - Présentation de l'environnement de travail	55
III.4.2 - Résultats de simulation	55
III.4.2.1 - Les scores de notre modèle	56
III.4.2.2 - Courbes de Perte et de F1-Score	57
III.4.3 - Discussions	59
III.4.3.1 - Discussions sur la Précision	61
III.4.3.2 - Discussions sur le rappel	61
III.4.3.3 - Discussions sur le F1-Score	62
III.5 - Synthèse	63
Conclusion générale	64
Problématique étudiée et choix méthodologiques	64
Analyse critique des résultats obtenus	65
Quelques perspectives	65
Bibliographie	66

LISTE DES ACRONYMES

BERT	Bidirectional Encoder Representations from Transformers.
BiLSTM	Bidirectional Long Short-Term Memory.
BIOBERT	Biomedical Bidirectional Encoder Representations from Transformers.
BioNER	Biomedical Name Entity Recognition
CRFs	Conditional Random Fields.
CLS	Classification
GAN	Graph Attention Network
HMMs	Hidden Markov Models.
IA	Intelligence Artificiel
ML	Machine Learning.
MLM	Masked language model
NSP	Next sentence prediction
NLP	Natural Language Processing.
PMC	PubMed Central
POS	Part of Speech.
QA	Question answering
RE	Relation extraction
RNA	Réseaux de Neurones Artificiels
REN	Reconnaissance d'Entités Nommées.
SVM	Support Vector Machine
SEP	Séparateur
TALN	Traitement automatique du langage naturel

LISTE DES TABLEAUX

I - Extrait du Dataset BC2GM avec annotation de Gène[54].	33
II - Scores des modèles de pointe pour la REN de Gène et Protéine.	45
III - Matrice de confusion	53
IV - Scores des modèles de pointe pour la REN de Gène et Protéine.	60

TABLE DES FIGURES

1 - Sous-domaines de l'intelligence artificielle [10]	7
2 - Apprentissage automatique[49]	8
3 - Apprentissage supervisé [1]	9
4 - Régression Vs Classification[7]	9
5 - Apprentissage non supervisé[7]	11
6 - Apprentissage semi-supervisé[66]	12
7 - Apprentissage par renforcement[73]	13
8 - Neurone Artificiel[23]	14
9 - Réseaux de Neurones artificiels[61]	15
10 - Réseaux de neurones récurrents[14]	17
11 - Long Short-Term Memory (LSTM)[47]	18
12 - Architecture d'un réseau de neurone convolutif[30]	21
13 - Architecture d'un transformer[67]	23
14 - Une vue très générale de BERT[68]	39
15 - Architecture de BioByGans[76]	42
16 - Écosystème de HunFlair [71]	44
17 - Architecture du modèle proposé	50
18 - Performance du modèle sur différents ensembles de données	56
19 - Courbes de Perte et de F1-Score	57
20 - Discussions sur la précision	61
21 - Discussions sur le rappel	61
22 - Discussions sur le F1-Score	62

RÉSUMÉ

La reconnaissance d'entités nommées (REN) biomédicale est cruciale pour l'extraction d'informations essentielles à partir de textes médicaux spécialisés. Ce processus permet de structurer les données biomédicales, facilitant ainsi les recherches et les diagnostics. Bien que les modèles basés sur l'architecture des transformeurs comme BioBERT soient largement utilisés dans le traitement automatique du langage naturel (TALN), certains modèles basés sur l'architecture BiLSTM-CRF, comme HunFlair, montrent des performances supérieures dans des contextes spécifiques. Ce mémoire présente une nouvelle architecture de modèle d'apprentissage automatique pré-entraîné, combinant les avantages de BioBERT et HunFlair. La couche d'embedding utilise BioBERT, reconnu pour sa capacité à capturer efficacement le contexte biomédical. La couche de traitement séquentiel repose sur un modèle BiLSTM, dont les poids sont initialisés à partir de ceux de HunFlair, et est complétée par un modèle CRF pour une segmentation et un étiquetage précis des séquences. Une couche de reprojection sophistiquée est intégrée entre les couches d'embedding et de traitement séquentiel pour harmoniser les disparités dimensionnelles, améliorant ainsi la sensibilité contextuelle sans compromettre les capacités structurelles. Les résultats obtenus montrent que notre modèle améliore significativement les performances de la REN biomédicale, établissant de nouvelles normes de précision pour l'identification des gènes et des protéines. En particulier, notre modèle a obtenu des scores de précision de 85,25% sur le dataset BC2GM, de 83,96% sur le dataset JNLPBA, de 93,35% sur le dataset BioNLPCG, et de 88,23% sur le dataset CRAFT. Les scores de rappel étaient également élevés, atteignant 84,76% sur BC2GM, 85,89% sur JNLPBA, 93,47% sur BioNLPCG, et 89,87% sur CRAFT. Enfin, les scores F1, qui équilibrent précision et rappel, étaient de 85,01% sur BC2GM, de 84,92% sur JNLPBA, de 93,41% sur BioNLPCG, et de 89,04% sur CRAFT. Après des tests rigoureux, les résultats indiquent des améliorations substantielles par rapport aux performances des modèles de pointe tels que HunFlair et BioBERT utilisés indépendamment. Ces avancées ouvrent la voie à des applications futures prometteuses de la REN dans le domaine biomédical, facilitant l'extraction et l'utilisation d'informations cruciales à partir de vastes corpus de textes spécialisés.

Mots clés : Reconnaissance d'Entités Nommées Biomédicales, BioBERT, HunFlair, BiLSTM-CRF, Transformeurs..

TRANSFORMER AND BiLSTM-CRF BASED APPROACH FOR GENE AND PROTEIN NAMED ENTITY RECOGNITION

ABSTRACT

Biomedical Named Entity Recognition (NER) is crucial for extracting essential information from specialized medical texts. This process helps structure biomedical data, thereby facilitating research and diagnostics. While transformer-based models like BioBERT are widely used in natural language processing (NLP), certain BiLSTM-CRF-based models like HunFlair exhibit superior performance in specific contexts. This thesis presents a novel pre-trained machine learning model architecture that combines the advantages of BioBERT and HunFlair. The embedding layer leverages BioBERT, known for its effective capture of biomedical context. The sequential processing layer relies on a BiLSTM model, initialized with HunFlair weights, and is complemented by a CRF model for precise sequence segmentation and labeling. A sophisticated reprojection layer is integrated between the embedding and sequential processing layers to harmonize dimensional disparities, enhancing contextual sensitivity without compromising structural capabilities. The results show that our model significantly improves the performance of biomedical NER, setting new standards of accuracy for gene and protein identification. Specifically, our model achieved precision scores of 85.25% on the BC2GM dataset, 83.96% on the JNLPBA dataset, 93.35% on the BioNLPCG dataset, and 88.23% on the CRAFT dataset. Recall scores were also high, reaching 84.76% on BC2GM, 85.89 on JNLPBA, 93.47% on BioNLPCG, and 89.87% on CRAFT. Finally, the F1 scores, which balance precision and recall, were 85.01% on BC2GM, 84.92% on JNLPBA, 93.41% on BioNLPCG, and 89.04% on CRAFT. After rigorous testing, the results indicate substantial improvements over the performance of state-of-the-art models such as HunFlair and BioBERT used independently. These advances pave the way for promising future applications of NER in the biomedical field, facilitating the extraction and utilization of crucial information from large corpora of specialized texts.

Keywords : Biomedical Named Entity Recognition, BioBERT, HunFlair, BiLSTM-CRF, Transformers.

INTRODUCTION GÉNÉRALE

SOMMAIRE

Contexte du travail	1
Problématique étudiée	2
Objectifs	3
Contribution	3
Organisation du manuscrit	5

Contexte du travail

Depuis le début de la pandémie de COVID-19, la communauté scientifique a publié des milliers d'articles de recherche sur le virus SARS-CoV-2, la maladie qu'il provoque, les mécanismes d'infection, les réponses immunitaires, et les potentiels traitements et vaccins. Cette explosion de données pose un défi immense pour les chercheurs qui doivent analyser *rapidement* et *efficacement* ces informations pour faire des progrès significatifs.

Les chercheurs doivent extraire des informations spécifiques sur les gènes et les protéines liés au SARS-CoV-2 et à la réponse immunitaire humaine à partir de cette masse de littérature scientifique. Par exemple, identifier les protéines virales impliquées dans l'infection, ou les gènes humains qui influencent la susceptibilité à la maladie et la gravité des symptômes. Manuellement, cela prendrait des semaines, voire des mois.

Avec la croissance exponentielle du nombre d'articles et de ressources biomédicales, la recherche et l'extraction d'informations précieuses sont devenues de véritables défis[17]. Les chercheurs doivent intégrer de multiples sources d'information et transformer les données textuelles non structurées en connaissances raffinées pour améliorer la productivité de la recherche[62][45]. Cependant, l'annotation manuelle et la génération de caractéristiques par des experts biomédi-

caux sont inefficaces, car elles nécessitent un processus complexe et une main-d'œuvre coûteuse[55]. Par conséquent, les techniques de traitement du langage naturel (NLP) efficaces et précises deviennent de plus en plus cruciales pour l'analyse des données informatiques. Des méthodes avancées d'exploration de texte sont nécessaires pour analyser automatiquement la littérature biomédicale et extraire des informations utiles des textes[18][70].

La Reconnaissance d'Entités Nommées (REN)[40], une des méthodes avancées d'exploration de texte, est une discipline essentielle du traitement automatique du langage naturel (TALN) appliquée aux textes médicaux spécialisés. Les avancées dans ce domaine sont cruciales pour l'extraction automatique d'informations pertinentes à partir de grandes quantités de données textuelles, facilitant ainsi les recherches biomédicales et les diagnostics cliniques[27]. La complexité et l'hétérogénéité de ces textes posent des défis uniques pour les techniques de REN. Par exemple, les entités biomédicales peuvent avoir des noms longs et composés, des abréviations multiples et des variations contextuelles significatives, comme c'est le cas pour les mentions de gènes et de protéines, ce qui rend leur identification automatique particulièrement difficile. Ces défis sont accentués par la nature spécialisée du vocabulaire biomédical et les variations de terminologie entre les différents sous-domaines médicaux[9][75].

Problématique étudiée

La problématique étudiée dans ce mémoire concerne les défis de la Reconnaissance d'Entités Nommées (REN) biomédicale, une tâche essentielle mais complexe du traitement automatique du langage naturel (TALN). En particulier, le focus est mis sur l'amélioration des performances de la REN de gènes et de protéines en exploitant les avantages des modèles existants.

La REN biomédicale est particulièrement complexe en raison de la diversité et de la spécialisation des textes. Les entités biomédicales, comme les noms de gènes et de protéines, présentent souvent des représentations complexes et des variations contextuelles importantes, ce qui complique leur identification automatique. Les modèles les plus efficaces existants pour cette tâche, tels que BioBERT et HunFlair, montrent des limitations lorsqu'il s'agit de capturer le contexte complexe et de fournir une segmentation et un étiquetage précis. Nous pouvons citer entre autres :

- Manque de précision dans l'étiquetage de séquences spécifiques (cas de BioBERT) : Bien qu'un modèle comme BioBERT soit performant pour capturer des contextes complexes, il peut manquer de précision lorsqu'il s'agit de

segmenter et d'étiqueter spécifiquement les noms de gènes et de protéines. Cela est dû à sa focalisation sur les embeddings contextuels au détriment des séquences spécifiques[5].

- Intégration limitée des contextes larges (cas de HunFlair) : Bien que performant pour l'étiquetage séquentiel, HunFlair, basé sur les BiLSTM-CRF, peut ne pas capturer aussi efficacement les contextes larges comme le fait BioBERT, basé sur les transformers, ce qui limite sa capacité à intégrer des informations contextuelles étendues nécessaires pour des tâches de REN complexes[67].

Objectifs

Au regard de notre problématique et des limites des modèles de pointe actuels, nous nous fixons comme objectif principal de proposer une nouvelle architecture de modèle qui offre des performances améliorées par rapport aux modèles de pointe actuels pour la reconnaissance d'entités nommées (REN) de gènes et de protéines. Plus spécifiquement, nous voulons :

- Concevoir et implémenter un modèle d'apprentissage automatique hybride qui intègre les points forts de BioBERT pour la capture du contexte biomédical et de HunFlair pour l'étiquetage séquentiel précis.
- Harmoniser les disparités dimensionnelles entre les embeddings fournis par BioBERT et ceux attendus par HunFlair afin d'améliorer la sensibilité contextuelle sans compromettre les capacités structurelles.
- Évaluer les performances du modèle proposé en effectuant des tests rigoureux pour comparer les performances du nouveau modèle par rapport aux modèles existants, en termes de précision, de rappel et de F1-score, sur divers corpus biomédicaux standardisés.

Contribution

La contribution principale de ce mémoire réside dans le développement d'une nouvelle architecture hybride pour la Reconnaissance d'Entités Nommées (REN) biomédicale, visant spécifiquement à améliorer la précision de l'identification des noms de gènes et de protéines. Cette architecture combine les avantages de deux modèles de pointe, BioBERT et HunFlair, pour surmonter leurs limitations indivi-

duelles et offrir une solution robuste et performante. Voici les deux aspects clés de cette contribution :

- Développement d’une Architecture Hybride Innovante qui intègre les forces de BioBERT et HunFlair.

En effet, BioBERT, basé sur une architecture de Transformers, est utilisé dans la couche d’embeddings pour générer des représentations vectorielles contextuelles riches grâce à son entraînement sur des textes biomédicaux, capturant ainsi des contextes complexes et spécifiques aux entités biomédicales. HunFlair est exploité dans la couche de traitement séquentiel pour initialiser les poids du modèle en charge. Ce modèle est basé sur une architecture BiLSTM-CRF, reconnue pour sa précision dans la segmentation et l’étiquetage séquentiel.

En combinant ces deux modèles, notre architecture hybride vise à tirer parti des embeddings contextuels profonds de BioBERT et de la segmentation précise de HunFlair.

- Harmonisation des Disparités Dimensionnelles.

Une des innovations techniques majeures de notre architecture est l’intégration d’une couche de reprojektion sophistiquée pour harmoniser les disparités dimensionnelles entre les représentations vectorielles fournies par la couche d’embeddings et celles attendues par la couche de traitement séquentiel, assurant ainsi une intégration fluide des informations contextuelles et séquentielles ainsi que l’optimisation de la précision, de la segmentation et de l’étiquetage des entités biomédicales.

Par ces deux aspects, notre architecture hybride vise à améliorer la précision et la sensibilité contextuelle des modèles de REN en biomédecine. En combinant les avantages des deux modèles, nous anticipons des améliorations notables dans la précision de la détection et de l’étiquetage des noms de gènes et de protéines, réduisant les erreurs de segmentation et les étiquetages incorrects d’une part, et la sensibilité contextuelle, permettant une meilleure capture des variations contextuelles importantes et des représentations complexes des entités biomédicales d’autre part. Nous avons conduit une évaluation rigoureuse de notre modèle hybride par rapport aux modèles existants. Cette évaluation inclut des tests comparatifs sur divers corpus biomédicaux standardisés pour mesurer les gains en termes de précision, de rappel et de F-score.

Organisation du manuscrit

Ce manuscrit est structuré en trois chapitres principaux, chacun visant à fournir une compréhension complète et progressive de notre travail de recherche. Voici un aperçu détaillé de l'organisation de ces chapitres :

Chapitre I : Généralités sur l'apprentissage automatique, le traitement du langage naturel et la reconnaissance d'entités nommées : Ce premier chapitre pose les bases théoriques et contextuelles nécessaires pour comprendre notre travail. Il aborde les concepts fondamentaux de l'apprentissage automatique (machine learning) et du traitement automatique du langage naturel (TALN), ainsi que les techniques spécifiques de la reconnaissance d'entités nommées (REN).

Chapitre II : État de l'art sur la reconnaissance d'entités nommées : Cadre biomédical : Ce chapitre est consacré à l'exploration des travaux antérieurs et des approches existantes dans le domaine de la REN biomédicale.

Chapitre III : Contribution à la reconnaissance d'entités nommées biomédicales : Gènes et protéines : Ce dernier chapitre présente notre contribution principale, à savoir le développement d'une nouvelle architecture hybride pour la REN biomédicale.

Conclusion générale : Dans cette partie, nous résumons notre travail et présentons quelques indications possibles pour la réalisation des travaux futurs.

I

CHAPITRE

GÉNÉRALITÉS SUR L'APPRENTISSAGE AUTOMATIQUE, LE TRAITEMENT DU LANGAGE NATUREL ET LA RECONNAISSANCE D'ENTITÉS NOMMÉES

SOMMAIRE

I.1 - Introduction	6
I.2 - Généralités sur l'apprentissage automatique	7
I.3 - Traitement automatique du langage naturel	25
I.4 - Reconnaissance d'entités nommées	27
I.5 - Synthèse	30

I.1. Introduction

L'essor des technologies numériques a transformé de nombreux domaines, notamment la biologie et la médecine, en apportant des outils puissants pour l'analyse des données textuelles. Parmi ces outils, l'apprentissage automatique s'est imposé comme une méthode essentielle pour extraire et interpréter de vastes quantités d'informations. Le traitement du langage naturel, une branche de l'apprentissage automatique, se concentre sur la compréhension et la génération du langage humain par les ordinateurs. Au sein du traitement du langage naturel, la reconnaissance des entités nommées (REN) joue un rôle crucial, en particulier dans le domaine biomédical, où l'extraction précise de noms de gènes, de protéines et d'autres entités biologiques est indispensable pour la recherche et le diagnostic. Ce premier

chapitre vise à fournir une vue d'ensemble des concepts fondamentaux de l'intelligence artificielle, tels que l'apprentissage automatique, le traitement du langage naturel, et la reconnaissance des entités nommées. Nous aborderons d'abord les bases de l'apprentissage automatique, y compris ses principaux paradigmes et techniques. Ensuite, nous explorerons le traitement du langage naturel et les approches couramment utilisées. Enfin, nous nous pencherons sur la reconnaissance d'entités nommées (REN) et les méthodes actuelles utilisées pour améliorer sa précision et son efficacité.




FIGURE 1 – Sous-domaines de l'intelligence artificielle [10]

I.2. Généralités sur l'apprentissage automatique

L'apprentissage automatique désigne le développement d'algorithmes et de modèles statistiques permettant aux systèmes informatiques d'apprendre et de prendre des décisions ou de faire des prédictions sans être explicitement programmés. Dans cette section, nous explorerons les concepts fondamentaux de l'apprentissage automatique, y compris l'apprentissage supervisé et non supervisé, l'ingénierie des caractéristiques, l'évaluation des modèles et le processus d'entraînement. Nous discuterons également des algorithmes couramment utilisés en apprentissage automatique, tels que les arbres de décision, les machines à vecteurs de support (SVM) et les réseaux neuronaux, ainsi que de leurs applications en traitement automatique du langage naturel (TALN) et en reconnaissance d'entités nommées (REN)[21]




FIGURE 2 – Apprentissage automatique[49]

I.2.1. Les méthodes d'analyse de l'apprentissage automatique

L'apprentissage automatique se divise généralement en quatre catégories principales : l'apprentissage supervisé, l'apprentissage non supervisé, l'apprentissage semi-supervisé et l'apprentissage par renforcement, chacune ayant ses propres caractéristiques et applications.

I.2.1.1. Apprentissage supervisé

L'apprentissage supervisé est une technique de Machine Learning qui nécessite que ses algorithmes s'entraînent sur un ensemble de données étiquetées, et l'objectif est de mapper de nouvelles données d'entrée à la valeur de sortie cible souhaitée[38]. Les problèmes dans ce type d'apprentissage sont généralement définis ou formatés de la manière suivante : à partir d'un ensemble n d'observations $\{\vec{x}_1, \vec{x}_2, \dots, \vec{x}_n\} = \{\vec{x}_i\}_{i=1, \dots, n}$ appartenant à l'ensemble X , et de leurs étiquettes $\{y_1, y_2, \dots, y_n\} = \{y_i\}_{i=1, \dots, n}$ décrites dans un ensemble Y , on cherche à estimer les dépendances entre l'ensemble X et Y afin d'en ressortir un modèle défini par une fonction $y_i = f(\vec{x}_i) + \epsilon_i$, où ϵ_i est un bruit aléatoire. Une fois entraîné avec les données étiquetées fournies, l'algorithme devient capable de prédire des étiquettes sur de nouvelles données non annotées.




FIGURE 3 – Apprentissage supervisé [1]

Ce mode d'apprentissage est principalement utilisé pour résoudre deux types de problèmes :

- Les problèmes de régression : ces problèmes consistent à prédire des valeurs continues ou réelles en fonction de variables d'entrée. Par exemple, prédire le prix d'une maison en fonction de ses caractéristiques telles que la surface, le nombre de chambres, etc.
- Les problèmes de classification : dans ce cas, l'objectif est de prédire une variable de sortie discrète, souvent désignée par des étiquettes de classe, à partir d'un ensemble de données d'entrée. Par exemple, classer les emails comme spam ou non-spam en fonction de leur contenu et de leurs caractéristiques.




FIGURE 4 – Régression Vs Classification[7]

Il existe plusieurs algorithmes d'apprentissage supervisé couramment utilisés pour résoudre divers problèmes dans ce domaine :

- **Régression linéaire** : Cet algorithme prédit la valeur d'une variable dépendante en se basant sur une variable indépendante. Par exemple, il peut être utilisé pour prédire les ventes annuelles d'un commercial en fonction de son niveau d'études ou de son expérience[51].
- **Régression Logistique** : Utilisée lorsque les variables dépendantes sont binaires. La machine à vecteur de support (SVM) est une autre méthode de régression utilisée lorsque les variables dépendantes sont plus complexes à classifier[64].
- **Arbres de Décision** : Cet algorithme génère des recommandations basées sur un ensemble de règles de décision fondées sur des données classifiées. Par exemple, il peut recommander sur quelle équipe de football parier en utilisant des données telles que l'âge des joueurs ou le pourcentage de victoires de l'équipe[22].
- **Forêt d'Arbres Aléatoires (Random Forest)** : Ce modèle est constitué d'un ensemble d'arbres de décision, chacun basé sur un échantillon de données tiré aléatoirement du dataset. Pour la classification, il rend son verdict par vote majoritaire des arbres de décision, et pour la régression, il utilise la moyenne des résultats des différents arbres[6].
- **Machine à Vecteur de Support (SVM)** : Utilisé pour des problèmes de classification ou de régression, cet algorithme transforme les données grâce à une technique appelée l'astuce du noyau et trouve une limite optimale entre les différentes classes possibles[43].
- **Réseau de Neurones** : Inspiré du fonctionnement des neurones humains, cet algorithme est capable de résoudre des problèmes complexes comme la reconnaissance de formes ou le traitement du langage naturel en ajustant les poids pendant la phase d'apprentissage[31].

I.2.1.2. Apprentissage non supervisé

L'apprentissage non supervisé est un type de machine learning qui traite des données sans étiquettes. L'objectif de ce type d'apprentissage est de découvrir la structure cachée des données, qui peut correspondre à une densité de probabilité. Pour formaliser les problèmes d'apprentissage non supervisé, on considère un ensemble de n observations, $\{\vec{x}_1, \vec{x}_2, \dots, \vec{x}_n\} = \{\vec{x}_i\}_{i=1, \dots, n}$ appartenant à l'ensemble X . L'objectif est de comprendre comment ces données sont organisées et d'en extraire des sous-ensembles homogènes. L'algorithme d'entraînement se concentre alors sur la détection des similarités et des distinctions au sein de ces données, afin de regrouper celles qui partagent des caractéristiques communes[39].




FIGURE 5 – Apprentissage non supervisé[7]

Plusieurs algorithmes sont couramment utilisés dans ce sous-domaine :

- **Clustering K-means** : Cet algorithme de clustering regroupe des points de données similaires en fonction de leurs caractéristiques ou similarités. Il aide à identifier les structures et les motifs sous-jacents dans les données. Le nombre de clusters souhaité est représenté par la lettre K[42].
- **Règles d'association** : Ces algorithmes découvrent des relations et des associations fréquentes entre les variables dans les ensembles de données[24].
- **Réduction de la dimensionnalité** : Cet algorithme réduit le nombre de variables ou d'entités dans un ensemble de données tout en conservant les informations importantes. L'analyse en composantes principales (ACP) est l'une des techniques les plus populaires pour la réduction de la dimensionnalité.

I.2.1.3. Apprentissage semi-supervisé

L'apprentissage semi-supervisé consiste à entraîner un modèle en utilisant un ensemble de données partiellement annotées, comprenant à la fois des données annotées et un grand nombre de données non annotées[46]. Autrement dit, certaines données possèdent des étiquettes, tandis qu'une majorité n'en ont pas. Parmi les observations $\{\vec{x}_1, \vec{x}_2, \dots, \vec{x}_n\}$, seulement un petit nombre ont une étiquette Y_i . L'objectif est de prédire les annotations des données non étiquetées en se basant sur la similarité avec les données étiquetées[56]. Ainsi, l'apprentissage semi-supervisé se situe entre l'apprentissage supervisé, qui utilise uniquement des données annotées, et l'apprentissage non supervisé, qui n'utilise que des données non annotées. La combinaison de ces deux types de données permet d'améliorer significativement les performances des modèles.




FIGURE 6 – Apprentissage semi-supervisé[66]

I.2.1.4. Apprentissage par renforcement

L'apprentissage par renforcement est une forme d'apprentissage automatique où un algorithme est entraîné à prendre des décisions en se basant sur des récompenses et des punitions. Plutôt que de fournir des paires d'entrées et de sorties, on décrit l'état actuel du système, on spécifie un objectif, on fournit une liste d'actions autorisées ainsi que leurs contraintes environnementales, et on laisse le modèle d'apprentissage automatique explorer le processus pour atteindre l'objectif par lui-même, en utilisant le principe d'essai et d'erreur pour maximiser une récompense[77].




FIGURE 7 – Apprentissage par renforcement[73]

L'apprentissage par renforcement, illustré par la figure 6, repose sur plusieurs concepts et métriques clés :

- **Agent** : Le système ou robot qui interagit avec et agit dans l'environnement.
- **Action** (a) : Une action spécifique choisie parmi un ensemble d'actions possibles.
- **État** (s) : La situation particulière dans laquelle se trouve l'agent à un moment donné.
- **Récompense** ($r(s, a)$) : Le gain, positif ou négatif, que l'agent reçoit en effectuant l'action a dans l'état s . L'objectif est de maximiser les récompenses totales obtenues par une politique donnée.

1.2.2. Domaine d'application : Apprentissage profond

L'apprentissage profond plus connu sous le nom *deep learning* en anglais est un sous-domaine de l'apprentissage automatique (*machine learning*) qui tente de reproduire le fonctionnement du cerveau humain. Les algorithmes de *deep learning* ont considérablement amélioré les performances dans divers domaines, notamment la vision par ordinateur, la reconnaissance vocale et la traduction automatique. Grâce à ces algorithmes, il est possible de résoudre des problèmes complexes dans de nombreux secteurs tels que la santé, le commerce, le transport, la finance et l'énergie, en exploitant de vastes quantités de données. L'apprentissage profond repose sur l'utilisation de réseaux de neurones artificiels, inspirés des neurones biologiques du cerveau humain. Ces réseaux sont conçus pour simuler les interactions neuronales à travers différentes couches, permettant ainsi un apprentissage progressif à partir de grandes quantités de données. Cette approche permet aux algorithmes d'apprentissage profond d'apprendre et de s'améliorer de manière

continue, en affinant leur compréhension et leur capacité à prédire ou classer des informations.

1.2.2.1. Neurones artificiels

Un neurone artificiel est la brique de base des réseaux de neurones artificiels (RNA), inspiré par le fonctionnement des neurones biologiques dans le cerveau humain. Il est conçu pour simuler la façon dont un neurone biologique reçoit, traite et transmet des informations.




FIGURE 8 – Neurone Artificiel[23]

Voici une explication détaillée du fonctionnement et des composants d'un neurone artificiel :

- **Entrées (Inputs)** : Un neurone artificiel reçoit plusieurs signaux d'entrée, chaque signal correspondant à une caractéristique ou une variable des données. Chaque entrée est associée à un poids (weight) qui détermine l'importance relative de cette entrée dans le calcul du neurone.
- **Poids (Weights)** : Les poids sont des paramètres ajustables qui multiplient les signaux d'entrée. Ils sont cruciaux car ils déterminent comment chaque entrée influence la sortie du neurone. Au début de l'apprentissage, les poids sont initialisés de manière aléatoire et sont ensuite ajustés pendant le processus de formation.
- **Somme pondérée (Weighted Sum)** : Le neurone calcule la somme pondérée des entrées, c'est-à-dire la somme des produits des entrées et des poids correspondants. Mathématiquement, cela peut être exprimé comme :

$z = \sum_{i=1}^n (w_i \cdot x_i) + b$, où w_i est le poids, x_i est l'entrée, et b est un biais.

- **Biais (Bias)** : Le biais est un paramètre additionnel du neurone qui permet de décaler la fonction d'activation. Il aide le modèle à mieux s'ajuster aux données en ajoutant une constante à la somme pondérée des entrées. Le biais est traité comme une entrée supplémentaire avec un poids toujours égal à 1.
- **Fonction d'activation (Activation Function)** : La fonction d'activation introduit de la non-linéarité dans le modèle. Elle prend la somme pondérée comme entrée et produit la sortie du neurone. Les fonctions d'activation couramment utilisées incluent :
 - Sigmoid (Sigmoid) : $\sigma(z) = \frac{1}{1+e^{-z}}$
 - Tanh (Tangente hyperbolique) : $\tanh(z) = \frac{e^z - e^{-z}}{e^z + e^{-z}}$
 - ReLU (Rectified Linear Unit) : $\text{ReLU}(z) = \max(0, z)$
 - Leaky ReLU : Comme la ReLU mais permet de petites valeurs négatives, $\text{Leaky ReLU}(z) = \max(\alpha z, z)$ avec α petit.

1.2.2.2. Réseaux de neurones artificiels

Les réseaux de neurones artificiels (RNA) sont des structures informatiques inspirées par le fonctionnement des neurones biologiques dans le cerveau humain. Ils constituent l'une des technologies de base de l'apprentissage profond. Ces réseaux sont utilisés pour modéliser des relations complexes entre des entrées et des sorties, identifier des motifs dans les données et faire des prédictions.




FIGURE 9 – Réseaux de Neurones artificiels[61]

Un réseau de neurones artificiels se compose de plusieurs couches de neurones, chacune jouant un rôle spécifique dans le traitement des informations :

- **Couche d'entrée (Input Layer)** : Cette couche reçoit les données brutes en entrée. Chaque neurone de cette couche représente une caractéristique ou une variable des données.
- **Couches cachées (Hidden Layers)** : Ces couches sont situées entre la couche d'entrée et la couche de sortie. Elles effectuent des transformations et des calculs complexes sur les données reçues de la couche précédente. Un réseau peut avoir une ou plusieurs couches cachées, et c'est là que se produisent la plupart des traitements.
- **Couche de sortie (Output Layer)** : Cette couche produit les résultats finaux du réseau, que ce soit une classification, une régression ou toute autre tâche de prédiction.

1.2.2.3. Réseaux de neurones récurrents

En 1986, David Rumelhart a introduit les réseaux de neurones récurrents (RNN), une classe de réseaux de neurones où les connexions entre les unités forment un cycle dirigé. Un des principaux avantages des RNN est leur capacité à exploiter les corrélations temporelles locales dans les données séquentielles, même en l'absence de corrélations globales. Cela les rend particulièrement utiles pour traiter des données séquentielles avec une structure temporelle variable. Les RNN se distinguent des réseaux de neurones traditionnels par leur architecture, qui utilise la sortie d'une étape précédente comme entrée pour l'étape actuelle. Contrairement aux réseaux de neurones classiques, où chaque entrée et sortie est indépendante des autres, les RNN sont particulièrement efficaces dans des contextes où la prédiction dépend des informations précédentes, comme la prédiction du mot suivant dans une phrase. La caractéristique la plus distinctive des RNN est leur état caché. Cet état caché permet au réseau de maintenir une mémoire interne, lui conférant ainsi la capacité de modéliser des comportements dynamiques temporels[15]. Les RNN utilisent les mêmes paramètres pour chaque entrée et chaque couche cachée, assurant ainsi des sorties fiables et cohérentes au fil du temps. Les RNN représentent une avancée significative dans le traitement des données séquentielles, grâce à leur capacité à se souvenir des informations précédentes et à utiliser ces informations pour influencer les prédictions futures.




FIGURE 10 – Réseaux de neurones récurrents[14]

I.2.2.4. Les réseaux LSTM et BiLSTM

Présentation des LSTM

Les réseaux de neurones récurrents (RNN) présentent un inconvénient majeur : leur mémoire à court terme se dégrade rapidement lorsqu'il s'agit de traiter des séquences longues. Pour pallier ce problème, les modèles LSTM (Long Short-Term Memory) ont été développés afin de prolonger la rétention des informations passées[35]. Les LSTM acheminent les données à travers différentes couches du réseau, similaires à celles d'un perceptron multicouche (MLP), pour effectuer des prédictions. Comme les RNN, les LSTM possèdent des connexions récurrentes, utilisant l'état des activations précédentes comme contexte pour générer une sortie. Cette architecture a été conçue suite à une analyse des erreurs dans les flux des RNN existants, qui a montré que les décalages temporels prolongés étaient difficiles à gérer. En effet, l'erreur rétro-propagée avait tendance à exploser ou à diminuer de manière exponentielle[28]. Une couche LSTM est constituée d'un ensemble de blocs de mémoire interconnectés de manière récurrente. Ces blocs peuvent être vus comme des versions différentiables des puces mémoire d'un ordinateur numérique. Chaque bloc contient une ou plusieurs cellules de mémoire, ainsi que trois unités multiplicatives : les portes d'entrée, de sortie et d'oubli. Ces portes permettent de réaliser des opérations continues d'écriture, de lecture et de réinitialisation sur les cellules. Le réseau interagit avec les cellules uniquement à travers ces portes, ce qui permet de gérer efficacement les informations à long terme.




FIGURE 11 – Long Short-Term Memory (LSTM)[47]

Les LSTM introduisent des cellules de mémoire qui peuvent conserver des informations sur de longues périodes. Chaque cellule LSTM comporte plusieurs composants clés :

- **Cellule de mémoire (Memory Cell)** : Stocke les informations sur des périodes prolongées, permettant au réseau de maintenir un état interne qui peut persister à travers de nombreuses étapes de temps.
- **Porte d'entrée (Input Gate)** : Contrôle la quantité d'informations nouvelles qui doivent être ajoutées à la cellule de mémoire. Fonctionne à l'aide d'une fonction sigmoïde qui détermine quels éléments des nouvelles entrées doivent être mis à jour.
- **Porte d'oubli (Forget Gate)** : Détermine la quantité d'informations de la cellule de mémoire précédente qui doit être conservée ou oubliée. Utilise également une fonction sigmoïde pour filtrer les informations.

- **Porte de sortie (Output Gate)** : Contrôle la sortie de la cellule de mémoire en fonction des informations internes de la cellule et des nouvelles entrées. La fonction sigmoïde régule quelles informations sont envoyées à l'état caché suivant.

Fonctionnement des LSTM

À chaque étape de temps, les LSTM effectuent les opérations suivantes :

- **Calcul de la porte d'oubli** :

$$f_t = \sigma(W_f \cdot [h_{t-1}, x_t] + b_f)$$

où f_t est le vecteur de la porte d'oubli, h_{t-1} est l'état caché précédent, x_t est l'entrée actuelle, W_f est le poids, et b_f est le biais.

- **Calcul de la porte d'entrée** :

$$i_t = \sigma(W_i \cdot [h_{t-1}, x_t] + b_i)$$

$$\tilde{C}_t = \tanh(W_C \cdot [h_{t-1}, x_t] + b_C)$$

où i_t est le vecteur de la porte d'entrée et $\tilde{C}_t$ est le vecteur des nouvelles informations candidates pour la cellule de mémoire.

- **Mise à jour de la cellule de mémoire** :

$$C_t = f_t \cdot C_{t-1} + i_t \cdot \tilde{C}_t$$

où C_t est le nouvel état de la cellule de mémoire.

- **Calcul de la porte de sortie** : $o_t = \sigma(W_o \cdot [h_{t-1}, x_t] + b_o)$

$$h_t = o_t \cdot \tanh(C_t)$$

où o_t est le vecteur de la porte de sortie et h_t est le nouvel état caché.

Bidirectional LSTM (BiLSTM)

Les LSTM bidirectionnels (BiLSTM) sont une extension des LSTM standard qui permettent au modèle de capturer des dépendances temporelles dans les deux directions, c'est-à-dire à la fois vers l'avant et vers l'arrière. Cela est particulièrement utile pour des tâches où le contexte passé et futur est important pour prendre des décisions précises.

Structure des BiLSTM

Un BiLSTM est constitué de deux couches LSTM :

- **LSTM avant (Forward LSTM)** : Traite la séquence des données dans l'ordre chronologique, de l'entrée initiale à la fin de la séquence.
- **LSTM arrière (Backward LSTM)** : Traite la séquence des données dans l'ordre inverse, de la fin de la séquence à l'entrée initiale.

Les sorties des deux LSTM sont ensuite combinées à chaque étape de temps pour former la sortie finale.

Fonctionnement des BiLSTM

À chaque étape de temps, les BiLSTM effectuent les opérations suivantes :

- **Propagation avant avec LSTM avant** : $\vec{h}_t = \text{LSTM}_{\text{forward}}(x_t)$, où $\vec{h}_t$ est l'état caché de la couche LSTM avant.
- **Propagation arrière avec LSTM arrière** : $\overleftarrow{h}_t = \text{LSTM}_{\text{backward}}(x_t)$, où $\overleftarrow{h}_t$ est l'état caché de la couche LSTM arrière.
- **Combinaison des états cachés** : $h_t = [\vec{h}_t, \overleftarrow{h}_t]$, où h_t est la concaténation des états cachés des LSTM avant et arrière.

I.2.2.5. Réseaux de neurones convolutifs

Les réseaux de neurones convolutifs (CNN) sont parmi les algorithmes les plus populaires et les plus utilisés dans le domaine de l'apprentissage profond [3][29]. Ils sont particulièrement efficaces pour la reconnaissance d'images grâce à la convolution, une technique mathématique largement employée dans le traitement d'images. La convolution agit comme un filtre en définissant une fenêtre qui se déplace sur l'image. Cette fenêtre commence en haut à gauche et se déplace horizontalement et verticalement selon un certain pas jusqu'à couvrir toute l'image. Les CNN sont utilisés dans divers domaines, y compris le traitement de la parole, la reconnaissance faciale et la vision par ordinateur[16]. Leur principal avantage par rapport aux méthodes précédentes est leur capacité à identifier automatiquement les caractéristiques pertinentes sans intervention humaine[19]. Les CNN se composent de deux blocs principaux.

Le premier bloc agit comme un extracteur de caractéristiques. Il utilise des opérations de convolution pour détecter des motifs dans l'image. La première couche applique plusieurs filtres de convolution pour générer des "feature maps". Ces cartes sont ensuite normalisées et redimensionnées à l'aide de fonctions d'activation. Ce processus se répète en appliquant de nouveaux filtres aux "feature maps" existantes, générant ainsi de nouvelles cartes à normaliser et redimensionner. Ce

cycle peut être répété plusieurs fois. Les valeurs finales des "feature maps" sont ensuite regroupées en un vecteur, qui représente la sortie du premier bloc et sert d'entrée au deuxième bloc.

Le deuxième bloc, contrairement à un CNN typique, se retrouve à la fin de tous les réseaux de neurones utilisés pour la classification. Le vecteur d'entrée subit des transformations à l'aide de combinaisons linéaires et de fonctions d'activation, générant un nouveau vecteur en sortie. Ce vecteur final contient un élément pour chaque classe : l'élément i représente la probabilité que l'image appartienne à la classe i . Chaque élément est compris entre 0 et 1, et la somme de tous les éléments est égale à 1. Ces probabilités sont calculées par la dernière couche du bloc, qui utilise une fonction logistique pour la classification binaire ou une fonction softmax pour la classification multiclass.




FIGURE 12 – Architecture d'un réseau de neurone convolutif[30]

I.2.2.6. Les transformers

Les transformers plus connu sous le nom de transformers en anglais, sont une architecture de réseau neuronal introduite par Vaswani et al. en 2017 dans le document "Attention is All You Need"[67]. Cette architecture a révolutionné le traitement du langage naturel (NLP) et a atteint des performances de pointe dans les tâches du NLP. Le modèle Transformer repose fondamentalement sur le concept d'attention, qui permet au modèle de se concentrer sur différentes parties de la séquence d'entrée pendant le traitement. Il se compose d'une structure encodeur-

décodeur, où l'encodeur et le décodeur sont constitués de plusieurs couches d'auto-attention et de réseaux neuronaux feed-forward.

Les mécanismes d'auto-attention permettent au modèle de capturer les relations entre différentes positions dans la séquence d'entrée, facilitant ainsi la parallélisation et la capture efficace des dépendances à long terme. Le mécanisme d'attention calcule des représentations pondérées de chaque position de la séquence d'entrée en fonction de sa pertinence par rapport aux autres positions, produisant ainsi des représentations contextuelles. L'encodeur traite la séquence d'entrée et génère un ensemble de représentations, qui sont ensuite utilisées par le décodeur pour générer la séquence de sortie. Le décodeur utilise également un mécanisme d'attention supplémentaire, appelé auto-attention masquée, pour éviter de prendre en compte les positions futures lors de la génération.

Les auteurs ont évalué le modèle Transformer sur diverses tâches de traduction automatique et ont atteint des performances de pointe sur les benchmarks de traduction anglais-allemand et anglais-français du WMT 2014. Le modèle a démontré une qualité de traduction supérieure tout en maintenant des temps d'entraînement rapides par rapport aux approches traditionnelles basées sur les réseaux neuronaux récurrents. L'article a également mis en évidence les avantages du modèle Transformer, tels que sa capacité à gérer les dépendances à long terme, à paralléliser les calculs et à capturer des structures hiérarchiques dans les entrées. Il a suscité un intérêt considérable dans la communauté de recherche et a inspiré des avancées ultérieures dans les tâches de traitement du langage naturel au-delà de la traduction automatique, y compris la synthèse de texte, les réponses aux questions, la reconnaissance des entités nommées [57] et la compréhension du langage. En résumé, "Attention Is All You Need" a démontré la puissance des mécanismes d'attention et a jeté les bases de l'adoption généralisée du modèle Transformer dans diverses applications de traitement du langage naturel.

Architecture des transformers




FIGURE 13 – Architecture d'un transformer[67]

Encodeur

L'encodeur est composé de N couches identiques, chacune comprenant deux sous-couches : multi-head attention et réseau feed-forward. Les représentations vectorielles (embeddings) d'entrée passent à travers ces sous-couches, et l'information est raffinée à chaque étape.

Décodeur

Le décodeur est similaire à l'encodeur mais avec une sous-couche d'attention supplémentaire pour intégrer les sorties de l'encodeur. Cela permet au décodeur de générer des séquences de sortie en prenant en compte les informations encodées.

Mécanisme d'attention

Le cœur des Transformers est le mécanisme d'attention (Attention Scaled Dot-Product) qui permet au modèle de se concentrer sur différentes parties de l'entrée de manière flexible. La formule de l'attention est donnée par :

$$\text{Attention}(Q, K, V) = \text{softmax} \left(\frac{QK^T}{\sqrt{d_k}} \right) V$$

où Q est la matrice de requête, K est la matrice de clé, V est la matrice de valeur, et d_k est la dimension des clés.

Attention Multi-Têtes

Pour permettre au modèle de se concentrer sur différentes parties de l'entrée simultanément, les Transformers utilisent plusieurs "têtes" d'attention (Multi-Head Attention) :

$$\text{MultiHead}(Q, K, V) = \text{Concat}(\text{head}_1, \text{head}_2, \dots, \text{head}_h)W^O$$

où chaque tête est une attention indépendante :

$$\text{head}_i = \text{Attention}(QW_i^Q, KW_i^K, VW_i^V)$$

Codage positionnel

Comme les Transformers ne possèdent pas d'invariance séquentielle comme les RNN, ils utilisent des codages positionnels pour injecter des informations de position dans les embeddings d'entrée :

$$\text{PE}_{(\text{pos}, 2i)} = \sin\left(\frac{\text{pos}}{10000^{2i/d_{\text{model}}}}\right)$$

$$\text{PE}_{(\text{pos}, 2i+1)} = \cos\left(\frac{\text{pos}}{10000^{2i/d_{\text{model}}}}\right)$$

Couches de Propagation Avant

Chaque couche d'attention est suivie par une couche de Propagation Avant (feed-forward) pleinement connectée, appliquée de manière identique à chaque position :

$$\text{FFN}(x) = \max(0, xW_1 + b_1)W_2 + b_2$$

Normalisation et régularisation par abandon

Les Transformers utilisent des couches de normalisation et de régularisation par abandon (dropout) pour stabiliser et régulariser le réseau. il est utilisée dans les réseaux de neurones pour prévenir le surapprentissage (overfitting).

$$\text{Norm}(x + \text{Sublayer}(x))$$

I.3. Traitement automatique du langage naturel

I.3.1. Définition du TALN

Le traitement automatique du langage naturel (TALN) plus connu sous le nom de natural language processing (NLP) en anglais est une branche de l'intelligence artificielle (IA) qui se concentre sur l'interaction entre les ordinateurs et le langage humain. Il implique le développement et l'application d'algorithmes et de modèles pour traiter, comprendre et générer le langage naturel.

I.3.2. Composent clés du TALN

Le TALN couvre un large éventail de tâches et de techniques qui permettent aux ordinateurs de comprendre et de travailler avec le langage humain de manière significative. Voici quelques-uns des principaux domaines du TALN :

- **Tokenisation** : Division du texte en mots individuels, phrases ou symboles appelés tokens. C'est souvent la première étape dans les tâches de NLP.
- **Lemmatisation et stemming** : Réduction des mots à leur forme de base ou racine. La lemmatisation vise à convertir les mots à leur forme de dictionnaire ou de base, tandis que le stemming consiste à supprimer les préfixes ou suffixes pour obtenir la forme racine.
- **Tagging morphosyntaxique (POS)** : Attribution de tags grammaticaux (tels que noms, verbes, adjectifs) aux mots d'une phrase pour comprendre leur rôle syntaxique.
- **Reconnaissance des entités nommées** : Identification et classification des entités nommées dans le texte, comme les noms de personnes, d'organisations, de lieux, de dates, et plus encore.
- **Analyse des sentiments** : Détermination du sentiment ou de l'émotion exprimé dans un texte, tel que positif, négatif ou neutre.
- **Classification de texte** : Catégorisation du texte en catégories ou classes prédéfinies. Cela peut être utilisé pour des tâches telles que la détection de spam, la classification des sentiments, la classification des sujets, et plus en-

core.

- **Traduction automatique** : Traduction de texte d'une langue à une autre en utilisant des modèles computationnels.
- **Réponse aux questions** : Construction de systèmes capables de comprendre des questions posées en langage naturel et de fournir des réponses précises basées sur les connaissances disponibles.
- **Génération de texte** : Création de textes cohérents et significatifs basés sur des invites ou des conditions données.

I.3.3. Outils et technologies du TALN.

- **NLTK** (Natural Language Toolkit) : Une bibliothèque complète pour le traitement du langage naturel en Python.
- **spaCy** : Une bibliothèque NLP rapide et moderne en Python, avec des modèles pré-entraînés pour plusieurs langues.
- **Stanford NLP** : Une suite d'outils NLP développée par l'Université de Stanford.
- **OpenNLP** : Une bibliothèque de machine learning pour le traitement du langage naturel.
- **Gensim** : Une bibliothèque pour la modélisation de sujets et la similarité de documents.
- **BERT** (Bidirectional Encoder Representations from Transformers) : Un modèle de langage pré-entraîné développé par Google.
- **GPT** (Generative Pre-trained Transformer) : Une série de modèles de langage pré-entraînés développés par OpenAI, célèbres pour leurs capacités de génération de texte.

I.3.4. Applications du TALN

- **Chatbots et assistants virtuels** : Comme ChatGPT, Siri, Alexa, et Google Assistant, qui utilisent le NLP pour comprendre et répondre aux requêtes des utilisateurs.
- **Analyse des sentiments** : Utilisée par les entreprises pour surveiller les avis des clients sur les réseaux sociaux et autres plateformes.
- **Traduction automatique** : Services comme Google Translate, qui utilisent des modèles NLP pour traduire des textes entre différentes langues.
- **Résumé automatique de texte** : Techniques pour extraire les informations clés d'un document et en générer un résumé.
- **Filtrage anti-spam** : Utilisé par les fournisseurs de services de messagerie pour détecter et filtrer les emails indésirables.
- **Analyse de texte pour la détection de fraudes** : Utilisée dans les secteurs bancaires et financiers pour identifier les comportements suspects.
- **Recherche d'information et moteurs de recherche** : Amélioration des résultats de recherche en comprenant mieux les requêtes des utilisateurs.
- **Diagnostics médicaux** : Utilisation du NLP pour analyser des notes cliniques et autres documents médicaux pour aider au diagnostic et au traitement.

I.4. Reconnaissance d'entités nommées

I.4.1. Définition et objectifs

Définition

La reconnaissance d'entités nommées (REN) est une sous-discipline du traitement du langage naturel (NLP) qui consiste à localiser et classer des entités nommées mentionnées dans le texte en catégories prédéfinies telles que les noms de

personnes, d'organisations, de lieux, de dates, de quantités monétaires, et autres. Par exemple, dans la phrase "Apple a annoncé de nouveaux produits lors de l'événement à San Francisco", les entités nommées seraient "Apple" (organisation) et "San Francisco" (lieu).

Objectifs

- **Extraction d'informations** : Identifier et extraire des informations importantes et structurées à partir de documents non structurés.
- **Amélioration de la recherche d'information** : Améliorer la précision des moteurs de recherche en identifiant les entités nommées dans les requêtes et les documents.
- **Annotation de données** : Aider à l'annotation automatique de grands volumes de données pour des applications d'apprentissage automatique.
- **Analyse de texte** : Permettre l'analyse des mentions d'entités dans des corpus de texte pour des applications telles que l'analyse de sentiments, la surveillance des médias sociaux, et l'extraction de connaissances.

I.4.2. Méthodologie de la REN

La méthodologie de la reconnaissance d'entités nommées implique plusieurs étapes et techniques :

- **Prétraitement des données** : Cela comprend la tokenisation, la suppression des stop-words, la lemmatisation et le stemming pour préparer le texte brut.
- **Annotation des données** : Les données textuelles doivent être annotées avec les entités nommées appropriées pour créer un jeu de données d'entraînement.
- **Modèles de machine learning** :
 - Approches basées sur des règles : Utilisation de règles manuellement définies pour identifier les entités nommées. Ces règles sont souvent basées sur des motifs de texte réguliers et des lexiques.

- **Modèles statistiques** : Utilisation de modèles probabilistes comme les modèles de Markov cachés (HMM) et les Conditional Random Fields (CRF) pour identifier les entités.
- **Approches d'apprentissage profond** : Utilisation de réseaux de neurones, notamment les réseaux de neurones récurrents (RNN) et les modèles d'attention comme BERT et GPT, qui ont montré des performances exceptionnelles dans les tâches de REN.
- **Évaluation des modèles** : Les modèles de REN sont évalués à l'aide de métriques comme la précision, le rappel et la mesure F1 pour déterminer leur efficacité.
- **Post-traitement** : Les résultats de REN peuvent nécessiter des étapes de post-traitement pour corriger les erreurs et affiner les résultats.

I.4.3. Défis spécifiques de la REN

- **Ambiguïté et polysemie** : Une même entité peut avoir plusieurs significations selon le contexte. Par exemple, "Apple" peut se référer à la société technologique ou au fruit.
- **Variabilité des noms** : Les entités nommées peuvent être mentionnées de différentes manières dans le texte. Par exemple, "New York City", "NYC", et "New York" doivent toutes être reconnues comme la même entité.
- **Langues et domaines spécifiques** : Les modèles de REN doivent être capables de s'adapter à différentes langues et à des domaines spécifiques, ce qui nécessite souvent des jeux de données annotés de manière exhaustive pour chaque cas.
- **Rareté des données** : Il peut être difficile de trouver suffisamment de données annotées de haute qualité pour entraîner des modèles performants, surtout pour des langues moins courantes ou des domaines spécialisés.
- **Évolution des entités** : Les entités nommées évoluent au fil du temps, avec de nouvelles entités apparaissant et d'autres disparaissant, ce qui nécessite une mise à jour régulière des modèles et des données.

I.5. Synthèse

Le premier chapitre de ce mémoire offre une vue d'ensemble sur l'apprentissage automatique (ML en anglais), le traitement automatique du langage naturel (TALN) et la reconnaissance d'entités nommées (REN). Après une introduction générale, le chapitre présente les bases du ML, en détaillant les différentes méthodes d'apprentissage, à savoir l'apprentissage supervisé, non supervisé, semi-supervisé et par renforcement. Ensuite, il explore un domaine d'application qui est l'apprentissage profond, en abordant les neurones artificiels, les réseaux de neurones artificiels, les réseaux de neurones récurrents, les réseaux LSTM et BiLSTM, les réseaux de neurones convolutifs et les transformers. La section sur le NLP décrit son évolution, ses composants clés, les outils et technologies utilisés, ainsi que ses applications. Enfin, le chapitre se concentre sur la REN, en fournissant une définition, en expliquant sa méthodologie et en discutant des défis spécifiques associés à cette tâche. Ce chapitre établit les fondations théoriques nécessaires pour comprendre les techniques et les concepts avancés qui seront explorés dans les chapitres suivants de ce mémoire.

II

CHAPITRE

ÉTAT DE L'ART SUR LA RECONNAISSANCE D'ENTITÉS NOMMÉES : CADRE BIOMÉDICAL

SOMMAIRE

II.1 - Introduction	31
II.2 - Généralité sur la reconnaissance d'entités nommées biomédicale . . .	32
II.3 - Approches de reconnaissance d'entités nommées biomédicale	35
II.4 - Analyse des résultats obtenus par les approches de REN biomédicale :	
Gènes et protéines	44
II.5 - Synthèse	46

II.1. Introduction

La reconnaissance d'entités nommées (REN) est une tâche clé dans le traitement automatique du langage naturel (TALN), visant à identifier et classer les entités nommées dans les textes[62]. Dans le domaine biomédical, la REN est cruciale pour extraire des entités telles que les noms de gènes, de protéines, de maladies et de médicaments à partir de la littérature scientifique et des bases de données médicales[65]. Cependant, la REN biomédicale présente des défis uniques en raison de la complexité et de la spécificité des textes biomédicaux, riches en jargon technique, en ambiguïtés et en synonymes. L'évolution rapide des connaissances scientifiques entraîne l'apparition constante de nouveaux termes et de termes rares, ajoutant une couche de complexité supplémentaire. La longueur et la complexité des termes biomédicaux nécessitent des approches sophistiquées pour une extraction précise et efficace. Ce chapitre propose une revue de l'état de l'art sur la REN

biomédicale. Nous aborderons les généralités de la REN biomédicale, ses spécificités, les types d'entités nommées et les défis associés. Ensuite, nous explorerons les approches basées sur les champs aléatoires conditionnels (Conditional Random Fields, CRFs), les modèles de Transformers et les modèles BiLSTM+CRF, qui ont récemment montré des performances prometteuses. Enfin, nous analyserons les résultats de ces approches dans le contexte de la reconnaissance des entités liées aux gènes et aux protéines, avant de conclure par une synthèse des principaux enseignements.

II.2. Généralité sur la reconnaissance d'entités nommées biomédicale

II.2.1. Définition et spécificités de la REN biomédicale

II.2.1.1. Définition de la REN biomédicale

La reconnaissance d'entités nommées biomédicale (REN biomédicale) est une sous-discipline de la REN, spécifiquement axée sur l'identification et la classification des entités dans les textes biomédicaux. Ces entités comprennent les noms de gènes, de protéines, de maladies, de médicaments et d'autres concepts pertinents pour la biologie et la médecine. La REN et l'apprentissage profond en général, dans le domaine médical, vont au-delà de la recherche. Ils contribuent désormais à améliorer le service aux patients, à détecter la propagation précoce des maladies et à créer de nouvelles perspectives sur les mécanismes des maladies pour fournir de meilleures méthodes de traitement[20][26][48].

II.2.1.2. Spécificités du domaine biomédical

Le domaine biomédical se caractérise par une terminologie complexe et évolutive. Les textes biomédicaux sont souvent remplis de jargon technique, d'acronymes, et de termes spécialisés qui peuvent être ambigus ou synonymes. En outre, l'émergence rapide de nouvelles découvertes scientifiques entraîne l'apparition constante de nouveaux termes et néologismes, rendant la REN particulièrement difficile dans ce domaine[78].

II.2.2. Types d'entités nommées biomédicale

II.2.2.1. Catégories principales d'entités

Les principales catégories d'entités nommées biomédical incluent :

- Les gènes et les protéines
- Les maladies et conditions médicales
- Les médicaments et traitements
- Les procédures médicales
- Les organismes biologiques

II.2.2.2. Exemples et annotations

Exemples d'entités nommées dans des textes biomédicaux :

- **Gènes** : BRCA1, TP53
- **Maladies** : cancer du sein, diabète de type 2
- **Médicaments** : ibuprofène, insuline

Les annotations de ces entités dans les corpus biomédicaux sont essentielles pour entraîner et évaluer les modèles de NER. Ces annotations permettent de créer des ensembles de données structurés qui facilitent la reconnaissance automatique des entités.

Texte	Label
Comparison with alkaline phosphatases and 5-nucleotidase	[Span[2 :4] : "alkaline phosphatases"/'Gene' (1.0), 'Span[5 :6] : "5-nucleotidase"/'Gene' (1.0)]
SGPT, SGOT, and alkaline phosphatase concentrations were essentially normal in all subjects.	[Span[0 :1] : "SGPT"/'Gene' (1.0), 'Span[2 :3] : "SGOT"/'Gene' (1.0), 'Span[5 :7] : "alkaline phosphatase"/'Gene' (1.0)]

TABLE I – Extrait du Dataset BC2GM avec annotation de Gène[54].

II.2.3. Défis de la REN biomédicale

II.2.3.1. Ambiguïté et synonymie

L'ambiguïté et la synonymie sont des défis majeurs en REN biomédicale. Un même terme peut avoir plusieurs significations selon le contexte, et différents termes peuvent se référer à la même entité. Par exemple, le terme "Jaguar" peut se référer à un animal ou à une marque de voiture.

II.2.3.2. Néologismes et termes rares

Les néologismes (mot ou une expression nouvelle qui apparaît dans une langue) et les termes rares représentent un autre défi. La rapidité des avancées scientifiques entraîne l'apparition constante de nouveaux termes qui ne sont pas encore réperto-

riés dans les bases de données existantes, rendant leur identification difficile pour les modèles de REN.

II.2.3.3. Longueur et complexité des termes

La longueur et la complexité des termes biomédicaux peuvent également poser des problèmes. Les termes composés de plusieurs mots ou les termes techniques complexes nécessitent des techniques de segmentation et de reconnaissance avancées pour être correctement identifiés.

II.2.4. Ressources et outils pour la REN biomédicale

II.2.4.1. Corpus et bases de données annotées

Les corpus et bases de données annotées sont des ressources indispensables pour la NER biomédicale. Parmi les corpus les plus utilisés, on peut citer :

- BioCreative[54]
- JNLPBA[12]
- CRAFT[11]
- BioNLPCG[44] ...

Ces corpus fournissent des données annotées de haute qualité pour entraîner et évaluer les modèles de REN biomédicale.

II.2.4.2. Outils et bibliothèques

Plusieurs outils et bibliothèques ont été développés pour la REN biomédicale, parmi lesquels :

- **Spacy** : Bibliothèque python pour l'extraction des caractéristiques syntaxiques
- **Flair** : Bibliothèque Python specialiser dans la REN Biomedical[2]
- **BioBERT** : un modèle de langage pré-entraîné pour l'extraction d'informations biomédicales[34]
- **HunFlair** : un model Pré-entraîné pour la REN biomédicale basée sur des modèles de pointe[71]

Ces outils facilitent l'application de la REN biomédicale en offrant des solutions prêtes à l'emploi et en permettant une intégration facile dans les flux de travail de traitement des données biomédicales.

II.3. Approches de reconnaissance d'entités nommées biomédicale

II.3.1. Approches basées sur l'apprentissage automatique : Les champs aléatoires conditionnels

II.3.1.1. Généralité sur les champs aléatoires conditionnels

Les champs aléatoires conditionnels plus connu sous le nom de conditional random fields (CRFs) en anglais, sont des modèles probabilistes utilisés principalement pour le traitement de données séquentielles et structurées. Ils sont particulièrement utiles dans des domaines comme la reconnaissance d'entités nommées (REN), l'étiquetage de séquences en traitement automatique du langage naturel (TALN) et la vision par ordinateur. Les CRFs ont été introduits par John Lafferty, Andrew McCallum et Fernando Pereira en 2001 pour surmonter certaines limitations des modèles de Markov cachés connu en anglais sous le nom de Hidden Markov Models (HMMs) et des classificateurs de maximum d'entropie [32].

Définition et principes de base

Les CRFs sont définis comme des modèles graphiques discriminatifs utilisés pour prédire des étiquettes de séquences. Contrairement aux HMMs, qui sont des modèles génératifs et modélisent la distribution conjointe des observations et des étiquettes, les CRFs modélisent la distribution conditionnelle des étiquettes données les observations. Cela permet aux CRFs d'incorporer une grande variété de caractéristiques dépendantes des observations sans faire d'hypothèses indépendantes simplificatrices [59].

Mathématiquement, un CRF est un graphe non orienté où chaque nœud représente une variable aléatoire (étiquette) et chaque arête encode les dépendances entre les variables. La probabilité d'une séquence d'étiquettes y étant donnée une séquence d'observations x est définie par une fonction exponentielle normalisée :

$$P(y|x) = \frac{1}{Z(x)} \exp \left(\sum_k \lambda_k f_k(y, x) \right)$$

où $f_k(y, x)$ sont les fonctions de caractéristiques, λ_k sont les poids associés, et $Z(x)$ est une fonction de partition qui assure que la somme des probabilités est égale à 1 [32].

Applications et avantages

Les champs aléatoires conditionnel sont largement utilisés dans le TALN pour des tâches telles que la REN, l'étiquetage de parties du discours (POS tagging), et le chunking syntaxique (est une technique utilisée pour diviser un texte en segments ou "chunks" qui sont des unités grammaticalement cohérentes. Ces segments peuvent inclure des groupes nominaux, verbaux, adjectivaux, etc.). Par exemple, dans la REN, les CRFs peuvent utiliser des caractéristiques telles que la présence de majuscules, des préfixes/suffixes, et des informations contextuelles pour identifier les entités nommées dans un texte [37].

L'un des principaux avantages des CRFs par rapport aux HMMs est leur capacité à modéliser des dépendances complexes entre les observations sans nécessiter de suppositions indépendantes. Cela permet aux CRFs d'incorporer des caractéristiques riches et interdépendantes des données d'entrée, améliorant ainsi la précision des prédictions [60].

Limitations et défis

Cependant, les CRFs ne sont pas sans défis. L'apprentissage des paramètres des CRFs implique l'optimisation d'une fonction de vraisemblance conditionnelle, qui peut être computationnellement coûteuse, en particulier pour des séquences longues ou des jeux de données volumineux [53]. De plus, le choix et la conception des fonctions de caractéristiques sont cruciaux pour les performances du modèle et nécessitent souvent une expertise approfondie du domaine.

Avancées Récentes et Extensions

Des variantes et extensions des CRFs ont été développées pour surmonter certaines de leurs limitations et étendre leur applicabilité. Par exemple, les CRFs linéaires en chaîne ont été généralisés aux CRFs de segment (Segmental CRFs) pour modéliser des segments de séquences, et les CRFs conditionnellement indépendants (Hierarchical CRFs) ont été introduits pour traiter des structures hiérarchiques [50].

Des recherches récentes ont également exploré l'intégration des CRFs avec des réseaux de neurones pour combiner les capacités d'apprentissage automatique des deux paradigmes. Les CRFs neuronaux (Neural CRFs) utilisent des réseaux de neurones pour extraire des caractéristiques riches des données d'entrée, qui sont

ensuite utilisées par les CRFs pour la prédiction des étiquettes. Cette approche a montré des performances prometteuses dans diverses applications du TALN [36].

Les champs aléatoires conditionnels représentent un outil puissant pour le traitement des données séquentielles et structurées, avec des applications étendues et des performances améliorées par rapport aux modèles génératifs traditionnels. Malgré leurs défis, les avancées récentes et les extensions continuent de faire des CRFs un domaine de recherche actif et pertinent.

II.3.1.2. Reconnaissance d'entités nommées biomédicales utilisant des champs aléatoires conditionnels et des ensembles de caractéristiques riches[52]

Problème et aspects traités

Ce travail de recherche traite le problème de la reconnaissance d'entités nommées (REN) dans le domaine biomédical, qui consiste à identifier et classer des mentions de gènes, de protéines, et d'autres entités biologiques dans des textes scientifiques. Avec l'augmentation de la littérature biomédicale, il devient crucial de disposer d'outils efficaces de traitement du langage naturel pour organiser, curer, et récupérer ces informations. Le travail se concentre sur la reconnaissance simultanée des classes d'entités telles que PROTEIN, DNA, RNA, CELL-LINE, et CELL-TYPE dans les résumés biomédicaux, une tâche essentielle pour de nombreuses applications de gestion de l'information [52].

Approche et solution apportée

L'approche proposée utilise les champs aléatoires conditionnels (CRFs) avec un ensemble riche de caractéristiques pour l'étiquetage de séquences. Les CRFs, des modèles graphiques statistiques, sont bien adaptés à l'analyse de séquences et permettent de modéliser des dépendances complexes entre les observations sans faire d'hypothèses d'indépendance simplificatrices. Le modèle de CRF utilise des fonctions de caractéristiques orthographiques et sémantiques pour capturer les propriétés pertinentes des données d'entrée. Les caractéristiques orthographiques incluent la capitalisation, les suffixes/préfixes, et les classes de mots généralisées, tandis que les caractéristiques sémantiques utilisent des lexiques construits manuellement et automatiquement pour intégrer des connaissances de domaine [52].

Résultats et gains obtenus

Les expériences menées sur des ensembles de données fournis par la tâche partagée BioNLP/NLPBA 2004 montrent que le modèle de CRF utilisant uniquement

des caractéristiques orthographiques atteint une mesure F1 globale de 69.8. En incluant les lexiques sémantiques, la performance globale atteint une mesure F1 de 69.5, avec une amélioration notable de la précision et du rappel pour les entités RNA et CELL-LINE, qui sont des classes moins fréquentes dans les données d'entraînement. Bien que l'ajout de lexiques sémantiques n'améliore pas la performance globale de manière significative, ces résultats montrent le potentiel des CRFs à traiter des tâches de NER dans des contextes de données biomédicales complexes [52].

II.3.2. Approches basées sur l'apprentissage profond : Les transformers

II.3.2.1. BERT : Pré-entraînement de transformeurs bidirectionnels profonds pour la compréhension du langage [13]

Problème et aspects traités

Le modèle "BERT : Pre-training of Deep Bidirectional Transformers for Language Understanding" introduit un modèle de représentation du langage appelé BERT (Bidirectional Encoder Representations from Transformers). Les auteurs identifient que les modèles de langage précédents, tels que ceux de Peters et al. (2018) et Radford et al. (2018), sont limités par leur nature unidirectionnelle, ce qui restreint leur capacité à capturer des contextes bidirectionnels dans le traitement automatique du langage naturel (TALN). Ce problème est particulièrement crucial pour les tâches de compréhension de texte où le contexte des deux côtés d'un mot est essentiel pour une interprétation précise [13].

Approche et solution apportée

BERT est conçu pour préentraîner des représentations profondes bidirectionnelles à partir de textes non étiquetés en conditionnant conjointement sur les contextes gauche et droit dans toutes les couches du modèle. Pour surmonter les limitations des modèles unidirectionnels, BERT utilise un objectif de préentraînement appelé "masked language model" (MLM), inspiré par la tâche Cloze, où une proportion de mots dans la phrase d'entrée est masquée de manière aléatoire, et le modèle doit prédire ces mots masqués en se basant sur le contexte environnant. En outre, BERT incorpore une tâche de "next sentence prediction" (NSP) pour améliorer la compréhension des relations entre les paires de phrases [13].

En termes simples, BERT est une architecture qui peut être utilisée pour de nombreuses tâches en aval telles que les réponses aux questions, la classification, la reconnaissance d'entités nommées (REN), etc. On peut considérer BERT pré-entraîné comme une boîte noire qui nous fournit des vecteurs de dimension $H = 768$ pour chaque jeton (mot) d'entrée dans une séquence. Ici, la séquence peut être une seule phrase ou une paire de phrases séparées par le séparateur [SEP] et commençant par un jeton [CLS].




FIGURE 14 – Une vue très générale de BERT[68]

Résultats et gains obtenus

Les résultats expérimentaux montrent que BERT obtient de nouveaux résultats de pointe sur onze tâches de traitement du langage naturel, incluant un score GLUE de 80,5 % (amélioration absolue de 7,7 points de pourcentage), une précision MultiNLI de 86,7 % (amélioration absolue de 4,6 points de pourcentage), un score F1 sur SQuAD v1.1 de 93,2 (amélioration de 1,5 point) et un score F1 sur SQuAD v2.0 de 83,1 (amélioration de 5,1 points). Ces résultats démontrent que les représentations préentraînées bidirectionnelles de BERT surpassent de manière significative les modèles précédents basés sur des architectures unidirectionnelles, offrant des améliorations substantielles dans diverses tâches de NLP sans nécessiter de modifications spécifiques à chaque tâche [13].

II.3.2.2. BioBERT : Un modèle de représentation linguistique biomédicale pré-entraîné pour l'exploration de textes biomédicaux[34]

Problème et aspects traités

Le modèle "BioBERT : a pre-trained biomedical language representation model for biomedical text mining" aborde le problème de l'extraction d'informations à partir des textes biomédicaux, un domaine devenu crucial avec l'explosion du nombre de documents biomédicaux. Les auteurs soulignent que les modèles de traitement automatique du langage naturel (TALN) généraux, tels que BERT, souvent ne sont pas adaptés aux textes biomédicaux en raison des différences de distribution de mots entre les corpus généraux et biomédicaux. Cette inadéquation entraîne des performances insatisfaisantes lorsqu'on applique directement ces modèles généraux aux tâches de text mining biomédical, comme la reconnaissance d'entités nommées (REN), l'extraction de relations (Relation extraction, RE) et le question-réponse (Question answering, QA) [34].

Approche et solution apportée

Pour répondre à ces défis, les auteurs introduisent BioBERT, un modèle de représentation du langage pré-entraîné spécifiquement sur des corpus biomédicaux. BioBERT est initialisé avec les poids de BERT, qui a été pré-entraîné sur des corpus de domaines généraux tels que Wikipédia en anglais et BooksCorpus. Ensuite, BioBERT est pré-entraîné sur des corpus biomédicaux à grande échelle, comprenant des résumés de PubMed et des articles en texte intégral de PubMed Central (PMC). Cette stratégie permet à BioBERT de capter les subtilités et le vocabulaire spécifique des textes biomédicaux. Les auteurs testent diverses combinaisons et tailles de corpus pour le pré-entraînement afin d'évaluer leur effet sur les performances des tâches de text mining biomédical [34].

Résultats et gains obtenus

Les résultats expérimentaux montrent que BioBERT surpasse largement BERT et les modèles précédents de pointe dans plusieurs tâches de text mining biomédical. BioBERT obtient des améliorations notables de la mesure F1 pour la reconnaissance d'entités nommées (amélioration de 0.62 %), l'extraction de relations (amélioration de 2.80 %), et une amélioration significative du MRR pour le question-réponse (12.24 %). Ces résultats démontrent que le pré-entraînement de BERT sur des corpus biomédicaux est crucial pour améliorer la compréhension

des textes biomédicaux complexes. En rendant les poids pré-entraînés et le code source de BioBERT librement accessibles, les auteurs offrent à la communauté un outil puissant pour diverses applications de text mining biomédical [34].

II.3.2.3. BioByGANS : Reconnaissance d'entités nommées biomédicales par fusion des caractéristiques contextuelles et syntaxiques à travers un réseau d'attention graphique dans un cadre de classification de nœuds[76]

Problème et aspects traités

Le modèle "BioByGANS : Biomedical Named Entity Recognition by Fusing Contextual and Syntactic Features Through Graph Attention Network in Node Classification Framework" aborde le problème crucial de la reconnaissance automatique et précise des entités nommées biomédicales (BioNER) dans la littérature biomédicale. Cette tâche est essentielle pour extraire des connaissances biomédicales structurées à partir de textes non structurés. Les méthodes actuelles de BioNER utilisant l'étiquetage de séquences et les réseaux neuronaux profonds sous-utilisent souvent les caractéristiques syntaxiques telles que les dépendances et la topologie des phrases. Par conséquent, il est urgent de résoudre le problème de l'intégration des caractéristiques sémantiques et syntaxiques dans le modèle BioNER [76].

Approche et solution apportée

Pour résoudre ces défis, les auteurs proposent un nouveau modèle de reconnaissance des entités nommées biomédicales appelé BioByGANS (BioBERT/SpaCy-Graph Attention Network-Softmax). Ce modèle utilise un graphe pour modéliser les dépendances et la topologie des phrases, en formulant la tâche de BioNER comme un problème de classification de nœuds. Premièrement, les phrases sont segmentées et les mots sont encodés par BioBERT pour les caractéristiques contextuelles et par SpaCy pour les caractéristiques syntaxiques. Ensuite, un réseau d'attention par graphe (Graph Attention Network, GAN) est utilisé pour générer une représentation fusionnée tenant compte à la fois des caractéristiques contextuelles et syntaxiques. Enfin, une fonction softmax calcule les probabilités pour obtenir les résultats. Les expériences menées sur 8 ensembles de données de référence montrent que BioByGANS surpasse les méthodes BioNER existantes [76].

Résultats et gains obtenus

Les résultats expérimentaux démontrent l'efficacité du modèle BioByGANS. Sur les 8 ensembles de données de référence biomédicale, BioByGANS dépasse les modèles de pointe actuels, atteignant des scores F1 de 85.15% pour BC2GM, 78.16% pour JNLPBA, 92.97% pour BC4CHEMD, 94.74% pour BC5CDR-chem, 87.74% pour BC5CDR-disease, 91.57% pour NCBI-disease, 75.01% pour Species-800, et 90.99% pour LINNAEUS. Ces résultats indiquent que la formulation de la tâche BioNER en tant que problème de classification de nœuds et l'intégration des caractéristiques syntaxiques dans les réseaux d'attention par graphe peuvent améliorer de manière significative les performances du modèle [76].




FIGURE 15 – Architecture de BioByGans[76]

II.3.3. Approches basées sur l'apprentissage profond : Le BILSTM+CRF

II.3.3.1. HunFlair : Un outil facile à utiliser pour la reconnaissance d'entités nommées biomédicales à la pointe de la technologie[71]

Problème et aspects traités

Le modèle "HunFlair : an easy-to-use tool for state-of-the-art biomedical named entity recognition" aborde le problème crucial de la reconnaissance automatique et précise des entités nommées biomédicales (BioNER) dans la littérature scientifique. La reconnaissance des entités nommées telles que les gènes, les produits chimiques ou les maladies dans les textes non structurés est une étape essentielle pour l'extraction d'informations biomédicales. Les outils de BioNER actuels sont

souvent limités par leur dépendance à des corpus d'entraînement spécifiques, ce qui peut entraîner des performances inégales lorsqu'ils sont appliqués à des textes de genres différents ou à des corpus non vus auparavant. Le défi est donc de développer un outil de BioNER qui soit à la fois précis, robuste et facile à utiliser, couvrant plusieurs types d'entités et capable de généraliser sur divers types de textes biomédicaux [71].

Approche et solution apportée

Pour répondre à ces défis, les auteurs ont développé HunFlair, un tagueur de REN biomédical intégré dans le cadre TALN largement utilisé dans flair. HunFlair repose sur un modèle de langage de niveau caractère pré-entraîné sur environ 24 millions de résumés biomédicaux et trois millions de textes complets. Il reconnaît cinq types d'entités biomédicales importantes : les lignées cellulaires, les produits chimiques, les maladies, les gènes et les espèces. L'approche adoptée par HunFlair combine des modèles de langage de niveau caractère avec un apprentissage conjoint sur plusieurs corpus de référence pour éviter les biais spécifiques aux corpus et améliorer la robustesse. Le modèle est facile à installer et à utiliser, nécessitant seulement quatre lignes de code pour être appliqué. De plus, HunFlair est accompagné de versions harmonisées de 23 corpus de REN biomédical pour faciliter la formation et les expériences avec de nouvelles approches [71].

Résultats et gains obtenus

Les résultats expérimentaux montrent que HunFlair surpasse les autres outils de NER biomédical disponibles, avec un gain moyen de 7.26 points de pourcentage (pp) en F1 par rapport au meilleur outil concurrent dans un cadre d'évaluation croisée sur corpus. HunFlair atteint ou dépasse les performances des prototypes de recherche de pointe dans les expériences sur corpus. Par exemple, il obtient des scores F1 de 59.69 pour les produits chimiques, 72.19 pour les gènes, 85.05 pour les maladies dans le corpus CRAFT, et des scores similaires dans d'autres corpus de référence tels que BioNLP13 Cancer Genetics et PDR. Ces résultats démontrent la capacité de HunFlair à offrir des performances robustes et à l'avant-garde pour la reconnaissance des entités nommées biomédicales, tout en étant facile à intégrer dans les pipelines d'extraction d'informations biomédicales [71].




FIGURE 16 – Écosystème de HunFlair [71]

II.4. Analyse des résultats obtenus par les approches de REN biomédicale : Gènes et protéines

L'évolution des modèles pour la NER biomédicale a conduit à une diversité de techniques, allant des CRF (Conditional Random Fields) aux modèles de transformeurs sophistiqués. Le tableau ci-dessous présente une comparaison des performances de différents modèles de NER appliqués à l'identification des gènes et des protéines sur plusieurs jeux de données.

II.4.1. Cas des approches basées sur les CRF

CRF

Le modèle basé sur les CRF, en utilisant des ensembles de fonctionnalités riches, affiche une performance relativement modeste sur le jeu de données JNLPBA avec une précision de 65.91% et un rappel de 57.03%, culminant à un F1-score de 60.47%. Ces résultats montrent les limitations des CRF face à des modèles plus avancés, surtout en termes de capture des complexités contextuelles des entités biomédicales.

Architecture	Modèle	Métriques	BC2GM	JNLPBA	BioNLP CG	CRAFT
CRF	CRF	P	//	65.91	//	//
		R	//	57.03	//	//
		F	//	60.47	//	//
Transformers	Bert	P	81.81	72.43	//	//
		R	81.57	81.22	//	//
		F	81.69	76.58	//	//
	Biobert	P	84.32	72.24	//	//
		R	85.12	83.56	//	//
		F	84.72	77.49	//	//
	BioByGans	P	84.97	72.69	//	//
		R	85.32	84.54	//	//
		F	85.15	78.16	//	//
BiLSTM+CRF	HunFlair	P	//	//	//	//
		R	//	//	//	//
		F	//	77.60	87.71	72.19

TABLE II – Scores des modèles de pointe pour la REN de Gène et Protéine.

II.4.2. Cas des approches basées sur les transformers

Bert

Le modèle Bert obtient des résultats significativement meilleurs avec une précision et un rappel élevés, par exemple un F1-score de 76.58% sur JNLPBA, démontrant l'efficacité des transformeurs pour la NER biomédicale.

BioBert

Une spécialisation du modèle Bert pour le domaine biomédical, BioBert, améliore encore les performances avec un F1-score atteignant 77.49% sur JNLPBA, prouvant l'avantage de l'entraînement sur des textes biomédicaux.

BioByGans

Ce modèle, combinant des caractéristiques contextuelles et syntaxiques via des réseaux de neurones à attention, surpasse BioBert avec un F1-score de 78.16% sur JNLPBA, illustrant l'impact positif de l'intégration des caractéristiques syntaxiques.

II.4.3. Cas des approches basées sur les BiLSTM-CRF

HunFlair

Ce modèle basé sur BiLSTM-CRF, avec un entraînement sur un corpus varié de textes biomédicaux, montre des performances remarquables, particulièrement sur BioNLP CG avec un F1-score de 87.71%. Son approche robuste et sa capacité à généraliser sur différents corpus en font un choix puissant pour la NER biomédicale.

Face aux résultats présentés, il est évident que les modèles de transformeurs surpassent les approches traditionnelles basées sur les CRF. Cependant, des modèles comme HunFlair, qui combinent des techniques de BiLSTM-CRF et un pré-entraînement sur des données biomédicales, montrent des performances particulièrement élevées dans des contextes spécifiques. Le tableau et l'analyse des résultats démontrent les avancées et les limitations des différents modèles de NER biomédicale, justifiant ainsi la contribution innovante de ce mémoire dans l'amélioration des performances de la NER pour les entités biologiques comme les gènes et les protéines.

II.5. Synthèse

Ce chapitre explore les avancées significatives dans la reconnaissance d'entités nommées (REN) biomédicales, en mettant en lumière une gamme étendue d'approches, des méthodes traditionnelles aux techniques de pointe les plus récentes. Les champs aléatoires conditionnels (CRF), combinés à des ensembles de caractéristiques riches, démontrent une robustesse remarquable dans la capture des dépendances entre mots, ce qui améliore la précision de la REN dans des contextes complexes. L'émergence de BERT, avec son architecture bidirectionnelle révolutionnaire, a permis une compréhension contextuelle approfondie, transformant ainsi les capacités de la REN. BioBERT, une variante de BERT pré-entraînée spécifiquement sur des corpus biomédicaux, améliore encore ces performances en assimilant les nuances et les terminologies propres au domaine biomédical, facilitant ainsi l'identification précise des gènes et des protéines. BioByGANS introduit une approche novatrice en fusionnant les caractéristiques contextuelles et syntaxiques par le biais de réseaux d'attention graphique, offrant une modélisation plus détaillée et une meilleure reconnaissance des entités biomédicales grâce à la classification des nœuds. Cette méthode se révèle particulièrement efficace pour traiter des textes

biomédicaux complexes, où les relations syntaxiques jouent un rôle crucial. Enfin, HunFlair se distingue comme un outil convivial et puissant, intégrant des modèles de pointe comme Flair pour fournir des capacités avancées de REN sans nécessiter une expertise technique approfondie. En rendant ces technologies accessibles, HunFlair permet aux chercheurs et praticiens de tirer parti des dernières avancées en REN biomédicale pour leurs travaux, améliorant ainsi la précision et l'efficacité de l'extraction d'informations cruciales sur les gènes et les protéines à partir de vastes corpus de textes biomédicaux.

III

CHAPITRE

CONTRIBUTION À LA RECONNAISSANCE D'ENTITÉS NOMMÉES BIOMÉDICALES : GÈNES ET PROTÉINES

SOMMAIRE

III.1 - Introduction	48
III.2 - Description de l'approche proposée	49
III.3 - Workflow de la méthode proposée	50
III.4 - Environnement de travail, résultats de simulation et discussions	55
III.5 - Synthèse	63

III.1. Introduction

Dans le domaine de la biomédecine, la reconnaissance d'entités nommées (REN) joue un rôle vital en permettant l'extraction d'informations pertinentes à partir de vastes corpus de textes médicaux et scientifiques. En particulier, l'identification précise des gènes et des protéines est essentielle pour la recherche biomédicale, le diagnostic clinique, et la découverte de médicaments. Ce chapitre se concentre sur notre contribution à l'amélioration des performances de la REN biomédicale, avec un accent particulier sur l'identification des gènes et des protéines. Les approches traditionnelles de REN, telles que les champs aléatoires conditionnels et les modèles basés sur l'apprentissage automatique, ont montré leurs limites dans la gestion de la complexité et de la variabilité des données biomédicales. Récemment, les modèles de d'apprentissage profond, tels que les transformeurs (ex. BioBERT) et

les architectures BiLSTM-CRF, ont considérablement amélioré les performances en capturant des contextes linguistiques riches et variés. Cependant, chaque méthode a ses propres avantages et inconvénients. Dans ce contexte, nous proposons une nouvelle architecture hybride qui combine les forces des modèles BioBERT (transformer) et Hunflair (BiLSTM-CRF). Notre approche utilise BioBERT pour extraire des embeddings contextuels riches, suivis d'une couche BiLSTM-CRF pour la segmentation et l'étiquetage précis des entités nommées. Pour résoudre les disparités dimensionnelles entre les différentes couches du modèle, nous intégrons une couche de reprojektion sophistiquée, optimisant ainsi la performance globale du système. Cette architecture hybride vise à tirer parti des capacités de généralisation des transformeurs tout en conservant la précision des modèles séquentiels traditionnels. Nous présenterons en détail les différentes composantes de notre modèle, y compris la collecte des données d'entraînement, le prétraitement des données, et les étapes de l'entraînement du modèle. Enfin, nous évaluerons les performances de notre approche par rapport aux modèles existants en utilisant des métriques standards de REN. Les travaux présentés dans ce chapitre contribuent à établir de nouvelles normes pour la REN dans le domaine biomédical, ouvrant la voie à des applications plus robustes et efficaces dans la recherche et la pratique clinique.

III.2. Description de l'approche proposée

Notre approche propose une architecture hybride innovante pour la reconnaissance d'entités nommées (NER) dans le domaine biomédical, combinant les capacités contextuelles des modèles de transformeurs avec la précision séquentielle des modèles BiLSTM-CRF. Le modèle utilise BioBERT[34] pour générer des représentations vectorielles (embeddings) contextuels riches, suivis d'une couche de reprojektion pour ajuster les dimensions des vecteurs. Un BiLSTM, initialisé avec les poids de HunFlair[71], traite ensuite les informations séquentielles, capturant les dépendances contextuelles des données textuelles. Enfin, une couche CRF est employée pour la segmentation et l'étiquetage précis des entités nommées. L'intégration de ces composants permet de tirer parti des forces de chaque modèle, améliorant ainsi les performances de la NER biomédicale. Pour évaluer les performances de notre modèle, nous utilisons des jeux de données de test standards et des métriques de performance couramment utilisées dans la NER, telles que la précision, le rappel et le F1-score.

III.3. Workflow de la méthode proposée

III.3.1. Architecture du modèle proposé




FIGURE 17 – Architecture du modèle proposé

III.3.1.1. Collecte de données d'entraînement

La collecte de données d'entraînement est une étape fondamentale dans le développement de notre modèle de reconnaissance d'entités nommées (NER) biomédicales. Nous avons sélectionné plusieurs corpus spécialisés pour garantir une couverture exhaustive des termes et contextes biomédicaux. Parmi ces corpus, nous utilisons les corpus BC2GM (Biomedical Text Mining Group's Gene Mention Corpus) et JNLPBA (Joint Workshop on Natural Language Processing in Biomedicine and its Applications), qui contiennent des annotations détaillées des mentions de gènes et de protéines. Ces corpus sont choisis pour leur pertinence et leur qualité d'annotation, assurant une base solide pour l'entraînement de notre modèle. Nous employons également des techniques de data augmentation pour enrichir le corpus, augmentant ainsi la diversité des exemples et la robustesse du modèle. L'intégration de ces divers corpus permet de créer un jeu de données riche et varié, crucial pour l'apprentissage efficace et généralisable du modèle.

III.3.1.2. Couche de prétraitement des données

Le prétraitement des données est une étape essentielle pour préparer les données brutes avant leur utilisation par le modèle. Cette étape comprend plusieurs sous-processus, notamment la tokenisation, la normalisation, et l'élimination des bruits. La tokenisation segmente le texte en unités significatives (tokens) telles que les mots ou les phrases. Ensuite, la normalisation standardise les différentes formes d'un mot en une forme canonique, par exemple en convertissant tous les mots en minuscules et en supprimant les caractères spéciaux non pertinents. En outre, nous effectuons une unification des étiquettes pour traiter les mentions de gènes et de protéines de manière cohérente, et la suppression des labels inutiles pour éliminer les annotations non pertinentes. Ces étapes de prétraitement permettent de garantir que les données d'entrée sont de haute qualité et prêtes pour l'étape suivante de l'extraction des embeddings.

III.3.1.3. Couche d'extraction des embeddings

La couche d'extraction des embeddings utilise BioBERT pour générer des représentations vectorielles contextuelles des tokens. BioBERT, un modèle de transformer pré-entraîné sur des textes biomédicaux, est particulièrement efficace pour capturer les relations sémantiques et contextuelles dans le domaine biomédical. Lors de cette étape, chaque token du texte prétraité est converti en un vecteur dense de dimension fixe (768 dimensions), encapsulant les informations contextuelles et

les relations avec les autres tokens dans la phrase. Ces embeddings vectoriels fournissent une représentation riche et détaillée des termes biomédicaux, facilitant ainsi les étapes de traitement séquentiel et d'étiquetage ultérieures.

III.3.1.4. Couche de reprojection

La couche de reprojection joue un rôle crucial dans l'intégration des embeddings de BioBERT avec les couches suivantes du modèle. Les dimensions des embeddings générés par BioBERT peuvent ne pas correspondre directement aux exigences des couches de traitement séquentiel. Pour résoudre ce problème, la couche de reprojection ajuste les dimensions des vecteurs d'embeddings, passant de 768 à 4296 dimensions. Cette transformation assure une transition fluide et sans perte d'information entre les différentes parties du modèle, harmonisant les disparités dimensionnelles et optimisant la performance globale du modèle.

III.3.1.5. Couche de traitement séquentiel

La couche de traitement séquentielle utilise un BiLSTM (Long Short-Term Memory bidirectionnel) pour capturer les dépendances séquentielles et contextuelles des données textuelles. Le BiLSTM traite les informations de manière bidirectionnelle, tenant compte des contextes passés (en amont) et futurs (en aval) de chaque token, ce qui est essentiel pour une reconnaissance précise des entités nommées. Les poids du BiLSTM sont initialisés à partir de ceux du modèle HunFlair, incorporant ainsi des connaissances biomédicales préalablement acquises. Cette couche améliore la capacité du modèle à comprendre les séquences complexes et les relations entre les entités dans le texte, renforçant ainsi la précision et la robustesse de la NER.

III.3.1.6. Couche de segmentation et d'étiquetage

Enfin, la couche de segmentation et d'étiquetage utilise un CRF (Conditional Random Fields) pour segmenter et étiqueter précisément les entités nommées dans le texte. Le CRF est particulièrement efficace pour les tâches de séquençage où il est crucial de garantir que les décisions d'étiquetage sont prises de manière globale et cohérente. Cette couche examine l'ensemble de la séquence d'étiquettes pour chaque phrase et optimise l'étiquetage en fonction des relations contextuelles et structurelles, améliorant ainsi la précision de la NER en garantissant des séquences d'étiquettes valides et cohérentes. Les entités nommées, telles que les mentions de

gènes (B-Gene, I-Gene) et de protéines, sont ainsi identifiées et étiquetées avec une haute précision, offrant une solution robuste pour l'extraction d'informations biomédicales critiques.

III.3.2. Evaluation du modèle

Pour évaluer les performances de notre modèle de reconnaissance d'entités nommées (NER) de gènes et de protéines dans le domaine biomédical, nous utilisons une matrice de confusion. Également connue sous le nom de tableau de contingence, la matrice de confusion permet d'évaluer les performances d'un modèle de classification. Elle compare les données réelles pour une variable cible à celles prédites par le modèle, révélant les prédictions justes et fausses par classe, ce qui permet de les comparer avec des valeurs définies. Dans sa forme la plus simple, il s'agit d'une matrice carrée comme illustré dans le tableau ci-dessous :

		Valeurs réelles	
		Classe négative (0)	Classe positive (1)
Valeurs prédites	Classe négative (0)	Vrais négatifs (TN)	Faux négatifs (FN)
	Classe positive (1)	Faux positifs (FP)	Vrais positifs (TP)

TABLE III – Matrice de confusion

Les résultats de cette matrice de confusion sont classés en quatre grandes catégories : les vrais positifs, les vrais négatifs, les faux positifs et les faux négatifs.

- **Vrais négatifs ou TN (true negative)** : représente le nombre de tokens dont le modèle a prédit comme n'étant pas une entité nommée de gène ou de protéine et c'est la réalité.
- **Vrais positifs ou TP (true positive)** : représente le nombre de tokens dont le modèle a prédit comme étant une entité nommée de gène ou de protéine et c'est la réalité.
- **Faux négatifs ou FN (false negative)** : représente le nombre de tokens dont le modèle a prédit comme n'étant pas une entité nommée de gène ou de protéine et ce n'est pas la réalité.

- **Faux positifs ou FP (false positive)** : représente le nombre de tokens dont le modèle a prédit comme étant une entité nommée de gène ou de protéine et ce n'est pas la réalité.

A partir de cette matrice de confusion, nous calculons les différentes métriques permettant de mieux apprécier la qualité de la précision du modèle. Ces métriques sont entre autres la précision, le rappel et le F1 score.

Précision

La précision détermine la proportion de prédictions positives qui étaient réellement correctes. Autrement dit, la précision indique le rapport entre les prévisions positives et le nombre total de prévisions positives. Elle est donnée par la formule suivante :

$$Precision = \frac{TP}{TP+FP}$$

Le rappel (Recall)

Le rappel est un paramètre qui permet de mesurer le nombre de prévisions positives correctes sur le nombre total de données positives. Dans le cas de la REN de gènes et de protéines, cela représente le rapport entre le nombre de tokens dont le modèle a prédit comme étant une entité nommée de gène ou de protéine sur le nombre réel de tokens qui sont des gènes ou des protéines. Cette métrique est déterminée par la formule suivante :

$$Recall = \frac{TP}{TP+FN}$$

F1 score

Le F1 Score est une métrique permettant d'évaluer un modèle de classification binaire sur la base des prédictions faites pour la classe positive. Il est calculé à l'aide de Précision et Recall. Il s'agit d'un type de score unique qui représente à la fois la précision et le rappel. Ainsi, le score F1 peut être calculé comme la moyenne harmonique de la précision et du rappel, en attribuant un poids égal à chacun d'eux. La formule pour calculer le F1-score est donnée ci-dessous :

$$F1 - score = 2 \times \frac{Precision \times Recall}{Precision + Recall}$$

Ces métriques fournissent une évaluation complète des performances de notre modèle de NER biomédicale, permettant d'identifier les forces et les faiblesses de notre approche et d'effectuer des améliorations si nécessaire.

III.4. Environnement de travail, résultats de simulation et discussions

III.4.1. Présentation de l'environnement de travail

Pour implémenter notre approche, nous avons utilisé un ensemble d'outils et de technologies pertinemment choisis. Ainsi, l'approche étant définie et expliquée dans la section précédente, nous avons utilisé Python, PyTorch, Flair.

Python : Le langage de programmation de notre approche est le langage Python. Ce choix se justifie par le niveau de popularité de Python dans le monde de l'intelligence artificielle. Il est également le langage de programmation par excellence au sein de la communauté des scientifiques des données (data scientists). Python est un langage polyvalent qui offre une grande variété de bibliothèques et de frameworks spécialement conçus pour le développement de solutions en intelligence artificielle et en apprentissage automatique.

PyTorch : Nous avons utilisé PyTorch comme framework principal pour définir et entraîner les composants de notre modèle. PyTorch offre une flexibilité et une performance élevées pour la création de réseaux de neurones complexes et leur optimisation..

Flair NLP : Nous avons utilisé la bibliothèque Flair pour ses capacités avancées en traitement du langage naturel, en particulier pour les tâches de REN. Flair fournit une interface simple et efficace pour travailler avec des modèles de séquences et des représentations vectorielles des mots(embeddings).

Jetstream2 : Pour lancer nos entraînements sur des instances, nous avons utilisé Jetstream2, une plateforme de cloud computing dédiée à la recherche scientifique. Jetstream2 offre des ressources informatiques flexibles et puissantes, permettant de gérer de grandes charges de travail de calcul, notamment pour l'entraînement de modèles d'apprentissage profond.

III.4.2. Résultats de simulation

L'évaluation de notre modèle de reconnaissance d'entités nommées (REN) biomédicales de gènes et de protéines a été réalisée sur quatre jeux de données les

plus utilisés pour la tâche de REN biomédicale : BC2GM, JNLPBA, BioNLPCG, et CRAFT. Les métriques utilisées pour évaluer les performances incluent la précision, le rappel et le F1-score. De plus, nous avons analysé les courbes de perte d'entraînement, de perte de validation et de F1-score tout au long de l'entraînement.

III.4.2.1. Les scores de notre modèle

Le diagramme ci-dessous présente les performances de notre modèle de reconnaissance d'entités nommées (REN) de gènes et de protéines




FIGURE 18 – Performance du modèle sur différents ensembles de données

Remarques Générales

- **Rappel Supérieur à la Précision** : Dans la majorité des cas, le rappel dépasse la précision. Cela est particulièrement pertinent pour la tâche de reconnaissance d'entités nommées de gènes et de protéines. Un rappel élevé signifie que notre modèle détecte la plupart des entités pertinentes, ce qui est crucial pour éviter les omissions d'informations essentielles. Bien que la précision soit également importante, un léger compromis sur celle-ci pour améliorer le rappel peut être justifié dans ce contexte.
- **Équilibre des Performances** : Les scores de F1 montrent un bon équilibre entre la précision et le rappel, avec des valeurs dépassant 84% pour tous les datasets, et atteignant même 93,41% pour BioNLPCG. Cela confirme la robustesse et l'efficacité de notre modèle hybride combinant BioBERT et HunFlair.

- **Implications Pratiques** : Les résultats obtenus démontrent que notre modèle est bien adapté pour des applications pratiques dans le domaine biomédical, où la capacité à détecter le plus grand nombre possible d'entités pertinentes (gènes et protéines) est essentielle pour des recherches précises et complètes.

En somme, le diagramme met en évidence les solides performances de notre modèle sur différents jeux de données, avec un accent particulier sur l'importance d'un rappel élevé pour les tâches de reconnaissance d'entités nommées dans le domaine biomédical. Ces résultats suggèrent que notre approche hybride est bien positionnée pour contribuer à des avancées significatives dans la recherche biomédicale et les applications cliniques.

III.4.2.2. Courbes de Perte et de F1-Score

Les diagrammes ci-dessous montrent les courbes de perte d'entraînement, de perte de validation et de F1-score pendant l'entraînement de notre modèle de reconnaissance d'entités nommées (REN) biomédicales.




FIGURE 19 – Courbes de Perte et de F1-Score

Analyse des Courbes de Perte

- **Courbe de Perte d'Entraînement** : Elle montre une diminution rapide au cours des premières époques, atteignant un plateau très bas après environ 2

à 3 époques. Cela indique que le modèle apprend efficacement à partir des données d'entraînement et minimise rapidement l'erreur sur ces données.

- **Courbe de Perte de Validation** : Elle commence également à diminuer, mais elle commence à augmenter après environ 3 à 4 époques. Cette augmentation progressive de la perte de validation après les premières époques suggère un début de surapprentissage, où le modèle commence à s'ajuster trop précisément aux données d'entraînement, perdant ainsi sa capacité à généraliser aux nouvelles données.

Analyse de la Courbe de F1-Score

La courbe de F1-score de validation : Elle montre une augmentation rapide initiale, atteignant un pic autour de la 4ème à la 5ème époque. Après ce point, le F1-score commence à diminuer légèrement, ce qui correspond au moment où la perte de validation commence à augmenter. Ce comportement indique que le modèle atteint sa performance optimale avant de commencer à sur-apprendre les données d'entraînement.

Remarques Générales

- **Performance Optimale Avant Surapprentissage** : Il est essentiel de noter que le modèle sauvegardé et utilisé pour les tests finaux est celui de l'époque où le F1-score de validation est maximal, avant que le surapprentissage ne commence. Cela permet de garantir que le modèle a la meilleure performance possible en termes de généralisation aux nouvelles données.
- **Importance de l'Évaluation Continue** : Les courbes démontrent l'importance de surveiller non seulement la perte d'entraînement, mais aussi la perte de validation et le F1-score de validation. Cela permet d'identifier le point optimal où le modèle doit être sauvegardé pour éviter le surapprentissage.
- **Stratégies pour Éviter le Surapprentissage** : Pour atténuer le surapprentissage observé, des techniques telles que l'arrêt précoce, la régularisation, ou l'utilisation de davantage de données d'entraînement peuvent être envisagées. L'arrêt précoce, en particulier, pourrait automatiquement sauvegarder le modèle au point optimal d'entraînement.
- **Robustesse du Modèle** : Malgré le début de surapprentissage après la 5ème époque, la robustesse initiale de l'apprentissage est évidente. La capacité du modèle à apprendre rapidement et à atteindre des performances élevées rapidement est un indicateur positif de son architecture efficace.

En somme, les courbes de perte et de F1-score fournissent des informations critiques sur la dynamique d'apprentissage de notre modèle. En identifiant et en sauvegardant le modèle au point de performance optimale, nous assurons une meilleure généralisation et une utilisation pratique efficace du modèle dans des contextes réels. Ces observations soulignent l'importance d'une évaluation continue et de l'application de techniques pour éviter le surapprentissage afin de maximiser la performance du modèle dans les tâches de reconnaissance d'entités nommées biomédicales de gènes et de protéines.

III.4.3. Discussions

Afin d'évaluer et de comparer les performances de 16 différents modèles de pointe dans la tâche de reconnaissance d'entités nommées (REN) de gènes et de protéines avec le nôtre, nous avons compilé les scores de précision, de rappel et de F1-score pour plusieurs modèles de pointe. Ces modèles ont été testés sur quatre jeux de données standards : BC2GM, JNLPBA, BioNLPCG, et CRAFT.[26][12][11][44] Le tableau ci-dessous présente les résultats obtenus pour chaque modèle, avec les scores majoritaires mis en gras pour une meilleure lisibilité. Ce tableau fournit une vue d'ensemble claire des performances des différents modèles, facilitant ainsi l'identification des approches les plus efficaces pour la tâche de REN de gènes et de protéines.

Modèle	Dataset	Précision (P)	Rappel (R)	F1-score (F)
BiLSTM-CRF[33]	BC2GM	81.57	79.48	80.51
	JNLPBA	71.35	75.74	73.48
CollaboNet[74]	BC2GM	80.49	78.99	79.73
	JNLPBA	74.43	83.22	78.58
MTM-CW[69]	BC2GM	82.10	79.42	80.74
	JNLPBA	70.91	76.34	73.52
BioKMNER[63]	BC2GM	-	-	84.92
	JNLPBA	-	-	77.72
BioBERT-MRC[58]	BC2GM	87.04	83.98	85.48
	JNLPBA	75.96	82.13	78.93
MTL-LS[8]	BC2GM[8]	-	-	82.92
BioELECTRA[25]	BC2GM	-	-	84.69
	JNLPBA	-	-	80.07

Modèle	Dataset	Précision (P)	Rappel (R)	F1-score (F)
BioBERT[34]	BC2GM	84.32	85.12	84.72
	JNLPBA	72.24	83.56	77.49
BioByGANs[76]	BC2GM	84.97	85.32	85.15
	JNLPBA	72.69	84.54	78.16
SciBERT[4]	JNLPBA	-	-	77.28
BERT[13]	BC2GM	81.81	81.57	81.69
	JNLPBA	74.43	83.22	78.58
SciSpacy[41]	CRAFT	-	-	47.76
	BioNLPCG	-	-	66.18
HUNER[72]	CRAFT	-	-	50.77
	BioNLPCG	-	-	71.22
HunFlair[71]	JNLPBA	-	-	77.60
	CRAFT	-	-	72.19
	BioNLPCG	-	-	87.71
Misc[71]	CRAFT	-	-	64.93
	BioNLPCG	-	-	68.97
CRF[52]	JNLPBA	65.91	57.03	60.47
Notre modèle	BC2GM	85.25	84.76	85.01
	JNLPBA	83.96	85.89	84.92
	CRAFT	88.23	89.87	89.04
	BioNLPCG	93.35	93.47	93.41

TABLE IV – Scores des modèles de pointe pour la REN de Gène et Protéine.

Afin de visualiser de manière plus intuitive et détaillée les performances des différents modèles de reconnaissance d’entités nommées dans le domaine biomédical, nous avons également tracé des courbes comparatives des scores de précision, de rappel et de F1-score pour chaque modèle sur les jeux de données BC2GM, JNLPBA, BioNLPCG, et CRAFT. Ces visualisations fournissent une vue d’ensemble claire des capacités des différents modèles à identifier correctement les entités, à capturer toutes les entités pertinentes et à maintenir un équilibre entre précision et rappel.

III.4.3.1. Discussions sur la Précision




FIGURE 20 – Discussions sur la précision

Le diagramme de précision illustre les performances de divers modèles sur les jeux de données BC2GM, JNLPBA, BioNLPCG, et CRAFT. Notre modèle se distingue par une précision élevée sur tous les jeux de données, surpassant systématiquement la plupart des autres modèles. Cette haute précision est essentielle dans la tâche de reconnaissance d'entités nommées de gènes et de protéines, car elle indique la capacité du modèle à identifier correctement les entités sans introduire un grand nombre de faux positifs. Une précision élevée réduit les erreurs de classification, ce qui est crucial pour les applications biomédicales où la fiabilité des résultats est primordiale.

III.4.3.2. Discussions sur le rappel




FIGURE 21 – Discussions sur le rappel

Le rappel, représenté dans le diagramme, montre la capacité des modèles à capturer toutes les entités pertinentes. Notre modèle affiche des scores de rappel exceptionnels, particulièrement sur les jeux de données JNLPBA et BioNLPCG. Un rappel élevé est d'une importance critique dans la reconnaissance d'entités nommées de gènes et de protéines, car il assure que le modèle identifie la majorité des entités pertinentes. Cela minimise les omissions, ce qui est vital pour les recherches biomédicales où chaque entité manquée peut entraîner des lacunes significatives dans les résultats de recherche ou les applications cliniques.

III.4.3.3. Discussions sur le F1-Score




FIGURE 22 – Discussions sur le F1-Score

Le F1-score combine les métriques de précision et de rappel, offrant une vue d'ensemble équilibrée des performances des modèles. Notre modèle démontre des F1-scores remarquablement élevés sur tous les jeux de données, illustrant sa capacité à maintenir un bon équilibre entre précision et rappel. Cela signifie que notre modèle n'est pas seulement bon pour éviter les faux positifs (haute précision) mais aussi pour capturer la plupart des entités pertinentes (haut rappel). Cet équilibre est crucial pour la reconnaissance d'entités nommées de gènes et de protéines, où il est essentiel d'assurer une identification exhaustive et précise des entités pour garantir la qualité des analyses biomédicales.

Remarques Générales

Les diagrammes de précision, de rappel et de F1-score mettent en évidence la performance robuste de notre modèle sur différents jeux de données standards. En général, notre modèle dépasse les performances des autres modèles dans la plupart des cas, en particulier sur les jeux de données JNLPBA et BioNLPCG.

- Précision : Notre modèle montre des scores de précision élevés, indiquant sa capacité à identifier correctement les entités nommées sans trop de faux positifs.
- Rappel : Le rappel élevé de notre modèle est particulièrement important dans le domaine biomédical, où il est crucial de capturer toutes les entités pertinentes.
- F1-Score : Les F1-scores de notre modèle confirment son efficacité globale, en équilibrant précision et rappel.

Ces résultats démontrent l'efficacité de l'approche hybride de notre modèle, combinant BioBERT et HunFlair pour une reconnaissance d'entités nommées biomédicales de gènes et de protéines.

III.5. Synthèse

Dans ce chapitre, nous avons présenté notre approche innovante pour la reconnaissance d'entités nommées (REN) dans le domaine biomédical, en mettant en avant les composantes clés de notre modèle hybride. Nous avons détaillé les étapes de collecte et de prétraitement des données, l'extraction des embeddings contextuels avec BioBERT, l'ajustement dimensionnel via une couche de reprojexion, et le traitement séquentiel avec BiLSTM initialisé par HunFlair. La segmentation et l'étiquetage des entités ont été optimisés grâce à l'utilisation d'un modèle CRF, garantissant une précision accrue. Nous avons également décrit l'environnement de travail et les outils utilisés pour développer et entraîner notre modèle, notamment les bibliothèques Flair et PyTorch, ainsi que la plateforme de cloud computing Jetstream2, qui a permis d'accélérer nos processus grâce à des ressources informatiques puissantes et flexibles. Les résultats de nos évaluations montrent que notre approche améliore significativement les performances de la REN biomédicale par rapport aux modèles existants utilisés indépendamment. En utilisant des métriques telles que la précision, le rappel, et le F1-score, nous avons démontré l'efficacité de notre modèle à identifier avec précision les gènes et les protéines dans les textes biomédicaux.

CONCLUSION GÉNÉRALE

CONTENTS

Problématique étudiée et choix méthodologiques	64
Analyse critique des résultats obtenus	65
Quelques perspectives	65

Pour conclure, nous allons récapituler la problématique abordée dans ce mémoire, puis exposer les principales caractéristiques de la solution proposée, ainsi que ses limites et les critiques pertinentes. Enfin, nous aborderons quelques perspectives envisageables pour des travaux futurs.

Problématique étudiée et choix méthodologiques

La reconnaissance d'entités nommées (REN) dans le domaine biomédical est une tâche essentielle pour l'extraction d'informations pertinentes à partir de textes spécialisés. La complexité des terminologies biomédicales, la variabilité des contextes et la richesse des données textuelles posent des défis significatifs pour les méthodes traditionnelles de NER. Notre travail s'est concentré sur l'amélioration de la précision et de l'efficacité de la NER biomédicale, spécifiquement pour l'identification des gènes et des protéines. Pour répondre à cette problématique, nous avons proposé une architecture hybride combinant les avantages des modèles de transformeurs et des architectures BiLSTM-CRF. Nous avons utilisé BioBERT pour générer des représentations vectorielles contextuelles (embeddings) riches, suivis d'une couche de reprojektion pour ajuster les dimensions des vecteurs, et un BiLSTM initialisé avec les poids de HunFlair pour capturer les dépendances séquentielles. Enfin, une couche champs aléatoires conditionnels (CRF en anglais) a été employée pour la segmentation et l'étiquetage précis des entités nommées. Cette combinaison méthodologique vise à tirer parti des points forts de chaque composant, optimisant ainsi les performances globales de notre modèle.

Analyse critique des résultats obtenus

Les résultats obtenus démontrent des améliorations significatives par rapport aux modèles existants utilisés indépendamment. Nos tests rigoureux ont montré que notre modèle hybride surpasse BioBERT et HunFlair en termes de précision, de rappel et de F1-score. L'utilisation de la matrice de confusion a permis d'évaluer en détail les performances du modèle, révélant une réduction substantielle des faux positifs et des faux négatifs. Cependant, malgré ces améliorations, il existe des domaines où notre modèle peut encore être optimisé. Par exemple, les faux négatifs restent un défi, indiquant que certains gènes essentiels ne sont toujours pas correctement identifiés. De plus, l'entraînement du modèle nécessite des ressources computationnelles importantes, ce qui peut limiter son déploiement dans des environnements à faible puissance de calcul. En termes d'analyse critique, il est également essentiel de noter que les performances du modèle dépendent fortement de la qualité et de la diversité des corpus d'entraînement. L'utilisation de données biomédicales annotées de haute qualité a été un facteur clé dans l'obtention de résultats précis. Toutefois, des variations dans les annotations ou la présence de biais dans les données pourraient influencer les résultats.

Quelques perspectives

Les avancées réalisées dans ce travail ouvrent la voie à plusieurs perspectives prometteuses pour la reconnaissance d'entités nommées biomédicales. Parmi celles-ci, nous envisageons les directions suivantes :

— **Amélioration de la Robustesse du Modèle en intégrant davantage de corpus biomédicaux diversifiés**

Ici, il est question de collecter plus de données pour renforcer la robustesse et la généralisation du modèle.

— **Intégration avec des Systèmes Cliniques**

Il est question ici de travailler sur l'intégration de notre modèle dans des systèmes d'information clinique pour faciliter l'extraction automatisée d'informations et améliorer la prise de décision médicale.

BIBLIOGRAPHIE

- [1] Blent AI. Apprentissage supervisé : Définition, n.d. Consulté le 5 juin 2024.
- [2] Alan Akbik, Tanja Bergmann, Duncan Blythe, Kashif Rasul, Stefan Schweter, and Roland Vollgraf. FLAIR : An easy-to-use framework for state-of-the-art NLP. In *NAACL 2019, 2019 Annual Conference of the North American Chapter of the Association for Computational Linguistics (Demonstrations)*, pages 54–59, 2019.
- [3] Adil Al-Azzawi, Anes Ouadou, Highsmith Max, Ye Duan, John J. Tanner, and Jianlin Cheng. Deepcryopicker : fully automated deep neural network for single protein particle picking in cryo-em. *BMC Bioinformatics*, 21(1) :509, September 2020.
- [4] Iz Beltagy, Kyle Lo, and Arman Cohan. Scibert : a pretrained language model for scientific text. In *Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing and the 9th International Joint Conference on Natural Language Processing (EMNLP-IJCNLP)*, pages 3615–3620, Hong Kong, China, 2019. Association for Computational Linguistics.
- [5] A. Bomgni, D. Abdala, B. Shrestha Gurung, M. Julius Nkenlifack, V. Gadhamshetty, and Z. Etienne Gnimpieba. Fine-tuning a pre-trained transformers-based model for gene name entity recognition in biomedical text using a customized dataset : case of *desulfovibrio vulgaris hildenborough*. In *2023 IEEE International Conference on Bioinformatics and Biomedicine (BIBM)*, pages 4473–4479, Los Alamitos, CA, USA, dec 2023. IEEE Computer Society.
- [6] Leo Breiman. Random forests. *Machine Learning*, 45(1) :5–32, October 2001.
- [7] BrightCape. Apprentissage supervisé vs non supervisé, n.d. Consulté le 5 juin 2024.

- [8] Zhuxi Chai, Xuefei Ma, Yifan Peng, and Zhiyong Lu. Hierarchical shared transfer learning for biomedical named entity recognition. *BMC Bioinformatics*, 23(1) :1–14, 2022.
- [9] Hyejin Cho and Hyunju Lee. Biomedical named entity recognition using deep neural networks with contextual information. *BMC Bioinformatics*, 20(1) :735, 2019.
- [10] Anna Choury and Benjamin Ejzenberg. *Objectif IA : initiez-vous à l'intelligence artificielle*. Formation, Jan 2023.
- [11] K. B. Cohen, K. Verspoor, K. Fort, C. Funk, M. Bada, M. Palmer, and L. E. Hunter. The colorado richly annotated full text (craft) corpus : multi-model annotation in the biomedical domain. In *Handbook of Linguistic Annotation*, pages 1379–1394. Springer, Dordrecht, 2017.
- [12] N. Collier and J.-D. Kim. Introduction to the bio-entity recognition task at jnlpba. In *Proceedings of the International Joint Workshop on Natural Language Processing in Biomedicine and its Applications (NLPBA/BioNLP)*, pages 73–78, 2004.
- [13] Jacob Devlin, Ming-Wei Chang, Kenton Lee, and Kristina Toutanova. Bert : Pre-training of deep bidirectional transformers for language understanding. In *Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics : Human Language Technologies, Volume 1 (Long and Short Papers)*, pages 4171–4186, 2019.
- [14] Devoteam. Aller plus loin en deep learning avec les réseaux de neurones récurrents (rnns), 2022. Accessed : 2024-06-05.
- [15] Messaoud DJEDDOU. *Prediction of Failure rate with Artificial Neural Networks in a WasteWater Treatment Plant French Copy*. PhD thesis, December 2014.
- [16] Weili Fang, Peter E.D. Love, Hanbin Luo, and Lieyun Ding. Computer vision for behaviour-based safety in construction : A review and future directions. *Advanced Engineering Informatics*, 43 :100980, 2020.
- [17] Dieter Galea, Ivan Laponogov, and Kirill Veselkov. Exploiting and assessing multi-source data for supervised biomedical named entity recognition. *Bioinformatics*, 34(14) :2474–2482, 2018.

- [18] John M Giorgi and Gary D Bader. Transfer learning for biomedical named entity recognition with neural networks. *Bioinformatics*, 34(23) :4087–4094, 2018.
- [19] Jiuxiang Gu, Zhenhua Wang, Jason Kuen, Lianyang Ma, Amir Shahroudy, Bing Shuai, Ting Liu, Xingxing Wang, Gang Wang, Jianfei Cai, and Tsuhan Chen. Recent advances in convolutional neural networks. *Pattern Recognition*, 77 :354–377, 2018.
- [20] K. Y. He, D. Ge, and M. M. He. Big data analytics for genomic medicine. *International Journal of Molecular Sciences*, 18(2) :412, 2017.
- [21] M. H. Jarrahi. Artificial intelligence and the future of work : Human-ai symbiosis in organizational decision making. *Business Horizons*, 61(4) :577–586, 2018.
- [22] Bahzad Jijo and Adnan Mohsin Abdulazeez. Classification based on decision tree algorithm for machine learning. *Journal of Applied Science and Technology Trends*, 2 :20–28, January 2021.
- [23] Ikram Chraïbi Kaadoud. Architecture des réseaux de neurones : Réseaux de neurones artificiels classiques (2/3)! nov 2018.
- [24] Bernard Kamsu-Foguem, Fabien Rigal, and Félix Mauget. Mining association rules for the quality improvement of the production process. *Expert Systems with Applications*, 40(4) :1034–1045, 2013.
- [25] Keerthana Kanakarajan, Qiao Jin, Eunji Kim, Zhongyu Wei, Leo Anthony Celi, Jimeng Sun, and Zhi He. Bioelectra : pretrained biomedical text encoder using discriminators. In *Proceedings of the 20th Workshop on Biomedical Language Processing*, pages 143–154, 2021.
- [26] A. Kankanhalli, J. Hahn, S. Tan, and G. Gao. Big data and analytics in healthcare : Introduction to the special section. *Information Systems Frontiers*, 18(2) :233–235, 2016.
- [27] Maryam Khordad, Robert Mercer, and Peter Rogan. A machine learning approach for phenotype name recognition. *Proceedings of Coling, COLING* :1425–1440, 01 2012.
- [28] Joos Korstanje. *LSTM RNNs*, pages 243–251. Apress, Berkeley, CA, 2021.
- [29] Alex Krizhevsky, Ilya Sutskever, and Geoffrey E. Hinton. Imagenet classification with deep convolutional neural networks. *Commun. ACM*, 60(6) :84–90, May 2017.

- [30] Ajitesh Kumar. Different types of cnn architectures explained : Examples - data analytics. <https://www.analyticsvidhya.com/blog/2023/05/different-types-of-cnn-architectures-explained-examples/>, May 2023. Accessed : 2024-06-05.
- [31] Kim KW, Han SH, Youn YC, and Kim S. Artificial neural network : Understanding the basic concepts without mathematics. *Dementia and Neurocognitive Disorders*, 17(3) :83–89, September 2018.
- [32] John Lafferty, Andrew McCallum, and Fernando Pereira. Conditional random fields : Probabilistic models for segmenting and labeling sequence data. In *Proceedings of the 18th International Conference on Machine Learning (ICML)*, pages 282–289, 2001.
- [33] Guillaume Lample, Miguel Ballesteros, Sandeep Subramanian, Kazuya Kawakami, and Chris Dyer. Neural architectures for named entity recognition. In *Proceedings of the 2016 Conference of the North American Chapter of the Association for Computational Linguistics : Human Language Technologies*, pages 260–270, 2016.
- [34] J. Lee, W. Yoon, S. Kim, D. Kim, S. Kim, C. H. So, and J. Kang. Biobert : a pre-trained biomedical language representation model for biomedical text mining. *Bioinformatics*, 36(4) :1234–1240, 2020.
- [35] J. Li and S. J. Qin. Applying and dissecting lstm neural networks and regularized learning for dynamic inferential modeling. *Computers & Chemical Engineering*, 175 :108264, 2023.
- [36] Xuezhe Ma and Eduard Hovy. End-to-end sequence labeling via bi-directional lstm-cnns-crf. In *Proceedings of the 54th Annual Meeting of the Association for Computational Linguistics (Volume 1 : Long Papers)*, pages 1064–1074, 2016.
- [37] Andrew McCallum and Wei Li. Early results for named entity recognition with conditional random fields, feature induction and web-enhanced lexicons. In *Proceedings of the Seventh Conference on Natural Language Learning at HLT-NAACL 2003-Volume 4*, pages 188–191, 2003.
- [38] Seyed Mahdi Miraftebadeh, Federica Foiadelli, Michela Longo, and Marco Pasetti. A survey of machine learning applications for power system analytics. In *Proceedings of the Conference*, pages 2–6, June 2019.

- [39] Seyed Mahdi Miraftebzadeh, Federica Foidadelli, Michela Longo, and Marco Pasetti. A survey of machine learning applications for power system analytics. In *Proceedings of the Conference*, pages 2–6, June 2019.
- [40] Behrang Mohit. Named entity recognition. pages 221–245, 03 2014.
- [41] Mark Neumann, Daniel King, Iz Beltagy, and Waleed Ammar. Scispacey : fast and robust models for biomedical natural language processing. In *Proceedings of the 18th BioNLP Workshop and Shared Task*, pages 58–66, Florence, Italy, 2019. Association for Computational Linguistics.
- [42] Dan Pelleg and Andrew Moore. Accelerating exact k-means algorithms with geometric reasoning. In *Proceedings of the Fifth ACM SIGKDD International Conference on Knowledge Discovery and Data Mining, KDD '99*, pages 277–281. Association for Computing Machinery, 1999.
- [43] John Platt. Sequential minimal optimization : A fast algorithm for training support vector machines. In *Advances in Kernel Methods-Support Vector Learning*, pages 208–232. MIT Press, July 1998. pp. 208–232, section 208.
- [44] Sampo Pyysalo, Tomoko Ohta, and Sophia Ananiadou. Overview of the cancer genetics (cg) task of bionlp shared task 2013. pages 58–66, 08 2013.
- [45] Reza Rawassizadeh, Blaine A Price, and Marian Petre. Wearables : Has the age of smartwatches finally arrived? *Communications of the ACM*, 58(1) :45 – 47, 2014.
- [46] Y. Reddy, Viswanath Pulabaigari, and Eswara B. Semi-supervised learning : a brief review. *International Journal of Engineering Technology*, 7 :83–84, February 2018.
- [47] ResearchGate. The structure of lstm memory cell, 2023. Accessed : 2024-06-05.
- [48] B. Ristevski and M. Chen. Big data analytics in medicine and healthcare. *Journal of Integrative Bioinformatics*, 15(3), 2018.
- [49] Sagar. Getting started with machine learning in 2023, 2023. Sagar - Medium.
- [50] Sunita Sarawagi and William W Cohen. Semi-markov conditional random fields for information extraction. In *Proceedings of the 2004 Conference on Neural Information Processing Systems (NIPS)*, pages 1185–1192, 2004.
- [51] Hilary L. Seal. Studies in the history of probability and statistics. xv the historical development of the gauss linear model. *Biometrika*, 54(1-2) :1–24, June 1967.

- [52] B. Settles. Biomedical named entity recognition using conditional random fields and rich feature sets. In *Proceedings of the International Joint Workshop on Natural Language Processing in Biomedicine and its Applications (NLPBA/BioNLP)*, pages 107–110, 2004.
- [53] Fei Sha and Fernando Pereira. Shallow parsing with conditional random fields. In *Proceedings of the 2003 Conference of the North American Chapter of the Association for Computational Linguistics on Human Language Technology-Volume 1*, pages 134–141, 2003.
- [54] L. Smith, L.K. Tanabe, C.-J. Kuo, I. Chung, C.-N. Hsu, Y.-S. Lin, R. Klinger, C.M. Friedrich, K. Ganchev, M. Torii, et al. Overview of biocreative ii gene mention recognition. *Genome Biology*, 9(2) :1–19, 2008.
- [55] Rion Snow, Brendan O’connor, Dan Jurafsky, and Andrew Y Ng. Cheap and fast—but is it good? evaluating non-expert annotations for natural language tasks. In *Proceedings of the 2008 conference on empirical methods in natural language processing*, pages 254–263, 2008.
- [56] S. Song, G. Huang, J. N. D. Gupta, and C. Wu. Semi-supervised and unsupervised extreme learning machines. *IEEE Transactions on Cybernetics*, 44(12) :2405–2417, December 2014.
- [57] P. Srivastava, S. Bej, K. Yordanova, and O. Wolkenhauer. Self-attention-based models for the extraction of molecular interactions from biological texts. *Bio-molecules*, 11(11) :1591, 2021.
- [58] Chengyu Sun, Zhi Yang, Weizhen Wang, Yuping Ma, Manman Zhang, and Aixin Sun. Biomedical named entity recognition using bert in the machine reading comprehension framework. *Journal of Biomedical Informatics*, 118 :103799, 2021.
- [59] Charles Sutton and Andrew McCallum. An introduction to conditional random fields for relational learning. *Introduction to statistical relational learning*, pages 93–128, 2006.
- [60] Charles Sutton and Andrew McCallum. An introduction to conditional random fields. *Foundations and Trends in Machine Learning*, 4(4) :267–373, 2012.
- [61] TechTarget. Deep neural network image, 2024. Accessed : 2024-06-05.
- [62] Sally Thorne. Data analysis in qualitative research. *Evidence-based nursing*, 3(3) :68–70, 2000.

- [63] Yixi Tian, Longxiang Cao, Zhen Wang, Yongqun He, and Hong Zhang. Improving biomedical named entity recognition with syntactic information. *BMC Bioinformatics*, 21(1) :1–17, 2020.
- [64] Juliana Tolles and William J. Meurer. Logistic regression : Relating patient characteristics to outcomes. *JAMA*, 316(5) :533–534, August 2016.
- [65] D. Tzitzivacos. International classification of diseases 10th edition (icd-10). *CME : Your SA Journal of CPD*, 25(1) :8–10, 2007.
- [66] Unknown. Image on medium, n.d. Consulté le 5 juin 2024.
- [67] Ashish Vaswani, Noam Shazeer, Niki Parmar, Jakob Uszkoreit, Llion Jones, Aidan N. Gomez, Lukasz Kaiser, and Illia Polosukhin. Attention is all you need, 2023.
- [68] K. Vu. Bert transformers : How do they work ? <https://dzone.com/articles/bert-transformers-how-do-they-work>, April 2021.
- [69] Xing Wang, Yong Peng, and Zhiyong Lu. Cross-type biomedical named entity recognition with deep multi-task learning. *Bioinformatics*, 35(10) :1745–1752, 2019.
- [70] Xu Wang, Chen Yang, and Renchu Guan. A comparative study for biomedical named entity recognition. *International Journal of Machine Learning and Cybernetics*, 9 :373–382, 2018.
- [71] Leon Weber, Mario Sängler, Jannes Münchmeyer, Maryam Habibi, Ulf Leser, and Alan Akbik. Hunflair : an easy-to-use tool for state-of-the-art biomedical named entity recognition. *Bioinformatics*, 37(17) :2792–2794, 2021.
- [72] Leonard Weber, Franck Dernoncourt, Peter Szolovits, Ozlem Uzuner, and Thorsten Berger. Huner : improving biomedical ner with pretraining. *Bioinformatics*, 36 :295–302, 2020.
- [73] Wikipedia. Reinforcement learning. https://en.wikipedia.org/wiki/Reinforcement_learning, June 2023. Consulté le 5 juin 2024.
- [74] Woori Yoon, Donghyeon Kim, Eunji Yang, Jaegul Lee, and Jaewoo Kang. Collabonet : collaboration of deep neural networks for biomedical named entity recognition. *BMC Bioinformatics*, 20(10) :55–65, 2019.
- [75] Sendong Zhao, Chang Su, Zhiyong Lu, and Fei Wang. Recent advances in biomedical literature mining. *Briefings in Bioinformatics*, 22(3) :bbaa057, 05 2020.

- [76] X. Zheng, H. Du, X. Luo, F. Tong, W. Song, and D. Zhao. Biobygans : Bio-medical named entity recognition by fusing contextual and syntactic features through graph attention network in node classification framework. *BMC Bio-informatics*, 23 :501, 2022.
- [77] Patrick Zschech, Christian Janiesch, and Kai Heinrich. Machine learning and deep learning. *Electronic Markets*, 31(3) :685–695, September 2021.
- [78] Gökberk Çelkmasat, Muhammed Enes Aktürk, Yunus Emre Ertunç, Abdul Majeed Issifu, and Murat Can Ganz. Biomedical named entity recognition using transformers with bilstm + crf and graph convolutional neural networks. In *2022 International Conference on INnovations in Intelligent SysTems and Applications (INISTA)*, pages 1–6, 2022.