
Titre du projet : Développement de Méthodes d'Apprentissage Automatique pour la Désagrégation Temporelle et la Mise à l'Échelle Spatiale des Données Climatiques pour les Communautés Locales

1 Contexte de l'étude

Les modèles climatiques mondiaux (GCM) sont des outils indispensables pour comprendre et anticiper les changements climatiques futurs. Cependant, ils opèrent à des résolutions spatiales grossières (souvent de 50 à 200 km), ce qui les rend inadaptés pour des évaluations d'impact à l'échelle locale [1]. Pour des secteurs comme l'agriculture, la gestion des ressources en eau ou la planification des risques, en particulier au sein de communautés tribales dont les activités sont intimement liées au climat local, des données à haute résolution spatiale et temporelle sont cruciales. Par exemple, savoir si la pluie journalière tombe en quelques heures sous forme d'orage violent ou en continu sur la journée a des implications radicalement différentes en termes d'érosion des sols et de risque d'inondation.

Le "downscaling" (ou mise à l'échelle statistique) est un ensemble de techniques visant à combler cet écart d'échelle. Récemment, l'apprentissage automatique (ML) a émergé comme une approche puissante et computationnellement efficace pour cette tâche, offrant une alternative prometteuse aux méthodes de downscaling dynamiques, qui sont extrêmement coûteuses en calcul [4].

2 État de l'art

La littérature scientifique sur la mise à l'échelle par apprentissage automatique a connu une croissance exponentielle, avec des avancées notables. Les architectures d'apprentissage profond, notamment les réseaux de neurones convolutionnels (CNN), les réseaux antagonistes génératifs (GAN) et les modèles à diffusion, ont démontré une capacité supérieure à capturer les relations complexes et non linéaires entre les prédicteurs climatiques à grande échelle et les variables locales (température, précipitations) [1, 2]. Ces approches surpassent souvent les méthodes statistiques traditionnelles en termes de précision et de réalisme spatial [5]. Des études récentes explorent également des architectures hybrides qui intègrent des contraintes physiques (par exemple, la conservation de l'énergie) pour garantir que les sorties des modèles restent physiquement plausibles, répondant ainsi à une critique majeure des modèles purement "boîte noire" [3].

Malgré ces progrès, des défis importants subsistent. L'un des plus critiques est la **désagrégation temporelle**, en particulier pour les précipitations. La plupart des modèles se concentrent sur l'amélioration de la résolution spatiale des données journalières, mais peu s'attaquent à la distribution infra-journalière de la pluie. De plus, la **validation rigoureuse** des modèles, notamment leur capacité à reproduire les événements extrêmes, reste un point faible. Enfin, la création de pipelines de données automatisés pour traiter, mettre à l'échelle et valider les projections climatiques est une étape indispensable mais souvent négligée pour rendre ces outils accessibles et opérationnels pour les communautés locales.

3 Problématique

Les données climatiques à haute résolution temporelle (horaire) sont essentielles pour la modélisation hydrologique, l'évaluation des risques d'inondations soudaines et la gestion des infrastructures, des enjeux particulièrement pertinents pour les communautés tribales. Or, les sorties des GCM et même des modèles climatiques régionaux (RCM) sont généralement disponibles, au mieux, à une résolution journalière. Les méthodes de désagrégation temporelle existantes sont souvent basées sur des

modèles stochastiques simples qui ne capturent pas adéquatement la structure et la variabilité des événements de précipitation réels. Par ailleurs, la mise en œuvre de ces techniques de downscaling reste une tâche complexe, nécessitant une expertise technique qui fait obstacle à leur adoption par les non-spécialistes.

C'est dans ce contexte que se pose la problématique suivante : **Comment développer et automatiser un cadre de modélisation basé sur l'apprentissage automatique capable non seulement de réaliser une mise à l'échelle spatiale, mais aussi une désagrégation temporelle fiable des précipitations, tout en validant rigoureusement sa performance par rapport aux données d'observation locales ?** L'objectif est de créer un pipeline de traitement de données qui soit à la fois performant, précis et suffisamment automatisé pour **générer des bases de données climatiques prêtes à l'emploi** pour les modèles d'adaptation.

4 Hypothèse de recherche

Notre hypothèse est qu'une combinaison de techniques d'apprentissage automatique, appliquées de manière séquentielle pour la mise à l'échelle spatiale puis la désagrégation temporelle, peut générer des données de précipitations à haute résolution (ex: 1 km, horaire) plus précises et réalistes que les méthodes statistiques standards.

Notre hypothèse se décline ainsi :

1. Des modèles d'apprentissage automatique avancés, notamment des techniques de régression non linéaire (ex: Random Forest, Gradient Boosting), peuvent réaliser une mise à l'échelle spatiale des précipitations journalières plus précise que les méthodes d'interpolation classiques.
2. Un modèle de série temporelle (ex: LSTM, Transformer) entraîné sur des données pluviométriques horaires observées peut apprendre la structure des événements pluvieux et être utilisé pour désagréger de manière réaliste les prédictions journalières issues de la première étape.
3. Un pipeline de traitement de données entièrement automatisé, de l'extraction des données GCM à la production de séries temporelles à haute résolution validées, est réalisable et peut accélérer significativement la création de bases de données climatiques pour la modélisation adaptative.

5 Objectif général et spécifiques

Objectif général :
Développer, automatiser et valider un pipeline de mise à l'échelle basé sur l'apprentissage automatique pour générer des données climatiques à haute résolution spatio-temporelle (en particulier pour les précipitations) adaptées aux besoins des communautés locales.

Objectifs spécifiques :

1. Développer et tester plusieurs méthodes de ML (ex: Random Forest, XGBoost, CNN) pour la mise à l'échelle spatiale de données de précipitations journalières à partir de sorties de modèles climatiques globaux.
2. Mettre en œuvre une méthode de ML basée sur l'analyse de séries temporelles (ex: LSTM) pour la désagrégation temporelle des précipitations journalières en données horaires, une étape essentielle pour les communautés tribales.

3. Créer un pipeline de traitement de données automatisé qui enchaîne l'acquisition des données brutes, la mise à l'échelle spatiale, la désagrégation temporelle et la **correction de biais**.
4. Comparer et valider de manière rigoureuse les performances des différentes méthodes de downscaling par rapport à un jeu de données d'observation indépendant, en se concentrant sur les métriques de précision (ex: RMSE) et la reproduction des extrêmes.
5. **Produire une base de données climatiques à haute résolution pour une zone d'étude spécifique, prête à être utilisée dans des modèles de réponse adaptative.**

6 Résultats attendus

À l'issue de ce travail de master, les résultats attendus sont les suivants :

1. **Un ensemble de modèles de ML évalués et comparés** pour la mise à l'échelle spatiale et la désagrégation temporelle des précipitations.
2. **Un pipeline logiciel automatisé et documenté** pour la création de bases de données climatiques à la demande.
3. **Un rapport de validation complet** analysant la performance des modèles, leurs forces et leurs faiblesses, notamment en ce qui concerne la reproduction des événements extrêmes.
4. **Une thèse de master** détaillant la méthodologie, les algorithmes, le processus d'automatisation et les résultats de la validation.
5. **Une base de données climatiques à haute résolution** (ex: 1 km, horaire) pour une région d'étude, qui pourra être directement utilisée par les partenaires communautaires pour leurs propres analyses d'impact.

Bibliographie

- [1] Koldunov, N., Rackow, T., Lessig, C., et al. (2024). Emerging ai-based weather prediction models as downscaling tools. *arXiv*.
- [2] Rampal, N., Gibson, P. B., Sherwood, S. C., et al. (2024). A reliable generative adversarial network approach for climate downscaling and weather generation. *essoar*.
- [3] Watson, C. D., & Zhang, T. (2023). Physics-constrained deep learning for downscaling. *egusphere*.
- [4] González-Abad, J., & Gutiérrez, J. M. (2024). Are deep learning methods suitable for downscaling global climate projections? Review and intercomparison of existing models. *arXiv*.
- [5] Baño-Medina, J., Manzanás, R., & Gutiérrez, J. M. (2020). Configuration and intercomparison of deep learning neural models for statistical downscaling. *Geoscientific Model Development*, 13(4), 2109-2124.