

ST-CDGM

Développement de Méthodes d'Apprentissage Automatique pour la Désagrégation
Temporelle et la Mise à l'Échelle Spatiale des Données Climatiques pour les Communautés
Locales

Kenfack Leonel

Université de Dschang
Master 2

29 mars 2026


- 1 Le trilemme de la modélisation climatique
- 2 Causalité et généralisation OOD
- 3 Présentation du cGAN
- 4 Limites du Residual cGAN
- 5 Présentation du ResDiff
- 6 Limites du ResDiff
- 7 Autres limites des modèles DL en désagrégation

Le trilemme de la modélisation climatique : un défi hors-distribution

La modélisation climatique se heurte à un obstacle structurel : le changement climatique est, par nature, un problème **hors distribution (OOD)**. Les modèles calés sur le passé apprennent des régularités statistiques qui ne sont pas garanties sous un climat futur : l'hypothèse de stationnarité devient fragile.

Les approches actuelles peinent à satisfaire **simultanément** trois exigences :


- 1 **Stabilité** à l'entraînement ;
- 2 **Réalisme** dans la reproduction des extrêmes et de la variance stochastique ;
- 3 **Robustesse OOD** face au décalage de distribution (généralisation hors échantillon).



De l'imitation statistique à la compréhension physique

Le défi fondamental du changement climatique est un problème **hors distribution (OOD)**.
Les modèles calés sur l'historique doivent généraliser vers des conditions futures inédites ;
Les modèles purement corrélacionnels apprennent des « raccourcis statistiques », peu fiables lorsque le climat se déplace hors de la distribution d'entraînement.

Notre objectif. Introduire la **causalité** : passer de l'apprentissage de corrélations à la modélisation de **mécanismes causaux invariants** — la physique — pour mieux assurer la **robustesse OOD** et limiter l'échec en généralisation.




Le cGAN : réseau antagoniste conditionnel

Le **cGAN** (réseau antagoniste génératif conditionnel) repose sur une **compétition** entre deux réseaux :

- **Générateur** : construit une carte climatique haute résolution à partir des données **basse résolution** (condition / guide) et d'un **vecteur de bruit** aléatoire.
- **Discriminateur (critique)** : reçoit des cartes réelles (vérité terrain) et des cartes générées ; il estime si une image est **authentique** ou **synthétique**.

À l'entraînement, le générateur cherche des textures suffisamment réalistes pour **tromper** le discriminateur, qui lui apprend à mieux distinguer vrai et faux : **adversarial training**.

Architecture du Residual cGAN



Limites du Residual cGAN


Limite 1 : forte sensibilité à l'hyperparamètre λ_{adv}

Problème identifié

- λ_{adv} **trop faible** : sous-estimation des événements extrêmes ;
- λ_{adv} **trop élevé** ($> 0,005$) : surestimation des extrêmes.

Solution adoptée

- **Contrainte d'intensité** : terme supplémentaire qui pénalise la surestimation des extrêmes.




Limites du Residual cGAN

Limite 2 : sous-estimation des incertitudes

- **Problème** : ensembles systématiquement « sous-dispersifs » ;
- **Comportement observé** : le modèle se comporte comme un prévisionniste trop confiant ;
- **Conséquence** : fourchette de résultats trop étroite.

Exemple concret

Au lieu de prédire « il pourrait pleuvoir entre 10 et 50 mm », le modèle propose une fourchette trop restreinte (ex. 20–25 mm) qui ne reflète pas l'incertitude météorologique réelle.







Impact : sous-estimation des risques climatiques

Le **ResDiff** (modélisation par diffusion résiduelle) sépare le problème en **deux étapes**, comme un flux décomposé en **moyenne** et **perturbations** :

- **Étape 1 — Régression (moyenne)**. Un réseau (souvent **U-Net**) prédit l'état moyen attendu haute résolution $\mathbb{E}[x \mid y]$ à partir du bas-résolution y : structure large correcte, aspect souvent lissé.
- **Étape 2 — Diffusion (résidu)**. Un modèle génératif apprend uniquement le **résidu** $x - \mu$: bruitage puis **débruitage** progressif pour retrouver les détails et fluctuations manquants.

La sortie finale est $\mathbf{x} = \boldsymbol{\mu} + \mathbf{r}$: **moyenne** + **résidu** débruité.

Architecture du ResDiff



Limites du ResDiff

Hypothèse de stationnarité invalide (robustesse OOD)

Explication. Les modèles profonds comme ResDiff apprennent des corrélations statistiques à partir de l'historique et supposent que les liens entre grande échelle et météo locale restent **constants**. Or le climat change : la distribution des données évolue (**OOD**), et les « raccourcis » appris deviennent **obsoètes** — le modèle généralise mal aux scénarios futurs.

Exemple

Si, dans le passé, un vent d'une certaine direction coïncide souvent avec 20 °C, le modèle peut appliquer cette règle de façon rigide. Dans un futur plus chaud où la même situation amène 25 °C, l'échec vient du fait qu'il s'appuie sur l'**habitude statistique**, pas sur la **cause physique**.

Limites du ResDiff

Ignorance du contexte physique (risque d'aberrations)

Explication. Les modèles de diffusion excellent pour le détail textural (résidus), mais traitent souvent les champs comme des **canales d'image**. Ils n'incorporent pas nativement la thermodynamique ni le relief : des **incohérences physiques** entre variables peuvent apparaître.

Exemple

Pour un même lieu et un même jour, le modèle peut produire une carte où $T_{\min} > T_{\max}$: aberration à la fois **mathématique** et **physique**, que le réseau ne reconnaît pas comme impossible sans contraintes explicites.


Autres limites des modèles DL en désagrégation

1. Violation des contraintes physiques inter-variables

Explication. Les modèles prédisent souvent chaque variable météo de façon **isolée**, sans imposer les lois naturelles qui les lient. Sans « compréhension » de la thermodynamique, ce sont des **calculs indépendants** par canal — d'où des sorties **incompatibles** entre elles.

Exemple

Pour une même journée et un même lieu, le modèle peut estimer $T_{\min} = 25^{\circ}\text{C}$ et $T_{\max} = 20^{\circ}\text{C}$: impossible physiquement ($T_{\min} > T_{\max}$), car aucune **contrainte dure** n'impose $T_{\min} \leq T_{\max}$.



Autres limites des modèles DL en désagrégation

2. Manque d'interprétabilité

Explication. Les réseaux profonds se comportent comme des **boîtes noires** : la prévision est fournie, mais pas le **raisonnement** sous-jacent. L'opacité favorise l'apprentissage de **coïncidences** (relations fallacieuses) dans le passé.

Exemple

Des analyses « ouvrent la boîte noire » : certains modèles s'appuient sur des champs **géographiquement hors sujet** (humidité ou vents lointains, ex. Pacifique) pour le climat local — **fausse corrélation globale**. Analogie : prédire la pluie à Paris en observant des signaux à l'autre bout du monde, sans logique locale pour des climats futurs inédits.

Comparaison cGAN et ResDiff — architecture et objectif

Les deux modèles **génératifs** corrigent le défaut des approches déterministes (ex. U-Net) : **lissage** des champs et **sous-estimation des extrêmes**. Ils diffèrent par l'architecture et la manière de produire la variabilité fine.

cGAN (réseau antagoniste conditionnel)

- **Générateur** : cartes haute résolution à partir du bas-résolution + bruit.
- **Discriminateur** : distingue les images synthétiques des observations réelles.
- Entraînement par **compétition** entre les deux réseaux.

ResDiff (diffusion sur résidu)

- **Étape 1** : régression déterministe (souvent U-Net) → **moyenne** conditionnelle (structures larges : fronts, typhons...).
- **Étape 2** : diffusion entraînée sur les **résidus** (vérité — moyenne) : bruitage puis débruitage progressif.

Comparaison cGAN et ResDiff — stabilité et extrêmes

Stabilité et réglages

- **cGAN** : entraînement **instable** ; qualité très sensible à λ_{adv} (équilibre difficile).
- **ResDiff** : diffusion en général **stable** ; travailler sur les **résidus** (faible variance, centrés) réduit le bruit et le nombre d'étapes de débruitage.

Extrêmes et réalisme

- **cGAN** : meilleur que le déterministe, mais risque de **sous-estimer** les extrêmes si λ_{adv} trop faible, ou **hallucinations** / surestimation si trop élevé → souvent une **contrainte d'intensité** dans la perte.
- **ResDiff** : le squelette déterministe ancre les phénomènes majeurs ; la diffusion ajoute la **texture stochastique**. Bonne fidélité aux spectres et aux lois de puissance des extrêmes, avec moins de corrections *ad hoc*.

Comparaison cGAN et ResDiff — incertitude et bilan

Ensembles et dispersion

- **cGAN** : risque d'**effondrement de mode** et d'ensembles **sous-dispersifs** (scénarios trop semblables, modèle trop confiant).
- **ResDiff** : meilleure **diversité** d'échantillons et couverture des modes; scores d'incertitude (ex. **CRPS**) souvent plus réalistes, enveloppe probabiliste plus cohérente.

Bilan

Le **cGAN** a remplacé utilement le lissage déterministe, mais reste **fragile** : réglages fins (λ_{adv}), contraintes pour les extrêmes, incertitude souvent peu fiable. Le **ResDiff** sépare **moyenne interprétable** et **résidu stochastique**, avec meilleure stabilité, moins d'hallucinations graves et une incertitude plus exploitable — base compatible avec des extensions **causales** (ex. moteur SCM) pour la robustesse climatique.

Notre principe fondateur : la causalité comme moteur central

Les analyses montrent que toute **séparation artificielle** du problème (moyenne / résidu, encodeur / prédicteur, etc.) conduit à des échecs **hors distribution** (OOD). Il faut une architecture **unifiée** où la causalité n'est ni un simple post-traitement ni une correction résiduelle en surcroupe.

L'innovation clé : le SCM doit être le moteur récurrent lui-même.


La transition dynamique $H(t) \rightarrow H(t+1)$ doit être l'**assignation structurelle causale**.

ST-CDGM — *Spatio-Temporal Causal-Dynamic Generative Model*


Introduction d'une architecture où **tout le processus génératif** est gouverné par un **modèle causal structurel** (SCM), et non par une couche causale ajoutée *a posteriori*.

Architecture globale (ST-CDGM)

Basse Résolution
(LR) - Carte Floue




2. Causal Residual Module
(Causal RCN)




1. Baseline Generator
(Lissage NetCDF / Interpolation)

Baseline
(Approximation Physique)





Baseline

3. Diffusion Decoder (UNet)



+

Haute Résolution
(HR) finale -
Carte Détaillée




Résidu
(Détails Fins)

Le RCN : unité causale récurrente

Le **RCN** (*Recurrent Causal Network*) est le **cerveau logique** du modèle : au lieu de seulement « lire » des champs comme des images, il encode des **règles physiques** sur les relations entre variables (température, pression, humidité, vent. . .).

À chaque pas de temps, le RCN enchaîne deux briques : un **SCM** (structure causale, DAG) puis une **mise à jour temporelle** (GRU) qui fusionne cette logique avec les **facteurs externes** $x(t)$ et la mémoire $H(t - 1)$.


Cellule RCN — architecture, pertes et pénalisation



Étape 1 : SCM — le plan de vol théorique

Analogie : avant de regarder le **radar**, le pilote s'appuie sur la **physique** et sa mémoire de la situation.


- **Entrées** : l'état caché précédent $H(t - 1)$ et la structure du graphe (**matrice d'adjacence** A_{dag}).
- **Traitement** : les MLP structurels appliquent les relations du DAG — *si la pression évolue ici, le vent réagit ainsi*.
- **Sortie** : la **prédiction causale** $\hat{H}(t)$: ce qui devrait se passer si les contraintes du graphe sont respectées.



Étape 2 : GRU — la mise à jour avec la réalité

Analogie : le pilote **regarde les instruments** : il fusionne le plan théorique avec les mesures réelles du moment.

- **Entrées** : les facteurs externes $x(t)$ (basse résolution) passent par un **encodeur** en **embedding** ; on réutilise $\hat{H}(t)$ issu de l'étape 1.
- **Traitement** : le **GRU** mélange embedding et $\hat{H}(t)$, avec portes z , r et état candidat $\tilde{h}$ — mémoire de ce qu'il faut **garder** ou **corriger**.
- **Sortie** : le nouvel état $H(t)$, réinjecté au pas suivant et envoyé comme **guidage** au décodeur (UNet / diffusion).



Pourquoi séparer logique puis observation ?

Trois piliers, comme un vêtement sur mesure : patron $\rightarrow$ ajustement $\rightarrow$ couture

On peut voir la chaîne **SCM** $\rightarrow$ **GRU** $\rightarrow$ **UNet** comme trois étapes de fabrication : le **patron** (la logique), l'**ajustement** (la réalité mesurée), la **couture finale** (le détail haute résolution).

- 1 **Cohérence** — « **garde-fou physique** » (**SCM**). Avant l'« apparence », le graphe impose des règles : certaines combinaisons T , humidité, pression... sont **impossibles** — comme éviter la neige « décorative » au désert à 40 °C. **Effet** : un cadre physique solide ; pas de phénomènes absurdes.
- 2 **Précision** — « **pied sur terre** » (**GRU**). La théorie SCM peut être rigide ; le **GRU** confronte $\hat{H}(t)$ aux **mesures réelles** $x(t)$ à l'instant t : « la théorie disait ceci, les capteurs voient cela ». **Effet** : une prédiction **possible** et alignée sur le ciel observé.
- 3 **Vers la carte** — « **du croquis au chef-d'œuvre** » (**UNet**). $H(t)$ rassemble les **instructions** (croquis d'architecte) ; le **UNet** de diffusion les transforme en image riche : textures, nuages, vents locaux. **Effet** : passage d'un schéma logique à une **peinture** haute résolution guidée, pas un dessin au hasard.

Synthèse

SCM = vérité **physique** ; **GRU** = vérité du **moment** ; **UNet** = **précision visuelle**. Ce n'est pas seulement une belle image : c'est une **simulation** exploitable pour les climatologues.

Intérêt pour le downscaling climatique

- ❶ **Réduire les hallucinations** — « **GPS qui connaît les murs** » (**DAG**). Une **hallucination** : le modèle produit du plausible mais **faux** (ex. nuages « photogéniques » là où l'air est trop sec). Le **DAG** encode des règles physiques : comme un GPS qui interdit de franchir un mur même si la route *semble* libre. **Résultat** : moins de beaux tirages *impossibles*; des simulations scientifiquement plus **valides**.
- ❷ **Climat changeant** — « **la recette, pas seulement le goût** » (**causalité**). Le futur ne copiera pas le passé : mémoriser des **corrélations** historiques fait échouer le modèle sur une canicule ou un extrême **inédit**. Apprendre les **causes** stables (ex. lois liant température et humidité) reste valide quand le climat se déplace. **Résultat** : meilleure **généralisation hors distribution** face aux événements rares.
- ❸ **Explicabilité** — « **copie avec le brouillon** » (**auditabilité**). Une boîte noire ne suffit pas : le climatologue doit pouvoir **suivre le raisonnement**. Le graphe causal trace les chemins : « ce vent *parce que* la pression a chuté ici et l'humidité était là ». **Résultat** : module **auditable** — on vérifie et critique chaque étape, pas une intuition magique.

*Au-delà d'un gain technique : une **démarche scientifique** — d'une IA qui imite la météo à une IA qui **comprend** et **explique** le climat.*

Entraînement : pertes et poids λ

Métaphore : l'IA est un **étudiant** ; la **fonction de perte** joue le **professeur** qui « corrige la copie » selon plusieurs critères — les **poids λ** règlent l'importance de chaque critère dans la note globale.

Pénalités et gradients : toute erreur définit un **gradient** (la flèche sur la copie) qui remonte vers **SCM** (logique), **GRU** (mémoire / instant t) et **UNet** (dessin) pour ajuster les **poids**.

- 1 $\lambda_{\text{causal}} / \mathcal{L}_{\text{causal}}$ — « **respect des lois physiques** ». Ex. pluie prédite alors que l'air est totalement sec $\Rightarrow$ forte pénalité. **But** : réfléchir comme un physicien (chaîne cause $\rightarrow$ effet du SCM).
- 2 $\lambda_{\text{recurr}} / \mathcal{L}_{\text{recurr}}$ — « **raccord de la scène** ». La météo est un **film** : $H(t)$ doit suivre $H(t-1)$. Soleil puis blizzard une seconde après $\Rightarrow$ pénalité. **But** : éviter les sauts incohérents dans le temps.
- 3 $\lambda_{\text{det}} / \mathcal{L}_{\text{det}}$ — « **précision du dessin** ». On compare le détail (résidu / branche déterministe) à l'observation réelle : flou ou décalage $\Rightarrow$ pénalité. **But** : une haute résolution réellement nette et alignée.
- 4 $\lambda_{\text{valid}} / \mathcal{L}_{\text{valid}}$ — « **logique sans boucle** ». Pas de cercle vicieux (« A cause B, B cause C, C cause A ») : le graphe doit rester un **DAG**. **But** : structure causale valide (acyclique).
- 5 $\lambda_{\text{sp}} / \mathcal{L}_{\text{sp}}$ — « **rasoir d'Occam** » (parcimonie sur A_{dag}). Trop de liens inutiles pour coller au bruit $\Rightarrow$ pénalité. **But** : graphe plus simple, plus lisible, moins surchargé.

Pourquoi ces λ ?

Chaque λ est un **bouton** : augmenter λ_{causal} favorise la rigueur physique au possible détriment du fini visuel ; augmenter λ_{det} pousse la netteté des détails au risque de moins respecter la logique. L'enjeu est le **juste équilibre** : à la fois **logicienne**, **observatrice** du réel et **précise** sur l'image.

Du RCN à la carte haute résolution

- **Guidage du UNet** : $H(t)$ fournit une **structure logique** instantanée ; la diffusion « peint » les détails compatibles avec ce guidage causal.
- **Stabilité temporelle** : le GRU lisse l'évolution de H d'une image à la suivante (séquences plus naturelles).
- **Réalisme physique** : vents, gradients et cohérence inter-variables alignés sur le SCM et les pénalités.

En résumé

Sans RCN : image HD possiblement **crédible visuellement mais fausse physiquement**. Avec RCN : prédictions **contrôlées** par une logique causale explicite et par des pertes ciblées sur la structure et le temps.

Protocole expérimental : environnement et logiciel

Matériel : entraînement sur une instance **48 CPU**, **128 Go RAM**, **250 Go** disque.

Temps : environ **15 h** pour un cycle de **20 époques**.

Logiciel :

- Langage : **Python 3.10**.
- Deep learning : **PyTorch $\geq 2.1.0$** , **PyTorch Geometric (GNN)**, **Hugging Face diffusers 0.36.0**.
- Données : **Xarray** pour lire les **NetCDF (.nc)**, **Dask** pour le calcul par blocs.

Protocole expérimental : données

Source NetCDF, entrées LR et cible HR

Fichiers : le pipeline lit directement des **NetCDF (.nc)** — format standard en climatologie qui garde latitudes, longitudes et unités : rien n'est perdu entre l'extraction et l'entraînement.

Entrées basse résolution (15 champs) : pour chaque nœud de la grille 23×26 , le modèle reçoit le vent u, v, w , l'humidité q et la température t à **850, 500 et 250 hPa** (basse, moyenne et haute atmosphère).

Cible haute résolution : précipitations p_r sur une grille 172×179 — d'une vue « large » à une carte de pluie fine (environ $\times 7-8$ en résolution), en restant physiquement cohérent.

Pour l'article

Préciser grilles et niveaux de pression assure la **reproductibilité** et montre la prise en compte de la structure **3D** de l'atmosphère (pas seulement la surface).

Protocole expérimental : données

Prétraitement et séquences temporelles

Prétraitement :

- **Moyenne / écart-type** sur les entrées : toutes les variables sont à la même échelle (évite qu'une grandeur écrase les autres, par ex. température vs vent).
- **log1p** sur **pr** : souvent 0, parfois des pluies très fortes; le logarithme compresse les extrêmes et étire les faibles valeurs — utile pour les pluies légères *et* les tempêtes, en lien avec les bons scores aux centiles élevés (p95, p99).

Dimension temporelle :

- **seq_len** = 8 : le modèle voit **8 pas consécutifs**; le **RCN (GRU)** suit la trajectoire des masses d'air.
- **Stride** = 2 : la fenêtre glisse de 2 pas entre deux échantillons — plus d'exemples d'entraînement, moins de redondance entre fenêtres voisines.

Chaîne complète

Ce tenseur nourrit le **SCM** pour extraire les relations de cause à effet avant que la **diffusion** ne dessine

Protocole expérimental : optimisation

Contexte et optimiseur (Adam)

Ces choix ne sont pas arbitraires : le modèle mélange **récence** (RCN), **causalité** (SCM) et **diffusion** — une combinaison difficile à stabiliser.

La configuration privilégie la **stabilité** et des résultats **fiables** plutôt que la vitesse pure d'entraînement, ce qui convient à un travail de recherche (Master 2) où l'on veut des courbes exploitables et peu de crashes (NaN).

Optimiseur retenu : Adam — adaptatif par paramètre, standard en deep learning.

Pourquoi Adam ici ? Les champs (vent, humidité, température, etc.) ont des échelles et des dynamiques très différentes ; Adam gère bien ce type de signaux hétérogènes. Il convient aussi aux pertes **multi-termes** (plusieurs composantes dans $\mathcal{L}_{\text{total}}$).

Protocole expérimental : optimisation

Taux d'apprentissage et taille de lot

Taux : 2×10^{-4} — relativement **modeste**
(souvent 10^{-3} en routine).

Pourquoi ce pas ? En **diffusion**, on vise une précision fine : un pas trop grand peut faire « sauter » au-dessus du bon minimum. Avec le module **récurrent** (RCN / GRU), un pas plus faible limite les instabilités aux premières époques.

Taille de lot : **48** échantillons par itération.

Pourquoi 48 ? Avec des grilles HR (172×179) et des séquences de **8** pas, la mémoire (RAM / VRAM) fixe souvent le plafond. 48 est un compromis : assez grand pour des gradients **stables**, assez petit pour tenir dans l'environnement (ex. 128 Go RAM) sans saturer.

Protocole expérimental : optimisation

Clipping de gradient : 1,0

Valeur retenue : norme du gradient bornée à **1,0**.

Pourquoi ici ? Les blocs **récurrents** (GRU dans le RCN) sont sensibles à l'**explosion des gradients** : des valeurs trop grandes mènent à NaN et arrêtent l'entraînement. Le clipping impose un plafond — une **ceinture de sécurité** classique.

Protocole expérimental : hyperparamètres du modèle

Trois réglages qui relient la « réflexion » (état interne) à la **création** de l'image HR.

- ❶ **Espace latent (dimension 128) — résumé intelligent.** L'atmosphère est immense; le modèle compresse l'information utile dans seulement **128 dimensions** — comme résumer un film en **128 mots-clés** : l'essentiel de la situation météo pour travailler vite sans tout stocker explicitement.
- ❷ **Diffusion (100 pas, DDPM) — nettoyer le brouillard.** À l'entraînement, on ajoute du bruit jusqu'à une image grise, puis on apprend à le retirer en **100 étapes**. L'ordonnanceur **DDPM** fixe combien de « poussière » enlever à chaque pas — comme des coups de ciseau successifs sur une statue pour affiner le détail jusqu'à une image nette.
- ❸ **Guidage causal (cross-attention) — dialogue cerveau / main.** Le **UNet** « dessine » tout en **cross-attention** avec les états du **RCN** : le décodeur *regarde* en permanence la logique physique (comme un peintre guidé par l'expert au microphone). Chaque pixel reste aligné sur les consignes causales, pas seulement sur un motif flou.

Ensemble : latent compact + diffusion nette + guidage causal $\Rightarrow$ un **simulateur climatique** guidé, pas un simple générateur d'images décoratif.

Résultats : performances globales

Introduction et corrélation spatiale

ST-CDGM (ResDiff causal) : les métriques mesurent si le modèle **voit juste** (emplacement et intensité) — image d'un **archer** et de la cible : la météo réelle.

Corrélation spatiale 0,896 — **le bon emplacement des formes.**

Elle mesure si le *dessin* des pluies sur la carte imite la réalité (fronts, zones sèches / humides). Proche de 1 $\Rightarrow$ si un front en « L » est observé sur une région, le modèle le replace au bon endroit, pas au hasard — preuve que le **SCM** oriente bien la structure spatiale.

Résultats : performances globales

MAE, MSE et CRPS

- ❶ **MAE 0,170** — **erreur absolue moyenne (*Mean Absolute Error*)**. Moyenne des écarts entre prédiction et observation sur la carte : à quel point on se trompe en **quantité** (eau, chaleur, etc.). Valeur faible $\Rightarrow$ très proche du terrain en intensité.
- ❷ **MSE 0,119** — **erreur quadratique moyenne (*Mean Squared Error*)**. Comme la MAE mais les écarts sont **au carré** : une grosse erreur compte bien plus qu'une petite. Score très bas $\Rightarrow$ peu de « ratés » extrêmes : comportement **régulier**.
- ❸ **CRPS 0,145** — ***Continuous Ranked Probability Score* (référence en météo)**. Ne regarde pas seulement la valeur ponctuelle : juge si les **incertitudes** annoncées sont réalistes. Bon CRPS $\Rightarrow$ modèle **calibré** pour un usage météorologique sérieux.

Synthèse jury : forte **corrélation** (phénomènes au bon endroit), **MSE/MAE** faibles, **CRPS** solide (probabilités dignes de confiance).

Résultats : événements extrêmes (F1)

Centiles (p95, p99) et F1-score

Prédire l'**extrême** (tempêtes, fortes pluies) est plus dur que dire « beau temps demain ». Beaucoup de modèles **lissent** et ratent les pics dangereux.

p95 et p99 — le haut de la distribution.

On classe les intensités ; **p95** $\approx$ top 5 % ; **p99** $\approx$ top 1 % (événements exceptionnels, queue *heavy tail*). Les IA classiques échouent souvent ici en prédisant une moyenne « molle ».

F1-score — équilibre de l'alarme.

Le F1 sanctionne l'**oubli** (tempête réelle non vue) et la **fausse alerte** (tempête annoncée, grand soleil). Résultats : **F1-p95** = 0,837, **F1-p99** = 0,754 — au seuil p99, le modèle a raison dans $\sim 75\%$ des cas pour des événements très rares, ce qui est **très élevé**.

Résultats : événements extrêmes (F1)

Focal Loss et enjeux

Focal Loss — forcer l'attention sur le difficile.

La météo « banale » est facile à prédire ; la Focal Loss **pénalise fortement** les erreurs sur les pixels / cas difficiles (fortes intensités). Le modèle apprend la **physique des extrêmes**, pas seulement des moyennes.

Intérêt (article / société).

Le downscaling sert aussi la **prévention** ; SCM + diffusion + Focal Loss montrent qu'on ne « gomme » pas les tempêtes pour une moyenne statistiquement confortable.

En résumé : sur la queue la plus rare (p99), le modèle reste juste dans une large fraction des cas — robustesse remarquable pour un cadre de recherche.

Résultats : synthèse (tableau)

Métrique	Valeur	Interprétation
Corrélation spatiale	0,896	Haute fidélité des motifs géographiques
CRPS	0,145	Calibration probabiliste robuste
F1 (extrême p99)	0,754	Forte capture des précipitations extrêmes
Temps / échantillon	163,8 s	Compromis précision / vitesse (15 pas DDPM)

En résumé : le module causal (SCM) et la structure résiduelle n'empêchent pas la performance brute ; ils permettent une précision forte sur les **queues de distribution** (événements rares), objectif central du downscaling climatique.