

Développement de Méthodes d'Apprentissage Automatique pour la Désagrégation Temporelle et la Mise à l'Échelle Spatiale des Données Climatiques pour les Communautés Locales

Rapport de Recherche : Limites et Solutions pour la Désagrégation
Climatique

KENFACK Leonel

Université de Dschang

19 septembre 2025

Introduction et Contexte

- **Thème du mémoire** : Développement de méthodes d'apprentissage automatique pour la désagrégation climatique
- **Objectif du rapport** : Analyser les limites du Residual C-GAN et proposer des solutions innovantes
- **Solutions étudiées** :
 - ResDiff (Residual Diffusion)
 - HG-SCM (Graphe Hétérogène - Modèle Causal Structurel)
 - IA Explicable (XAI)
- **Importance** : Fournir des prévisions climatiques à haute résolution pour les communautés locales

Aperçu du Plan

- 1 Limites du Residual C-GAN
- 2 Solutions Proposées : ResDiff
- 3 Graphe Hétérogène HG-SCM
- 4 Implémentation Combinée
- 5 IA Explicable (XAI)
- 6 Conclusion et Perspectives


Limite 1 : Haute Sensibilité à l'Hyperparamètre λ_{adv}

Problème identifié :

- λ_{adv} trop faible $\rightarrow$ sous-estime les événements extrêmes
- λ_{adv} trop élevé ($>0,005$) $\rightarrow$ surestime les événements extrêmes

Solution adoptée :

- Contrainte d'intensité
- Pénalise le modèle lors de surestimation des événements extrêmes



Limite 2 : Sous-estimation des Incertitudes

- **Problème** : Ensembles systématiquement "sous-dispersifs"
- **Comportement observé** : Le modèle agit comme un prévisionniste trop confiant
- **Conséquence** : Fourchette de résultats toujours trop étroite

Exemple concret

Au lieu de prédire "il pourrait pleuvoir entre 10 et 50 mm", le modèle propose une fourchette trop restreinte (ex : 20-25 mm) qui ne capture pas la véritable incertitude météorologique.

Impact : Sous-estimation des risques climatiques

Limite 3 : Cadre d'Évaluation Restreint

Limitations identifiées :

- Focus uniquement sur données historiques
- Pas de test d'extrapolation vers climats futurs plus chauds
- Cadre d'évaluation "parfait" vs. réalité opérationnelle




Problème majeur

Le modèle est entraîné sur des données RCM grossières, non sur des données GCM globales réelles. Des évaluations supplémentaires sont nécessaires pour un cadre opérationnel.

Limite 4 : Mode Collapse

- **Définition** : Le générateur ne produit qu'une diversité limitée d'échantillons
- **Status dans l'étude** : Pas d'impact observé, mais risque potentiel
- **Cause** : Instabilité inhérente des GANs



Autres Limites des Modèles DL en Désagrégation

1. Violation des contraintes physiques inter-variables

- Variables traitées indépendamment
- Exemple : $T_{\min} > T_{\max}$ (violation physique)


2. Manque d'interprétabilité

- Modèles "boîte noire"
- Relations non locales fallacieuses
- Utilisation d'informations géographiquement non pertinentes

3. Hypothèse de stationnarité invalide

- Relations statistiques du passé $\neq$ climat futur
- Approche "Perfect Prognosis" limitée
- Problème majeur dans un climat changeant

Violations des Contraintes Physiques



Manque d'interprétabilité





Figure 7. Saliency Dispersion Maps (SDM) for temperature at 1000 hPa for August and December (in rows) for each of the three intercompared models (in columns).

Hypothèse de stationnarité invalide



Qu'est-ce que ResDiff ?

Définition

ResDiff (Residual Diffusion) est un modèle d'IA avancé pour la désagrégation climatique, transformant des prévisions météo à grande échelle en cartes ultra-détaillées et réalistes.

Principe de base :

- Transformation : 25 km $\rightarrow$ 2 km de résolution
- Approche en deux étapes (similaire au cGAN résiduel)
- Moteur technologique : Modèles de diffusion (plus performant)



Fonctionnement de ResDiff en Deux Étapes

Étape 1 : Prédiction de la moyenne

- Réseau U-Net entraîné pour prédire l'état moyen attendu
- Version "lissée" capturant les grandes structures
- Prédiction la plus probable


Étape 2 : Génération des détails avec diffusion

- Modèle de diffusion pour générer les résidus
- Résidus = détails fins, fluctuations, incertitude
- Processus : bruit $\rightarrow$ nettoyage progressif $\rightarrow$ résultat cohérent

Avantage clé

Les résidus ont une variance beaucoup plus faible que les données brutes, rendant l'apprentissage plus facile pour le modèle.

Fonctionnement de ResDiff



Avantages de l'Approche Combinée ResDiff + HG-Causal

Cette synergie ResDiff + HG-Causal cumule quatre avantages majeurs :

1. Stabilité et Efficacité

- Bénéficie de la stabilité du processus de diffusion
- Simplicité de l'apprentissage sur résidus à faible variance

2. Robustesse et Généralisabilité

- Relations causales vs "raccourcis" statistiques
- Fiabilité accrue pour projections climats futurs (OOD)

3. Utilisation Intelligente de la Physique

- Modélisation explicite : topographie → détails fins météo
- Approche physiquement logique des résidus

4. Interprétabilité Transparente

- Explication causale de chaque prédiction
- Exemple : "Résidu pluie ajouté car pression basse + forte pente"


ResDiff : Stabilité et Fiabilité

Élimination de l'instabilité adversariale :

- Pas de compétition générateur/discriminateur
- Processus de débruitage intrinsèquement stable
- Technique émergente et fiable

Résolution du problème principal :

- Fin de la sensibilité à λ_{adv}
- Entraînement reproductible
- Performance constante



Avantages Spécifiques de ResDiff

1. Capture des extrêmes et réalisme physique

- Reproduction fidèle des phénomènes complexes (typhons, fronts froids)
- Distribution statistique robuste des événements extrêmes
- Pas de surestimation drastique

2. Meilleure quantification de l'incertitude

- Génération d'une plus grande diversité d'échantillons
- Ensembles plus dispersifs et réalistes
- Meilleure évaluation des risques

Résultat : Transformation d'une méthode prometteuse mais peu fiable en outil robuste pour la science du climat

Qu'est-ce qu'un Graphe Hétérogène HG-SCM ?

Définition :

- Structure de données représentant différents types de variables climatiques et leurs relations causales
- "Hétérogène" = variables de natures différentes (temporelles, spatiales, statiques)
- SCM = Structural Causal Model (Modèle Causal Structurel)

Principe fondamental :

- Chaque type de variable climatique = un type de nœud différent
- Les connexions représentent des relations de cause à effet
- Apprentissage automatique de la structure causale (DAG)

Avantage sur les approches classiques :

- Capture les vraies relations physiques (non de simples corrélations)
- Intégration naturelle de données multi-échelles
- Explicabilité intrinsèque du modèle

Qu'est-ce qu'un Graphe Hétérogène HG-SCM ?

Towards Human-like Perception: Learning Structural Causal Model in Heterogeneous Graph




Figure 2: Overall architecture of HG-SCM.

Pertinence du Graphe Hétérogène HG-SCM

Approche hybride s'attaquant à trois problèmes majeurs :

1. Corrélations fallacieuses (résolu par inférence causale)

- Découverte des véritables relations cause-effet
- Robustesse et généralisation améliorées

2. Manque de contexte physique (résolu par cartes de relief/pression)

- Topographie → effets orographiques
- Pression atmosphérique → systèmes météo à grande échelle

3. Résultats physiquement impossibles (résolu par contraintes dures)

- Respect des lois physiques fondamentales
- Garantie de plausibilité des résultats

Modélisation : Construction des Variables

Structure du graphe hétérogène :

Variables de Prédiction (basse résolution) :

- Température_LR, Pression_LR, Humidité_LR
- Vent_U_LR, Vent_V_LR (composantes du vent)

Variables Statiques (haute résolution) :

- Topographie_HR (relief détaillé)
- Caractéristiques_Sol_HR (porosité, albedo)

Variables Cibles (haute résolution) :

- Température_HR (min, max, moyenne)
- Précipitation_HR

Encodage : CNNs indépendants pour représentation vectorielle fixe

Apprentissage de la Structure Causale

Construction du Modèle Causal Structurel (SCM) :

- Représenté par un Graphe Orienté Acyclique (DAG)
- Apprentissage automatique à partir des données
- Minimisation d'une fonction de perte avec contrainte d'acyclicité

Exemples de liens causaux découverts :

- Pression_LR $\rightarrow$ Précipitation_HR (basses pressions causent la pluie)
- Topographie_HR $\rightarrow$ Température_HR (altitude influence température)
- Topographie_HR $\rightarrow$ Précipitation_HR (relief influence précipitations)

Intégration des Contraintes Physiques

Application au niveau du décodeur :

Principe pour les températures :

- Au lieu de prédire $T_{\min}$, T , $T_{\max}$ séparément
- Prédiction de $T_{\min}$ et deux différences non-négatives :
 - $\Delta T_1 = T - T_{\min} \geq 0$
 - $\Delta T_2 = T_{\max} - T \geq 0$
- Fonction ReLU pour garantir $\Delta T_1, \Delta T_2 \geq 0$

Reconstruction finale :

$$T = T_{\min} + \Delta T_1 \quad (1)$$

$$T_{\max} = T + \Delta T_2 \quad (2)$$

Garantie mathématique : $T_{\min} \leq T \leq T_{\max}$

Exemple de Diagrammes de Causalité Appris




Figure 9: Learned DAGs for different tasks: these DAGs can provide explanations of the possible causal relationships in the task. Please refer to Figure 3 for interpretation of the abbreviated relations and meta-paths.

Approche Combinée : ResDiff + HG-Causal

Clarification des rôles : ResDiff répond à "QUOI ?"

- Décomposition intelligente
- Prédiction = Moyenne + Résidus
- Focus sur résidus (faible variance)

HG-Causal répond à "COMMENT ?"

- Relations cause-effet
- Robustesse et généralisation
- Interprétabilité

Synergie optimale

Utiliser le modèle HG-Causal comme "dénoyauteur" intelligent à l'intérieur du processus de diffusion de ResDiff pour prédire les résidus.

Étapes d'Implémentation

Étape 1 : Prédiction de la moyenne (μ)

- Modèle de régression (U-Net, MLP, Random Forest)
- Partie "facile" et déterministe
- Capture des grandes structures

Étape 2 : Prédiction des résidus (r) avec diffusion causale

- Dénoyauteur = Architecture graphe causal hétérogène
- Variable cible du graphe = résidu r (non prédiction finale x)
- Apprentissage du DAG reliant prédicteurs aux résidus

Prédiction finale : $x = \mu + r$

Fonctionnement en Pratique

Phase d'entraînement :

- Données historiques complètes (toutes variables connues)
- Construction du diagramme de causalité (DAG)
- Apprentissage des fonctions de transformation

Phase de prédiction (exemple : scénario 2080) :

- 1 Données GCM basse résolution + cartes statiques haute résolution
- 2 Encodage des entrées
- 3 Propagation via chemins causaux pertinents uniquement
- 4 Décodeur contraint → cartes haute résolution physiquement cohérentes

Avantages combinés : Simplicité, robustesse, généralisabilité, interprétabilité

Implémentation de l'IA Explicable (XAI)

Deux approches complémentaires :

1. Approche de diagnostic (post-hoc) :

- Cartes de saillance (Integrated Gradients)
- "Carte de chaleur" montrant influences des entrées
- Révèle les zones géographiques utilisées pour chaque prédiction

2. Approche inhérente (conception) :

- Inférence causale via HG-SCM
- Diagramme de causalité = explication intrinsèque
- Modèle dont le fonctionnement est transparent

Exemple

Pour prédire la température à Paris, quelles informations sur la carte européenne le modèle utilise-t-il le plus ?

XAI : Amélioration des Performances

Impact indirect (cartes de saillance) :

- Diagnostic pour sélection de modèles
- Révélation de relations fallacieuses invisibles aux métriques standard
- Exemple : UNET (comportement local) vs DeepESD/PAN (relations non-locales)

Impact direct (modèles causaux) :

- Relations cause-effet invariantes
- Robustesse Out-Of-Distribution (OOD)
- Généralisation améliorée pour climats futurs

Résultat clé

XAI permet d'écarter les modèles qui "trichent" et de sélectionner ceux ayant appris les bonnes règles physiques, garantissant de meilleures performances sur données inconnues.

Exemples et Impacts de XAI

Cartes de saillance révélatrices :

- Modèle UNET : Focus local et physiquement logique
- Modèles DeepESD/PAN : Utilisation d'informations géographiquement non pertinentes
- Détection de corrélations fallacieuses statistiques mais non physiques

Conséquences pratiques :

- Modèles avec bonnes métriques mais mauvais comportement révélé par XAI
- Performance désastreuse sur climats futurs pour modèles "tricheurs"
- UNET maintient performance grâce à comportement physiquement cohérent

Message clé : L'explicabilité n'est pas qu'un bonus, c'est un gage de fiabilité pour les applications climatiques critiques.

Conclusion et Perspectives

Synthèse des solutions proposées :

- **ResDiff** : Stabilité et réalisme physique améliorés
- **HG-SCM** : Causalité et contraintes physiques intégrées
- **XAI** : Fiabilité et interprétabilité garanties

Lien avec le mémoire :

- Amélioration significative de la désagrégation climatique
- Prévisions haute résolution fiables pour communautés locales
- Outil robuste pour évaluation des risques climatiques

Perspectives futures :

- Conceptions d'une architecture détaillée

Bibliographie



A Reliable Generative Adversarial Network Approach for Climate Downscaling and Weather Generation.



Multi-Variable Hard Physical Constraints for Climate Model Downscaling.



Using Explainability to Inform Statistical Downscaling Based on Deep Learning Beyond Standard Validation Approaches.



Regional climate model emulator based on deep learning : concept and first evaluation of a novel hybrid downscaling.



Using Machine Learning to Cut the Cost of Dynamical Downscaling.



Generative Residual Diffusion Modeling for Km-scale Atmospheric Downscaling.



Deep generative model super-resolves spatially correlated multivariate climate data.



Convolutional conditional neural processes for local climate downscaling.



Spatial downscaling of precipitation using adaptable random forests.



HG-SCM : Heterogeneous Graph as Structural Causal Model for climate