





**Développement de Méthodes
d'Apprentissage Automatique pour la
Désagrégation Temporelle et la Mise à
l'Échelle Spatiale des Données
Climatiques pour les Communautés
Locales**



A Reliable Generative Adversarial Network Approach for Climate Downscaling and Weather Generation

Neelesh Rampal, Peter B. Gibson, Steven Sherwood, Gab
Abramowitz and Sanaa Hobeichi



01

Rappel de la
dernière
présentation






Les methodes existantes

Désagrégation dynamique (Dynamic Downscaling) : Cette approche basée sur la physique utilise des modèles climatiques régionaux (RCMs) pour augmenter la résolution spatiale.

1. On prend les résultats d'un modèle climatique global.
2. On les "zoome" dans une région avec un modèle plus précis qui prend en compte le relief, les vents, la mer, etc.
3. Le modèle simule physiquement le climat dans cette région (température, pluie, vents...).







Les methodes existantes

Désagrégation statistique/empirique : Elle consiste à trouver des algorithmes plus efficaces en termes de calcul tels que la régression linéaire multiple, les perceptrons multicouches, les analogies statistiques et les flux normalisés.

1. On analyse des données passées (climat global ↔ climat local).
2. On crée une formule ou une règle qui permet de prédire le climat local à partir du global.
3. Ces relations sont simples, souvent linéaires.





Les methodes existantes

ML/Deep learning : Il y a eu une tendance vers ces algorithmes, comme les réseaux de neurones convolutionnels (CNNs), qui sont meilleurs pour apprendre des relations non-linéaires complexes et ont généralement surperformé les algorithmes statistiques et d'apprentissage automatique traditionnels.

1. On donne au modèle beaucoup de données (globales et locales).
2. Il apprend tout seul à reconnaître des relations complexes, même non linéaires.
3. Il peut faire des prédictions sans règles explicites et s'adapte mieux à des contextes nouveaux.





02

Quelles sont les limitations ?

A Reliable Generative Adversarial Network Approach for Climate Downscaling and Weather Generation






Approches déterministes


La principale limitation connue actuellement est la sous-estimation des événements extrêmes et lissage des prédictions en d'autres termes, les approches déterministes ont tendance à vouloir ramener à la norme les événements extrêmes. Par exemple, en cas de violent d'orage, et de sécheresse extrême, le modèle va lisser cette prédiction pour nous ramener vers quelque chose de plus "normale", comme s'il avait du mal à nous croire.



Les causes

Les méthodes déterministes ou certains algorithmes d'apprentissage profond comme les CNNs, sont conçues pour prédire l'état moyen ou la valeur la plus probable à un moment précis et en un lieu donné. Elles cherchent à minimiser l'erreur entre leur prédiction et la réalité ponctuelle.





Les consequences

Le fait de rechercher toujours la moyenne nous font perdre la variabilité et la fréquence d'événement spécifique: Ces modèles ont donc des difficultés à saisir les petits détails très locaux ou très rapides :

- Distinguer où l'adverse est la plus intense dans une région
- Comment la pluie évolue sur une courte période

Elles peuvent prédire de la pluie, mais pas à quel point elle est intense, ni à quelle fréquence des averses très intenses se produisent, encore moins où et quand avec précision.





La solution ?

Les GANs (Les Réseaux Antagonistes Génératifs), une avancée récente en apprentissage automatique, sont présentés comme une solution potentielle à ces lacunes des méthodes déterministes. Contrairement à ces derniers qui ont tendance à prédire une valeur unique basé sur une moyenne (ce qui leur rend lisse), les GANs quant à eux, en tant que générateur, créent un ensemble de prévisions possibles pour le même scénario d'entrée.





Comment ca marche ?

Le **générateur** prend en entrée les informations climatiques a basse résolution et le bruits stochastique et essaie de créer un échantillon a haute résolution qui semble aussi reel que possible. Son objectif est de tromper le Discriminateur.


Dans le cas du cGAN utilise ici, le générateur utilise aussi la prédiction de précipitation à haute résolution issue d'un modèle déterministe U-Net (*ypred UNET*) et des données d'élévation à haute résolution comme entrées supplémentaires








Comment ca marche ?


Le discriminateur quant à lui reçoit les vrai données a haute résolution ou des fausses (venant du generateur) ainsi que des informations contextuelles comme les prédictions de précipitation du modèle déterministe, la topographie et les champs de circulation à grande échelle. Son but est de pouvoir distinguer les vrai donnees, des fausses et ainsi agir en bon critique pour le générateur qui lui s'améliorer pour pouvoir duper le discriminateur.



(a) c-GAN Training Framework







03

Matériel et
données de l'étude








Configuration du RCM

Dans cette étude, le modèle utilisé pour les obtenir des données haute résolution à partir des GCM est le CCAM (~12km) qui se distingue du RCM en permettant d'avoir de meilleurs détails au bords de la région grâce au spectral nudging.

Région Cible : Bien que le CCAM soit un modèle global, les efforts d'émulation se sont concentrés sur la région de la **Nouvelle-Zélande**. Dans cette région, la face de plus haute résolution du CCAM est quasi-uniformément de 12 km.






Configuration du RCM

Cette région a été choisie comme une étude de cas idéale pour tester les limites de l'émulation RCM en raison de ses divers microclimats. Ces microclimats résultent de la géographie complexe de la Nouvelle-Zélande, incluant des côtes, des montagnes, et sa position aux moyennes latitudes.

La Nouvelle-Zélande est également exposée à divers phénomènes météorologiques, tels que les cyclones tropicaux et les rivières atmosphériques, ainsi qu'à des moteurs climatiques à grande échelle comme El Niño-Southern Oscillation (ENSO) et le Southern Annular Mode (SAM)




(a) Generator Architecture



(b) Discriminator Architecture

Outputs





04


Entrainement du Modele






Paramètres d'Entraînement

- **Optimiseurs utilisés :**
 - Le générateur et le discriminateur sont entraînés avec l'optimiseur Adam.
 - La ligne de base déterministe (U-Net) est également entraînée avec l'optimiseur Adam.
- **Taille de lot (Batch Size) :**
 - Fixée à 32 pour tous les modèles.
- **Durée de l'entraînement :**
 - Chaque modèle est entraîné pendant 200 époques.
 - Cela représente environ 48 heures d'entraînement sur un seul GPU NVIDIA A100 (avec 80 Go de RAM).





05

Evaluation des metriques






Qualité des Prévisions

Plusieurs outils sont utilisés pour vérifier si nos modèles reproduisent fidèlement la pluie :


- **Distribution des précipitations (LHD) :**
 - Ce que ça mesure : Est-ce que le modèle prévoit la bonne fréquence de pluies (légères, fortes, extrêmes) par rapport à la réalité ?
 - Pourquoi c'est important : Les modèles classiques sous-estiment souvent les pluies extrêmes. Un score LHD plus faible signifie une meilleure ressemblance.





Qualité des Prévisions

- **Détails spatiaux de la pluie (RALSD) :**
 - Le modèle capture-t-il les petites structures et les détails fins des zones de pluie ?
 - Les modèles ont tendance à "lisser" les prévisions. Un score RALSD plus faible indique une meilleure reproduction des détails fins.
- **Variabilité de la pluie dans le temps:**
 - Le modèle reproduit-il les variations naturelles de la pluie d'un jour à l'autre ou d'une saison à l'autre ?
 - Une valeur de 100% est l'objectif pour montrer que la variabilité est bien capturée.






1' Incertitude des Prévisions

Statistiques climatiques clés (DJF, JJA, RX1Day, CDD) : Ces métriques vérifient si le modèle prédit correctement les moyennes saisonnières de pluie pour l'été (DJF) et l'hiver (JJA), le jour le plus pluvieux de l'année (RX1Day), et la durée des périodes sans pluie (CDD). Ces indicateurs sont essentiels pour évaluer les impacts du changement climatique à long terme, et sont plus pertinents que les prévisions instantanées.






1' Incertitude des Prévisions

Fiabilité des ensembles (Histogrammes de rangs) : Cette mesure évalue si l'ensemble des prédictions générées par le cGAN capture fidèlement la véritable variabilité des résultats possibles. Un histogramme "plat" indique un ensemble bien calibré, où la valeur réelle a une chance égale d'apparaître à n'importe quel rang, ce qui est crucial pour estimer l'incertitude et la probabilité d'événements extrêmes






1' Incertitude des Prévisions

Précision et dispersion des ensembles (CRPS) : Le CRPS (Continuous Ranked Probability Score) évalue à la fois la justesse des prévisions de l'ensemble et sa capacité à représenter l'étendue de l'incertitude. C'est une mesure robuste qui est moins sensible aux petites erreurs de localisation ou d'intensité de la pluie que les méthodes classiques comme l'erreur absolue moyenne (MAE). Des scores CRPS plus faibles indiquent une meilleure performance. Des variantes "groupées" (Max4 CRPS, Max16 CRPS) récompensent les prédictions qui, même légèrement déplacées, ont la bonne intensité et la bonne étendue sur des zones plus larges.






06


Resultats





Exemple de precipitation journaliere

**(a)
GAN IC**




(a)
DJF

(i)
GAN Intensity
Constraint


Deterministic

$\lambda_{adv} = 0.0$




MAE:1.02
MBIAS:-1.02

$\lambda_{adv} = 0.005$




MAE:0.29
MBIAS:0.06

$\lambda_{adv} = 0.1$




MAE:0.21
MBIAS:0.01


Ground Truth




(ii)
GAN




MAE:1.00
MBIAS:-1.00




MAE:0.34
MBIAS:-0.29




MAE:0.31
MBIAS:-0.01




précipitations moyennes saisonnières pour l'hiver



Le jour le plus pluvieux de l'annees




durée des jours secs consécutifs (CDD)



06


Discussion






- **Extrapolation aux scénarios climatiques futurs** : L'étude s'est concentrée uniquement sur l'entraînement et l'évaluation historiques. Des recherches supplémentaires sont nécessaires pour déterminer la capacité des GAN à extrapoler aux scénarios futurs, en particulier dans les climats plus chauds. Cela pourrait nécessiter un entraînement plus large englobant les périodes historiques et futures, ainsi que diverses simulations de RCM (Modèles Climatiques Régionaux).
- **Reproduction des signaux de changement climatique** : Il est important d'évaluer la capacité de l'émulateur à reproduire les signaux de changement climatique des RCM et les changements non stationnaires, tels que les tendances des précipitations extrêmes






- **Évaluation dans le cadre imparfait** : L'étude a utilisé un cadre d'entraînement "parfait". Une évaluation plus approfondie en utilisant directement les champs prédicteurs des Modèles Climatiques Globaux (GCM) et une comparaison entre les cadres d'entraînement (parfait vs imparfait) sont nécessaires.
- **Développement de contraintes statistiques supplémentaires** : Bien que la contrainte d'intensité améliore les performances sur diverses métriques, elle montre une compétence inférieure pour le nombre de jours secs consécutifs (CDD). Il est suggéré d'appliquer des contraintes supplémentaires spécifiquement conçues pour le CDD afin d'améliorer cette métrique.





- **Généralisation à d'autres domaines et variables** : L'étude s'est limitée à la région de la Nouvelle-Zélande. Il est important de déterminer si la modification de la contrainte d'intensité et la valeur optimale de λ_{adv} sont généralisables à d'autres domaines (notamment les plus grands comme ceux du CORDEX) et pour d'autres variables (comme la température). Des tests supplémentaires sont requis pour confirmer leur robustesse.
- **Exploration approfondie de l'hyperparamètre λ_{adv}** : Il est fortement recommandé d'explorer et de tester minutieusement l'hyperparamètre λ_{adv} dans différents contextes (régions, variables cibles, architectures), car sa performance est très sensible à sa valeur.





- **Création d'un ensemble de données de référence** : Un ensemble de données de référence pour la désagrégation climatique serait une ressource précieuse pour permettre des tests et des comparaisons exhaustifs entre les différentes architectures.
- **Amélioration de la dispersion de l'ensemble et de l'exactitude** : Bien que l'augmentation de λ_{adv} et l'utilisation de la contrainte d'intensité améliorent la dispersion de l'ensemble, aucune relation claire n'a été trouvée avec l'exactitude de l'ensemble. Cela suggère que les cGANs peuvent être plus facilement ajustés pour le downscaling climatique que pour la prévision météorologique, où l'exactitude de l'ensemble est particulièrement importante.





Merci à vous

T
H
A
N
K

Y
O
U

