




**Développement de Méthodes
d'Apprentissage Automatique pour la
Désagrégation Temporelle et la Mise à
l'Échelle Spatiale des Données
Climatiques pour les Communautés
Locales**





01

Contexte et fondements du downscaling climatique par l'apprentissage automatique







La problématique...

L'échelle

Les **modèles climatiques mondiaux (GCM)** sont des outils indispensables pour comprendre le changement climatique, mais leur résolution spatiale, généralement entre 50 et 200 km, est trop grossière pour les évaluations d'impact à l'échelle locale. Pour des secteurs comme l'agriculture, la gestion de l'eau, la planification urbaine et l'évaluation des risques de catastrophes, des données à une résolution beaucoup plus fine sont cruciales.





La problématique...

E X E M P L E

Par exemple, La gestion des risques d'inondation nécessite des informations sur la distribution temporelle des précipitations intra-journalières, et non seulement le total journalier, *une distinction que les GCM ne peuvent pas faire.*



02

Évolution des méthodes de désagrégation (downscaling)






Désagrégation dynamique

Elle consiste à utiliser des modèles climatiques régionaux plus détaillés (RCM) pour simuler les processus physiques à une échelle plus petite. Cette méthode est très fiable sur le plan physique, mais elle est extrêmement coûteuse en temps de calcul, ce qui limite son utilisation

1. On prend les résultats d'un modèle climatique global.
2. On les "zoome" dans une région avec un modèle plus précis qui prend en compte le relief, les vents, la mer, etc.
3. Le modèle simule physiquement le climat dans cette région (température, pluie, vents...).






Désagrégation statistique

C'est une méthode plus rapide et moins coûteuse. Elle consiste à trouver des relations mathématiques entre les données à grande échelle et les observations locales. Cependant, elle suppose que ces relations ne changeront pas à l'avenir, une hypothèse qui peut être remise en question dans un climat en mutation.

1. On analyse des données passées (climat global ↔ climat local).
2. On crée une formule ou une règle qui permet de prédire le climat local à partir du global.
3. Ces relations sont simples, souvent linéaires.






ML/Deep Learning

L'apprentissage automatique (ML), en particulier l'apprentissage profond, a émergé comme une troisième voie prometteuse. Ces modèles sont rapides comme les méthodes statistiques, mais ils sont beaucoup plus puissants. Ils peuvent découvrir des relations complexes et non linéaires dans les données, ce qui n'était pas possible avec les méthodes précédentes, le tout sans les coûts astronomiques des modèles dynamiques.

1. On donne au modèle beaucoup de données (globales et locales).
2. Il apprend tout seul à reconnaître des relations complexes, même non linéaires.
3. Il peut faire des prédictions sans règles explicites et s'adapte mieux à des contextes nouveaux.






03

Architectures Avancées pour la Désagrégation Spatiale et Temporelle

*La **désagrégation spatiale** est souvent formulée comme un problème de "super-résolution" issu de la vision par ordinateur, où un modèle apprend à générer une image à haute résolution à partir d'une version à basse résolution.*





Les (CNN)


Les réseaux de neurones convolutionnels (CNN) constituent la pierre angulaire de la désagrégation par ML en raison de leur capacité à extraire des caractéristiques spatiales et à maintenir la cohérence spatiale. Des architectures plus sophistiquées, comme le Super-Resolution Deep Residual Network (SRDRN) et le Very Deep Super-resolution (VDSR), ont amélioré les performances, notamment pour la reproduction des extrêmes et des modèles spatiaux complexes dans des zones à topographie difficile.





Les (GAN)

Les Réseaux Antagonistes Génératifs (GANs) fonctionnent comme un jeu entre deux réseaux : un "générateur" qui crée de fausses images de précipitations, et un "discriminateur" qui doit dire si ces images sont réelles ou fausses. Ce jeu force le générateur à créer des images de plus en plus réalistes, capables de simuler des événements extrêmes . Le modèle SRGAN, par exemple, intègre des informations physiques comme la pression atmosphérique et la topographie pour améliorer la qualité de ses prédictions. Cependant, les GANs peuvent être instables pendant leur apprentissage et produire des anomalies (des "hallucinations") qui ne sont pas réalistes. Une variante appelée RaGAN permet de rendre le processus plus stable.






Les Modèles à Diffusion

A
R
C
H
I
T
E
C
T
U
R
E

Ils fonctionnent en deux étapes :

1. D'abord, ils apprennent à ajouter du bruit à une image jusqu'à ce qu'elle devienne une image de pure statique.
2. Puis, ils apprennent à faire le chemin inverse, en retirant le bruit progressivement pour recréer l'image originale.

Cette méthode permet de générer des ensembles de prévisions très diversifiés et d'une grande fidélité, ce qui est particulièrement utile pour simuler les événements extrêmes de pluie et pour estimer l'incertitude.






Modèles Hybrides

ARCHITECTURE

Des modèles hybrides, comme le R2-D2 (Regional Residual Diffusion-based Downscaling), combinent la fiabilité d'un RCM avec l'efficacité d'un modèle à diffusion, ce qui permet de réduire les coûts de calcul de 97,5 % par rapport à une désagrégation purement dynamique.

Le modèle ResDiff utilise une approche en deux étapes : une première étape de régression prédit la moyenne, et une seconde étape de diffusion modélise la différence (le "résidu"), ce qui facilite l'apprentissage et la correction des erreurs.





04

Autres architectures avancées





Autres architectures

ARCHITECTURE

De nouvelles approches étendent la désagrégation au-delà des grilles. Le modèle MiMa (Micro-Macro) combine des observations de stations météorologiques à haute fréquence (données "micro") avec les sorties de modèles numériques à plus basse résolution (données "macro") pour des prédictions à l'échelle de la minute. Son extension, Re-MiMa, utilise l'apprentissage par transfert pour faire des prédictions précises dans des zones sans capteurs en s'appuyant sur les données de quelques stations représentatives.






Autres architectures

ARCHITECTURE

Une autre innovation est l'utilisation de systèmes de prévision météorologique numérique basés sur l'IA (AI-NWP) pour un downscaling "zero-shot", c'est-à-dire que le modèle, entraîné sur des données historiques, peut être utilisé pour de nouvelles régions ou de nouvelles données sans avoir besoin d'un nouvel entraînement. De même, des techniques de fine-tuning (PEFT) comme LoRA permettent d'adapter un modèle global pré-entraîné à un domaine régional spécifique, améliorant la précision et l'efficacité de manière simple





05

La Désagrégation Spatio-Temporel le des Précipitations






Solutions architecturales

ARCHITECTURE

Une approche logique est le pipeline séquentiel, où la désagrégation spatiale est effectuée d'abord, puis suivie par la désagrégation temporelle. Des modèles de séries temporelles comme les réseaux à mémoire à long et court terme (LSTM) sont particulièrement bien adaptés pour cela, car ils peuvent analyser la séquence d'événements de pluie sur une période donnée pour en prédire la dynamique future de manière réaliste.

Les modèles MiMa et Re-MiMa ont montré qu'ils pouvaient combiner des données ponctuelles très précises et des données de modèles plus générales pour faire des prédictions à l'échelle de la minute, ce qui est une avancée majeure pour les applications en temps réel.





06

Défis et Solutions pour des Modèles Robuste et Fiables






Stratégies de correction de biais

A
R
C
H
I
T
E
C
T
U
R
E

Des techniques comme le quantile mapping sont souvent intégrées dans les processus d'entraînement pour améliorer l'alignement des sorties avec les observations. Les modèles AI-NWP, formés sur des réanalyses observationnelles (comme ERA5), peuvent implicitement corriger les biais en rapprochant les sorties des données observées. Une approche plus récente utilise un modèle de diffusion conditionnel informé des biais (Bias-aware Guided Sampling) pour réduire systématiquement les biais à chaque étape du processus de denoising.






Quantification de l'Incertitude et des Extrêmes

A
R
C
H
I
T
E
C
T
U
R
E

Les prédictions ponctuelles ne sont pas suffisantes pour la gestion des risques. La quantification de l'incertitude demeure un point faible persistant. Les modèles génératifs, et plus particulièrement les modèles à diffusion, apportent une solution prometteuse en permettant de générer des ensembles de sorties qui représentent la distribution de probabilité complète des variables climatiques.






Contraintes physiques

A
R
C
H
I
T
E
C
T
U
R
E

Des contraintes "strictes" (hard constraints) peuvent être appliquées via des couches de renormalisation qui garantissent, par exemple, la conservation de la masse entre les entrées et les sorties. Cette méthode est considérée comme plus fiable que les contraintes "souples" (soft constraints), qui ne font qu'encourager le réseau à minimiser une pénalité. Un modèle hybride physique-statistique utilise un modèle physique simple pour une "première estimation" des précipitations, ce qui permet de mieux capturer les événements extrêmes.





IA explicable (XAI)

A
R
C
H
I
T
E
C
T
U
R
E

L'IA explicable (XAI) est utilisée pour comprendre comment les modèles prennent leurs décisions. L'analyse des cartes de saillance, par exemple, permet de diagnostiquer si un modèle se concentre sur des caractéristiques physiquement pertinentes, comme la topographie, pour faire ses prédictions.





Merci à vous

T
H
A
N
K

Y
O
U

