

Guide d'étude détaillé — Soutenance ORACLE

Chaque slide expliquée pour un novice : le rôle, chaque formule décryptée terme à terme, chaque métrique et chaque résultat expliqués

KENFACK Leonel

Comment lire ce guide. Les numéros sont ceux des *pages du PDF* de la présentation (42 pages). Les pages non listées (couverture, sommaire, pages de titre de section) sont des transitions sans contenu à expliquer. Chaque slide de contenu est décrite en trois temps : **ce que montre la slide**, **l'explication simple** (le concept comme si on l'expliquait à un ami), **à retenir** (chiffres et phrases-clés). Pour les slides à **formule**, un bloc *Décryptage* explique chaque symbole et un bloc *Pourquoi cette formule est là* justifie sa présence. Pour les slides à **résultats**, un bloc *Comment lire les chiffres* explique la métrique avant le nombre. Les encadrés *Si le jury demande* préparent les questions sensibles.

Table des matières

1	Contexte et motivation (pages 4–9)	3
	Page 4 : Le climat local n'est pas un détail	3
	Page 5 : Prévoir le temps de demain ne suffit pas	3
	Page 6 : Un pixel du modèle global peut contenir une ville et un volcan	4
	Page 7 : Structure d'une image classique	4
	Page 8 : Structure d'une image climatique	4
	Page 9 : La solution : retrouver le détail que le modèle global ne voit pas	5
2	État de l'art (pages 11–12)	5
	Page 11 : La solution physique est hors de portée pour l'Afrique	5
	Page 12 : Trois familles de solutions, trois limites	6
3	Présentation de la causalité (pages 14–18)	6
	Page 14 : Corrélation : le piège hors distribution	6
	Page 15 : Causalité : la robustesse par la physique	7
	Page 16 : Formaliser : chaque variable est une fonction de ses causes	7
	Page 17 : La fonction f_i , concrètement : un petit réseau par variable	8
	Page 18 : La vraie question causale : et si on intervenait ?	8

4	Architecture (pages 20–25)	9
	Page 20 : Vue d'ensemble : l'architecture complète en deux étages	9
	Page 21 : Stage 1 : de y_{LR} à μ_{HR} , par le chemin causal	10
	Page 22 : Point de départ : la baseline par interpolation	11
	Page 23 : Zoom sur un pixel : l'interpolation ne crée rien	12
	Page 24 : Stage 2 : le conditionnement par concaténation de canaux	12
	Page 25 : Vue d'ensemble : la formule qui assemble tout	13
5	Résultats (pages 27–34)	13
	Page 27 : Protocole expérimental	13
	Page 28 : Entraînement : Google Colab, ~ 45 heures	14
	Page 29 : Le résultat central : un gain de CRPS dans tous les régimes	14
	Page 30 : Le vrai test : généraliser à des modèles climatiques jamais vus	15
	Page 31 : Une incertitude enfin fiable	16
	Page 32 : Les extrêmes, pas juste la moyenne	16
	Page 33 : Le modèle raisonne juste sous intervention	16
	Page 34 : D'où vient le gain ? L'ablation le prouve	17
6	Limites (pages 36–37)	18
	Page 36 : Ce que ce travail démontre et ce qu'il ne démontre pas	18
	Page 37 : Limite clé : le gain porte sur le niveau, pas sur la pente	18
7	Perspectives (pages 39–40)	19
	Page 39 : Court et moyen terme : enrichir le graphe, ancrer la physique	19
	Page 40 : Vers une causalité par groupes : les Cluster-DAG	19
8	Conclusion (page 42)	20
	Page 42 : Ce que ce mémoire retient	20
	Annexe — Lexique minute	20

1 Contexte et motivation (pages 4–9)

Note d'organisation. Cette partie fusionne l'ancienne section « Comprendre une image climatique » : après le problème du pixel trop gros (page 6), on explique d'abord *de quoi une image climatique est faite* (pages 7–8), puis on présente la solution (page 9). L'ordre suit la logique : problème → matière première → solution.

Page 4 : Le climat local n'est pas un détail

Ce que montre la slide

Quatre chiffres sur le Cameroun et l'Afrique : **22 %** (part du PIB tirée de l'agriculture pluviale), **74 %** (part de l'électricité du Nord fournie par le barrage de Lagdo), **356 000** (personnes touchées par les inondations d'octobre 2024) et **−34 %** (chute de la productivité agricole africaine depuis 1961).

Explication simple

Le but est de montrer que le climat n'est pas un sujet abstrait : au Cameroun, l'économie dépend directement de la pluie. L'agriculture *pluviale*, c'est l'agriculture sans irrigation : elle boit l'eau qui tombe, donc une sécheresse ou une inondation devient immédiatement une crise humaine et économique. Le barrage de Lagdo produit l'électricité avec l'eau du fleuve : pas de pluie en amont, pas de courant. Les inondations de 2024 montrent l'autre extrême : trop d'eau, d'un coup, sans anticipation possible. Le fil : tous ces drames auraient pu être mieux anticipés si l'on avait su, à l'avance et localement, ce qui allait arriver. C'est la porte d'entrée du mémoire.

À retenir

- 22 % du PIB : Banque mondiale, rapport climat-développement Cameroun, 2022.
- 74 % de l'électricité du Nord : Nonki et al., *Proceedings of IAHS*, 2021.
- 356 000 personnes, 84 500 hectares : OCHA, octobre 2024.
- −34 % depuis 1961 : GIEC, 6^e rapport (AR6), 2022.

Page 5 : Prévoir le temps de demain ne suffit pas

Ce que montre la slide

Trois puces qui distinguent la météo du climat et introduisent les modèles climatiques globaux (GCM).

Explication simple

C'est *la* distinction que le public confond. Une **appli météo** fait de la *prévision* : elle part de l'état réel de l'atmosphère aujourd'hui (satellites, stations, ballons) et calcule les prochains jours. Au-delà d'une à deux semaines, le chaos atmosphérique rend la prévision impossible : une petite erreur initiale explose (« effet papillon »). Un **modèle climatique (GCM)** fait de la *simulation* : il ne prédit pas le temps d'un jour précis, mais reproduit les *statistiques* du climat sur des décennies (nombre de jours de pluie, températures moyennes, extrêmes). Analogie : la météo prédit le prochain lancer de dé ; le climat prédit que sur mille lancers, chaque face sortira environ 167 fois. Anticiper à 10 ou 30 ans exige donc de simuler le climat. Mais à quelle résolution ? (transition).

À retenir

Météo = *prévoir* quelques jours depuis l'état observé. Climat = *simuler* des décennies de statistiques. Le downscaling travaille sur le second. GCM = *Global Climate Model*.

Page 6 : Un pixel du modèle global peut contenir une ville et un volcan

Ce que montre la slide

La carte du Cameroun quadrillée par la grille d'un GCM (canal température), avec un zoom sur la case du sud-ouest qui contient à la fois Douala et le Mont Cameroun. Légende : « un seul chiffre pour toute cette zone ».

Explication simple

Un GCM découpe la planète en cases d'environ 200 km de côté, car simuler la physique de toute l'atmosphère à plus fin coûterait trop cher. Résultat : tout ce qui est dans une case reçoit *une seule valeur*. Or la case montrée contient Douala (ville côtière, chaude et humide) *et* le Mont Cameroun (volcan de 4 000 m, froid au sommet, qui déclenche des pluies torrentielles sur ses flancs). Une seule valeur pour deux mondes : physiquement absurde à l'échelle locale, donc inutilisable pour décider (construire, planter, évacuer).

À retenir

Grille GCM ≈ 200 km : les GCM voient *loin dans le temps* (jusqu'à 2100) mais *flou dans l'espace*. Le pixel de l'exemple vaut $T_{850} = 292$ K ($\approx 19^\circ\text{C}$) : une moyenne qui ne représente ni la ville ni la montagne. **Ce même exemple (température, en rouge) revient page 23.**

Page 7 : Structure d'une image classique

Ce que montre la slide

À gauche un dessin (maison rouge, ciel bleu, herbe verte) ; à droite la même image décomposée en trois canaux : rouge, vert, bleu.

Explication simple

Pour un ordinateur, une image n'est pas une « photo » : c'est un tableau de nombres. Chaque pixel contient trois valeurs entre 0 et 255 (intensité de rouge, de vert, de bleu). Le toit est « rouge » parce que son canal R est élevé et ses canaux G et B faibles. En empilant les trois couches, l'œil reconstruit les couleurs. Message : **une image = plusieurs couches de nombres superposées**. C'est la clé de la slide suivante.

À retenir

1 pixel = 3 nombres (R, G, B). Une image couleur = empilement de 3 « cartes » de nombres.

Page 8 : Structure d'une image climatique

Ce que montre la slide

Cinq cartes du Cameroun empilées, chacune dans une couleur : vent zonal (u), humidité spécifique (q), vitesse verticale (w), vent méridien (v), température (t).

Explication simple

Une image climatique fonctionne comme une photo, mais ses « couleurs » sont des grandeurs physiques. Au lieu de 3 canaux R/G/B, notre entrée en a **15** : 5 variables (deux composantes du vent, vitesse verticale, humidité, température) mesurées à **3 altitudes** (850, 500, 250 hPa, soit basse, moyenne, haute atmosphère). $5 \times 3 = 15$ canaux. Chaque pixel d'entrée contient donc 15 nombres

décrivant l'état complet de l'atmosphère au-dessus de ce point. Le modèle lit ces 15 cartes grossières et produit *une seule* carte fine : la précipitation.

À retenir

15 canaux = 5 variables $\times$ 3 niveaux de pression. Mêmes variables que la référence (Rampal et al.), pour rester comparable. hPa (hectopascals) = niveaux de pression $\approx$ altitudes : 850 hPa $\approx$ 1,5 km, 500 hPa $\approx$ 5,5 km, 250 hPa $\approx$ 10 km.

Page 9 : La solution : retrouver le détail que le modèle global ne voit pas

Ce que montre la slide

À gauche une grille grossière ; à droite la même région en grille fine où apparaissent rivière et relief ; entre les deux, la flèche « DOWNSCALING, facteur ≈ 50 ».

Explication simple

Le *downscaling* (mise à l'échelle) transforme l'image grossière du GCM en une image fine, à ~ 5 km, où les détails locaux réapparaissent. Le facteur ≈ 50 vient du rapport des tailles (~ 250 km / ~ 5 km). Point important : on n'*invente* pas le détail à partir de rien, on l'*apprend*. Le modèle est entraîné sur des années où l'on possède à la fois la version grossière *et* la version fine ; il apprend la correspondance, puis l'applique à de nouvelles images grossières. Même principe que la super-résolution de photos, mais sous contraintes physiques.

À retenir

Downscaling = grossier $\rightarrow$ fin, facteur ≈ 50 . Dans notre cas : entrée 23×26 pixels $\rightarrow$ sortie 172×179 pixels, sur la Nouvelle-Zélande.

Si le jury demande : « Pourquoi la Nouvelle-Zélande et pas le Cameroun ? » — Parce qu'il faut, pour entraîner et évaluer, une vérité terrain haute résolution de qualité (~ 5 km) *et* une baseline de référence publiée (Rampal et al. 2024, CORRDIFF). Ça n'existe pas encore pour l'Afrique centrale : c'est précisément la perspective de long terme.

2 État de l'art (pages 11–12)

Page 11 : La solution physique est hors de portée pour l'Afrique

Ce que montre la slide

Trois puces sur les modèles régionaux (RCM) et leur coût.

Explication simple

La façon « propre » de faire du downscaling, c'est le modèle climatique régional (RCM) : on rejoue les équations de la physique sur une petite région à maille fine (10–50 km). Rigoureux, c'est de la vraie physique, mais extrêmement coûteux : l'exemple de Taïwan mobilise 928 cœurs de calcul en parallèle, et ce coût est à payer *pour chaque scénario*. Or les applications de risque demandent des *milliers* de scénarios. Pour l'Afrique ($< 1\%$ des capacités mondiales de calcul haute performance), cette voie est inaccessible : le continent ne peut pas produire lui-même ses projections fines ainsi.

À retenir

RCM = physique rigoureuse à 10–50 km, mais 928 cœurs pour *un seul* scénario (CWA-WRF, Taïwan); Afrique < 1 % du HPC mondial. Détail si on te pousse : ces 928 cœurs produisent ~13 h de prévision en ~20 minutes, rapide pour *une* prévision, mais une projection climatique = décennies × milliers de scénarios : le coût explose.

Page 12 : Trois familles de solutions, trois limites

Ce que montre la slide

Un tableau : trois familles d'apprentissage automatique (déterministe, générative GAN, générative diffusion) jugées sur trois critères (stabilité, extrêmes, OOD), plus la ligne ORACLE.

Explication simple

Face au coût des RCM, on se tourne vers l'apprentissage automatique. Trois familles :

- **Déterministe** (U-Net, DeepSD) : *une seule* réponse. Entraînement stable, mais comme il minimise l'erreur moyenne, il « lisse » tout et rate les extrêmes (or les extrêmes, inondations et sécheresses, sont ce qui nous intéresse).
- **Générative GAN** : deux réseaux qui s'affrontent (un générateur, un juge). Cartes réalistes avec extrêmes, mais entraînement instable (« effondrement »).
- **Générative diffusion** (CORRDIFF) : part d'un bruit aléatoire qu'elle « débruite » pas à pas vers une carte réaliste. Stable *et* bonne sur les extrêmes : c'est l'état de l'art, et notre point de départ.

Mais la colonne **OOD** (*out-of-distribution*, hors distribution) est à × pour les trois : aucune ne garantit de bien se comporter quand le climat change (conditions hors de l'entraînement). C'est le trou que vise ORACLE.

À retenir

Déterministe = stable mais lisse. GAN = réaliste mais instable. Diffusion = les deux, mais fragile hors distribution. OOD = conditions jamais vues à l'entraînement (ex. un climat plus chaud).

Si le jury demande : « En quoi CORRDIFF est-il fragile ? » — CORRDIFF (NVIDIA, Mardani et al. 2023) est un *two-stage* (régression de la moyenne + diffusion du résidu), ~60× plus rapide qu'un RCM. Faille reconnue par les auteurs eux-mêmes : la méthode suppose que la relation grossier→fin reste *stationnaire* entre entraînement et usage ; or le changement climatique fait précisément *dérivée* cette relation. On garde le two-stage, on répare la fragilité.

« Pourquoi se méfier du deep learning classique ? » — Il n'a aucune notion de physique : des réseaux entraînés séparément pour $T_{\min}$ et $T_{\max}$ prédisent $T_{\min} > T_{\max}$ dans 15–17 % des cas sous fort réchauffement (González-Abad et al.) ; et 31 réentraînements *identiques* d'un même U-Net donnent des climatologies variant d'un facteur 46 (Doury et al.). Bon en moyenne, incohérent dès qu'on pousse.

3 Présentation de la causalité (pages 14–18)

Page 14 : Corrélation : le piège hors distribution

Ce que montre la slide

Deux graphes température/précipitation. À gauche (*en distribution*) : la courbe du modèle (rouge)

colle à la réalité (noire). À droite (*hors distribution*, fond grisé) : la réalité *descend*, le modèle rouge *monte* ; une double flèche montre l'erreur qui grandit.

Explication simple

Un modèle corrélatif apprend les *associations* présentes dans ses données. Exemple réel de Nouvelle-Zélande : les jours chauds y sont majoritairement secs, parce que la chaleur vient souvent d'un anticyclone (beau temps stable). Le modèle en déduit « plus chaud $\Rightarrow$ moins de pluie ». Sur le climat d'entraînement cette règle marche très bien (graphe gauche). Mais ce n'est pas une loi de la nature : c'est une coïncidence de régime météo. Quand le climat se réchauffe (graphe droit), la vraie physique donne *plus* d'eau dans l'air, donc des pluies plus intenses, et le modèle, qui applique sa règle apprise, prédit l'*inverse*. L'erreur explose exactement là où on avait besoin du modèle.

À retenir

Corrélation $\neq$ cause. L'association « chaud = sec » vient d'un facteur caché (l'anticyclone) qui cause *les deux*. Ce facteur caché s'appelle un *confondant*.

Page 15 : Causalité : la robustesse par la physique

Ce que montre la slide

Les deux mêmes graphes, mais avec un modèle causal (courbe verte) : il colle à la réalité *aussi bien hors distribution* (à droite, il descend avec la réalité).

Explication simple

Un modèle causal ne demande pas « qu'est-ce qui va ensemble ? » mais « qu'est-ce qui cause quoi ? ». Ici le mécanisme est la loi de **Clausius-Clapeyron** : l'air chaud peut contenir environ 7 % de vapeur d'eau en plus *par degré*. C'est de la thermodynamique, vrai en Nouvelle-Zélande, au Cameroun, aujourd'hui et en 2100. Un modèle bâti sur ce mécanisme suit la réalité même dans un climat jamais observé, parce que le mécanisme, lui, ne change pas. C'est la promesse *théorique* de la causalité : la robustesse vient de l'invariance des lois physiques, pas de la ressemblance avec le passé.

À retenir

Clausius-Clapeyron : $\sim +7\%$ d'humidité par degré. Phrase-clé : « une corrélation est vraie *quelque part* ; un mécanisme est vrai *partout* ». Nuance honnête : c'est une promesse *théorique* ; le mémoire mesure ensuite ce qu'elle donne en pratique.

Page 16 : Formaliser : chaque variable est une fonction de ses causes

Ce que montre la slide

La formule du modèle causal structurel (SCM) de Judea Pearl :

$$V_i = f_i(\text{Pa}(V_i), U_i)$$

Décryptage de la formule (terme à terme)

- V_i : une variable observable (par exemple la précipitation, ou la température). L'indice i numérote les variables ($i = 1, \dots, 15$ chez nous).
- $\text{Pa}(V_i)$: les **parents** de V_i (*Pa* pour *parents*), c'est-à-dire ses *causes directes*. Pour la pluie : humidité, vent, température, relief.

- U_i : un **bruit propre** à V_i , tout ce qu'on ne modélise pas (turbulence, hasard local). C'est ce qui fait que deux journées « identiques » sur le papier ne donnent pas exactement la même pluie.
- f_i : le **mécanisme**, la « recette » qui transforme les causes en effet. Se lit : « V_i égale f de ses parents et de son bruit ».

Pourquoi cette formule est là

Toute la thèse repose sur l'idée « causer, pas seulement corrélérer ». Pour la mettre dans un réseau de neurones, il faut d'abord l'écrire en maths. Cette équation dit une chose forte et simple : **un effet est entièrement déterminé par ses causes directes, plus un peu de hasard**. Rien d'autre n'entre. L'ensemble des relations parent→enfant, mises bout à bout, forme un *graphe orienté sans cycle* (un DAG) : les flèches disent qui cause qui, sans boucle (une variable ne peut pas être sa propre cause).

À retenir

V_i = la variable ; $\text{Pa}(V_i)$ = ses causes directes ; U_i = le hasard propre ; f_i = le mécanisme. Exemple à citer : pluie = $f(\text{humidité, vent, température, orographie}) + \text{hasard}$.

Page 17 : La fonction f_i , concrètement : un petit réseau par variable

Ce que montre la slide

Un schéma en trois blocs : *états des parents* (pondérés par la matrice A_{dag}) → *petit réseau à 2 couches* → *nouvel état* de la variable.

Explication simple

Dans un manuel de physique, f serait une formule écrite à la main. En climat, personne ne sait écrire la formule exacte de la pluie. Notre solution : chaque f_i est un **petit réseau de neurones à 2 couches** (un MLP), un par variable. Il reçoit les états de ses causes, chacun pondéré par un poids appris. Ces poids forment la matrice A_{dag} , qui *est* littéralement le graphe causal du modèle : la case (j, i) dit avec quelle force la variable j influence la variable i . Nous fixons l'*architecture* (la forme de la recette) ; l'*entraînement* trouve les *poids* (les doses).

À retenir

f_i = MLP à 2 couches, un par variable ; A_{dag} = matrice des influences = graphe causal appris. La contrainte « pas de boucle » (acyclicité) est imposée à l'entraînement par la méthode **DAGMA**, qui la rend *différentiable* (compatible avec la descente de gradient).

Page 18 : La vraie question causale : et si on intervenait ?

Ce que montre la slide

La comparaison de deux probabilités :

$$p(Y \mid X = x) \quad \text{vs} \quad p(Y \mid \text{do}(X = x))$$

Décryptage de la formule (terme à terme)

- Y : ce qu'on veut prédire (la pluie). X : la variable qu'on regarde ou qu'on manipule (la température).

- $p(Y \mid X = x)$: « la loi de Y sachant qu'on a observé $X = x$ ». C'est de l'**observation** passive : parmi les jours où X se trouve valoir x , que vaut Y ?
- $\text{do}(X = x)$: l'**opérateur do** de Pearl. Il signifie « je *force* X à la valeur x , en le coupant de ses causes habituelles ». $p(Y \mid \text{do}(X = x))$ est donc la loi de Y quand on *intervient* au lieu d'observer.

Pourquoi cette formule est là

C'est la distinction la plus subtile, et le cœur de la thèse. **Observer** : « parmi les jours où la température *est* élevée, combien pleut-il ? » Ces jours-là sont surtout des jours d'anticyclone, donc secs : la statistique est *contaminée* par le confondant. **Intervenir** : « si je *force* la température à monter, toutes choses égales par ailleurs, que devient la pluie ? » Là, l'anticyclone n'a plus son mot à dire : on isole l'effet propre de la température, et la physique répond « plus de pluie ». Un modèle vraiment causal doit donner la bonne réponse à la *seconde* question. C'est exactement ce que teste notre diagnostic Q_{int} (résultat page 33).

À retenir

Observer $\neq$ intervenir. Analogie du baromètre : observer une aiguille basse annonce la tempête, mais *forcer* l'aiguille à la main ne déclenche rien ; le baromètre est corrélé, pas causal. L'opérateur do formalise le geste « forcer, en coupant les causes ».

4 Architecture (pages 20–25)

Fil conducteur de la section (à comprendre avant les slides). L'architecture a *deux étages*. Le **Stage 1** part des 15 canaux grossiers et, en les faisant passer par le graphe causal, produit μ_{HR} : une *moyenne* haute résolution, déterministe. Le **Stage 2** est une diffusion qui ajoute le *résidu* $\hat{\delta}$: les détails fins et la part de hasard. La sortie finale est une somme de trois termes : $\hat{x}_{\text{HR}} = \text{baseline} + \mu_{\text{HR}} + \hat{\delta}$.

Le pari de conception. La causalité est mise dans l'*architecture*, pas dans la fonction de perte. Une simple pénalité (« sois puni si tu n'es pas causal ») serait contournée par un réseau expressif ; ici, l'information est *physiquement obligée* de passer par le graphe : il n'y a rien à contourner. Phrase-clé : « la causalité n'est pas une option du modèle, c'est sa tuyauterie ». Ce pari est ensuite *prouvé* par le test O3 (voir page 27) et par l'ablation (page 34).

Pourquoi la baseline apparaît après le Stage 1 (page 22) et non au début. La *baseline* est une simple interpolation de la pluie grossière sur la grille fine. Elle ne fait **pas** partie du calcul causal du Stage 1 : celui-ci part des 15 canaux bruts et construit μ_{HR} tout seul, par le graphe. La baseline, elle, ne sert qu'au **Stage 2**, à deux endroits (vérifiés dans le code) : (i) c'est l'un des trois canaux *concaténés* à l'entrée du réseau de diffusion, et (ii) c'est le champ de référence auquel on *rajoute* μ_{HR} et $\hat{\delta}$ pour reconstruire la sortie. La placer au tout début (comme si elle amorçait le Stage 1) serait trompeur : elle prend son sens juste avant le Stage 2. D'où l'ordre : Stage 1 (page 21) → baseline (page 22) → zoom pixel (page 23) → concaténation du Stage 2 (page 24) → formule de synthèse (page 25).

Page 20 : Vue d'ensemble : l'architecture complète en deux étages

Ce que montre la slide

Le pipeline complet : **Entrée LR** → **Encodeur** (15 MLP) → **Graphe** hétérogène → **RCN** (SCM + GRU + DAGMA) → **Décodeur** (→ μ_{HR}), puis **UNet EDM** (→ $\hat{\delta}$) → **Sortie HR**. Deux cadres pointillés délimitent Stage 1 (causal, déterministe) et Stage 2 (diffusion résiduelle).

Explication simple

On suit le trajet d'une image. **Stage 1 (causal, déterministe)** : l'*encodeur* traduit chacune des 15 variables en une représentation interne (un petit réseau par variable, pour rester lisible) ; le *graphe* organise ces variables en nœuds reliés par le DAG appris ; le *RCN* (réseau causal récurrent) fait circuler l'information le long des flèches du graphe, pas à pas dans le temps ; le *décodeur* reprojette sur la grille fine et produit μ_{HR} , la meilleure estimation *moyenne*. **Stage 2 (stochastique)** : un réseau de diffusion (UNet EDM) génère le *résidu* $\hat{\delta}$, les détails fins et le hasard que la moyenne ne peut pas capturer.

À retenir

Stage 1 = moyenne, causal, déterministe. Stage 2 = résidu, diffusion, stochastique. La causalité est concentrée dans le Stage 1 ; le réalisme des extrêmes vient du Stage 2. RCN = *Recurrent Causal Network* ; EDM = la variante de diffusion utilisée (Karras et al. 2022).

Page 21 : Stage 1 : de y_{LR} à μ_{HR} , par le chemin causal

Ce que montre la slide

Le détail du Stage 1 : y_{LR} (15 variables, grille 23×26) $\rightarrow$ Encodeur (15 MLP) $\rightarrow$ un *graphe causal* de nœuds (GP₂₅₀, GP₅₀₀, GP₈₅₀, et SP_HR statique : orographie/masque) $\rightarrow$ RCN (propagation par A_{dag} , 8 pas de temps) $\rightarrow$ Décodeur $\rightarrow \mu_{HR}$ (172×179). Une **flèche de boucle** au-dessus de la boîte RCN matérialise la récurrence temporelle ($H_{t-1} \rightarrow H_t, \times 8$). En bas, deux formules.

Décryptage de la formule ① — la propagation causale

$$\hat{H}_t^{(i)} = f_i \left(A_{dag}^{(i,:)} \odot H_{t-1}, x_t, \varepsilon_t^{(i)} \right)$$

C'est la formule du SCM (page 16) rendue *concrète et temporelle*. Terme à terme :

- $\hat{H}_t^{(i)}$: le **nouvel état** du nœud i , calculé au pas de temps t . C'est le « V_i » de la page 16, mais suivi dans le temps.
- H_{t-1} : l'état de *tous* les nœuds au pas de temps précédent (le vecteur mémoire du réseau récurrent).
- $A_{dag}^{(i,:)}$: la **i -ème ligne** de la matrice du graphe, les poids des arêtes qui *pointent vers* le nœud i . Un poids nul = « ce nœud n'est pas un parent de i ».
- $\odot$: le produit **terme à terme** (Hadamard). $A_{dag}^{(i,:)} \odot H_{t-1}$ garde donc uniquement les états des *parents* de i , chacun dosé par la force de son arête. C'est exactement le « $\text{Pa}(V_i)$ » de la page 16, mais *filtré par le graphe appris*.
- x_t : l'entrée du moment (les drivers grossiers injectés à ce pas de temps).
- $\varepsilon_t^{(i)}$: le bruit propre du nœud, le « U_i » de la page 16.
- f_i : le petit MLP par variable (page 17).

Pourquoi elle est là : c'est la ligne qui matérialise le pari « causalité dans l'architecture ». L'information ne peut atteindre le nœud i qu'à *travers* $A_{dag}^{(i,:)}$: si une arête vaut 0, ce parent est physiquement déconnecté, sans contournement possible. On répète l'opération sur **8 pas de temps** (c'est la boucle dessinée sur le schéma) pour laisser l'influence se propager de proche en proche dans le graphe, comme une cascade : le haut de l'atmosphère influence le milieu, qui influence la surface.

Sur la boucle récurrente (nouveau du schéma)

La flèche qui reboucle sur la boîte RCN représente **une seule** récurrence : la boucle *temporelle*. À chaque pas, l'état H_t ressort et rentre comme entrée du pas suivant, 8 fois. **Attention** : il n'y a *pas*

de deuxième boucle « sur les échantillons » (le batch). Le batch est traité *en parallèle* (vectorisé), il ne se reboucle jamais. Seul le temps est récurrent.

Décryptage de la formule ② — l'entraînement du Stage 1

$$\mathcal{L}_{\text{total}}^{(1)} = \mathcal{L}_{\text{mse}} + \alpha \mathcal{L}_{\text{rec}} + \mathcal{L}_{\text{dag}}$$

Une *fonction de perte* est le « score d'erreur » que l'entraînement cherche à rendre le plus petit possible. Ici elle est la somme de trois exigences :

- $\mathcal{L}_{\text{mse}}$: l'**exactitude**. Écart quadratique moyen entre μ_{HR} prédit et la vraie précipitation. « Sois juste. »
- $\mathcal{L}_{\text{rec}}$: la **lisibilité** (reconstruction). Elle oblige la représentation interne de l'encodeur à rester fidèle aux vraies variables physiques, au lieu de devenir un code opaque. « Reste interprétable. » α dose son importance.
- $\mathcal{L}_{\text{dag}}$: la **validité causale**. C'est la pénalité DAGMA : elle vaut 0 si A_{dag} est un vrai DAG (sans boucle) et grandit dès qu'un cycle apparaît. « Reste un graphe causal valide. »

Pourquoi elle est là : un modèle seulement précis ($\mathcal{L}_{\text{mse}}$) redeviendrait une boîte noire. Les deux autres termes sont ce qui garde ORACLE *à la fois* juste, lisible et causal, les trois en même temps.

À retenir

Formule ① = « chaque nœud n'écoute que ses parents (via A_{dag}), sur 8 pas de temps ». Formule ② = « sois juste ($\mathcal{L}_{\text{mse}}$) + reste lisible ($\mathcal{L}_{\text{rec}}$) + reste sans boucle ($\mathcal{L}_{\text{dag}}$) ». SP_HR = nœuds statiques (orographie, masque terre/mer), un par pixel HR : c'est *là*, et seulement là, qu'entre le relief.

Page 22 : Point de départ : la baseline par interpolation

Ce que montre la slide

L'image d'une carte grossière « agrandie » par interpolation sur la grille fine : plus de pixels, mais aucun détail nouveau. Légende : « Plus de pixels, aucune information nouvelle ».

Explication simple

La *baseline* est le champ de pluie grossier, simplement redimensionné (interpolation bilinéaire) à la taille fine. Elle sert de **point de départ neutre** : le champ « bête » qu'on aurait sans aucune intelligence. Elle ne contient rien de plus que le GCM, elle est juste plus grande. **Pourquoi cette slide arrive ici, et pas au début ?** Parce que la baseline n'appartient pas au Stage 1 (qui, lui, part des 15 canaux bruts et fabrique μ_{HR} par le graphe). La baseline ne sert qu'au **Stage 2** : c'est l'un des canaux qu'on lui donne en entrée (page 24) *et* le champ de référence auquel on ajoutera μ_{HR} et $\hat{\delta}$ (formule de la page 25). On l'introduit donc *juste avant* le Stage 2, là où elle prend son sens.

À retenir

Baseline = interpolation bilinéaire de la pluie grossière = point de départ sans information ajoutée. Rôle réel : entrée *et* référence du **Stage 2**, jamais du Stage 1. C'est *au modèle* de créer le détail manquant par-dessus cette baseline.

Page 23 : Zoom sur un pixel : l'interpolation ne crée rien

Ce que montre la slide

À gauche, 1 gros pixel **rouge** marqué « 19 °C ». À droite, le même carré redécoupé en 36 petits pixels... tous à 19 °C (même couleur). Légende : « aucun gain d'information ». On utilise ici la *température* (en rouge), pour rester cohérent avec le pixel du slide 6.

Explication simple

C'est la démonstration visuelle de la slide précédente, illustrée sur une température. Interpoler, c'est répartir la même valeur sur plus de cases : on passe de 1 à 36 pixels, mais ils portent tous la *même* valeur (19 °C). On a plus de pixels, zéro information supplémentaire. La conclusion motive tout le reste : le détail fin ne peut pas venir de l'agrandissement ; il doit être *créé* par le modèle (μ_{HR} du Stage 1 pour la structure, $\hat{\delta}$ du Stage 2 pour la texture).

À retenir

Interpolation = « même couleur, même valeur ». Le vrai travail commence après la baseline. Phrase-clé : « agrandir n'est pas deviner ».

Si le jury demande : « Pourquoi 19 °C et pas 200 km ? » — Piège classique : un pixel porte *deux* informations distinctes. Sa **valeur** (ce qu'il contient : ici 19 °C de température) et sa **taille** (son étendue au sol : ~ 200 km pour le GCM, ~ 5 km pour la cible). Le « 19 °C » est la *valeur*, pas la taille. La slide montre la valeur parce que le message est « l'interpolation recopie la même valeur » ; l'axe *taille* (~ 200 km $\rightarrow$ ~ 5 km) est représenté, lui, par la subdivision 1 pixel $\rightarrow$ 36 pixels. Passer de 200 km à 5 km = subdiviser ; garder 19 °C partout = ne rien inventer.

Page 24 : Stage 2 : le conditionnement par concaténation de canaux

Ce que montre la slide

L'image de trois cartes empilées (comme les canaux R, G, B) : c'est ce qu'on donne en entrée au réseau de diffusion. La slide ne porte qu'une image (la légende explicative a été retirée pour l'épurer, mais le concept ci-dessous reste à connaître).

Explication simple

Comment le Stage 2 « sait-il » quoi générer ? Par **concaténation de canaux**, exactement comme une image couleur empile R, G, B. On empile trois cartes en entrée du réseau de diffusion : (1) le résidu bruité en cours de débruitage, (2) μ_{HR} (la moyenne causale du Stage 1) et (3) la baseline. Le réseau lit ces trois couches superposées et génère le résidu $\hat{\delta}$ cohérent avec elles. Point capital pour le récit causal : parmi ces canaux, **le seul qui porte de l'information causale, c'est μ_{HR}** (la baseline est neutre, page 22, le canal bruité est du bruit). Donc si le Stage 2 fait mieux que CORRDIFF, c'est bien la causalité du Stage 1 qui a transité par ce canal.

Décryptage (ce qui est réellement passé au réseau, vérifié dans le code)

Entrée du UNet = [$\hat{\delta}_{\text{bruité}}$, μ_{HR} , baseline] empilés sur l'axe des canaux. **Concaténer $\neq$ additionner** : on *juxtapose* trois cartes pour *conditionner* (informer) la génération ; on ne les additionne qu'à la toute fin, pour *reconstruire* le champ (formule page 25). Aucune variable statique (relief) n'entre ici : le relief est déjà passé au Stage 1 (nœuds SP_HR).

À retenir

Stage 2 conditionné par **concaténation** de 3 canaux [bruit, μ_{HR} , baseline]. μ_{HR} = l'unique canal porteur de causalité. Concaténer (informer) au début $\neq$ additionner (reconstruire) à la fin.

Page 25 : Vue d'ensemble : la formule qui assemble tout

Ce que montre la slide

Le pipeline complet (rappel), puis la formule de synthèse avec ses trois sous-accolades.

Décryptage de la formule — la reconstruction finale

$$\hat{x}_{\text{HR}} = \underbrace{\text{baseline}}_{\text{interpolation}} + \underbrace{\mu_{\text{HR}}}_{\text{Stage 1 (causal)}} + \underbrace{\hat{\delta}}_{\text{Stage 2 (diffusion)}}$$

- $\hat{x}_{\text{HR}}$: la carte de pluie fine *finale* produite par ORACLE (le « chapeau » signifie « estimé »).
- **baseline** : le point de départ neutre (interpolation, page 22). Il donne l'ordre de grandeur général.
- μ_{HR} : la **correction causale** du Stage 1, la structure grande échelle que le graphe a su déduire (là où il pleut plus/moins, pilotage par l'humidité/le vent/le relief).
- $\hat{\delta}$: le **résidu stochastique** du Stage 2, la texture fine et la part de hasard (les cellules orageuses, les pointes locales).

Pourquoi cette formule est là (et pourquoi elle justifie l'ordre des slides)

C'est l'équation-mère de toute l'architecture : elle montre que la sortie est une **somme de trois contributions empilées**, chacune avec un rôle distinct. Elle rend aussi limpide le placement de la baseline : celle-ci est un *terme de la somme finale*, aux côtés de μ_{HR} (Stage 1) et $\hat{\delta}$ (Stage 2). Elle ne « lance » pas le Stage 1, elle *referme* le calcul. D'où sa présentation juste avant le Stage 2. Répartition des rôles : la baseline situe, μ_{HR} structure (causal), $\hat{\delta}$ texture (réalisme des extrêmes).

À retenir

$\hat{x}_{\text{HR}} = \text{baseline} + \mu_{\text{HR}} + \hat{\delta}$. Trois briques : *situer* (baseline), *structurer* (μ_{HR} , causal), *texturer* ($\hat{\delta}$, diffusion). Le gain de skill vient des deux dernières ; la causalité, uniquement de μ_{HR} .

5 Résultats (pages 27–34)

Page 27 : Protocole expérimental

Ce que montre la slide

Deux encadrés. **Données (Nouvelle-Zélande)** : entraînement 1980–2009, validation 2010–2012, test 2013–2014 (ACCESS-CM2) ; généralisation sur EC-Earth3 et NorESM2-MM (GCM jamais vus). **Évaluation** : baseline *Noncausal* = CORRDIFF réentraîné à l'identique. Bandeau : « comparaison strictement appariée : seule la causalisation du Stage 1 change ». (*Le slide a été allégé : les dimensions [15 canaux 23×26 → 172×179] et la liste des métriques ne sont plus écrites dessus, mais restent à savoir. Les métriques sont détaillées dans les slides de résultats ; les 2 diagnostics causaux, ci-dessous.*)

Explication simple

Cette slide établit la *rigueur* de la comparaison. Le point décisif est la **comparaison appariée** : la baseline « Noncausal » est *exactement* CORRDIFF, réentraîné avec les mêmes données, le même protocole, la même famille d'architecture ; *la seule* différence est la causalisation du Stage 1. Donc tout écart de performance mesuré est attribuable à notre contribution, pas à un détail d'implémentation

ou à un jeu de données plus favorable. Les 4 familles de métriques couvrent des aspects complémentaires (erreur, calibration probabiliste, texture, extrêmes) ; les 2 diagnostics causaux testent la *mécanique* interne (le graphe sert-il ? le modèle raisonne-t-il juste sous intervention ?).

Les deux diagnostics causaux, en clair

- **O3** (le « test du graphe à zéro ») : on met le graphe à zéro ($A_{\text{dag}} \leftarrow \mathbf{0}$) et on mesure combien on perd. Formellement $\Delta_{O3} = \text{MSE}(\mu_{\text{HR}}(\mathbf{0})) - \text{MSE}(\mu_{\text{HR}}(A_{\text{dag}}))$, et le ratio $\Delta_{O3}/\text{MSE}(A_{\text{dag}}) = \mathbf{0,87}$ (proche de 1) : couper le graphe casse presque tout, donc l'information *passé réellement* par le graphe (il n'est pas décoratif).
- Q_{int} (le test d'intervention) : on *force* une hausse de température et on vérifie que la pluie prédite bouge dans le bon sens (résultat page 33).

À retenir

Train 1980–2009 / Val 2010–2012 / Test 2013–2014 sur ACCESS-CM2 ; généralisation sur 2 GCM jamais vus. Noncausal = CORRDIFF à l'identique. « Strictement apparié » = la seule variable qui change est la causalité $\Rightarrow$ le gain lui est imputable. O3 = le graphe est indispensable (ratio 0,87) ; Q_{int} = réponse correcte sous intervention.

Page 28 : Entraînement : Google Colab, ~45 heures

Ce que montre la slide

Un encadré **Ressources** (entraînement sur Google Colab avec GPU, ~45 heures au total) et un petit tableau **Deux étages, deux budgets** : Stage 1 (causal, déterministe) = **15 époques**, Stage 2 (diffusion résiduelle) = **200 époques**.

Explication simple

Cette slide chiffre le *coût* de l'entraînement, et renforce le message applicatif du début (pages 11–12) : là où un RCM demande 928 cœurs d'un supercalculateur, ORACLE s'entraîne en ~45 heures sur **Google Colab**, une ressource gratuite et grand public. Une *époque* est un passage complet sur toutes les données d'entraînement. Les deux étages ont des budgets très différents parce que leurs tâches diffèrent : le Stage 1 (régression de la moyenne causale) converge vite, **15 époques** suffisent ; le Stage 2 (diffusion) doit apprendre à générer de la texture fine à partir de bruit, tâche plus difficile qui demande **200 époques**.

À retenir

~45 h sur Google Colab (GPU). Stage 1 = 15 époques (la moyenne converge vite), Stage 2 = 200 époques (la diffusion en demande plus). Message : un entraînement à la portée d'un laboratoire modeste, sans supercalculateur. Chiffres tirés de la configuration réelle du projet.

Page 29 : Le résultat central : un gain de CRPS dans tous les régimes

Ce que montre la slide

Un tableau de CRPS (mm/j) sur trois régimes, comparant ORACLE, Noncausal, et le gain relatif :

Régime	ORACLE	Noncausal	Gain
En distribution	0,249	0,415	–40 %
Inter-GCM (EC-Earth3 / NorESM2)	0,319 / 0,342	0,457 / 0,478	–30 / –28 %
Hors distribution (froid / chaud)	0,389 / 0,288	0,561 / 0,444	–31 / –35 %

Comment lire les chiffres — d’abord, qu’est-ce que le CRPS ?

Le **CRPS** (*Continuous Ranked Probability Score*) est la métrique des prévisions probabilistes. ORACLE ne produit pas une carte mais un *ensemble* de cartes (plusieurs tirages). Le CRPS compare la *distribution* prédite (l’ensemble) à la valeur réellement observée, en récompensant deux choses à la fois : la *justesse* (être centré au bon endroit) et l’*honnêteté de l’incertitude* (ni trop sûr, ni trop vague). Il est en mm/jour, et **plus il est bas, mieux c’est**. Un gain « -40% » signifie donc « 40% d’erreur probabiliste en moins ».

Comment lire les chiffres — les trois régimes, du plus facile au plus dur

- **En distribution** (données du même type que l’entraînement, le régime facile) : 0,249 contre 0,415, soit -40% . C’est le résultat-phare.
- **Inter-GCM** : on teste sur deux *autres* modèles climatiques jamais vus. Le gain se maintient : -30% (EC-Earth3), -28% (NorESM2). Preuve que le modèle n’a pas appris par cœur les « tics » de son GCM d’entraînement.
- **Hors distribution (froid / chaud)** : climats artificiellement décalés vers le froid ou le chaud. Le gain tient encore : -31% / -35% .

Le message : *le gain ne s’effondre pas* quand on s’éloigne des conditions d’entraînement, il reste du même ordre partout.

À retenir

CRPS bas = distribution prédite proche du réel. Gain qui *tient* de la distribution (-40%) aux climats jamais vus (-28 à -35%). Nuance à préparer (voir page 37) : c’est le *niveau* d’erreur qui reste meilleur ; la *pente* de dégradation, elle, est comparable à la baseline.

Page 30 : Le vrai test : généraliser à des modèles climatiques jamais vus

Ce que montre la slide

Les courbes de *période de retour* (loi de Gumbel) sur les GCM jamais vus : ORACLE suit la vérité, la baseline sature en dessous. Légende : robustesse inter-GCM -30% (EC-Earth3), -28% (NorESM2-MM).

Comment lire les chiffres — qu’est-ce qu’une période de retour ?

Une **période de retour** de « 100 ans » désigne un événement si intense qu’il n’arrive en moyenne qu’une fois par siècle (probabilité 1% par an). L’axe horizontal va des événements fréquents (à gauche) aux événements rares (à droite) ; l’axe vertical donne l’intensité de pluie correspondante. Un bon modèle doit suivre la courbe de la *vérité* jusqu’aux événements rares. « **Saturer en dessous** » veut dire que la baseline plafonne : elle est incapable de produire les pluies extrêmes, elle les rabote. ORACLE, lui, suit la vérité plus loin.

Comment lire les chiffres — pourquoi tester sur d’autres GCM ?

On ne peut pas attendre 2050 pour vérifier la robustesse. Astuce standard : entraîner sur *un* GCM (ACCESS-CM2) et évaluer sur *d’autres* jamais vus (EC-Earth3, NorESM2-MM). Chaque GCM a sa « personnalité » (biais, dynamique propres) : changer de GCM est un vrai *déplacement de distribution*, une répétition générale du changement de climat. Que le gain tienne (-30% / -28%) prouve que le modèle a appris quelque chose de *transférable*, pas les tics d’un GCM.

À retenir

Inter-GCM : -30% (EC-Earth3), -28% (NorESM2-MM). ORACLE suit la courbe des extrêmes là où la baseline sature. C’est le test de robustesse le plus proche du vrai changement climatique disponible sans attendre le futur.

Page 31 : Une incertitude enfin fiable

Ce que montre la slide

Un diagramme de fiabilité (courbe d'ORACLE proche de la diagonale idéale, baseline en dessous) et le *ratio spread-skill* : $0,20 \rightarrow 0,69$ ($\times 3,5$).

Comment lire les chiffres — calibration et spread-skill

Un modèle probabiliste doit être **calibré** : quand il annonce « 90 % de chances de pluie », il doit pleuvoir dans 90 % de ces cas. Le *diagramme de fiabilité* trace la probabilité annoncée contre la fréquence réelle ; un modèle parfait suit la *diagonale*. Le **ratio spread-skill** compare deux quantités qui devraient être égales : le *spread* (à quel point les membres de l'ensemble s'écartent les uns des autres, c'est-à-dire l'incertitude que le modèle *s'attribue*) et le *skill* (l'erreur *réelle* de sa moyenne). Idéalement, ce ratio vaut **1** : le modèle est aussi incertain qu'il a raison de l'être.

- Baseline à **0,20** : son ensemble est ~ 5 fois *trop resserré*. Elle affiche une confiance qu'elle ne mérite pas, dangereux pour décider (on croit savoir, on se trompe).
- ORACLE à **0,69** : pas parfait, mais **3,5 fois plus honnête**. Ses intervalles de confiance commencent enfin à vouloir dire quelque chose.

À retenir

Spread-skill : $0,20 \rightarrow 0,69$ ($\times 3,5$). En dessous de 1 = trop confiant ; à 1 = calibré. Phrase-clé : « quand ORACLE dit 'je suis sûr', on peut enfin le croire ».

Page 32 : Les extrêmes, pas juste la moyenne

Ce que montre la slide

Deux grands chiffres : distance spectrale **RAPSD divisée par 450** vs CORRDIFF ; biais **RX1day ramené de $-4,1$ à $-2,7$ mm**.

Comment lire les chiffres — deux mesures complémentaires

- **RAPSD** (*Radially Averaged Power Spectral Density*, distance spectrale) vérifie que l'image a la bonne *texture*. Une vraie carte de pluie est *granuleuse*, avec des cellules orageuses fines ; un modèle qui lisse produit une image « floue » dont le spectre spatial est faux. « Divisée par 450 » signifie que notre distance au spectre réel est **450 fois plus petite** que celle de la baseline : nos cartes ont la texture du réel, pas la sienne.
- **RX1day** est un indice climatique standard : le *maximum annuel de pluie en un jour*, l'indicateur direct des inondations. Un *biais* négatif signifie qu'on *sous-estime* cet extrême. La baseline le sous-estime de 4,1 mm en moyenne ; ORACLE, de 2,7 mm : biais réduit d'un tiers. Or sous-estimer les extrêmes, c'est *sous-dimensionner les digues*.

À retenir

RAPSD $\div 450$ (texture réaliste) ; biais RX1day $-4,1 \rightarrow -2,7$ mm (extrêmes moins sous-estimés). Les extrêmes sont l'enjeu applicatif n° 1 : c'est ce qui déborde, pas la moyenne.

Page 33 : Le modèle raisonne juste sous intervention

Ce que montre la slide

Des cartes de réponse à une perturbation contrôlée, et un tableau : sous une hausse de température au niveau 850 hPa, ORACLE répond $+0,84 \times 10^{-3}$ (*cohérent CC*), la baseline répond $-0,84 \times 10^{-3}$ (*contraire CC*).

Comment lire les chiffres — le test d'intervention Q_{int}

C'est l'application concrète de l'opérateur do de la page 18. **Protocole** : on prend une entrée réelle, on *force* artificiellement une hausse de température ($+\Delta t_{850}$, le geste do), et on mesure comment la pluie prédite bouge. La physique (Clausius-Clapeyron) impose le **signe** de la réponse : plus chaud $\Rightarrow$ plus d'eau disponible $\Rightarrow$ réponse *positive*. Le tableau donne la variation de pluie ($\times 10^{-3}$, unités normalisées) :

- ORACLE : $+0,84 \times 10^{-3}$, signe *positif*, cohérent avec la physique.
- Noncausal : $-0,84 \times 10^{-3}$, signe *négatif*, à l'envers. La baseline rejoue l'association « chaud = sec » de la Nouvelle-Zélande : c'est le piège corrélatif de la page 14, *pris en flagrant délit*.

Ce qui compte ici, c'est le **signe**, pas l'amplitude : le test vérifie que le modèle *raisonne* dans le bon sens, pas qu'il donne l'amplitude exacte.

À retenir

Q_{int} : ORACLE donne le *bon signe* (+), la baseline le *mauvais* (-). C'est la démonstration *expérimentale* de la différence corrélation/causalité. Honnêteté à garder : le *signe* est correct, l'*amplitude* reste inférieure à la théorie ; c'est un contrôle de cohérence directionnelle, pas un outil de projection.

Page 34 : D'où vient le gain ? L'ablation le prouve

Ce que montre la slide

Un tableau d'*ablation* (CRPS), quatre variantes du plus complet au plus pauvre :

Variante	CRPS	Lecture
ORACLE complet (A_{dag} appris)	0,508	référence
$A_{\text{dag}} = \mathbf{0}$ (graphe coupé)	0,522	+2,7 %
A_{dag} aléatoire (même norme)	0,529	+4,2 %
Noncausal (baseline)	0,592	+16,6 %

Comment lire les chiffres — qu'est-ce qu'une ablation ?

Une **ablation**, c'est *retirer un organe* pour voir ce qu'il faisait. On compare quatre variantes à protocole identique (donc les écarts sont imputables au seul composant retiré). Comme c'est du CRPS, *plus bas = mieux* ; les pourcentages sont la dégradation par rapport à ORACLE complet (0,508). Lecture, ligne par ligne :

- **Couper le graphe** ($A_{\text{dag}} = \mathbf{0}$) dégrade de +2,7 % $\Rightarrow$ le graphe *sert* (cohérent avec le test O3, page 27).
- **Le remplacer par un graphe aléatoire** (même « taille », mais arêtes fausses) dégrade *davantage* (+4,2 %) que de le couper $\Rightarrow$ résultat contre-intuitif et fort : **une structure fausse est pire que pas de structure**. Ce sont donc bien les *bonnes* connexions qui comptent, pas la simple présence d'une structure.
- **La baseline** est à +16,6 % : l'écart *total* entre ORACLE et le Noncausal.

Comment lire les chiffres — la décomposition 84 / 16

On peut découper l'écart total (16,6 %) en deux morceaux : ce qu'apporte l'*architecture two-stage causale elle-même* (~ 84 % du gain) et ce qu'ajoute la *structure fine du DAG* (~ 16 %). Autrement dit : l'essentiel du gain vient d'avoir *obligé* l'information à passer par un chemin causal (le two-stage), et un supplément vient de la *qualité* précise des arêtes apprises.

À retenir

$0,508 < 0,522 < 0,529 < 0,592$. Phrase-clé : « un graphe faux fait *pire* qu'aucun graphe : la structure apprise porte une information réelle ». Décomposition : $\sim 84\%$ two-stage, $\sim 16\%$ structure fine du DAG. Le gain est *attribuable pièce par pièce*, pas un effet de hasard.

6 Limites (pages 36–37)

Page 36 : Ce que ce travail démontre et ce qu'il ne démontre pas

Ce que montre la slide

Deux encadrés : *démontré* / *non démontré*.

Explication simple

Annoncer soi-même ses limites est la meilleure défense en soutenance. **Démontré** : gain de skill mesurable (en distribution et inter-GCM), indispensabilité du chemin causal (O3), réponse correcte sous intervention. **Non démontré** : (1) le graphe appris n'est pas *identifié* au sens strict de Pearl : ses flèches ne coïncident que partiellement avec la physique attendue ($Q_{\text{phys}} = 0,40$ à 6 nœuds) ; c'est une limite *théorique connue* de l'apprentissage sur données d'observation, pas un bug. (2) Aucune donnée africaine testée. (3) Un seul entraînement (une seule graine), par contrainte de calcul.

Comment lire le chiffre Q_{phys}

Q_{phys} mesure la *fidélité du graphe appris à la physique attendue* : quelle proportion des arêtes attendues sont retrouvées et bien orientées. $Q_{\text{phys}} = 0,40$ à 6 nœuds = le graphe capte une partie de la physique, mais pas tout. Distinction de vocabulaire essentielle : notre modèle est **structurellement causal** (l'information passe *obligatoirement* par le graphe, vérifiable et vérifié par O3) sans que le graphe soit **causalement identifié** (ses flèches = la vraie physique, non garanti). Les deux sont différents, et on ne revendique que le premier.

À retenir

Structurellement causal (prouvé, O3 = 0,87) $\neq$ *causalement identifié* ($Q_{\text{phys}} = 0,40$, partiel). Détail rassurant si on te pousse : une variante à **9 nœuds** retrouve quasi parfaitement la structure attendue ($Q_{\text{phys}} \approx 1,0$) ; la platitude à 6 nœuds est le prix de la *lisibilité*, pas un plafond de l'architecture (voir page 39).

Page 37 : Limite clé : le gain porte sur le niveau, pas sur la pente

Ce que montre la slide

Un graphe : deux droites parallèles, ORACLE (bleu) sous Noncausal (rouge), qui montent toutes deux avec « l'éloignement du climat » ; une double flèche « écart constant » entre les deux.

Explication simple

C'est la limite la plus importante à comprendre, et le point où il faut être précis pour ne pas se contredire avec les résultats. Sur l'axe horizontal, on s'éloigne du climat d'entraînement ; sur l'axe vertical, l'erreur (CRPS) monte pour *les deux* modèles. ORACLE reste *en dessous* (*meilleur niveau*, $\sim 1,4\times$ meilleur), mais sa droite a *la même pente* que la baseline : quand on s'éloigne, il se dégrade *au même rythme*. Autrement dit, la causalité, telle qu'implémentée ici, améliore le **point de départ** (le niveau d'erreur) mais pas encore la **robustesse différentielle** (la vitesse de dégradation).

Pourquoi ce n'est pas une contradiction avec les pages 29–30

Le gain « qui se maintient » (pages 29–30) et « la même pente » (ici) sont *compatibles* : l'écart *constant* entre les deux droites, c'est exactement le gain qui se maintient. Ce qui n'est *pas* encore acquis, c'est que l'écart *grandisse* en s'éloignant ; ce serait la vraie promesse théorique de la causalité (page 15), et c'est ce que le test SSP futur (page 39) doit trancher.

À retenir

Gain sur le *niveau* (écart constant, $\sim 1,4\times$ meilleur), pas encore sur la *pente* (même vitesse de dégradation). Formulation honnête : « la causalité améliore le point de départ, pas (encore) la robustesse différentielle ». C'est une limite *assumée*, pas un échec caché.

7 Perspectives (pages 39–40)

Page 39 : Court et moyen terme : enrichir le graphe, ancrer la physique

Ce que montre la slide

La matrice (*heatmap*) du graphe appris par la variante à 9 nœuds, et trois pistes.

Explication simple

Trois chantiers réalistes. (1) **Enrichir le graphe** : ajouter des nœuds physiquement parlants, comme IVT (les « rivières atmosphériques » qui portent l'essentiel des extrêmes côtiers), MSLP (pression au niveau de la mer), CAPE/CIN (l'énergie de la convection). La heatmap le montre : avec 9 nœuds au lieu de 6, le graphe appris retrouve les arêtes physiques attendues ($Q_{\text{phys}} \approx 1,0$) ; la machinerie causale répond dès qu'on lui donne les bonnes variables. (2) **Ancrer la physique** : guider doucement le graphe vers la structure attendue par une pénalité de *prior* (λ_{prior}). (3) Surtout, **le test SSP5-8.5** : évaluer sur un scénario futur de réchauffement, le *vrai* test hors distribution, celui qui manque encore et qui trancherait la question de la « pente » (page 37).

À retenir

9 nœuds $\Rightarrow$ structure physique retrouvée ($Q_{\text{phys}} \approx 1,0$). Le test SSP est *la* suite logique du travail : c'est lui qui dira si la causalité aplatis la pente de dégradation.

Page 40 : Vers une causalité par groupes : les Cluster-DAG

Ce que montre la slide

Deux graphes côte à côte. À gauche, « aujourd'hui : nœud $\rightarrow$ nœud » (des variables individuelles $V_1, \dots, V_4$ reliées). À droite, « demain : groupe $\rightarrow$ groupe » (trois blocs physiques, *Dynamique*, *Thermo.*, *Surface*, reliés).

Explication simple

Réponse directe à la limite Q_{phys} (page 36). Aujourd'hui, on essaie d'apprendre les arêtes *fin*es, variable par variable ; or, sur données d'observation, orienter chaque arête individuelle est fragile (d'où $Q_{\text{phys}} = 0,40$). L'idée du **Cluster-DAG** : regrouper d'abord les variables en *familles physiques* (la dynamique : vents ; la thermodynamique : température, humidité ; la surface : relief, masque), puis apprendre la causalité *entre familles*. La causalité au niveau des groupes est **plus robustement identifiable** que les arêtes fines : même si on ne sait pas dire exactement quelle variable de la

dynamique cause quoi, on peut affirmer avec confiance que « la dynamique cause la surface ». On échange un peu de finesse contre beaucoup de robustesse.

À retenir

Cluster-DAG = causalité *entre familles physiques* (dynamique / thermo / surface), plus identifiable que les arêtes fines. Réponse directe à la limite Q_{phys} . Référence : *Cluster-DAG*, Anand et al., AAAI 2023.

8 Conclusion (page 42)

Page 42 : Ce que ce mémoire retient

Ce que montre la slide

Quatre puces de synthèse, puis « Merci de votre attention ».

Explication simple

Le message final tient en une idée : la causalité **placée dans l'architecture** (et non décorative) produit trois choses *mesurables* : un *gain de performance* (−40 % de CRPS en distribution, −30 / −28 % sur des GCM jamais vus), une *incertitude honnête* ($\times 3,5$ de calibration), et un *raisonnement physiquement cohérent* sous intervention (bon signe là où la baseline inverse). Chaque mot de la conclusion est adossé à un résultat chiffré des slides précédentes ; c'est ce qui la rend solide.

À retenir

Les trois piliers à réciter : **gain** (−40 %), **robustesse** (inter-GCM −30 %), **cohérence** (Q_{int} , bon signe). Et l'horizon : un downscaling fiable pour les régions qui en ont le plus besoin.

Annexe — Lexique minute (à relire la veille)

GCM

Modèle climatique global : simule toute la planète, cases ~ 100 –250 km, horizons jusqu'à 2100.

RCM

Modèle climatique régional : même physique sur une région, 10–50 km, très coûteux (928 cœurs / scénario).

Downscaling

Passer d'une carte grossière à une carte fine (ici facteur ~ 50), en apprenant la correspondance sur le passé.

OOD (hors distribution)

Conditions jamais vues à l'entraînement, ex. un climat plus chaud. Le cœur du problème.

Confondant

Cause commune cachée qui crée une fausse association (l'anticyclone rend les jours chauds *et* secs).

SCM / DAG

Modèle causal structurel : $V_i = f_i(\text{Pa}(V_i), U_i)$; le DAG est le graphe orienté sans boucle des relations cause $\rightarrow$ effet.

A_{dag}

La matrice du graphe appris : la case (j, i) = force de l'influence de j sur i . Sa ligne i sélectionne les parents de i .

do($X = x$)

Intervention : forcer X à la valeur x en le coupant de ses causes ; répond à « que se passe-t-il si on *agit* ? ».

DAGMA

Méthode qui rend la contrainte « pas de boucle » différentiable, donc apprenable par descente de gradient ($\mathcal{L}_{\text{dag}}$).

RCN

Réseau causal récurrent : propage l'information le long des arêtes de A_{dag} sur 8 pas de temps. Une seule boucle, la temporelle ; le batch est vectorisé, pas bouclé.

Diffusion (EDM)

Modèle génératif : part d'un bruit pur et le débruite pas à pas vers une image réaliste ; le hasard du bruit donne des scénarios différents.

Two-stage

Découpage régression (moyenne μ_{HR}) + diffusion (résidu $\hat{\delta}$) ; stabilise l'entraînement et, chez nous, *force* le passage causal.

Baseline

Interpolation bilinéaire de la pluie grossière ; point de départ neutre. Sert au *Stage 2* (canal concaténé + terme de la reconstruction), pas au *Stage 1*.

$$\hat{x}_{\text{HR}} = \text{baseline} + \mu_{\text{HR}} + \hat{\delta}$$

La sortie finale : situer + structurer (causal) + texturer (diffusion).

Époque

Un passage complet sur les données d'entraînement. *Stage 1* : 15 ; *Stage 2* : 200 ; ~ 45 h sur Google Colab.

CRPS

Score d'erreur des prévisions probabilistes (distribution contre observation) ; plus bas = mieux. En distribution : 0,249 vs 0,415 (−40 %).

Spread-skill

Dispersion de l'ensemble / erreur réelle ; 1 = incertitude honnête, $\ll 1$ = trop confiant. 0,20 $\rightarrow$ 0,69.

RAPSD

Spectre spatial de l'image : vérifie que la « texture » (granularité) est réaliste. Distance $\div 450$ vs CORRDIFF.

RX1day

Maximum annuel de pluie en un jour, l'indice des inondations. Biais $-4,1 \rightarrow -2,7$ mm.

Période de retour

Rareté d'un événement (« 100 ans » = 1 % par an). La baseline *sature* sur les extrêmes rares.

Inter-GCM

Entraîner sur un GCM, tester sur d'autres : répétition générale du déplacement de distribution.

Ablation

Retirer/remplacer un composant pour mesurer sa contribution réelle. Décomposition : 84 % two-stage, 16 % DAG fin.

O3 (ratio 0,87)

Preuve que l'information passe *obligatoirement* par le graphe : $\Delta_{O3}/\text{MSE}(A_{\text{dag}})$. Proche de 1 = graphe indispensable.

Q_{int} Test d'intervention : le *signe* de la réponse à $+\Delta t$ est physiquement correct (+ pour ORACLE, − pour la baseline).

Q_{phys}

Fidélité du graphe appris à la physique attendue (0,40 à 6 nœuds ; $\approx 1,0$ à 9 nœuds). *Structurellement causal $\neq$ identifié*.