

RÉPUBLIQUE DU CAMEROUN
REPUBLIC OF CAMEROON
Peace – Work – Fatherland

UNIVERSITÉ DE DSCHANG
UNIVERSITY OF DSCHANG
Scholae Thesaurus Dschangensis Ibi Cordum

BP 96, Dschang (Cameroun)
Tél./Fax : (237) 233 45 13 81
Website : <http://www.univ-dschang.org>
E-mail : udsrectorat@univ-dschang.org



FACULTÉ DES SCIENCES
FACULTY OF SCIENCES

Département de Mathématiques et
Informatique
*Department of Mathematics and
Computer Science*

BP 67, Dschang (Cameroun)
Tél. : (237) 233 45 17 35
Website : <http://fs.univ-dschang.org>
E-mail : dept.math-info@univ-dschang.org

Développement de méthodes d'apprentissage automatique pour la mise à l'échelle spatiale des données climatiques

Par

KENFACK Leonel

CM-UDS-17SCI0998

Sous la direction de

Pr. BOMGNI Alain Bertrand

Maître de Conférences, Université de Dschang

Contexte et motivation
Comprendre une image climatique
État de l'art
Présentation de la causalité
Architecture
Résultats
Limites
Perspectives
Conclusion

Plan de présentation

- 1 Contexte et motivation
- 2 Comprendre une image climatique
- 3 État de l'art
- 4 Présentation de la causalité
- 5 Architecture
- 6 Résultats
- 7 Limites
- 8 Perspectives
- 9 Conclusion



- 1 Contexte et motivation
- 2 Comprendre une image climatique
- 3 État de l'art
- 4 Présentation de la causalité
- 5 Architecture
- 6 Résultats
- 7 Limites
- 8 Perspectives
- 9 Conclusion




Le climat local n'est pas un détail



22 %

du PIB, secteur
agricole pluvial



74 %

de l'électricité du Nord
(barrage de Lagdo)



356 000

personnes touchées,
inondations d'octobre 2024



-34 %

productivité agricole
africaine depuis 1961




Prévoir le temps de demain ne suffit pas

Météo $\neq$ climat

- Une appli météo **prévoit** quelques jours, à partir de l'état observé aujourd'hui.
- Anticiper un événement à 10 ou 30 ans demande de **simuler** le climat, pas de prévoir le temps.
- C'est le rôle des modèles climatiques globaux (GCM) — mais à quelle résolution ?




Un pixel du modèle global peut contenir une ville — et un volcan



Grille GCM de $\sim 200 \text{ km}$: un seul chiffre pour toute cette zone.

La solution : retrouver le détail que le modèle global ne voit pas




Mise à l'échelle : d'une image grossière à une image fine (facteur ~ 50).

- 1 Contexte et motivation
- 2 Comprendre une image climatique
- 3 État de l'art
- 4 Présentation de la causalité
- 5 Architecture
- 6 Résultats
- 7 Limites
- 8 Perspectives
- 9 Conclusion

Structure d'une image classique




Image normale



Décomposée : 3 canaux (R, G, B)

Chaque pixel d'une photo, c'est 3 nombres empilés.

Structure d'une image climatique



- 1 Contexte et motivation
- 2 Comprendre une image climatique
- 3 État de l'art**
- 4 Présentation de la causalité
- 5 Architecture
- 6 Résultats
- 7 Limites
- 8 Perspectives
- 9 Conclusion



La solution physique est hors de portée pour l'Afrique

- Un modèle régional (RCM) résout la physique à 10–50 km : rigoureux, mais coûteux.
- 928 cœurs mobilisés pour **un seul** scénario (CWA-WRF, Taïwan).
- L'Afrique héberge moins de 1 % des capacités HPC mondiales.



Trois familles de solutions, trois limites

Approche	Stabilité	Extrêmes	OOD
Déterministe (U-Net, DeepSD)	✓	×	×
Générative GAN (cGAN résiduel)	△	△	×
Générative diffusion (CORRDIFF)	✓	✓	×
ORACLE (ce travail)	✓	✓	△

✓ bien traité △ partiellement traité × non traité




- 1 Contexte et motivation
- 2 Comprendre une image climatique
- 3 État de l'art
- 4 Présentation de la causalité**
- 5 Architecture
- 6 Résultats
- 7 Limites
- 8 Perspectives
- 9 Conclusion




Corrélation : le piège hors distribution

En distribution




Hors distribution




Causalité : la robustesse par la physique

En distribution



Hors distribution



Formaliser : chaque variable est une fonction de ses causes


Modèle causal structurel (Pearl)

$$V_i = f_i(\text{Pa}(V_i), U_i)$$

- V_i : une variable observable (ex. la précipitation).
- $\text{Pa}(V_i)$: ses causes directes (humidité, vent, température, orographie).
- U_i : un peu de hasard propre, non modélisé.
- f_i : **apprise** par le réseau, pas écrite à la main.



La fonction f_i , concrètement : un petit réseau par variable



- f_i n'est **pas** écrite à la main : c'est un petit réseau (2 couches), un par variable.
- Son architecture est fixée par nous ; c'est l'entraînement qui trouve les poids.
- Les poids de A_{dag} pondèrent la contribution de chaque parent avant le MLP.



La vraie question causale : et si on intervenait ?

Observer $\neq$ intervenir


$$p(Y \mid X = x) \quad \text{vs} \quad p(Y \mid \text{do}(X = x))$$

- Observer T élevé $\rightarrow$ associé à moins de pluie (confondu par l'anticyclone).
- **Intervenir** sur T (do-opérateur) $\rightarrow$ isole le vrai effet physique, signe positif attendu.
- C'est précisément ce que mesure notre test Q_{int} .




- 1 Contexte et motivation
- 2 Comprendre une image climatique
- 3 État de l'art
- 4 Présentation de la causalité
- 5 Architecture**
- 6 Résultats
- 7 Limites
- 8 Perspectives
- 9 Conclusion

Vue d'ensemble : l'architecture complète en deux étages



Stage 1 : de y_{LR} à μ_{HR} , par le chemin causal




Propagation causale (par nœud) : $\hat{H}_t^{(i)} = f_i(A_{dag}^{(i,:)} \odot H_{t-1}, x_t, \varepsilon_t^{(i)})$

Entraînement (3 objectifs) : $\mathcal{L}_{total}^{(1)} = \mathcal{L}_{mse} + \alpha \mathcal{L}_{rec} + \mathcal{L}_{dag}$




Point de départ : la baseline par interpolation




Plus de pixels, aucune information nouvelle.

Zoom sur un pixel : l'interpolation ne crée rien

Avant : 1 pixel




Après : 36 pixels



Même couleur, même valeur : **aucun gain d'information**. C'est au modèle de créer le détail manquant.




Stage 2 : le conditionnement par concaténation de canaux



Trois canaux empilés, comme les canaux R, G, B d'une photo. La seule source d'information causale du Stage 2 est μ_{HR} .

Vue d'ensemble : l'architecture complète en deux étages



$$\hat{x}_{\text{HR}} = \underbrace{\text{baseline}}_{\text{interpolation}} + \underbrace{\mu_{\text{HR}}}_{\text{Stage 1 (causal)}} + \underbrace{\hat{\delta}}_{\text{Stage 2 (diffusion)}}$$



- 1 Contexte et motivation
- 2 Comprendre une image climatique
- 3 État de l'art
- 4 Présentation de la causalité
- 5 Architecture
- 6 Résultats**
- 7 Limites
- 8 Perspectives
- 9 Conclusion



Protocole expérimental

Données (Nouvelle-Zélande)

- 15 canaux LR (23×26) $\rightarrow$ précipitation HR (172×179)
- Train 1980–2009 · Val 2010–2012 · Test 2013–2014 (ACCESS-CM2)
- Généralisation : EC-Earth3, NorESM2-MM (GCM jamais vus)

Évaluation

- Baseline **Noncausal** = CORR-DIFF réentraîné à l'identique
- 4 familles (RMSE, CRPS, RAPSD, F1@p99) + 2 diagnostics causaux ($O3$, Q_{int})

Comparaison strictement appariée : seule la causalisation du Stage 1 change.



Entraînement : Google Colab, ~45 heures

Ressources

- Entraînement réalisé sur **Google Colab** (GPU)
- **~45 heures** de calcul au total

Deux étages, deux budgets

- Stage 1 (causal, déterministe) :
15 époques
- Stage 2 (diffusion résiduelle) :
200 époques

Un entraînement accessible sur ressources grand public, sans supercalculateur.




Le résultat central : un gain de CRPS dans tous les régimes

Régime (CRPS mm/j)	ORACLE	Noncausal	Gain
En distribution	0,249	0,415	−40 %
Inter-GCM (EC-Earth3 / NorESM2)	0,319 / 0,342	0,457 / 0,478	−30 / −28 %
Hors distribution (froid / chaud)	0,389 / 0,288	0,561 / 0,444	−31 / −35 %

Le gain se maintient de la distribution aux climats jamais vus.




Le vrai test : généraliser à des modèles climatiques jamais vus



Robustesse inter-GCM historique : -30% (EC-Earth3), -28% (NorESM2-MM). Le gain de niveau se maintient sur des GCM jamais vus à l'entraînement.



Une incertitude enfin fiable



Ratio spread-skill : $0,20 \rightarrow 0,69 (\times 3,5)$. Les intervalles de confiance du modèle deviennent enfin interprétables.




Les extrêmes, pas juste la moyenne

Distance spectrale RAPSD divisée par **450** vs
CORRDIFF

Biais RX1day ramené de $-4,1$ à **$-2,7$** mm



Le modèle raisonne juste sous intervention



Modèle	$\Delta(t_{850})$	Signe
ORACLE	$+0,84 \times 10^{-3}$	cohérent CC
Noncausal	$-0,84 \times 10^{-3}$	contraire CC



D'où vient le gain ? L'ablation le prouve

Variante	CRPS	Lecture
ORACLE complet (A_{dag} appris)	0,508	référence
$A_{\text{dag}} = \mathbf{0}$	0,522	+2,7 %
A_{dag} aléatoire (même norme)	0,529	+4,2 %
Noncausal (baseline)	0,592	+16,6 %

L'architecture two-stage porte 84 % du gain, la structure fine du DAG 16 %. Un DAG **aléatoire** fait pire qu'aucun DAG.



- 1 Contexte et motivation
- 2 Comprendre une image climatique
- 3 État de l'art
- 4 Présentation de la causalité
- 5 Architecture
- 6 Résultats
- 7 Limites**
- 8 Perspectives
- 9 Conclusion



Ce que ce travail démontre — et ce qu'il ne démontre pas

Démontré


Gain de skill mesurable en distribution et inter-GCM ; indispensabilité architecturale (O3) ; réponse interventionnelle cohérente.

Non démontré

DAG identifié au sens de Pearl ($Q_{\text{phys}} = 0,40$ à 6 nœuds) ; transfert au climat africain ; variabilité inter-graine (un seul entraînement).



Limite clé : le gain porte sur le niveau, pas sur la pente




ORACLE reste $\sim 1,4\times$ meilleur, mais se dégrade **à la même pente** que la baseline : la causalité améliore le point de départ, pas (encore) la robustesse différentielle.



- 1 Contexte et motivation
- 2 Comprendre une image climatique
- 3 État de l'art
- 4 Présentation de la causalité
- 5 Architecture
- 6 Résultats
- 7 Limites
- 8 Perspectives**
- 9 Conclusion




Court et moyen terme : enrichir le graphe, ancrer la physique




Vers une causalité par groupes : les Cluster-DAG

Aujourd'hui : nœud $\rightarrow$ nœud



Demain : groupe $\rightarrow$ groupe



La causalité au niveau des **groupes physiques** est plus robustement identifiable que les arêtes fines : réponse directe à la limite Q_{phys} .
Cluster-DAG, Anand et al., AAAI 2023.



- 1 Contexte et motivation
- 2 Comprendre une image climatique
- 3 État de l'art
- 4 Présentation de la causalité
- 5 Architecture
- 6 Résultats
- 7 Limites
- 8 Perspectives
- 9 Conclusion

Ce que ce mémoire retient

- La causalité comme **contrainte architecturale**, pas décoration.
- Gain de skill mesurable (-40% CRPS ID, $-30/-28\%$ inter-GCM).
- Robustesse inter-GCM et raisonnement interventionnel cohérent.
- Un pas concret vers un downscaling fiable pour les régions qui en ont le plus besoin.

Merci de votre attention.

