

RÉPUBLIQUE DU CAMEROUN
REPUBLIC OF CAMEROON
Peace – Work – Fatherland

UNIVERSITÉ DE DSCHANG
UNIVERSITY OF DSCHANG
Scholae Thesaurus Dschangensis Ibi Cordum

BP 96, Dschang (Cameroun)
Tél./Fax : (237) 233 45 13 81
Website : <http://www.univ-dschang.org>
E-mail : udsrectorat@univ-dschang.org



FACULTÉ DES SCIENCES
FACULTY OF SCIENCES

Département de Mathématiques et
Informatique

*Department of Mathematics and
Computer Science*

BP 67, Dschang (Cameroun)
Tél. : (237) 233 45 17 35
Website : <http://fs.univ-dschang.org>
E-mail : dept.math-info@univ-dschang.org

Développement d'une méthode d'apprentissage automatique pour la mise à l'échelle spatiale des données climatiques

Par

KENFACK Leonel

CM-UDS-17SCI0998

Sous la direction de

Pr. BOMGNI Alain Bertrand

Maître de Conférences, Université de Dschang

Contexte et motivation
État de l'art
Présentation de la causalité
Architecture
Protocole et entraînement
Résultats
Limites
Perspectives
Conclusion

Plan de présentation

- 1 Contexte et motivation
- 2 État de l'art
- 3 Présentation de la causalité
- 4 Architecture
- 5 Protocole et entraînement
- 6 Résultats
- 7 Limites
- 8 Perspectives
- 9 Conclusion



- 1 Contexte et motivation
- 2 État de l'art
- 3 Présentation de la causalité
- 4 Architecture
- 5 Protocole et entraînement
- 6 Résultats
- 7 Limites
- 8 Perspectives
- 9 Conclusion



Le climat local n'est pas un détail



356 000

personnes touchées,
inondations d'octobre 2024



-34 %

productivité agricole
africaine depuis 1961




Prévoir le temps de demain ne suffit pas

Météo $\neq$ climat

- Une appli météo **prévoit** quelques jours, à partir de l'état observé aujourd'hui.
- Anticiper un événement à 10 ou 30 ans demande de **simuler** le climat, pas de prévoir le temps.
- C'est le rôle des modèles climatiques globaux (GCM), mais à quelle résolution ?




Un pixel du modèle global peut contenir une ville et un volcan



Grille GCM de $\sim 200 \text{ km}$: un seul chiffre pour toute cette zone.



La solution : retrouver le détail que le modèle global ne voit pas




Mise à l'échelle : d'une image grossière à une image fine (facteur ~ 50).



Structure d'une image classique




Image normale



Décomposée : 3 canaux (R, G, B)

Chaque pixel d'une photo, c'est 3 nombres empilés.

Structure d'une image climatique



- 1 Contexte et motivation
- 2 État de l'art
- 3 Présentation de la causalité
- 4 Architecture
- 5 Protocole et entraînement
- 6 Résultats
- 7 Limites
- 8 Perspectives
- 9 Conclusion



La solution physique est hors de portée pour l'Afrique

- Un modèle régional (RCM) résout la physique à 10–50 km : rigoureux, mais coûteux.
- 928 cœurs mobilisés pour **un seul** scénario (CWA-WRF, Taïwan).
- L'Afrique héberge moins de 1 % des capacités HPC mondiales.



Trois familles de solutions, trois limites

Approche	Stabilité	Extrêmes	OOD
Déterministe (U-Net, DeepSD)	✓	×	×
Générative GAN (cGAN résiduel)	△	✓	×
Générative diffusion (CORRDIFF)	✓	△	×
ORACLE (ce travail)	✓	△	△

✓ bien traité △ partiellement traité × non traité



- 1 Contexte et motivation
- 2 État de l'art
- 3 Présentation de la causalité**
- 4 Architecture
- 5 Protocole et entraînement
- 6 Résultats
- 7 Limites
- 8 Perspectives
- 9 Conclusion



Formaliser : chaque variable est une fonction de ses causes


Modèle causal structurel (Pearl)

$$V_i = f_i(\text{Pa}(V_i), U_i)$$

- V_i : une variable observable (ex. la précipitation).
- $\text{Pa}(V_i)$: ses causes directes (humidité, vent, température, orographie).
- U_i : un peu de hasard propre, non modélisé.
- f_i : **apprise** par le réseau, pas écrite à la main.



La fonction f_i , concrètement : un petit réseau par variable



- f_i n'est **pas** écrite à la main : c'est un petit réseau (3 couches), un par variable.
- Son architecture est fixée par nous ; c'est l'entraînement qui trouve les poids.
- Les poids de A_{dag} pondèrent la contribution de chaque parent avant le MLP.



La vraie question causale : et si on intervenait ?

Observer $\neq$ intervenir


$$p(Y \mid X = x) \quad \text{vs} \quad p(Y \mid \text{do}(X = x'))$$

- Observer T élevé $\rightarrow$ associé à moins de pluie (confondu par l'anticyclone).
- **Intervenir** sur T (do-opérateur) $\rightarrow$ isole le vrai effet physique, signe positif attendu.
- C'est précisément ce que mesure notre test Q_{int} .




Corrélation : le piège hors distribution

En distribution




Hors distribution




Causalité : la robustesse par la physique

En distribution




Hors distribution




- 1 Contexte et motivation
- 2 État de l'art
- 3 Présentation de la causalité
- 4 Architecture**
- 5 Protocole et entraînement
- 6 Résultats
- 7 Limites
- 8 Perspectives
- 9 Conclusion



Vue d'ensemble : l'architecture complète en deux étages



Stage 1 : de y_{LR} à μ_{HR} , par le chemin causal




Propagation causale (par nœud) : $\hat{H}_t^{(i)} = f_i(A_{dag}^{(i,:)} \odot H_{t-1}, x_t, \varepsilon_t^{(i)})$

Entraînement (3 objectifs) : $\mathcal{L}_{total}^{(1)} = \mathcal{L}_{mse} + \alpha \mathcal{L}_{rec} + \mathcal{L}_{dag}$



Point de départ : la baseline par interpolation




Plus de pixels, aucune information nouvelle.




Zoom sur un pixel : l'interpolation ne crée rien

Avant : 1 pixel




Après : 36 pixels




Même couleur, même valeur : **aucun gain d'information**. C'est au modèle de créer le détail manquant.



Stage 2 : le conditionnement par concaténation de canaux



Vue d'ensemble : l'architecture complète en deux étages



$$\hat{x}_{\text{HR}} = \underbrace{\text{baseline}}_{\text{interpolation}} + \underbrace{\mu_{\text{HR}}}_{\text{Stage 1 (causal)}} + \underbrace{\hat{\delta}}_{\text{Stage 2 (diffusion)}}$$



- 1 Contexte et motivation
- 2 État de l'art
- 3 Présentation de la causalité
- 4 Architecture
- 5 Protocole et entraînement**
- 6 Résultats
- 7 Limites
- 8 Perspectives
- 9 Conclusion



Protocole expérimental

Données (Nouvelle-Zélande)

- Train 1980–2009 · Val 2010–2012 · Test 2013–2014 (ACCESS-CM2)
- Généralisation : EC-Earth3, NorESM2-MM (GCM jamais vus)

Évaluation

- Baseline **Noncausal** = CORR-DIFF réentraîné à l'identique

Comparaison strictement appariée : seule la causalisation du Stage 1 change.



Entraînement : Google Colab, ~45 heures

Ressources

Entraînement réalisé sur **Google Colab** (GPU), pour **~45 heures** de calcul au total.

Deux étages, deux budgets

Étage	Rôle	Budget
Stage 1	causal, déterministe	15 époques
Stage 2	diffusion résiduelle	200 époques



- 1 Contexte et motivation
- 2 État de l'art
- 3 Présentation de la causalité
- 4 Architecture
- 5 Protocole et entraînement
- 6 Résultats**
- 7 Limites
- 8 Perspectives
- 9 Conclusion


Le résultat central : un gain de CRPS dans tous les régimes

Régime (CRPS mm/j)	ORACLE	Noncausal	Gain
En distribution	0,249	0,415	−40 %
Inter-GCM (EC-Earth3 / NorESM2)	0,319 / 0,342	0,457 / 0,478	−30 / −28 %
Hors distribution (froid / chaud)	0,389 / 0,288	0,561 / 0,444	−31 / −35 %

Le gain se maintient de la distribution aux climats jamais vus.



Le vrai test : généraliser à des modèles climatiques jamais vus



Robustesse inter-GCM historique : -30% (EC-Earth3), -28% (NorESM2-MM). Le gain de niveau se maintient sur des GCM jamais vus à l'entraînement.



Les extrêmes, pas juste la moyenne

Distance spectrale RAPSD divisée par **450** vs
CORRDIFF


Biais RX1day ramené de $-4,1$ à **$-2,7$** mm



- 1 Contexte et motivation
- 2 État de l'art
- 3 Présentation de la causalité
- 4 Architecture
- 5 Protocole et entraînement
- 6 Résultats
- 7 Limites**
- 8 Perspectives
- 9 Conclusion



Limite clé : le gain porte sur le niveau, pas sur la pente




ORACLE reste $\sim 1,4\times$ meilleur, mais se dégrade **à la même pente** que la baseline : la causalité améliore le point de départ, pas (encore) la robustesse différentielle.



- 1 Contexte et motivation
- 2 État de l'art
- 3 Présentation de la causalité
- 4 Architecture
- 5 Protocole et entraînement
- 6 Résultats
- 7 Limites
- 8 Perspectives**
- 9 Conclusion




Court et moyen terme : enrichir le graphe, ancrer la physique




Vers une causalité par groupes : les Cluster-DAG

Aujourd'hui : nœud $\rightarrow$ nœud



Demain : groupe $\rightarrow$ groupe



La causalité au niveau des **groupes physiques** est plus robustement identifiable que les arêtes fines : réponse directe à la limite Q_{phys} .
Cluster-DAG, Anand et al., AAAI 2023.



- 1 Contexte et motivation
- 2 État de l'art
- 3 Présentation de la causalité
- 4 Architecture
- 5 Protocole et entraînement
- 6 Résultats
- 7 Limites
- 8 Perspectives
- 9 Conclusion

Ce que ce mémoire retient

- La causalité comme **contrainte architecturale**, pas décoration.
- Gain de skill mesurable (-40% CRPS ID, $-30/-28\%$ inter-GCM).
- Robustesse inter-GCM et raisonnement interventionnel cohérent.
- Un pas concret vers un downscaling fiable pour les régions qui en ont le plus besoin.

Merci de votre attention.

